Optimisation

Grégoire Allaire

CentraleSupélec



CentraleSupélec

Plan

1 Présentation

2 Existence et unicité

3 Critère différentiel pour la minimisation

4 Contraintes d'égalité : théorème d'Euler-Lagrange

5 Contraintes d'inégalité : théorème de Karuch-Kuhn-Tucker

6 Algorithmes de minimisation sans contraintes

7 Algorithmes de minimisation sous contraintes

Vincent Lescarret : vincent.lescarret@centralesupelec.fr

Domaine de recherche : EDP en physique mathématique
Equations hyperboliques (ondes), Schrödinger et diffusion non linéaire

Plan du cours

Optimisation continue :

1. Existence et unicité - convexité
2. Euler-Lagrange et théorème KKT
3. dualité
4. Algorithmes de détermination d'un minimum local intérieur (Gradient, Gradient Conjugué, sous-gradient, d'Uzawa,...)
5. Programmation linéaire continue - algorithme du simplexe

Optimisation Discrète

1. programmation linéaire en nombres entiers
2. Algorithme glouton, recuit-simulé
3. Technique de Branch and Bound

- Contrôle :
  - TP (3h python)
  - examen écrit de 3h
- Note finale sans projet : 80% EE + 20% TP
- Note finale avec projet :

  Max (80% EE + 20% TP, 60% EE + 20% TP + 20% PR)

Projet personnel

- Soin apporté à la modélisation mathématique du problème,
- Discussion sur l'existence d'un minimum et de son éventuelle unicité
- Application du théorème du cours correspondant à votre situation.
- Choix de l'agorithme de résolution approprié.
- Convergence de l'algorithme - validation des hypothèses
- illustrations
- Originalité : contraintes non linéaires / plusieurs minima locaux / dimension infinie / dualité / fonction coût discontinue / méthode du simplexe / problème discret
- Aide IA acceptée avec les restrictions suivantes : Pas de phrase vague ou imprécise : tout doit être justifié et compréhensible sans avoir à lire des articles ; en lien avec le cours. Rapport concis : effort de synthèse (sans compter les figures et le code)

Problématique et objectif

Trouver $u \in X_{ad}$, $X_{ad} \subset X$, tel que :

$$J(u) \leqslant J(v) \quad \forall v \in X_{ad}$$

avec

- X est un espace de Hilbert ($\mathbb{R}^n$, espaces fonctionnels), ou un ensemble dénombrable.
- X_{ad} est un sous-ensemble fermé de X, dit "espace des états admissibles", c'est à dire ($u \in X$ vérifiant certaines contraintes) (contraintes d'égalité, d'inégalités,...),
- J est la fonction "critère" à minimiser (fonction coût...).

Exemple 1 : Modèle de portefeuille de Markowitz

Investissement dans n actifs, chacun de rendement r_i , avec une matrice de volatilité V. On cherche la meilleure stratégie d'investissements, c'est à dire la proportion x_i de l'actif i à prendre dans son portefeuille. On a les contraintes :

1. $\sum_{i=1}^{N} x_i = 1$
2. $x_i \geqslant 0$ pour touit i

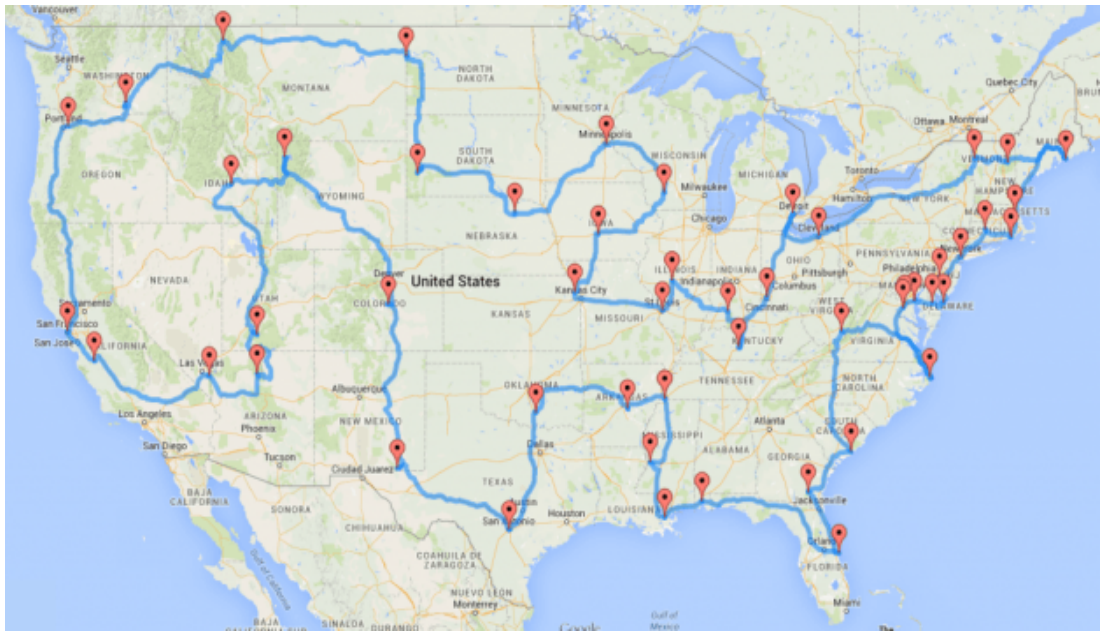
On peut vouloir le portefeuille

1. Le moins risqué, c'est à dire minimisant $W(X) = \frac{1}{2}{}^t XVX$
2. le plus rentable sous une contrainte de risque, c'est à dire minimisant $J(X) = -{}^t RX$ sous la contrainte $W(X) \leqslant \rho$.

$\Longrightarrow$ Optimisation continue sous contrainte

Exemple 2 : Problème du Voyageur de Commerce

N villes de coordonnées $M_i = (x_i, y_i)$, $1 \leqslant i \leqslant N$ à visiter pour un "voyageur de commerce". Dans quel ordre doit-il les visiter ?



$$J = \sum_{i=1}^{N} d(M_{\sigma(i)}, M_{\sigma(i+1)})$$

où $\sigma(i)$ est l'indice de la ième ville visitée.

$\Longrightarrow$ Optimisation Discrète : déterminer la permutation σ minimisant J.

Exemple 3 : Identification paramétrique

Soit un système S décrit par un modèle $M(u, \theta, v) = 0$ (statique ou dynamique, discret ou continu, déterministe ou stochastique : EDO, EDP, EDPS, Equation de récurrence ...)

1. u représente les variables d'état du système (variables internes)
2. θ représente les paramètres
3. v représente les variables de contrôle ou de commande (variables externes) et $w = G(u)$ un vecteur d'observations du système.

Identification Paramétrique : étant donné un vecteur de données expérimentales w_{obs}, trouver $\theta \in \Theta_{ad}$ minimisant $\|w(\theta) - w_{obs}\|$ sous la contrainte $M(u, \theta, v) = 0$.
Exemple statistique : réseau de neuronnes.

Plan

1 Présentation

2 Existence et unicité

3 Critère différentiel pour la minimisation

4 Contraintes d'égalité : théorème d'Euler-Lagrange

5 Contraintes d'inégalité : théorème de Karuch-Kuhn-Tucker

6 Algorithmes de minimisation sans contraintes

7 Algorithmes de minimisation sous contraintes

Généralités

- On notera souvent K l'ensemble X_{ad}
- On note $\inf_K J$ si l'on ne sait pas si J admet un minimum. Sinon on écrit $\min_K J$.
- u minimum local de J sur K si

$$\exists \delta > 0, \quad \|u - v\| \leqslant \delta \Rightarrow J(u) \leqslant J(v).$$

- Par définition de l'infimum il existe une suite dite minimisante $u_n \in K$ telle que $\lim_{n\to\infty} J(u_n) = \inf_K J$.

Dimension finie

Définition

- $J : X \to \mathbb{R}$ *est coercive si* $\lim_{|x|\to\infty} J(x) = \infty$
- J *est semi-continue inférieurement (sci) si*

$$\forall (u_n)_{n\geqslant 0} \quad \text{suite de } K,\ \lim_n u_n = u \Longrightarrow \liminf_{n\to\infty} J(u_n) \geqslant J(u).$$

Théorème (2.2.1)

Soit J sci et coercive sur $K \subset \mathbb{R}^n$ fermé. Alors J possède au moins un point de minimum. De plus on peut extraire de toute suite minimisante une sous-suite qui converge vers un tel point.

Minimisation convexe

Proposition (2.3.4)

Si J est une fonction convexe sur un ensemble convexe K, tout point de minimum local de J sur K est un minimum global et l'ensemble des points de minimum est un ensemble convexe (éventuellement vide).
Si de plus J est strictement convexe, alors il existe au plus un point de minimum.

Propriétés utiles des fonctions convexes:

- Si J_1 et J_2 sont convexes alors $J_1 + J_2$ et $\max(J_1, J_2)$ sont convexes
- J convexe est continue. Son graphe est convexe et situé au-dessus de ses tangentes.

Minimisation convexe

Théorème (2.3.9)

Soit K un convexe fermé non vide d'un espace de Hilbert V, et J une fonction convexe sci et coercive sur K. Alors il existe un minimum de J sur K.

Minimisation fortement convexe

Définition

On dit qu'une fonction J, définie sur un ensemble convexe K, est fortement convexe (ou α-convexe) s'il existe $\alpha > 0$ tel que, pour tout $u, v \in K$ et tout $\theta \in [0,1]$,

$$J(\theta u + (1-\theta)v) \leqslant \theta J(u) + (1-\theta)J(v) - \alpha \frac{\theta(1-\theta)}{2} \|u - v\|^2.$$

Théorème (2.3.8)

Soit K un convexe fermé non vide d'un Hilbert V et J une fonction α-convexe continue sur K. Alors, il existe un unique minimum u de J sur K et pour tout $v \in K$ on a

$$\|v - u\|^2 \leqslant \frac{4}{\alpha}(J(v) - J(u))$$

En particulier, toute suite minimisante de J sur l'ensemble K converge vers u.

Plan

1 Présentation

2 Existence et unicité

3 Critère différentiel pour la minimisation

4 Contraintes d'égalité : théorème d'Euler-Lagrange

5 Contraintes d'inégalité : théorème de Karuch-Kuhn-Tucker

6 Algorithmes de minimisation sans contraintes

7 Algorithmes de minimisation sous contraintes

Différentiabilité au sens de Fréchet

Définition (2.4.1)

On dit que la fonction J, définie sur un voisinage de $u \in V$ à valeurs dans $\mathbb{R}$, est dérivable (ou différentiable) au sens de Fréchet en u s'il existe une forme linéaire continue sur V, $L \in V'$, telle que

$$J(u+w) = J(u) + L(w) + o(w), \qquad \text{avec} \qquad \lim_{w \to 0} \frac{|o(w)|}{\|w\|} = 0.$$

On appelle L la dérivée (ou la différentielle, ou le gradient) de J en u et on note $L = J'(u)$.

Remarques

- Par Thm. de Riesz il existe $p \in V$ tel que $L(v) = \langle p, v \rangle$. On note alors par abus de langage $p = J'(u)$.
- dans $\mathbb{R}^n$, $\partial_i J(u) = L(e_i)$ avec e_i: vecteur de base.

Inequation d'Euler

Théorème (2.5.1)

Soit $u \in K$ convexe. On suppose que J est différentiable en u. Si u est un point de minimum local de J sur K, alors

$$\langle J'(u), v - u \rangle \geqslant 0 \qquad \forall\ v \in K$$

Si $u \in K$ vérifie l'inégalité ci-dessus et si J est convexe, alors u est un minimum global de J sur K.

Différentielle seconde

Définition (2.4.7)

Soit J une fonction de V dans $\mathbb{R}$. On dit que J est deux fois dérivable en $u \in V$ si J est dérivable dans un voisinage de u et si sa dérivée $J'(u)$ est dérivable en u. On note $J''(u)$ la dérivée seconde de J en u qui vérifie

$$J'(u+w) = J'(u)+J''(u,w)+o(w), \qquad \text{avec} \qquad \lim_{w\to 0} \frac{\|o(w)\|_{V'}}{\|w\|} = 0.$$

On note $J''(u)(w,v)$ au lieu de $\langle J''(u,w), v\rangle$.

Lemme (2.4.8)

Si J est une fonction deux fois dérivable de V dans $\mathbb{R}$, elle vérifie

$$J(u+w) = J(u) + \langle J'(u), w\rangle + \frac{1}{2}J''(u)(w,w) + o(\|w\|^2)$$

Cône tangent

Définition (2.5.4)

En tout point $u \in K$, l'ensemble

$$K(u) = \left\{ w \in V,\ \exists\, u_n \in K \to u \text{et } \varepsilon_n \searrow 0,\ \lim_{n\to\infty} \frac{u_n - u}{\varepsilon_n} = w \right\}$$

est appelé le cône des directions admissibles au point u.

Proposition (2.5.5)

Soit u un minimum local de J sur K. Si J est différentiable en u, on a $\langle J'(u), w\rangle \geqslant 0$ pour tout $w \in K(u)$.

Plan

1 Présentation

2 Existence et unicité

3 Critère différentiel pour la minimisation

4 Contraintes d'égalité : théorème d'Euler-Lagrange

5 Contraintes d'inégalité : théorème de Karuch-Kuhn-Tucker

6 Algorithmes de minimisation sans contraintes

7 Algorithmes de minimisation sous contraintes

Contraintes d'égalité

On considére $K = \{v \in V, \quad F_1(v) = 0, \ldots, F_M(v) = 0\}$.

Si les F_i sont dérivables en u on a $K(u) \subset \bigcap_{i=1}^{M} (F_i'(u))^{\perp}$.

Théorème (2.5.6)

Soit $u \in K$ où K est donné ci-dessus. On suppose que J est dérivable en $u \in K$ et que les fonctions $(F_i)_{1 \leqslant i \leqslant M}$ sont continûment dérivables dans un voisinage de u. On suppose de plus que les vecteurs $F_i'(u)$ sont linéairement indépendants. Alors, si u est un minimum local de J sur K, il existe $\lambda_1, \ldots, \lambda_M \in \mathbb{R}$, appelés multiplicateurs de Lagrange, tels que

$$J'(u) + \sum_{i=1}^{M} \lambda_i F_i'(u) = 0$$

Critère de minimalité d'ordre 2

Lorsque les $F_i'(u)$ sont indépendants on parle de cas **régulier**.

Proposition (2.5.13)

On se place sous les hypothèses du Théorème 2.5.6 et on suppose de plus les fonctions J et F_i sont deux fois continûment dérivables sur un voisinage de u. Alors si u est un minimum local de J sur K on a

$$\left(J''(u) + \sum_{i=1}^{M} \lambda_i F_i''(u)\right)(w, w) \geqslant 0 \quad \forall w \in K(u).$$

Plan

1 Présentation

2 Existence et unicité

3 Critère différentiel pour la minimisation

4 Contraintes d'égalité : théorème d'Euler-Lagrange

5 Contraintes d'inégalité : théorème de Karuch-Kuhn-Tucker

6 Algorithmes de minimisation sans contraintes

7 Algorithmes de minimisation sous contraintes

Contraintes d'inégalité

On considére $K = \{v \in V, \quad F_1(v) \leqslant 0, \ldots, F_M(v) \leqslant 0\}.$

Définition (2.5.14)

Soit $u \in K$. L'ensemble $I(u) = \{i \in [\![1, M]\!], F_i(u) = 0\}$ est appelé l'ensemble des contraintes actives en u.

Remarque

Soit $u \in K$ tel que $I(u) \neq \emptyset$. Alors $K(u)$ est le cône tangent à K en u formé des directions rentrantes :

$$K(u) \subset \left\{d \in V, \ \left\langle F_i'(u), d \right\rangle \leqslant 0\right\}.$$

Contraintes qualifiées

Définition (2.5.15)

On dit que les contraintes d'inégalité sont qualifiées en $u \in K$ si et seulement si il existe une direction $\bar{w} \in V$ telle que l'on ait pour tout $i \in I(u)$: $\left\langle F_i'(u), \bar{w} \right\rangle < 0$. Si F_i est affine on peut remplacer l'inégalité par une égalité.

Lemme

Soit $u \in K$ tel que $I(u) \neq \emptyset$. Si les $F_i'(u)$ pour $i \in I(u)$ forment une famille libre alors les contraintes d'inégalité sont qualifiées.

Théorème KKT

Théorème (2.5.17)

On suppose K donné par des contraintes d'inégalité, que les fonctions J et F_i sont dérivables en u et que les contraintes sont qualifiées en u. Alors, si u est un minimum local de J sur K, il existe $\lambda_1, \ldots, \lambda_M \geqslant 0$, appelés multiplicateurs de Lagrange, tels que

$$J'(u) + \sum_{i=1}^{M} \lambda_i F_i'(u) = 0 \quad \text{et} \quad \lambda_i = 0 \text{ si } F_i(u) < 0 \ \forall i \in [1, M]$$

Théorème KKT généralisé

$$K = \{v \in V, \quad G_1(v) = \ldots = G_N(v) = 0, \quad F_1(v) \leqslant 0, \ldots, F_M(v) \leqslant 0\}.$$

Théorème (2.5.24)

On suppose K donné par des contraintes d'égalité et d'inégalité ci-dessus, que les fonctions J, G_i et F_j sont dérivables en u, que $\left(G_i'(u)\right)_{1\leqslant i\leqslant N}$ est libre et qu'il existe $\bar{w} \in \bigcap_{i=1}^{N} \left(G_i'(u)\right)^{\perp}$ tel que $\left\langle F_j'(u), \bar{w} \right\rangle < 0$. Alors, si u est un minimum local de J sur K, il existe $\mu_1, \ldots, \mu_N \in \mathbb{R}$ et $\lambda_1, \ldots, \lambda_M \geqslant 0$, appelés multiplicateurs de Lagrange, tels que

$$J'(u) + \sum_{i=1}^{N} \mu_i G_i'(u) + \sum_{i=1}^{M} \lambda_i F_i'(u) = 0 \quad \text{où} \quad \lambda_i = 0 \text{ si } F_i(u) < 0$$

Lagrangien

Définition (2.5.50)

On appelle Lagrangien du problème de minimisation de J, sous les contraintes d'inégalité $F_i(v) \leqslant 0$, la fonction $\mathcal{L}(v, \mu)$ définie par

$$\mathcal{L}(v, \mu) = J(v) + \sum_{i=1}^{M} \mu_i F_i(v) \quad \forall (v, \mu) \in V \times (\mathbb{R}^+)^M.$$

Lemme (2.5.21)

Le problème de minimisation sous contrainte d'inégalité est équivalent à un problème de min-max :

$$\inf_{v \in V,\ F_i(v) \leqslant 0} J(v) = \inf_{v \in V} \sup_{\mu \in (\mathbb{R}^+)^M} \mathcal{L}(v, \mu)$$

Dualité

Définition (2.6.7)

Soit $\mathcal{L} = J + \mu \cdot F$ le Lagrangien associé au problème de minimisation avec contraintes d'inégalité. On définit

$$I(v) = \sup_{\mu \in (\mathbb{R}^+)^M} \mathcal{L}(v, \mu), \quad G(\mu) = \inf_{v \in V} \mathcal{L}(v, \mu).$$

On appelle problème PRIMAL : $\inf_{v \in V} I(v)$
On appelle problème DUAL : $\sup_{\mu \in (\mathbb{R}^+)^M} G(\mu)$.

Remarque

1. *Le problème initial* $\inf_{F \leqslant 0} J$ *est le problème primal*
2. *On a* $\inf_{v \in V} I(v) \leqslant \sup_{\mu \in (\mathbb{R}^+)^M} G(\mu)$ *et la différence est appelée saut de dualité.*

Théorème de dualité (convexe)

Théorème (2.6.9)

Soient J et F_i des fonctions convexes et soit u une solution du problème primal. Il existe $\lambda \in (\mathbb{R}^+)^M$ tel que le couple (u, λ) soit un point-selle de $\mathcal{L}$ sur $V \times (\mathbb{R}^+)^M$ et

$$I(u) = \min_v I(v) = \max_\mu G(\mu) = G(\lambda).$$

Plan

1 Présentation

2 Existence et unicité

3 Critère différentiel pour la minimisation

4 Contraintes d'égalité : théorème d'Euler-Lagrange

5 Contraintes d'inégalité : théorème de Karuch-Kuhn-Tucker

6 Algorithmes de minimisation sans contraintes

7 Algorithmes de minimisation sous contraintes

Algorithme du gradient

On définit l'algorithme de minimisation : $u_0 \in V$ et

$$u_{n+1} = u_n - \mu J'(u_n)$$

Théorème (3.2.6)

On suppose que J est α-convexe différentiable et que J' est Lipschitzien sur V , c'est-à-dire qu'il existe une constante $L > 0$ telle que

$$\| J'(u) - J'(v)\| \leqslant L\| u - v\|, \quad \forall u, v \in V.$$

Alors, si $0 < \mu < 2\alpha/L^2$, l'algorithme de gradient à pas fixe converge : quel que soit u_0, la suite u_n définie ci-dessus converge vers le minimum u de J et

$$\| u_n - u\| \leqslant \gamma^n \| u_0 - u\|, \quad \textit{avec} \quad \gamma = \sqrt{1 - 2\alpha\mu + \mu^2 L^2} < 1.$$

Sous-gradient

Définition (3.3.19)

Si J est une fonction convexe de $\mathbb{R}^n$ dans $\mathbb{R}$, on appelle sous-différentiel de J en x l'ensemble

$$\partial J(x) = \{p \in \mathbb{R}^n \mid J(y) - J(x) \geqslant p \cdot (y - x),\ \forall y \in \mathbb{R}^n\}.$$

Les éléments de $\partial J(x)$ sont appelés sous-gradients.

Lemme

- *Si J est différentiable au point x alors $\partial J(x) = \{x\}$.*
- *Si $0 \in \partial J(x)$ alors x est un point de minimum pour J.*
- *Si $J = \sup_\lambda J_\lambda$ où les J_λ sont convexes et différentiables alors pour tout λ tel que $J(x) = J_\lambda(x)$, $J'_\lambda(x)$ est un sous-gradient de J au point x.*

Algorithme du sous-gradient

Soit l'algorithme

$$x_{n+1} = x_n - \frac{\rho_n}{\|p_n\|} p_n \quad \text{où } p_n \in \partial J(x_n).$$

Proposition (3.3.23)

Soit une fonction J convexe, coercive, admettant en tout point un sous-différentiel non-vide et localement Lipschitzienne, au sens où, pour tout $M > 0$, il existe $L_M > 0$ tel que

$$\|x\| + \|y\| \leqslant M \implies \|J(x) - J(y)\| \leqslant L_M \|x - y\|, \quad \forall u, v \in V.$$

Si, dans l'algorithme ci-dessus $(\rho_n)_{n\geqslant 0} \in \ell^1$, $(\rho_n)_{n\geqslant 0} \notin \ell^2$ alors l'algorithme du sous-gradient converge.

Algorithme de Newton

▶ Soit $F : \mathbb{R}^n \longrightarrow \mathbb{R}^n$. On note F' la Jacobienne de F.
L'algorithme de Newton pour approcher une racine de F est défini par

$$u_{n+1} - u_n = -(F'(u_n))^{-1} F(u_n) \quad \text{pour} \quad n \geqslant 0$$

et u_0 choisi tel que $F'(u_0) \neq 0$.
▶ Pour la minimisation de J que l'on suppose de classe C^2 on définit la suite

$$u_{n+1} - u_n = -(J''(u_n))^{-1} J'(u_n) \quad \text{pour} \quad n \geqslant 0$$

et u_0 choisi tel que $J''(u_0) \neq 0$.

Algorithme de Newton

Proposition (3.5.1)

Soit F une fonction de classe C^2 de $\mathbb{R}^n$ dans $\mathbb{R}^n$, et u un zéro régulier de F (i.e. $F(u) = 0$ et $F'(u)$ inversible). Il existe un réel $\varepsilon > 0$ et une constante $0 < C < 1/\varepsilon$ tels que, si $\|u - u_0\| \leqslant \varepsilon$, la méthode de Newton converge de façon quadratique :

$$\|u_{n+1} - u\| \leqslant C\|u_n - u\|^2.$$

Algorithme de Newton

Proposition (3.5.1)

Soit F une fonction de classe C^2 de $\mathbb{R}^n$ dans $\mathbb{R}^n$, et u un zéro régulier de F (i.e. $F(u) = 0$ et $F'(u)$ inversible). Il existe un réel $\varepsilon > 0$ et une constante $0 < C < 1/\varepsilon$ tels que, si $\|u - u_0\| \leqslant \varepsilon$, la méthode de Newton converge de façon quadratique :

$$\|u_{n+1} - u\| \leqslant C\|u_n - u\|^2.$$

Remarque : la constante $C \approx (F'(u))^{-1}$.

Plan

1 Présentation

2 Existence et unicité

3 Critère différentiel pour la minimisation

4 Contraintes d'égalité : théorème d'Euler-Lagrange

5 Contraintes d'inégalité : théorème de Karuch-Kuhn-Tucker

6 Algorithmes de minimisation sans contraintes

7 Algorithmes de minimisation sous contraintes

Newton avec contraintes d'égalité

Pour le problème $\min_{G(v)=0} J(v)$ un minimum est un point critique du Lagrangien. On a

$$\nabla \mathcal{L}(u,\lambda) \;=\; (\, J'(u) + \lambda G'(u),\; G(u)\,) \in V \times \mathbb{R}$$

et pour $v = (v_u, v_\lambda)$ et $w = (w_u, w_\lambda)$

$$\mathcal{L}''(u,\lambda)(v,w) = J''(u)(v_u,w_u) + \lambda \cdot G''(u)(v_u,w_u) + \langle G'(u), v_u\rangle\, w_\lambda + \langle G'(u), w_u\rangle\, v_\lambda$$

L'algorithme s'entend en dimension infinie comme une formulation variationelle :

$$\mathcal{L}''(u,\lambda)(u_{n+1}-u_n, \lambda_{n+1}-\lambda_n; w) = -\nabla \mathcal{L}(u_n,\lambda_n)\cdot w$$

Algorithme du gradient projeté

Pour le problème $\inf_K J$ où K est convexe fermé on considère l'algorithme du gradient projeté

$$u_{n+1} = P_K(u_n - \mu J'(u_n)), \quad \text{où} \quad P_K \text{ est la projection sur } K$$

Théorème (3.4.1)

On suppose que J est α-convexe différentiable et que J' est Lipschitzien sur V de constante L. Alors, si $0 < \mu < 2\alpha/L^2$, l'algorithme de gradient à pas fixe avec projection converge.

Algorithme de Uzawa

Pour le problème de minimisation de J sous contraintes d'inégalité on considère le lagragien $\mathcal{L}(v, \mu) = J(v) + \mu \cdot F(v)$ associé et l'algorithme suivant : soient $\varepsilon > 0$, $\mu_0 \in (\mathbb{R}^+)^M$ et

$$\mathcal{L}(u_n, \mu_n) = \inf_V \mathcal{L}(v, \mu_n) \qquad \text{et} \qquad \mu_{n+1} = P_{\mathbb{R}^n_+}(\mu_n + \varepsilon F(u_n))$$

Théorème (3.4.3)

On suppose que J est α-convexe différentiable, que F est convexe et Lipschitzienne de V dans $\mathbb{R}^n$ de constante L. Si $0 < \varepsilon < 2\alpha/L^2$, l'algorithme d'Uzawa converge.

Pénalisation des contraintes

Soit $\varepsilon > 0$. Pour le problème de minimisation de J avec contraintes d'inégalité on considère

$$\inf_{v \in \mathbb{R}^n} J_\varepsilon(v) := \left(J(v) + \frac{1}{\varepsilon} \sum_{i=1}^{M} \max(0, F_i(v))^2 \right)$$

Proposition (3.4.6)

On suppose que J est continue, strictement convexe et coercive, que les fonctions F_i sont convexes et continues pour $1 \leqslant i \leqslant M$, et que $K = \{F \leqslant 0\} \neq \emptyset$. Soit u l'unique solution du problème initial et u_ε le min de J_ε. Alors $\lim_{\varepsilon \to 0} u_\varepsilon = u$.