Où relâcher la vérification ?

Allocation optimale d'un budget de déviation en décodage spéculatif

Prénom Nom 1
Prénom Nom 2

DM d'optimisation, CentraleSupélec, dominante Mathématiques et Sciences des Données, 2026–2027

Résumé

En décodage spéculatif, un petit modèle (le *draft*) propose des tokens qu'un grand modèle (le *target*) vérifie en une seule passe. Nous formalisons deux problèmes d'optimisation issus de notre projet de recherche. **(I)** Vérifier un token revient à résoudre un programme linéaire de transport. Le simplexe et la dualité montrent que l'acceptation maximale vaut $1 - \mathrm{TV}(p, q)$; si l'on tolère une déviation ε de la loi émise, elle passe à $\min(1, 1 - \mathrm{TV} + \varepsilon)$, et le prix dual d'une unité de déviation vaut 1. **(II)** Répartir un budget de déviation entre les positions d'un bloc drafté est un problème *non concave* sous contraintes linéaires. Nous écrivons les conditions KKT, résolvons le problème par gradient projeté et vérifions les conditions d'optimalité. Résultat principal : comme un rejet termine le bloc, le budget doit aller en priorité aux **premières** positions, même lorsqu'elles sont plus sensibles ; un modèle qui ignore cette structure perd jusqu'à 26 % de vitesse.

Attendu du DM	**Où**
Modélisation (variables, objectif, contraintes)	§1, §2.1, §3.1
Existence et unicité	§2.2 (PL), §3.2 (compacité, non-concavité, cas $\gamma = 2$)
Théorèmes du cours, conditions d'optimalité	dualité en PL (§2.3), conditions KKT, Th. 2.5.17 (§3.3), inéquation d'Euler, Th. 2.5.1 (annexe A)
Choix de l'algorithme et convergence	simplexe en deux phases (§2.4), gradient projeté (§3.4 et annexe A)
Plusieurs minima locaux ?	§3.4 : objectif non concave, multi-départs systématiques
Points d'originalité	**méthode du simplexe**, **mise en œuvre de la dualité** (certificat, prix duaux), objectif non concave

1 Contexte et notations

À chaque position, le target définit une loi p sur le vocabulaire et le draft une loi q. La règle de Leviathan et al. [1] accepte le token drafté $x \sim q$ avec probabilité $\min(1, p_x/q_x)$; en cas de rejet, elle ré-échantillonne dans $(p - q)_+$ normalisée, et la loi émise est alors exactement p. Le draft propose un bloc de γ tokens, que le target vérifie en *une* passe ; le premier rejet termine le bloc. La vitesse se mesure par le nombre moyen de tokens produits par passe du target. Une vérification *avec perte* [4] accepte plus souvent, au prix d'une déformation de la loi émise ; notre projet de recherche cherche *où* cette déformation est sans danger pour la réponse finale. On note $\mathrm{TV}(p, q) = \frac{1}{2}\|p - q\|_1$ et $\beta(p, q) = \sum_i \min(p_i, q_i) = 1 - \mathrm{TV}(p, q)$ (identité démontrée au §2.2).

Exemple concret (Qwen2.5-0.5B propose, Qwen2.5-1.5B vérifie, GSM8K). Le draft propose 5 tokens ; le target les vérifie en une passe, garde les tokens jusqu'au premier désaccord, puis écrit le sien (vérification gloutonne). Problème A : « Sofie marche deux fois plus que Brian… » ; problème B : « trois bâtons de colle, il en reste 1/6, 2/3 et 1/2… ». Le token barré est celui du draft, le token en gras celui du target ; la colonne $\min(1, p_x/q_x)$ donne la probabilité avec laquelle la règle stochastique de [1] aurait quand même accepté le token rejeté.

Pb	Bloc proposé par le draft	Acceptés	$\min(1, p_x/q_x)$	Lecture
A	`To ~~determine~~ → find...`	1/5	0,59	synonyme : sans effet sur la réponse
A	`out how many miles Brian`	5/5	–	bloc entier accepté : 6 tokens pour une passe
B	`we need to ~~follow~~ → calculate...`	3/5	0,17	synonyme : sans effet sur la réponse
A	`10 miles every day`	5/5	–	nombres recopiés de l'énoncé : acceptés
B	`is ~~not~~ → left...`	1/5	0,24	**pivot** : « ce qui est utilisé » ou « ce qui reste »
A	`the distance ~~Brian~~ → Sof...`	2/5	0,43	**pivot** : distance de Brian ou de Sofie

Sur ces deux solutions, le target produit en moyenne 4,76 et 4,59 tokens par passe, au lieu de 1 sans draft. La plupart des rejets portent sur des **synonymes** sans effet sur la réponse : c'est là qu'une vérification avec perte gagnerait de la vitesse sans risque. Quelques rejets portent sur des **pivots** qui orientent le raisonnement : c'est là qu'il ne faut pas relâcher. Ce DM formalise ce compromis.

2 Partie I : vérifier un token est un programme linéaire

2.1 Modèle : variables, objectif, contraintes

Variables. Une règle de vérification (exacte ou non) est entièrement décrite par la loi jointe du couple (token proposé par le draft, token finalement émis) :

$$\pi \in \mathbb{R}_+^{n\times n}, \qquad \pi_{xy} = \mathbb{P}(\text{le draft propose } x \text{ et l'on émet } y).$$

On accepte le token du draft exactement quand $y = x$: la probabilité d'acceptation est la somme des cases *diagonales* de π.

Contraintes. (i) Le draft propose selon sa loi : la somme de la ligne x vaut q_x. (ii) La règle est exacte si le token émis suit la loi du target : la somme de la colonne y vaut p_y. (iii) $\pi \geq 0$. D'où

$$(P_0) \qquad \max_{\pi\geq 0} \sum_x \pi_{xx} \quad \text{s.c.} \quad \sum_y \pi_{xy} = q_x \;\; (x = 1, \dots, n), \qquad \sum_x \pi_{xy} = p_y \;\; (y = 1, \dots, n).$$

Forme standard du cours ($\min c \cdot x$, $Ax = b$, $x \geq 0$). On range les n^2 inconnues ligne par ligne : $\mathrm{vec}(\pi) = (\pi_{11}, \dots, \pi_{1n}, \pi_{21}, \dots, \pi_{nn})$.

- **Coût.** Maximiser $\sum_x \pi_{xx}$ revient à minimiser son opposé : $c = -\mathrm{vec}(I_n)$ vaut -1 sur les n composantes diagonales et 0 ailleurs, de sorte que $c \cdot \pi = -\text{acceptation}$.
- **Matrice $A \in \{0,1\}^{2n\times n^2}$ et second membre** $b = (q, p) \in \mathbb{R}^{2n}$: une colonne par variable π_{xy}, une ligne par contrainte. Pour $n = 3$:

	π_{11}	π_{12}	π_{13}	π_{21}	π_{22}	π_{23}	π_{31}	π_{32}	π_{33}	b
ligne $x = 1$	1	1	1	0	0	0	0	0	0	q_1
ligne $x = 2$	0	0	0	1	1	1	0	0	0	q_2
ligne $x = 3$	0	0	0	0	0	0	1	1	1	q_3
colonne $y = 1$	1	0	0	1	0	0	1	0	0	p_1
colonne $y = 2$	0	1	0	0	1	0	0	1	0	p_2
colonne $y = 3$	0	0	1	0	0	1	0	0	1	p_3

Trois propriétés de A.

1. **Structure de flot.** Chaque colonne contient exactement deux 1 : π_{xy} intervient dans la contrainte « ligne x » et dans la contrainte « colonne y ». En multipliant par -1 les n lignes « colonne », chaque colonne contient un $+1$ et un -1 : c'est la matrice d'incidence d'un graphe

orienté biparti (tokens proposés → tokens émis), totalement unimodulaire par le lemme de Poincaré (Lemme 4.3.5) ; changer le signe d'une ligne ne change que le signe des déterminants, donc A est aussi TU. Comme $b = (q, p)$ n'est pas entier, cette propriété ne sert pas ici à l'intégrité : elle situe simplement (P_0) parmi les problèmes de flot du cours.

2. **Rang.** $\mathrm{rg}(A) = 2n - 1$. La somme des n lignes du haut et celle des n lignes du bas valent toutes deux $(1, \dots, 1)$: une ligne est redondante, donc $\mathrm{rg}(A) \le 2n - 1$. Réciproquement, si l'on retire la contrainte « colonne 1 », les $2n - 1$ colonnes associées à π_{11}, aux π_{1y} $(y \ge 2)$ et aux π_{x1} $(x \ge 2)$ engendrent tous les vecteurs de base de $\mathbb{R}^{2n-1}$: $\mathrm{rg}(A) = 2n - 1$. Le cours suppose $\mathrm{rg}(A) = m$; le code retire donc une ligne avant le simplexe.
3. **Compatibilité.** Le système n'a de solution que si $\sum_x q_x = \sum_y p_y$ (les deux valent la masse totale $\sum_{x,y} \pi_{xy}$), ce qui est vrai pour deux lois. Sur les données réelles, les sommes valent 1 ± 10^{-6} (arrondis du softmax en float32) : on renormalise, faute de quoi le PL est réellement non admissible.

2.2 Existence, valeur et (non-)unicité

Existence. L'ensemble admissible est **non vide** (le couplage indépendant $\pi_{xy} = q_x p_y$ vérifie $\sum_y q_x p_y = q_x$ et $\sum_x q_x p_y = p_y$) et **borné** ($0 \le \pi_{xy} \le \sum_{y'} \pi_{xy'} = q_x \le 1$). C'est donc un polyèdre compact ; l'objectif est linéaire, donc continu, et le maximum est atteint (Th. 2.2.1). La Prop. 4.2.6 du cours garantit de plus l'existence d'une **solution basique optimale** (un sommet du polyèdre).

Proposition 1 (valeur de (P_0))**.** *La valeur optimale de (P_0) vaut $\beta(p, q) = \sum_x \min(p_x, q_x) = 1 - \mathrm{TV}(p, q)$. Les solutions optimales sont exactement les $\pi \ge 0$ telles que $\pi_{xx} = \min(p_x, q_x)$ pour tout x et dont la partie hors diagonale a pour marges $(q - p)_+$ (lignes) et $(p - q)_+$ (colonnes). La solution est unique si et seulement si l'un de ces deux vecteurs a au plus une composante non nulle.*

Deux identités utilisées partout. Pour deux réels a, b : $\min(a, b) + (a - b)_+ = a$ (cas $a \le b$ et $a > b$). Pour deux lois p, q :

$$\sum_x (p_x - q_x)_+ = \sum_x (q_x - p_x)_+ = \mathrm{TV}(p, q),$$

car la différence de ces deux sommes vaut $\sum_x (p_x - q_x) = 0$ et leur somme $\sum_x |p_x - q_x| = 2\,\mathrm{TV}$. On en déduit $\beta = \sum_x \big(p_x - (p_x - q_x)_+\big) = 1 - \mathrm{TV}$.

Démonstration. Étape 1 : majoration. Pour tout π admissible, une case diagonale est inférieure à la somme de sa ligne et à celle de sa colonne (les autres cases sont ≥ 0) : $\pi_{xx} \le q_x$ et $\pi_{xx} \le p_x$, donc $\sum_x \pi_{xx} \le \beta$.

Étape 2 : la borne est atteinte par le couplage de Leviathan. Si $\mathrm{TV} = 0$, alors $p = q$ et $\mathrm{diag}(p)$ convient. Sinon, la règle de [1] accepte x avec probabilité $\min(1, p_x/q_x)$, et sinon tire y selon $(p - q)_+/\mathrm{TV}$; elle induit le couplage

$$\pi^L = \underbrace{\mathrm{diag}\,(\min(p, q))}_{\text{proposer } x \text{ et l'accepter}} + \underbrace{\frac{(q - p)_+ \, (p - q)_+^\top}{\mathrm{TV}}}_{\text{proposer } x\text{, rejeter, émettre } y}.$$

— Diagonale : $\mathbb{P}(\text{proposer } x \text{ et accepter}) = q_x \min(1, p_x/q_x) = \min(p_x, q_x)$.

— Lignes : $\sum_y \pi^L_{xy} = \min(p_x, q_x) + (q_x - p_x)_+ \dfrac{\sum_y (p_y - q_y)_+}{\mathrm{TV}} = \min(p_x, q_x) + (q_x - p_x)_+ = q_x$.

— Colonnes : $\sum_x \pi^L_{xy} = \min(p_y, q_y) + \dfrac{\sum_x (q_x - p_x)_+}{\mathrm{TV}} (p_y - q_y)_+ = p_y$.

— Trace : le terme de rang 1 est nul sur la diagonale, car $(q_x - p_x)_+ (p_x - q_x)_+ = 0$. Donc $\sum_x \pi^L_{xx} = \beta$.

π^L est admissible et atteint la borne de l'étape 1 : il est optimal, et la valeur de (P_0) est β.

Étape 3 : forme de toutes les solutions. Si π est optimal, $\sum_x \pi_{xx} = \beta$ alors que $\pi_{xx} \le \min(p_x, q_x)$ pour tout x : toutes ces inégalités sont des égalités. Il reste sur la ligne x la masse $(q_x - p_x)_+$ et sur la colonne y la masse $(p_y - q_y)_+$, à répartir hors diagonale. Une case $\pi_{xy} > 0$ hors diagonale exige $q_x > p_x$ et $p_y > q_y$; ces deux ensembles étant disjoints, on a bien $x \neq y$. Réciproquement, tout $\pi \ge 0$ de cette forme a les bonnes marges et la trace β.

Étape 4 : (non-)unicité. Supposons que $\{q > p\}$ et $\{p > q\}$ contiennent chacun au moins deux tokens. Il existe alors $x \neq x'$ dans $\{q > p\}$ et $y \neq y'$ dans $\{p > q\}$ avec $\pi_{xy} > 0$ et $\pi_{x'y'} > 0$. En effet, chaque colonne $y \in \{p > q\}$ reçoit une masse > 0, donc il existe $\pi_{x_1 y_1} > 0$ et $\pi_{x_2 y_2} > 0$ avec $y_1 \neq y_2$; si $x_1 \neq x_2$, c'est terminé ; sinon on prend une autre ligne $x' \in \{q > p\}$, qui a une case $\pi_{x'y''} > 0$ avec y'' différent de y_1 ou de y_2, et l'on associe ces deux cases. On remplace alors $\pi_{xy}, \pi_{x'y'}$ par $\pi_{xy} - \delta, \pi_{x'y'} - \delta$ et $\pi_{xy'}, \pi_{x'y}$ par $\pi_{xy'} + \delta, \pi_{x'y} + \delta$, avec $0 < \delta \le \min(\pi_{xy}, \pi_{x'y'})$: chaque ligne et chaque colonne gagne et perd δ, la diagonale est inchangée, et l'on obtient une autre solution optimale. Si l'un des deux supports a au plus un élément, la partie hors diagonale est forcée (toute la masse va vers, ou vient de, ce seul token, ou il n'y a rien à placer) : la solution est unique. □

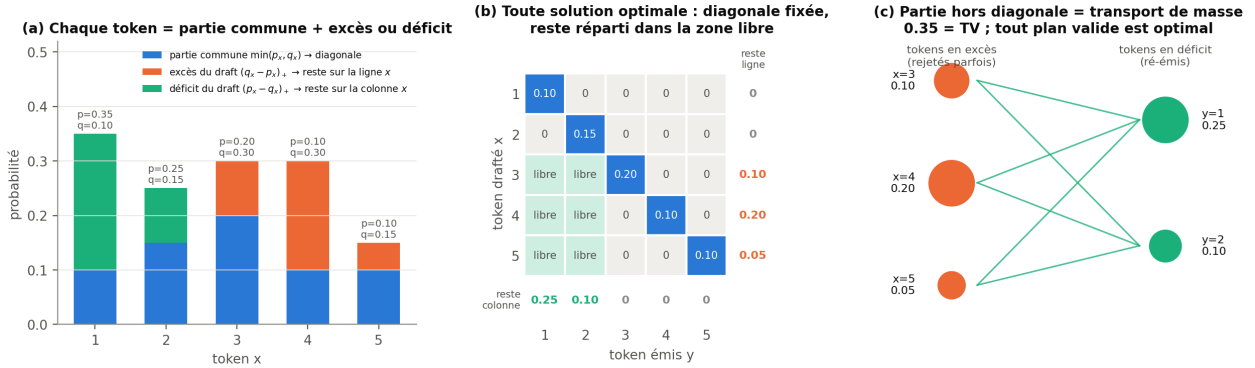


Figure 1 – *Étape 3 de la preuve.* Exemple $p = (0{,}35; 0{,}25; 0{,}2; 0{,}1; 0{,}1)$, $q = (0{,}1; 0{,}15; 0{,}3; 0{,}3; 0{,}15)$. (a) Chaque token se décompose en une partie commune $\min(p_x, q_x)$ (bleu), qui va sur la diagonale de π, plus soit un excès du draft $(q_x - p_x)_+$ (orange), soit un déficit $(p_x - q_x)_+$ (vert). (b) Structure imposée à toute solution optimale : diagonale fixée à $\min(p, q)$; il reste $(q - p)_+$ à placer sur chaque ligne et $(p - q)_+$ sur chaque colonne. Une case hors diagonale ne peut être non nulle que si sa ligne a un reste et sa colonne un besoin (cases « libres » : lignes 3 à 5, colonnes 1 et 2). (c) Remplir la zone libre revient à transporter la masse TV $= 0{,}35$ des tokens en excès vers les tokens en déficit ; tout plan qui respecte ces masses donne la même acceptation $\beta = 0{,}65$.

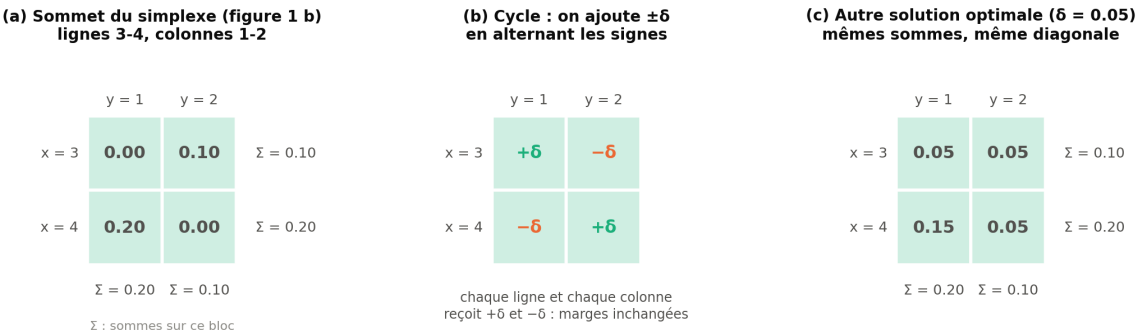


Figure 2 – *Étape 4 de la preuve.* (a) Bloc lignes 3–4 × colonnes 1–2 du sommet renvoyé par le simplexe. (b) On ajoute $+\delta$ et $-\delta$ en alternant les signes : chaque ligne et chaque colonne du bloc gagne et perd δ. (c) Avec $\delta = 0{,}05$, on obtient une autre solution admissible avec la même diagonale, donc la même acceptation $\beta = 0{,}65$: il y a une infinité de solutions optimales. Ce cycle n'existe pas si un seul token est en excès ou un seul en déficit (exemple 1).

Exemple 1 ($n = 3$)**.** Target $p = (0{,}5; 0{,}3; 0{,}2)$, draft $q = (0{,}2; 0{,}3; 0{,}5)$. On a $\min(p, q) = (0{,}2; 0{,}3; 0{,}2)$, donc $\beta = 0{,}7$ et $\mathrm{TV} = 0{,}3$; $(q-p)_+ = (0; 0; 0{,}3)$ (le draft sur-propose le token 3) et $(p-q)_+ = (0{,}3; 0; 0)$ (il sous-propose le token 1).

$$\pi^L = \begin{pmatrix} 0{,}2 & 0 & 0 \\ 0 & 0{,}3 & 0 \\ \mathbf{0{,}3} & 0 & 0{,}2 \end{pmatrix} :$$

la case en gras se lit « le draft propose 3 alors que le target préfère 1 : on rejette et on émet 1 ». Lignes $(0{,}2; 0{,}3; 0{,}5) = q$, colonnes $(0{,}5; 0{,}3; 0{,}2) = p$, trace $0{,}7 = \beta$. Chaque support est un singleton : la solution optimale est unique.

2.3 Dualité : un certificat d'optimalité explicite

Écriture du dual. Le dual de $\min\{c \cdot x : Ax = b,\ x \geq 0\}$ est $\max\{b \cdot \mu : A^\top \mu \leq c\}$ (Th. 4.2.13). On note $\mu = (u, v) \in \mathbb{R}^n \times \mathbb{R}^n$, où u_x est le multiplicateur de la contrainte « ligne x » et v_y celui de « colonne y ». La colonne de A associée à π_{xy} contient un 1 sur la ligne x et un 1 sur la ligne $n + y$, donc $(A^\top \mu)_{xy} = u_x + v_y$; de plus $c_{xy} = -\delta_{xy}$ et $b \cdot \mu = q \cdot u + p \cdot v$. D'où

$$(D_0) \qquad \max_{u,v}\ q \cdot u + p \cdot v \quad \text{s.c.} \quad u_x + v_y \leq -\delta_{xy} \quad \forall x, y.$$

Dualité faible, en une ligne. Pour π admissible et μ dual admissible, $c - A^\top \mu \geq 0$ et $\pi \geq 0$, donc

$$c \cdot \pi \ \geq\ (A^\top \mu) \cdot \pi = \mu \cdot (A\pi) = \mu \cdot b, \qquad \text{soit} \qquad -\sum_x \pi_{xx} \ \geq\ q \cdot u + p \cdot v.$$

Si l'on exhibe π et μ pour lesquels il y a égalité, les deux sont optimaux.

Le certificat. Posons $S = \{x : q_x \leq p_x\}$ (tokens que le draft ne sur-propose pas) et

$$u_x = \begin{cases} -1 & x \in S \\ 0 & x \notin S \end{cases} \qquad v_y = \begin{cases} 0 & y \in S \\ -1 & y \notin S. \end{cases}$$

— Admissibilité sur la diagonale : exactement l'un des deux vaut -1, donc $u_x + v_x = -1$.

— Admissibilité hors diagonale : $u_x + v_y \in \{0, -1, -2\}$, donc $\leq 0 = c_{xy}$.

— Valeur : $q \cdot u + p \cdot v = -\sum_{x \in S} q_x - \sum_{y \notin S} p_y = -\sum_x \min(p_x, q_x) = -\beta$.

La valeur duale $-\beta$ égale la valeur primale $c \cdot \pi^L$: par dualité faible, π^L et (u, v) sont optimaux. On retrouve la proposition 1 sans l'étape 1.

Écarts complémentaires. À l'optimum, $\pi_{xy} > 0 \Rightarrow u_x + v_y = c_{xy}$. Sur π^L : une case hors diagonale non nulle a $q_x > p_x$ ($u_x = 0$) et $p_y > q_y$ ($v_y = 0$), donc $u_x + v_y = 0 = c_{xy}$; sur la diagonale, $u_x + v_x = -1 = c_{xx}$. *Lecture :* $u_x = -1$ marque les tokens que le draft propose « trop peu » ($q_x \leq p_x$) : ils sont toujours acceptés.

Exemple 2 (suite)**.** $S = \{1, 2\}$, donc $u = (-1, -1, 0)$ et $v = (0, 0, -1)$; valeur duale $-(0{,}2 + 0{,}3) - 0{,}2 = -0{,}7 = -\beta$.

2.4 Algorithme : simplexe révisé en deux phases

Le simplexe est programmé comme dans le cours (`specdm/simplex.py`). À chaque itération, avec l'ensemble de base $\mathcal{B}$ (matrice $A_\mathcal{B}$) et l'ensemble hors base $\mathcal{N}$:

1. solution de base $x_\mathcal{B} = A_\mathcal{B}^{-1} b$ et multiplicateurs $\mu = A_\mathcal{B}^{-\top} c_\mathcal{B}$;
2. coûts réduits $\tilde{c}_\mathcal{N} = c_\mathcal{N} - A_\mathcal{N}^\top \mu$; si $\tilde{c}_\mathcal{N} \geq 0$, la base est optimale (Prop. 4.2.8) ;

3. sinon, la variable entrante j a le coût réduit le plus négatif (règle de Dantzig) ; direction $d = A_{\mathcal{B}}^{-1} A_j$, et le long de $x_{\mathcal{B}}(\theta) = x_{\mathcal{B}} - \theta d$ le coût baisse de $|\tilde{c}_j|\theta$;
4. test du ratio : $\theta^* = \min\{x_{\mathcal{B},i}/d_i : d_i > 0\}$; si aucun $d_i > 0$, le problème n'est pas borné, sinon la variable qui s'annule sort de la base.

Phase 1. On résout $\min \mathbf{1} \cdot y$ sous $\tilde{A}x + y = \tilde{b}$, $\tilde{b} = |b|$ (lignes de signe changé si besoin), en partant du sommet $(x, y) = (0, \tilde{b})$; valeur nulle si et seulement si le problème est admissible, et la base finale, purgée des variables artificielles, démarre la phase 2. **Dégénérescence.** Une base compte $2n - 1$ variables, dont plusieurs sont souvent nulles ($\theta^* = 0$: pivot sans progrès). Pour exclure tout cyclage, on passe à la règle de Bland (plus petit indice) après $2m$ pivots dégénérés consécutifs. Les multiplicateurs μ de la base finale forment la solution duale : c'est ainsi que l'on obtient les prix du §2.6.

2.5 Validation numérique

Nous vérifions trois choses distinctes : (i) l'implémentation du simplexe trouve le vrai optimum et le vrai dual ; (ii) la valeur du PL coïncide avec la formule β ; (iii) le tout fonctionne sur de vraies lois de LLM.

Données synthétiques. Pour chaque $n = 3, \ldots, 12$, on tire 30 paires (p, q) (300 au total), chaque loi suivant une loi de Dirichlet $\mathrm{Dir}(c, \ldots, c)$ avec $c \in \{0{,}3; 1; 3\}$: $c = 0{,}3$ donne des lois très piquées (un LLM sûr de son prochain token), $c = 3$ des lois presque uniformes. On couvre ainsi des paires très proches ($\beta \approx 1$) comme très éloignées ($\beta \approx 0$). Pour chaque paire, on compare la valeur de (P_0) par **notre simplexe**, par **HiGHS** (solveur de référence de SciPy, développé indépendamment) et la **formule** β.

Comparaison	Écart maximal	Lecture
notre simplexe / formule β	$4{,}4 \times 10^{-16}$	précision machine (en double précision, deux nombres proches de 1 ne se distinguent pas à moins de $2{,}2 \times 10^{-16}$ près)
HiGHS / formule β	$4{,}4 \times 10^{-16}$	idem
notre simplexe / formule, paires réelles	$3{,}5 \times 10^{-11}$	voir ci-dessous

Vérification du dual. Les tests unitaires (`tests/test_specdm.py`) contrôlent, sur des PL aléatoires, l'**admissibilité duale** $A^\top \mu \le c$ et la **dualité forte** $b \cdot \mu = c \cdot x$ (à 10^{-8} près), comparent valeur et statut à HiGHS, et vérifient la détection des problèmes non admissibles et non bornés. Pour (P_0), ils vérifient que le certificat (u, v) du §2.3 est admissible et de valeur $-\beta$, que π^L a les bonnes marges et que les écarts complémentaires sont satisfaits.

Coût du simplexe. Nombre moyen d'itérations (phases 1 et 2) :

n	3	4	5	6	7	8	9	10	11	12
itérations	10	16	21	31	38	47	58	75	87	105

Le PL a n^2 variables et $2n - 1$ contraintes indépendantes ; un ajustement en loi de puissance donne un exposant d'environ 1,7. Pour un vrai vocabulaire ($n \approx 150\,000$), (P_0) aurait 2×10^{10} variables : le simplexe sert ici à *vérifier* la formule fermée β, que l'on calcule ensuite directement.

Données réelles. On prend 320 positions tirées au hasard dans les solutions GSM8K (20 par problème) avec les lois (p_t, q_t) des deux modèles Qwen2.5. Le vocabulaire étant trop grand pour le PL, on réduit chaque paire aux 6 tokens les plus probables de chaque modèle plus une case « autres » qui regroupe la masse restante (supports de 7 à 12 tokens). Deux précautions :

— **Renormalisation.** En float32, les sommes valent 1 ± 10^{-6} ; or (P_0) exige $\sum p = \sum q$ exactement : sans renormalisation, le PL est non admissible, et notre simplexe le détecte en phase 1.

— **Écart de $3{,}5 \times 10^{-11}$.** Les lois réelles contiennent des masses minuscules (jusqu'à 10^{-12}), plus petites que la tolérance 10^{-10} utilisée pour décider qu'un coût réduit est négatif : le simplexe s'arrête dès que le gain restant est inférieur à 10^{-10}. L'écart reste négligeable devant toute quantité d'intérêt.

Portée de cette validation. Elle ne remplace pas la preuve de la proposition 1, qui vaut pour toutes les lois ; elle détecte les erreurs d'implémentation, de formulation ou de données. Elle a d'ailleurs révélé deux points : les lois réelles non renormalisées rendaient le PL non admissible, et un test qui attendait un prix dual égal à 1 en $\varepsilon = 0$ a échoué (le simplexe renvoyait 2) ; ce n'était pas une erreur mais un coin de la fonction valeur, où tout prix ≥ 1 est valide (§2.6).

Non-unicité, observée. Le simplexe renvoie un **sommet** (8 cases non nulles, au plus $2n - 1 = 9$), tandis que π^L est un autre optimum qui n'est pas un sommet (11 cases) ; les deux acceptent avec probabilité 0,65 (figure 3).

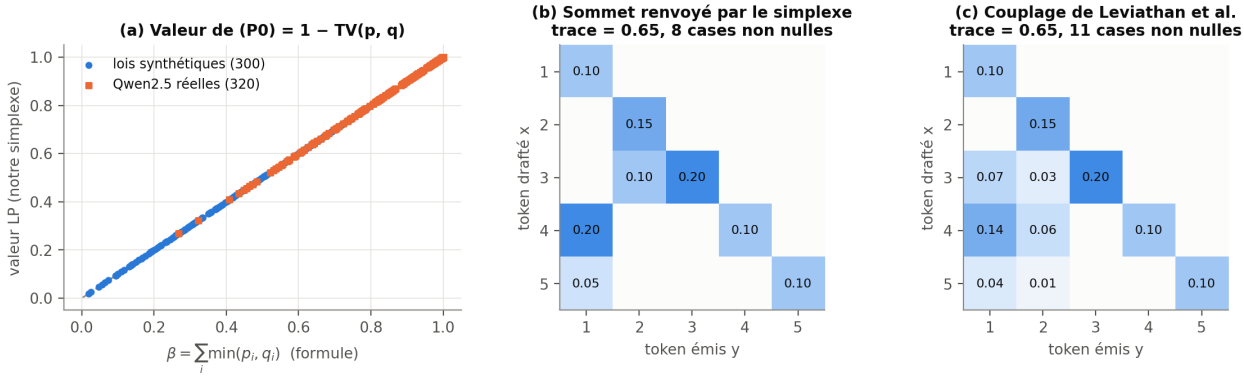


Figure 3 – (a) La valeur de (P_0) calculée par notre simplexe coïncide avec $\beta = \sum \min(p, q)$. (b-c) Deux couplages optimaux pour $p = (0{,}35; 0{,}25; 0{,}2; 0{,}1; 0{,}1)$ et $q = (0{,}1; 0{,}15; 0{,}3; 0{,}3; 0{,}15)$: même diagonale, partie hors diagonale différente.

2.6 Vérification avec perte et prix dual du budget

Modèle. On autorise la loi émise r à s'écarter de p d'au plus ε en variation totale : la seconde marge de π devient une variable r (automatiquement une loi, comme somme des colonnes de $\pi \geq 0$, de masse $\sum q = 1$), avec $\mathrm{TV}(r, p) \leq \varepsilon$. La valeur absolue n'étant pas linéaire, on introduit $t_y \geq 0$ avec $t_y \geq r_y - p_y$ et $t_y \geq p_y - r_y$, c'est-à-dire $t_y \geq |r_y - p_y|$. Alors $\sum_y t_y \leq 2\varepsilon$ implique $\mathrm{TV}(r, p) \leq \varepsilon$; réciproquement, si $\mathrm{TV}(r, p) \leq \varepsilon$, le choix $t_y = |r_y - p_y|$ est admissible. Les deux formulations ont donc les mêmes (π, r) admissibles :

$$(P_\varepsilon) \qquad \max_{\pi, r, t \geq 0} \sum_x \pi_{xx} \quad \text{s.c.} \quad \begin{array}{lll} \sum_y \pi_{xy} = q_x, & \sum_x \pi_{xy} = r_y, & \\ t_y \geq r_y - p_y, & t_y \geq p_y - r_y, & \sum_y t_y \leq 2\varepsilon. \end{array}$$

En forme standard, chaque inégalité reçoit une variable d'écart positive ; la dernière ligne a pour second membre 2ε.

Proposition 2 (frontière avec perte)**.** *La valeur de (P_ε) vaut $\alpha^*(\varepsilon) = \min(1, \beta + \varepsilon)$. Elle est atteinte par $r_\varepsilon = p + \theta(q - p)$ avec $\theta = \min(1, \varepsilon / \mathrm{TV}(p, q))$ (et $\theta = 1$ si $\mathrm{TV} = 0$).*

Démonstration. Majoration. Pour (π, r, t) admissible, π est un couplage des lois q et r : la proposition 1 appliquée à (q, r) donne $\sum_x \pi_{xx} \leq 1 - \mathrm{TV}(q, r)$. L'inégalité triangulaire $\mathrm{TV}(q, p) \leq \mathrm{TV}(q, r) + \mathrm{TV}(r, p)$

donne alors

$$\sum_x \pi_{xx} \;\le\; 1 - \mathrm{TV}(q,p) + \mathrm{TV}(r,p) \;\le\; \beta + \varepsilon,$$

et bien sûr $\sum_x \pi_{xx} \le \sum_{x,y} \pi_{xy} = 1$.

Borne atteinte. r_ε est un mélange de p et q, donc une loi ; $r_\varepsilon - p = \theta(q-p)$ donne $\mathrm{TV}(r_\varepsilon, p) = \theta\,\mathrm{TV} \le \varepsilon$, et $q - r_\varepsilon = (1-\theta)(q-p)$ donne $\mathrm{TV}(q, r_\varepsilon) = (1-\theta)\mathrm{TV}$. Le couplage de Leviathan entre q et r_ε accepte avec probabilité

$$1 - (1-\theta)\mathrm{TV} = \beta + \theta\,\mathrm{TV} = \begin{cases} \beta + \varepsilon & \text{si } \varepsilon \le \mathrm{TV}\ (\theta = \varepsilon/\mathrm{TV}), \\ 1 & \text{si } \varepsilon \ge \mathrm{TV}\ (\theta = 1,\ r_\varepsilon = q). \end{cases}$$

□

Exemple 3 (suite, $\varepsilon = 0{,}1$)**.** $\theta = 1/3$, $r_\varepsilon = p + \frac{1}{3}(q-p) = (0{,}4; 0{,}3; 0{,}3)$; $\mathrm{TV}(r_\varepsilon, p) = \frac{1}{2}(0{,}1+0+0{,}1) = 0{,}1$ et $\beta(q, r_\varepsilon) = 0{,}2 + 0{,}3 + 0{,}3 = 0{,}8 = \beta + \varepsilon$.

Lecture duale : le multiplicateur du budget est une pente. Notons $V(\varepsilon) = -\alpha^*(\varepsilon)$ la valeur du problème écrit en minimisation, $b(\varepsilon) = b_0 + 2\varepsilon\, e_{\text{budget}}$ son second membre et $D = \{\mu : A^\top \mu \le c\}$ l'ensemble dual admissible, qui *ne dépend pas* de ε. Par dualité forte, $V(\varepsilon) = \max_{\mu \in D} b(\varepsilon) \cdot \mu$ pour tout $\varepsilon \ge 0$; V est donc convexe, comme maximum de fonctions affines. Soit μ^* un dual optimal en ε et μ^*_B sa composante sur la ligne de budget ($\mu^*_B \le 0$, car la variable d'écart de cette ligne a un coût nul). Pour tout $\varepsilon' \ge 0$,

$$V(\varepsilon') \;\ge\; b(\varepsilon') \cdot \mu^* = V(\varepsilon) + 2\mu^*_B(\varepsilon' - \varepsilon).$$

Donc $2\mu^*_B$ est un sous-gradient de V, et le **prix du budget** $\kappa(\varepsilon) := -2\mu^*_B \ge 0$ est un sur-gradient de α^* (concave). Là où α^* est dérivable, $\kappa(\varepsilon) = \alpha^{*\prime}(\varepsilon)$: c'est le nombre d'unités d'acceptation gagnées par unité de déviation. Avec $\alpha^*(\varepsilon) = \min(1, \beta + \varepsilon)$, ce prix vaut 1 pour $0 < \varepsilon < \mathrm{TV}$ et 0 pour $\varepsilon > \mathrm{TV}$, ce que renvoie le simplexe (figure 4b). Aux deux coins, le sur-gradient n'est pas unique : en $\varepsilon = \mathrm{TV}$, tout prix de $[0, 1]$ convient ; en $\varepsilon = 0$ (où $\varepsilon < 0$ est non admissible), tout prix ≥ 1 convient, et le simplexe y renvoie 2.

Interprétation. **Une unité de déviation achète exactement une unité d'acceptation**, tant qu'il reste du désaccord à absorber : c'est la frontière de Pareto linéaire de Yin et al. [3], retrouvée ici avec les seuls outils du cours. C'est la brique de la partie II : relâcher la position t d'une déviation $\varepsilon_t \le \mathrm{TV}_t$ fait passer son acceptation de a_t à $a_t + \varepsilon_t$.

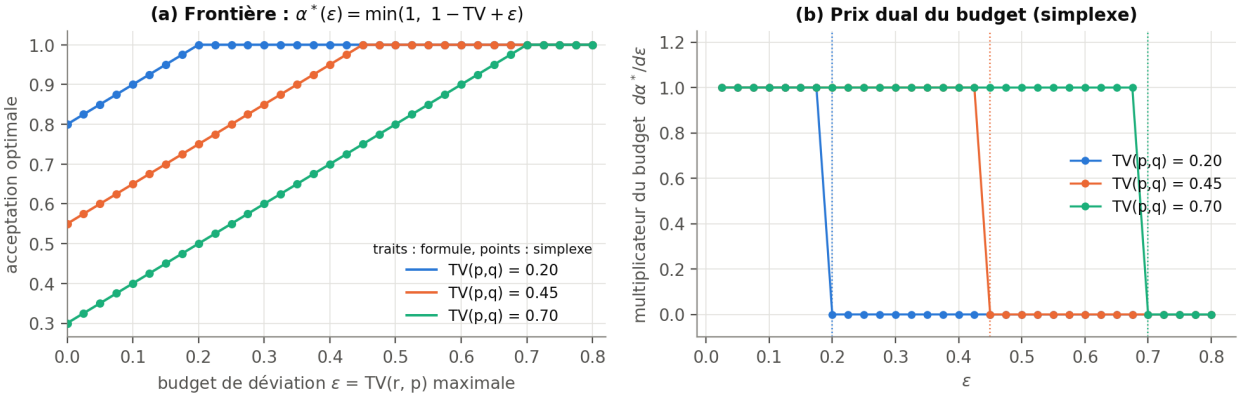


Figure 4 – (a) Acceptation optimale en fonction du budget ε, pour trois paires (p, q) ; points : simplexe, traits : proposition 2 (écart maximal $2{,}8 \times 10^{-16}$). (b) Prix du budget $\kappa = -2\mu^*_B = d\alpha^*/d\varepsilon$ calculé à partir du dual renvoyé par le simplexe : 1 avant $\varepsilon = \mathrm{TV}$ (pointillés), 0 après.

3 Partie II : répartir le budget entre les positions d'un bloc

3.1 Modèle : variables, objectif, contraintes

Un bloc compte γ positions draftées. La position t a une acceptation exacte $a_t = \beta(p_t, q_t) \in (0,1)$ et une **sensibilité** $s_t > 0$: la baisse de qualité de la réponse finale par unité de déviation (en variation totale) à cette position.

Variables : les déviations $\varepsilon = (\varepsilon_1, \dots, \varepsilon_\gamma)$. **Hypothèses :**

(H1) les acceptations des différentes positions sont indépendantes, comme dans [1] ;

(H2) la perte de qualité est additive au premier ordre : $\sum_t s_t \varepsilon_t$;

(H3) d'après la proposition 2, relâcher la position t de ε_t donne l'acceptation $\alpha_t = a_t + \varepsilon_t$, avec $0 \le \varepsilon_t \le m_t := 1 - a_t = \mathrm{TV}_t$ (au-delà, l'acceptation vaut déjà 1). On appelle m_t la *marge* de la position t.

Objectif : nombre moyen de tokens par passe du target. Soit N le nombre de tokens draftés acceptés dans le bloc. Le bloc s'arrête au premier rejet, donc « au moins k acceptés » signifie « les k premiers acceptés » et, sous (H1),

$$\mathbb{P}(N \ge k) = \alpha_1 \alpha_2 \cdots \alpha_k =: P_k \qquad (P_0 = 1).$$

Pour une variable à valeurs entières, $\mathbb{E}[N] = \sum_{k \ge 1} \mathbb{P}(N \ge k)$. Le target émet en plus un token à la fin de chaque passe (sa correction en cas de rejet, ou un token bonus si tout est accepté). D'où

$$E(\varepsilon) = 1 + \mathbb{E}[N] = 1 + \sum_{k=1}^{\gamma} \prod_{j=1}^{k} (a_j + \varepsilon_j).$$

Contraintes : $K = \{\varepsilon \in \mathbb{R}^\gamma : \ 0 \le \varepsilon_t \le m_t, \ s \cdot \varepsilon \le B\}$, toutes affines.

$$(Q_B) \qquad \max_{\varepsilon \in K} \ E(\varepsilon) \qquad \Longleftrightarrow \qquad \min_{\varepsilon \in K} \ J(\varepsilon) = -E(\varepsilon).$$

On le compare au **modèle A**, qui ignore la structure en bloc et maximise $\sum_t \alpha_t$: un PL de type sac à dos fractionnaire.

Exemple 4 ($\gamma = 3$, sans relâchement, $a = (0{,}9; 0{,}5; 0{,}8)$)**.** $P_1 = 0{,}9$, $P_2 = 0{,}45$, $P_3 = 0{,}36$, donc $E = 2{,}71$ tokens par passe. Le faible $a_2 = 0{,}5$ coupe la moitié des blocs à la position 2 : la position 3, pourtant facile, n'est atteinte qu'une fois sur deux.

3.2 Existence, structure et unicité

Existence. K est un polyèdre non vide ($0 \in K$ car $B \ge 0$), fermé et borné ($0 \le \varepsilon \le m$), donc compact ; $J = -E$ est un polynôme, donc continu. Le théorème 2.2.1 (la coercivité est automatique sur un borné) donne au moins un minimum de J, c'est-à-dire un maximum de E.

Gradient. α_t n'apparaît que dans les P_k avec $k \ge t$, et linéairement : $\partial P_k / \partial \alpha_t = P_k / \alpha_t$ pour $k \ge t$, 0 sinon. Comme $\partial \alpha_t / \partial \varepsilon_t = 1$,

$$\partial_t E = \sum_{k \ge t} \frac{P_k}{\alpha_t} = P_{t-1}(1 + \alpha_{t+1} + \alpha_{t+1}\alpha_{t+2} + \cdots + \alpha_{t+1} \cdots \alpha_\gamma) = P_{t-1}\, T_t,$$

où P_{t-1} est la **probabilité d'atteindre** la position t et T_t (défini par $T_\gamma = 1$, $T_t = 1 + \alpha_{t+1} T_{t+1}$) le **nombre de tokens** que l'acceptation de t « débloque », elle comprise. Tous les α_j sont > 0, donc $\partial_t E > 0$: E croît strictement en chaque variable.

Hessienne. E est affine en chaque α_t séparément (fonction multilinéaire), donc $\partial^2_{tt}E = 0$. Pour $i < j$, α_j n'apparaît que dans T_i, et

$$\partial^2_{ij}E = P_{i-1}\Big(\prod_{i<k<j}\alpha_k\Big)T_j \;> 0.$$

Non-concavité. La hessienne H est symétrique, non nulle et de trace nulle : ses valeurs propres sont réelles, de somme nulle et pas toutes nulles, donc l'une est > 0. H n'est semi-définie négative en aucun point : E **n'est pas concave** (J n'est pas convexe).

Exemple 5 ($\gamma = 2$, $a = (0{,}5; 0{,}5)$)**.** $E = 1 + \alpha_1 + \alpha_1\alpha_2$, $\nabla E = (1 + \alpha_2, \alpha_1)$ et $H = \left(\begin{smallmatrix} 0 & 1 \\ 1 & 0 \end{smallmatrix}\right)$, de valeurs propres ± 1. Sur la diagonale $\varepsilon_1 = \varepsilon_2$: $E(0;0) = 1{,}75$, $E(0{,}5;0{,}5) = 3$, mais $E(0{,}25;0{,}25) = 2{,}3125$, *sous* la corde $(1{,}75 + 3)/2 = 2{,}375$; une fonction concave serait au-dessus.

Lecture. $\partial^2_{ij}E > 0$ signifie que relâcher une position augmente la valeur marginale des autres (on atteint plus souvent les suivantes) : les positions sont **complémentaires**. Conséquence : les résultats d'unicité par convexité (Prop. 2.3.4, Th. 2.3.8) ne s'appliquent pas, et l'on ne peut pas exclure a priori plusieurs maxima locaux.

Lemme 1 (concavité le long des échanges)**.** *Pour deux positions $i \neq j$, la direction $d = s_j e_i - s_i e_j$ conserve le coût ($s \cdot d = 0$), et $h \mapsto E(\varepsilon + hd)$ est un trinôme strictement concave.*

Démonstration. À coordonnées autres que i, j fixées, E est affine en α_i et en α_j séparément : $E = c_0 + c_i\alpha_i + c_j\alpha_j + \partial^2_{ij}E\,\alpha_i\alpha_j$, où $\partial^2_{ij}E > 0$ ne dépend ni de α_i ni de α_j. Le long de d, $\alpha_i \leftarrow \alpha_i + hs_j$ et $\alpha_j \leftarrow \alpha_j - hs_i$: le coefficient de h^2 vaut $-s_is_j\,\partial^2_{ij}E < 0$. □

Transférer du budget d'une position à une autre est donc toujours un problème concave en dimension 1 : la non-concavité de E vient des directions qui augmentent ou diminuent simultanément plusieurs positions (comme $\varepsilon_1 = \varepsilon_2$ dans l'exemple). Ce lemme explique la proposition 3 ci-dessous et rend plausible l'unimodalité observée au §3.4, sans la démontrer pour $\gamma \geq 3$.

Lemme 2 (budget saturé)**.** *En tout maximum local, ou bien $s \cdot \varepsilon = B$, ou bien $\varepsilon = m$ (budget surabondant, $B \geq s \cdot m$).*

Démonstration. Si $s \cdot \varepsilon < B$ et $\varepsilon_t < m_t$ pour un t, alors $\varepsilon + he_t \in K$ pour $h > 0$ petit, et $E(\varepsilon + he_t) = E(\varepsilon) + h\,\partial_t E + o(h) > E(\varepsilon)$ puisque $\partial_t E > 0$: ce n'est pas un maximum local. □

Proposition 3 (cas $\gamma = 2$: unicité et solution explicite)**.** *Si $B < s \cdot m$, le maximum est unique. On note $\kappa_s = s_1/s_2$ et $c = a_2 + B/s_2$. Avec $\eta^* = \frac{1}{2}((1+c)/\kappa_s - a_1)$, la solution est $\varepsilon_1^* = \mathrm{proj}_{[\eta_-,\eta_+]}(\eta^*)$ et $\varepsilon_2^* = (B - s_1\varepsilon_1^*)/s_2$, où $[\eta_-, \eta_+] = \big[\max\big(0, (B - s_2m_2)/s_1\big),\ \min\big(m_1, B/s_1\big)\big]$ est l'ensemble des ε_1 compatibles avec les bornes. Si $\eta^* \in [\eta_-, \eta_+]$, la valeur optimale et le multiplicateur valent*

$$E^*(B) = 1 + \frac{(1 + c + \kappa_s a_1)^2}{4\kappa_s}, \qquad \lambda^* = \frac{1 + c + \kappa_s a_1}{2s_1} = \frac{dE^*}{dB}.$$

Démonstration. Par le lemme 2, tout maximum est sur le segment $\{s \cdot \varepsilon = B\} \cap K$. On pose $\varepsilon_1 = \eta$, $\varepsilon_2 = (B - s_1\eta)/s_2$, soit $\alpha_1 = a_1 + \eta$ et $\alpha_2 = c - \kappa_s\eta$; les bornes imposent $\eta \in [\eta_-, \eta_+]$. Alors

$$E(\eta) = 1 + (a_1 + \eta)(1 + c - \kappa_s\eta), \qquad E'(\eta) = (1 + c) - \kappa_s(a_1 + 2\eta), \qquad E''(\eta) = -2\kappa_s < 0.$$

E est un trinôme strictement concave (c'est le lemme 1) : son maximum sur un segment est unique, égal à η^* (zéro de E') projeté sur $[\eta_-, \eta_+]$. Si η^* est intérieur, $a_1 + \eta^* = (1 + c + \kappa_s a_1)/(2\kappa_s)$ et $1 + c - \kappa_s\eta^* = (1 + c + \kappa_s a_1)/2$, d'où E^*. Enfin c dépend de B avec $dc/dB = 1/s_2$, donc $dE^*/dB = (1 + c + \kappa_s a_1)/(2\kappa_s s_2) = (1 + \alpha_2^*)/s_1 = \partial_1 E/s_1 = \lambda^*$ (§3.3). □

Dans ce régime, $E^*(B)$ est un polynôme de degré 2 en B, de coefficient dominant positif : la frontière est *convexe* et le prix λ^* croît avec B.

Exemple 6 (instance de la figure 5)**.** $a = (0{,}55; 0{,}7)$, $s = (1{,}5; 0{,}6)$, $B = 0{,}35\, s \cdot m = 0{,}29925$.

- $c = 0{,}7 + 0{,}29925/0{,}6 = 1{,}19875$, $\kappa_s = 2{,}5$; $\varepsilon_1^* = \frac{1}{2}(0{,}4 \times 2{,}19875 - 0{,}55) = 0{,}16475 \in [\eta_-, \eta_+] = [0{,}0795; 0{,}1995]$; $\varepsilon_2^* = (0{,}29925 - 1{,}5 \times 0{,}16475)/0{,}6 = 0{,}086875$.
- $\alpha^* = (0{,}71475; 0{,}786875)$ et $E^* = 1 + 0{,}71475 \times 1{,}786875 = 2{,}2772$.
- KKT : $\nabla E = (1 + \alpha_2, \alpha_1) = (1{,}786875; 0{,}71475)$ et $\partial_1 E/s_1 = 1{,}19125 = \partial_2 E/s_2$: $\nabla E = \lambda s$ avec $\lambda = 1{,}19125$, qui est aussi la valeur de dE^*/dB donnée par la proposition.
- Le gradient projeté trouve exactement ces valeurs. Le modèle A relâche d'abord la position la moins sensible (la 2), sature $\varepsilon_2 = m_2 = 0{,}3$ puis $\varepsilon_1 = 0{,}0795$: $E = 2{,}2590$ contre 2,2772.

Proposition 4 (positions identiques : relâcher d'abord le début)**.** *Si $a_t \equiv a$ et $s_t \equiv s$, toute solution optimale vérifie $\alpha_1 \geq \alpha_2 \geq \cdots \geq \alpha_\gamma$.*

Démonstration. Supposons $\alpha_t < \alpha_{t+1}$ en un optimum et échangeons ε_t et ε_{t+1}. Le point obtenu est admissible (mêmes marges, même coût). Pour $k < t$, P_k ne contient ni α_t ni α_{t+1} ; pour $k \geq t+1$, il contient le produit $\alpha_t \alpha_{t+1}$, inchangé. Seul $P_t = P_{t-1}\alpha_t$ change et devient $P_{t-1}\alpha_{t+1}$: E augmente de $P_{t-1}(\alpha_{t+1} - \alpha_t) > 0$, ce qui contredit l'optimalité. □

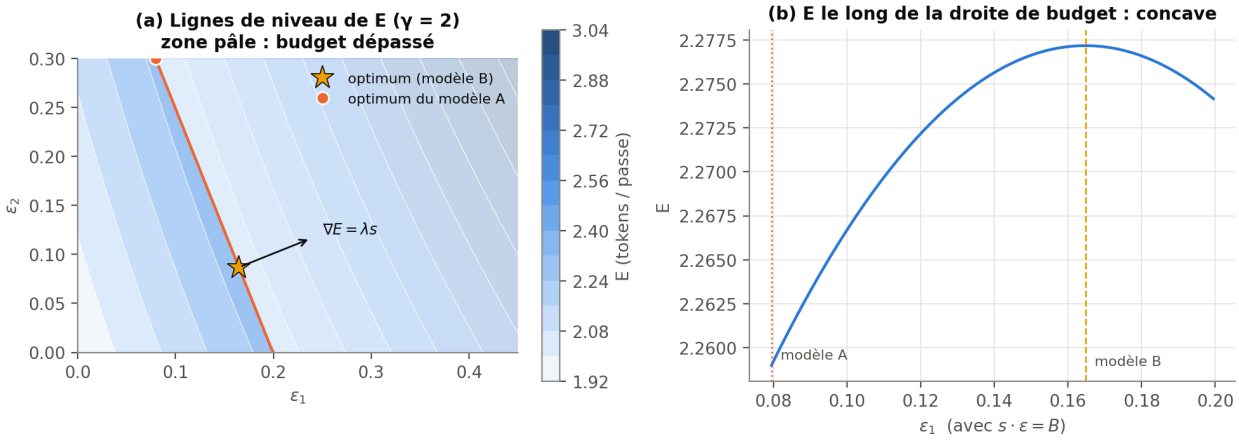


Figure 5 – $\gamma = 2$, $a = (0{,}55; 0{,}7)$, $s = (1{,}5; 0{,}6)$, $B = 0{,}35\, s \cdot m$. (a) À l'optimum, ∇E est orthogonal à la droite de budget ($\nabla E = \lambda s$). (b) Le long de cette droite, E est un trinôme concave ($E'' = -2s_1/s_2 = -5$). Le modèle A choisit le bord ($E = 2{,}2590$ contre 2,2772).

3.3 Conditions d'optimalité (KKT)

Contraintes écrites $F_i(\varepsilon) \leq 0$ et leurs gradients.

Contrainte	$F_i(\varepsilon)$	∇F_i	Multiplicateur
budget	$s \cdot \varepsilon - B$	s	$\lambda \geq 0$
borne basse, position t	$-\varepsilon_t$	$-e_t$	$\mu_t^0 \geq 0$
borne haute, position t	$\varepsilon_t - m_t$	e_t	$\mu_t^1 \geq 0$

Qualification. Toutes les F_i sont affines. La définition 2.5.15 demande une direction w telle que $\langle \nabla F_i, w \rangle < 0$ pour chaque contrainte active, l'égalité $\langle \nabla F_i, w \rangle = 0$ étant permise pour les contraintes affines : $w = 0$ convient (Rq. 2.5.16). Les contraintes sont qualifiées en tout point de K.

Conditions KKT (Th. 2.5.17, appliqué à $J = -E$). En tout minimum local de J (maximum local de E), il existe $\lambda, \mu^0, \mu^1 \geq 0$ tels que

$$\nabla J + \lambda s - \sum_t \mu_t^0 e_t + \sum_t \mu_t^1 e_t = 0 \quad \Longleftrightarrow \quad \nabla E(\varepsilon) = \lambda s - \mu^0 + \mu^1,$$

avec les écarts complémentaires $\lambda(s \cdot \varepsilon - B) = 0$, $\mu_t^0 \varepsilon_t = 0$ et $\mu_t^1(m_t - \varepsilon_t) = 0$. Ces conditions sont **seulement nécessaires** : J n'est pas convexe, donc le théorème de Kuhn–Tucker (Th. 2.6.4), qui les rendrait suffisantes, ne s'applique pas. Un point KKT peut a priori être un maximum local non global, ou un point selle.

Lecture coordonnée par coordonnée. Notons $\rho_t = \partial_t E / s_t$ le **rendement** de la position t (tokens gagnés par unité de qualité perdue). La t-ième équation s'écrit $\partial_t E = \lambda s_t - \mu_t^0 + \mu_t^1$:

- si $0 < \varepsilon_t < m_t$, aucune borne n'est active : $\mu_t^0 = \mu_t^1 = 0$ et $\rho_t = \lambda$;
- si $\varepsilon_t = 0$: $\mu_t^1 = 0$, donc $\rho_t \leq \lambda$ (pas rentable, on ne relâche pas) ;
- si $\varepsilon_t = m_t$: $\mu_t^0 = 0$, donc $\rho_t \geq \lambda$ (très rentable, on relâche au maximum).

C'est une **règle de seuil** : on relâche les positions dont le rendement dépasse le prix λ.

- **Modèle A** : $\partial_t(\sum_j \alpha_j) = 1$, donc $\rho_t = 1/s_t$ ne dépend pas de ε. On trie par sensibilité croissante et l'on sature les positions dans cet ordre jusqu'à épuisement du budget ; $\lambda = 1/s_{t^*}$ pour la position charnière t^* (sac à dos fractionnaire). Notre simplexe et cet algorithme glouton donnent la même solution (tests unitaires).
- **Modèle B** : $\rho_t = P_{t-1} T_t / s_t$ dépend de la **place** de la position : une position précoce est atteinte souvent (P_{t-1} grand) et débloque beaucoup de tokens (T_t grand). C'est pourquoi le budget va au début du bloc.

λ est le prix marginal du budget. Si l'on augmente B de dB et que l'on dépense ce supplément sur une position intérieure t, ε_t augmente de dB/s_t et E de $\partial_t E \, dB/s_t = \lambda \, dB$. Ce raisonnement (analogue au lemme 2.6.6 du cours, qui suppose la convexité) n'est pas une preuve dans notre cadre non concave ; il est exact pour $\gamma = 2$ (proposition 3) et vérifié numériquement à 0,5 % près en général (figure 8c).

3.4 Algorithme : gradient projeté, et question des maxima locaux

K est convexe et la projection sur K se calcule presque explicitement : on choisit le **gradient projeté** du cours, en montée,

$$\varepsilon_{k+1} = P_K\big(\varepsilon_k + \tau \nabla E(\varepsilon_k)\big).$$

1. Calcul de la projection $z = P_K(y)$. C'est la solution de $\min_{z \in K} \frac{1}{2}\|z - y\|^2$, fonction fortement convexe : elle existe et est unique (Th. 2.3.8). On dualise seulement la contrainte de budget, avec un multiplicateur $\nu \geq 0$:

$$\min_{0 \leq z \leq m} \ \tfrac{1}{2}\|z - y\|^2 + \nu(s \cdot z - B) = \sum_t \Big[\tfrac{1}{2}(z_t - y_t)^2 + \nu s_t z_t\Big] - \nu B.$$

Le problème se sépare coordonnée par coordonnée : chaque terme est une parabole de minimum libre en $y_t - \nu s_t$, et sur $[0, m_t]$ le minimum est ce point ramené dans l'intervalle :

$$z_t(\nu) = \mathrm{clip}(y_t - \nu s_t,\ 0,\ m_t).$$

Si $s \cdot z(0) \leq B$, on prend $\nu = 0$. Sinon, $\varphi(\nu) = s \cdot z(\nu)$ est continue et décroissante, $\varphi(0) > B$ et $\varphi(\nu) = 0 \leq B$ pour ν grand : le théorème des valeurs intermédiaires donne ν tel que $\varphi(\nu) = B$,

calculé par dichotomie. Dans les deux cas, $(z(\nu), \nu)$ vérifie les conditions KKT du problème de projection (stationnarité, $\nu \geq 0$, $\nu(s \cdot z(\nu) - B) = 0$, bornes traitées exactement). Ce problème étant convexe à contraintes affines, ces conditions sont suffisantes (Th. 2.6.4) : $z(\nu) = P_K(y)$. C'est un problème dual de dimension 1.

2. Choix du pas. Sur K, on a $\alpha \in [0,1]^\gamma$, donc $P_{i-1} \leq 1$, $\prod \alpha_k \leq 1$ et $T_j \leq \gamma - j + 1$ (somme de $\gamma - j + 1$ produits ≤ 1). D'où $|\partial^2_{ij} E| \leq \gamma - \max(i,j) + 1$ et, puisque $\|H\|_2 \leq \|H\|_F$,

$$\|\nabla E(x) - \nabla E(y)\| \leq L\|x - y\| \quad (x, y \in K), \qquad L = \Big(\sum_{i \neq j} \big(\gamma - \max(i,j) + 1\big)^2 \Big)^{1/2}.$$

Pour $\gamma = 2$, $L = \sqrt{2}$ (la vraie norme de H vaut 1) ; pour $\gamma = 8$, $L \approx 25{,}9$. On prend $\tau = 1/L$.

3. Convergence. Le théorème 3.4.1 suppose J α-convexe : il **ne s'applique pas** ici, et pour la même raison ni Uzawa (Th. 3.4.3) ni la pénalisation (Prop. 3.4.6). On démontre en annexe A, avec l'inéquation d'Euler (Th. 2.5.1), que $E(\varepsilon_k)$ croît, que les pas tendent vers 0 et que toute valeur d'adhérence de (ε_k) vérifie les conditions KKT. Pour un problème non concave, c'est la meilleure garantie générale : un point KKT n'est pas forcément un maximum global.

4. Global ou local ? On lance le gradient projeté depuis 20 points initiaux aléatoires sur 100 instances aléatoires ($\gamma \in \{3, 4, 6, 8\}$; hessienne indéfinie à l'optimum dans tous les cas). L'écart maximal entre valeurs finales vaut $1{,}8 \times 10^{-15}$, l'écart maximal entre solutions $1{,}1 \times 10^{-8}$, et le résidu KKT maximal $2{,}9 \times 10^{-10}$. Nous n'avons donc **jamais observé deux maxima locaux distincts** : le problème est non concave mais, empiriquement, unimodal. L'unicité n'est démontrée que pour $\gamma = 2$ (proposition 3).

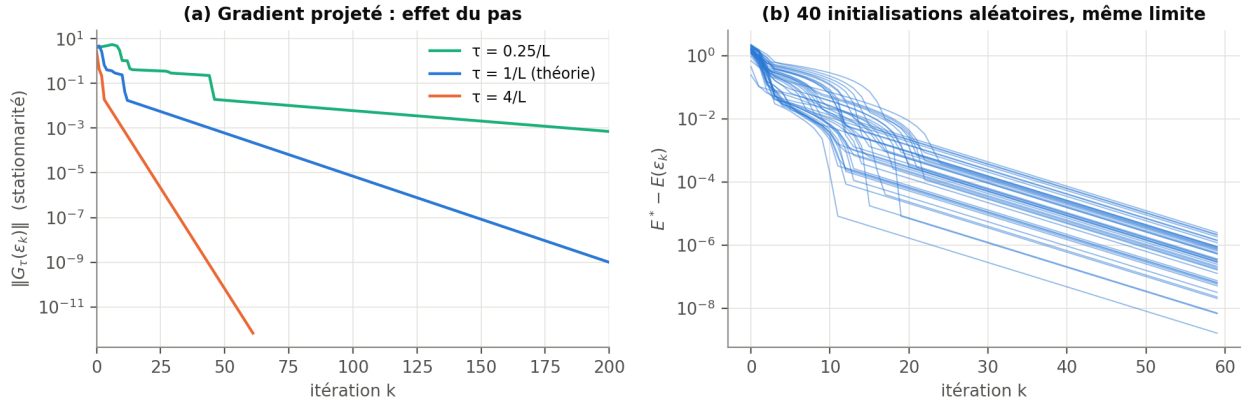


Figure 6 – Instance $\gamma = 8$. (a) Norme de l'application gradient $\|P_K(\varepsilon + \tau\nabla E) - \varepsilon\|/\tau$: convergence linéaire. Avec $\tau = 1/L$, 279 itérations ; avec $\tau = 4/L$, 62 itérations (la monotonie est observée mais n'est plus garantie, voir l'annexe A). (b) 40 départs aléatoires convergent vers la même valeur $E^* = 5{,}4544$.

3.5 Résultats : où placer la déviation ?

On prend $\gamma = 6$, $a_t = 0{,}6$ et un budget $B = 0{,}3\, B_{\max}$ (où $B_{\max} = s \cdot m$), avec trois profils de sensibilité (figure 7).

— **S1 (positions identiques, $s_t = 1$).** Le modèle B relâche dans l'ordre $1, 2, \ldots$ (proposition 4). Le modèle A est *indifférent* : tous les $\rho_t = 1/s$ sont égaux, donc toute répartition de même coût est A-optimale, y compris « fin d'abord », qui ne donne que $E = 2{,}54$ contre 4,12. La solution gloutonne de A coïncide ici avec B uniquement grâce à son départage par indice.

— **S2 (début plus sensible, $s = (2; 1{,}7; 1{,}4; 1{,}1; 0{,}8; 0{,}5)$).** Le modèle A relâche les dernières positions, les moins chères. Le modèle B relâche malgré tout les **premières** : $E = 3{,}52$ contre 2,79 pour A (+26 %) et 3,21 pour une déviation uniforme. À l'optimum, $\rho_1 = \rho_2 = \lambda = 1{,}308$ (positions intérieures) et $\rho_t < \lambda$ ailleurs, comme le prévoit KKT.

— **S3 (deux tokens pivots, $s = 2{,}5$ en positions 2 et 5, 0,3 ailleurs).** Le modèle B évite le pivot tardif (position 5) mais relâche en partie le pivot précoce (position 2), qui conditionne l'accès aux positions 3 et 4. L'écart avec A est faible (4,98 contre 4,96).

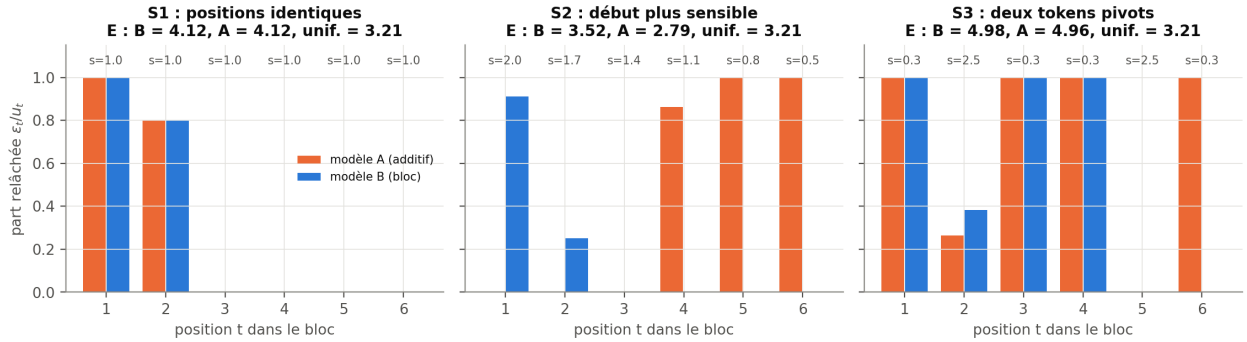


Figure 7 – Part relâchée ε_t/m_t par position, pour le modèle additif A (orange) et le modèle par blocs B (bleu). Les sensibilités s_t sont indiquées au-dessus de chaque position.

Frontière vitesse–budget (figure 8). Pour chaque budget, on compare l'optimum aux heuristiques. En S2, le gain maximal sur A vaut 0,97 token par passe, et sur la déviation uniforme 0,40. L'heuristique « fin d'abord » relâche le moins les premiers tokens, à la manière de [5] qui vérifie plus strictement le début pour la sécurité ; du point de vue de la vitesse, elle est toujours la pire (à égalité avec A en S2).

La forme de la frontière $E^*(B)$ dépend du profil. En **S2**, elle est convexe et $\lambda^*(B)$ croît (figure 8c) : l'effet de complémentarité des positions ($\partial^2_{ij} E > 0$) domine, et il vaut mieux concentrer la déviation sur quelques positions que de la diluer, ce qui explique les solutions presque « tout ou rien » de la figure 7. En **S3**, au contraire, la frontière est concave par morceaux (figure 8b) : on dépense d'abord sur les positions bon marché ($s_t = 0{,}3$), très rentables, puis sur les pivots, chers ; les rendements décroissent comme dans un sac à dos. Les deux effets coexistent : en général, $E^*(B)$ n'est ni convexe ni concave (elle est convexe dans le régime intérieur du cas $\gamma = 2$, proposition 3).

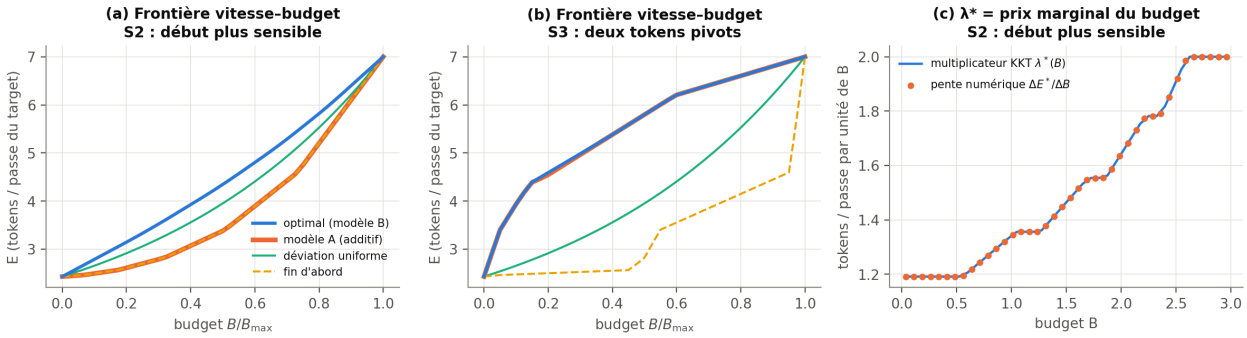


Figure 8 – (a-b) Nombre moyen de tokens par passe du target en fonction du budget, pour l'allocation optimale et trois heuristiques. (c) Multiplicateur KKT $\lambda^*(B)$ et pente numérique $\Delta E^*/\Delta B$ en S2 : le multiplicateur est bien le prix marginal du budget.

4 Données réelles : Qwen2.5-1.5B (target) et Qwen2.5-0.5B (draft) sur GSM8K

Le target rédige des solutions à 16 problèmes GSM8K tirés au hasard, en décodage glouton (2344 tokens générés), tronquées à 150 tokens : seules les lois (p_t, q_t) comptent ici, pas la justesse des réponses. À chaque position, on calcule $a_t = \beta(p_t, q_t)$ sur le vocabulaire complet. L'acceptation exacte moyenne vaut 0,893, et 47 % des positions ont $a_t > 0{,}99$; elle vaut 0,982 sur les tokens contenant un chiffre (15 % des tokens), contre 0,878 sur les autres. Les sensibilités ne sont **pas mesurées** dans ce DM (c'est l'objet du projet de recherche). On utilise un proxy explicite : $s_t = 10$ si le token contient un chiffre, $s_t = 1$ sinon (les nombres décident de la réponse à GSM8K). On découpe la séquence en blocs consécutifs de $\gamma = 5$ et l'on maximise $\sum_{\text{blocs}} E$ sous un budget commun ; le même gradient projeté s'applique, car la hessienne est diagonale par blocs.

— Sans relâchement, on obtient 4,66 tokens par passe et par bloc, et 6,00 si l'on relâche tout. À $B = 0{,}2\,B_{\max}$: 5,18 (optimal), 4,98 (modèle A), 4,87 (uniforme).

— Le gain maximal de l'allocation optimale vaut 0,235 token par passe sur A et 0,467 sur l'uniforme. Il est plus faible qu'en synthétique, parce que la plupart des positions réelles ont déjà $a_t \approx 1$.

— L'optimum ne dépense **rien** sur les tokens numériques tant que $B \le 0{,}75\,B_{\max}$: ils sont à la fois chers ($s_t = 10$) et déjà presque toujours acceptés (les nombres sont souvent recopiés de l'énoncé).

— À $B = 0{,}2\,B_{\max}$, l'optimum relâche la première position du bloc à 73 % de sa marge, la deuxième à 43 %, et les suivantes à 0 % ; le modèle A ne distingue pas les positions (entre 22 et 28 %). On retrouve sur données réelles la conclusion de la partie II : la déviation doit aller au **début** du bloc.

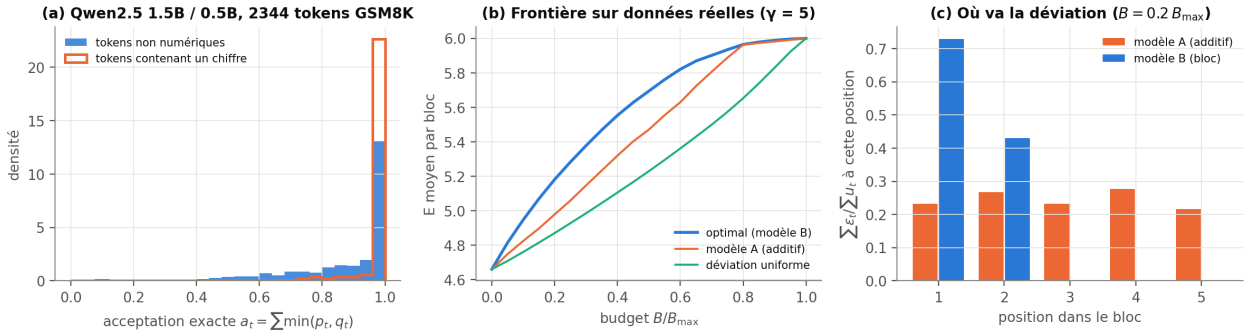


Figure 9 – (a) Distribution des acceptations exactes mesurées. (b) Frontière vitesse–budget sur les données réelles. (c) Part relâchée selon la position dans le bloc, à $B = 0{,}2\,B_{\max}$.

5 Conclusion, limites et lien avec le projet

Les deux problèmes se traitent avec les outils du cours. La partie I est un PL de transport : le simplexe et la dualité en donnent la valeur $(1 - \mathrm{TV})$, un certificat explicite et le prix exact d'une unité de déviation. La partie II est un problème non concave sous contraintes affines : les contraintes y sont qualifiées, les conditions KKT donnent une règle de seuil interprétable, le gradient projeté converge vers un point KKT, et tous nos multi-départs ont abouti au même point.

Le message pour notre projet de recherche : **la structure en bloc change la réponse**. Une règle qui relâche les tokens « peu sensibles » sans tenir compte de leur position (modèle A) peut perdre plus d'un quart de la vitesse atteignable. De plus, la contrainte de vitesse pousse à relâcher le début du bloc, à l'opposé des heuristiques de sécurité qui le vérifient plus strictement [5] ; cette

tension est à quantifier avec de vraies sensibilités.

Limites. (H1) ignore la corrélation entre positions ; (H2) est une approximation au premier ordre ; les blocs réels se recalent après chaque rejet ; et nos sensibilités sont des hypothèses, que le projet de recherche devra mesurer.

A Convergence du gradient projeté (cas non concave)

Notations : $g = \nabla E(\varepsilon_k)$, $\varepsilon^+ = \varepsilon_{k+1} = P_K(\varepsilon_k + \tau g)$, $d = \varepsilon^+ - \varepsilon_k$, et $0 < \tau < 2/L$ (on prend $\tau = 1/L$).

1. **Caractérisation de la projection.** $P_K(y)$ minimise la fonction convexe $\phi(z) = \frac{1}{2}\|z-y\|^2$, de gradient $z - y$, sur le convexe K ; l'inéquation d'Euler (Th. 2.5.1) est nécessaire, et suffisante puisque ϕ est convexe :

$$z^* = P_K(y) \iff z^* \in K \quad \text{et} \quad \langle z^* - y, w - z^* \rangle \geq 0 \quad \forall w \in K. \tag{A.1}$$

   Avec $y = \varepsilon_k + \tau g$, $z^* = \varepsilon^+$ et $w = \varepsilon_k$:

$$\langle d - \tau g, -d \rangle \geq 0 \iff \langle g, d \rangle \geq \frac{\|d\|^2}{\tau}. \tag{A.2}$$

   Le pas projeté est une direction de montée.

2. **Lemme de montée.** Le segment $[\varepsilon_k, \varepsilon^+]$ est dans K (convexe), où ∇E est L-lipschitzien (§3.4). Par Taylor avec reste intégral,

$$E(\varepsilon^+) - E(\varepsilon_k) - \langle g, d \rangle = \int_0^1 \langle \nabla E(\varepsilon_k + \sigma d) - \nabla E(\varepsilon_k), d \rangle \, d\sigma \;\geq\; -\frac{L}{2}\|d\|^2.$$

   Avec (A.2) :

$$E(\varepsilon_{k+1}) \;\geq\; E(\varepsilon_k) + \Big(\frac{1}{\tau} - \frac{L}{2}\Big)\|\varepsilon_{k+1} - \varepsilon_k\|^2, \tag{A.3}$$

   avec $\frac{1}{\tau} - \frac{L}{2} > 0$ pour $\tau < 2/L$ (et $= L/2$ pour $\tau = 1/L$). Pour $\tau = 4/L$ (figure 6), cette garantie disparaît.

3. **Conséquences.** $E(\varepsilon_k)$ est croissante et majorée par $1 + \gamma$ (chaque $P_k \leq 1$). En sommant (A.3) de $k = 0$ à $N - 1$:

$$\Big(\frac{1}{\tau} - \frac{L}{2}\Big) \sum_{k=0}^{N-1} \|\varepsilon_{k+1} - \varepsilon_k\|^2 \;\leq\; E(\varepsilon_N) - E(\varepsilon_0) \;\leq\; 1 + \gamma,$$

   donc la série converge et $\|\varepsilon_{k+1} - \varepsilon_k\| \to 0$. K étant compact, une sous-suite ε_{k_j} converge vers un $\bar{\varepsilon} \in K$, et $\varepsilon_{k_j+1} = \varepsilon_{k_j} + d_{k_j} \to \bar{\varepsilon}$ aussi. Comme P_K (1-lipschitzienne) et ∇E sont continues, le passage à la limite dans $\varepsilon_{k_j+1} = P_K(\varepsilon_{k_j} + \tau \nabla E(\varepsilon_{k_j}))$ donne

$$\bar{\varepsilon} = P_K\big(\bar{\varepsilon} + \tau \nabla E(\bar{\varepsilon})\big).$$

4. **Point fixe $\iff$ Euler $\iff$ KKT.** Par (A.1) avec $y = \bar{\varepsilon} + \tau \nabla E(\bar{\varepsilon})$ et $z^* = \bar{\varepsilon}$, le point fixe équivaut à

$$\langle \nabla E(\bar{\varepsilon}), w - \bar{\varepsilon} \rangle \leq 0 \quad \forall w \in K,$$

   la condition nécessaire d'Euler (Th. 2.5.1) pour un minimum local de $J = -E$ sur le convexe K : aucune direction admissible ne fait monter E au premier ordre. K étant défini par des contraintes affines (qualifiées), cette condition équivaut aux conditions KKT du §3.3 (lemme de Farkas).

Ce que l'on n'obtient pas. Rien ne garantit que $\bar{\varepsilon}$ soit le maximum *global* : E n'est pas concave, et l'inéquation d'Euler n'est plus suffisante. On ne montre pas non plus la convergence de toute la suite (elle a lieu si les points KKT sont isolés, puisque $\|\varepsilon_{k+1} - \varepsilon_k\| \to 0$). C'est pourquoi on combine des multi-départs avec une vérification numérique des conditions KKT, dont le résidu est calculé par moindres carrés positifs sur (λ, μ^0, μ^1) en n'autorisant que les multiplicateurs des contraintes actives.

B Reproduire les résultats

Commande (depuis `DM_Optimisation/`)	Effet
`python -m pytest -q tests`	19 tests : simplexe contre HiGHS, propositions 1–2, certificat dual, gradient et hessienne (différences finies), projection, KKT
`python scripts/extract_llm_stats.py`	(optionnel, CPU, environ 20 min) statistiques draft/target sur GSM8K, dans `data/`
`python scripts/examples_draft_vs_target.py`	(optionnel, CPU, environ 15 min) exemples de blocs proposés par le draft et vérifiés par le target (§1)
`python scripts/run_all.py`	toutes les figures (`figures/`) et les chiffres (`results.json`)
`python scripts/build_notebook.py`	notebook exécuté `DM_Optimisation_SpecDec.ipynb`

Références

[1] Y. Leviathan, M. Kalman, Y. Matias. *Fast Inference from Transformers via Speculative Decoding*. ICML 2023.

[2] C. Chen et al. *Accelerating Large Language Model Decoding with Speculative Sampling*. arXiv :2302.01318, 2023.

[3] M. Yin, M. Chen, K. Huang, M. Wang. *A Theoretical Perspective for Speculative Decoding Algorithm*. NeurIPS 2024.

[4] M. Holsman, Y. Huang, B. Dhingra. *Fuzzy Speculative Decoding for a Tunable Accuracy-Runtime Tradeoff*. Findings of ACL 2025.

[5] Y. Zhang, Z. Wang, N. Gong, Y. Yang. *Secure Speculative Decoding for Large Language Models*. arXiv :2610.08678, 2026.

[6] G. Allaire. *Analyse numérique et optimisation*. Éditions de l'École polytechnique (numérotation des théorèmes reprise du cours).