Où relâcher la vérification ?

Allocation optimale d'un budget de déviation en décodage spéculatif

Prénom Nom 1
Prénom Nom 2

DM d'optimisation, CentraleSupélec, dominante Mathématiques et Sciences des Données, 2026–2027

Résumé

Les grands modèles de langage (LLM), qui animent les assistants conversationnels, écrivent un texte morceau de mot par morceau de mot, et chaque morceau coûte un calcul complet du modèle : la génération est lente. Le *décodage spéculatif* l'accélère : un petit modèle rapide (le *draft*) propose plusieurs morceaux d'avance, et le grand modèle (le *target*) les vérifie tous en un seul calcul. Ce DM, issu de notre projet de recherche en apprentissage automatique, étudie deux problèmes d'optimisation posés par cette vérification. **(I)** Vérifier un morceau proposé est un programme linéaire de transport : notre simplexe et un certificat dual montrent que la probabilité d'acceptation maximale vaut $1 - \mathrm{TV}(p, q)$, et qu'une petite déviation ε tolérée sur le texte produit la porte à $\min(1, 1 - \mathrm{TV} + \varepsilon)$. **(II)** Répartir un budget de déviation entre les positions d'un bloc proposé est un problème *non concave* sous contraintes linéaires, que nous traitons par les conditions KKT et le gradient projeté. Comme un rejet interrompt le bloc, il faut dévier d'abord sur les **premières** positions : dans un scénario typique, on va ainsi 26 % plus vite qu'avec une règle qui ignore cette structure.

Attendu du DM	**Où**
Modélisation	§2.1 (PL), §3.1 (allocation)
Existence et unicité	§2.2 (PL : non-unicité caractérisée), §3.2 (non-concavité, cas $\gamma = 2$)
Théorèmes du cours, conditions d'optimalité	dualité en PL (§2.3), KKT, Th. 2.5.17 (§3.3), Euler, Th. 2.5.1 (annexe A)
Algorithme et convergence	simplexe en deux phases (§2.4), gradient projeté (§3.4, annexe A)
Plusieurs minima locaux ?	objectif non concave, multi-départs (§3.4)
Originalité	**méthode du simplexe**, **mise en œuvre de la dualité** (certificat, prix duaux)

1 Introduction : accélérer un modèle de langage

1.1 Un modèle de langage, vu par un optimiseur

Un texte est découpé en **tokens** : des mots ou des morceaux de mots, pris dans un vocabulaire fixe de n éléments ($n \approx 150\,000$ pour les modèles utilisés ici). Un **modèle de langage** est une fonction qui associe au début d'un texte une loi de probabilité $p \in \Delta_n = \{p \in \mathbb{R}_+^n : \sum_i p_i = 1\}$ sur le token suivant. Par exemple (valeurs illustratives), après « Le chat dort sur le », un modèle pourrait donner :

token suivant	`canapé`	`lit`	`tapis`	`toit`	autres
probabilité	0,40	0,25	0,20	0,05	0,10

Pour écrire, on tire un token selon p, on l'ajoute au texte et l'on recommence : c'est la génération **autorégressive**. Chaque token demande une **passe** du modèle, c'est-à-dire un calcul complet d'un réseau de neurones qui compte des milliards de paramètres, et ces passes sont séquentielles, puisque chaque token dépend des précédents. Une réponse de 500 tokens coûte 500 passes successives : c'est

le goulot d'étranglement. Un fait technique permet d'aller plus vite : en *une* passe, le modèle calcule la loi du token suivant à *toutes* les positions d'un texte donné (c'est ainsi qu'il est entraîné). Vérifier γ tokens déjà écrits coûte donc à peu près autant que d'en générer un seul.

1.2 Le décodage spéculatif : un petit modèle propose, le grand vérifie

On dispose de deux modèles : le **target**, grand et lent, dont on veut la qualité (ici Qwen2.5-1.5B, de loi p), et le **draft**, petit et rapide (Qwen2.5-0.5B, de loi q). À chaque étape, le draft propose un **bloc** de γ tokens, l'un après l'autre, ce qui est peu coûteux. Le target les examine tous en une seule passe et les accepte de gauche à droite tant qu'ils passent la vérification. Au premier rejet, il remplace le token rejeté par le sien et jette la fin du bloc ; si tout est accepté, il ajoute un token de plus. Une passe du target produit donc entre 1 et $\gamma + 1$ tokens au lieu d'un seul (figure 1), et la **vitesse** se mesure par le nombre moyen de tokens produits par passe du target. Sur les solutions de deux problèmes de mathématiques du jeu de données GSM8K, le target produit ainsi en moyenne 4,76 et 4,59 tokens par passe.

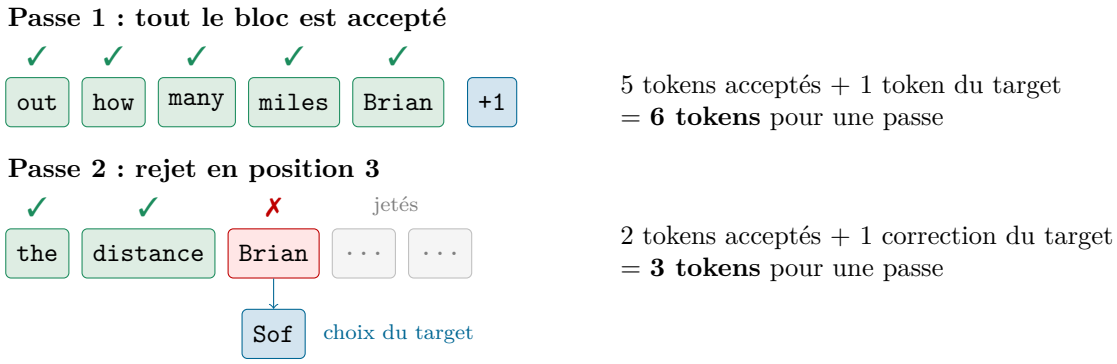


Figure 1 – Deux passes réelles sur un problème GSM8K (« Sofie marche deux fois plus que Brian… »), avec Qwen2.5-0.5B comme draft et Qwen2.5-1.5B comme target. Le draft propose 5 tokens ; le target les vérifie en une passe, en acceptant chaque token qui coïncide avec son propre choix (vert). Au premier désaccord (rouge), il émet son token (bleu) et jette la fin du bloc (gris). Sans draft, chaque passe ne produirait qu'un token.

1.3 Une règle de vérification qui ne change pas le texte produit

La figure 1 utilise la vérification la plus simple : le target accepte un token s'il coïncide avec son choix le plus probable. Pour échantillonner, c'est-à-dire tirer chaque token au hasard selon p (ce qui donne des textes variés), la règle de Leviathan et al. [1], proposée indépendamment par Chen et al. [2], accepte le token x proposé par le draft avec probabilité $\min(1, p_x/q_x)$; en cas de rejet, le target tire son token selon $(p-q)_+$ renormalisé. Le texte produit suit alors *exactement* la loi p du target : on va plus vite sans rien changer à la qualité.

Prenons un vocabulaire de trois tokens (`canapé`, `lit`, `tapis`), avec $p = (0{,}5; 0{,}3; 0{,}2)$ pour le target et $q = (0{,}2; 0{,}3; 0{,}5)$ pour le draft.

- Si le draft propose `canapé` (probabilité 0,2) ou `lit` (0,3), le target les veut au moins aussi souvent ($p_x \geq q_x$) : il accepte toujours.
- Si le draft propose `tapis` (probabilité 0,5), que le target ne veut qu'avec probabilité 0,2, il l'accepte avec probabilité $0{,}2/0{,}5 = 0{,}4$. Sinon (probabilité $0{,}5 \times 0{,}6 = 0{,}3$), il émet `canapé`, le seul token que le draft propose moins souvent que lui.

Le texte produit contient `canapé` avec probabilité $0{,}2 + 0{,}3 = 0{,}5$, `lit` avec probabilité 0,3 et `tapis` avec probabilité $0{,}5 \times 0{,}4 = 0{,}2$: c'est bien p. Le token proposé est accepté avec probabilité $0{,}2 + 0{,}3 + 0{,}2 = 0{,}7 = \sum_x \min(p_x, q_x)$. **Peut-on accepter plus souvent, tout en produisant exactement p ?** C'est la partie I : la réponse est non, et la question est un programme linéaire.

1.4 Relâcher la vérification, mais où ?

Si l'on tolère que le texte produit s'écarte un peu de p, on peut accepter plus souvent : dans l'exemple, accepter toujours `tapis` porte l'acceptation à 1, mais le texte suit alors la loi q du petit modèle. Entre les deux, une **déviation** ε (l'écart permis entre la loi du texte produit et p, mesuré en variation totale) donne une acceptation $\min(1, 0{,}7 + \varepsilon)$ (proposition 2). Cette vérification *avec perte* [4] soulève deux questions.

Toutes les positions ne se valent pas pour la qualité. Sur GSM8K, la plupart des rejets portent sur des **synonymes** sans effet sur la réponse (`determine` contre `find`). Quelques-uns portent sur des **pivots** qui orientent le raisonnement : dans la figure 1, le draft parle de la distance de Brian là où le target parle de celle de Sofie, et la suite du calcul en dépend ; ailleurs, il écrit « is `not` » au lieu de « is `left` », c'est-à-dire ce qui est utilisé au lieu de ce qui reste. Dévier sur un synonyme ne coûte rien, mais dévier sur un pivot fausse la réponse : on attribue à chaque position une **sensibilité** s_t, le coût en qualité d'une unité de déviation.

Toutes les positions ne se valent pas pour la vitesse. Un rejet interrompt le bloc : les premières positions conditionnent l'accès aux suivantes. Avec $\gamma = 3$ et des probabilités d'acceptation $(0{,}9; 0{,}5; 0{,}8)$, une passe produit en moyenne $1 + 0{,}9 + 0{,}9 \times 0{,}5 + 0{,}9 \times 0{,}5 \times 0{,}8 = 2{,}71$ tokens (formule du §3.1) : la position 3, pourtant facile, n'est atteinte qu'une fois sur deux. Gagner 0,1 d'acceptation en position 2 rapporte 0,162 token par passe, contre 0,045 en position 3.

Ce DM cherche donc **où dépenser un budget de déviation** pour aller le plus vite possible à perte de qualité donnée, compromis entre sensibilité et position. Nous en tirons deux problèmes d'optimisation, traités avec les outils du cours :

— **partie I (une position)** : la meilleure règle de vérification, exacte ou avec déviation ε, est la solution d'un programme linéaire, que l'on résout par le simplexe et la dualité ;

— **partie II (un bloc)** : la meilleure répartition d'un budget de déviation entre les γ positions est un problème non concave sous contraintes linéaires ; on écrit les conditions KKT et on le résout par gradient projeté.

Terme	Sens dans ce DM
token	mot ou morceau de mot, élément d'un vocabulaire de taille n
target, draft	grand modèle, de loi p sur le token suivant ; petit modèle, de loi q
passe	un calcul du target ; il vérifie tout un bloc en une passe
bloc, γ	suite de γ tokens proposés par le draft, interrompue au premier rejet
acceptation	probabilité qu'un token proposé soit accepté ; sans déviation, au mieux $\beta(p, q) = \sum_x \min(p_x, q_x)$
$\mathrm{TV}(p, q)$	variation totale $\frac{1}{2}\sum_x \lvert p_x - q_x \rvert$ (on montre que $\beta = 1 - \mathrm{TV}$)
déviation ε	écart permis, en variation totale, entre la loi du texte produit et p
sensibilité s_t	coût en qualité d'une unité de déviation à la position t

2 Partie I : vérifier un token est un programme linéaire

En bref. Pour une position, on cherche la règle de vérification qui accepte le plus souvent le token du draft tout en produisant exactement la loi p du target (§1.3). Une règle est décrite par une matrice de probabilités, et la question devient un programme linéaire ; on en déduit ensuite ce que rapporte une déviation ε.

2.1 Modèle

Une règle de vérification (exacte ou non) est décrite par la loi jointe du couple (token proposé, token émis) : $\pi \in \mathbb{R}_+^{n \times n}$, $\pi_{xy} = \mathbb{P}$(le draft propose x et l'on émet y). On accepte exactement quand $y = x$: l'acceptation est la trace de π. Le draft propose selon q (lignes) et la règle est exacte si le

token émis suit p (colonnes) :

$$(P_0) \qquad \max_{\pi \geq 0} \sum_x \pi_{xx} \quad \text{s.c.} \quad \sum_y \pi_{xy} = q_x \;\; (x = 1, \dots, n), \qquad \sum_x \pi_{xy} = p_y \;\; (y = 1, \dots, n).$$

Dans l'exemple du §1.3 (ordre `canapé`, `lit`, `tapis` ; lignes : token proposé, colonnes : token émis), la règle de Leviathan correspond à

$$\pi^L = \begin{pmatrix} 0{,}2 & 0 & 0 \\ 0 & 0{,}3 & 0 \\ \mathbf{0{,}3} & 0 & 0{,}2 \end{pmatrix} :$$

la case en gras se lit « le draft propose `tapis`, le target rejette et émet `canapé` ». Les lignes somment à q, les colonnes à p, et la trace vaut 0,7.

En forme standard ($\min c \cdot x$, $Ax = b$, $x \geq 0$), $c = -\operatorname{vec}(I_n)$, $b = (q, p) \in \mathbb{R}^{2n}$, et $A \in \{0,1\}^{2n \times n^2}$ a une colonne par variable π_{xy}, avec un 1 sur la ligne x et un 1 sur la ligne $n + y$.

— **Flot.** En multipliant par -1 les n lignes « colonne », chaque colonne de A a un $+1$ et un -1 : c'est la matrice d'incidence d'un graphe biparti orienté, totalement unimodulaire par le lemme de Poincaré (Lemme 4.3.5) ; changer le signe d'une ligne ne change que des signes de déterminants, donc A est TU. Comme b n'est pas entier, cela ne sert pas à l'intégrité, mais situe (P_0) parmi les problèmes de flot du cours.

— **Rang.** Les n lignes du haut et les n lignes du bas ont la même somme $(1, \dots, 1)$, donc $\operatorname{rg}(A) \leq 2n - 1$; sans la ligne « colonne 1 », les colonnes de π_{11}, des π_{1y} $(y \geq 2)$ et des π_{x1} $(x \geq 2)$ engendrent $\mathbb{R}^{2n-1}$, donc $\operatorname{rg}(A) = 2n - 1$. Le cours supposant A de rang plein, le code retire une ligne avant le simplexe.

— **Compatibilité.** Le système exige $\sum_x q_x = \sum_y p_y$; les lois réelles (sommes 1 ± 10^{-6} en float32) sont donc renormalisées.

2.2 Existence, valeur et (non-)unicité

L'ensemble admissible est non vide (couplage indépendant $\pi_{xy} = q_x p_y$) et borné ($0 \leq \pi_{xy} \leq q_x$) : c'est un polyèdre compact, et le maximum de l'objectif linéaire est atteint (Th. 2.2.1), en un sommet (Prop. 4.2.6).

Proposition 1 (valeur de (P_0))**.** *La valeur de (P_0) vaut $\beta(p, q) = 1 - \mathrm{TV}(p, q)$. Les solutions optimales sont exactement les $\pi \geq 0$ telles que $\pi_{xx} = \min(p_x, q_x)$ et dont la partie hors diagonale a pour marges $(q - p)_+$ (lignes) et $(p - q)_+$ (colonnes). La solution est unique si et seulement si l'un de ces deux vecteurs a au plus une composante non nulle.*

On utilise $\min(a, b) + (a - b)_+ = a$ et $\sum_x (p_x - q_x)_+ = \sum_x (q_x - p_x)_+ = \mathrm{TV}$ (leur différence vaut $\sum_x (p_x - q_x) = 0$, leur somme $2\,\mathrm{TV}$), d'où $\beta = \sum_x \big(p_x - (p_x - q_x)_+\big) = 1 - \mathrm{TV}$.

Démonstration. Majoration. Une case diagonale est majorée par la somme de sa ligne et par celle de sa colonne : $\pi_{xx} \leq \min(p_x, q_x)$, donc $\sum_x \pi_{xx} \leq \beta$.

Borne atteinte. Si $\mathrm{TV} = 0$, $\operatorname{diag}(p)$ convient. Sinon, la règle de [1] induit le couplage

$$\pi^L = \operatorname{diag}\big(\min(p, q)\big) + \frac{(q - p)_+ \, (p - q)_+^\top}{\mathrm{TV}} :$$

proposer x et l'accepter a probabilité $q_x \min(1, p_x/q_x) = \min(p_x, q_x)$; proposer x et le rejeter a probabilité $(q_x - p_x)_+$, puis y est tiré selon $(p - q)_+/\mathrm{TV}$. Ses lignes valent $\min(p_x, q_x) + (q_x - p_x)_+ = q_x$, ses colonnes $\min(p_y, q_y) + (p_y - q_y)_+ = p_y$, et le terme de rang 1 est nul sur la diagonale ($(q_x - p_x)_+ (p_x - q_x)_+ = 0$) : sa trace vaut β.

Toutes les solutions. À l'optimum, les inégalités de la majoration sont des égalités : $\pi_{xx} = \min(p_x, q_x)$. Il reste $(q_x - p_x)_+$ à placer sur la ligne x et $(p_y - q_y)_+$ sur la colonne y, et une case

hors diagonale non nulle exige $q_x > p_x$ et $p_y > q_y$. Réciproquement, tout $\pi \geq 0$ de cette forme est admissible et de trace β.

Unicité. Supposons que $\{q > p\}$ et $\{p > q\}$ aient chacun au moins deux éléments. Chaque colonne de $\{p > q\}$ reçoit une masse > 0, d'où $\pi_{x_1 y_1} > 0$ et $\pi_{x_2 y_2} > 0$ avec $y_1 \neq y_2$; si $x_1 = x_2$, une autre ligne $x' \in \{q > p\}$ a une case $\pi_{x' y''} > 0$, avec y'' différent de y_1 ou de y_2. On dispose ainsi de $\pi_{xy} > 0$ et $\pi_{x'y'} > 0$ avec $x \neq x'$, $y \neq y'$. Retirer $\delta \in]0, \min(\pi_{xy}, \pi_{x'y'})]$ à ces deux cases et l'ajouter à $\pi_{xy'}$ et $\pi_{x'y}$ conserve les marges et la diagonale (les quatre cases sont hors diagonale, car $\{q > p\} \cap \{p > q\} = \emptyset$) : c'est une autre solution optimale. Si l'un des deux ensembles a au plus un élément, la partie hors diagonale est forcée, et la solution est unique. □

2.3 Dualité : un certificat d'optimalité explicite

Le dual de $\min\{c \cdot x : Ax = b,\ x \geq 0\}$ est $\max\{b \cdot \mu : A^\top \mu \leq c\}$ (Th. 4.2.13). Avec $\mu = (\varphi, \psi)$ (multiplicateurs des lignes et des colonnes), $(A^\top \mu)_{xy} = \varphi_x + \psi_y$ et $c_{xy} = -\delta_{xy}$:

$$(D_0) \qquad \max_{\varphi, \psi} \ q \cdot \varphi + p \cdot \psi \quad \text{s.c.} \quad \varphi_x + \psi_y \leq -\delta_{xy} \quad \forall x, y.$$

Pour π et μ admissibles, $c \cdot \pi \geq (A^\top \mu) \cdot \pi = \mu \cdot b$ (dualité faible) : une égalité certifie l'optimalité des deux. Posons $S = \{x : q_x \leq p_x\}$, $\varphi_x = -1$ si $x \in S$ et 0 sinon, $\psi_y = 0$ si $y \in S$ et -1 sinon. Sur la diagonale, exactement l'un des deux vaut -1, donc $\varphi_x + \psi_x = -1$; hors diagonale, $\varphi_x + \psi_y \leq 0$: (φ, ψ) est admissible, de valeur $-\sum_{x \in S} q_x - \sum_{y \notin S} p_y = -\beta = c \cdot \pi^L$. Les deux sont donc optimaux, ce qui redémontre la proposition 1. Les écarts complémentaires ($\pi_{xy} > 0 \Rightarrow \varphi_x + \psi_y = c_{xy}$) se vérifient sur π^L : une case hors diagonale non nulle a $q_x > p_x$ et $p_y > q_y$, donc $\varphi_x + \psi_y = 0 = c_{xy}$. *Lecture :* $\varphi_x = -1$ marque les tokens que le draft propose « trop peu » ($q_x \leq p_x$), toujours acceptés.

2.4 Simplexe révisé en deux phases, et validation

Le simplexe est programmé comme dans le cours. Avec la base $\mathcal{B}$ et les hors-base $\mathcal{N}$: $x_\mathcal{B} = A_\mathcal{B}^{-1} b$, multiplicateurs $\mu = A_\mathcal{B}^{-\top} c_\mathcal{B}$, coûts réduits $\tilde{c}_\mathcal{N} = c_\mathcal{N} - A_\mathcal{N}^\top \mu$; si $\tilde{c}_\mathcal{N} \geq 0$, la base est optimale (Prop. 4.2.8) ; sinon, la variable de coût réduit le plus négatif entre, et le test du ratio $\theta^* = \min\{x_{\mathcal{B},i}/d_i : d_i > 0\}$, avec $d = A_\mathcal{B}^{-1} A_j$, désigne la variable sortante. La phase 1 (variables artificielles) fournit une base admissible, ou prouve que le problème ne l'est pas. Les bases sont très dégénérées ($2n - 1$ variables de base, souvent nulles) : pour exclure le cyclage, on passe à la règle de Bland après $2m$ pivots dégénérés consécutifs ($m = 2n - 1$ contraintes). Les multiplicateurs de la base finale donnent le dual (§2.5).

Validation. Sur 300 paires synthétiques ($n = 3$ à 12, lois de Dirichlet plus ou moins piquées), notre simplexe, le solveur HiGHS de SciPy et la formule β coïncident à $4{,}4 \times 10^{-16}$ près ; sur 320 paires réelles (Qwen2.5, réduites aux 6 tokens les plus probables de chaque modèle plus une case « autres »), à $3{,}5 \times 10^{-11}$ près, au niveau de la tolérance du test d'optimalité (figure 2a). Des tests unitaires vérifient l'admissibilité duale, la dualité forte et le certificat (φ, ψ). Le nombre d'itérations croît environ comme $n^{1{,}7}$: pour un vrai vocabulaire ($n \approx 150\,000$, plus de 2×10^{10} variables), on utilise la formule fermée, que le simplexe sert à valider. Enfin, le simplexe renvoie un sommet (8 cases non nulles, au plus $2n - 1 = 9$) et π^L en a 11 : deux optimums distincts, comme le prévoit la proposition 1 (figure 2b-c).

2.5 Vérification avec perte et prix dual du budget

On autorise la loi émise r à s'écarter de p d'au plus ε en variation totale : la seconde marge de π devient une variable r (automatiquement une loi), et l'on linéarise $|r_y - p_y|$ par $t_y \geq \pm(r_y - p_y)$ (le choix $t_y = |r_y - p_y|$ montre que les deux formulations ont les mêmes (π, r) admissibles) :

$$(P_\varepsilon) \qquad \max_{\pi, r, t \geq 0} \sum_x \pi_{xx} \quad \text{s.c.} \quad \textstyle\sum_y \pi_{xy} = q_x, \quad \sum_x \pi_{xy} = r_y, \quad t_y \geq \pm(r_y - p_y), \quad \sum_y t_y \leq 2\varepsilon.$$

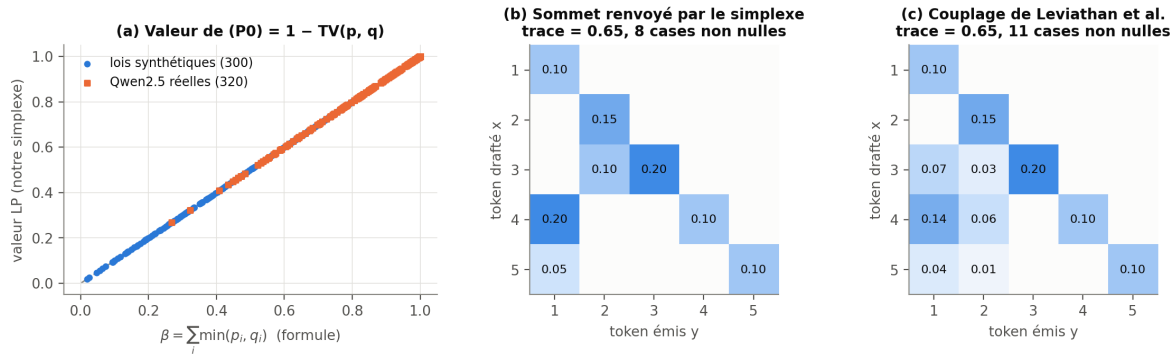


Figure 2 – (a) Valeur de (P_0) calculée par notre simplexe contre la formule $\beta = \sum \min(p, q)$. (b-c) Deux couplages optimaux pour $p = (0{,}35; 0{,}25; 0{,}2; 0{,}1; 0{,}1)$ et $q = (0{,}1; 0{,}15; 0{,}3; 0{,}3; 0{,}15)$: même diagonale, partie hors diagonale différente.

Proposition 2 (frontière avec perte)**.** *La valeur de* (P_ε) *vaut* $\alpha^*(\varepsilon) = \min(1, \beta + \varepsilon)$*, atteinte pour* $r_\varepsilon = p + \theta(q - p)$*,* $\theta = \min(1, \varepsilon/\mathrm{TV})$.

Démonstration. Pour (π, r, t) admissible, π couple q et r : par la proposition 1 et l'inégalité triangulaire, $\sum_x \pi_{xx} \le 1 - \mathrm{TV}(q, r) \le 1 - \mathrm{TV}(q, p) + \mathrm{TV}(r, p) \le \beta + \varepsilon$, et $\sum_x \pi_{xx} \le 1$. Inversement, $\mathrm{TV}(r_\varepsilon, p) = \theta\,\mathrm{TV} \le \varepsilon$ et $\mathrm{TV}(q, r_\varepsilon) = (1 - \theta)\mathrm{TV}$: le couplage de Leviathan entre q et r_ε accepte avec probabilité $\beta + \theta\,\mathrm{TV} = \min(1, \beta + \varepsilon)$. □

Le multiplicateur du budget est une pente. Soit $V(\varepsilon) = -\alpha^*(\varepsilon)$ la valeur en minimisation. L'ensemble dual $D = \{\mu : A^\top \mu \le c\}$ ne dépend pas de ε ; seul le second membre $b(\varepsilon) = b_0 + 2\varepsilon\, e_{\text{budget}}$ en dépend. Par dualité forte, $V(\varepsilon) = \max_{\mu \in D} b(\varepsilon) \cdot \mu$ est convexe et, pour un dual optimal μ^* en ε, $V(\varepsilon') \ge b(\varepsilon') \cdot \mu^* = V(\varepsilon) + 2\mu^*_B(\varepsilon' - \varepsilon)$. Le **prix du budget** $\kappa = -2\mu^*_B \ge 0$ ($\mu^*_B \le 0$, car l'écart de la ligne de budget a un coût nul) est donc un sur-gradient de α^* : le gain d'acceptation par unité de déviation. Il vaut 1 pour $\varepsilon < \mathrm{TV}$ et 0 au-delà, ce que renvoie le simplexe (figure 3b) ; aux coins, il n'est pas unique (tout $\kappa \in [0, 1]$ en $\varepsilon = \mathrm{TV}$, tout $\kappa \ge 1$ en $\varepsilon = 0$). **Une unité de déviation achète exactement une unité d'acceptation** tant qu'il reste du désaccord : c'est la frontière linéaire de [3], retrouvée avec les outils du cours, et la brique de la partie II.

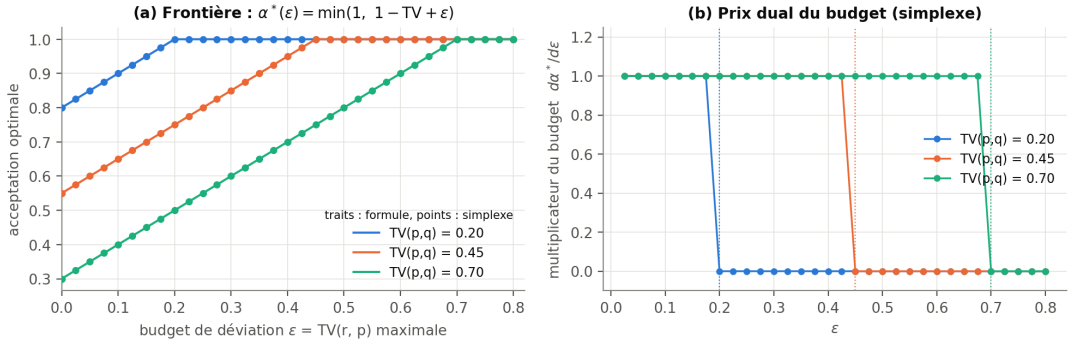


Figure 3 – (a) Acceptation optimale en fonction de ε pour trois paires (p, q) ; points : simplexe, traits : proposition 2. (b) Prix du budget $\kappa = -2\mu^*_B = d\alpha^*/d\varepsilon$ tiré du dual renvoyé par le simplexe : 1 avant $\varepsilon = \mathrm{TV}$ (pointillés), 0 après.

3 Partie II : répartir le budget entre les positions d'un bloc

En bref. On dispose maintenant d'un budget de déviation pour tout un bloc. Dévier à la position t augmente son acceptation (partie I) mais coûte s_t par unité en qualité ; on cherche la répartition qui

maximise le nombre moyen de tokens par passe du target, à budget de qualité donné (§1.4).

3.1 Modèle

Un bloc compte γ positions. La position t a une acceptation exacte $a_t = \beta(p_t, q_t) \in (0,1)$ et une **sensibilité** $s_t > 0$ (baisse de qualité de la réponse par unité de déviation). Les variables sont les déviations $\varepsilon \in \mathbb{R}^\gamma$, sous trois hypothèses : (H1) acceptations indépendantes, comme dans [1] ; (H2) perte de qualité additive, $\sum_t s_t\varepsilon_t$; (H3) par la proposition 2, relâcher la position t de ε_t donne l'acceptation $\alpha_t = a_t + \varepsilon_t$, avec $0 \le \varepsilon_t \le u_t := 1 - a_t$ (la *marge*).

Le bloc s'arrête au premier rejet : « au moins k acceptés » signifie « les k premiers acceptés », de probabilité $P_k = \alpha_1 \cdots \alpha_k$ ($P_0 = 1$). Avec $\mathbb{E}[N] = \sum_{k\ge1} \mathbb{P}(N \ge k)$ et le token que le target émet à la fin de chaque passe, le nombre moyen de tokens par passe vaut

$$E(\varepsilon) = 1 + \sum_{k=1}^{\gamma} \prod_{j=1}^{k} (a_j + \varepsilon_j), \qquad (Q_B) \quad \max_{\varepsilon \in K} E(\varepsilon), \quad K = \{0 \le \varepsilon \le u,\ s\cdot\varepsilon \le B\}.$$

C'est la formule de l'exemple du §1.4. Les contraintes sont affines. Ce problème est le **modèle B** (« bloc »). On le compare à un modèle plus naïf, le **modèle A** (« additif ») : il fait comme si chaque position était vérifiée séparément, le rejet de l'une n'empêchant pas de vérifier les suivantes, et maximise donc $\sum_t \alpha_t$ sous les mêmes contraintes. C'est un sac à dos fractionnaire, qui relâche d'abord les positions les moins sensibles. Dans l'exemple du §1.4, A voit le même gain (+0,1) en position 2 ou 3, alors que le vrai gain vaut 0,162 contre 0,045.

3.2 Existence et structure

K est un polyèdre non vide ($0 \in K$) et compact, E est continue : un maximum existe (Th. 2.2.1, dont l'hypothèse de coercivité est vraie par vacuité sur un borné, puisqu'aucune suite n'y tend vers l'infini). α_t n'apparaît, linéairement, que dans les P_k avec $k \ge t$, d'où

$$\partial_t E = P_{t-1}\, T_t > 0, \qquad T_t = 1 + \alpha_{t+1} + \alpha_{t+1}\alpha_{t+2} + \cdots + \alpha_{t+1}\cdots\alpha_\gamma,$$

produit de la **probabilité d'atteindre** la position t et du **nombre de tokens** que son acceptation débloque. E est affine en chaque variable, donc $\partial^2_{tt} E = 0$, et pour $i < j$, $\partial^2_{ij} E = P_{i-1}(\prod_{i<k<j} \alpha_k) T_j > 0$. La hessienne, symétrique, non nulle et de trace nulle, a une valeur propre > 0 en tout point : E **n'est pas concave**, et les résultats d'unicité par convexité (Prop. 2.3.4, Th. 2.3.8) ne s'appliquent pas. Les dérivées croisées positives rendent les positions **complémentaires** : relâcher l'une fait atteindre plus souvent les suivantes.

Lemme 1 (concavité le long des échanges)**.** *Pour $i \ne j$, la direction $d = s_j e_i - s_i e_j$ conserve le coût, et $h \mapsto E(\varepsilon + hd)$ est un trinôme strictement concave.*

Démonstration. À autres coordonnées fixées, $E = c_0 + c_i\alpha_i + c_j\alpha_j + \partial^2_{ij}E\,\alpha_i\alpha_j$; le long de d, le coefficient de h^2 vaut $-s_i s_j\, \partial^2_{ij} E < 0$. □

La non-concavité vient donc des directions qui font varier plusieurs positions dans le même sens.

Lemme 2 (budget saturé)**.** *En tout maximum local, $s\cdot\varepsilon = B$, ou bien $\varepsilon = u$ (budget surabondant).*

Démonstration. Si $s\cdot\varepsilon < B$ et $\varepsilon_t < u_t$, augmenter ε_t reste admissible et augmente E, car $\partial_t E > 0$. □

Proposition 3 (cas $\gamma = 2$: unicité et solution explicite)**.** *Si $B < s\cdot u$, le maximum est unique. Avec $\kappa_s = s_1/s_2$, $c = a_2 + B/s_2$ et $\eta^* = \frac{1}{2}((1+c)/\kappa_s - a_1)$, on a $\varepsilon_1^* = \mathrm{proj}_{[\eta_-,\eta_+]}(\eta^*)$ et $\varepsilon_2^* = (B - s_1\varepsilon_1^*)/s_2$, où $[\eta_-, \eta_+] = \big[\max\big(0, (B - s_2u_2)/s_1\big), \min\big(u_1, B/s_1\big)\big]$. Si $\eta_- < \eta^* < \eta_+$,*

$$E^*(B) = 1 + \frac{(1 + c + \kappa_s a_1)^2}{4\kappa_s}, \qquad \lambda^* = \frac{1 + c + \kappa_s a_1}{2 s_1} = \frac{dE^*}{dB}.$$

Démonstration. Par le lemme 2, le maximum est sur le segment $s\cdot\varepsilon = B$. Avec $\varepsilon_1 = \eta$, on a $\alpha_1 = a_1+\eta$ et $\alpha_2 = c-\kappa_s\eta$, d'où $E(\eta) = 1+(a_1+\eta)(1+c-\kappa_s\eta)$, un trinôme strictement concave ($E'' = -2\kappa_s$, c'est le lemme 1) : son maximum sur $[\eta_-, \eta_+]$ est unique, égal à η^* projeté. Si η^* est intérieur, on obtient E^*, et $dc/dB = 1/s_2$ donne $dE^*/dB = (1+c+\kappa_s a_1)/(2s_1) = (1+\alpha_2^*)/s_1 = \partial_1 E/s_1 = \lambda^*$ (§3.3). □

Proposition 4 (positions identiques : relâcher d'abord le début)**.** *Si $a_t \equiv a$ et $s_t \equiv s$, toute solution optimale vérifie $\alpha_1 \geq \alpha_2 \geq \cdots \geq \alpha_\gamma$.*

Démonstration. Si $\alpha_t < \alpha_{t+1}$ à l'optimum, échanger ε_t et ε_{t+1} reste admissible ; seul $P_t = P_{t-1}\alpha_t$ change (les P_k, $k > t$, contiennent le produit $\alpha_t\alpha_{t+1}$), et E augmente de $P_{t-1}(\alpha_{t+1}-\alpha_t) > 0$: contradiction. □

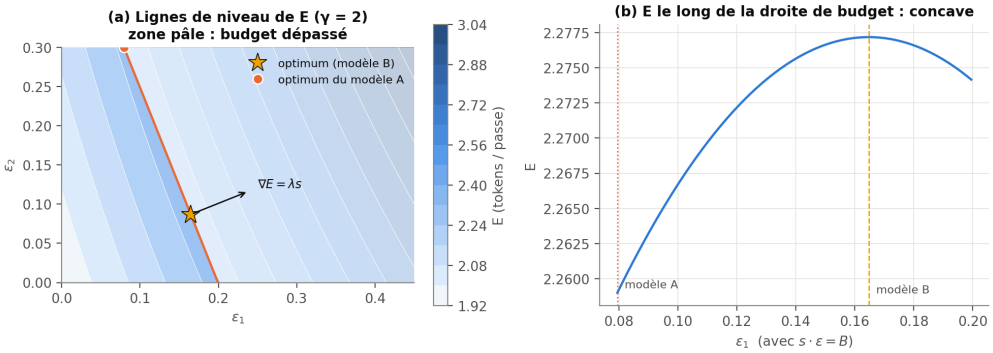


Figure 4 – $\gamma = 2$, $a = (0{,}55; 0{,}7)$, $s = (1{,}5; 0{,}6)$, $B = 0{,}35\, s\cdot u$. (a) À l'optimum $\varepsilon^* = (0{,}165; 0{,}087)$, $\nabla E = \lambda s$ avec $\lambda = 1{,}191 = dE^*/dB$. (b) Le long de la droite de budget, E est un trinôme concave ($E'' = -5$) : $E^* = 2{,}277$ (proposition 3, retrouvé par le gradient projeté), contre 2,259 pour le modèle A, qui choisit le bord.

3.3 Conditions d'optimalité (KKT)

Les contraintes s'écrivent $F_i(\varepsilon) \leq 0$: budget $s\cdot\varepsilon - B$ (multiplicateur λ), bornes $-\varepsilon_t$ et $\varepsilon_t - u_t$ (multiplicateurs μ_t^0, μ_t^1). Elles sont affines, donc qualifiées en tout point : la définition 2.5.15 autorise l'égalité $\langle \nabla F_i, w\rangle = 0$ pour les contraintes affines, et $w = 0$ convient (Rq. 2.5.16). Le Th. 2.5.17, appliqué à $J = -E$, donne en tout maximum local de E des $\lambda, \mu^0, \mu^1 \geq 0$ tels que

$$\nabla E(\varepsilon) = \lambda s - \mu^0 + \mu^1, \qquad \lambda(s\cdot\varepsilon - B) = 0, \quad \mu_t^0\varepsilon_t = 0, \quad \mu_t^1(u_t - \varepsilon_t) = 0.$$

Ces conditions sont **seulement nécessaires** : J n'est pas convexe, donc le théorème de Kuhn–Tucker (Th. 2.6.4) ne s'applique pas.

Règle de seuil. Avec le **rendement** $\rho_t = \partial_t E/s_t$ (tokens gagnés par unité de qualité perdue) : $\rho_t = \lambda$ si $0 < \varepsilon_t < u_t$, $\rho_t \leq \lambda$ si $\varepsilon_t = 0$, $\rho_t \geq \lambda$ si $\varepsilon_t = u_t$. On relâche les positions dont le rendement dépasse le prix λ. Pour le modèle A, $\rho_t = 1/s_t$: on sature les positions par sensibilité croissante (sac à dos). Pour le modèle B, $\rho_t = P_{t-1}T_t/s_t$ dépend de la **place** : une position précoce est atteinte souvent et débloque beaucoup de tokens. C'est pourquoi le budget va au début du bloc.

λ est le prix marginal du budget. Soit ε^* optimal pour B, avec une position intérieure t, et $0 < h \leq s_t \min(\varepsilon_t^*, u_t - \varepsilon_t^*)$. Les points $\varepsilon^* \pm (h/s_t)e_t$ sont admissibles pour les budgets $B\pm h$, et E, affine en ε_t, y vaut exactement $E^*(B)\pm\partial_t E\, h/s_t = E^*(B)\pm\lambda h$ (car $\rho_t = \lambda$). Donc $E^*(B\pm h) \geq E^*(B)\pm\lambda h$:

$$\frac{E^*(B) - E^*(B-h)}{h} \;\leq\; \lambda \;\leq\; \frac{E^*(B+h) - E^*(B)}{h}. \tag{1}$$

Là où E^* est dérivable, $\lambda = dE^*/dB$: c'est l'analogue du lemme 2.6.6 du cours, qui suppose la convexité, obtenu ici grâce à la seule structure multilinéaire de E.

3.4 Algorithme : gradient projeté, et question des maxima locaux

On utilise le gradient projeté du cours, en montée : $\varepsilon_{k+1} = P_K(\varepsilon_k + \tau \nabla E(\varepsilon_k))$.

Projection. $P_K(y)$ minimise $\frac{1}{2}\|z - y\|^2$, fortement convexe : elle existe et est unique (Th. 2.3.8). En dualisant le budget avec $\nu \geq 0$, le problème se sépare et donne $z_t(\nu) = \mathrm{clip}(y_t - \nu s_t, 0, u_t)$. On prend $\nu = 0$ si $s \cdot z(0) \leq B$; sinon, $\Phi(\nu) = s \cdot z(\nu)$ décroît continûment de $\Phi(0) > B$ à 0, et une dichotomie trouve $\Phi(\nu) = B$. Avec les multiplicateurs des bornes $\omega_t^0 = (\nu s_t - y_t)_+$ et $\omega_t^1 = (y_t - \nu s_t - u_t)_+$, $(z(\nu), \nu, \omega^0, \omega^1)$ vérifie KKT pour ce problème convexe à contraintes affines, où ces conditions sont suffisantes (Th. 2.6.4) : $z(\nu) = P_K(y)$.

Pas. Sur K, $\alpha \in [0,1]^\gamma$ donne $|\partial^2_{ij} E| \leq \gamma - \max(i,j) + 1$; la norme de Frobenius majorant la norme de la hessienne, ∇E est L-lipschitzien sur K avec

$$L = \Big(\sum_{i \neq j} \big(\gamma - \max(i,j) + 1\big)^2 \Big)^{1/2}, \qquad \text{et l'on prend } \tau = 1/L.$$

Convergence. Le Th. 3.4.1 suppose J α-convexe et ne s'applique pas, pas plus qu'Uzawa (Th. 3.4.3). On montre en annexe A, avec l'inéquation d'Euler, que $E(\varepsilon_k)$ croît, que les pas tendent vers 0 et que toute valeur d'adhérence vérifie KKT : c'est la meilleure garantie générale pour un problème non concave.

Global ou local ? Sur 100 instances aléatoires ($\gamma \in \{3,4,6,8\}$), 20 départs aléatoires chacune aboutissent à la même valeur, à $1{,}8 \times 10^{-15}$ près (résidu KKT $\leq 2{,}9 \times 10^{-10}$) : nous n'avons **jamais observé deux maxima locaux distincts**. Le problème est non concave mais, empiriquement, unimodal ; l'unicité n'est démontrée que pour $\gamma = 2$.

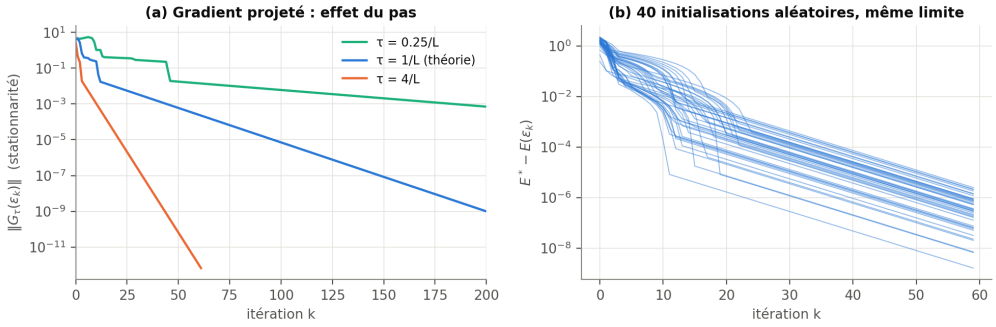


Figure 5 – Instance $\gamma = 8$. (a) Norme de l'application gradient : convergence linéaire, en 279 itérations pour $\tau = 1/L$ (62 pour $\tau = 4/L$, sans garantie de montée). (b) 40 départs aléatoires convergent vers la même valeur $E^* = 5{,}4544$.

3.5 Résultats : où placer la déviation ?

On prend $\gamma = 6$, $a_t = 0{,}6$, $B = 0{,}3\, B_{\max}$ ($B_{\max} = s \cdot u$) et trois profils de sensibilité (figure 6). **S1** ($s_t = 1$) : B relâche dans l'ordre $1, 2, \ldots$ (proposition 4) ; A est indifférent entre toutes les répartitions de même coût, y compris « fin d'abord », qui ne donne que $E = 2{,}54$ contre 4,12. **S2** (début plus sensible, $s = (2; 1{,}7; 1{,}4; 1{,}1; 0{,}8; 0{,}5)$) : A relâche les dernières positions, les moins chères ; B relâche malgré tout les **premières**, avec $E = 3{,}52$ contre 2,79 pour A (+26 %) et 3,21 pour une déviation uniforme ; à l'optimum, $\rho_1 = \rho_2 = \lambda = 1{,}308$ et $\rho_t < \lambda$ ailleurs, comme le prévoit KKT. **S3** (pivots coûteux en positions 2 et 5) : B évite le pivot tardif mais relâche en partie le pivot précoce, qui conditionne l'accès aux positions suivantes (4,98 contre 4,96 pour A).

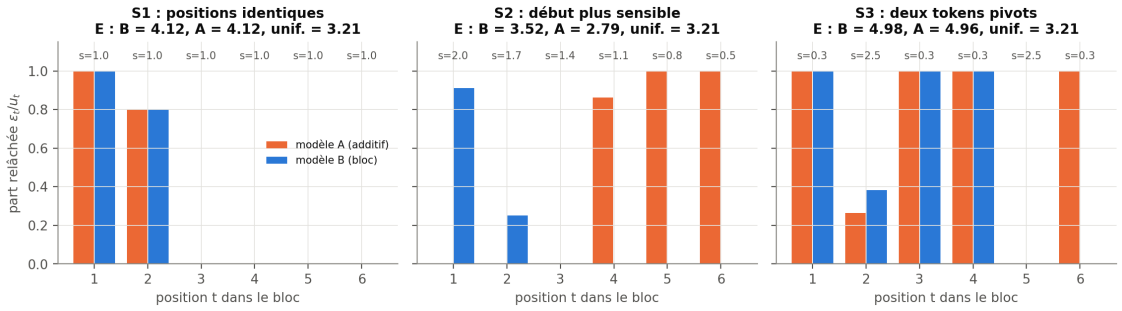


Figure 6 – Part relâchée ε_t/u_t par position, pour le modèle additif A (orange) et le modèle par blocs B (bleu) ; les sensibilités s_t sont indiquées au-dessus des positions.

Frontière vitesse–budget (figure 7). En S2, l'optimum gagne jusqu'à 0,97 token par passe sur A et 0,40 sur la déviation uniforme ; l'heuristique « fin d'abord », qui vérifie plus strictement le début comme [5] pour la sécurité, est toujours la plus lente. La forme de $E^*(B)$ dépend du profil : convexe en S2, où la complémentarité pousse à concentrer la déviation sur les deux premières positions ; essentiellement concave en S3, où l'on dépense d'abord sur les positions bon marché, puis sur les pivots, comme dans un sac à dos. L'encadrement (1) explique ces deux formes. Pour $B < s \cdot u$, le budget est saturé ; si B n'est pas l'une des valeurs « sommets » $B_I = \sum_{t\in I} s_t u_t$ ($I \subset \{1,\dots,\gamma\}$), l'optimum n'est pas un sommet du pavé, donc il a une position intérieure, et (1) donne une droite d'appui locale de pente λ sous E^*. Une fonction continue qui a une telle droite en tout point d'un intervalle y est convexe [1]. Ainsi, E^* **est convexe entre deux valeurs** B_I **consécutives, et sa pente ne peut baisser qu'en un** B_I : en S3, elle chute en B_I pour $I = \{1\}$, $\{1,3\}$, $\{1,3,4\}$ et $\{1,2,3,4,6\}$, à chaque fois qu'une position est saturée.

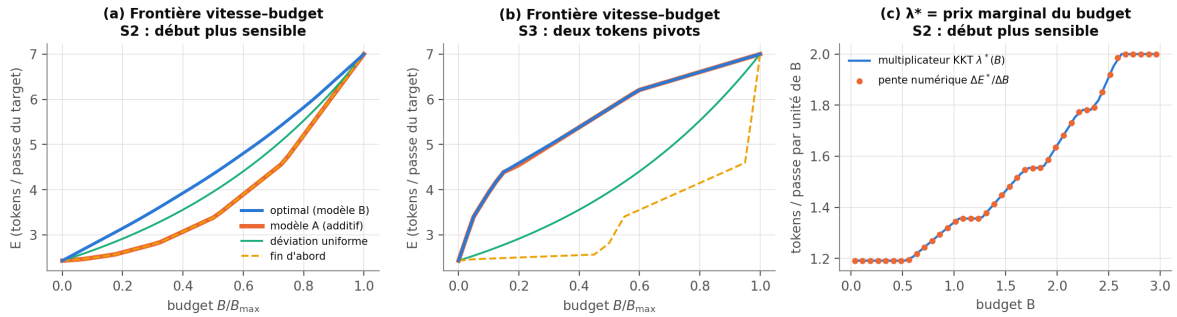


Figure 7 – (a-b) Tokens par passe en fonction du budget, pour l'optimum et trois heuristiques. (c) Multiplicateur KKT $\lambda^*(B)$ et pente numérique $\Delta E^*/\Delta B$ en S2 : λ est bien le prix marginal du budget.

4 Données réelles et conclusion

Données réelles. Le target (Qwen2.5-1.5B) rédige des solutions à 16 problèmes GSM8K (2344 tokens) ; à chaque position, on calcule $a_t = \beta(p_t, q_t)$ sur le vocabulaire complet, avec le draft Qwen2.5-0.5B. L'acceptation exacte moyenne vaut 0,893 (0,982 sur les tokens contenant un chiffre). Les sensibilités n'étant pas mesurées dans ce DM, on prend le proxy $s_t = 10$ pour les tokens contenant un chiffre et $s_t = 1$ sinon, et l'on optimise des blocs de $\gamma = 5$ sous un budget commun. À $B = 0{,}2\,B_{\max}$, on obtient 5,18 tokens par passe (optimum), contre 4,98 (modèle A) et 4,87 (uniforme). L'optimum relâche la première position du bloc à 73 % de sa marge, la deuxième à 43 % et les suivantes à 0 %, là où A répartit uniformément (22 à 28 %) : on retrouve sur données réelles que la déviation doit

1. Sinon, E^* moins une de ses cordes atteindrait un maximum > 0 en un point intérieur ; la droite d'appui y aurait la pente de la corde, et l'ensemble des points de maximum serait ouvert et fermé sans être tout l'intervalle, ce qui contredit la connexité. E^* est continue : si ε' est optimal pour $B' > B > 0$, $(B/B')\varepsilon'$ est admissible pour B.

aller au **début** du bloc.

Conclusion. Les deux problèmes se traitent avec les outils du cours. La partie I est un PL de transport : le simplexe et la dualité en donnent la valeur $(1 - \mathrm{TV})$, un certificat explicite et le prix exact d'une unité de déviation. La partie II est un problème non concave sous contraintes affines : les contraintes sont qualifiées, les conditions KKT donnent une règle de seuil dont le seuil λ est le prix marginal exact du budget, et le gradient projeté converge vers un point KKT, le même depuis tous nos départs. Pour notre projet de recherche, **la structure en bloc change la réponse** : une règle qui relâche les tokens peu sensibles sans tenir compte de leur position peut perdre plus d'un cinquième de la vitesse atteignable, et la vitesse pousse à relâcher le début du bloc, à l'opposé des heuristiques de sécurité [5]. **Limites :** (H1) ignore la corrélation entre positions, (H2) est une approximation au premier ordre, les blocs réels se recalent après chaque rejet, et nos sensibilités sont des hypothèses, que le projet devra mesurer.

A Convergence du gradient projeté (cas non concave)

Notons $g = \nabla E(\varepsilon_k)$, $\varepsilon^+ = \varepsilon_{k+1} = P_K(\varepsilon_k + \tau g)$, $d = \varepsilon^+ - \varepsilon_k$, et $0 < \tau < 2/L$.

1. **Projection.** $P_K(y)$ minimise la fonction convexe $\frac{1}{2}\|z - y\|^2$ sur le convexe K ; l'inéquation d'Euler (Th. 2.5.1), nécessaire et ici suffisante, donne

$$z^* = P_K(y) \iff z^* \in K \quad \text{et} \quad \langle z^* - y, w - z^* \rangle \geq 0 \quad \forall w \in K. \tag{A.1}$$

   Avec $y = \varepsilon_k + \tau g$, $z^* = \varepsilon^+$ et $w = \varepsilon_k$: $\langle d - \tau g, -d \rangle \geq 0$, soit $\langle g, d \rangle \geq \|d\|^2/\tau$.

2. **Montée.** Sur le segment $[\varepsilon_k, \varepsilon^+] \subset K$, ∇E est L-lipschitzien ; par Taylor avec reste intégral, $E(\varepsilon^+) \geq E(\varepsilon_k) + \langle g, d \rangle - \frac{L}{2}\|d\|^2$, d'où

$$E(\varepsilon_{k+1}) \;\geq\; E(\varepsilon_k) + \Big(\frac{1}{\tau} - \frac{L}{2}\Big)\|\varepsilon_{k+1} - \varepsilon_k\|^2, \qquad \frac{1}{\tau} - \frac{L}{2} > 0. \tag{A.2}$$

3. **Conséquences.** $E(\varepsilon_k)$ croît et reste majorée par $1+\gamma$; en sommant (A.2), $\sum_k \|\varepsilon_{k+1} - \varepsilon_k\|^2 < \infty$, donc $\|\varepsilon_{k+1} - \varepsilon_k\| \to 0$. K étant compact, une sous-suite ε_{k_j} converge vers $\bar{\varepsilon}$, ainsi que ε_{k_j+1} ; par continuité de P_K (1-lipschitzienne) et de ∇E, $\bar{\varepsilon} = P_K\big(\bar{\varepsilon} + \tau \nabla E(\bar{\varepsilon})\big)$.

4. **Point fixe $\iff$ Euler $\iff$ KKT.** Par (A.1), ce point fixe équivaut à $\langle \nabla E(\bar{\varepsilon}), w - \bar{\varepsilon} \rangle \leq 0$ pour tout $w \in K$: la condition nécessaire d'Euler pour un minimum local de $J = -E$ sur K, équivalente aux conditions KKT du §3.3 puisque les contraintes sont affines (lemme de Farkas).

Rien ne garantit que $\bar{\varepsilon}$ soit le maximum *global*, ni que toute la suite converge (c'est le cas si les points KKT sont isolés) : d'où les multi-départs du §3.4.

Références

[1] Y. Leviathan, M. Kalman, Y. Matias. *Fast Inference from Transformers via Speculative Decoding.* ICML 2023.

[2] C. Chen et al. *Accelerating Large Language Model Decoding with Speculative Sampling.* arXiv:2302.01318, 2023.

[3] M. Yin, M. Chen, K. Huang, M. Wang. *A Theoretical Perspective for Speculative Decoding Algorithm.* NeurIPS 2024.

[4] M. Holsman, Y. Huang, B. Dhingra. *Fuzzy Speculative Decoding for a Tunable Accuracy-Runtime Tradeoff.* Findings of ACL 2025.

[5] Y. Zhang, Z. Wang, N. Gong, Y. Yang. *Secure Speculative Decoding for Large Language Models.* arXiv:2610.08678, 2026.

[6] G. Allaire. *Analyse numérique et optimisation.* Éditions de l'École polytechnique (numérotation des théorèmes reprise du cours).