Statistiques avancées 3A

CentraleSupélec

Sarah Lemler

2024





Outline

1 Introduction

2 Penalized methods

Cadre général : régression linéaire multidimensionnelle

On dispose d'un n-échantillon $(x_1, y_1), \ldots, (x_n, y_n)$ tel que :

$$y_i = x_i \beta^* + \varepsilon_i, \quad i = 1, \ldots, n$$

- ε_i v.a. mutuellement indépendantes de loi normale $\mathcal{N}(0, \sigma^2)$, avec σ connu
- $x_i = (x_{i,1}, \ldots, x_{i,p})$ vecteur de covariables p-dimensionnel, supposé déterministe
- $\beta^* \in \mathbb{R}^p$ vecteur inconnu des paramètres de régression

Cadre général : régression linéaire multidimensionnelle

Notations :

$$X = \begin{pmatrix} x_{1,1} & \dots & x_{1,p} \\ \vdots & \ddots & \vdots \\ x_{n,1} & \dots & x_{n,p} \end{pmatrix} = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} X^1 & \dots & X^p \end{pmatrix}$$

$$Y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}, \quad \varepsilon = \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{pmatrix}, \quad \beta^* = \begin{pmatrix} \beta_1^* \\ \vdots \\ \beta_p^* \end{pmatrix}$$

- X : matrice des données ou matrice de design
- X^j pour $j = 1, \dots, p$: variables explicatives
- Y : la réponse

Cadre général : régression linéaire multidimensionnelle

Sous forme matricielle :

$$Y = \sum_{j=1}^{p} \beta_j^* X^j + \varepsilon = X\beta^* + \varepsilon$$

β_j^* traduit l'influence de la variable X^j sur Y

La grande dimension

$$p = p(n) \geq n$$

Objectifs :

- Estimation de β^*
- Estimation de $X\beta^*$

Les moindres carrés ordinaires

Méthode usuelle pour estimer β^* : $\hat{\beta}$ minimise la somme des carrés résiduels

$$\sum_{i=1}^{n}(y_i - x_i\hat{\beta})^2 = \min_{\beta\in\mathbb{R}^p}\sum_{i=1}^{n}(y_i - x_i\beta)^2$$

$$\Leftrightarrow$$

$$\|Y - X\hat{\beta}\|_n^2 = \min_{\beta\in\mathbb{R}^p}\frac{1}{n}\|Y - X\beta\|^2$$

Estimateur des moindres carrés (EMC)

$$\hat{\beta}^{\mathrm{MC}} \in \operatorname*{arg\,min}_{\beta\in\mathbb{R}^p}\frac{1}{n}\sum_{i=1}^{n}(y_i - x_i\beta)^2 = \operatorname*{arg\,min}_{\beta\in\mathbb{R}^p}\|Y - X\beta\|_n^2$$

Les moindres carrés ordinaires

Méthode usuelle pour estimer β^* : $\hat{\beta}$ minimise la somme des carrés résiduels

$$\sum_{i=1}^{n}(y_i - x_i\hat{\beta})^2 = \min_{\beta\in\mathbb{R}^p}\sum_{i=1}^{n}(y_i - x_i\beta)^2$$

$$\Leftrightarrow$$

$$\|Y - X\hat{\beta}\|_n^2 = \min_{\beta\in\mathbb{R}^p}\frac{1}{n}\|Y - X\beta\|^2$$

Estimateur des moindres carrés (EMC)

$$\hat{\beta}^{\mathrm{MC}} \in \operatorname*{arg\,min}_{\beta\in\mathbb{R}^p}\frac{1}{n}\sum_{i=1}^{n}(y_i - x_i\beta)^2 = \operatorname*{arg\,min}_{\beta\in\mathbb{R}^p}\|Y - X\beta\|_n^2$$

Théorème

Si X^TX est inversible, l'EMC est unique et s'écrit

$$\hat{\beta}^{\mathrm{MC}} = (X^TX)^{-1}X^TY$$

Erreur de prédiction de l'estimateur des moindres carrés

Théorème

Pour tout (p, n), l'erreur de prédiction de l'EMC vaut :

$$\mathbb{E}\left[\|X\hat{\beta}^{\mathsf{MC}} - X\beta^*\|_n^2\right] = \sigma^2 \frac{\mathrm{rg}(X)}{n},$$

où $\mathbb{E}$ est l'espérance sous la loi de probabilité de ε.

L'estimateur $X\hat{\beta}^{\mathsf{MC}}$ de $X\beta^*$, basé sur l'EMC, est consistant au sens ℓ_2 pour l'estimation de $X\beta^*$ quand n tend vers l'infini dès lors que $\frac{\mathrm{rg}(X)}{n} = o(1)$:

- pour $p(n) = o(n)$
- p fixe et $\mathrm{rg}(X) \leq \min\{p, n\}$

Limites de l'estimateur des moindres carrés

β^* n'est pas identifiable si la matrice X^TX n'est pas inversible :

- lorsque les colonnes de X sont liées
- pour $p > n$, la matrice X^TX étant au plus de rang n (cadre qui nous intéresse)

- EMC pas défini de manière unique et résultats obtenus non interprétables
- Estimateur en général pas consistant au sens ℓ_2 pour l'estimation de $X\beta^*$ (sauf si les colonnes de X sont liées telles que $\mathrm{rg}(X)$ asymptotiquement négligeable devant n)
- p proche de n (et $p < n$) ou variables corrélées $\Rightarrow$ valeurs propres de X^TX proches de zéro $\Rightarrow$ X^TX mal conditionnée et calcul numérique de l'inverse de X^TX instable $\Rightarrow$ EMC inexploitable

Outline

1 Introduction

2 Penalized methods

Les méthodes pénalisées

$$\hat{\beta} = \underset{\beta \in \mathbb{R}^p}{\arg\min} \left\{ \| Y - X\beta \|_n^2 + \text{pen}(\beta, n) \right\},$$

où l'application $\text{pen} : \mathbb{R}^p \to \mathbb{R}^+$ est appelée pénalité

- le choix de la pénalité dépend de l'objectif
- bien choisie, elle permet d'éviter l'inversion de $X^T X$

L'estimateur Ridge

Pénalité Ridge (Hoerl et Kennard [5])

$$\text{pen}(\beta, n) = \lambda \sum_{j=1}^{p} \beta_j^2,$$

où $\lambda \geq 0$ est un paramètre de lissage qui dépend éventuellement de n et l'estimateur Ridge est défini par

$$\hat{\beta}^R(\lambda) = \underset{\beta \in \mathbb{R}^p}{\arg\min} \left\{ \| Y - X\beta \|_n^2 + \lambda \| \beta \|^2 \right\}$$

Estimateur Ridge

L'estimateur Ridge $\hat{\beta}^R$ est défini de manière unique, même dans le cadre de la grande dimension, $p \geq n$, lorsque $\lambda > 0$. Il s'écrit

$$\hat{\beta}^R(\lambda) = (X^T X + \lambda I_p)^{-1} X^T Y$$

L'estimateur Ridge

Remarque : si les β_j ne sont pas contraints, ils peuvent prendre de très grandes valeurs et donc avoir une grande variance

Idée : pour contrôler la variance, il faut contrôler la taille des β_j

X^TX et $X^TX+\lambda I_p$ ont les mêmes vecteurs propres, mais des valeurs propres différentes : si v_j est un vecteur propre de X^TX associé à la valeur propre μ_j,

$$(X^TX+\lambda I_p)\,v_j = X^TXv_j + \lambda v_j = (\mu_j+\lambda)\,v_j$$

alors v_j est un vecteur propre de $X^TX+\lambda I_p$ associé à la valeur propre $\mu_j+\lambda$

$$\hat{\beta}^R(\lambda) = (X^TX+\lambda I_p)^{-1}X^TY$$

Propriétés de l'estimateur Ridge

- Point de vue numérique : $\hat{\beta}^R$ plus stable que $\hat{\beta}^{MC}$, choix de λ suffisamment grand permet de rendre les valeurs propres de $X^TX + \lambda I_p$ assez grandes pour que l'inverse de cette matrice soit bien conditionnée

- Point de vue statistique : l'estimateur Ridge est biaisé

Vers la sélection de variables

$\beta^* = (\beta_1^*, \ldots, \beta_p^*)$ traduit le poids des variables explicatives $(X^1, \ldots, X^p)$ sur la réponse Y

Objectif : évaluer la contribution de chaque variable et éliminer les variables non pertinentes

Plusieurs méthodes :

- Sélection de sous-ensembles (*Subset Selection*) : trouver le meilleur sous-ensemble $\mathscr{B}_k$ de taille k, où $k \in \{1, \ldots, p\}$ qui réduit au maximum la somme des carrés des résidus (Hastie, Tibshirani, et Friedman [4])
- Seuillage : utilisation d'un estimateur préliminaire (e.g. l'EMC si $p \leq n$), on ne sélectionne que les variables X^j pour lesquelles l'estimation de β_j dépasse un seuil arbitraire choisi par le statisticien (Donoho et Johnstone [2, 3])
- Tests : (H_0) $\beta_j = 0$ contre (H_1) $\beta_j \neq 0$ pour tout $j \in \{1, \ldots, p\}$ (test de student ou de Fisher si le bruit est gaussien) (Hastie, Tibshirani, et Friedman [4])

Pénalisation ℓ_0

$|\mathscr{A}|$ correspond au cardinal de $\mathscr{A}$, un ensemble quelconque d'indices

Définition

Soit le modèle de régression linéaire. On définit l'ensemble de sparsité associé au vecteur β^* par

$$\mathscr{A}^* = \{j : \beta_j^* \neq 0\}.$$

On définit l'indice de sparsité de β^* par la quantité $|\mathscr{A}^*|$.

Objectif : construction d'estimateurs interprétables

Exemples d'estimateurs interprétables construits à partir de la pénalité ℓ_0 :

- critère d'information du Cp de Mallows (Mallows [6])
- critère AIC (Akaike Information Criterion) (Akaike [1])
- critère BIC (Bayesian Information Criterion)(Schwartz [7])

Pénalisation ℓ_0

Idée générale de ces critères :

- soit $\hat{\mathscr{F}} = \{\hat{\beta}_1, \ldots, \hat{\beta}_D\}$ une collection d'estimateurs de taille D
- sélection dans cette collection de l'estimateur qui remplit au mieux le double objectif suivant :
  - la bonne estimation de $X\beta^*$
  - la bonne estimation des variables pertinentes $\mathscr{A}^*$
  - pénalité de ces critères :

$$\text{pen}(\beta, n) = \lambda_n \|\beta\|_0,$$

où $\|\beta\|_0 = \sum_{j=1}^{p} \mathbb{1}_{\{\beta_j \neq 0\}}$

Cp de Mallows et AIC

Sous l'hypothèse du bruit gaussien :

$$\mathbb{E}\left[\|X\hat{\beta} - X\beta^*\|_n^2\right] + \sigma^2 = \mathbb{E}\left[\|Y - X\hat{\beta}\|_n^2\right] + \frac{2\sigma^2}{n}\mathrm{Tr}(P_{<X>})$$

où $\mathbb{E}$ désigne l'espérance sous la loi de ε et $P_{<X>}$ la projection sur $<X>$

$\hookrightarrow$minimiser l'erreur de prédiction équivaut à minimiser le membre de droite
$\|\beta\|_0$ est un estimateur de $\mathrm{Tr}(P_{<X>})$

$\tilde{\beta}$ estimateur Cp et AIC est tel que

$$\|Y - X\tilde{\beta}\|_n^2 + \frac{2\sigma^2\|\tilde{\beta}\|_0}{n}$$

donne une bonne approximation de l'erreur de prédiction

$\hookrightarrow$Cp et AIC bons estimateurs pour la prédiction $X\beta^*$

Cp de Mallows et AIC

Modèle de régression linéaire gaussien

$$\text{pen}^{\text{AIC}}(\beta, n) = \text{pen}^{Cp}(\beta, n) := \frac{2\sigma^2 \|\beta\|_0}{n}$$

Critère BIC

Plus approprié pour l'estimation de $\mathscr{A}^*$ car surpénalise les gros modèles

$$\mathrm{pen}^{\mathrm{BIC}}(\beta, n) := \sigma^2 \log(n) \frac{\|\beta\|_0}{n}$$

$\hookrightarrow$ tend à sélectionner des estimateurs plus parcimonieux (*sparse*) que ceux choisis par les critères Cp et AIC (dès que $n > 7$)

Critères Cp, AIC,BIC

Performances théoriques :

- BIC a de meilleures performances théoriques dans le cadre de l'estimation du support $\mathscr{A}^*$ de β^* (on parle de sélection)
- les estimateurs Cp et AIC donnent de meilleurs résultats pour l'estimation de $X\beta^*$ (on parle de prédiction).

Inconvénient de ces critères

Complexité algorithmique trop grande dès que D grand ou que p grand
$\Rightarrow$ Exemple d'hypothèses sur le modèle :

- supposer les variables ordonnées
- considérer une famille $\hat{\mathscr{F}}$ d'estimateurs sparses

Ces méthodes de sélection de variables ont été introduites dans un cadre classique d'estimation, où la dimension p est raisonnable ($p \leq n$)

Hypothèse de sparsité

On se place dans un cadre de grande dimension $p > n$
Les différents objectifs :

- Estimation de β^*
- Estimation de $X\beta^*$
- Estimation du support $\mathscr{A}^*$ de β^*

Hypothèse (S) de sparsité

Soit $\mathscr{A}^*$ l'ensemble de sparsité de β^*. Il existe un entier s, tel que

$$|\mathscr{A}^*| \leq s,$$

et on suppose que $s = o(n)$

$\hookrightarrow$ contrôle sur la sparsité du modèle
$\hookrightarrow$ on part du principe qu'il y a peu de variables explicatives pertinentes pour l'étude

Estimateur des moindres carrés restreint

Cadre idéal : on connaît l'ensemble de sparsité $\mathscr{A}^*$

$\hat{\beta}^{MCR}$ estimateur des moindres carrés restreint aux variables X^j dont les indices j sont dans $\mathscr{A}^*$:

$$\hat{\beta}^{MCR} = (X_{\mathscr{A}^*}^T X_{\mathscr{A}^*})^{-1} X_{\mathscr{A}^*}^T Y,$$

où $X_{\mathscr{A}^*}$ restriction de la matrice X aux colonnes X^j avec $j \in \mathscr{A}^*$

Erreur de prédiction

$$\mathbb{E}\left[\|X\hat{\beta}^{MCR} - X\beta^*\|_n^2\right] = \sigma^2 \frac{|\mathscr{A}^*|}{n}$$

Si (S) est satisfaite, $\hat{\beta}^{MCR}$ est consistant, son erreur ne dépend pas de la dimension effective p du problème, mais de la dimension réelle $|\mathscr{A}^*|$

↪ En pratique, $\mathscr{A}^*$ est rarement connu, donc $\hat{\beta}^{MCR}$ n'est pas exploitable

Estimateur LASSO

Introduit par Tibshirani [8] :
LASSO (Least Absolute Shrinkage and Selection Operator)
Estimateur défini comme l'estimateur des moindres carrés sous une contrainte de type ℓ_1 :

$$\tilde{\beta}^L(t) = \begin{cases} \operatorname{argmin}_{\beta \in \mathbb{R}^p} \|Y - X\beta\|_n^2, \\ \text{s.c. } \|\beta\|_1 \leq t, \end{cases}$$

où $t \geq 0$

$$\hat{\beta}^L(\lambda) \in \operatorname*{argmin}_{\beta \in \mathbb{R}^p} \left\{ \|Y - X\beta\|_n^2 + \lambda \|\beta\|_1 \right\} \tag{1}$$

Les estimateurs $\tilde{\beta}^L$ et $\hat{\beta}^L$ sont équivalents point par point :
pour un t fixé, on peut trouver un λ (qui dépend des données) tel que $\tilde{\beta}^L = \hat{\beta}^L$; pour un λ fixé, il existe un t tel que $\tilde{\beta}^L = \hat{\beta}^L$ et $t = \sum_{j=1}^p |\hat{\beta}_j^L(\lambda)|$

References I


Hirotogu Akaike.
Information theory and an extension of the maximum likelihood principle.
In *Selected papers of hirotugu akaike*, pages 199–213. Springer, 1998.


David L Donoho and Iain M Johnstone.
Ideal spatial adaptation by wavelet shrinkage.
biometrika, 81(3):425–455, 1994.


David L Donoho and Iain M Johnstone.
Adapting to unknown smoothness via wavelet shrinkage.
Journal of the american statistical association, 90(432):1200–1224, 1995.


Trevor Hastie.
Tibshirani r. friedman j.: The elements of statistical learning.
Friedman J.: The elements of statistical learning, 2001.

References II


Arthur E Hoer1 and Robert W Kennard.
A note on a power generalization of ridge regression.
Technometrics, 17(2):269–269, 1975.


CL Mallows.
Some remarks of cp.
Technometrics, 15:661–675, 1973.


Gideon Schwarz.
Estimating the dimension of a model.
The annals of statistics, pages 461–464, 1978.


Robert Tibshirani.
Regression shrinkage and selection via the lasso.
Journal of the Royal Statistical Society Series B: Statistical Methodology, 58(1):267–288, 1996.