Statistiques avancées 3A

CentraleSupélec

Sarah Lemler

2024





CentraleSupélec

Outline

1 Introduction

2 Penalized methods

3 Theoretical study of the Lasso in the linear regression model

Cadre général : régression linéaire multidimensionnelle

On dispose d'un n-échantillon $(x_1, y_1), \ldots, (x_n, y_n)$ tel que :

$$y_i = x_i \beta^* + \varepsilon_i, \quad i = 1, \ldots, n$$

- ε_i v.a. mutuellement indépendantes de loi normale $\mathcal{N}(0, \sigma^2)$, avec σ connu
- $x_i = (x_{i,1}, \ldots, x_{i,p})$ vecteur de covariables p-dimensionnel, supposé déterministe
- $\beta^* \in \mathbb{R}^p$ vecteur inconnu des paramètres de régression

Cadre général : régression linéaire multidimensionnelle

Notations :

$$X = \begin{pmatrix} x_{1,1} & \dots & x_{1,p} \\ \vdots & \ddots & \vdots \\ x_{n,1} & \dots & x_{n,p} \end{pmatrix} = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} X_1 & \dots & X_p \end{pmatrix}$$

$$Y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}, \quad \varepsilon = \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{pmatrix}, \quad \beta^* = \begin{pmatrix} \beta_1^* \\ \vdots \\ \beta_p^* \end{pmatrix}$$

- X : matrice des données ou matrice de design
- X_j pour $j = 1, \dots, p$: variables explicatives
- Y : la réponse

Cadre général : régression linéaire multidimensionnelle

Sous forme matricielle :

$$Y = \sum_{j=1}^{p} \beta_j^* X_j + \varepsilon = X\beta^* + \varepsilon$$

β_j^* traduit l'influence de la variable X_j sur Y

La grande dimension

$$p = p(n) \geq n$$

Objectifs :

- Estimation de β^*
- Estimation de $X\beta^*$

Les moindres carrés ordinaires

Méthode usuelle pour estimer β^* : $\hat{\beta}$ minimise la somme des carrés résiduels

$$\sum_{i=1}^{n}(y_i - x_i\hat{\beta})^2 = \min_{\beta\in\mathbb{R}^p}\sum_{i=1}^{n}(y_i - x_i\beta)^2$$

$$\Leftrightarrow$$

$$\|Y - X\hat{\beta}\|_n^2 = \min_{\beta\in\mathbb{R}^p}\|Y - X\beta\|^2$$

Estimateur des moindres carrés (EMC)

$$\hat{\beta}^{\mathsf{MC}} \in \operatorname*{argmin}_{\beta\in\mathbb{R}^p}\frac{1}{n}\sum_{i=1}^{n}(y_i - x_i\beta)^2 = \operatorname*{argmin}_{\beta\in\mathbb{R}^p}\|Y - X\beta\|_n^2$$

Théorème

Si X^TX est inversible, l'EMC est unique et s'écrit

$$\hat{\beta}^{\mathsf{MC}} = (X^TX)^{-1}X^TY$$

Erreur de prédiction de l'estimateur des moindres carrés

Théorème

Pour tout (p, n), l'erreur de prédiction de l'EMC vaut :

$$\mathbb{E}\left[\|X\hat{\beta}^{\mathsf{MC}} - X\beta^*\|_n^2\right] = \sigma^2 \frac{\mathrm{rg}(X)}{n},$$

où $\mathbb{E}$ est l'espérance sous la loi de probabilité de ε.

L'estimateur $X\hat{\beta}^{\mathsf{MC}}$ de $X\beta^*$, basé sur l'EMC, est consistant au sens ℓ_2 pour l'estimation de $X\beta^*$ quand n tend vers l'infini dès lors que $\frac{\mathrm{rg}(X)}{n} = o(1)$:

- pour $p(n) = o(n)$
- p fixe et $\mathrm{rg}(X) \leq \min\{p, n\}$

Limites de l'estimateur des moindres carrés

β^* n'est pas identifiable si la matrice X^TX n'est pas inversible :

- lorsque les colonnes de X sont liées
- pour $p > n$, la matrice X^TX étant au plus de rang n (cadre qui nous intéresse)

- EMC pas défini de manière unique et résultats obtenus non interprétables
- Estimateur en général pas consistant au sens ℓ_2 pour l'estimation de $X\beta^*$ (sauf si les colonnes de X sont liées telles que $\mathrm{rg}(X)$ asymptotiquement négligeable devant n)
- p proche de n (et $p < n$) ou variables corrélées $\Rightarrow$ valeurs propres de X^TX proches de zéro $\Rightarrow$ X^TX mal conditionnée et calcul numérique de l'inverse de X^TX instable $\Rightarrow$ EMC inexploitable

Outline

1 Introduction

2 Penalized methods

3 Theoretical study of the Lasso in the linear regression model

Les méthodes pénalisées

$$\hat{\beta} = \underset{\beta \in \mathbb{R}^p}{\arg\min} \left\{ \| Y - X\beta \|_n^2 + \text{pen}(\beta, n) \right\},$$

où l'application $\text{pen} : \mathbb{R}^p \to \mathbb{R}^+$ est appelée pénalité

- le choix de la pénalité dépend de l'objectif
- bien choisie, elle permet d'éviter l'inversion de $X^T X$

L'estimateur Ridge

Pénalité Ridge (Hoerl et Kennard [7])

$$\text{pen}(\beta, n) = \lambda \sum_{j=1}^{p} \beta_j^2,$$

où $\lambda \geq 0$ est un paramètre de lissage qui dépend éventuellement de n

Estimateur Ridge

L'estimateur Ridge $\hat{\beta}^R$ est défini de manière unique, même dans le cadre de la grande dimension, $p \geq n$, lorsque $\lambda > 0$. Il s'écrit

$$\hat{\beta}^R(\lambda) = (X^T X + \lambda I_p)^{-1} X^T Y$$

L'estimateur Ridge

Remarque : si les β_j ne sont pas contraints, ils peuvent prendre de très grandes valeurs et donc avoir une grande variance

Idée : pour contrôler la variance, il faut contrôler la taille des β_j

X^TX et $X^TX+\kappa I_p$ ont les mêmes vecteurs propres, mais des valeurs propres différentes : si v_j est un vecteur propre de X^TX associé à la valeur propre μ_j,

$$(X^TX+\lambda I_p)v_j = X^TXv_j+\kappa v_j = (\mu_j+\lambda)v_j$$

alors v_j est un vecteur propre de $X^TX+\lambda I_p$ associé à la valeur propre $\mu_j+\lambda$

$$\hat{\beta}^R(\lambda) = (X^TX+\lambda I_p)^{-1}X^TY$$

Propriétés de l'estimateur Ridge

- Point de vue numérique : $\hat{\beta}^R$ plus stable que $\hat{\beta}^{MC}$, choix de λ suffisamment grand permet de rendre les valeurs propres de $X^TX + \lambda I_p$ assez grandes pour que l'inverse de cette matrice soit bien conditionnée

- Point de vue statistique : l'estimateur Ridge est biaisé

Vers la sélection de variables

$\beta^* = (\beta_1^*, \ldots, \beta_p^*)$ traduit le poids des variables explicatives $(X_1, \ldots, X_p)$ sur la réponse Y

Objectif : évaluer la contribution de chaque variable et éliminer les variables non pertinentes

Plusieurs méthodes :

- Sélection de sous-ensembles (*Subset Selection*) : trouver le meilleur sous-ensemble $\mathscr{B}_k$ de taille k, où $k \in \{1, \ldots, p\}$ qui réduit au maximum la somme des carrés des résidus (Hastie, Tibshirani, et Friedman [6])
- Seuillage : utilisation d'un estimateur préliminaire (e.g. l'EMC si $p \leq n$), on ne sélectionne que les variables X_j pour lesquelles l'estimation de β_j dépasse un seuil arbitraire choisi par le statisticien (Donoho et Johnstone [3, 4])
- Tests : (H_0) $\beta_j = 0$ contre (H_1) $\beta_j \neq 0$ pour tout $j \in \{1, \ldots, p\}$ (test de student ou de Fisher si le bruit est gaussien) (Hastie, Tibshirani, et Friedman [6])

Pénalisation ℓ_0

$|\mathscr{A}|$ correspond au cardinal de $\mathscr{A}$, un ensemble quelconque d'indices

Définition

Soit le modèle de régression linéaire. On définit l'ensemble de sparsité associé au vecteur β^* par

$$\mathscr{A}^* = \{j : \beta_j^* \neq 0\}.$$

On définit l'indice de sparsité de β^* par la quantité $|\mathscr{A}^*|$.

Objectif : construction d'estimateurs interprétables

Exemples d'estimateurs interprétables construits à partir de la pénalité ℓ_0 :

- critère d'information du Cp de Mallows (Mallows [8])
- critère AIC (Akaike Information Criterion) (Akaike [1])
- critère BIC (Bayesian Information Criterion)(Schwartz [9])

Pénalisation ℓ_0

Idée générale de ces critères :

- soit $\hat{\mathscr{F}} = \{\hat{\beta}_1, \ldots, \hat{\beta}_D\}$ une collection d'estimateurs de taille D
- sélection dans cette collection de l'estimateur qui remplit au mieux le double objectif suivant :
  - la bonne estimation de $X\beta^*$
  - la bonne estimation des variables pertinentes $\mathscr{A}^*$
  - pénalité de ces critères :

$$\text{pen}(\beta, n) = \lambda_n \|\beta\|_0,$$

où $\|\beta\|_0 = \sum_{j=1}^{p} \mathbb{1}_{\{\beta_j \neq 0\}}$

Cp de Mallows et AIC

Sous l'hypothèse du bruit gaussien :

$$\mathbb{E}\left[\|X\hat{\beta} - X\beta^*\|_n^2\right] + \sigma^2 = \mathbb{E}\left[\|Y - X\hat{\beta}\|_n^2\right] + \frac{2\sigma^2}{n}\mathrm{Tr}(P_{<X>})$$

où $\mathbb{E}$ désigne la covariance sous la loi de ε et $P_{<X>}$ la projection sur $<X>$

$\hookrightarrow$minimiser l'erreur de prédiction équivaut à minimiser le membre de droite
$\|\beta\|_0$ est un estimateur de $Tr(P_{<X>})$

$\tilde{\beta}$ estimateur Cp et AIC est tel que

$$\|Y - X\tilde{\beta}\|_n^2 + \frac{2\sigma^2\|\tilde{\beta}\|_0}{n}$$

donne une bonne approximation de l'erreur de prédiction

$\hookrightarrow$Cp et AIC bons estimateurs pour la prédiction $X\beta^*$

Cp de Mallows et AIC

Modèle de régression linéaire gaussien

$$\text{pen}^{\text{AIC}}(\beta, n) = \text{pen}^{Cp}(\beta, n) := \frac{2\sigma^2 \|\beta\|_0}{n}$$

Critère BIC

Plus approprié pour l'estimation de $\mathscr{A}^*$ car surpénalise les gros modèles

$$\text{pen}^{\text{BIC}}(\beta, n) := \sigma^2 \log(n) \frac{\|\beta\|_0}{n}$$

$\hookrightarrow$ tend à sélectionner des estimateurs plus parcimonieux (*sparse*) que ceux choisis par les critères Cp et AIC

Critères Cp, AIC,BIC

Performances théoriques :

- BIC a de meilleures performances théoriques dans le cadre de l'estimation du support $\mathscr{A}^*$ de β^* (on parle de sélection)
- les estimateurs Cp et AIC donnent de meilleurs résultats pour l'estimation de $X\beta^*$ (on parle de prédiction).

Inconvénient de ces critères

Complexité algorithmique trop grande dès que D grand ou que p grand
$\Rightarrow$ Exemple d'hypothèses sur le modèle :

- supposer les variables ordonnées
- considérer une famille $\hat{\mathscr{F}}$ d'estimateurs sparses

Ces méthodes de sélection de variables ont été introduites dans un cadre classique d'estimation, où la dimension p est raisonnable ($p \leq n$)

Hypothèse de sparsité

On se place dans un cadre de grande dimension $p > n$
Les différents objectifs :

- Estimation de β^*
- Estimation de $X\beta^*$
- Estimation du support $\mathscr{A}^*$ de β^*

Hypothèse (S) de sparsité

Soit $\mathscr{A}^*$ l'ensemble de sparsité de β^*. Il existe un entier s, tel que

$$|\mathscr{A}^*| \leq s,$$

et on suppose que $s = o(n)$

$\hookrightarrow$ contrôle sur la sparsité du modèle
$\hookrightarrow$ on part du principe qu'il y a peu de variables explicatives pertinentes pour l'étude

Estimateur des moindres carrés restreint

Cadre idéal : on connaît l'ensemble de sparsité $\mathscr{A}^*$

$\hat{\beta}^{MCR}$ estimateur des moindres carrés restreint aux variables X_j dont les indices j sont dans $\mathscr{A}^*$:

$$\hat{\beta}^{MCR} = (X_{\mathscr{A}^*}^T X_{\mathscr{A}^*})^{-1} X_{\mathscr{A}^*}^T Y,$$

où $X_{\mathscr{A}^*}$ restriction de la matrice X aux colonnes X_j avec $j \in \mathscr{A}^*$

Erreur de prédiction

$$\mathbb{E}\left[\| X\hat{\beta}^{MCR} - X\beta^* \|_n^2 \right] = \sigma^2 \frac{|\mathscr{A}^*|}{n}$$

Si (S) est satisfaite, $\hat{\beta}^{MCR}$ est consistant, son erreur ne dépend pas de la dimension effective p du problème, mais de la dimension réelle $|A^*|$

↪ En pratique, $\mathscr{A}^*$ est rarement connu, donc $\hat{\beta}^{MCR}$ n'est pas exploitable

Estimateur LASSO

Introduit par Tibshirani [10] :
LASSO (Least Absolute Shrinkage and Selection Operator)
Estimateur défini comme l'estimateur des moindres carrés sous une contrainte de type ℓ_1 :

$$\tilde{\beta}^L(t) = \begin{cases} \operatorname{argmin}_{\beta \in \mathbb{R}^p} \|Y - X\beta\|_n^2, \\ \text{s.c. } \|\beta\|_1 \leq t, \end{cases}$$

où $t \geq 0$

$$\hat{\beta}^L(\lambda) \in \operatorname*{argmin}_{\beta \in \mathbb{R}^p} \left\{ \|Y - X\beta\|_n^2 + \lambda \|\beta\|_1 \right\} \tag{1}$$

Les estimateurs $\tilde{\beta}^L$ et $\hat{\beta}^L$ sont équivalents point par point :
pour un t fixé, on peut trouver un λ (qui dépend des données) tel que $\tilde{\beta}^L = \hat{\beta}^L$; pour un λ fixé, il existe un t tel que $\tilde{\beta}^L = \hat{\beta}^L$ et $t = \sum_{j=1}^p |\hat{\beta}_j^L(\lambda)|$

Outline

1. Introduction
2. Penalized methods
3. Theoretical study of the Lasso in the linear regression model

Propriétés de l'estimateur Lasso

- $\lambda = 0 \Rightarrow \hat{\beta}^L = \hat{\beta}^{MC}$: la procédure Lasso sélectionne toutes les variables explicatives
  $\lambda \to +\infty \Rightarrow \hat{\beta}^L = \mathbf{0_p}$: la procédure Lasso ne sélectionne aucune variable explicative
  Entre ces deux valeurs extrêmes, la procédure Lasso sélectionne d'autant plus de variables explicatives que λ est petit, i.e., plus λ est grand, plus la contrainte sur les coefficients de β l'est également.
- L'estimateur Lasso peut s'interpréter en terme d'estimation dans le cadre de l'inférence bayésienne. En effet, nous pouvons déduire l'estimateur Lasso en considérant le modèle de régression avec bruit gaussien, et en prenant comme loi a priori pour le paramètre β^* la loi de Laplace; i.e., β_j^* admet pour densité a priori par rapport à la mesure de Lebesgue $\frac{\lambda}{2}\exp\left(-\lambda|\beta_j^*|\right)$.

Propriétés de l'estimateur Lasso I

- L'estimateur Lasso est linéaire par morceaux comme fonction de λ.
  - Si les colonnes de X sont orthogonales (ou le cas trivial où $p=1$) :

Chaque composante du vecteur $\hat{\beta}^L = (\hat{\beta}^L_1, \ldots, \hat{\beta}^L_p)^T$ s'écrit en fonction de l'estimateur des moindres carrés $\hat{\beta}^{MC} = (X^T X)^{-1} X^T Y$:

$$\hat{\beta}^L_j(\lambda) = \mathrm{sgn}(\hat{\beta}^{MC}_j)(|\hat{\beta}^{MC}_j| - \lambda/2)_+, \quad \forall j \in \{1, \ldots, p\}$$

où $(\alpha)_+ = \max(\alpha, 0)$ pour α un réel et la fonction $\mathrm{sgn}(.)$ est définie pour tout réel b par

$$\mathrm{sgn}(b) = \begin{cases} 1 & \text{si } b > 0 \\ 0 & \text{si } b = 0 \\ -1 & \text{si } b < 0 \end{cases}$$

Si on choisit $\lambda^{(k)} = |\hat{\beta}^{MC}_k|$, $k \in \{1, \ldots, p\}$, la linéarité de $\hat{\beta}^L$ change en fonction de ces λ

Propriétés de l'estimateur Lasso II

- Si X n'est pas une matrice orthogonale (et $p \neq 1$) :
  les valeurs du paramètre de régularisation telles que la linéarité change peuvent être trouvées en considérant les conditions d'optimalité du premier ordre (1), les conditions Karush-Kuhn-Tucker (KKT).
  Ensemble de sparsité ou ensemble actif de l'estimateur Lasso $\hat{\beta}^L(\lambda)$:

$$\hat{\mathscr{A}}_L = \hat{\mathscr{A}}(\lambda) = \{j \in \{1, \dots, p\} : \hat{\beta}_j^L \neq 0\}$$

  Conditions KKT :

$$\begin{cases} 2(X^j)^T(Y - X\hat{\beta}^L(\lambda)) = \lambda \operatorname{sgn}(\hat{\beta}_j^L) & \forall j \in \hat{\mathscr{A}}_L, \\ 2|(X^j)^T(Y - X\hat{\beta}^L(\lambda))| \leq \lambda & \forall j \notin \hat{\mathscr{A}}_L \end{cases} \tag{2}$$

  Pour trouver des valeurs du paramètre de régularisation $\{\lambda^{(1)}, \dots, \lambda^{(K)}\}$ pour lesquels la linéarité de $\hat{\beta}^L(\lambda)$ change, on considère les conditions non saturées dans les conditions KKT ($2^{\text{ème}}$ ligne de (2)) : pour tout $j \notin \hat{\mathscr{A}}_L$, il existe $\lambda^{(k)}$ tel que $|(X^j)^T(Y - X\hat{\beta}^L(\lambda^{(k)}))| = \lambda^{(k)}/2$.
  Pour $\lambda = \lambda^{(k)}$, la contrainte correspondant à X^j devient saturée et X^j devient active (i.e., l'indice j "passe" de $\hat{\mathscr{A}}_L^c$ à $\hat{\mathscr{A}}_L$).

Propriétés de l'estimateur Lasso III

- Une solution approchée de l'estimateur Lasso peut être obtenue grâce par exemple à l'algorithme LARS (Efron, Hastie, Johnstone, et Tibshirani [5])
  Algorithme basée sur les conditions KKT, i.e., sur les corrélations entre le résidu $Y - X\hat{\beta}^L(\lambda)$ et les variables explicatives $(X_1, \ldots, X_p)$.

  Inconvénient de cet algorithme :
  → échoue à construire de bonnes évaluations de l'estimateur lorsque de fortes corrélations interviennent entre les variables
  → tend à sélectionner une variable explicative par groupe de variables corrélées, écartant ainsi de l'étude les autres variables du groupe

Nature des résultats

3 objectifs différents :

- fournir la meilleure approximation du vecteur $X\beta^*$: on parle de prédiction
- estimer le vecteur β^* : on parle d'estimation
- identifier le support $\mathscr{A}^*$ de β^*, ou encore le vecteur signe de β^* : on parle de sélection

Nature des résultats

Définition

Soit l'hypothèse (S) de sparsité vérifiée et s l'indice associé. On dit qu'un estimateur $\hat{\beta}$ vérifie une Inégalité de Sparsité (IS)

en prédiction si : $$\mathbb{E}\left[\|X\beta^* - X\hat{\beta}\|_n^2\right] \leq Cs\frac{L(n,p)}{n}$$

en estimation en norme ℓ_1 si : $$\mathbb{E}\left[\|\hat{\beta} - \beta^*\|_1\right] \leq Cs\sqrt{\frac{L(n,p)}{n}}$$

en estimation en norme-sup si : $$\mathbb{E}\left[\|\hat{\beta} - \beta^*\|_\infty\right] \leq C\sqrt{\frac{L(n,p)}{n}}$$

où $C > 0$ et $L(n,p)$ dépendance au plus logarithmique en n et p.

Remarque : Toutes les IS peuvent être également définies à l'aide d'inégalités probabilistes.

Nature des résultats

IS généralement difficiles à obtenir $\Rightarrow$ nécessité d'ajouter une hypothèse, souvent restrictive, sur la matrice de Gram, $\Psi^n = \dfrac{X^T X}{n}$

Nature des résultats

IS généralement difficiles à obtenir $\Rightarrow$ nécessité d'ajouter une hypothèse, souvent restrictive, sur la matrice de Gram, $\Psi^n = \dfrac{X^T X}{n}$

"Bon" estimateur :

- Optimalité : résultats d'optimalité de deux types :
  - d'un point de vue asymptotique ($n \to +\infty$), consistance de la procédure d'estimation.
  - d'un point de vue non-asymptotique, on recherche des IS du même type que celles décrites dans la Définition précédente
- Hypothèses : hypothèses sur la matrice de Gram Ψ^n aussi faibles que possible.
- Complexité algorithmique : méthode d'estimation utilisable en pratique; i.e., implémentable en un temps raisonnable même lorsque p est plus grand que n
- Interprétabilité : estimateur sparse $\Rightarrow$ possibilité d'extraire l'information utile et d'interpréter les résultats

References I


Hirotogu Akaike.
Information theory and an extension of the maximum likelihood principle.
In *Selected papers of hirotugu akaike*, pages 199–213. Springer, 1998.


Peter J Bickel, Ya'acov Ritov, and Alexandre B Tsybakov.
Simultaneous analysis of lasso and dantzig selector.
The Annals of Statistics, 2009.


David L Donoho and Iain M Johnstone.
Ideal spatial adaptation by wavelet shrinkage.
biometrika, 81(3):425–455, 1994.

References II


David L Donoho and Iain M Johnstone.
Adapting to unknown smoothness via wavelet shrinkage.
Journal of the american statistical association, 90(432):1200–1224, 1995.


Bradley Efron, Trevor Hastie, Iain Johnstone, and Robert Tibshirani.
Least angle regression.
The Annals of Statistics, 2004.


Trevor Hastie.
Tibshirani r. friedman j.: The elements of statistical learning.
Friedman J.: The elements of statistical learning, 2001.


Arthur E Hoer1 and Robert W Kennard.
A note on a power generalization of ridge regression.
Technometrics, 17(2):269–269, 1975.

References III


CL Mallows.
Some remarks of cp.
Technometrics, 15:661–675, 1973.


Gideon Schwarz.
Estimating the dimension of a model.
The annals of statistics, pages 461–464, 1978.


Robert Tibshirani.
Regression shrinkage and selection via the lasso.
Journal of the Royal Statistical Society Series B: Statistical Methodology, 58(1):267–288, 1996.