Statistiques avancées 3A

CentraleSupélec

Sarah Lemler

2024





CentraleSupélec

Outline

1. Introduction
2. Penalized methods
3. Theoretical study of the Lasso in the linear regression model
4. Theoretical study of the Lasso in a non-linear regression model
5. Generalized Linear Model and the Lasso

Cadre général : régression linéaire multidimensionnelle

On dispose d'un n-échantillon $(x_1, y_1), \ldots, (x_n, y_n)$ tel que :

$$y_i = x_i \beta^* + \varepsilon_i, \quad i = 1, \ldots, n$$

- ε_i v.a. mutuellement indépendantes de loi normale $\mathcal{N}(0, \sigma^2)$, avec σ connu
- $x_i = (x_{i,1}, \ldots, x_{i,p})$ vecteur de covariables p-dimensionnel, supposé déterministe
- $\beta^* \in \mathbb{R}^p$ vecteur inconnu des paramètres de régression

Cadre général : régression linéaire multidimensionnelle

Notations :

$$X = \begin{pmatrix} x_{1,1} & \dots & x_{1,p} \\ \vdots & \ddots & \vdots \\ x_{n,1} & \dots & x_{n,p} \end{pmatrix} = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} X_1 & \dots & X_p \end{pmatrix}$$

$$Y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}, \quad \varepsilon = \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{pmatrix}, \quad \beta^* = \begin{pmatrix} \beta_1^* \\ \vdots \\ \beta_p^* \end{pmatrix}$$

- X : matrice des données ou matrice de design
- X_j pour $j = 1, \dots, p$: variables explicatives
- Y : la réponse

Cadre général : régression linéaire multidimensionnelle

Sous forme matricielle :

$$Y = \sum_{j=1}^{p} \beta_j^* X_j + \varepsilon = X\beta^* + \varepsilon$$

β_j^* traduit l'influence de la variable X_j sur Y

La grande dimension

$$p = p(n) \geq n$$

Objectifs :

- Estimation de β^*
- Estimation de $X\beta^*$

Les moindres carrés ordinaires

Méthode usuelle pour estimer β^* : $\hat{\beta}$ minimise la somme des carrés résiduels

$$\sum_{i=1}^{n}(y_i - x_i\hat{\beta})^2 = \min_{\beta\in\mathbb{R}^p}\sum_{i=1}^{n}(y_i - x_i\beta)^2$$

$$\Leftrightarrow$$

$$\|Y - X\hat{\beta}\|_n^2 = \min_{\beta\in\mathbb{R}^p}\|Y - X\beta\|^2$$

Estimateur des moindres carrés (EMC)

$$\hat{\beta}^{\mathsf{MC}} \in \operatorname*{argmin}_{\beta\in\mathbb{R}^p}\frac{1}{n}\sum_{i=1}^{n}(y_i - x_i\beta)^2 = \operatorname*{argmin}_{\beta\in\mathbb{R}^p}\|Y - X\beta\|_n^2$$

Théorème

Si X^TX est inversible, l'EMC est unique et s'écrit

$$\hat{\beta}^{\mathsf{MC}} = (X^TX)^{-1}X^TY$$

Erreur de prédiction de l'estimateur des moindres carrés

Théorème

Pour tout (p, n), l'erreur de prédiction de l'EMC vaut :

$$\mathbb{E}\left[\|X\hat{\beta}^{\mathsf{MC}} - X\beta^*\|_n^2\right] = \sigma^2 \frac{\mathrm{rg}(X)}{n},$$

où $\mathbb{E}$ est l'espérance sous la loi de probabilité de ε.

L'estimateur $X\hat{\beta}^{\mathsf{MC}}$ de $X\beta^*$, basé sur l'EMC, est consistant au sens ℓ_2 pour l'estimation de $X\beta^*$ quand n tend vers l'infini dès lors que $\frac{\mathrm{rg}(X)}{n} = o(1)$:

- pour $p(n) = o(n)$
- p fixe et $\mathrm{rg}(X) \leq \min\{p, n\}$

Limites de l'estimateur des moindres carrés

β^* n'est pas identifiable si la matrice X^TX n'est pas inversible :

- lorsque les colonnes de X sont liées
- pour $p > n$, la matrice X^TX étant au plus de rang n (cadre qui nous intéresse)

- EMC pas défini de manière unique et résultats obtenus non interprétables
- Estimateur en général pas consistant au sens ℓ_2 pour l'estimation de $X\beta^*$ (sauf si les colonnes de X sont liées telles que $\mathrm{rg}(X)$ asymptotiquement négligeable devant n)
- p proche de n (et $p < n$) ou variables corrélées $\Rightarrow$ valeurs propres de X^TX proches de zéro $\Rightarrow$ X^TX mal conditionnée et calcul numérique de l'inverse de X^TX instable $\Rightarrow$ EMC inexploitable

Outline

1. Introduction
2. Penalized methods
3. Theoretical study of the Lasso in the linear regression model
4. Theoretical study of the Lasso in a non-linear regression model
5. Generalized Linear Model and the Lasso

Les méthodes pénalisées

$$\hat{\beta} = \underset{\beta \in \mathbb{R}^p}{\arg\min} \left\{ \| Y - X\beta \|_n^2 + \text{pen}(\beta, n) \right\},$$

où l'application $\text{pen} : \mathbb{R}^p \to \mathbb{R}^+$ est appelée pénalité

- le choix de la pénalité dépend de l'objectif
- bien choisie, elle permet d'éviter l'inversion de $X^T X$

L'estimateur Ridge

Pénalité Ridge (Hoerl et Kennard [?])

$$\text{pen}(\beta, n) = \lambda \sum_{j=1}^{p} \beta_j^2,$$

où $\lambda \geq 0$ est un paramètre de lissage qui dépend éventuellement de n

Estimateur Ridge

L'estimateur Ridge $\hat{\beta}^R$ est défini de manière unique, même dans le cadre de la grande dimension, $p \geq n$, lorsque $\lambda > 0$. Il s'écrit

$$\hat{\beta}^R(\lambda) = (X^T X + \lambda I_p)^{-1} X^T Y$$

L'estimateur Ridge

Remarque : si les β_j ne sont pas contraints, ils peuvent prendre de très grandes valeurs et donc avoir une grande variance

Idée : pour contrôler la variance, il faut contrôler la taille des β_j

X^TX et $X^TX+\kappa I_p$ ont les mêmes vecteurs propres, mais des valeurs propres différentes : si v_j est un vecteur propre de X^TX associé à la valeur propre μ_j,

$$(X^TX+\lambda I_p)v_j = X^TXv_j+\kappa v_j = (\mu_j+\lambda)v_j$$

alors v_j est un vecteur propre de $X^TX+\lambda I_p$ associé à la valeur propre $\mu_j+\lambda$

$$\hat{\beta}^R(\lambda) = (X^TX+\lambda I_p)^{-1}X^TY$$

Propriétés de l'estimateur Ridge

- Point de vue numérique : $\hat{\beta}^R$ plus stable que $\hat{\beta}^{MC}$, choix de λ suffisamment grand permet de rendre les valeurs propres de $X^TX + \lambda I_p$ assez grandes pour que l'inverse de cette matrice soit bien conditionnée

- Point de vue statistique : l'estimateur Ridge est biaisé

Vers la sélection de variables

$\beta^* = (\beta_1^*, \ldots, \beta_p^*)$ traduit le poids des variables explicatives $(X_1, \ldots, X_p)$ sur la réponse Y

Objectif : évaluer la contribution de chaque variable et éliminer les variables non pertinentes

Plusieurs méthodes :

- Sélection de sous-ensembles (*Subset Selection*) : trouver le meilleur sous-ensemble $\mathscr{B}_k$ de taille k, où $k \in \{1, \ldots, p\}$ qui réduit au maximum la somme des carrés des résidus (Hastie, Tibshirani, et Friedman [?])
- Seuillage : utilisation d'un estimateur préliminaire (e.g. l'EMC si $p \leq n$), on ne sélectionne que les variables X_j pour lesquelles l'estimation de β_j dépasse un seuil arbitraire choisi par le statisticien (Donoho et Johnstone [?, ?])
- Tests : (H_0) $\beta_j = 0$ contre (H_1) $\beta_j \neq 0$ pour tout $j \in \{1, \ldots, p\}$ (test de student ou de Fisher si le bruit est gaussien) (Hastie, Tibshirani, et Friedman [?])

Pénalisation ℓ_0

$|\mathscr{A}|$ correspond au cardinal de $\mathscr{A}$, un ensemble quelconque d'indices

Définition

Soit le modèle de régression linéaire. On définit l'ensemble de sparsité associé au vecteur β^* par

$$\mathscr{A}^* = \{j : \beta_j^* \neq 0\}.$$

On définit l'indice de sparsité de β^* par la quantité $|\mathscr{A}^*|$.

Objectif : construction d'estimateurs interprétables

Exemples d'estimateurs interprétables construits à partir de la pénalité ℓ_0 :

- critère d'information du Cp de Mallows (Mallows [?])
- critère AIC (Akaike Information Criterion) (Akaike [?])
- critère BIC (Bayesian Information Criterion)(Schwartz [?])

Pénalisation ℓ_0

Idée générale de ces critères :

- soit $\hat{\mathscr{F}} = \{\hat{\beta}_1, \ldots, \hat{\beta}_D\}$ une collection d'estimateurs de taille D
- sélection dans cette collection de l'estimateur qui remplit au mieux le double objectif suivant :
  - la bonne estimation de $X\beta^*$
  - la bonne estimation des variables pertinentes $\mathscr{A}^*$
  - pénalité de ces critères :

$$\text{pen}(\beta, n) = \lambda_n \|\beta\|_0,$$

où $\|\beta\|_0 = \sum_{j=1}^{p} \mathbb{1}_{\{\beta_j \neq 0\}}$

Cp de Mallows et AIC

Sous l'hypothèse du bruit gaussien :

$$\mathbb{E}\left[\|X\hat{\beta} - X\beta^*\|_n^2\right] + \sigma^2 = \mathbb{E}\left[\|Y - X\hat{\beta}\|_n^2\right] + \frac{2\sigma^2}{n}\mathrm{Tr}(P_{<X>})$$

où $\mathbb{E}$ désigne la covariance sous la loi de ε et $P_{<X>}$ la projection sur $<X>$

$\hookrightarrow$minimiser l'erreur de prédiction équivaut à minimiser le membre de droite
$\|\beta\|_0$ est un estimateur de $Tr(P_{<X>})$

$\tilde{\beta}$ estimateur Cp et AIC est tel que

$$\|Y - X\tilde{\beta}\|_n^2 + \frac{2\sigma^2\|\tilde{\beta}\|_0}{n}$$

donne une bonne approximation de l'erreur de prédiction

$\hookrightarrow$Cp et AIC bons estimateurs pour la prédiction $X\beta^*$

Cp de Mallows et AIC

Modèle de régression linéaire gaussien

$$\text{pen}^{\text{AIC}}(\beta, n) = \text{pen}^{Cp}(\beta, n) := \frac{2\sigma^2 \|\beta\|_0}{n}$$

Critère BIC

Plus approprié pour l'estimation de $\mathscr{A}^*$ car surpénalise les gros modèles

$$\text{pen}^{\text{BIC}}(\beta, n) := \sigma^2 \log(p) \frac{\|\beta\|_0}{n}$$

$\hookrightarrow$ impose une plus forte contrainte aux estimateurs dont beaucoup de composantes sont différentes de zéro, dès que $p \geq 7$

$\hookrightarrow$ tend à sélectionner des estimateurs plus parcimonieux (*sparse*) que ceux choisis par les critères Cp et AIC

Critères Cp, AIC,BIC

Performances théoriques :

- BIC a de meilleures performances théoriques dans le cadre de l'estimation du support $\mathscr{A}^*$ de β^* (on parle de sélection)
- les estimateurs Cp et AIC donnent de meilleurs résultats pour l'estimation de $X\beta^*$ (on parle de prédiction).

Inconvénient de ces critères

Complexité algorithmique trop grande dès que D grand ou que p grand
$\Rightarrow$ Exemple d'hypothèses sur le modèle :

- supposer les variables ordonnées
- considérer une famille $\hat{\mathscr{F}}$ d'estimateurs sparses

Ces méthodes de sélection de variables ont été introduites dans un cadre classique d'estimation, où la dimension p est raisonnable ($p \leq n$)

Hypothèse de sparsité

On se place dans un cadre de grande dimension $p > n$
Les différents objectifs :

- Estimation de β^*
- Estimation de $X\beta^*$
- Estimation du support $\mathscr{A}^*$ de β^*

Hypothèse (S) de sparsité

Soit $\mathscr{A}^*$ l'ensemble de sparsité de β^*. Il existe un entier s, tel que

$$|\mathscr{A}^*| \leq s,$$

et on suppose que $s = o(n)$

$\hookrightarrow$ contrôle sur la sparsité du modèle
$\hookrightarrow$ on part du principe qu'il y a peu de variables explicatives pertinentes pour l'étude

Estimateur des moindres carrés restreint

Cadre idéal : on connaît l'ensemble de sparsité $\mathscr{A}^*$

$\hat{\beta}^{MCR}$ estimateur des moindres carrés restreint aux variables X_j dont les indices j sont dans $\mathscr{A}^*$:

$$\hat{\beta}^{MCR} = (X_{\mathscr{A}^*}^T X_{\mathscr{A}^*})^{-1} X_{\mathscr{A}^*}^T Y,$$

où $X_{\mathscr{A}^*}$ restriction de la matrice X aux colonnes X_j avec $j \in \mathscr{A}^*$

Erreur de prédiction

$$\mathbb{E}\left[\| X\hat{\beta}^{MCR} - X\beta^* \|_n^2 \right] = \sigma^2 \frac{|\mathscr{A}^*|}{n}$$

Si (S) est satisfaite, $\hat{\beta}^{MCR}$ est consistant, son erreur ne dépend pas de la dimension effective p du problème, mais de la dimension réelle $|A^*|$

↪ En pratique, $\mathscr{A}^*$ est rarement connu, donc $\hat{\beta}^{MCR}$ n'est pas exploitable

Estimateur LASSO

Introduit par Tibshirani [?] :
LASSO (Least Absolute Shrinkage and Selection Operator)
Estimateur défini comme l'estimateur des moindres carrés sous une contrainte de type ℓ_1 :

$$\tilde{\beta}^L(t) = \begin{cases} \operatorname{argmin}_{\beta \in \mathbb{R}^p} \|Y - X\beta\|_n^2, \\ \text{s.c. } \|\beta\|_1 \leq t, \end{cases}$$

où $t \geq 0$

$$\hat{\beta}^L(\lambda) \in \operatorname*{argmin}_{\beta \in \mathbb{R}^p} \left\{ \|Y - X\beta\|_n^2 + \lambda \|\beta\|_1 \right\} \tag{1}$$

Les estimateurs $\tilde{\beta}^L$ et $\hat{\beta}^L$ sont équivalents point par point :
pour un t fixé, on peut trouver un λ (qui dépend des données) tel que $\tilde{\beta}^L = \hat{\beta}^L$; pour un λ fixé, il existe un t tel que $\tilde{\beta}^L = \hat{\beta}^L$ et $t = \sum_{j=1}^p |\hat{\beta}_j^L(\lambda)|$

Outline

1. Introduction
2. Penalized methods
3. Theoretical study of the Lasso in the linear regression model
4. Theoretical study of the Lasso in a non-linear regression model
5. Generalized Linear Model and the Lasso

Propriétés de l'estimateur Lasso

- $\lambda = 0 \Rightarrow \hat{\beta}^L = \hat{\beta}^{MC}$: la procédure Lasso sélectionne toutes les variables explicatives
  $\lambda \to +\infty \Rightarrow \hat{\beta}^L = \mathbf{0_p}$: la procédure Lasso ne sélectionne aucune variable explicative
  Entre ces deux valeurs extrêmes, la procédure Lasso sélectionne d'autant plus de variables explicatives que λ est petit, i.e., plus λ est grand, plus la contrainte sur les coefficients de β l'est également.
- L'estimateur Lasso peut s'interpréter en terme d'estimation dans le cadre de l'inférence bayésienne. En effet, nous pouvons déduire l'estimateur Lasso en considérant le modèle de régression avec bruit gaussien, et en prenant comme loi a priori pour le paramètre β^* la loi de Laplace; i.e., β_j^* admet pour densité a priori par rapport à la mesure de Lebesgue $\frac{\lambda}{2}\exp\left(-\lambda|\beta_j^*|\right)$.

Propriétés de l'estimateur Lasso I

- L'estimateur Lasso est linéaire par morceaux comme fonction de λ.
  - Si les colonnes de X sont orthogonales (ou le cas trivial où $p=1$) :

Chaque composante du vecteur $\hat{\beta}^L = (\hat{\beta}^L_1, \ldots, \hat{\beta}^L_p)^T$ s'écrit en fonction de l'estimateur des moindres carrés $\hat{\beta}^{MC} = (X^T X)^{-1} X^T Y$:

$$\hat{\beta}^L_j(\lambda) = \mathrm{sgn}(\hat{\beta}^{MC}_j)(|\hat{\beta}^{MC}_j| - \lambda/2)_+, \quad \forall j \in \{1, \ldots, p\}$$

où $(\alpha)_+ = \max(\alpha, 0)$ pour α un réel et la fonction $\mathrm{sgn}(.)$ est définie pour tout réel b par

$$\mathrm{sgn}(b) = \begin{cases} 1 & \text{si } b > 0 \\ 0 & \text{si } b = 0 \\ -1 & \text{si } b < 0 \end{cases}$$

Si on choisit $\lambda^{(k)} = |\hat{\beta}^{MC}_k|$, $k \in \{1, \ldots, p\}$, la linéarité de $\hat{\beta}^L$ change en fonction de ces λ

Propriétés de l'estimateur Lasso II

- Si X n'est pas une matrice orthogonale (et $p \neq 1$) :
  les valeurs du paramètre de régularisation telles que la linéarité change peuvent être trouvées en considérant les conditions d'optimalité du premier ordre (1), les conditions Karush-Kuhn-Tucker (KKT).
  Ensemble de sparsité ou ensemble actif de l'estimateur Lasso $\hat{\beta}^L(\lambda)$:

$$\hat{\mathscr{A}}_L = \hat{\mathscr{A}}(\lambda) = \{j \in \{1, \dots, p\} : \hat{\beta}_j^L \neq 0\}$$

  Conditions KKT :

$$\begin{cases} 2(X^j)^T(Y - X\hat{\beta}^L(\lambda)) = \lambda \operatorname{sgn}(\hat{\beta}_j^L) & \forall j \in \hat{\mathscr{A}}_L, \\ 2|(X^j)^T(Y - X\hat{\beta}^L(\lambda))| \leq \lambda & \forall j \notin \hat{\mathscr{A}}_L \end{cases} \tag{2}$$

  Pour trouver des valeurs du paramètre de régularisation $\{\lambda^{(1)}, \dots, \lambda^{(K)}\}$ pour lesquels la linéarité de $\hat{\beta}^L(\lambda)$ change, on considère les conditions non saturées dans les conditions KKT ($2^{\text{ème}}$ ligne de (2)) : pour tout $j \notin \hat{\mathscr{A}}_L$, il existe $\lambda^{(k)}$ tel que $|(X^j)^T(Y - X\hat{\beta}^L(\lambda^{(k)}))| = \lambda^{(k)}/2$.
  Pour $\lambda = \lambda^{(k)}$, la contrainte correspondant à X^j devient saturée et X^j devient active (i.e., l'indice j "passe" de $\hat{\mathscr{A}}_L^c$ à $\hat{\mathscr{A}}_L$).

Propriétés de l'estimateur Lasso III

- Une solution approchée de l'estimateur Lasso peut être obtenue grâce par exemple à l'algorithme LARS (Efron, Hastie, Johnstone, et Tibshirani [?])
  Algorithme basée sur les conditions KKT, i.e., sur les corrélations entre le résidu $Y - X\hat{\beta}^L(\lambda)$ et les variables explicatives $(X_1, \ldots, X_p)$.

  Inconvénient de cet algorithme :
  → échoue à construire de bonnes évaluations de l'estimateur lorsque de fortes corrélations interviennent entre les variables
  → tend à sélectionner une variable explicative par groupe de variables corrélées, écartant ainsi de l'étude les autres variables du groupe

Nature des résultats

3 objectifs différents :

- fournir la meilleure approximation du vecteur $X\beta^*$: on parle de prédiction
- estimer le vecteur β^* : on parle d'estimation
- identifier le support $\mathscr{A}^*$ de β^*, ou encore le vecteur signe de β^* : on parle de sélection

Nature des résultats

Définition

Soit l'hypothèse (S) de sparsité vérifiée et s l'indice associé. On dit qu'un estimateur $\hat{\beta}$ vérifie une Inégalité de Sparsité (IS)

en prédiction si : $$\mathbb{E}\left[\|X\beta^* - X\hat{\beta}\|_n^2\right] \leq Cs\frac{L(n,p)}{n}$$

en estimation en norme ℓ_1 si : $$\mathbb{E}\left[\|\hat{\beta} - \beta^*\|_1\right] \leq Cs\sqrt{\frac{L(n,p)}{n}}$$

en estimation en norme-sup si : $$\mathbb{E}\left[\|\hat{\beta} - \beta^*\|_\infty\right] \leq C\sqrt{\frac{L(n,p)}{n}}$$

où $C > 0$ et $L(n,p)$ dépendance au plus logarithmique en n et p.

Remarque : Toutes les IS peuvent être également définies à l'aide d'inégalités probabilistes.

Nature des résultats

IS généralement difficiles à obtenir $\Rightarrow$ nécessité d'ajouter une hypothèse, souvent restrictive, sur la matrice de Gram, $\Psi^n = \dfrac{X^T X}{n}$

Nature des résultats

IS généralement difficiles à obtenir $\Rightarrow$ nécessité d'ajouter une hypothèse, souvent restrictive, sur la matrice de Gram, $\Psi^n = \dfrac{X^T X}{n}$

"Bon" estimateur :

- Optimalité : résultats d'optimalité de deux types :
  - d'un point de vue asymptotique ($n \to +\infty$), consistance de la procédure d'estimation.
  - d'un point de vue non-asymptotique, on recherche des IS du même type que celles décrites dans la Définition précédente
- Hypothèses : hypothèses sur la matrice de Gram Ψ^n aussi faibles que possible.
- Complexité algorithmique : méthode d'estimation utilisable en pratique; i.e., implémentable en un temps raisonnable même lorsque p est plus grand que n
- Interprétabilité : estimateur sparse $\Rightarrow$ possibilité d'extraire l'information utile et d'interpréter les résultats

Résultats théoriques pour l'estimateur Lasso[1]

[1] Bickel, Peter J and Ritov, Ya'acov and Tsybakov, Alexandre B, *Simultaneous analysis of Lasso and Dantzig selector*, The Annals of Statistics [?]

Notations

- $\mathscr{M}(\beta) = \sum_{j=1}^{p} \mathbb{1}_{\{\beta_j \neq 0\}} = |J(\beta)|$ number of nonzero coordinates of β
  $\rightarrow$ characterizes the sparsity of the vector β: the smaller $\mathscr{M}(\beta)$, the "sparser" β
- $J(\beta) = \{j \in \{1, \ldots, p\} : \beta_j \neq 0\}$ and $|J|$ the cardinality of J
- For a vector $\delta \in \mathbb{R}^p$ and a subset $J \subset \{1, \ldots, p\}$, δ_J is the vector in $\mathbb{R}^p$ that has the same coordinates as δ on J and zero coordinates on the complement J^c of J

Lasso estimator

$$\hat{\beta}^L = \underset{\beta \in \mathbb{R}^p}{\arg\min} \left\{ \frac{1}{n} \| Y - X\beta \|_2^2 + 2r \|\beta\|_1 \right\}, \quad r > 0 \tag{3}$$

Assumption on the Gram matrix I

Assumption on the Gram matrix Ψ^n allows only a weak correlation between variables

Notations:

- Matrice de Gram:

$$\Psi^n = \left[\Psi^n_{j,k}\right]_{1\leq j,k\leq p} = \frac{X^T X}{n},$$

- ϕ_{max} maximal eigenvalue of Ψ^n

Assumption

The diagonal elements of the Gram matrix Ψ^n are all equal to 1.

Remark: this assumption is just for the sake of simplicity.

Assumption on the Gram matrix II

Degenerate case :

For $p > n$ and even $p \gg n$, Ψ^n is degenerate

$$\Rightarrow \min_{\delta \in \mathbb{R}^p : \delta \neq 0} \frac{(\delta^T \Psi^n \delta)^{1/2}}{\|\delta\|_2} = \min_{\delta \in \mathbb{R}^p : \delta \neq 0} \frac{\|X\delta\|_2}{\sqrt{n}\|\delta\|_2} = 0 \tag{4}$$

$\Rightarrow$ ordinary least squares does not work in this case, since it requires positive definiteness of Ψ^n

$\rightarrow$ Lasso requires much weaker assumptions: the minimum in (4) can be replaced by the minimum over a restricted set of vectors, and the norm $\|\delta\|_2$ in the denominator of the condition can be replaced by the ℓ_2–norm of only a part of δ

Assumption on the Gram matrix III

The residuals of the linear regression model $\delta = \hat{\beta}^L - \beta^*$ satisfy with probability close to 1:

$$\|\delta_{J_0^c}\|_1 \leq 3\|\delta_{J_0}\|_1, \qquad \text{where } J_0 = J(\beta^*) \tag{5}$$

Let Ψ be a positive definite $(p \times p)-$matrix, $\omega_n = \max_{i,j} |(\Psi^n - \Psi)_{i,j}|$ the maximal difference between the elements of Ψ^n and Ψ; and δ satisfies (5)

$$\begin{aligned}\frac{\delta^T \Psi^n \delta}{\|\delta\|_2^2} &= \frac{\delta^T \Psi \delta + \delta^T (\Psi^n - \Psi)\delta}{\|\delta\|_2^2} \geq \frac{\delta^T \Psi \delta}{\|\delta\|_2^2} - \frac{\omega_n \|\delta\|_1^2}{\|\delta\|_2^2} \\ &\geq \frac{\delta^T \Psi \delta}{\|\delta\|_2^2} - \omega_n \left(\frac{4\|\delta_{J_0}\|_1}{\|\delta_{J_0}\|_2}\right)^2 \geq \frac{\delta^T \Psi \delta}{\|\delta\|_2^2} - 16\omega_n |J_0|\end{aligned}$$

$\Rightarrow$ for $\omega_n |J_0|$ small enough, $\dfrac{\delta^T \Psi^n \delta}{\|\delta\|_2^2}$ bounded away from 0

$\Rightarrow$ kind of "restricted" positive definiteness, which is valid only for the vectors satisfying (5).

Assumption on the Gram matrix IV

Restricted Eigenvalue (RE) assumptions : $\mathrm{RE}(s,3)$

For some integer s such that $1 \leq s \leq p$, the following condition holds:

$$\kappa(s,3) = \min_{\substack{J_0 \subseteq \{1,\dots,p\}, \\ |J_0| \leq s}} \min_{\substack{\delta \neq 0, \\ \|\delta_{J_0^c}\|_1 \leq 3\|\delta_{J_0}\|_1}} \frac{\|X\delta\|_2}{\sqrt{n}\|\delta_{J_0}\|_2} > 0$$

Remark:

- s plays the role of an upper bound on the sparsity $\mathscr{M}(\beta^*)$
- under Assumption $\mathrm{RE}(s,3)$,

$$\min\{\|X\delta\|_2 : \mathscr{M}(\delta) \leq 2s, \delta \neq 0\} > 0$$

$\Rightarrow$ the square submatrices of size $\leq 2s$ of the Gram matrix are necessarily positive definite

Theoretical results

Theorem (Bickel, Ritov, Tsybakov (2009))

Assumptions :

- ε_i independent $\mathcal{N}(0,\sigma^2)$ random variables with $\sigma^2 > 0$,
- the diagonal elements of the matrix $X^T X/n$ equal to 1,
- $\mathcal{M}(\beta^*) \leq s$, where $1 \leq s \leq p$, $n \geq 1$, $p \geq 2$,
- $\mathrm{RE}(s,3)$ is satisfied.

Consider the Lasso estimator $\hat{\beta}^L$ defined by (3) with $r = A\sigma\sqrt{\frac{\log p}{n}}$ and $A > 2\sqrt{2}$. Then, with probability at least $1 - p^{1-A^2/8}$, we have

$$\|\hat{\beta}^L - \beta^*\|_1 \leq \frac{16A}{\kappa^2(s,3)}\sigma s\sqrt{\frac{\log p}{n}}, \tag{6}$$

$$\|X(\hat{\beta}^L - \beta^*)\|_2^2 \leq \frac{16A^2}{\kappa^2(s,3)}\sigma^2 s\log p, \tag{7}$$

$$\mathcal{M}(\hat{\beta}^L) \leq \frac{64\phi_{max}}{\kappa^2(s,3)}s. \tag{8}$$

Theoretical results

Remarks:

- Gives only non-asymptotic upper bounds on the loss, with some probability and under some conditions. The probability depends on p and the conditions depend on n and p. Recall that Assumption $\mathrm{RE}(s,3)$ is imposed on the $n \times p$ matrix X. To deduce asymptotic convergence (as $n \to +\infty$ and/or as $p \to +\infty$), we would need some very strong additional properties.
- Assumption $\mathrm{RE}(s,3)$ does not implies identifiability of β^*, but β^* is uniquely defined because of the assumption $\mathscr{M}(\beta^*) \leq s$

Outline

1. Introduction
2. Penalized methods
3. Theoretical study of the Lasso in the linear regression model
4. Theoretical study of the Lasso in a non-linear regression model
5. Generalized Linear Model and the Lasso

Non-linear regression model

The model :

$$Y_i = f(Z_i) + \varepsilon_i, \quad i = 1, \ldots, n$$

- $Z_i \in \mathbb{R}^p$ deterministic covariates
- $\varepsilon_1, \ldots, \varepsilon_n$ i.i.d. $\mathcal{N}(0, \sigma^2)$
- $f : \mathbb{R}^p \to \mathbb{R}$ regression function to be estimated

Estimation in high-dimensional non-linear regression models

$\mathscr{F} = \{f_1, \ldots, f_M\}$ set of functions called a dictionary,
M can be much larger than n

Objective: learn from data an estimator of f of the form

$$f_\beta(z) = \sum_{j=1}^{M} \beta_j f_j(z)$$

with the following properties:

- the empirical error $\frac{1}{n}\sum_{i=1}^{n}(f_\beta(Z_i) - f(Z_i))^2$ is small
- the sparsity of β: $\|\beta\|_0 = |J(\beta)| = |\{j = 1, \ldots, M : \beta_j \neq 0\}|$ is small compared to M

If both properties are satisfied $\Rightarrow$ we can find a sparse linear combination of elements of $\mathscr{F}$ to estimate f

$\Rightarrow$ Sparse estimation

Estimation in high-dimensional non-linear regression models

Remark: if $M = p$ and $f_j(x) = x_j$, we recover the standard linear regression model where $f_\beta(x) = x^T\beta$

Notations:

$$X = \begin{pmatrix} f_1(Z_1) & \dots & f_M(Z_1) \\ \vdots & & \vdots \\ f_1(Z_n) & \dots & f_M(Z_n) \end{pmatrix} = \begin{pmatrix} X_1^T \\ \vdots \\ X_n^T \end{pmatrix} = \begin{pmatrix} X^1 & \dots & X^M \end{pmatrix}$$

$$y = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}, \quad f = \begin{pmatrix} f(Z_1) \\ \vdots \\ f(Z_n) \end{pmatrix}, \quad f_\beta = \begin{pmatrix} f_\beta(Z_1) \\ \vdots \\ f_\beta(Z_n) \end{pmatrix}, \quad \varepsilon = \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

Gaussian linear model:

$$y = X\beta + \varepsilon,$$

$M \gg n \Rightarrow X$ can be overdetermined: it is not full-rank

$\|u\|$ Euclidean norm of $u \in \mathbb{R}^n$

Estimation in high-dimensional non-linear regression models

Oracle inequalities: we are looking for an estimator $\hat{\beta}_n$ s.t. $\|\hat{\beta}_n\|_0 \ll M$ and

$$\frac{1}{n}\|f_{\hat{\beta}_n} - f\|^2 \leq \inf_{\beta \in \mathbb{R}^M} \left\{ \frac{1}{n}\|f_\beta - f\|^2 + remainder(\beta) \right\} \quad \text{oracle inequality}$$

ideally, $remainder(\beta)$ small quantity that depends on β, but might depends on $n, \mathscr{F}, \sigma^2$

Interpretation:

If *remainder* is small, then such an inequality would prove that the estimator $f_{\hat{\beta}_n}$ performs almost as well as the best linear combination $f^* = f_{\beta^*}$ of elements from $\mathscr{F}$, where $\beta^* \in \underset{\beta \in \mathbb{R}^M}{\arg\min} \|f_\beta - f\|^2$

f^* is an oracle since it depends on the unknown function f

Estimation in high-dimensional non-linear regression models

Questions:

- How can we construct a sparse estimator $\hat{\beta}_n$?
- What is the value of *remainder* in the oracle inequality?

$$\hat{\beta}_n^{lasso} = \underset{\beta \in \Theta}{\arg\min} \left\{ \frac{1}{n} \sum_{i=1}^{n} (Y_i - f_\beta(X_i))^2 + \lambda \|\beta\|_1 \right\}, \quad \Theta \subset \mathbb{R}^M \text{ convex set}$$

Convex optimization

Convex relaxation: ℓ_1 convex relaxation of ℓ_0

Convex envelope[2] of $g_0(x) = \mathbb{1}_{\{x \neq 0\}}$ over the interval $[-1,1]$ is $g_1(x) = |x|$

$\Rightarrow$ Convex envelope of $x \mapsto \|x\|_0$ over $[-1,1]^M$ is $x \mapsto \|x\|_1$

Constrained optimization problem:

$$\begin{cases} \min \|x\|_0 \\ \text{s.t. } x \in C \text{ and } \|x\|_\infty \leq R, \text{ where } C \text{ is a convex set} \end{cases}$$

$$\Leftrightarrow \begin{cases} \min \mathbb{1}^T u \\ \text{s.t. } u \in \{0,1\}^M, |x_i| \leq R u_i \text{ for all } i = 1, \ldots, M \\ x \in C \end{cases}$$

$\hookrightarrow$ hard to solve exactly since it requires to try out all possible vectors $u \in \{0,1\}^M$

[2] convex envelope of $g : [a,b] \to \mathbb{R}$ is at each point $x \in [a,b]$ the supremum of all convex functions that lie under g: $g^{env}(x) = \sup\{h(x) : h \text{ convex and } h \leq g \text{ over} [a,b]\}$

Convex optimization

Convex relaxation of this problem:

$$\begin{cases} \min \mathbb{1}^T u \\ \text{s.t. } u \in \{0,1\}^M, |x_i| \leq R u_i \text{ for all } i = 1, \dots, M \\ x \in C \end{cases}$$

$$\Leftrightarrow \begin{cases} \min \frac{1}{R} \|x\|_1 \\ \text{s.t. } x \in C \text{ and } \|x\|_\infty \leq R \end{cases}$$

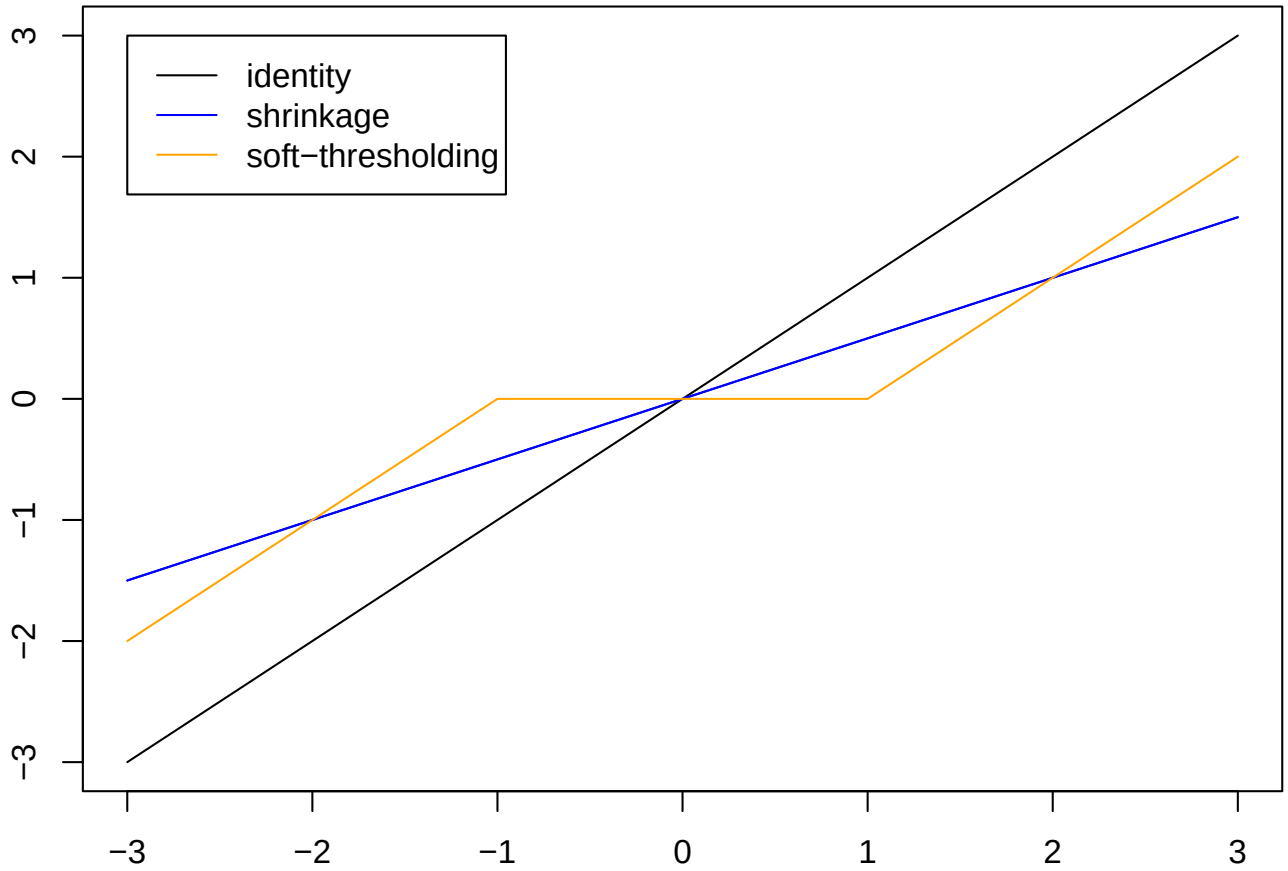
Soft-thresholding:

$$\underset{a \in \mathbb{R}}{\arg\min} \left\{ \frac{1}{2}(a-b)^2 + \lambda |a| \right\} = \operatorname{sgn}(b)(|b| - \lambda)_+, \quad \text{for any } b \in \mathbb{R}$$

$$\Rightarrow \underset{a \in \mathbb{R}^M}{\arg\min} \left\{ \frac{1}{2}\|a-b\|_2^2 + \lambda \|a\|_1 \right\} = T_\lambda(b), \quad \forall b \in \mathbb{R}^M,$$

where $(T_\lambda(b))_j = \operatorname{sgn}(b_j)\left(|b_j| - \lambda\right)_+$, for $j = 1, \dots, M$

Convex optimization

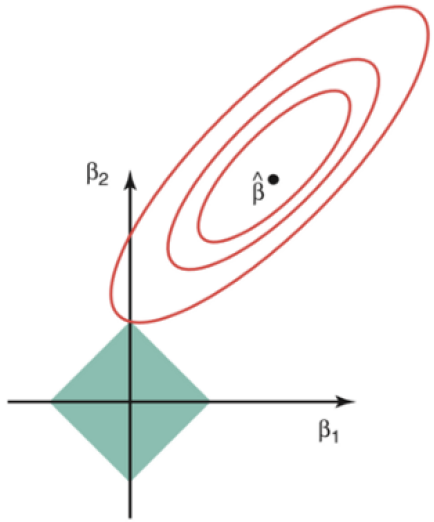


Soft-thresholding and shrinkage with $\lambda = 1$ on a single coordinate

Convex optimization

Interpretation:

- shrinkage operator (= ridge regression) does not induce sparsity while soft-thresholding does
- ℓ_1-norm induces sparsity because of the fact that the absolute value is not differentiable at 0
- geometrically, unit ℓ_1 ball has sparse corners at $\pm e_j$ for $j = 1, \ldots, M$ (canonical basis vectors) that are sparse vectors: when we project a point onto an ℓ_1-ball, we are likely to project onto a corner or an edge, that are sets of sparse points



Some tools from convex optimization

$\phi : \mathbb{R}^p \to \mathbb{R}$ convex function

Definition: Subdifferential

$g \in \mathbb{R}^p$ is a subgradient of a convex function $\phi : \mathbb{R}^p \to \mathbb{R}$ at $u \in \mathbb{R}^p$ if and only if

$$\phi(v) - \phi(u) \geq g^T (v - u) \quad \text{for any } v \in \mathbb{R}^p$$

The subdifferential of ϕ at u is defined by

$$\partial\phi(u) = \left\{ g \in \mathbb{R}^p : \phi(v) - \phi(u) \geq g^T (v - u) \text{ for all } v \in \mathbb{R}^p \right\}$$

$\hookrightarrow$ it generalizes the differential to non-differentiable convex functions

Example: $\phi(u) = |u|$,

$$\partial\phi(u) = \{1\} \text{ if } u > 0$$
$$\partial\phi(u) = \{-1\} \text{ if } u < 0$$
$$\partial\phi(u) = [-1, 1] \text{ if } u = 0$$

Some tools from convex optimization

Properties

- $u^* \in \underset{u \in \mathbb{R}^p}{\arg\min} \phi(u)$ if and only if $0 \in \partial\phi(u^*)$
- $\partial\left(\sum_{k=1}^{K} \alpha_k \phi_k(u)\right) = \sum_{k=1}^{K} \alpha_k \partial\phi_k(u)$ whenever $\alpha_k \geq 0$ and ϕ_k convex functions for all $k = 1, \ldots, K$
- if $\phi(u) = \max_{k=1,\ldots,K} \phi_k(u)$, $\partial\phi(u) = conv\left(\bigcup_{k=1}^{K} \{\partial\phi_k(u) : \phi_k(u) = \phi(u)\}\right)$

  $conv(A)$: convex hull of a set A

Some tools from convex optimization

$C \subset \mathbb{R}^p$ convex set, $\delta_C(u) = \begin{cases} 0 & \text{if } u \in C \\ +\infty & \text{if } u \notin C \end{cases}$

$$u^* \in \underset{u \in C}{\arg\min}\ \phi(u) \Leftrightarrow u^* \in \underset{u \in \mathscr{R}^p}{\arg\min} \left\{\phi(u) + \delta_C(u)\right\}$$
$$\Leftrightarrow 0 \in \partial\phi(u^*) + \partial\delta_C(u^*)$$
$$\Leftrightarrow \exists g^* \in \partial\phi(u^*) : -g^* \in \partial\delta_C(u^*)$$

$g \in \partial\delta_C(u^*)$ with $u^* \in C \Leftrightarrow \delta_C(u) - \underbrace{\delta_C(u^*)}_{=0} \geq g^T(u - u^*),\ \forall u \in \mathbb{R}^p$

$\Rightarrow \forall u \in C, \quad \partial\delta_C(u) = \left\{g \in \mathbb{R}^p : g^T(v - u) \leq 0, \forall v \in C\right\}$ normal cone to C at u

Some tools from convex optimization

Proposition

Let $\phi : \mathbb{R}^p \to \mathbb{R}$ be a convex function and $C \subset \mathbb{R}^p$ a convex set. An optimally criterion for the problem $u^* \in \underset{u \in C}{\arg\min}\ \phi(u)$ is given by

$$\exists g^* \in \partial\phi(u^*) \text{ s.t. } (g^*)^T(u - u^*) \geq 0, \text{for all } u \in C$$

Proposition: monotonicity of the subdifferential

Given a convex function $\phi : \mathbb{R}^p \to \mathbb{R}$, any $u_1, u_2 \in \mathbb{R}^p$ and any $g_1 \in \partial\phi(u_1)$ and $g_2 \in \partial\phi(u_2)$, we have

$$(u_1 - u_2)^T(g_1 - g_2) \geq 0$$

Some tools from convex optimization

Subdifferential of ℓ_1–norm:

$$\phi(u) = \|u\|_1 = \max\left\{e^T u : e \in \{-1,1\}^p\right\} = \max_{i=1,\dots,2^p} \phi_i(u),$$

where $\phi_i(u) = e_i^T u$ and $e_1, \dots, e_{2^p} \in \{-1,1\}^p$

We define $I(u) = \left\{i \in \{1,\dots,2^p\} : e_i^T u = \|u\|_1\right\}$. Each ϕ_i is differentiable and $\nabla \phi_i(u) = e_i$

$$\begin{aligned}\partial \|u\|_1 &= conv\left(\bigcup_{i \in I(u)} \{e_i\}\right) \\ &= \left\{\mathrm{sgn}(u) + h, h \in \mathbb{R}^p, \|h\|_\infty \leq 1, h \odot u = 0\right\},\end{aligned}$$

where $h \odot u$ is the Hadamard product: $(h \odot u)_j = h_j u_j$

Example: if $p = 4$, $u = \begin{pmatrix}17 & -42 & 0 & 3\end{pmatrix}^T$, then

$$\partial \|u\|_1 = \{1\} \times \{-1\} \times [-1,1] \times \{1\}$$

Slow oracle inequality I

Assumption

The columns of X are standardized $\|X^j\|_2 = \sqrt{n}$.

Remark: unrestrictive assumption that follows good practice when using linear methods in ML

$$\hat{\beta}_n = \underset{\beta\in\Theta}{\arg\min}\left\{\frac{1}{n}\sum_{i=1}^{n}(Y_i - f_\beta(Z_i))^2 + \lambda\|\beta\|_1\right\}$$

$$= \underset{\beta\in\Theta}{\arg\min}\left\{\frac{1}{n}\|y - f_\beta\|^2 + \lambda\|\beta\|_1\right\} \quad \text{for some convex set } \Theta \subset \mathbb{R}^p,$$

where $\lambda = 2\sigma\sqrt{\dfrac{2(x+\log M)}{n}}$,

$x > 0$ confidence level and $\sigma > 0$ standard deviation of the noise

Slow oracle inequality II

Theorem

If $\hat{\beta}_n$ is the Lasso estimator, we have that

$$\frac{1}{n}\|f_{\hat{\beta}_n} - f\|^2 \leq \inf_{\beta \in \Theta} \left\{ \frac{1}{n}\|f_\beta - f\|^2 + 2\lambda\|\beta\|_1 \right\}$$

with probability larger than $1 - 2e^{-x}$.

$\hookrightarrow$ slow oracle inequality: the remainder is $O(1/\sqrt{n})$

Proof

Fast oracle inequality I

In order to obtain a faster $O(1/n)$ rate, we need an extra assumption on the matrix of features X:

$$G = \frac{1}{n} X^T X = \left[\frac{1}{n} \langle f_j, f_{j'} \rangle \right]_{1 \leq j, j' \leq M}, \quad f_j = [f_j(Z_1), \ldots, f_j(Z_n)] \in \mathbb{R}^n$$

If $M > n$, we have that

$$\min_{t \in \mathbb{R}^M \setminus \{0\}} \frac{\sqrt{t^T G t}}{\| t \|} = \min_{t \in \mathbb{R}^M \setminus \{0\}} \frac{\| Xt \|}{\sqrt{n} \| t \|} = 0$$

since $X : \mathbb{R}^M \to \mathbb{R}^n$ and $Ker(X) \neq \{0\}$, hence the smallest eigenvalue of G is 0

Fast oracle inequality II

Assumption: Restricted Eigenvalues

X satisfies the $\mathrm{RE}(s, c_0)$ assumption for some $c_0 > 0$ and some $s \in \{1, \dots, M\}$ whenever:

$$\kappa(s, c_0) = \min_{\substack{J \subset \{1,\dots,M\} \\ |J| \leq s}} \min_{\substack{\delta \neq 0 \\ \|\delta_{J^c}\|_1 \leq c_0 \|\delta_J\|_1}} \frac{\|X\delta\|_2}{\sqrt{n}\|\delta_J\|_2} > 0$$

Proposition

If X satisfies $\mathrm{RE}(s, 1)$, then any submatrix of X formed by any subset of $2s$ columns from X has full rank.

Fast oracle inequality III

Theorem

Under $\mathrm{RE}(s,3)$, we have

$$\frac{1}{n}\|f_{\hat{\beta}_n} - f\|^2 \leq \inf_{\substack{\beta \in \Theta \\ \|\beta\|_0 \leq s}} \left\{ \frac{1}{n}\|f_\beta - f\|^2 + \frac{18\sigma^2}{\kappa(s,3)^2} \frac{s(x+\log M)}{n} \right\}$$

with a probability larger than $1 - 2\mathrm{e}^{-x}$.

$\hookrightarrow$ the Lasso estimator realizes a balance between an approximation term $\|f_\beta - f\|^2$ and a complexity term which involves the sparsity of β

$\hookrightarrow$ the Lasso estimator, which is solution of a simple convex problem, is almost as good as the best sparse representation of f using the dictionary $\mathscr{F}$

$\hookrightarrow$ in this inequality, the convergence rate is of order $\frac{s \log M}{n}$, where s is the sparsity of the best β

Outline

1. Introduction
2. Penalized methods
3. Theoretical study of the Lasso in the linear regression model
4. Theoretical study of the Lasso in a non-linear regression model
5. Generalized Linear Model and the Lasso

Introduction

Generalized Linear Models (GLM) [Nelder and Wedderburn (1972)]:

- include gaussian linear, logit and log-linear models
- express the expectation of the variable of interest Y as a function of a linear combination of the covariates

The exponential family

Definition

We say that the random variable Y belongs to exponential family if its density can be written as follows:

$$f_\theta(y) = \exp\left(\eta(\theta)\, T(y) - A(\theta) + B(y)\right),$$

where η, T, A, B are deterministic functions, θ is the unknown parameter.

Examples:

1) Normal distribution $\mathcal{N}(\mu, 1)$:

$$f_\mu(y) = \frac{1}{\sqrt{2\pi}} \exp\left(\frac{-(y-\mu)^2}{2}\right) = \exp\left(y\mu - \frac{1}{2}\mu^2 - \frac{1}{2}y^2 - \log(\sqrt{2\pi})\right)$$

2) Bernoulli distribution $\mathcal{B}(p)$:

$$f_p(y) = p^y(1-p)^{1-y} = (1-p)\exp\left(y\log\left(\frac{p}{1-p}\right)\right), \quad \text{for } y \in \{0,1\}$$

Definition of the GLM

A Generalized Linear Model for the data $(x_1, Y_1), \ldots, (x_n, Y_n)$ consists in

1) an exponential model for $Y \in \mathbb{R}$
2) a linear predictor $\eta_i = x_i^T \beta$, (with $\beta \in \mathbb{R}^p$)
3) a link function such that $g(\mathbb{E}(Y_i)) = x_i^T \beta$

Remark:

- This model allows to link Y with the linear predictor $\eta_i = x_i^T \beta$, assuming that $\mu_i = \mathbb{E}(Y_i) = g^{-1}(\eta_i) = g^{-1}(x_i^T \beta)$ for some link function g.
- The link between the linear predictor and the exponential model is through the expectation of Y and the link function g.
- There are many possible choices for the function g, but it must take all the values that $\mathbb{E}(Y)$ can handle. However, there is a particular choice for the link function g: the canonical link function.

The link function g is assumed to be monotonic and differentiable.

The link function

Definition

Let Y be a random variable with a density function $f_\theta(y) = \exp(\theta T(y) - A(\theta) + B(y))$, then the canonical link function is the function g such that $\theta = g(\mu)$, i.e., $\theta = g(E(Y))$.

Remark: When we choose the canonical link function, we have $\theta = g(\mu) = x^T\beta$, i.e., $\theta_i = g(\mu_i) = x_i^T\beta$.

Examples I

$Y_1, \ldots, Y_n$ n independent variables with distribution f_{θ_i} belonging to the exponential family, where θ_i is the parameter of the exponential family

1) Normal distribution $\mathcal{N}(\mu_i, \sigma^2)$:

$$f_{\mu_i}(y_i) = \exp\left\{-\frac{1}{2}\frac{\mu_i^2}{\sigma^2}\right\} \exp\left\{-\frac{1}{2}\frac{y_i^2}{\sigma^2} - \frac{1}{2}\ln(2\pi\sigma^2)\right\} \exp\left\{y_i \frac{\mu_i}{\sigma^2}\right\}$$

$$\theta_i = \mathbb{E}(Y_i) = \mu_i \quad \text{and} \quad g(x) = x$$

2) Bernoulli distribution $\mathcal{B}(\pi_i)$:

$$f_{\pi_i}(y_i) = \pi_i^{y_i}(1-\pi_i)^{1-y_i} = (1-\pi_i)\exp\left\{y_i \ln\frac{\pi_i}{1-\pi_i}\right\}$$

$$\theta_i = \ln\frac{\pi_i}{1-\pi_i} \quad \text{and} \quad g(x) = \ln\left(\frac{x}{1-x}\right)$$

This relationship defines the logit function for the canonical link function associated with this model: $logit(x) = \ln\left(\frac{x}{1-x}\right)$

Examples II

3) Poisson distribution $\mathscr{P}(\lambda_i)$:

$$f_{\lambda_i}(y_i) = \frac{\lambda_i^{y_i} e^{-\lambda_i}}{y_i!} = \exp(-\lambda_i)\frac{1}{y_i!}\exp(y_i \ln \lambda_i)$$

$$\theta_i = \ln \lambda_i \quad \text{and} \quad g(x) = \ln(x)$$

Moments

$\ell(\theta_i; y_i) = \ln\ f_{\theta_i}(y_i)$: the contribution of the ith observation to the log-likelihood

$$\ell(\theta_i, y_i) = \theta_i T(y_i) - A(\theta_i) + B(y_i)$$

We have

$$\frac{\partial \ell}{\partial \theta_i} = T(y_i) - A'(\theta_i) \quad \text{and} \quad \frac{\partial^2 \ell}{\partial \theta_i^2} = -A''(\theta_i)$$

Under regularity assumptions (differentiation under the integral),

$$\mathbb{E}\left(\frac{\partial \ell}{\partial \theta}\right) = 0 \quad \text{and} \quad -\mathbb{E}\left(\frac{\partial^2 \ell}{\partial \theta^2}\right) = \mathbb{E}\left[\left(\frac{\partial \ell}{\partial \theta}\right)^2\right].$$

Then,

$$\mathbb{E}[T(Y_i)] = A'(\theta_i) \quad \text{and} \quad \text{Var}[T(Y_i)] = A''(\theta_i)$$

Estimation

Recall that: $\eta_i = x_i^T \beta = g(\mu_i)$ where $\mu_i = \mathbb{E}(Y_i)$
The estimators of the β_j are calculated by maximizing the log-likelihood.
Log-likelihood:

$$\mathscr{L}(\beta) = \sum_{i=1}^{n} \ln f_{\theta_i}(y_i) = \sum_{i=1}^{n} \ell_i(\theta_i; y_i)$$

We have:

$$\frac{\partial \ell_i}{\partial \beta_j} = \frac{\partial \ell_i}{\partial \theta_i} \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \eta_i} \frac{\partial \eta_i}{\partial \beta_j}$$

Estimation

If $T(y) = y$, we have

$$\frac{\partial \ell_i}{\partial \theta_i} = y_i - A'(\theta_i) = y_i - \mu_i$$
$$\frac{\partial \mu_i}{\partial \theta_i} = A''(\theta_i) = \mathrm{Var}(Y_i)$$
$$\frac{\partial \eta_i}{\partial \beta_j} = x_{ij}$$
$$\frac{\partial \mu_i}{\partial \eta_i} \text{ depend on the link function } \eta_i = g(\mu_i)$$

Likelihood equations:

$$\sum_{i=1}^{n} \frac{(y_i - \mu_i) x_{ij}}{\mathrm{Var}(Y_i)} \frac{\partial \mu_i}{\partial \eta_i} = 0, \quad j = 1, \ldots, p$$

$\rightsquigarrow$ Non linear equations in β that need iterative methods to be solved

Particular case: the canonical link function

In that case : $\eta_i = \theta_i = x_i^T \beta$ and

$$\frac{\partial \mu_i}{\partial \eta_i} = \frac{\partial \mu_i}{\partial \theta_i} = \frac{\partial A'(\theta_i)}{\partial \theta_i} = A''(\theta_i)$$

Then,

$$\frac{\partial \ell_i}{\partial \beta_j} = \frac{y_i - \mu_i}{\mathrm{Var}(Y_i)} A''(\theta_i) x_{ij} = (y_i - \mu_i) x_{ij}$$

The equations become: $X^T y = X^T \mu$
In the gaussian case with $\mu = X\beta$ (the link function is the identity), we obtain the solution

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

which corresponds to the ordinary least squares estimator

Resolution of the likelihood equations

Iterated Reweighted Least Squares (IRLS)

To calculate (approximate) the Maximum Likelihood Estimator, we use a Newton-Raphson type algorithm.

At iteration k, we denote $\hat{\beta}^k$ the current solution. We approximate $\ell_n = \frac{1}{n}\ell$ by a quadratic function:

$$\ell_n(\hat{\beta}^k + h) = \ell_n(\hat{\beta}^k) + \nabla \ell_n(\hat{\beta}^k)^T h + \frac{1}{2} h^T \nabla^2 \ell_n(\hat{\beta}^k) h$$

we minimize this approximation to obtain h^*, we consider

$$\hat{\beta}^{k+1} = \hat{\beta}^k + h^*$$

and we iterate.

Theoretical results

We introduce $\mathscr{I}_n(\gamma) = -\mathbb{E}\left(\nabla^2 \ell_n(\gamma)\right) = n\mathscr{I}(\gamma)$ for all γ, where $\mathscr{I}(\gamma) = -\mathbb{E}[\nabla^2 \log f_\gamma(y_1)]$ (Fisher information of one observation).

Consistency and asymptotic normality

Under certain conditions (cf. Fahrmeir and Kaufman - 1985), we can prove that for every true parameter β,

- $\hat{\beta} \xrightarrow{\mathbb{P}} \beta$
- $\hat{\beta}$ is asymptotically gaussian

$$\sqrt{n}(\hat{\beta} - \beta) \xrightarrow{\mathscr{L}} \mathcal{N}(0, \mathscr{I}(\beta)^{-1})$$

This results are satisfied for the considered models (with canonical link function), when the covariates are bounded and if $\lambda_{\min}(X^T X) \to +\infty$.

Proof