TD1 : Méthodes pénalisées

Correction

Exercice 1 (Propriétés de l'estimateur Ridge)

Soit $Y = (Y_1, \dots, Y_n)^T$, $X = (x_{i,j})_{1 \leq i \leq n, 1 \leq j \leq p}$ non aléatoire vérifiant

$$Y = X\beta^* + \varepsilon,$$

avec $\varepsilon \sim \mathcal{N}(0, \sigma^2 I)$ et $\beta^* = (\beta_1^*, \dots, \beta_p^*)^T \in \mathbb{R}^p$. Nous considérons, pour $\lambda > 0$, l'estimateur Ridge

$$\hat{\beta}^R(\lambda) = (X^T X + \lambda I_p)^{-1} X^T Y.$$

1. Montrer que le problème de minimisation

$$\min_{\beta \in \mathbb{R}^p} \left\{ \sum_{i=1}^{n} (Y_i - X_i \beta)^2 + \lambda \|\beta\|^2 \right\} \tag{1}$$

admet $\hat{\beta}^R(\lambda)$ comme unique solution.

2. Montrer que toute solution du problème d'optimisation sous contrainte suivant

$$\min_{\beta \in \mathbb{R}^p, \|\beta\| \leq M_\lambda} \left\{ \sum_{i=1}^{n} (Y_i - X_i \beta)^2 \right\} \tag{2}$$

avec $M_\lambda = \|(X^T X + \lambda I_p)^{-1} X^T Y\|$ est aussi solution du problem (1). En déduire que $\hat{\beta}^R(\lambda)$ est aussi l'unique solution du problème (2).

3. Exprimer la norme au carré du biais de $\hat{\beta}^R(\lambda)$ en fonction des valeurs propres $\lambda_1, \dots, \lambda_p$ (comptées avec multiplicité) de $X^T X$:

$$B^R(\lambda) := \left\| \mathbb{E}\left[\hat{\beta}^R(\lambda)\right] - \beta^* \right\|^2.$$

4. Exprimer

$$V^R(\lambda) := \mathbb{E}\left[\left\| \hat{\beta}^R(\lambda) - \mathbb{E}\left[\hat{\beta}^R(\lambda)\right] \right\|^2 \right]$$

en fonction de la variance du bruit σ^2 et des valeurs propres $\lambda_1, \dots, \lambda_p$.

Solution.

1. La fonction $\beta \mapsto \lambda\|\beta\|^2$ est fortement convexe car pour tout $\beta_1, \beta_2 \in \mathbb{R}^p$, $t \in]0,1[$,

$$\begin{aligned}
\lambda\|t\beta_1 + (1-t)\beta_2\|^2 &= \lambda(t^2\|\beta_1\|^2 + 2t(1-t)\langle\beta_1, \beta_2\rangle + (1-t)^2\|\beta_2\|^2) \\
&= t^2\lambda\|\beta_1 l^2 + (1-t)^2\lambda\|\beta_2\|^2 + \lambda t(1-t)(-\|\beta_1 - \beta_2\|^2 + \|\beta_1\|^2 + \|\beta_2\|^2) \\
&= t\lambda\|\beta_1\|^2 + (1-t)\lambda\|\beta_2\|^2 - \lambda t(1-t)\|\beta_1 - \beta_2\|^2.
\end{aligned}$$

Comme la fonction à minimiser

$$f_\lambda^R(\beta) = \sum_{i=1}^n (Y_i - X_i\beta)^2 + \lambda\|\beta\|^2,$$

est strictement convexe (car somme d'une fonction convexe $f_0(\beta) = \sum_{i=1}^n (Y_i - X_i\beta)^2$ et d'une fonction fortement convexe $\beta \mapsto \lambda\|\beta\|^2$), coercive et de classe C^1, elle admet un unique minimum $\bar{\beta}$ sur $\mathbb{R}^p$ qui vérifie

$$\nabla f_\lambda^R(\bar{\beta}) = 0.$$

Nous avons

$$\nabla f_\lambda^R(\beta) = -2\sum_{i=1}^n X_i^T(Y_i - X_i\beta) + 2\lambda\beta = -2X^TY + 2X^TX\beta + 2\lambda\beta,$$

nous obtenons bien que $\bar{\beta}$ est l'unique solution du système linéaire

$$(X^TX + \lambda I_p)\bar{\beta} = X^TY,$$

i.e. $\bar{\beta} = \hat{\beta}^R(\lambda)$.

2. La fonction f_0 est continue sur le compact $\{\beta \in \mathbb{R}^p, \|\beta\| \leq M_\lambda\}$, le problème (2) admet donc au moins une solution. Soit $\tilde{\beta}$ une telle solution. Nous savons par définition que :

$$\|\tilde{\beta}\| \leq M_\lambda \quad \text{et } f_0(\tilde{\beta}) \leq f_0(\beta),$$

pour tout $\beta \in \mathbb{R}^p$ tel que $\|\beta\| \leq M_\lambda$. Comme

$$\|\hat{\beta}^R(\lambda)\| = \|(X^TX + \lambda I_p)^{-1}X^TY\| = M_\lambda,$$

$\hat{\beta}^R(\lambda)$ vérifie la contrainte, ce qui signifie que

$$f_0(\tilde{\beta}) \leq f_0(\hat{\beta}^R(\lambda))$$

et donc que

$$f_\lambda^R(\tilde{\beta}) = f_0(\tilde{\beta}) + \lambda\|\tilde{\beta}\|^2 \leq f_0(\hat{\beta}^R(\lambda)) + \lambda\|\tilde{\beta}\|^2.$$

Comme $\|\tilde{\beta}\| \leq M_\lambda$, nous avons donc

$$f_\lambda^R(\tilde{\beta}) \leq f_0(\hat{\beta}^R(\lambda)) + \lambda M_\lambda^2 = f_0(\hat{\beta}^R(\lambda)) + \lambda\|\hat{\beta}^R(\lambda)\|^2 = f_\lambda^R(\hat{\beta}^R(\lambda)) \leq f_\lambda^R(\beta),$$

pour tout $\beta \in \mathbb{R}^p$ car $\hat{\beta}^R(\lambda)$ minimise f_λ^R sur $\mathbb{R}^p$. Donc, $\tilde{\beta}$ est aussi solution de (1) et, par unicité, $\tilde{\beta} = \hat{\beta}^R(\lambda)$.

3. Calcul du biais :

$$\begin{aligned}\mathbb{E}[\hat{\beta}^R(\lambda)] &= \mathbb{E}[(X^TX + \lambda I_p)^{-1}X^TY] = (X^TX + \lambda I_p)^{-1}X^T\mathbb{E}[Y] = (X^TX + \lambda I_p)^{-1}X^TX\beta^* \\ &= (X^TX + \lambda I_p)^{-1}(X^TX + \lambda I_p - \lambda I_p)\beta^* \\ &= \beta^* - \lambda(X^TX + \lambda I_p)^{-1}\beta^*.\end{aligned}$$

Donc

$$B^R(\lambda) = \left\|\lambda(X^TX + \lambda I_p)^{-1}\beta^*\right\|^2.$$

Soit P la matrice orthogonale telle que $X^TX = PDP^T$ avec D la matrice diagonale de coefficients $(\lambda_1, \ldots, \lambda_p)$, nous avons

$$\begin{aligned}(X^TX + \lambda I_p)^{-1}\beta^* &= (PDP^T + \lambda I_p)^{-1}\beta^* = (PDP^T + \lambda PP^T)^{-1}\beta^* = (P(D + \lambda I_p)P^T)^{-1}\beta^* \\ &= P(D + \lambda I_p)^{-1}P^T\beta^*.\end{aligned}$$

D'où, comme P est orthogonale,

$$B^R(\lambda) = \lambda^2\|P(D + \lambda I_p)^{-1}P^T\beta^*\|^2 = \lambda^2\|(D + \lambda I_p)^{-1}P^T\beta^*\|^2 = \sum_{j=1}^p \frac{\lambda^2}{(\lambda_j + \lambda)^2}[P^T\beta^*]_j^2.$$

4. Calcul de la variance : étant donné que Y est un vecteur gaussien de moyenne $X\beta^*$ et de matrice de covariance $\sigma^2 I_n$, $\hat{\beta}^R(\lambda) = (X^TX + \lambda I_p)^{-1}X^TY$ est aussi un vecteur gaussien de moyenne $\mathbb{E}[\hat{\beta}^R(\lambda)]$ (calculée à la question précédente) et de matrice de covariance

$$\Sigma_\lambda^R = (X^TX+\lambda I_p)^{-1}X^T\sigma^2 I_n \left((X^TX + \lambda I_p)^{-1}X^T\right)^T = \sigma^2(X^TX+\lambda I_p)^{-1}X^TX(X^TX+\lambda I_p)^{-1}.$$

On obtient donc

$$V^R(\lambda) = \sum_{j=1}^p \mathbb{E}\left[\left([\hat{\beta}^R(\lambda)]_j - \mathbb{E}\left[[\hat{\beta}^R(\lambda)]_j\right]\right)^2\right] = \sum_{j=1}^p \mathrm{Var}([\hat{\beta}^R(\lambda)]_j) = \sum_{j=1}^p \left[\Sigma_\lambda^R\right]_{j,j} = \mathrm{Tr}(\Sigma_\lambda^R)$$
$$= \sigma^2 \sum_{j=1}^p \frac{\lambda_j}{(\lambda+\lambda_j)^2}.$$

Rappel : Soit $X \in \mathbb{R}^p$ un vecteur aléatoire centrée (pour simplifier mais le résultat est vrai dans le cas non centré). Alors on a

$$\mathbb{E}[\|X\|^2] = \mathbb{E}[X^TX] = \mathbb{E}[\mathrm{Tr}(X^TX)] = \mathbb{E}[\mathrm{Tr}(XX^T)] = \mathrm{Tr}(\mathbb{E}(XX^T)) = \mathrm{Tr}(\mathrm{Var}(X)) \in \mathbb{R}.$$

Exercice 2 (Propriétés de l'estimateur Lasso)

Soit $Y = (Y_1, \dots, Y_n)^T$, $X = (x_{i,j})_{1\le i\le n, 1\le j\le p}$ non aléatoire vérifiant

$$Y = X\beta^* + \varepsilon,$$

avec $\varepsilon \sim \mathcal{N}(0, \sigma^2 I)$ et $\beta^* = (\beta_1^*, \dots, \beta_p^*)^T \in \mathbb{R}^p$.

L'objectif est de montrer que les problèmes d'optimisation

$$\min_{\beta\in\mathbb{R}^p} \left\{\sum_{i=1}^n (Y_i - X_i\beta)^2 + \lambda\|\beta\|_1\right\} \tag{3}$$

et

$$\min_{\beta\in\mathbb{R}^p, \|\beta\|_1\le M_\lambda} \left\{\sum_{i=1}^n (Y_i - X_i\beta)^2\right\}, \tag{4}$$

sont équivalents lorsque M_λ est bien choisi dans le sens où l'ensemble des solutions des deux problèmes est identique (on rappelle que, sans hypothèse supplémentaire sur la matrice X, l'unicité de la solution du Lasso n'est pas garantie).

1. Montrer que, pour toutes solutions $\hat{\beta}_\lambda^{(L,1)}$ et $\hat{\beta}_\lambda^{(L,2)}$ du problème pénalisé (3),

$$\left\|\hat{\beta}_\lambda^{(L,1)}\right\|_1 = \left\|\hat{\beta}_\lambda^{(L,2)}\right\|_1.$$

Nous noterons par la suite cette valeur commune N_λ.

2. Montrer que toute solution de (3) est aussi solution de (4) lorsque $M_\lambda = N_\lambda$.
3. Montrer que toute solution de (4) est aussi solution de (3) lorsque $M_\lambda = N_\lambda$.

Solution.

1. Notons

$$f_\lambda^L(\beta) := \sum_{i=1}^n (Y_i - X_i\beta)^2 + \lambda\|\beta\|_1 = f_0(\beta) + \lambda\|\beta\|_1,$$

la fonction à minimiser dans le problème (3). Comme $\beta_\lambda^{(L,1)}$ et $\beta_\lambda^{(L,2)}$ minimisent f_λ^L, on a :

$$f_\lambda^L(\hat{\beta}_\lambda^{(L,1)}) = f_\lambda^L(\hat{\beta}_\lambda^{(L,2)}).$$

Montrons que pour tout $i = 1, \dots, n$, $X_i\hat{\beta}_\lambda^{(L,1)} = X_i\hat{\beta}_\lambda^{(L,2)}$, ce qui implique que $f_0(\hat{\beta}_\lambda^{(L,1)}) = f_0(\hat{\beta}_\lambda^{(L,2)})$. Supposons par l'absurde qu'il existe j tel que $X_j\hat{\beta}_\lambda^{(L,1)} \neq X_j\hat{\beta}_\lambda^{(L,2)}$ et notons

$$\tilde{\beta} = \frac{1}{2}\hat{\beta}_\lambda^{(L,1)} + \frac{1}{2}\hat{\beta}_\lambda^{(L,2)}.$$

Par stricte convexité de la fonction $x \mapsto x^2$, on a

$$(Y_j - X_j\tilde{\beta})^2 = \left(\frac{1}{2}\left(Y_j - X_j\hat{\beta}_\lambda^{(L,1)}\right) + \frac{1}{2}\left(Y_j - X_j\hat{\beta}_\lambda^{(L,2)}\right)\right)^2 < \frac{1}{2}\left(Y_j - X_j\hat{\beta}_\lambda^{(L,1)}\right)^2 + \frac{1}{2}\left(Y_j - X_j\hat{\beta}_\lambda^{(L,2)}\right)^2,$$

et pour $i \neq j$,

$$(Y_i - X_i\tilde{\beta})^2 \leq \frac{1}{2}\left(Y_i - X_i\hat{\beta}_\lambda^{(L,1)}\right)^2 + \frac{1}{2}\left(Y_i - X_i\hat{\beta}_\lambda^{(L,2)}\right)^2$$

ce qui implique que

$$f_0(\tilde{\beta}) < \frac{1}{2}f_0(\hat{\beta}_\lambda^{(L,1)}) + \frac{1}{2}f_0(\hat{\beta}_\lambda^{(L,2)}).$$

D'un autre côté, l'inégalité triangulaire nous donne

$$\|\tilde{\beta}\|_1 \leq \frac{1}{2}\|\hat{\beta}_\lambda^{(L,1)}\|_1 + \frac{1}{2}\|\hat{\beta}_\lambda^{(L,2)}\|_1.$$

D'où

$$f_\lambda^L(\tilde{\beta}) < \frac{1}{2}f_\lambda^L(\hat{\beta}_\lambda^{(L,1)}) + \frac{1}{2}f_\lambda^L(\hat{\beta}_\lambda^{(L,2)}) \leq f_\lambda^L(\tilde{\beta}),$$

la dernière inégalité provenant du fait que, comme $\hat{\beta}_\lambda^{(L,1)}$ et $\hat{\beta}_\lambda^{(L,2)}$ minimisent f_λ^L, alors $f_\lambda^L(\hat{\beta}_\lambda^{(L,1)}) = f_\lambda^L(\hat{\beta}_\lambda^{(L,2)}) \leq f_\lambda^L(\tilde{\beta})$. On aboutit donc à une absurdité.
Puisque $f_\lambda^L(\hat{\beta}_\lambda^{(L,1)}) = f_\lambda^L(\hat{\beta}_\lambda^{(L,2)})$ et $f_0(\hat{\beta}_\lambda^{(L,1)}) = f_0(\hat{\beta}_\lambda^{(L,2)})$, alors nécessairement

$$\left\|\hat{\beta}_\lambda^{(L,1)}\right\|_1 = \left\|\hat{\beta}_\lambda^{(L,2)}\right\|_1.$$

2. Soit $\hat{\beta}_\lambda^L$ une solution du problème (3). Si $M_\lambda = N_\lambda$, $\hat{\beta}_\lambda^L$ vérifie la contrainte $\|\hat{\beta}_\lambda^L\|_1 \leq M_\lambda$. D'autre part, soit $\beta \in \mathbb{R}^p$ quelconque vérifiant aussi la contrainte $\|\beta\|_1 \leq M_\lambda$, alors, comme $\hat{\beta}_\lambda^L$ minimise f_λ^L,

$$f_\lambda^L(\hat{\beta}_\lambda^L) \leq f_\lambda^L(\beta).$$

D'où

$$f_0(\hat{\beta}_\lambda^L) + \lambda\|\hat{\beta}_\lambda^L\|_1 \leq f_0(\beta) + \lambda\|\beta\|_1,$$

ce qui implique

$$f_0(\hat{\beta}_\lambda^L) \leq f_0(\beta) + \lambda(\|\beta\|_1 - \|\hat{\beta}_\lambda^L\|_1) = f_0(\beta) + \lambda(\|\beta\|_1 - N_\lambda) \leq f_0(\beta),$$

car $\|\beta\|_1 \leq M_\lambda = N_\lambda$. Cela implique bien que $\hat{\beta}_\lambda^L$ est également solution du problème (4).

3. Soit $\tilde{\beta}_{M_\lambda}$ une solution du problème (4) et $\hat{\beta}_\lambda^L$ une solution du problème (3). Nous allons montrer que

$$f_\lambda^L(\tilde{\beta}_{M_\lambda}) \leq f_\lambda^L(\hat{\beta}_\lambda^L),$$

ce qui implique bien que $\tilde{\beta}_\lambda$ est aussi solution du problème (3). Notons que, par définition, $M_\lambda = \|\hat{\beta}_\lambda^L\|_1$, donc $\hat{\beta}_\lambda^L$ vérifie bien la contrainte $\|\hat{\beta}_\lambda^L\|_1 \leq M_\lambda$ ce qui implique que

$$f_0(\tilde{\beta}_{M_\lambda}) \leq f_0(\hat{\beta}_\lambda^L).$$

D'où

$$f_\lambda^L(\tilde{\beta}_{M_\lambda}) = f_0(\tilde{\beta}_{M_\lambda}) + \|\tilde{\beta}_{M_\lambda}\|_1 \leq f_0(\hat{\beta}_\lambda^L) + M_\lambda = f_\lambda^L(\hat{\beta}_\lambda^L).$$

Exercice 3 (Un problème de sélection de modèle)

Soit $Y = (Y_1, \dots, Y_n)^T$ et $X = [X_1, \dots, X_p] \in \mathbb{R}^{n\times p}$. Considérons le modèle de régression linéaire suivant :

$$Y = f^* + \varepsilon,$$

avec $f^* = X\beta^* \in \mathbb{R}^n$ et $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$.. Soit $m^* = \{j \in \{1, \dots, p\} : \beta_j^* \neq 0\}$ l'ensemble des coordonnées non nulles du vecteur β^*. Cet ensemble appelé *modèle* est inconnu. On définit $\hat{f}_m = X\hat{\beta} = P_{S_m} Y$ où $P_{S_m} : \mathbb{R}^n \to \mathbb{R}^n$ est la matrice de projection orthogonale sur $S_m = \text{Vect}\{X_j, j \in m\}$ et $m \subset \{1, \dots, p\}$.

Soit $\mathcal{M}$ une collection de modèles, on veut sélectionner $\hat{m} \in \mathcal{M}$ tel que le risque de $\hat{f}_{\hat{m}}$ soit le plus petit possible.

On note m_0 l'oracle, $m_0 = \arg\min_{m\in\mathcal{M}} \mathbb{E}\left[\|\hat{f}_m - f^*\|^2\right]$ et $\hat{f}_{m_0}$ l'estimateur oracle. On cherche $\hat{m} \in \mathcal{M}$ tel que $\mathbb{E}\left[\|\hat{f}_{\hat{m}} - f^*\|^2\right] \leq C\mathbb{E}\left[\|\hat{f}_{m_0} - f^*\|^2\right]$, avec $C > 0$.

Remarques :

1. m^* n'appartient pas forcément à $\mathcal{M}$.
2. Même si $m^* \in \mathcal{M}$, m^* peut être différent de m_0.
3. L'oracle n'est pas aléatoire mais dépend de β^* donc $\hat{f}_{m_0}$ n'est pas utilisable en pratique.

On définit le risque de $\hat{f}_m$ par $R(\hat{f}_m) := \mathbb{E}\left[\|\hat{f}_m - f^*\|^2\right]$ et $d_m = \dim(S_m)$.

Questions :

1. Montrer que $R(\hat{f}_m) = \|(I_n - P_{S_m})f^*\|^2 + \sigma^2 d_m$ et interpréter ce résultat.
2. On considère le critère de sélection de modèle suivant :

$$C(m) = \|Y - \hat{f}_m\|^2 + \sigma^2 \,\text{pen}(m)$$

où $\text{pen}(m) := K(\sqrt{d_m} + \sqrt{2\log(1/\Pi_m)})^2$ pour $K > 1$ et $\Pi_m \in]0, 1]$ tel que $\sum_{m\in\mathcal{M}} \Pi_m = 1$ et $\hat{m} := \arg\min_{m\in\mathcal{M}} C(m)$.

   (a) Soit $m \in \mathcal{M}$ fixé. Montrer que

$$R(\hat{f}_{\hat{m}}) \leq R(\hat{f}_m) + 2\mathbb{E}\left[\langle \varepsilon, f^* - \hat{f}_m\rangle\right] + \sigma^2 \,\text{pen}(m) + \mathbb{E}\left[2\langle \varepsilon, \hat{f}_{\hat{m}} - f^*\rangle - \sigma^2 \,\text{pen}(\hat{m})\right]. \quad (5)$$

   (b) Montrer que $\mathbb{E}\left[\langle \varepsilon, f^* - \hat{f}_m\rangle\right] = -\sigma^2 d_m$.

   (c) Soit $a > 1$, on introduit $\bar{S}_{\hat{m}} = \text{Vect}(S_{\hat{m}}, f^*)$. Montrer que

$$2\langle \varepsilon, \hat{f}_{\hat{m}} - f^*\rangle \leq a\sigma^2(N^2 + U_{\hat{m}}) + a^{-1}\|\hat{f}_{\hat{m}} - f^*\|^2,$$

   avec

$$N^2 = \frac{\|P_{\text{Vect}(f^*)}\varepsilon\|^2}{\sigma^2} \sim \chi^2(1) \quad \text{et} \quad U_m = \frac{\|P_{\tilde{S}_m}\varepsilon\|^2}{\sigma^2}$$

   où $\tilde{S}_m \oplus \text{Vect}(f^*) = \bar{S}_m$.

   (d) On pose $a = \dfrac{K+1}{2} > 1$. En déduire qu'il existe une variable aléatoire Z telle que

$$2\langle \varepsilon, \hat{f}_{\hat{m}} - f^*\rangle - \sigma^2 \,\text{pen}(\hat{m}) \leq a^{-1}\|\hat{f}_{\hat{m}} - f^*\|^2 + Z$$

   avec $\mathbb{E}(Z) \leq C_K\sigma^2$ et $C_K \geq 0$ une constante qui dépend de K.

   On pourra utiliser le lemme suivant :

   Lemme : *On suppose que $F : \mathbb{R}^d \to \mathbb{R}$ est $1-$Lipschitzienne et $Z \sim \mathcal{N}(0, \sigma^2 I_d)$. Alors il existe $\xi \sim \mathcal{E}(1)$ tel que $F(Z) \leq \mathbb{E}[F(Z)] + \sigma\sqrt{2\xi}$.*

   (e) Montrer que $\sigma^2 \,\text{pen}(m) \leq 2KR(\hat{f}_m) + 4K\sigma^2 \log(\Pi^{-1})$.

   (f) En déduire qu'il existe $C_K > 0$ qui ne dépend que de K tel que

$$\mathbb{E}\left[\|\hat{f}_{\hat{m}} - f^*\|^2\right] \leq C_K \min_{m\in\mathcal{M}} \left\{\mathbb{E}\left[\|\hat{f}_m - f^*\|\right] + \sigma^2 \log(\Pi_m^{-1}) + \sigma^2\right\}.$$

   (g) Que peut-on dire lorsque $\log(\Pi_m^{-1}) \leq Cd_m$, où $C > 0$ est une constante.

Solution.

1. On a la décomposition suivante :

$$\begin{aligned} R(\hat{f}_m) &= \mathbb{E}\left[\|\hat{f}_m - \mathbb{E}(\hat{f}_m) + \mathbb{E}(\hat{f}_m) - f^*\|^2\right] \\ &= \mathbb{E}\left[\|\hat{f}_m - \mathbb{E}(\hat{f}_m)\|^2\right] + \underbrace{\|\mathbb{E}(\hat{f}_m) - f^*\|^2}_{\text{déterministe}}. \end{aligned}$$

On a d'une part $\mathbb{E}(\hat{f}_m) = \mathbb{E}(P_{S_m}Y) = P_{S_m}f^*$ donc $\|\mathbb{E}(\hat{f}_m) - f^*\|^2 = \|(I_n - P_{S_m})f^*\|^2$, qui correspond au terme de biais au carré. D'autre part, on a

$$\mathbb{E}\left[\|\hat{f}_m - \mathbb{E}(\hat{f}_m)\|^2\right] = \|\mathrm{Var}(\hat{f}_m)\|^2 = \|P_{S_m}\mathrm{Var}(Y)P_{S_m}^T\|^2 = \sigma^2\mathrm{Tr}(P_{S_m}) = \sigma^2 d_m,$$

qui correspond à un terme de variance. Cette décomposition correspond à la décomposition biais-variance. L'oracle $m_0 := \underset{m\in\mathcal{M}}{\arg\min}\, R(\hat{f}_m)$ réalise le meilleur compromis biais-variance.

2. (a) On a $C(\hat{m}) \leq C(m)$ pour tout $m \in \mathcal{M}$, il suffit donc de remplacer Y par $f^* + \varepsilon$ et de développer la norme 2, puis de passer à l'espérance pour obtenir le résultat demandé.

   (b) On a

$$\begin{aligned} \mathbb{E}\left[\langle \varepsilon, f^* - \hat{f}_m\rangle\right] &= \mathbb{E}\left[\langle \varepsilon, f^* - P_{S_m}Y\rangle\right] = -\mathbb{E}\left[\langle \varepsilon, P_{S_m}(f^* + \varepsilon)\rangle\right] = -\mathbb{E}\left[\langle \varepsilon, P_{S_m}\varepsilon\rangle\right] \\ &= -\mathbb{E}\left[\|P_{S_m}\varepsilon\|^2\right] = -\mathbb{E}\left[\mathrm{Tr}(\varepsilon P_{S_m}\varepsilon)\right] = -\mathrm{Tr}(P_{S_m})\mathbb{E}[\varepsilon\varepsilon^T] = -\sigma^2 d_m \leq 0. \end{aligned}$$

   (c) On peut écrire

$$\begin{aligned} 2\langle \varepsilon, \hat{f}_{\hat{m}} - f^*\rangle &= 2\langle P_{\bar{S}_{\hat{m}}}\varepsilon, \hat{f}_{\hat{m}} - f^*\rangle \quad \text{car } \bar{S}_{\hat{m}} = \mathrm{Vect}(S_{\hat{m}}, f^*), \\ &\leq a\|P_{\bar{S}_{\hat{m}}}\varepsilon\|^2 + a^{-1}\|\hat{f}_{\hat{m}} - f^*\|^2 \\ &\leq a\sigma^2(N^2 + U_{\hat{m}}) + a^{-1}\|\hat{f}_{\hat{m}} - f^*\|^2, \end{aligned}$$

   avec la décomposition suivante sur $\bar{S}_m = \tilde{S}_m \oplus \mathrm{Vect}(f^*)$

$$N^2 = \frac{\|P_{\mathrm{Vect}(f^*)}\varepsilon\|^2}{\sigma^2} \sim \chi^2(1) \quad \text{et } U_m = \frac{\|P_{\tilde{S}_m}\varepsilon\|^2}{\sigma^2}.$$

   Remarque : On a

$$\begin{cases} U_m \sim \chi^2(d_m) & \text{si } f^* \notin S_m \\ U_m \sim \chi^2(d_m - 1) & \text{si } f^* \in S_m. \end{cases}$$

   Mais $\hat{m}$ dépend des données, donc $U_{\hat{m}}$ ne suit pas une loi du χ^2.

   (d) On va prendre $Z = a\sigma^2(N^2 + U_{\hat{m}}) - \sigma^2\,\mathrm{pen}(\hat{m})$. Pour prouver le résultat, il faut donc montrer que $\mathbb{E}[aU_{\hat{m}} - \mathrm{pen}(\hat{m})]$ est borné. On a

$$\begin{aligned} \mathbb{E}[aU_{\hat{m}} - \mathrm{pen}(\hat{m})] &\leq \frac{K+1}{2}\mathbb{E}\left[\max_{m\in\mathcal{M}}\left(U_m - \frac{2}{K+1}\,\mathrm{pen}(m)\right)\right] \\ &\leq \frac{K+1}{2}\sum_{m\in\mathcal{M}}\mathbb{E}\left[\left(U_m - \frac{2}{K+1}\,\mathrm{pen}(m)\right)_+\right] \\ &\leq \frac{K+1}{2}\sum_{m\in\mathcal{M}}\mathbb{E}\left[\left(U_m - \frac{2K}{K+1}\left(\sqrt{d_m} + \sqrt{2\log\Pi_m^{-1}}\right)^2\right)_+\right], \end{aligned}$$

   où $x_+ = \max(0, x)$.

   On va appliquer le résultat du lemme donné comme indication dans la question. On a que $\varepsilon \mapsto \|P_{\tilde{S}_m}\varepsilon\|$ est $1-$Lipschitzienne, il existe donc d'après le lemme $\xi_m \sim \mathcal{E}(1)$ telle que $\|P_{\tilde{S}_m}\varepsilon\| \leq \mathbb{E}[\|P_{\tilde{S}_m}\varepsilon\|] + \sigma\sqrt{2\xi_m}$. On a donc

$$\begin{aligned} U_m = \frac{\|P_{\tilde{S}_m}\varepsilon\|^2}{\sigma^2} &\leq \left(\mathbb{E}\left[\|P_{\tilde{S}_m}\sigma^{-1}\varepsilon\|\right] + \sqrt{2\xi_m}\right)^2 \\ &\leq \left(\left(\mathbb{E}\left[\|P_{\tilde{S}_m}\sigma^{-1}\varepsilon\|^2\right]\right)^{1/2} + \sqrt{2\xi_m}\right)^2. \end{aligned}$$

Comme $\frac{\|P_{\tilde{S}_m}\varepsilon\|^2}{\sigma^2} \sim \chi^2(d_m)$ ou $\frac{\|P_{\tilde{S}_m}\varepsilon\|^2}{\sigma^2} \sim \chi^2(d_m - 1)$,

$$\begin{aligned} U_m &\leq \left(\sqrt{d_m} + \sqrt{2\xi_m}\right)^2 \\ &\leq \left(\sqrt{d_m} + \sqrt{2\log\Pi_m^{-1}} + \sqrt{2(\xi_m - \log\Pi_m^{-1})_+}\right)^2 \\ &\leq (1+\alpha)(\sqrt{d_m} + \sqrt{2\log\Pi_m^{-1}})^2 + 2(1+\alpha^{-1})(\xi_m - \log\Pi_m^{-1})_+ \end{aligned}$$

avec $\alpha = \frac{K-1}{K+1}$, donc $1+\alpha = \frac{2K}{K+1}$ et $2(1+\alpha^{-1}) = \frac{4K}{K-1}$. On en déduit

$$\mathbb{E}\left[\left(U_m - \frac{2K}{K+1}\left(\sqrt{d_m} + \sqrt{2\log\Pi_m^{-1}}\right)^2\right)_+\right] \leq \frac{4K}{K-1}\mathbb{E}\left[\left(\xi_m - \log\Pi_m^{-1}\right)_+\right] = \frac{4K}{K-1}\Pi_m$$

et

$$\mathbb{E}[aU_m - \mathrm{pen}(\hat{m})] \leq \frac{K+1}{2}\sum_{m\in\mathcal{M}}\frac{4K}{K-1}\Pi_m = \frac{2K(K+1)}{K-1}.$$

Donc

$$\mathbb{E}\left[2\langle\varepsilon, \hat{f}_{\hat{m}} - f^*\rangle - \sigma^2\,\mathrm{pen}(\hat{m})\right] \leq C_K\sigma^2 + a^{-1}R(\hat{f}_{\hat{m}}).$$

(e) Enfin, par définition de $\mathrm{pen}(m)$, on en déduit

$$\begin{aligned} \sigma^2\,\mathrm{pen}(m) &\leq 2K\sigma^2 d_m + 4K\sigma^2\log\Pi_m^{-1} \\ &\leq 2KR(\hat{f}_m) + 4K\sigma^2\log\Pi_m^{-1} \end{aligned}$$

car $R(\hat{f}_m) = \sigma^2 d_m +$ quelque chose de positif.

(f) En mettant bout à bout tous les résultats obtenus dans les questions précédentes, on en déduit le résultat demandé.

(g) Lorsque $\log\Pi_m^{-1} \leq Cd_m$, $\hat{f}_{\hat{m}}$ atteint la même vitesse de convergence que l'oracle (à une constante prêt).