Lemme : Soient $p \geq 2$, $n \geq 1$

Soient $\varepsilon_1, \dots, \varepsilon_n$ des v.a.r i.id $\mathcal{N}(0, \sigma^2)$, $\sigma^2 > 0$

$$\hat{\beta}_L = \underset{\beta \in \mathbb{R}^p}{\operatorname{argmin}} \left\{ \frac{1}{n} \|Y - X\beta\|_2^2 + 2\tau \|\beta\|_1 \right\}, \quad \tau > 0$$

On prend $\tau = A\sigma\sqrt{\frac{\log p}{n}}$ et $A > 2\sqrt{2}$. $\operatorname{diag}(X^T X/n)_j = 1 \ \forall j \in \{1, \dots, p\}$

Alors avec probabilité supérieure à $1 - 2p^{1 - A^2/8}$, on a pour tout $\beta \in \mathbb{R}^p$

$$\|X\hat{\beta}^L - X\beta^*\|_n^2 + \tau \sum_{j=1}^{p} |\hat{\beta}_j^L - \beta_j| \leq \|X\beta - X\beta^*\|_n^2 + 4\tau \sum_{j \in J(\beta)} |\hat{\beta}_j^L - \beta_j| \quad (1)$$

$$\leq \|X\beta - X\beta^*\|_n^2 + 4\tau\sqrt{s(\beta)}\sqrt{\sum_{j \in J(\beta)} |\hat{\beta}_j^L - \beta_j|^2}$$

$$(2) \quad \left\| \frac{1}{n} X^T (X\beta^* - X\hat{\beta}_L) \right\|_\infty \leq \frac{3\tau}{2}$$

$$(3) \quad s(\hat{\beta}^L) \leq 4 \frac{\phi_{max}}{\tau^2} \|X\hat{\beta}^L - X\beta^*\|_n^2 \text{ où } \phi_{max} \text{ est la valeur propre maximale de } \frac{X^T X}{n}$$

Preuve : * Posons $\hat{S}(\beta) = \frac{1}{n} \|Y - X\beta\|_2^2$.

Par définition, $\hat{S}(\hat{\beta}^L) + 2\tau \|\hat{\beta}^L\|_1 \leq S(\beta) + 2\tau \|\beta\|_1, \ \forall \beta \in \mathbb{R}^p$

$$\iff \frac{1}{n} \|Y - X\hat{\beta}^L\|_2^2 + 2\tau \sum_{j=1}^{p} |\hat{\beta}_j^L| \leq \frac{1}{n} \|Y - X\beta\|_2^2 + 2\tau \sum_{j=1}^{p} |\beta_j|$$

$$\iff \|X\beta^* + \varepsilon - X\hat{\beta}^L\|_n^2 + 2\tau \sum_{j=1}^{p} |\hat{\beta}_j^L| \leq \|X\beta^* + \varepsilon - X\beta\|_n^2 + 2\tau \sum_{j=1}^{p} |\beta_j|$$

$$\iff \|X\beta^* - X\hat{\beta}^L\|_n^2 + \frac{2}{n} \langle \varepsilon, X\beta^* - X\hat{\beta}^L \rangle + 2\tau \sum_{j=1}^{p} |\hat{\beta}_j^L|$$

$$\leq \|X\beta^* - X\beta\|_n^2 + \frac{2}{n} \langle \varepsilon, X\beta^* - X\hat{\beta}^L \rangle + 2\tau \sum_{j=1}^{p} |\beta_j|$$

$$\iff \|X\beta^* - X\hat{\beta}^L\|_n^2 + 2\tau \sum_{j=1}^{p} |\hat{\beta}_j^L| \leq \|X\beta^* - X\beta\|_n^2 + \underbrace{\frac{2}{n} \sum_{i=1}^{n} \varepsilon_i x_i (\hat{\beta}^L - \beta)}_{= \frac{2}{n} \sum_{i=1}^{n} \varepsilon_i \sum_{j=1}^{p} (\hat{\beta}_j^L - \beta_j) x_{ij} = \sum_{j=1}^{p} (\hat{\beta}_j^L - \beta_j) \underbrace{\frac{2}{n} \sum_{i=1}^{n} \varepsilon_i x_{ij}}_{= 2V_j}} + 2\tau \sum_{j=1}^{p} |\beta_j|$$

On introduit donc $V_j = \frac{1}{n} \sum_{i=1}^{n} \varepsilon_i x_{ij}$, $1 \leq j \leq p$

et l'événement $A = \bigcap_{j=1}^{p} \{ 2|V_j| \leq \tau \}$

$V_j \sim \mathcal{N}(0, \sigma^2/n)$ (cf. dos de la feuille)

$$\mathbb{P}(A^c) = \mathbb{P}\left(\bigcup_{j=1}^{p} \{ 2|V_j| > \tau \} \right) \leq \sum_{j=1}^{p} \mathbb{P}(2|V_j| > \tau) \leq \sum_{j=1}^{p} \mathbb{P}\left(\frac{\sqrt{n}|V_j|}{\sigma} > \frac{\sqrt{n}\tau}{2\sigma} \right) \leq \sum_{j=1}^{p} \mathbb{P}(|Z| > \frac{\sqrt{n}\tau}{2\sigma})$$

où $\varepsilon \sim \mathcal{N}(0,1)$.

$\left(V_j = \frac{1}{n}\sum_{i=1}^n \varepsilon_i x_{ij} \sim \mathcal{N}\left(0, \frac{\sigma^2}{n^2}\sum_{i=1}^n x_{ij}^2\right) = \mathcal{N}\left(0, \frac{\sigma^2}{n}\right)$ car $\operatorname{diag}(X^TX) = n$

$\Rightarrow \frac{1}{n}\sum_{i=1}^n x_{ij}^2 = 1 \quad \forall j \in \{1,\dots,p\}$ $\right)$

Lemme : Si $Z \sim \mathcal{N}(0,1)$, alors $\mathbb{P}(|Z| \geq z) \leq 2e^{-z^2/2} \quad \forall z > 0$

Preuve : $\mathbb{P}(|Z| \geq z) = 2\mathbb{P}(Z \geq z)$

Soit $\lambda \geq 0$, $\mathbb{P}(e^{\lambda Z} \geq e^{\lambda z}) \underset{\text{inégalité de Markov}}{\leq} e^{-\lambda z}\mathbb{E}[e^{\lambda Z}] = e^{-\lambda z}e^{\lambda^2/2}$

Cette inégalité est vraie pour tout $\lambda \geq 0$

On choisit celui qui minimise la quantité ci-dessus

$\mathbb{P}(Z \geq z) \leq \exp\left(-\sup_{\lambda \geq 0}\{\lambda z - \lambda^2/2\}\right)$

Posons $f(\lambda) = \exp\left(-\lambda z + \frac{\lambda^2}{2}\right)$. $f(\lambda) = \lambda z - \frac{\lambda^2}{2}$, $f'(\lambda) = z - \lambda$

$f'(\lambda) = 0 \Rightarrow \lambda = z$

$f'(\lambda) = (-z+\lambda)\exp\left(-\lambda z + \frac{\lambda^2}{2}\right) = 0 \iff \lambda = z$

λ	0		z		$+\infty$
$f'(\lambda)$		$+$	0	$-$	
f		↗		↘	

$\Rightarrow \mathbb{P}(Z \geq z) \leq \exp(-z^2)\exp\left(\frac{z^2}{2}\right) = \exp\left(-\frac{z^2}{2}\right)$

On en déduit

$$\mathbb{P}(2|V_j| > \pi) = \mathbb{P}\left(|V_j| > \frac{\pi}{2}\right) = \mathbb{P}\left(\frac{\sqrt{n}|V_j|}{\sigma} > \frac{\pi\sqrt{n}}{2\sigma}\right) = \mathbb{P}\left(|Z| > \frac{\pi\sqrt{n}}{2\sigma}\right)$$

$$= 2\mathbb{P}\left(Z > \frac{\pi\sqrt{n}}{2\sigma}\right) \leq 2\exp\left(-\frac{\pi^2 n}{8\sigma^2}\right) = 2\exp\left(-\frac{A^2}{8}\log p\right) = 2p^{-A^2/8}$$

$$\mathbb{P}(A^c) \leq \sum_{j=1}^p \mathbb{P}(2|V_j| > \pi) = 2p^{1-A^2/8}.$$

Donc sur l'événement A :

$$\|X\hat{\beta}^L - X\beta^*\|_n^2 + 2\pi\sum_{j=1}^p |\hat{\beta}_j^L| \leq \|X\beta - X\beta^*\|_n^2 + 2\pi\sum_{j=1}^p |\beta_j| + \pi\sum_{j=1}^p |\hat{\beta}_j^L - \beta_j|$$

$$\iff \|X\hat{\beta}^L - X\beta^*\|_n^2 + \pi\sum_{j=1}^p |\hat{\beta}_j^L - \beta_j| \leq \|X\beta - X\beta^*\|_n^2 + 2\pi\sum_{j=1}^p \left(|\hat{\beta}_j^L - \beta_j| + |\beta_j| - |\hat{\beta}_j^L|\right)$$

(on retranche des 2 côtés par $\pi\sum_{j=1}^p |\hat{\beta}_j^L - \beta_j|$)

Or on a $|\hat{\beta}_j^L - \beta_j| + |\beta_j| - |\hat{\beta}_j^L| = 0$ pour $j \notin J(\beta)$

Donc sur A

$$\|X\hat{\beta}^L - X\beta^*\|_n^2 + \pi\sum_{j=1}^p |\hat{\beta}_j^L - \beta_j| \leq \|X\beta - X\beta^*\|_n^2 + 4\pi\sum_{j\in J(\beta)} |\hat{\beta}_j^L - \beta_j|$$

car $||\beta_j| - |\hat{\beta}_j^L|| \leq |\hat{\beta}_j^L - \beta_j|$ (inégalité triangulaire)

Donc (2) est prouvé

* Sur A : $\left\| \frac{1}{n} X^T \varepsilon \right\|_\infty \leq \frac{r}{2}$

D'après les condition KKT satisfaites par l'estimateur Lasso, on a donc

$$\left\| \frac{1}{n} X^T (Y - X\hat{\beta}^L) \right\|_\infty \leq r$$

Rque : le $\frac{1}{n}$ vient du Lasso $\hat{\beta}^L = \operatorname{argmin} \{ \|Y - X\beta\|_n^2 + 2r\|\beta\|_1 \}$ au lieu de $\|Y - X\beta\|^2$

On en déduit que

$$\left\| \frac{1}{n} X^T (X\beta^* - X\hat{\beta}^L) \right\|_\infty \leq \left\| \frac{1}{n} X^T (Y - X\hat{\beta}^L) \right\|_\infty + \left\| \frac{1}{n} X^T \varepsilon \right\|_\infty$$

$$\leq r + \frac{r}{2} = \frac{3r}{2} \quad \text{et (3) est prouvée}$$

* Sur A, on a pour tout $j \in \{1, \dots, p\}$ $\left| \frac{1}{n} X_j^T \varepsilon \right| \leq \frac{r}{2}$

et les conditions KKT satisfaites par le Lasso donnent

$$\begin{cases} \frac{1}{n} (X^j)^T (Y - X\hat{\beta}^L) = r \operatorname{sign}(\hat{\beta}_j^L) & \text{si } \hat{\beta}_j^L \neq 0 \\ \left| \frac{1}{n} (X^j)^T (Y - X\hat{\beta}^L) \right| \leq r & \text{si } \hat{\beta}_j^L = 0 \end{cases}$$

⚠ le 2 devant le paramètre de régularité permet de s'affranchir du 2 des KKT

On déduit donc que pour $\hat{\beta}_j^L \neq 0$

$$\left| \frac{1}{n} (X^j)^T (X\beta^* - X\hat{\beta}^L) \right| \geq \left| \left| \frac{1}{n} (X^j)^T (Y - X\hat{\beta}^L) \right| - \left| \frac{1}{n} (X^j)^T \varepsilon \right| \right|$$

$$\geq \left| |r \operatorname{sign}(\hat{\beta}_j^L)| - \frac{r}{2} \right| = \frac{r}{2}.$$

Donc $\frac{1}{n^2} (X\beta^* - X\hat{\beta}^L)^T X X^T (X\beta^* - X\hat{\beta}^L) = \frac{1}{n^2} \sum_{j=1}^p \left((X^j)^T (X\beta^* - X\hat{\beta}^L) \right)^2$

$$\geq \frac{1}{n^2} \sum_{j : \hat{\beta}_j^L \neq 0} \left((X^j)^T (X\beta^* - X\hat{\beta}^L) \right)^2 \geq \frac{r^2}{4} \sigma(\hat{\beta}^L) \quad (A)$$

Comme les matrices $\frac{X^T X}{n}$ et $\frac{X X^T}{n}$ ont les m valeurs propres (si λ vp de $X^T X$ et u vp $X^T X u = \lambda u \Rightarrow X X^T (Xu) = \lambda X u$)

$$\frac{1}{n^2} (X\beta^* - X\hat{\beta}^L)^T X X^T (X\beta^* - X\hat{\beta}^L) \leq \frac{\phi_{max}}{n} \|X\beta^* - X\hat{\beta}^L\|_2^2 = \phi_{max} \|X\beta^* - X\hat{\beta}^L\|_n^2 \quad (B)$$

On en déduit avec (A) et (B) que

$$\sigma(\hat{\beta}^L) \leq \frac{4\phi_{max}}{r^2} \|X\hat{\beta}^L - X\beta^*\|_n^2 \text{ où } \phi_{max} \text{ vp max de } \frac{X^T X}{n}.$$

Corollaire : Sous les mêmes hyp. que le lemme précédent et en supposant que $\operatorname{diag}(X^TX/n)_j = 1 \quad \forall j \in \{1, \dots, p\}$, on a avec probabilité supérieure à $1 - 2p^{1-A^2/8}$

$$\|\delta_{J_0^c}\|_1 \leq 3\|\delta_{J_0}\|_1 \text{ avec } \delta = \hat{\beta}^L - \beta^*, \quad J_0 = J(\beta^*)$$ ensemble des indices des coef. non nuls de β^*

Preuve : D'après (1) du lemme avec $\beta = \beta^*$

$$r\|\hat{\beta}^L - \beta^*\|_1 \leq 4r\|(\hat{\beta}^L - \beta^*)_{J_0}\|_1 \iff \|(\hat{\beta}^L - \beta^*)_{J_0^c}\|_1 \leq 3\|(\hat{\beta}^L - \beta^*)_{J_0}\|_1$$

Preuve du théorème : Soient $\delta = \hat{\beta}^L - \beta^*$ et $J_0 = J(\beta^*)$

* on applique (1) avec $\beta = \beta^*$:

$$\|X\hat{\beta}^L - X\beta^*\|_n^2 + r\sum_{j=1}^p |\hat{\beta}_j^L - \beta_j^*| \leq 4r\sqrt{s(\beta^*)}\sqrt{\sum_{j \in J_0} |\hat{\beta}_j^L - \beta_j^*|^2}$$

$$\iff \frac{1}{n}\|X\delta\|_2^2 \leq 4r\sqrt{s}\,\|\delta_{J_0}\|_2 \quad (*) \text{ et } \|\delta_{J_0^c}\|_1 \leq 3\|\delta_{J_0}\|_1 \text{ d'après le corollaire précédent}$$

En appliquant l'hypothèse $RE(s,3)$, on a

$$K(s,3) \leq \frac{\|X\delta\|_2}{\sqrt{n}\,\|\delta_{J_0}\|_2} \implies K^2(s,3)\|\delta_{J_0}\|_2^2 \leq \frac{\|X\delta\|_2^2}{n}$$

$$\underset{(*)}{\implies} K^2(s,3)\|\delta_{J_0}\|_2^2 \leq 4r\sqrt{s}\,\|\delta_{J_0}\|_2$$

$$\implies \|\delta_{J_0}\|_2 \leq \frac{4r\sqrt{s}}{K^2(s,3)}$$

Donc $$\boxed{\|X\delta\|_2^2 \leq \frac{16r^2 s n}{K^2(s,3)} = \frac{16A^2}{K^2(s,3)}\sigma^2 s \log p} \implies (7) \text{ slides}$$ (6) TD

* D'après (3), $s(\hat{\beta}^L) \leq \frac{4\phi_{max}}{r^2}\|X\hat{\beta}^L - X\beta^*\|_n^2 \leq \frac{4\phi_{max}}{r^2 n}\|X\delta\|_2^2 \leq \frac{64\phi_{max}\, s}{K^2(s,3)} \implies (8)$ (7)

* Soit A, $\|\delta\|_1 = \|\delta_{J_0}\|_1 + \|\delta_{J_0^c}\|_1 \underset{\text{corollaire}}{\leq} 4\|\delta_{J_0}\|_1 \underset{\text{C-S}}{\leq} 4\sqrt{s}\,\|\delta_{J_0}\|_2 \leq \frac{16A\sigma}{K^2(s,3)} s\sqrt{\frac{\log p}{n}}$

$\implies$ (6) (5) ∎