TD1 : Méthodes pénalisées

Exercice 1 (Propriétés de l'estimateur Ridge)

Soit $Y = (Y_1, \dots, Y_n)^T$, $X = (x_{i,j})_{1 \leq i \leq n, 1 \leq j \leq p}$ non aléatoire vérifiant

$$Y = X\beta^* + \varepsilon,$$

avec $\varepsilon \sim \mathcal{N}(0, \sigma^2 I)$ et $\beta^* = (\beta_1^*, \dots, \beta_p^*)^T \in \mathbb{R}^p$. Nous considérons, pour $\lambda > 0$, l'estimateur Ridge

$$\hat{\beta}^R(\lambda) = (X^T X + \lambda I_p)^{-1} X^T Y.$$

1. Montrer que le problème de minimisation

$$\min_{\beta \in \mathbb{R}^p} \left\{ \sum_{i=1}^n (Y_i - X_i \beta)^2 + \lambda \|\beta\|^2 \right\} \tag{1}$$

   admet $\hat{\beta}^R(\lambda)$ comme unique solution.
2. Montrer que toute solution du problème d'optimisation sous contrainte suivant

$$\min_{\beta \in \mathbb{R}^p, \|\beta\| \leq M_\lambda} \left\{ \sum_{i=1}^n (Y_i - X_i \beta)^2 \right\} \tag{2}$$

   avec $M_\lambda = \|(X^T X + \lambda I_p)^{-1} X^T Y\|$ est aussi solution du problem (1). En déduire que $\hat{\beta}^R(\lambda)$ est aussi l'unique solution du problème (2).
3. Exprimer la norme au carré du biais de $\hat{\beta}^R(\lambda)$ en fonction des valeurs propres $\lambda_1, \dots, \lambda_p$ (comptées avec multiplicité) de $X^T X$:

$$B^R(\lambda) := \left\| \mathbb{E}\left[\hat{\beta}^R(\lambda)\right] - \beta^* \right\|^2.$$

4. Exprimer

$$V^R(\lambda) := \mathbb{E}\left[\left\| \hat{\beta}^R(\lambda) - \mathbb{E}\left[\hat{\beta}^R(\lambda)\right] \right\|^2 \right]$$

   de $\hat{\beta}^R(\lambda)$ en fonction de la variance du bruit σ^2 et des valeurs propres $\lambda_1, \dots, \lambda_p$.

Exercice 2 (Propriétés de l'estimateur Lasso)

Soit $Y = (Y_1, \dots, Y_n)^T$, $X = (x_{i,j})_{1 \leq i \leq n, 1 \leq j \leq p}$ non aléatoire vérifiant

$$Y = X\beta^* + \varepsilon,$$

avec $\varepsilon \sim \mathcal{N}(0, \sigma^2 I)$ et $\beta^* = (\beta_1^*, \dots, \beta_p^*)^T \in \mathbb{R}^p$.

L'objectif est de montrer que les problèmes d'optimisation

$$\min_{\beta \in \mathbb{R}^p} \left\{ \sum_{i=1}^n (Y_i - X_i \beta)^2 + \lambda \|\beta\|_1 \right\} \tag{3}$$

et

$$\min_{\beta\in\mathbb{R}^p, \|\beta\|_1\leq M_\lambda} \left\{ \sum_{i=1}^{n} (Y_i - X_i\beta)^2 \right\}, \tag{4}$$

sont équivalents lorsque M_λ est bien choisi dans le sens où l'ensemble des solutions des deux problèmes est identifque (on rappelle que pour le Lasso on n'a pas unicité de la solution).

1. Montrer que, pour toutes solutions $\beta_\lambda^{(L,1)}$ et $\beta_\lambda^{(L,2)}$ du problème pénalisé (3),
$$\left\|\hat{\beta}_\lambda^{(L,1)}\right\|_1 = \left\|\hat{\beta}_\lambda^{(L,2)}\right\|_1.$$
Nous noterons par la suite cette valeur commune N_λ.
2. Montrer que toute solution de (3) est aussi solution de (4) lorsque $M_\lambda = N_\lambda$.
3. Montrer que toute solution de (4) est aussi solution de (3) lorsque $M_\lambda = N_\lambda$.

Exercice 3 (Un problème de sélection de modèle)

Soit $Y = (Y_1, \dots, Y_n)^T$ et $X = [X_1, \dots, X_p] \in \mathbb{R}^{n\times p}$. Considérons le modèle de régression linéaire suivant :

$$Y = f^* + \varepsilon,$$

avec $f^* = X\beta^* \in \mathbb{R}^n$ et $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$.. Soit $m^* = \{j \in \{1, \dots, p\} : \beta_j^* \neq 0\}$ l'ensemble des coordonnées non nulles du vecteur β^*. Cet ensemble appelé *modèle* est inconnu. On définit $\hat{f}_m = X\hat{\beta} = P_{S_m}Y$ où $P_{S_m} : \mathbb{R}^n \to \mathbb{R}^n$ est la matrice de projection orthogonale sur $S_m = \text{Vect}\{X_j, j \in m\}$ et $m \subset \{1, \dots, p\}$.
Soit $\mathcal{M}$ une collection de modèles, on veut sélectionner $\hat{m} \in \mathcal{M}$ tel que le risque de $\hat{f}_{\hat{m}}$ soit le plus petit possible.
On note m_0 l'oracle, $m_0 = \arg\min_{m\in\mathcal{M}} \mathbb{E}\left[\|\hat{f}_m - f^*\|^2\right]$ et $\hat{f}_{m_0}$ l'estimateur oracle. On cherche $\hat{m} \in \mathcal{M}$ tel que $\mathbb{E}\left[\|\hat{f}_{\hat{m}} - f^*\|^2\right] \leq C\mathbb{E}\left[\|\hat{f}_{m_0} - f^*\|^2\right]$, avec $C > 0$.

Remarques :

1. m^* n'appartient pas forcément à $\mathcal{M}$.
2. Même si $m^* \in \mathcal{M}$, m^* peut être différent de m_0.
3. L'oracle n'est pas aléatoire mais dépend de β^* donc $\hat{f}_{m_0}$ n'est pas utilisable en pratique.

On définit le risque de $\hat{f}_m$ par $R(\hat{f}_m) := \mathbb{E}\left[\|\hat{f}_m - f^*\|^2\right]$ et $d_m = \dim(S_m)$.

Questions :

1. Montrer que $R(\hat{f}_m) = \|(I_n - P_{S_m})f^*\|^2 + \sigma^2 d_m$ et interpréter ce résultat.
2. On considère le critère de sélection de modèle suivant :
$$C(m) = \|Y - \hat{f}_m\|^2 + \sigma^2 \,\text{pen}(m)$$
où $\text{pen}(m) := K(\sqrt{d_m} + \sqrt{2\log(1/\Pi_m)})^2$ pour $K > 1$ et $\Pi_m \in]0, 1]$ tel que $\sum_{m\in\mathcal{M}} \Pi_m = 1$ et $\hat{m} := \arg\min_{m\in\mathcal{M}} C(m)$.
   (a) Soit $m \in \mathcal{M}$ fixé. Montrer que
   $$R(\hat{f}_{\hat{m}}) \leq R(\hat{f}_m) + 2\mathbb{E}\left[\langle\varepsilon, f^* - \hat{f}_m\rangle\right] + \sigma^2\,\text{pen}(m) + \mathbb{E}\left[2\langle\varepsilon, \hat{f}_{\hat{m}} - f^*\rangle - \sigma^2\,\text{pen}(\hat{m})\right]. \tag{5}$$
   (b) Montrer que $\mathbb{E}\left[\langle\varepsilon, f^* - \hat{f}_m\rangle\right] = -\sigma^2 d_m$.
   (c) Soit $a > 1$, on introduit $\bar{S}_{\hat{m}} = \text{Vect}(S_{\hat{m}}, f^*)$. Montrer que
   $$2\langle\varepsilon, \hat{f}_{\hat{m}} - f^*\rangle \leq a\sigma^2(N^2 + U_{\hat{m}}) + a^{-1}\|\hat{f}_{\hat{m}} - f^*\|^2,$$
   avec
   $$N^2 = \frac{\|P_{\text{Vect}(f^*)}\varepsilon\|^2}{\sigma^2} \sim \chi^2(1) \quad \text{et} \quad U_m = \frac{\|P_{\tilde{S}_m}\varepsilon\|^2}{\sigma^2}$$
   où $\tilde{S}_m \oplus \text{Vect}(f^*) = \bar{S}_m$.

(d) On pose $a = \dfrac{K+1}{2} > 1$. En déduire qu'il existe une variable aléatoire Z telle que

$$2\langle \varepsilon, \hat{f}_{\hat{m}} - f^* \rangle - \sigma^2 \operatorname{pen}(\hat{m}) \leq a^{-1} \|\hat{f}_{\hat{m}} - f^*\|^2 + Z$$

avec $\mathbb{E}(Z) \leq C_K \sigma^2$ et $C_K \geq 0$ une constante qui dépend de K.
On pourra utiliser le lemme suivant :
Lemme : *On suppose que $F : \mathbb{R}^d \to \mathbb{R}$ est $1-$Lipschitzienne et $Z \sim \mathcal{N}(0, \sigma^2 I_d)$. Alors il existe $\xi \sim \mathcal{E}(1)$ tel que $F(Z) \leq \mathbb{E}[F(Z)] + \sigma\sqrt{2\xi}$.*

(e) Montrer que $\sigma^2 \operatorname{pen}(m) \leq 2KR(\hat{f}_m) + 4K\sigma^2 \log(\Pi^{-1})$.

(f) En déduire qu'il existe $C_K > 0$ qui ne dépend que de K tel que

$$\mathbb{E}\left[\|\hat{f}_{\hat{m}} - f^*\|^2\right] \leq C_K \min_{m \in \mathcal{M}} \left\{ \mathbb{E}\left[\|\hat{f}_m - f^*\|\right] + \sigma^2 \log(\Pi_m^{-1}) + \sigma^2 \right\}.$$

(g) Que peut-on dire lorsque $\log(\Pi_m^{-1}) \leq C d_m$, où $C > 0$ est une constante.