TD2 : Inégalités oracles pour l'estimateur Lasso dans le modèle de régression linéaire gaussien

Lemme : Soient $p \geq 2$, $n \geq 1$. Soient $\varepsilon_1, \ldots, \varepsilon_n$ des variables aléatoires réelles indépendantes, identiquement distribuées de loi $\mathcal{N}(0, \sigma^2)$, $\sigma^2 > 0$. On définit l'estimateur Lasso par

$$\hat{\beta}_L = \underset{\beta \in \mathbb{R}^p}{\arg\min} \left\{ \frac{1}{n} \|Y - X\beta\|_2^2 + 2r\|\beta\|_1 \right\}, \tag{1}$$

avec $r = A\sigma\sqrt{\dfrac{\log p}{n}}$ et $A > 2\sqrt{2}$. On suppose que $\mathrm{diag}(X^T X/n)_j = 1$ pour tout $j \in \{1, \ldots, p\}$. Alors avec probabilité supérieure à $1 - 2p^{1-A^2/8}$, on a pour tout $\beta \in \mathbb{R}^p$,

$$\begin{aligned} \|X\hat{\beta}^L - X\beta^*\|_n^2 + r\sum_{j=1}^p |\hat{\beta}_j^L - \beta_j| &\leq \|X\beta - X\beta^*\|_n^2 + 4r \sum_{j \in J(\beta)} |\hat{\beta}_j^L - \beta_j| \\ &\leq \|X\beta - X\beta^*\|_n^2 + 4r\sqrt{\mathcal{M}(\beta)} \sqrt{\sum_{j \in J(\beta)} |\hat{\beta}_j^L - \beta_j|^2} \end{aligned} \tag{2}$$

$$\left\| \frac{1}{n} X^T (X\beta^* - X\hat{\beta}_L) \right\|_\infty \leq \frac{3r}{2} \tag{3}$$

$$\mathcal{M}(\hat{\beta}^L) \leq \frac{4\phi_{\max}}{r^2} \|X\hat{\beta}^L - X\beta^*\|_n^2, \tag{4}$$

où $\phi_{\max}$ est la valeur propre maximale de $\dfrac{X^T X}{n}$.

Preuve :

1. Montrer que pour tout $\beta \in \mathbb{R}^p$,

$$\|X\beta^* - X\hat{\beta}^L\|_n^2 + 2r\sum_{j=1}^p |\hat{\beta}_j^L| \leq \|X\beta^* - X\beta\|_n^2 + 2\sum_{j=1}^p (\hat{\beta}_j^L - \beta_j) V_j + 2r\sum_{j=1}^p |\beta_j|,$$

   avec $V_j = \dfrac{1}{n}\displaystyle\sum_{i=1}^n \varepsilon_i x_{ij}$ et $X = (x_{ij})_{1 \leq i \leq n, 1 \leq j \leq p}$ la matrice de covariables.

2. Soit $\mathcal{A} = \bigcap_{j=1}^p \{2|V_j| \leq r\}$, montrer que $\mathbb{P}(\mathcal{A}^c) \leq \displaystyle\sum_{j=1}^p \mathbb{P}\left(|\eta| > \frac{\sqrt{n} r}{2\sigma} \right)$, avec $\eta \sim \mathcal{N}(0,1)$.
3. Montrer que si $Z \sim \mathcal{N}(0,1)$, alors $\mathbb{P}(|Z| \geq z) \leq 2\mathrm{e}^{-z^2/2}$ pour tout $z > 0$.
4. En déduire que $\mathbb{P}(2|V_j| > r) \leq 2p^{-A^2/8}$ et que $\mathbb{P}(\mathcal{A}^c) \leq 2p^{1-A^2/8}$.

5. Montrer que sur $\mathcal{A}$,

$$\|X\hat{\beta}^L - X\beta^*\|_n^2 + r\sum_{j=1}^{p}|\hat{\beta}_j^L - \beta_j| \leq \|X\beta - X\beta^*\|_n^2 + 2r\sum_{j=1}^{p}(|\hat{\beta}_j^L - \beta_j| + |\beta_j| - |\hat{\beta}_j^L|)$$

   et en déduire le résultat (2).
6. En utilisant les conditions KKT satisfaites par le Lasso, en déduire (3).
7. Montrer que $\left|\frac{1}{n}(X^j)^T(X\beta^* - X\hat{\beta}^L)\right| \geq \frac{r}{2}$ pour $j \in \{1,\dots,p\}$ et $\hat{\beta}_j^L \neq 0$, où X^j est la j^{ème} colonne de X.
8. En déduire que

$$\frac{1}{n^2}(X\beta^* - X\hat{\beta}^L)^T XX^T(X\beta^* - X\hat{\beta}^L) \geq \frac{r^2}{4}\mathcal{M}(\hat{\beta}^L).$$

9. En déduire (4).

Corollaire : Sous les mêmes hypothèses que le lemme précédent, on a avec probabilité supérieure à $1 - 2p^{1-A^2/8}$, $\|\delta_{J_0^c}\|_1 \leq 3\|\delta_{J_0}\|_1$ avec $\delta = \hat{\beta}^L - \beta^*$ et $J_0 = J(\beta^*)$ ensemble des indices des coefficients non nuls de β^*.

Preuve : Déduire de (2) le résultat du corollaire.

Théorème (Bickel, Ritov, Tsybakov (2009)) :
We assume that

- ε_i independent $\mathcal{N}(0,\sigma^2)$ random variables with $\sigma^2 > 0$,
- the diagonal elements of the matrix X^TX/n equal to 1,
- $\mathcal{M}(\beta^*) \leq s$, where $1 \leq s \leq p$, $n \geq 1$, $p \geq 2$,
- RE$(s,3)$ is satisfied.

Consider the Lasso estimator $\hat{\beta}^L$ defined by (1) with $r = A\sigma\sqrt{\frac{\log p}{n}}$ and $A > 2\sqrt{2}$. Then, with probability at least $1 - p^{1-A^2/8}$, we have

$$\|\hat{\beta}^L - \beta^*\|_1 \leq \frac{16A}{\kappa^2(s,3)}\sigma s\sqrt{\frac{\log p}{n}}, \tag{5}$$

$$\|X(\hat{\beta}^L - \beta^*)\|_2^2 \leq \frac{16A^2}{\kappa^2(s,3)}\sigma^2 s\log p, \tag{6}$$

$$\mathcal{M}(\hat{\beta}^L) \leq \frac{64\phi_{max}}{\kappa^2(s,3)}s. \tag{7}$$

Preuve : Déduire du lemme et du corollaire précédents les trois inégalités du théorème.