TD3 : Modèle Linéaire Généralisé

Exercice 1 (Le modèle logistique)

Nous nous plaçons dans un cadre de classification binaire où $Y_i \in \{0,1\}$ dépend de $X_i = (X_{i,1}, \dots, X_{i,p})^T \in \mathbb{R}^p$ non aléatoire. Nous supposons que

$$g(\mathbb{E}[Y_i]) = X_i^T \beta^*$$

avec $g(x) = \log(x/(1-x))$ la fonction de lien *logit* et $\beta^* \in \mathbb{R}^p$ inconnu. Nous souhaitons estimer β^* à partir de l'observation de $\{(X_i, Y_i)), i = 1, \dots, n\}$. Pour cela, nous considérons deux critères basés sur la log-vraisemblance des données, que nous noterons par la suite $\ell_n(\beta)$: un critère de type Ridge

$$\hat{\beta}^R(\lambda) = \underset{\beta \in \mathbb{R}^p}{\arg\min}\{-\ell_n(\beta) + \lambda \|\beta\|_2^2\},$$

et un critère de type Lasso,

$$\hat{\beta}^L(\lambda) = \underset{\beta \in \mathbb{R}^p}{\arg\min}\{-\ell_n(\beta) + \lambda \|\beta\|_1\}$$

dépendant tous deux d'un paramètre $\lambda \geq 0$.

1. Nous commençons par étudier la log-vraisemblance $\ell_n(\beta)$.
   (a) Soit Y une variable aléatoire de loi binomiale de paramètre $\mu \in]0,1[$, calculer la densité de la loi de Y par rapport à la mesure de comptage sur $\{0,1\}$.
   (b) En déduire la vraisemblance de $Y_1, \dots, Y_n$ en fonction de $(\mu_1, \dots, \mu_n)$ telle que, pour tout i, $\mu_i = \mathbb{E}[Y_i]$.
   (c) Montrer que
   $$\ell_n(\beta) = \sum_{i=1}^{n} \left(Y_i X_i^T \beta - \log\left(1 + \mathrm{e}^{X_i^T \beta}\right)\right).$$
   (d) La fonction ℓ_n est-elle convexe ? concave ? dérivable ?
2. Peut-t'on calculer facilement l'estimateur $\hat{\beta}^R(\lambda)$? Que vaut-t'il pour $\lambda = 0$?
3. Supposons que nos données sont des données génomiques, c'est-à-dire que pour n femmes ayant ou non un cancer du sein, nous avons prélevé et analysé l'ARN présent dans un échantillon de leurs cellules et nous disposons des données suivantes :
   - $Y_i = 1$ si le i-ème individu est atteint d'un cancer du sein ($Y_i = 0$ sinon),
   - $X_{i,j}$ le nombre de fois où l'ARN correspondant au j-ème gène étudié pour l'individu i a été retrouvé.

   Nous souhaitons déterminer les gènes ayant de l'influence sur l'apparition d'un cancer du sein. Devons-nous calculer l'estimateur Ridge ou l'estimateur Lasso ? Justifier.
4. Donner les conditions KKT pour le Lasso dans le modèle logistique.

Exercice 2 (Lasso et modèle logistique)

Soient $(z_1, Y_1), \dots, (z_n, Y_n) \in \mathbb{R}^p \times \{0,1\}$ n observations. Nous considérons le modèle logistique défini de la façon suivante :

$$\mathbb{P}(Y_i = 1) = \pi(z_i^T \beta_0) = \frac{\exp(z_i^T \beta_0)}{1 + \exp(z_i^T \beta_0)},$$

où $z_1, \dots, z_n$ sont supposés déterministes et $\beta_0 \in \mathbb{R}^p$ le paramètre inconnu à estimer.

Nous introduisons les notations suivantes :

- $X = (z_{ij})_{1 \leq i \leq n, 1 \leq j \leq p}$,

- $J(\beta) = \{j \in \{1, \dots, p\} : \beta_j \neq 0\}$

Nous définissions le risque empirique (ou fonction de perte) pour le modèle logistique :

$$\hat{R}(\beta) = \frac{1}{n} \sum_{i=1}^{n} \log(1 + \exp(z_i^T \beta)) - Y_i z_i^T \beta$$

et l'estimateur Lasso :

$$\hat{\beta}_L = \underset{\beta \in \mathbb{R}^p}{\arg\min} \left\{ \hat{R}(\beta) + \lambda \|\beta\|_1 \right\},$$

avec $\lambda > 0$ paramètre de régularisation.
On suppose qu'il existe une constante $0 < c < \infty$ telle que $\max_{1 \leq i \leq n} \max_{1 \leq j \leq p} |z_{ij}| \leq c$.

1. Justifier le choix de $\hat{R}(\beta)$ dans la définition de l'estimateur Lasso.
2. On définit $R(\beta) = \mathbb{E}[\hat{R}(\beta)]$. Montrer que

$$R(\beta) = \hat{R}(\beta) + \frac{1}{n} \sum_{i=1}^{n} z_i^T \beta (Y_i - \pi(z_i^T \beta_0)).$$

3. On définit le processus empirique suivant : pour tout $j \in \{1, \dots, p\}$,

$$V_j = \frac{1}{n} \sum_{i=1}^{n} z_{ij} \varepsilon_i, \quad \text{avec } \varepsilon_i = Y_i - \mathbb{E}(Y_i).$$

   (a) Montrer que pour tout $\beta \in \mathbb{R}^p$,

$$R(\hat{\beta}_L) \leq R(\beta) + \sum_{j=1}^{p} (\hat{\beta}_{L,j} - \beta_j) V_j + \lambda \|\beta\|_1 - \lambda \|\hat{\beta}_L\|_1.$$

   (b) Introduire un événement $\mathcal{A}$ bien choisi dont on calculera la probabilité à l'aide de l'inégalité de Hoeffding définie ci-dessous.
   Inégalité de Hoeffding : soient $X_1, \dots, X_n$ des variables aléatoires indépendantes telles que $X_i \in [a_i, b_i]$ presque sûrement. On pose $S = \sum_{i=1}^{n} (X_i - \mathbb{E}(X_i))$. Alors pour tout $x > 0$,

$$\mathbb{P}(|S| \geq x) \leq 2 \exp\left(\frac{-2x^2}{\sum_{i=1}^{n} (b_i - a_i)^2} \right).$$

   (c) En déduire que pour $\lambda = A\sqrt{\dfrac{\log p}{n}}$ avec $A > \sqrt{2}c$, avec probabilité au moins $1 - 2p^{1 - A^2/2c^2}$,

$$R(\hat{\beta}_L) - R(\beta_0) \leq \inf_{\beta \in \mathbb{R}^p} \left\{ R(\beta) - R(\beta_0) + 2A\|\beta\|_1 \sqrt{\frac{\log p}{n}} \right\}.$$

   (d) Commenter ce résultat.

Remarque : Sous l'hypothèse RE$(s, 3)$,

$$\kappa(s, c_0) = \min_{\substack{J \subset \{1, \dots, M\} \\ |J| \leq s}} \min_{\substack{\delta \neq 0 \\ \|\delta_{J^c}\|_1 \leq 3\|\delta_J\|_1}} \frac{\|X\delta\|_2}{\sqrt{n}\|\delta_J\|_2} > 0,$$

et en supposant que $|J(\beta_0)| \leq s$, pour $1 \leq s \leq p$ on peut montrer [1], avec probabilité supérieure à $1 - 2p^{1 - A^2/2c_2}$, que

$$R(\hat{\beta}_L) - R(\beta_0) \leq \frac{9sA^2}{\kappa^2(s, 3)C} \frac{\log p}{n},$$

1. Kwemou, M. (2016). Non-asymptotic oracle inequalities for the Lasso and group Lasso in high dimensional logistic model. ESAIM : Probability and Statistics, 20, 309-331

$$\|X\hat{\beta}_L - X\beta_0\|_n^2 \leq \frac{9s^2A^2}{\kappa^2(s,3)C^2}\frac{\log p}{n},$$

$$\|\hat{\beta}_L - \beta_0\|_1 \leq \frac{12sA}{\kappa^2(s,3)C}\sqrt{\frac{\log p}{n}},$$

où $C > 0$ est telle que $\max_{1\leq i\leq n} z_i^T\beta \leq C$ pour tout $\beta \in \mathbb{R}^p$.

Exercice 3 (Régression de Poisson)

On considère n variables aléatoires indépendantes $Y_1, \ldots, Y_n$ telles que

$$Y_i \sim \mathcal{P}(\mu_i), \qquad \mu_i = \exp(X_i^T\beta^*),$$

où $X_i \in \mathbb{R}^p$ est un vecteur de covariables déterministes et $\beta^* \in \mathbb{R}^p$ est inconnu. On note $X \in \mathbb{R}^{n\times p}$ la matrice dont les lignes sont les X_i^T.

Pour $\lambda > 0$, on définit l'estimateur Lasso par

$$\widehat{\beta}_\lambda \in \arg\min_{\beta\in\mathbb{R}^p} \left\{L_n(\beta) + \lambda\|\beta\|_1\right\},$$

où L_n est l'opposé de la log-vraisemblance normalisée, à une constante additive près.

1. Montrer que
$$L_n(\beta) = \frac{1}{n}\sum_{i=1}^n \left[\exp(X_i^T\beta) - Y_iX_i^T\beta\right].$$

2. Calculer le gradient et la Hessienne de L_n. Montrer que L_n est convexe. À quelle condition sur X est-elle strictement convexe ?

3. Montrer que $\widehat{\beta}_\lambda$ minimise le critère pénalisé si et seulement si
$$\frac{1}{n}X^T(Y - \widehat{\mu}) \in \lambda\partial\|\widehat{\beta}_\lambda\|_1, \qquad \widehat{\mu}_i = \exp(X_i^T\widehat{\beta}_\lambda).$$
En déduire les conditions KKT selon que $\widehat{\beta}_{\lambda,j} = 0$ ou non.

4. Montrer que si
$$\left|\frac{1}{n}X_j^T(Y - \widehat{\mu})\right| < \lambda,$$
alors $\widehat{\beta}_{\lambda,j} = 0$. La réciproque est-elle vraie ?

5. Supposons $p = 3$ et
$$\frac{1}{n}X^T(Y - \mathbf{1}) = \begin{pmatrix} 0.3 \\ -0.1 \\ 0.05 \end{pmatrix}.$$
Déterminer la plus petite valeur de $\lambda > 0$ pour laquelle le vecteur nul est solution du problème de minimisation.