Statistiques avancées 3A · version pédagogique

Révision pour l'examen — l'essentiel

Les synthèses à relire en dernier : le cours en une page, les conventions, les théorèmes et leurs hypothèses, les preuves à savoir refaire, les pièges, le jour J.

Le cours en une page

Si vous ne deviez relire qu'une section le matin de l'examen, ce serait celle-ci.

Le fil du cours

1. **Le point de départ (S1).** Modèle $Y = X\beta^* + \varepsilon$. Les moindres carrés ont une erreur de prédiction $\sigma^2 \operatorname{rg}(X)/n$: très bien si $p \ll n$, inutile dès que $p \geq n$ (typiquement $\operatorname{rg} X = n$, d'où une erreur σ^2). Si de plus $p > n$, $\operatorname{Ker} X \neq \{0\}$ et β^* n'est plus identifiable.

2. **Pénaliser (S1, TD1).** Le Ridge ($\lambda \|\beta\|_2^2$) stabilise mais ne sélectionne aucune variable. La pénalité ℓ_0 (Cp, AIC, BIC) sélectionne, mais impose d'explorer 2^p modèles. L'oracle qui connaîtrait le support ferait $\sigma^2 |\mathcal{A}^*|/n \leq \sigma^2 s/n$. Le TD1 démontre une vraie inégalité oracle pour la sélection de modèles.

3. **Le Lasso (S1, S2).** La pénalité $\lambda \|\beta\|_1$ est convexe, donc calculable, et produit des zéros exacts. En design orthogonal, le Lasso est un seuillage doux. En général, on le reconnaît à ses conditions KKT. Son chemin en λ est linéaire par morceaux (LARS).

4. **Pourquoi il marche (S3, TD2).** Sur l'événement $\mathcal{E} = \{\frac{2}{n} \left\|X^\top \varepsilon\right\|_\infty \leq r\}$, de grande probabilité, l'erreur $\delta = \hat{\beta} - \beta^*$ vit dans un cône. Sous la condition RE$(s, 3)$, le théorème de Bickel–Ritov–Tsybakov donne une erreur de prédiction $\frac{1}{n}\|X\delta\|^2$ en $\sigma^2 s \log p/n$ et une erreur $\|\delta\|_1$ en $\sigma s\sqrt{\log p/n}$: l'oracle $\sigma^2 s/n$, à une constante et un facteur $\log p$ près.

5. **Sans modèle exact (S4).** On approche une fonction f quelconque par un dictionnaire de M fonctions. L'inégalité oracle lente ne demande que des colonnes normalisées, aucune hypothèse sur leurs corrélations (reste $2\lambda \|\beta\|_1$). L'inégalité rapide suppose RE, et pénalise par $2\lambda \|\beta\|_1$ (reste $\propto s(x + \log M)/n$). Les outils : sous-différentiel et $0 \in \partial F$.

6. **Sortir du gaussien (S5, TD3).** Les GLM : famille exponentielle, lien canonique, log-vraisemblance concave, IRLS, normalité asymptotique, intervalles de Wald. Le Lasso d'un GLM (logistique, Poisson) a des KKT de même forme, avec le résidu $y - \hat{\mu}$ à la place de $Y - X\hat{\beta}$. Son inégalité oracle lente se prouve de la même façon, avec Hoeffding.

7. **Réparer les défauts du Lasso (S6).** Biais : LSLasso, relaxé, adaptatif. Variables corrélées et $p > n$: elastic net. Structure : fusionné, group-Lasso. Programme linéaire : Dantzig. Le bridge relie ℓ_0, Lasso et Ridge.

Les incontournables

Les formules qui reviennent partout. En mode auto-test, la colonne de droite est cachée.

Notion	Formule
Séance 1 — moindres carrés, Ridge, ℓ0 → partie 1	
Modèle	$Y = X\beta^* + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$, $X \in \mathbb{R}^{n\times p}$ déterministe ; $\|u\|_n^2 = \frac{1}{n}\|u\|^2$
Moindres carrés	$X^\top X\hat\beta = X^\top Y$; si $\operatorname{rg} X = p$: $\hat\beta^{\mathrm{MC}} = (X^\top X)^{-1}X^\top Y$; $X\hat\beta^{\mathrm{MC}} = PY$, P projection orthogonale sur $\operatorname{Im} X$
Erreur de prédiction des MCO	$\mathbb{E}\left\|X\hat\beta^{\mathrm{MC}} - X\beta^*\right\|_n^2 = \sigma^2 \operatorname{rg}(X)/n$
Ridge	critère $\|Y - X\beta\|^2 + \lambda\|\beta\|_2^2$: $\hat\beta^R = (X^\top X + \lambda I_p)^{-1}X^\top Y$, unique si $\lambda > 0$; dans la direction propre v_j de $X^\top X$ (valeur propre $\mu_j > 0$) : $v_j^\top\hat\beta^R = \frac{\mu_j}{\mu_j+\lambda} v_j^\top\hat\beta^{\mathrm{MC}}$
Pénalités ℓ0 (ajoutées à $\|Y - X\beta\|_n^2$)	Cp/AIC : $\frac{2\sigma^2\|\beta\|_0}{n}$; BIC : $\frac{\sigma^2\log(n)\|\beta\|_0}{n}$
Identité de Cp (modèle fixé de dimension d)	$\mathbb{E}\left\|X\hat\beta_m - X\beta^*\right\|_n^2 + \sigma^2 = \mathbb{E}\left\|Y - X\hat\beta_m\right\|_n^2 + \frac{2\sigma^2 d}{n}$
Oracle (MCO restreints au vrai support $\mathcal{A}^*$)	$X_{\mathcal{A}^*}$ de rang plein : $\mathbb{E}\left\|X\hat\beta^{MCR} - X\beta^*\right\|_n^2 = \sigma^2\|\mathcal{A}^*\|/n \le \sigma^2 s/n$
Séance 2 — le Lasso de près (critère $\|Y - X\beta\|^2 + \lambda\|\beta\|_1$) → partie 2	
Seuillage doux ($X^\top X = I$, $b = X^\top Y$)	$\hat\beta_j = \operatorname{sgn}(b_j)\big(\|b_j| - \lambda/2\big)_+$
Conditions KKT	$2X_j^\top(Y - X\hat\beta) = \lambda\operatorname{sgn}(\hat\beta_j)$ si $\hat\beta_j \neq 0$; $\left\|2X_j^\top(Y - X\hat\beta)\right\| \le \lambda$ si $\hat\beta_j = 0$
Le Lasso est nul	$\hat\beta = 0 \iff \lambda \ge \lambda_{\max} = 2\left\|X^\top Y\right\|_\infty$
Séance 3 — cône, RE, BRT (critère $\frac{1}{n}\|Y - X\beta\|^2 + 2r\|\beta\|_1$, $\|X_j\|^2 = n$) → partie 3	
Cône ($\delta = \hat\beta - \beta^*$, $J_0 = J(\beta^*)$)	sur $\mathcal{E} = \{\frac{2}{n}\left\|X^\top\varepsilon\right\|_\infty \le r\}$: $\left\|\delta_{J_0^c}\right\|_1 \le 3\|\delta_{J_0}\|_1$
Condition RE$(s,3)$	$\kappa(s,3) = \min_{\|J_0|\le s}\ \min_{\delta\neq 0,\ \left\|\delta_{J_0^c}\right\|_1 \le 3\left\|\delta_{J_0}\right\|_1} \frac{\|X\delta\|}{\sqrt{n}\,\|\delta_{J_0}\|} > 0$
Théorème BRT	bruit $\mathcal{N}(0,\sigma^2 I_n)$, $M(\beta^*) \le s$, RE$(s,3)$, $\kappa = \kappa(s,3)$; $r = A\sigma\sqrt{\log p/n}$, $A > 2\sqrt{2}$; avec probabilité $\ge 1 - p^{1-A^2/8}$: $\left\|\hat\beta - \beta^*\right\|_1 \le \frac{16A}{\kappa^2}\sigma s\sqrt{\frac{\log p}{n}}$, $\left\|X(\hat\beta - \beta^*)\right\|^2 \le \frac{16A^2}{\kappa^2}\sigma^2 s\log p$, $M(\hat\beta) \le \frac{64\varphi_{\max}}{\kappa^2}s$
Séance 4 — outils convexes, inégalités oracle → partie 4	
Sous-gradient, optimalité	$g \in \partial\varphi(u) \iff \varphi(v) \ge \varphi(u) + g^\top(v-u)\ \forall v$; $\partial\|\cdot\|(0) = [-1,1]$; $\partial\|u\|_1 = \{g :\ g_j = \operatorname{sgn} u_j$ si $u_j \neq 0,\ g_j \in [-1,1]$ sinon$\}$; u^* minimise φ convexe $\iff 0 \in \partial\varphi(u^*)$; monotonie : $(u_1 - u_2)^\top(g_1 - g_2) \ge 0$
Seuillage doux, une coordonnée	$\arg\min_a \frac{1}{2}(a-b)^2 + \lambda|a| = \operatorname{sgn}(b)(|b| - \lambda)_+$

Notion	Formule
Inégalité oracle lente	$\|X_j\|^2 = n$; critère $\frac{1}{n}\|y - X\beta\|^2 + \lambda\|\beta\|_1$ minimisé sur Θ convexe, $\lambda = 2\sigma\sqrt{2(x+\log M)/n}$; avec probabilité $\geq 1 - 2e^{-x}$: $\frac{1}{n}\left\|f_{\hat\beta} - f\right\|^2 \leq \inf_{\beta\in\Theta}\{\frac{1}{n}\|f_\beta - f\|^2 + 2\lambda\|\beta\|_1\}$
Inégalité oracle rapide	+ RE$(s,3)$; critère $\frac{1}{n}\|y - X\beta\|^2 + 2\lambda\|\beta\|_1$, même λ ; avec probabilité $\geq 1 - 2e^{-x}$: $\frac{1}{n}\left\|f_{\hat\beta} - f\right\|^2 \leq \inf_{\beta\in\Theta,\,\|\beta\|_0\leq s}\{\frac{1}{n}\|f_\beta - f\|^2 + \frac{9\lambda^2 s}{4\kappa^2}\}$, et $\frac{9\lambda^2 s}{4\kappa^2} = \frac{18\sigma^2 s(x+\log M)}{\kappa^2 n}$
Séance 5 — modèles linéaires généralisés → partie 5	
Famille exponentielle	$f_\theta(y) = \exp\big(\theta T(y) - A(\theta) + B(y)\big)$; $\mathbb{E}T(Y) = A'(\theta)$, $\operatorname{Var}T(Y) = A''(\theta)$
Lien canonique	$\theta_i = g(\mu_i) = x_i^\top\beta$; avec $T(y) = y$: $g = (A')^{-1}$; Bernoulli $g(\mu) = \log\frac{\mu}{1-\mu}$, Poisson $g(\mu) = \log\mu$, gaussienne $g(\mu) = \mu$
Gradient, hessienne (lien canonique)	$\nabla\ell = X^\top(y - \mu)$, $\nabla^2\ell = -X^\top W X$, $W = \operatorname{diag}\big(A''(\theta_i)\big)$; équations $X^\top y = X^\top\mu$
IRLS (Newton)	$\beta_{k+1} = (X^\top W X)^{-1}X^\top W z$, $z = X\beta_k + W^{-1}(y - \mu)$
Asymptotique, intervalle de Wald	p fixé, information moyenne $I_n(\beta^*) \to I(\beta^*) \succ 0$: $\sqrt{n}(\hat\beta - \beta^*) \to \mathcal{N}\big(0, I(\beta^*)^{-1}\big)$; $\hat\beta_j \pm q_{1-\alpha/2}\sqrt{[I(\hat\beta)^{-1}]_{jj}/n}$, de niveau asymptotique $1-\alpha$
Logistique, codage $y_i \in \{-1, 1\}$	$L_n(\beta) = \frac{1}{n}\sum_i \log\big(1 + e^{-y_i x_i^\top\beta}\big)$; $\nabla^2 L_n(\beta) = \frac{1}{n}X^\top W X$, poids $W_{ii} = \pi_i(1-\pi_i) \in]0, \frac{1}{4}]$, $\pi_i = \sigma(x_i^\top\beta)$
KKT du Lasso d'un GLM (critère $L_n(\beta) + \lambda\|\beta\|_1$, $L_n = -\frac{1}{n}\ell$, lien canonique)	$\frac{1}{n}X_j^\top(y - \hat\mu) = \lambda\operatorname{sgn}(\hat\beta_j)$ si $\hat\beta_j \neq 0$; $\left\|\frac{1}{n}X_j^\top(y - \hat\mu)\right\| \leq \lambda$ sinon ; $\hat\mu_i = A'(x_i^\top\hat\beta)$
Séance 6 — variantes (critère $\|Y - X\beta\|^2$ + pénalité, $X^\top X = I$, $b = X^\top Y$) → partie 6	
LSLasso (Lasso, puis MCO sur le support choisi)	seuillage dur : $b_j\,\mathbf{1}\{\|b_j\| > \lambda/2\}$
Lasso relaxé (pénalité $\delta\lambda\|\beta\|_1$ sur le support du Lasso, $\delta \in [0,1]$)	$\big(b_j - \operatorname{sgn}(b_j)\,\delta\lambda/2\big)\,\mathbf{1}\{\|b_j\| > \lambda/2\}$
Lasso adaptatif (pénalité $\lambda\sum_j \|\beta_j\| / \left\|\tilde\beta_j\right\|$, avec $\tilde\beta = b$)	$\operatorname{sgn}(b_j)\Big(\|b_j\| - \dfrac{\lambda}{2\,\|b_j\|}\Big)_+$
Elastic net (pénalité $\lambda_1\|\beta\|_1 + \lambda_2\|\beta\|_2^2$)	$\dfrac{\operatorname{sgn}(b_j)(\|b_j\| - \lambda_1/2)_+}{1 + \lambda_2}$
Group-Lasso (pénalité $\lambda\sum_k \left\|\beta_{(k)}\right\|_2$)	$\Big(1 - \dfrac{\lambda}{2\left\|b_{(k)}\right\|_2}\Big)_+ b_{(k)}$

Les conventions : la source n°1 d'erreurs

Multiplier un critère par une constante positive ne change pas son minimiseur. **Mais** quand il y a une pénalité, la constante se reporte sur λ : le seuil, les conditions KKT et $\lambda_{\max}$ changent d'un facteur 2 ou n. Le cours utilise plusieurs normalisations, toutes réunies ici.

Critère	**Où**	**Lasso en design orthonormé**	**KKT pour $\hat{\beta}_j \neq 0$**	**$\hat{\beta} = 0$ dès que**
$\|Y - X\beta\|^2 + \lambda \|\beta\|_1$	S2 (diapos 26–27), S6, TD1	$X^\top X = I$, $b = X^\top Y$: seuil $\lambda/2$, $\mathrm{sgn}(b_j)(\|b_j\| - \lambda/2)_+$	$2X_j^\top(Y - X\hat{\beta}) = \lambda \,\mathrm{sgn}(\hat{\beta}_j)$	$\lambda \geq 2 \left\|X^\top Y\right\|_\infty$
$\frac{1}{n}\|Y - X\beta\|^2 + \lambda \|\beta\|_1$	S1 (diapo 23, écrit $\|Y - X\beta\|_n^2 + \lambda \|\beta\|_1$), S4 (oracle lente)	$X^\top X = nI$, $b = X^\top Y/n$: seuil $\lambda/2$	$\frac{2}{n}X_j^\top(Y - X\hat{\beta}) = \lambda \,\mathrm{sgn}(\hat{\beta}_j)$	$\lambda \geq \frac{2}{n}\left\|X^\top Y\right\|_\infty$
$\frac{1}{n}\|Y - X\beta\|^2 + 2r\|\beta\|_1$	S3 (BRT), TD2	$X^\top X = nI$, $b = X^\top Y/n$: seuil r	$\frac{1}{n}X_j^\top(Y - X\hat{\beta}) = r \,\mathrm{sgn}(\hat{\beta}_j)$	$r \geq \frac{1}{n}\left\|X^\top Y\right\|_\infty$
$\frac{1}{n}\|y - X\beta\|^2 + 2\lambda\|\beta\|_1$	S4 (oracle rapide, preuve de la professeure)	$X^\top X = nI$, $b = X^\top y/n$: seuil λ	$\frac{1}{n}X_j^\top(y - X\hat{\beta}) = \lambda \,\mathrm{sgn}(\hat{\beta}_j)$	$\lambda \geq \frac{1}{n}\left\|X^\top y\right\|_\infty$
$\frac{1}{2}(a-b)^2 + \lambda\|a\|$ (une coordonnée)	S4 (diapo 46)	seuil λ : $\mathrm{sgn}(b)(\|b\| - \lambda)_+$	$b - a = \lambda \,\mathrm{sgn}(a)$	$\|b\| \leq \lambda$
$L_n(\beta) + \lambda\|\beta\|_1$, $L_n = -\frac{1}{n}\times$ log-vraisemblance (lien canonique)	S5 (GLM, Cours5 enrichi p. 27–28), TD3 ex. 2 et 3	pas de formule explicite	$\frac{1}{n}X_j^\top(y - \hat{\mu}) = \lambda \,\mathrm{sgn}(\hat{\beta}_j)$	$\lambda \geq \|\nabla L_n(0)\|_\infty = \left\|\frac{1}{n}X^\top(y - \mu(0))\right\|_\infty$ (sans constante) ; logistique : $\mu(0) = \frac{1}{2}\mathbf{1}$; Poisson : $\mu(0) = \mathbf{1}$
$-\ell(\beta) + \lambda\|\beta\|_1$, log-vraisemblance **non normalisée** (somme)	TD3 ex. 1 (Lasso logistique)	pas de formule explicite	$X_j^\top(y - \hat{\mu}) = \lambda \,\mathrm{sgn}(\hat{\beta}_j)$ (pas de $\frac{1}{n}$)	$\lambda \geq \left\|X^\top(y - \frac{1}{2}\mathbf{1})\right\|_\infty$ (logistique sans constante : $\hat{\mu}_i = \frac{1}{2}$ en $\beta = 0$)

Et pour le Ridge : $\|Y - X\beta\|^2 + \lambda\|\beta\|_2^2$ donne $(X^\top X + \lambda I)^{-1}X^\top Y$ (la formule de la diapo 11 et du TD1 ; $b_j/(1+\lambda)$ si $X^\top X = I$) ; $\frac{1}{n}\|Y - X\beta\|^2 + \lambda\|\beta\|_2^2$ (le critère tel qu'il est écrit sur la diapo 11) donne $(X^\top X + n\lambda I)^{-1}X^\top Y$; en une coordonnée, $\frac{1}{2}(a-b)^2 + \frac{\lambda}{2}a^2$ donne $\frac{b}{1+\lambda}$.

> **Réflexe — Avant tout calcul, recopiez le critère**
>
> Quand vous voyez un Lasso, un Ridge ou une variante → écrivez d'abord le critère exact (facteur devant le carré, facteur devant la pénalité), puis dérivez. Pour retrouver un facteur : en design orthonormé,

$\|Y - X\beta\|^2 = \|\beta - b\|^2 + \text{cte}$; la dérivée de $(\beta_j - b_j)^2 + \lambda\,|\beta_j|$ s'annule en $\beta_j = b_j - \frac{\lambda}{2}\operatorname{sgn}(\beta_j)$: le seuil est $\lambda/2$.

Les théorèmes et leurs hypothèses

« Énoncez le théorème » veut dire : le cadre, les hypothèses, l'estimateur avec sa convention et son λ, la conclusion avec ses constantes, et la probabilité. Les quatre colonnes de droite sont à savoir par cœur.

Résultat	Cadre et hypothèses	Estimateur, λ	Conclusion	Probabilité
Erreur des MCO → S1	$Y = X\beta^* + \varepsilon$, X déterministe, ε centré de covariance $\sigma^2 I_n$ (gaussien dans le cours)	moindres carrés	$\mathbb{E}\left\|X\hat{\beta}^{\mathrm{MC}} - X\beta^*\right\|_n^2 = \sigma^2\,\mathrm{rg}(X)/n$	en espérance
Identité de Cp → S1	même cadre ; un modèle m **fixé** (choisi sans regarder les données), de dimension d	MCO sur le modèle m	$\mathbb{E}\left\|X\hat{\beta}_m - X\beta^*\right\|_n^2 + \sigma^2 = \mathbb{E}\left\|Y - X\hat{\beta}_m\right\|_n^2 + \frac{2\sigma^2 d}{n}$	en espérance
Sélection de modèle → TD1	$Y = f^* + \varepsilon \in \mathbb{R}^n$, $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$; modèles S_m de dimension d_m, $\hat{f}_m = P_{S_m} Y$; poids $\Pi_m \in]0,1]$, $\sum_m \Pi_m = 1$; $K > 1$	$\hat{m} = \arg\min_m \{\left\|Y - \hat{f}_m\right\|^2 + \sigma^2 \mathrm{pen}(m)\}$, $\mathrm{pen}(m) = K\left(\sqrt{d_m} + \sqrt{2\log(1/\Pi_m)}\right)^2$	$\mathbb{E}\left\|\hat{f}_{\hat{m}} - f^*\right\|^2 \le C'_K \min_m \left\{\mathbb{E}\left\|\hat{f}_m - f^*\right\|^2 + \sigma^2 \log(1/\Pi_m) + \sigma^2\right\}$, C'_K ne dépendant que de K (notée C_K dans l'énoncé)	en espérance
Bickel–Ritov–Tsybakov → S3	$\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$; $\|X_j\|^2 = n$; $M(\beta^*) \le s$; RE $(s, 3)$, $\kappa = \kappa(s, 3)$; $\varphi_{\max}$ plus grande valeur propre de $X^\top X/n$	$\frac{1}{n}\|Y - X\beta\|^2 + 2r\|\beta\|_1$, $r = A\sigma\sqrt{\log p / n}$, $A > 2\sqrt{2}$	$\left\|\hat{\beta} - \beta^*\right\|_1 \le \frac{16A}{\kappa^2}\sigma s\sqrt{\frac{\log p}{n}}$; $\left\|X(\hat{\beta} - \beta^*)\right\|^2 \le \frac{16A^2}{\kappa^2}\sigma^2 s \log p$; $M(\hat{\beta}) \le \frac{64\varphi_{\max}}{\kappa^2} s$	$\ge 1 - p^{1 - A^2/8}$
Lemme du TD2 → TD2	bruit gaussien, $\mathrm{diag}(X^\top X/n) = 1$; ni RE ni parcimonie ; vrai **pour tout** $\beta \in \mathbb{R}^p$	même estimateur, même r, $A > 2\sqrt{2}$	$\left\|X\hat{\beta} - X\beta^*\right\|_n^2 + r\left\|\hat{\beta} - \beta\right\|_1 \le \|X\beta - X\beta^*\|_n^2 + 4r\sum_{j \in J(\beta)}\left|\hat{\beta}_j - \beta_j\right|$; $\left\|\frac{1}{n}X^\top(X\beta^* - X\hat{\beta})\right\|_\infty \le \frac{3r}{2}$; $M(\hat{\beta}) \le \frac{4\varphi_{\max}}{r^2}\left\|X\hat{\beta} - X\beta^*\right\|_n^2$	$\ge 1 - 2p^{1 - A^2/8}$

Résultat	Cadre et hypothèses	Estimateur, λ	Conclusion	Probabilité
Inégalité oracle lente → S4	$Y_i = f(Z_i) + \varepsilon_i$, $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$; dictionnaire de M fonctions $f_1, \dots, f_M$, $X_{ij} = f_j(Z_i)$, $f_\beta = X\beta$; colonnes normalisées $\|X_j\|^2 = n$; Θ convexe ; aucune hypothèse sur les corrélations	$\arg\min_{\beta\in\Theta}\{\frac{1}{n}\|y - f_\beta\|^2 + \lambda\|\beta\|_1\}$, $\lambda = 2\sigma\sqrt{2(x+\log M)/n}$, $x > 0$	$\frac{1}{n}\left\|f_{\hat\beta} - f\right\|^2 \le \inf_{\beta\in\Theta}\{\frac{1}{n}\|f_\beta - f\|^2 + 2\lambda\|\beta\|_1\}$	$\ge 1 - 2e^{-x}$
Inégalité oracle rapide → S4	idem + RE$(s, 3)$, $\kappa = \kappa(s, 3)$	$\arg\min_{\beta\in\Theta}\{\frac{1}{n}\|y - f_\beta\|^2 + 2\lambda\|\beta\|_1\}$, **même** λ	$\frac{1}{n}\left\|f_{\hat\beta} - f\right\|^2 \le \inf_{\beta\in\Theta,\,\|\beta\|_0\le s}\{\frac{1}{n}\|f_\beta - f\|^2 + \frac{18\sigma^2 s(x+\log M)}{\kappa^2 n}\}$	$\ge 1 - 2e^{-x}$
Normalité asymptotique de l'EMV d'un GLM → S5	p fixé, $n \to \infty$; information de Fisher moyenne $I_n(\beta) = -\mathbb{E}[\nabla^2 \ell_n(\beta)]$, $\ell_n = \frac{1}{n}\ell$ (= $\frac{1}{n}X^\top W(\beta)X$ avec le lien canonique), et $I_n(\beta^*) \to I(\beta^*) \succ 0$; plus identifiabilité et conditions de régularité	maximum de vraisemblance	$\hat\beta \to \beta^*$ en probabilité et $\sqrt{n}(\hat\beta - \beta^*) \to \mathcal{N}\big(0, I(\beta^*)^{-1}\big)$ en loi ; IC de Wald $\hat\beta_j \pm q_{1-\alpha/2}\sqrt{[I(\hat\beta)^{-1}]_{jj}/n}$	niveau $1-\alpha$ seulement asymptotiquement (Slutsky)
Lasso logistique, oracle lente → TD3	$Y_i \in \{0, 1\}$ indépendantes, $\mathbb{P}(Y_i = 1) = \pi(z_i^\top \beta_0)$, z_i déterministes ; $\max_{i,j}\|z_{ij}\| \le c$; aucune hypothèse sur les corrélations	$\arg\min\{\hat R(\beta) + \lambda\|\beta\|_1\}$, $\hat R(\beta) = \frac{1}{n}\sum_i[\log(1 + e^{z_i^\top\beta}) - Y_i z_i^\top\beta]$; $\lambda = A\sqrt{\log p/n}$, $A > \sqrt{2}\,c$	$R(\hat\beta) - R(\beta_0) \le \inf_\beta\{R(\beta) - R(\beta_0) + 2A\|\beta\|_1\sqrt{\log p/n}\}$, $R = \mathbb{E}\hat R$	$\ge 1 - 2p^{1-A^2/(2c^2)}$

À comprendre — La même mécanique partout À COMPRENDRE

Les théorèmes « avec grande probabilité » se démontrent tous de la même façon. On écrit l'inégalité de base (le minimiseur bat n'importe quel concurrent ; pour l'inégalité rapide, la professeure part du critère d'optimalité). Le bruit n'apparaît que dans un terme croisé, majoré par $\|\cdot\|_\infty \times \|\cdot\|_1$ (Hölder). On se place sur l'événement où ce terme est dominé par la pénalité. La probabilité de cet événement vient d'une queue gaussienne (ou de Hoeffding), combinée avec une borne de l'union sur les p (ou M) colonnes : c'est de là que vient le $\log p$ dans λ. Dans les versions « rapides », le bruit ne consomme que la moitié de la pénalité ; l'autre moitié met l'erreur dans le cône, puis RE fait passer de la norme ℓ_1 à la norme de prédiction.

Les preuves à savoir refaire

Pour chaque ligne : lisez le résultat, récitez l'idée clé (cachée en mode auto-test), puis refaites la preuve sur une feuille. La « fiche » contient la preuve express.

Résultat	L'idée clé, à réciter	Où la revoir
Hölder et vecteur parcimonieux : $\lvert a^\top b\rvert \le \lVert a\rVert_1 \lVert b\rVert_\infty$ et $\lVert v_J\rVert_1 \le \sqrt{\lvert J\rvert}\ \lVert v_J\rVert_2$	Hölder : $\left\lvert\sum_j a_j b_j\right\rvert \le \sum_j \lvert a_j\rvert\,\lvert b_j\rvert$, puis chaque $\lvert b_j\rvert \le \lVert b\rVert_\infty$. Parcimonieux : Cauchy–Schwarz entre $(1,\dots,1)\in\mathbb{R}^{\lvert J\rvert}$ et $(\lvert v_j\rvert)_{j\in J}$.	fiche · Rappels · S3
Matrice de Gram : $X^\top X$ symétrique positive, $\operatorname{Ker}(X^\top X)=\operatorname{Ker} X$, $\operatorname{rg}(X^\top X)=\operatorname{rg} X$	$v^\top X^\top X v = \lVert Xv\rVert^2 \ge 0$; si $X^\top X v=0$, alors $\lVert Xv\rVert^2 = v^\top X^\top X v = 0$, donc $Xv=0$; théorème du rang pour deux matrices à p colonnes.	fiche · Rappels
Espérance d'une forme quadratique : $\mathbb{E}[\varepsilon^\top M\varepsilon] = \sigma^2 \operatorname{tr} M$, et $\mathbb{E}\lVert P\varepsilon\rVert^2 = \sigma^2 \operatorname{rg} P$	Un nombre est sa propre trace : $\varepsilon^\top M\varepsilon = \operatorname{tr}(M\varepsilon\varepsilon^\top)$; la trace commute avec l'espérance et $\mathbb{E}[\varepsilon\varepsilon^\top]=\sigma^2 I_n$. Pour un projecteur, $P^\top P = P$ et $\operatorname{tr} P = \operatorname{rg} P$.	fiche · Rappels
Queue gaussienne (Chernoff) : $\mathbb{P}(Z\ge t)\le e^{-t^2/2}$, et $\mathbb{P}(\lvert Z\rvert\ge t)\le 2e^{-t^2/2}$	Markov appliqué à $e^{\theta Z}$, avec $\mathbb{E}[e^{\theta Z}]=e^{\theta^2/2}$ (compléter le carré) ; on optimise en $\theta=t$; la symétrie donne le facteur 2.	fiche · fiche TD2 · Rappels · TD2
Maximum de p gaussiennes : $\mathbb{P}\big(\max_j \lvert Z_j\rvert > \sqrt{2(\log p + x)}\big)\le 2e^{-x}$	Borne de l'union (aucune indépendance requise) puis queue gaussienne : $2p\,e^{-t^2/2}$; le choix $t^2 = 2(\log p + x)$ compense exactement le facteur p.	fiche · Rappels · S3
Décomposition biais–variance : $\mathbb{E}\left\lVert\hat\theta-\theta\right\rVert^2 = \left\lVert\mathbb{E}\hat\theta-\theta\right\rVert^2 + \mathbb{E}\left\lVert\hat\theta-\mathbb{E}\hat\theta\right\rVert^2$	Ajouter et retrancher $\mathbb{E}\hat\theta$, développer le carré ; le double produit est d'espérance nulle car $\mathbb{E}\hat\theta-\theta$ n'est pas aléatoire.	fiche · Rappels
Identités du score : $\mathbb{E}[s_\theta(Y)]=0$ et $I(\theta)=\mathbb{E}[s_\theta(Y)^2] = -\mathbb{E}[\partial_\theta^2 \log f_\theta(Y)]$	Dériver $\int f_\theta = 1$ sous l'intégrale, avec $\partial_\theta f_\theta = s_\theta f_\theta$; dériver encore $\int s_\theta f_\theta = 0$ (dérivée d'un produit).	fiche · Rappels · S5
Équations normales des MCO : $X^\top X\hat\beta = X^\top Y$, minimum global	Développer $\lVert Y-X\beta\rVert^2$, annuler le gradient $-2X^\top(Y-X\beta)$; la hessienne $2X^\top X$ est positive, donc gradient nul ⇔ minimum. Géométriquement : le résidu est orthogonal à $\operatorname{Im} X$.	fiche · S1
Erreur de prédiction des MCO : $\mathbb{E}\left\lVert X\hat\beta^{\mathrm{MC}} - X\beta^*\right\rVert_n^2 = \sigma^2 \operatorname{rg}(X)/n$	$X\hat\beta^{\mathrm{MC}} - X\beta^* = P\varepsilon$ (P projecteur sur $\operatorname{Im} X$, qui fixe $X\beta^*$), puis $\mathbb{E}\lVert P\varepsilon\rVert^2 = \sigma^2 \operatorname{tr} P = \sigma^2 \operatorname{rg} X$.	fiche · S1

Résultat	L'idée clé, à réciter	Où la revoir
Ridge : $(X^\top X + \lambda I_p)^{-1} X^\top Y$ est l'unique minimiseur de $\|Y - X\beta\|^2 + \lambda \|\beta\|^2$, $\lambda > 0$ (TD1, ex. 1 Q1)	Hessienne $2(X^\top X + \lambda I_p)$ définie positive (valeurs propres $\mu_j + \lambda \geq \lambda > 0$) : stricte convexité ; coercivité $f \geq \lambda \|\beta\|^2$; gradient nul.	fiche · TD1
Biais² et variance du Ridge dans la base propre (TD1, ex. 1 Q3–Q4)	$\mathbb{E}\hat{\beta}^R - \beta^* = -\lambda(X^\top X + \lambda I_p)^{-1}\beta^*$; l'écart à la moyenne est $A\varepsilon$, d'où une variance $\sigma^2 \operatorname{tr}(AA^\top)$; puis diagonaliser $X^\top X = PDP^\top$.	fiche · TD1
Identité d'optimisme (Cp/AIC), modèle fixé : en moyenne, erreur de test = erreur d'apprentissage $+ 2\sigma^2 d/n$ (en $\|\cdot\|_n^2$)	Même biais $\|(I-P)X\beta^*\|^2$ des deux côtés ; le bruit vaut $\sigma^2 \operatorname{tr}(I-P) = \sigma^2(n-d)$ en apprentissage et $\sigma^2 \operatorname{tr} P = \sigma^2 d$ en prédiction ; on soustrait.	fiche · S1
Forme contrainte du Ridge (TD1, ex. 1 Q2)	Le Ridge est admissible pour la boule de rayon $\left\|\hat{\beta}^R\right\|$; une solution contrainte ajuste au moins aussi bien et ne paie pas plus de pénalité, donc minimise le critère pénalisé ; on conclut par l'unicité.	fiche · TD1
Lasso : mêmes $X\hat{\beta}$ et même $\left\|\hat{\beta}\right\|_1$ pour toutes les solutions ; pénalisé = contraint (TD1, ex. 2)	Milieu de deux solutions + stricte convexité de $x \mapsto x^2$ ⇒ même ajustement ⇒ même f_0 ⇒ même pénalité (diviser par $\lambda > 0$). Puis, pour chaque inclusion, comparer les critères en une solution de l'autre problème, avec $M_\lambda = N_\lambda$.	fiche · TD1
Inégalité oracle pour la sélection de modèles (TD1, ex. 3)	Inégalité de base ; terme croisé du modèle fixé $= -\sigma^2 d_m$; terme croisé du modèle choisi : projection, Young, puis $\max \leq \sum(\cdot)_+$, concentration gaussienne et poids Π_m de somme 1 ; enfin absorber $a^{-1}R$ à gauche ($a = \frac{K+1}{2} > 1$).	fiche · TD1
Lasso = MAP avec a priori de Laplace de densité $\frac{a}{2}e^{-a\|\beta_j\|}$ (S2) : $\lambda_{\text{Lasso}} = 2\sigma^2 a$ pour le critère $\|Y - X\beta\|^2 + \lambda \|\beta\|_1$	$-\log(\text{vraisemblance gaussienne} \times \text{a priori de Laplace}) = \frac{1}{2\sigma^2}\|Y - X\beta\|^2 + a\|\beta\|_1 + C$, puis multiplier par $2\sigma^2$.	fiche · S2
Design orthogonal (S2) : critère $\|Y - X\beta\|^2 + \lambda \|\beta\|_1$, $X^\top X = I_p$, $b = X^\top Y$; $\hat{\beta}_j^L = \operatorname{sgn}(b_j)(\|b_j\| - \lambda/2)_+$	$X^\top X = I \Rightarrow \|Y - X\beta\|^2 = \sum_j (\beta_j - b_j)^2 + \text{cte}$: p problèmes à une variable ; trois cas selon le signe de β_j (ou $0 \in 2(\hat{\beta}_j - b_j) + \lambda\, \partial\, \|\cdot\|\, (\hat{\beta}_j)$).	fiche · S2
Conditions KKT du Lasso (S2, critère $\|Y - X\beta\|^2 + \lambda \|\beta\|_1$) : $2X_j^\top(Y - X\hat{\beta}) = \lambda \operatorname{sgn}(\hat{\beta}_j)$ si $\hat{\beta}_j \neq 0$, $2\left\|X_j^\top(Y - X\hat{\beta})\right\| \leq \lambda$ sinon	Pour chaque j : $0 \in -2X_j^\top(Y - X\hat{\beta}) + \lambda\, \partial\, \|\cdot\|\, (\hat{\beta}_j)$, avec $\partial\, \|\cdot\| = \{\operatorname{sgn}\}$ hors de 0 et $[-1, 1]$ en 0 ; critère convexe ⇒ conditions nécessaires et suffisantes.	fiche · S2

Résultat	L'idée clé, à réciter	Où la revoir
$\hat\beta = 0$ est solution $\Leftrightarrow \lambda \geq 2\left\|X^\top Y\right\|_\infty$ (S2, critère $\|Y - X\beta\|^2 + \lambda \|\beta\|_1$)	KKT en 0 : aucune variable active, le résidu vaut Y, il reste $2\left\|X_j^\top Y\right\| \leq \lambda$ pour tout j.	fiche · S2
Le chemin du Lasso est linéaire par morceaux (S2)	À A et s_A fixés, l'égalité KKT $2X_A^\top(Y - X_A\hat\beta_A) = \lambda s_A$ donne $\hat\beta_A = (X_A^\top X_A)^{-1}(X_A^\top Y - \frac{\lambda}{2}s_A)$, affine en λ ; coude quand une variable entre ou sort.	fiche · S2
Valeurs ajustées $X\hat\beta^L$ et norme $\left\|\hat\beta^L\right\|_1$ uniques pour $\lambda > 0$ (S2)	Milieu de deux solutions + identité $\left\|Y - \frac{u+v}{2}\right\|^2 = \frac{1}{2}\|Y-u\|^2 + \frac{1}{2}\|Y-v\|^2 - \frac{1}{4}\|u-v\|^2$: $F(\text{milieu}) \leq m - \frac{1}{4}\|u-v\|^2$, donc $u = v$, puis normes ℓ_1 égales.	fiche · S2
Inégalité de base du Lasso (BRT, étape 1) : $\frac{1}{n}\|X\delta\|^2 \leq \frac{2}{n}\varepsilon^\top X\delta + 2r(\|\beta^*\|_1 - \left\|\hat\beta^L\right\|_1)$	Critère$(\hat\beta^L) \leq$ critère(β^*) ; $Y - X\beta^* = \varepsilon$ et $Y - X\hat\beta^L = \varepsilon - X\delta$; on développe $\|\varepsilon - X\delta\|^2$ et $\frac{1}{n}\|\varepsilon\|^2$ se simplifie.	fiche · S3
Le cône sur $\mathcal{E}$: $\left\|\delta_{J_0^c}\right\|_1 \leq 3\|\delta_{J_0}\|_1$	Hölder + $\mathcal{E}$: bruit $\leq r\|\delta\|_1$; ajouter $r\|\delta\|_1$; découpage (termes hors support compensés, triangulaire inversée dessus) ⇒ $\frac{1}{n}\|X\delta\|^2 + r\|\delta\|_1 \leq 4r\|\delta_{J_0}\|_1$; $4 - 1 = 3$.	fiche · S3
Bornes (7) et (6) du théorème BRT	Sur le cône, $\|\delta_{J_0}\|_1 \leq \sqrt{s}\,\|\delta_{J_0}\|_2 \leq \sqrt{s}\,u/\kappa$ (RE) ⇒ $u^2 + r\|\delta\|_1 \leq cu$, $c = 4r\sqrt{s}/\kappa$; $u \leq c$ donne (7), $r\|\delta\|_1 \leq c^2$ donne (6).	fiche · S3
$\mathbb{P}(\mathcal{E}^c) \leq p^{1-A^2/8}$ pour $r = A\sigma\sqrt{\log p/n}$	$X_j^\top\varepsilon/(\sigma\sqrt{n}) \sim \mathcal{N}(0,1)$ (colonnes normalisées) ; seuil $\frac{A}{2}\sqrt{\log p}$; queue $e^{-t^2/2}$ donne $p^{-A^2/8}$; borne de l'union sur les p variables.	fiche · S3
Taille du support estimé : $M(\hat\beta^L) \leq 64\varphi_{\max}s/\kappa^2$	KKT (égalité $\pm r$) + $\mathcal{E}$ (bruit $\leq r/2$) ⇒ $\left\|\frac{1}{n}X_j^\top X\delta\right\| \geq r/2$ pour chaque variable sélectionnée ; somme des carrés $\leq \varphi_{\max}\frac{1}{n}\|X\delta\|^2 \leq \varphi_{\max}\cdot 16r^2s/\kappa^2$.	fiche · S3
Sous RE$(s,3)$, toute famille d'au plus $2s$ colonnes est libre	J = les s plus grosses coordonnées de δ : $\|\delta_{J^c}\|_1 \leq \|\delta_J\|_1$, donc δ est dans le cône ; RE donne $\|X\delta\|_2 \geq \kappa\sqrt{n}\,\|\delta_J\|_2 > 0$.	fiche · S3
Lemme du TD2 : (2) pour tout β, (3) et (4)	Base contre β ; sur $\mathcal{E}$, bruit $\leq r\left\|\hat\beta^L - \beta\right\|_1$; ajouter $r\left\|\hat\beta^L - \beta\right\|_1$; terme nul hors de $J(\beta)$, $\leq 2\left\|\hat\beta_j^L - \beta_j\right\|$ dessus. (3) : résidu (KKT, $\leq r$) moins bruit ($\leq r/2$). (4) : $r^2/4$ par variable sélectionnée, Rayleigh avec $XX^\top/n$.	fiche · TD2
Seuillage doux : $\arg\min_a\{\frac{1}{2}(a-b)^2 + \lambda\|a\|\} = \text{sgn}(b)(\|b\| - \lambda)_+$	Trois cas : $a > 0$ et $a < 0$ (dériver, puis vérifier que la solution a le bon signe), et $\|b\| \leq \lambda$ où la fonction décroît puis croît, d'où 0. En une ligne : $0 \in a - b + \lambda\,\partial\|a\|$.	fiche · S4

Résultat	L'idée clé, à réciter	Où la revoir
L'enveloppe convexe de $\mathbf{1}\{x \neq 0\}$ sur $[-1,1]$ est $\lvert x\rvert$	$\lvert x\rvert$ est un candidat ; tout h convexe sous l'indicatrice vérifie $h(0) \leq 0$ et $h(\pm 1) \leq 1$, et la corde entre 0 et ± 1 donne $h(x) \leq \lvert x\rvert$.	fiche · S4
$\partial \lvert\cdot\rvert (0) = [-1,1]$, puis $\partial \lVert u\rVert_1$ et $\partial \lVert\cdot\rVert_2 (0)$	$g \in \partial \lvert\cdot\rvert (0) \iff \lvert v\rvert \geq gv \; \forall v \iff \lvert g\rvert \leq 1$ (contre-exemple $v = \operatorname{sgn}(g)$) ; $\lVert\cdot\rVert_1$ est une somme de fonctions d'une coordonnée, d'où le produit des $\partial \lvert u_j\rvert$; pour $\lVert\cdot\rVert_2$ en 0 : Cauchy–Schwarz, puis $v = g$.	fiche · S4
Monotonie : $(u_1 - u_2)^\top (g_1 - g_2) \geq 0$	L'inégalité du sous-gradient en u_1 (au point u_2) et en u_2 (au point u_1), additionnées : les φ s'éliminent.	fiche · S4
Conditions KKT du Lasso (critère $\frac{1}{n}\lVert y - X\beta\rVert^2 + \lambda \lVert\beta\rVert_1$)	Règle de Fermat et règle de la somme : $0 \in -\frac{2}{n} X^\top (y - X\hat\beta) + \lambda\, \partial \left\lVert \hat\beta \right\rVert_1$, puis lecture coordonnée par coordonnée (égalité si $\hat\beta_j \neq 0$, inégalité sinon).	fiche · S4
RE$(s,1)$ ⇒ toute sous-matrice d'au plus $2s$ colonnes est de rang plein	Un $t \neq 0$ à au plus $2s$ coordonnées non nulles, avec J = ses s plus grandes coordonnées, est dans le cône $c_0 = 1$; RE donne alors $\lVert Xt\rVert > 0$.	fiche · S4
Inégalité oracle lente (pénalité $\lambda \lVert\beta\rVert_1$) : sur $\mathcal{A}$, $\left\lVert f_{\hat\beta} - f \right\rVert_n^2 \leq \lVert f_\beta - f\rVert_n^2 + 2\lambda \lVert\beta\rVert_1$ pour tout $\beta \in \Theta$	$F(\hat\beta) \leq F(\beta)$ et $y = f + \varepsilon$; terme croisé $2\sum_j (\hat\beta_j - \beta_j) V_j \leq \lambda \left\lVert \hat\beta - \beta \right\rVert_1$ sur $\mathcal{A} = \{\lvert V_j\rvert \leq \lambda/2 \; \forall j\}$; l'inégalité triangulaire fait disparaître $\lambda \left\lVert \hat\beta \right\rVert_1$; $V_j \sim \mathcal{N}(0, \sigma^2/n)$, queue gaussienne et borne de l'union : $\mathbb{P}(\mathcal{A}^c) \leq 2e^{-x}$.	fiche · S4
Inégalité oracle rapide (RE$(s,3)$, pénalité $2\lambda \lVert\beta\rVert_1$ avec le même λ) : constante 18	Critère d'optimalité, monotonie et polarisation (bonus $\left\lVert f_{\hat\beta} - f_\beta \right\rVert_n^2$) ; $g = \operatorname{sgn}(\beta) + h$ fait apparaître $-2\lambda \left\lVert \hat\beta_{J^c} \right\rVert_1$; deux cas, bruit $\leq \lambda$ (moitié de la pénalité) ⇒ cône $c_0 = 3$; RE, Cauchy–Schwarz et $ax \leq x^2 + \frac{a^2}{4}$: reste $\frac{9\lambda^2 s}{4\kappa^2} = \frac{18\sigma^2 s(x + \log M)}{\kappa^2 n}$.	fiche · S4
Moments de la famille exponentielle : $\mathbb{E}T(Y) = A'(\theta)$, $\operatorname{Var} T(Y) = A''(\theta)$	Score d'espérance nulle (dériver $\int f_\theta = 1$) et identité de Fisher (dériver une seconde fois), avec $\frac{\partial \ell}{\partial \theta} = T(y) - A'(\theta)$ et $\frac{\partial^2 \ell}{\partial \theta^2} = -A''(\theta)$. Ou bien : $A = \log Z$, $(\log Z)' = \mathbb{E}T$, $(\log Z)'' = \operatorname{Var} T$.	fiche · S5
Équations de vraisemblance d'un GLM ; $X^\top y = X^\top \mu$ avec le lien canonique	Chaîne $\beta \to \eta \to \mu \to \theta \to \ell$: $\frac{\partial \ell_i}{\partial \beta_j} = (y_i - \mu_i) \cdot \frac{1}{\operatorname{Var} Y_i} \cdot \frac{\partial \mu_i}{\partial \eta_i} \cdot x_{ij}$; avec le lien canonique, $\frac{\partial \mu_i}{\partial \eta_i} = A''(\theta_i) = \operatorname{Var} Y_i$ se simplifie.	fiche · S5
Convexité de $L_n = -\ell_n$ (canonique, p. 24) ; existence et unicité du Ridge logistique ; pas d'EMV en cas de séparation	$\nabla^2 L_n = \frac{1}{n}\sum_i A''(x_i^\top \beta)\, x_i x_i^\top$, donc $v^\top \nabla^2 L_n v = \frac{1}{n}\sum_i A''(x_i^\top \beta)(x_i^\top v)^2 \geq 0$ car $A'' = \operatorname{Var}$. Ridge : hessienne $\succeq 2\lambda I$ + coercivité ($-\ell_n \geq 0$). Séparation : $\ell_n(tb) \to 0 = \sup \ell_n$, jamais atteint.	fiche · TD3 · S5

Résultat	L'idée clé, à réciter	Où la revoir
IRLS : un pas de Newton est une régression par moindres carrés pondérés	$h^* = (X^\top W X)^{-1} X^\top (y-\mu)$, puis on factorise : $\beta_{k+1} = (X^\top W X)^{-1} X^\top W\big(X\beta_k + W^{-1}(y-\mu)\big) = (X^\top W X)^{-1} X^\top W z$.	fiche · S5
Intervalle de confiance asymptotique (lemme de Slutsky)	$\sqrt{n}\, I(\beta^*)^{1/2}(\hat\beta - \beta^*) \to \mathcal{N}(0, I_p)$; remplacer $I(\beta^*)$ par $I(\hat\beta)$ (consistance + continuité), conclure par Slutsky, puis isoler β^* dans $\lvert\cdot\rvert \le q_{1-\alpha/2}$.	fiche · S5
Régression logistique en codage ± 1 : perte, gradient, hessienne, convexité	$\sigma(-z) = 1-\sigma(z) \Rightarrow \mathbb{P}(Y=y \mid x) = \sigma(y\, x^\top\beta) \Rightarrow$ perte $f(z) = \log(1+e^{-z})$; $f' = -\sigma(-z)$, $f'' = \sigma(1-\sigma) \in \,]0, \tfrac14]$ $\Rightarrow 0 \preceq \nabla^2 \preceq \frac{1}{4n} X^\top X$.	fiche · S5
Conditions KKT d'un Lasso de GLM et $\lambda_{\max}$ (logistique, Poisson)	$0 \in \nabla L_n(\hat\beta) + \lambda\, \partial \left\lVert\hat\beta\right\rVert_1$ avec $\nabla L_n = \frac1n X^\top(\mu - y)$, lu coordonnée par coordonnée ; en $\hat\beta = 0$ seule l'inégalité reste : 0 est solution $\iff \lambda \ge \lVert\nabla L_n(0)\rVert_\infty$.	fiche · TD3 · S5
Inégalité oracle lente du Lasso logistique (TD3, exercice 2)	Inégalité de base avec $\hat R = R - \sum_j \beta_j V_j$; événement $\max_j \lvert V_j\rvert \le \lambda/2$ (Hoeffding avec $b_i - a_i \le c$, puis borne de l'union : $2p^{1-A^2/(2c^2)}$) ; Hölder + triangulaire $\Rightarrow$ reste $\frac{3\lambda}{2}\lVert\beta\rVert_1 \le 2\lambda\lVert\beta\rVert_1$.	fiche · TD3
Identité $\lVert Y - X\beta\rVert^2 = (\beta - \hat\beta^{\mathrm{MC}})^\top X^\top X(\beta - \hat\beta^{\mathrm{MC}}) + \left\lVert Y - X\hat\beta^{\mathrm{MC}}\right\rVert^2$	Ajouter et retrancher $X\hat\beta^{\mathrm{MC}}$; le terme croisé $2\hat r^\top X(\hat\beta^{\mathrm{MC}} - \beta)$ est nul car $X^\top \hat r = 0$ (équations normales). Pythagore.	fiche · S6
Bridge : convexe $\Leftrightarrow \gamma \ge 1$	$\gamma \ge 1$: $t \mapsto t^\gamma$ convexe et croissante sur $[0,\infty[$, composée avec $\lvert\cdot\rvert$, puis somme. $\gamma < 1$: e_1, e_2 dans la boule, leur milieu donne $2^{1-\gamma} > 1$.	fiche · S6
Règles orthonormées : Ridge, Lasso, $\ell 0$, LSLasso, relaxé, adaptatif	Découplage $\sum_j (\beta_j - b_j)^2 + \mathrm{cte}$; problème à une variable : Ridge, dérivée nulle ; Lasso, cas $\beta_j > 0$, $\beta_j < 0$, puis $\beta_j = 0 \Leftrightarrow \lvert b_j\rvert \le \lambda/2$; $\ell 0$: comparer λ et b_j^2 ; seuil remplacé par $\lambda\omega_j/2$ (adaptatif) ou $\delta\lambda/2$ sur $\hat S_\lambda$ (relaxé).	fiche · S6
Dantzig : $\left\lVert\hat\beta^D\right\rVert_1 \le \left\lVert\hat\beta^L\right\rVert_1$, et Dantzig = Lasso en design orthonormé	KKT $\Rightarrow \left\lVert 2X^\top(Y - X\hat\beta^L)\right\rVert_\infty \le \lambda$, donc $\hat\beta^L \in D_\lambda$, où $\hat\beta^D$ minimise $\lVert\cdot\rVert_1$. Orthonormé : D_λ est la boîte $\lvert\beta_j - b_j\rvert \le \lambda/2$; minimiser $\lvert\beta_j\rvert$ sur un intervalle donne le seuillage doux.	fiche · S6
Elastic net en design orthonormé : $\hat\beta_j^{e.n} = \mathrm{sgn}(b_j)(\lvert b_j\rvert - \lambda_1/2)_+/(1+\lambda_2)$	Regrouper les β^2, factoriser par $1+\lambda_2$, compléter le carré : Lasso à une variable de cible $b/(1+\lambda_2)$ et de paramètre $\lambda_1/(1+\lambda_2)$.	fiche · S6
Colonne dupliquée : infinité de solutions du Lasso ; partage égal de l'elastic net	Fusionner les deux copies ($\gamma_p + \gamma_{p+1}$) ne change pas l'ajustement et ne fait pas augmenter $\ell 1$ (inégalité triangulaire, égalité si même signe). Elastic net : $a^2 + (c-a)^2$ n'est minimal qu'en $a = c/2$.	fiche · S6 · partage

Résultat	L'idée clé, à réciter	Où la revoir
Group-Lasso : conditions de la diapo 87 et seuillage doux par groupe	$0 \in -2X_{(k)}^\top(Y - X\hat\beta) + \lambda\,\partial\,\|\cdot\|_2\,(\hat\beta_{(k)})$ bloc par bloc ; $\partial\,\|\cdot\|_2\,(0)$ = boule unité ⇒ bloc nul ssi $\|b_{(k)}\| \le \lambda/2$; sinon $\hat\beta_{(k)}$ a la direction de $b_{(k)}$ et $\|\hat\beta_{(k)}\| = \|b_{(k)}\| - \lambda/2$.	fiche · S6

Les pièges classiques

Les erreurs que l'on fait sous la pression de l'examen. Cachez la colonne de droite et dites pourquoi la phrase de gauche est fausse.

La phrase fausse (ou le geste risqué)	La bonne version
Appliquer une formule de seuil ou de KKT sans regarder la normalisation du critère.	Seuil λ ou $\lambda/2$, KKT avec ou sans facteur 2, λ ou $n\lambda$: écrivez d'abord le critère exact (voir les conventions).
« Quand $p > n$, on ne peut rien prédire. »	$\hat\beta^{\mathrm{MC}}$ n'est pas unique mais $X\hat\beta^{\mathrm{MC}} = PY$ l'est (les MCO interpolent toutefois : erreur $\sigma^2\,\mathrm{rg}(X)/n$, soit σ^2 si $\mathrm{rg}\,X = n$). Prédire $X\beta^*$ reste possible avec le Lasso, sans hypothèse sur les corrélations (inégalité oracle lente, si $\|\beta^*\|_1$ n'est pas trop grand) ; estimer β^* demande la parcimonie et une condition comme RE.
« La solution du Lasso est unique. »	Pas toujours (colonnes liées, par exemple deux colonnes identiques ; c'est possible dès que $p > n$). Mais, pour $\lambda > 0$, toutes les solutions ont le même ajustement $X\hat\beta$ et la même norme $\|\hat\beta\|_1$ (TD1).
« Le Ridge sélectionne des variables. »	Non : en design orthonormé, $b_j/(1+\lambda) \neq 0$ dès que $b_j \neq 0$. Il rétrécit tout, n'annule (presque) rien.
Choisir le modèle qui minimise l'erreur d'apprentissage.	Elle décroît toujours quand on ajoute des variables : pour un modèle fixé de dimension d, elle est optimiste de $2\sigma^2 d/n$ en moyenne (identité de Cp). D'où Cp/AIC, BIC, validation croisée.
Écrire la dérivée de $\|\beta_j\|$ en $\beta_j = 0$.	$\|\cdot\|$ n'est pas dérivable en 0 : $\partial\,|\cdot|\,(0) = [-1, 1]$. C'est ce coin qui crée les zéros exacts, et qui donne l'inégalité des KKT.
« RE, c'est $X^\top X/n$ inversible. »	RE ne demande $\|X\delta\| > 0$ que pour les $\delta \neq 0$ du cône (pour tout J_0 de taille $\le s$). Elle est compatible avec $p > n$: le noyau de X peut être non trivial s'il évite le cône.
« $\|\beta\|_0$ est une norme. »	$\|2\beta\|_0 = \|\beta\|_0$: ni homogène, ni convexe. D'où la difficulté combinatoire et la relaxation convexe en ℓ_1.

La phrase fausse (ou le geste risqué)	La bonne version
Énoncer BRT ou une inégalité oracle sans la probabilité.	Ce sont des résultats sur un événement : donnez λ (ou r), l'événement, et la probabilité (BRT : $1 - p^{1-A^2/8}$, ou $1 - 2p^{1-A^2/8}$ avec la queue du TD2 ; oracle lente et rapide : $1 - 2e^{-x}$; Lasso logistique : $1 - 2p^{1-A^2/(2c^2)}$).
Inégalité oracle rapide pour le Lasso pénalisé par $\lambda \|\beta\|_1$.	Dans la preuve de la professeure, l'estimateur est pénalisé par $2\lambda \|\beta\|_1$ avec le **même** λ que l'inégalité lente ; le reste vaut $\frac{9\lambda^2 s}{4\kappa^2} = \frac{18\sigma^2 s(x+\log M)}{\kappa^2 n}$.
$\mathbb{E}\|Z\|^2 = \operatorname{tr}\operatorname{Var} Z$ pour un vecteur Z non centré.	$\mathbb{E}\|Z\|^2 = \operatorname{tr}\operatorname{Var} Z + \|\mathbb{E}Z\|^2$ (c'est « biais² + variance »).
« L'intervalle de Wald est de niveau $1-\alpha$. »	Seulement asymptotiquement, à p fixé (normalité asymptotique + Slutsky) ; à n fini, le niveau réel peut être plus petit.
Mélanger les codages logistiques.	$y \in \{0,1\}$: perte $\log(1+e^\eta) - y\eta$. $\tilde{y} = 2y - 1 \in \{-1,1\}$: perte $\log(1+e^{-\tilde{y}\eta})$. C'est la même perte, écrite autrement.
Pénaliser la constante dans le Lasso d'un GLM.	La constante n'est pas pénalisée (Cours5 enrichi p. 27). $\lambda_{\max}$ se calcule alors au point « constante seule », où $\hat{\mu}_i = \bar{y}$: en logistique ($0 < \bar{y} < 1$), $\lambda_{\max} = \frac{1}{n}\left\|X^\top(y - \bar{y}\mathbf{1})\right\|_\infty$.
« La hessienne logistique est $\succeq 0$, donc le critère est fortement convexe. »	$W_{ii} = \pi_i(1-\pi_i) \to 0$ quand $\left\|x_i^\top \beta\right\| \to \infty$: pas de courbure minimale uniforme ($\inf W_{ii} = 0$).
LSLasso : réutiliser le λ choisi pour le Lasso seul.	La validation croisée doit porter sur toute la procédure (Lasso puis MCO sur le support).
« Le bridge avec $\gamma < 1$ se calcule comme le Lasso. »	Pour $\gamma < 1$ la pénalité n'est pas convexe : minima locaux, aucune garantie qu'un algorithme trouve le minimum global.

Le jour J

> **Méthode — En ouvrant un exercice**
>
> 1. **Écrivez le cadre** : le modèle, la convention exacte du critère, les hypothèses données (normalisation des colonnes, bruit, parcimonie, RE...).
> 2. **Reconnaissez le type d'exercice** dans le tableau ci-dessous et **annoncez la méthode** en une phrase avant de calculer. Si le calcul déraille, la démarche reste visible.
> 3. **Vérifiez sur un cas simple** : design orthonormé, $p = 1$, $\lambda = 0$ ou $\lambda \to \infty$.

On vous demande de…	Commencez par…
calculer un estimateur pénalisé en design orthonormé	$\|Y - X\beta\|^2 = \|\beta - b\|^2 + \text{cte}$ avec $b = X^\top Y$; découpler coordonnée par coordonnée (ou groupe par groupe) ; trois cas $\beta_j > 0$, $\beta_j < 0$, $\beta_j = 0$; vérifier la cohérence de chaque cas.

On vous demande de…	Commencez par…
montrer qu'un vecteur est solution, ou trouver le λ qui annule tout	Conditions KKT : $0 \in \partial F(\hat\beta)$, coordonnée par coordonnée (égalité si $\hat\beta_j \neq 0$, inégalité si $\hat\beta_j = 0$) ; le critère est convexe, donc elles suffisent. Pour $\lambda_{\max}$: les KKT au point $\hat\beta = 0$ (résidu Y, ou $y - \mu(0)$ pour un GLM).
borner une erreur de prédiction ou d'estimation	Inégalité de base ; $Y = X\beta^* + \varepsilon$ et développement ; Hölder sur le terme croisé et événement $\{\left\|\frac{2}{n}X^\top\varepsilon\right\|_\infty \leq \dots\}$; découpage selon le support (cône) ; RE ; $u^2 \leq cu \Rightarrow u \leq c$, ou Young.
minorer la probabilité de l'événement	Loi de $X_j^\top\varepsilon$ (gaussienne centrée de variance $\sigma^2\|X_j\|^2$), queue $\mathbb{P}(\lvert Z\rvert \geq z) \leq 2e^{-z^2/2}$ (TD2 ; la séance 3 utilise la version plus fine $e^{-z^2/2}$), ou Hoeffding si les Y_i sont bornées ; borne de l'union sur les p colonnes, puis réglage de λ.
calculer une espérance de norme au carré	Biais² + variance ; $\mathbb{E}[\varepsilon^\top M\varepsilon] = \sigma^2 \operatorname{tr} M$ (ε centré, $\operatorname{Cov}\varepsilon = \sigma^2 I_n$) ; pour un projecteur $\operatorname{tr} P = \operatorname{rg} P$.
traiter un GLM	Forme $\exp(\theta y - A(\theta) + B(y))$; A' = moyenne, A'' = variance ; lien canonique $(A')^{-1}$; log-vraisemblance ; avec le lien canonique, gradient $X^\top(y-\mu)$, hessienne $-X^\top W X$; ℓ concave, donc $-\ell$ convexe ; KKT si pénalisé.
passer de la forme pénalisée à la forme contrainte (ou l'inverse)	Comparer les critères en la solution de l'autre problème ; conclure par l'unicité (Ridge) ou par l'égalité des normes ℓ_1 de toutes les solutions (Lasso).
commenter un résultat	Vitesse (en $s\log p/n$, ou $\|\beta\|_1\sqrt{\log p/n}$), comparaison avec l'oracle $\sigma^2 s/n$, rôle de chaque hypothèse (κ, normalisation, parcimonie), probabilité, ce que le résultat ne dit pas (sélection exacte du support…).

Réflexe — Avant de rendre la copie

- ☐ Chaque énoncé de théorème a ses hypothèses, son λ et sa probabilité.
- ☐ Les signes des KKT ($Y - X\hat\beta$ et non $X\hat\beta - Y$) et les facteurs 2 sont cohérents avec le critère écrit en tête.
- ☐ Chaque hypothèse donnée par l'énoncé a servi quelque part (sinon, cherchez l'étape qui l'utilise).
- ☐ Les ordres de grandeur sont plausibles : un λ en $\sigma\sqrt{\log p/n}$; une erreur de prédiction $\frac{1}{n}\|X\delta\|^2$ en $s\log p/n$ (vitesse rapide) ou en $\|\beta\|_1\sqrt{\log p/n}$ (vitesse lente).

Statistiques avancées 3A (CentraleSupélec, S. Lemler) — guide d'étude pédagogique, version 2. Les numéros de diapositives renvoient aux fichiers Cours1.pdf … Cours6.pdf du dossier parent.