Statistiques avancées 3A · version pédagogique

Révision pour l'examen

Tout le cours (séances 1 à 6, TD1 à TD3) en un seul document, trié selon ce que vous devez en faire : savoir par cœur, savoir refaire, comprendre. Puis des questions pour vous tester.

Ce document en bref

Ce n'est pas un résumé de plus : chaque encadré vous dit **ce que vous devez en faire**.

- PAR CŒUR à réciter exactement : formule, définition, énoncé avec ses hypothèses, ses constantes et sa convention ;
- À SAVOIR REFAIRE calcul ou preuve à reproduire seul, sur une feuille blanche (une « preuve express » repliée vous guide) ;
- À COMPRENDRE idée à savoir expliquer en deux phrases, sans constante à retenir.

Chaque encadré renvoie (→ S1, → TD2…) à l'endroit du cours où tout est expliqué pas à pas : si une formule ne vous parle plus, c'est là qu'il faut aller.

Mode d'emploi : deux jours pour tout revoir

Le document suit l'ordre du cours :

- **Le cours en une page** et **les conventions** : la vue d'ensemble, et les facteurs 2 qui piègent tout le monde ;
- **parties 0 à 6** : la boîte à outils, puis une partie par séance (avec le TD qui lui est rattaché) ;
- **les théorèmes et leurs hypothèses**, **les preuves à savoir refaire**, **les pièges** : trois tableaux de synthèse pour la fin des révisions ;
- **l'auto-test** : des questions, partie par partie, réponses repliées ;
- **le jour J** : comment attaquer chaque type d'exercice.

Le plan sur deux jours

Quand	Quoi	Comment
Jour 1, séance 1 (≈ 3 h)	Le cours en une page, les conventions, parties 0, 1 et 2	Lisez chaque encadré, puis repassez la partie en mode auto-test : titre visible, réponse cachée, vous récitez.
Jour 1, séance 2 (≈ 3 h)	Parties 3 et 4 (théorème BRT, inégalités oracle)	Refaites sur papier les preuves express, sans regarder, puis comparez. Le squelette : inégalité de base → événement → cône → RE → $u^2 \leq cu$ (l'inégalité lente s'arrête à l'événement : une inégalité triangulaire conclut).
Jour 1, soir (≈ 1 h)	Auto-test des parties 0 à 4	Notez les questions ratées.
Jour 2, séance 1 (≈ 3 h)	Parties 5 et 6 (GLM, variantes du Lasso)	Refaites : moments de la famille exponentielle, gradient et hessienne de la logistique, chaque règle $b \mapsto \hat{\beta}$ en design orthonormé.

Quand	Quoi	Comment
Jour 2, séance 2 (≈ 2 h 30)	Théorèmes et hypothèses, preuves à savoir refaire, pièges	Récitez chaque ligne des tableaux. Refaites trois preuves complètes sans aide : le théorème BRT, l'inégalité oracle lente, KKT et seuillage doux.
Jour 2, soir (≈ 1 h)	Auto-test des parties 5 et 6, puis toutes les questions ratées la veille	Ce qui est raté deux fois : recopiez-le à la main sur une feuille à part.
Jour J (20 min)	Le cours en une page, les conventions, les pièges, le jour J, votre feuille à part	Rien de nouveau : on relit seulement.

Méthode — Apprendre par cœur sans y passer la nuit

1. **Comprendre d'abord.** Lisez le « Pour la retrouver » de chaque formule : une formule que vous savez reconstruire en deux lignes ne s'oublie pas le jour de l'examen.
2. **Se tester plutôt que relire.** Relire donne l'illusion de savoir. Le mode auto-test vous oblige à produire la réponse avant de la voir : c'est ce qui fixe la mémoire.
3. **Écrire à la main.** Les constantes (16, 64, $2\sqrt{2}$, $\frac{9}{4}$, 18…) et les signes des KKT se retiennent en les écrivant, pas en les lisant.
4. **Espacer.** Revoyez la même partie le soir, le lendemain, puis le jour J. Ce qui est réussi trois fois est acquis.
5. **S'appuyer sur un cas particulier.** Design orthonormé, $p = 1$, $\lambda = 0$: un cas simple redonne le bon facteur en dix secondes.

Le cours en une page

Si vous ne deviez relire qu'une section le matin de l'examen, ce serait celle-ci.

Le fil du cours

1. **Le point de départ (S1).** Modèle $Y = X\beta^* + \varepsilon$. Les moindres carrés ont une erreur de prédiction $\sigma^2 \operatorname{rg}(X)/n$: très bien si $p \ll n$, inutile dès que $p \geq n$ (typiquement $\operatorname{rg} X = n$, d'où une erreur σ^2). Si de plus $p > n$, $\operatorname{Ker} X \neq \{0\}$ et β^* n'est plus identifiable.

2. **Pénaliser (S1, TD1).** Le Ridge ($\lambda \|\beta\|_2^2$) stabilise mais ne sélectionne aucune variable. La pénalité ℓ_0 (Cp, AIC, BIC) sélectionne, mais impose d'explorer 2^p modèles. L'oracle qui connaîtrait le support ferait $\sigma^2 |\mathcal{A}^*|/n \leq \sigma^2 s/n$. Le TD1 démontre une vraie inégalité oracle pour la sélection de modèles.

3. **Le Lasso (S1, S2).** La pénalité $\lambda \|\beta\|_1$ est convexe, donc calculable, et produit des zéros exacts. En design orthogonal, le Lasso est un seuillage doux. En général, on le reconnaît à ses conditions KKT. Son chemin en λ est linéaire par morceaux (LARS).

4 **Pourquoi il marche (S3, TD2).** Sur l'événement $\mathcal{E} = \{\frac{2}{n}\left\|X^\top \varepsilon\right\|_\infty \le r\}$, de grande probabilité, l'erreur $\delta = \hat\beta - \beta^*$ vit dans un cône. Sous la condition RE$(s,3)$, le théorème de Bickel–Ritov–Tsybakov donne une erreur de prédiction $\frac{1}{n}\left\|X\delta\right\|^2$ en $\sigma^2 s \log p/n$ et une erreur $\left\|\delta\right\|_1$ en $\sigma s\sqrt{\log p/n}$: l'oracle $\sigma^2 s/n$, à une constante et un facteur $\log p$ près.

5 **Sans modèle exact (S4).** On approche une fonction f quelconque par un dictionnaire de M fonctions. L'inégalité oracle lente ne demande que des colonnes normalisées, aucune hypothèse sur leurs corrélations (reste $2\lambda\left\|\beta\right\|_1$). L'inégalité rapide suppose RE, et pénalise par $2\lambda\left\|\beta\right\|_1$ (reste $\propto s(x + \log M)/n$). Les outils : sous-différentiel et $0 \in \partial F$.

6 **Sortir du gaussien (S5, TD3).** Les GLM : famille exponentielle, lien canonique, log-vraisemblance concave, IRLS, normalité asymptotique, intervalles de Wald. Le Lasso d'un GLM (logistique, Poisson) a des KKT de même forme, avec le résidu $y - \hat\mu$ à la place de $Y - X\hat\beta$. Son inégalité oracle lente se prouve de la même façon, avec Hoeffding.

7 **Réparer les défauts du Lasso (S6).** Biais : LSLasso, relaxé, adaptatif. Variables corrélées et $p > n$: elastic net. Structure : fusionné, group-Lasso. Programme linéaire : Dantzig. Le bridge relie ℓ_0, Lasso et Ridge.

Les incontournables

Les formules qui reviennent partout. En mode auto-test, la colonne de droite est cachée.

Notion	Formule
Séance 1 — moindres carrés, Ridge, ℓ0 → partie 1	
Modèle	$Y = X\beta^* + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$, $X \in \mathbb{R}^{n\times p}$ déterministe ; $\left\|u\right\|_n^2 = \frac{1}{n}\left\|u\right\|^2$
Moindres carrés	$X^\top X\hat\beta = X^\top Y$; si $\operatorname{rg} X = p$: $\hat\beta^{\mathrm{MC}} = (X^\top X)^{-1}X^\top Y$; $X\hat\beta^{\mathrm{MC}} = PY$, P projection orthogonale sur $\operatorname{Im} X$
Erreur de prédiction des MCO	$\mathbb{E}\left\|X\hat\beta^{\mathrm{MC}} - X\beta^*\right\|_n^2 = \sigma^2 \operatorname{rg}(X)/n$
Ridge	critère $\left\|Y - X\beta\right\|^2 + \lambda\left\|\beta\right\|_2^2$: $\hat\beta^R = (X^\top X + \lambda I_p)^{-1}X^\top Y$, unique si $\lambda > 0$; dans la direction propre v_j de $X^\top X$ (valeur propre $\mu_j > 0$) : $v_j^\top\hat\beta^R = \frac{\mu_j}{\mu_j + \lambda}\, v_j^\top\hat\beta^{\mathrm{MC}}$
Pénalités ℓ0 (ajoutées à $\left\|Y - X\beta\right\|_n^2$)	Cp/AIC : $\frac{2\sigma^2\left\|\beta\right\|_0}{n}$; BIC : $\frac{\sigma^2\log(n)\left\|\beta\right\|_0}{n}$
Identité de Cp (modèle fixé de dimension d)	$\mathbb{E}\left\|X\hat\beta_m - X\beta^*\right\|_n^2 + \sigma^2 = \mathbb{E}\left\|Y - X\hat\beta_m\right\|_n^2 + \frac{2\sigma^2 d}{n}$
Oracle (MCO restreints au vrai support $\mathcal{A}^*$)	$X_{\mathcal{A}^*}$ de rang plein : $\mathbb{E}\left\|X\hat\beta^{MCR} - X\beta^*\right\|_n^2 = \sigma^2\left\|\mathcal{A}^*\right\|/n \le \sigma^2 s/n$
Séance 2 — le Lasso de près (critère $\left\|Y - X\beta\right\|^2 + \lambda\left\|\beta\right\|_1$) → partie 2	
Seuillage doux ($X^\top X = I$, $b = X^\top Y$)	$\hat\beta_j = \operatorname{sgn}(b_j)\big(\left|b_j\right| - \lambda/2\big)_+$

Notion	Formule
Conditions KKT	$2X_j^\top(Y-X\hat\beta)=\lambda\operatorname{sgn}(\hat\beta_j)$ si $\hat\beta_j\neq 0$; $\left\lvert 2X_j^\top(Y-X\hat\beta)\right\rvert\le\lambda$ si $\hat\beta_j=0$
Le Lasso est nul	$\hat\beta=0 \iff \lambda\ge\lambda_{\max}=2\left\lVert X^\top Y\right\rVert_\infty$
Séance 3 — cône, RE, BRT (critère $\frac{1}{n}\lVert Y-X\beta\rVert^2+2r\lVert\beta\rVert_1$, $\lVert X_j\rVert^2=n$) → partie 3	
Cône ($\delta=\hat\beta-\beta^*$, $J_0=J(\beta^*)$)	sur $\mathcal{E}=\{\frac{2}{n}\left\lVert X^\top\varepsilon\right\rVert_\infty\le r\}$: $\left\lVert\delta_{J_0^c}\right\rVert_1\le 3\lVert\delta_{J_0}\rVert_1$
Condition RE$(s,3)$	$\kappa(s,3)=\min_{\lvert J_0\rvert\le s}\ \min_{\delta\neq 0,\ \left\lVert\delta_{J_0^c}\right\rVert_1\le 3\left\lVert\delta_{J_0}\right\rVert_1}\dfrac{\lVert X\delta\rVert}{\sqrt{n}\,\lVert\delta_{J_0}\rVert}>0$
Théorème BRT	bruit $\mathcal{N}(0,\sigma^2 I_n)$, $M(\beta^*)\le s$, RE$(s,3)$, $\kappa=\kappa(s,3)$; $r=A\sigma\sqrt{\log p/n}$, $A>2\sqrt{2}$; avec probabilité $\ge 1-p^{1-A^2/8}$: $\left\lVert\hat\beta-\beta^*\right\rVert_1\le\frac{16A}{\kappa^2}\sigma s\sqrt{\frac{\log p}{n}}$, $\left\lVert X(\hat\beta-\beta^*)\right\rVert^2\le\frac{16A^2}{\kappa^2}\sigma^2 s\log p$, $M(\hat\beta)\le\frac{64\varphi_{\max}}{\kappa^2}s$
Séance 4 — outils convexes, inégalités oracle → partie 4	
Sous-gradient, optimalité	$g\in\partial\varphi(u)\iff\varphi(v)\ge\varphi(u)+g^\top(v-u)\ \forall v$; $\partial\lvert\cdot\rvert(0)=[-1,1]$; $\partial\lVert u\rVert_1=\{g:\ g_j=\operatorname{sgn}u_j$ si $u_j\neq 0,\ g_j\in[-1,1]$ sinon$\}$; u^* minimise φ convexe $\iff 0\in\partial\varphi(u^*)$; monotonie : $(u_1-u_2)^\top(g_1-g_2)\ge 0$
Seuillage doux, une coordonnée	$\arg\min_a\frac{1}{2}(a-b)^2+\lambda\lvert a\rvert=\operatorname{sgn}(b)(\lvert b\rvert-\lambda)_+$
Inégalité oracle lente	$\lVert X_j\rVert^2=n$; critère $\frac{1}{n}\lVert y-X\beta\rVert^2+\lambda\lVert\beta\rVert_1$ minimisé sur Θ convexe, $\lambda=2\sigma\sqrt{2(x+\log M)/n}$; avec probabilité $\ge 1-2e^{-x}$: $\frac{1}{n}\left\lVert f_{\hat\beta}-f\right\rVert^2\le\inf_{\beta\in\Theta}\{\frac{1}{n}\lVert f_\beta-f\rVert^2+2\lambda\lVert\beta\rVert_1\}$
Inégalité oracle rapide	+ RE$(s,3)$; critère $\frac{1}{n}\lVert y-X\beta\rVert^2+2\lambda\lVert\beta\rVert_1$, même λ ; avec probabilité $\ge 1-2e^{-x}$: $\frac{1}{n}\left\lVert f_{\hat\beta}-f\right\rVert^2\le\inf_{\beta\in\Theta,\ \lVert\beta\rVert_0\le s}\{\frac{1}{n}\lVert f_\beta-f\rVert^2+\frac{9\lambda^2 s}{4\kappa^2}\}$, et $\frac{9\lambda^2 s}{4\kappa^2}=\frac{18\sigma^2 s(x+\log M)}{\kappa^2 n}$
Séance 5 — modèles linéaires généralisés → partie 5	
Famille exponentielle	$f_\theta(y)=\exp\big(\theta T(y)-A(\theta)+B(y)\big)$; $\mathbb{E}T(Y)=A'(\theta)$, $\operatorname{Var}T(Y)=A''(\theta)$
Lien canonique	$\theta_i=g(\mu_i)=x_i^\top\beta$; avec $T(y)=y$: $g=(A')^{-1}$; Bernoulli $g(\mu)=\log\frac{\mu}{1-\mu}$, Poisson $g(\mu)=\log\mu$, gaussienne $g(\mu)=\mu$
Gradient, hessienne (lien canonique)	$\nabla\ell=X^\top(y-\mu)$, $\nabla^2\ell=-X^\top WX$, $W=\operatorname{diag}\big(A''(\theta_i)\big)$; équations $X^\top y=X^\top\mu$
IRLS (Newton)	$\beta_{k+1}=(X^\top WX)^{-1}X^\top Wz$, $z=X\beta_k+W^{-1}(y-\mu)$
Asymptotique, intervalle de Wald	p fixé, information moyenne $I_n(\beta^*)\to I(\beta^*)\succ 0$: $\sqrt{n}(\hat\beta-\beta^*)\to\mathcal{N}\big(0,I(\beta^*)^{-1}\big)$; $\hat\beta_j\pm q_{1-\alpha/2}\sqrt{[I(\hat\beta)^{-1}]_{jj}/n}$, de niveau asymptotique $1-\alpha$
Logistique, codage $y_i\in\{-1,1\}$	$L_n(\beta)=\frac{1}{n}\sum_i\log\big(1+e^{-y_i x_i^\top\beta}\big)$; $\nabla^2 L_n(\beta)=\frac{1}{n}X^\top WX$, poids $W_{ii}=\pi_i(1-\pi_i)\in\,]0,\frac{1}{4}]$, $\pi_i=\sigma(x_i^\top\beta)$

Notion	Formule
KKT du Lasso d'un GLM (critère $L_n(\beta) + \lambda \|\beta\|_1$, $L_n = -\frac{1}{n}\ell$, lien canonique)	$\frac{1}{n} X_j^\top (y - \hat{\mu}) = \lambda \operatorname{sgn}(\hat{\beta}_j)$ si $\hat{\beta}_j \neq 0$; $\left\|\frac{1}{n} X_j^\top (y - \hat{\mu})\right\| \leq \lambda$ sinon ; $\hat{\mu}_i = A'(x_i^\top \hat{\beta})$
Séance 6 — variantes (critère $\|Y - X\beta\|^2 +$ pénalité, $X^\top X = I$, $b = X^\top Y$) → partie 6	
LSLasso (Lasso, puis MCO sur le support choisi)	seuillage dur : $b_j \, \mathbf{1}\{\|b_j\| > \lambda/2\}$
Lasso relaxé (pénalité $\delta\lambda \|\beta\|_1$ sur le support du Lasso, $\delta \in [0,1]$)	$\left(b_j - \operatorname{sgn}(b_j)\, \delta\lambda/2\right) \mathbf{1}\{\|b_j\| > \lambda/2\}$
Lasso adaptatif (pénalité $\lambda \sum_j \|\beta_j\| / \left\|\tilde{\beta}_j\right\|$, avec $\tilde{\beta} = b$)	$\operatorname{sgn}(b_j)\left(\|b_j\| - \dfrac{\lambda}{2\,\|b_j\|}\right)_+$
Elastic net (pénalité $\lambda_1 \|\beta\|_1 + \lambda_2 \|\beta\|_2^2$)	$\dfrac{\operatorname{sgn}(b_j)(\|b_j\| - \lambda_1/2)_+}{1 + \lambda_2}$
Group-Lasso (pénalité $\lambda \sum_k \left\|\beta_{(k)}\right\|_2$)	$\left(1 - \dfrac{\lambda}{2\left\|b_{(k)}\right\|_2}\right)_+ b_{(k)}$

Les conventions : la source n°1 d'erreurs

Multiplier un critère par une constante positive ne change pas son minimiseur. **Mais** quand il y a une pénalité, la constante se reporte sur λ : le seuil, les conditions KKT et $\lambda_{\max}$ changent d'un facteur 2 ou n. Le cours utilise plusieurs normalisations, toutes réunies ici.

Critère	Où	Lasso en design orthonormé	KKT pour $\hat{\beta}_j \neq 0$	$\hat{\beta} = 0$ dès que
$\|Y - X\beta\|^2 + \lambda \|\beta\|_1$	S2 (diapos 26–27), S6, TD1	$X^\top X = I$, $b = X^\top Y$: seuil $\lambda/2$, $\operatorname{sgn}(b_j)(\|b_j\| - \lambda/2)_+$	$2X_j^\top (Y - X\hat{\beta}) = \lambda \operatorname{sgn}(\hat{\beta}_j)$	$\lambda \geq 2 \left\|X^\top Y\right\|_\infty$
$\frac{1}{n}\|Y - X\beta\|^2 + \lambda \|\beta\|_1$	S1 (diapo 23, écrit $\|Y - X\beta\|_n^2 + \lambda \|\beta\|_1$), S4 (oracle lente)	$X^\top X = nI$, $b = X^\top Y/n$: seuil $\lambda/2$	$\frac{2}{n} X_j^\top (Y - X\hat{\beta}) = \lambda \operatorname{sgn}(\hat{\beta}_j)$	$\lambda \geq \frac{2}{n} \left\|X^\top Y\right\|_\infty$
$\frac{1}{n}\|Y - X\beta\|^2 + 2r \|\beta\|_1$	S3 (BRT), TD2	$X^\top X = nI$, $b = X^\top Y/n$: seuil r	$\frac{1}{n} X_j^\top (Y - X\hat{\beta}) = r \operatorname{sgn}(\hat{\beta}_j)$	$r \geq \frac{1}{n} \left\|X^\top Y\right\|_\infty$

Critère	Où	Lasso en design orthonormé	KKT pour $\hat\beta_j \neq 0$	$\hat\beta = 0$ dès que
$\frac{1}{n}\|y - X\beta\|^2 + 2\lambda\|\beta\|_1$	S4 (oracle rapide, preuve de la professeure)	$X^\top X = nI$, $b = X^\top y/n$: seuil λ	$\frac{1}{n}X_j^\top(y - X\hat\beta) = \lambda\,\mathrm{sgn}(\hat\beta_j)$	$\lambda \geq \frac{1}{n}\|X^\top y\|_\infty$
$\frac{1}{2}(a-b)^2 + \lambda\|a\|$ (une coordonnée)	S4 (diapo 46)	seuil λ : $\mathrm{sgn}(b)(\|b\| - \lambda)_+$	$b - a = \lambda\,\mathrm{sgn}(a)$	$\|b\| \leq \lambda$
$L_n(\beta) + \lambda\|\beta\|_1$, $L_n = -\frac{1}{n}\times$ log-vraisemblance (lien canonique)	S5 (GLM, Cours5 enrichi p. 27–28), TD3 ex. 2 et 3	pas de formule explicite	$\frac{1}{n}X_j^\top(y - \hat\mu) = \lambda\,\mathrm{sgn}(\hat\beta_j)$	$\lambda \geq \|\nabla L_n(0)\|_\infty = \|\frac{1}{n}X^\top(y - \mu(0))\|_\infty$ (sans constante) ; logistique : $\mu(0) = \frac{1}{2}\mathbf{1}$; Poisson : $\mu(0) = \mathbf{1}$
$-\ell(\beta) + \lambda\|\beta\|_1$, log-vraisemblance **non normalisée** (somme)	TD3 ex. 1 (Lasso logistique)	pas de formule explicite	$X_j^\top(y - \hat\mu) = \lambda\,\mathrm{sgn}(\hat\beta_j)$ (pas de $\frac{1}{n}$)	$\lambda \geq \|X^\top(y - \frac{1}{2}\mathbf{1})\|_\infty$ (logistique sans constante : $\hat\mu_i = \frac{1}{2}$ en $\beta = 0$)

Et pour le Ridge : $\|Y - X\beta\|^2 + \lambda\|\beta\|_2^2$ donne $(X^\top X + \lambda I)^{-1}X^\top Y$ (la formule de la diapo 11 et du TD1 ; $b_j/(1+\lambda)$ si $X^\top X = I$) ; $\frac{1}{n}\|Y - X\beta\|^2 + \lambda\|\beta\|_2^2$ (le critère tel qu'il est écrit sur la diapo 11) donne $(X^\top X + n\lambda I)^{-1}X^\top Y$; en une coordonnée, $\frac{1}{2}(a-b)^2 + \frac{\lambda}{2}a^2$ donne $\frac{b}{1+\lambda}$.

Réflexe — Avant tout calcul, recopiez le critère

Quand vous voyez un Lasso, un Ridge ou une variante → écrivez d'abord le critère exact (facteur devant le carré, facteur devant la pénalité), puis dérivez. Pour retrouver un facteur : en design orthonormé, $\|Y - X\beta\|^2 = \|\beta - b\|^2 + \mathrm{cte}$; la dérivée de $(\beta_j - b_j)^2 + \lambda|\beta_j|$ s'annule en $\beta_j = b_j - \frac{\lambda}{2}\mathrm{sgn}(\beta_j)$: le seuil est $\lambda/2$.

0. La boîte à outils : les rappels qui servent dans les preuves

→ Rappels

L'essentiel de la boîte à outils en 5 lignes

- **Changer de norme** : Hölder $|a^\top b| \leq \|a\|_1\|b\|_\infty$ sépare le bruit de l'erreur ; $\|v\|_1 \leq \sqrt{k}\|v\|_2$ (au plus k coordonnées non nulles) fait entrer la parcimonie s dans les bornes.
- **Moindres carrés = projection**, et « chaque dimension coûte σ^2 » : $\mathbb{E}[\varepsilon^\top M\varepsilon] = \sigma^2\,\mathrm{tr}\,M$ et $\mathrm{tr}\,P = \mathrm{rg}\,P$.
- **Le $\log p$ du cours** : $X_j^\top\varepsilon \sim \mathcal{N}(0, \sigma^2\|X_j\|^2)$, queue gaussienne en $e^{-t^2/2}$, borne de l'union : pour p gaussiennes standard (indépendantes ou non), $\max_j|Z_j|$ reste sous $\sqrt{2(\log p + x)}$ avec probabilité au moins $1 - 2e^{-x}$.
- **Optimisation** : convexe ⇒ un point critique est un minimum global ; strictement convexe ⇒ au plus un minimiseur ; continue et coercive ⇒ un minimiseur existe.

- **Statistique** : risque = biais² + variance ; information de Fisher = moins l'espérance de la hessienne de la log-vraisemblance ; pour n observations i.i.d., l'EMV est asymptotiquement $\mathcal{N}\big(\theta, (nI(\theta))^{-1}\big)$, avec $I(\theta)$ l'information d'*une* observation, et Slutsky permet de remplacer $I(\theta)$ par $I(\hat{\theta})$.

Normes et inégalités entre normes

Définition — Les quatre « normes » du cours PAR CŒUR → Rappels

Pour $v \in \mathbb{R}^p$:

$$\|v\|_0 = \#\{j : v_j \neq 0\}, \qquad \|v\|_1 = \sum_{j=1}^{p} |v_j|,$$

$$\|v\|_2 = \Big(\sum_{j=1}^{p} v_j^2\Big)^{1/2}, \qquad \|v\|_\infty = \max_{1\le j\le p} |v_j|.$$

Sans indice, $\|v\| = \|v\|_2$, et $\|v\|_2^2 = v^\top v$. $\|\cdot\|_0$ n'est **pas** une norme : $\|2v\|_0 = \|v\|_0$ (ni homogène, ni convexe).

Pour la retrouver : $v = (3, -4, 0)$ donne $\|v\|_0 = 2$, $\|v\|_1 = 7$, $\|v\|_2 = 5$, $\|v\|_\infty = 4$. Trois d'entre elles sont des pénalités du cours : ℓ_0 (Cp, AIC, BIC), ℓ_1 (Lasso), ℓ_2^2 (Ridge) ; ℓ_∞ mesure le bruit, $\big\|X^\top \varepsilon\big\|_\infty$.

Théorème — Cauchy–Schwarz, Hölder, vecteur parcimonieux PAR CŒUR À SAVOIR REFAIRE

→ Rappels

1. Cauchy–Schwarz : $\big|a^\top b\big| \le \|a\|_2 \, \|b\|_2$.
2. Hölder (ℓ_1–ℓ_∞) : $\big|a^\top b\big| \le \|a\|_1 \, \|b\|_\infty$.
3. Si v a au plus k coordonnées non nulles : $\|v\|_1 \le \sqrt{k}\, \|v\|_2$. Forme utilisée en S3–S4 : pour tout ensemble d'indices J, $\|v_J\|_1 \le \sqrt{|J|}\, \|v_J\|_2$ (v_J garde les coordonnées de v dans J et met les autres à 0). Et $\|v\|_1 \le \sqrt{p}\, \|v\|_2$ pour tout $v \in \mathbb{R}^p$.
4. Toujours : $\|v\|_\infty \le \|v\|_2 \le \|v\|_1$.
5. Triangulaire inversée : $\|a\| - \|b\| \le \|a - b\|$.

L'idée : Hölder = majorer chaque $|b_j|$ par le plus grand d'entre eux ; l'inégalité parcimonieuse = Cauchy–Schwarz contre le vecteur $(1, \dots, 1)$ restreint au support. Égalité quand v a exactement k coordonnées non nulles, toutes de même valeur absolue.

Preuve express

1. $$\big|a^\top b\big| \le \sum_j |a_j|\, |b_j| \le \Big(\max_k |b_k|\Big) \sum_j |a_j| = \|a\|_1 \, \|b\|_\infty$$

   ↳ inégalité triangulaire pour une somme, puis chaque $|b_j|$ est au plus le maximum : c'est Hölder

2. $$\|v\|_1 = \sum_{j\in S} 1 \cdot |v_j| \le \sqrt{|S|}\, \Big(\sum_{j\in S} v_j^2\Big)^{1/2} \le \sqrt{k}\, \|v\|_2$$

   ↳ S = indices où $v_j \neq 0$, avec $|S| \le k$; Cauchy–Schwarz entre $(1, \dots, 1)$ et $(|v_j|)_{j\in S}$

3 $$\|a\| = \|(a-b)+b\| \leq \|a-b\| + \|b\|$$

↳ inégalité triangulaire : on obtient la triangulaire inversée

Réflexe — bruit × erreur, puis ℓ1 → ℓ2

Quand vous voyez un produit scalaire « bruit × erreur » $\varepsilon^\top X\delta = (X^\top\varepsilon)^\top\delta$ → Hölder : $\leq \left\|X^\top\varepsilon\right\|_\infty \|\delta\|_1$. La partie aléatoire devient un maximum (contrôlable), l'erreur une norme ℓ_1. Quand vous devez passer de $\|\delta_J\|_1$ à $\|\delta_J\|_2$ sur un support de taille s → facteur $\sqrt{s}$. Où : S3 · étape 2, S3 · étape 3, S4 · oracle lente.

Algèbre linéaire : rang, matrice de Gram, valeurs propres

Théorème — Rang, noyau et grande dimension PAR CŒUR → Rappels

$\operatorname{Im} X = \{X\beta : \beta \in \mathbb{R}^p\} \subset \mathbb{R}^n$, $\operatorname{Ker} X = \{\beta : X\beta = 0\}$, $\operatorname{rg} X = \dim \operatorname{Im} X \leq \min(n,p)$. Théorème du rang : $\operatorname{rg} X + \dim \operatorname{Ker} X = p$.

Si $p > n$: $\dim \operatorname{Ker} X \geq p - n \geq 1$; pour $v \in \operatorname{Ker} X$, $v \neq 0$, on a $X(\beta + tv) = X\beta$ pour tout t : β n'est **pas identifiable**.

Pour la retrouver : « $p > n$ » **entraîne** « noyau non trivial », qui équivaut à « β non identifiable » et à « $X^\top X$ non inversible ». La réciproque est fausse : deux colonnes égales rendent le noyau non trivial même si $p \leq n$. Exemple : $X = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{pmatrix}$, $v = (1,1,-1) \in \operatorname{Ker} X$.

Théorème — Les quatre propriétés de la matrice de Gram PAR CŒUR À SAVOIR REFAIRE → Rappels

$(X^\top X)_{jk} = X_j^\top X_k$; version normalisée des diapos : $\Psi_n = X^\top X/n$ (diagonale égale à 1 si $\|X_j\|^2 = n$).

1. $X^\top X$ est symétrique.
2. Elle est positive : $v^\top X^\top X v = \|Xv\|^2 \geq 0$.
3. $\operatorname{Ker}(X^\top X) = \operatorname{Ker} X$, donc $\operatorname{rg}(X^\top X) = \operatorname{rg} X$.
4. $X^\top X$ inversible $\iff$ $\operatorname{rg} X = p$ $\iff$ colonnes linéairement indépendantes ; impossible si $p > n$.

L'idée : tout repose sur $v^\top X^\top X v = \|Xv\|^2$. Le même argument montre que $X^\top W X$ (W diagonale positive) est positive : c'est la convexité des GLM en séance 5.

Preuve express

1 $$v^\top X^\top X v = (Xv)^\top (Xv) = \|Xv\|^2 \geq 0$$

↳ $(Xv)^\top = v^\top X^\top$: propriété 2

2 $Xv = 0 \Rightarrow X^\top X v = 0$; et $X^\top X v = 0 \Rightarrow \|Xv\|^2 = v^\top X^\top X v = 0 \Rightarrow Xv = 0$.
↳ les deux inclusions donnent $\operatorname{Ker} X^\top X = \operatorname{Ker} X$: propriété 3

3 $\operatorname{rg}(X^\top X) = p - \dim \operatorname{Ker}(X^\top X) = p - \dim \operatorname{Ker} X = \operatorname{rg} X \leq n$.
↳ théorème du rang pour les deux matrices (toutes deux à p colonnes) ; une matrice $p \times p$ est inversible ssi son rang vaut p : propriété 4

Théorème — Théorème spectral, matrices positives, Rayleigh, conditionnement PAR CŒUR

→ Rappels

- A symétrique $\Rightarrow A = VDV^\top$ avec V orthogonale (ses colonnes v_j : base orthonormée de vecteurs propres) et $D = \mathrm{diag}(\mu_1, \ldots, \mu_p)$ réelle.
- A inversible $\iff$ aucun μ_j nul ; A^{-1} a les valeurs propres $1/\mu_j$; $A + \lambda I$ a les **mêmes** vecteurs propres et les valeurs propres $\mu_j + \lambda$.
- Semi-définie positive ($v^\top A v \geq 0$ pour tout v) $\iff$ tous les $\mu_j \geq 0$; définie positive ($v^\top A v > 0$ pour tout $v \neq 0$) $\iff$ tous les $\mu_j > 0$.
- Rayleigh : pour tout $v \in \mathbb{R}^p$, $\mu_{\min} \|v\|^2 \leq v^\top A v \leq \mu_{\max} \|v\|^2$.
- Conditionnement (définie positive) : $\mathrm{cond}(A) = \mu_{\max}/\mu_{\min}$.

Pour la retrouver : dans la base des v_j, A multiplie la coordonnée j par μ_j. Avec $v = \sum_j c_j v_j$: $v^\top A v = \sum_j \mu_j c_j^2$ et $\|v\|^2 = \sum_j c_j^2$, ce qui donne Rayleigh en une ligne.

À comprendre — Petite valeur propre, grande variance À COMPRENDRE → S1

Une petite valeur propre μ_j de $X^\top X$ désigne une direction v_j de β que les données voient mal : la variance des moindres carrés dans cette direction vaut σ^2/μ_j. Le Ridge remplace μ_j par $\mu_j + \lambda$: il décale toutes les valeurs propres de λ. Exemple : deux variables normalisées de corrélation 0,99 donnent Ψ de valeurs propres 1,99 et 0,01, soit un conditionnement de 199.

Projection orthogonale et trace

Théorème — Projecteur orthogonal PAR CŒUR → Rappels

- P est un projecteur orthogonal si $P^2 = P$ et $P^\top = P$. Si $\mathrm{rg}\, X = p$, le projecteur sur $\mathrm{Im}\, X$ est la « matrice chapeau » $P = X(X^\top X)^{-1}X^\top$, et $X\hat{\beta}^{\mathrm{MC}} = PY$.
- $I - P$ est le projecteur sur l'orthogonal de $\mathrm{Im}\, X$, et $P(I-P) = 0$; Pythagore : $\|Y\|^2 = \|PY\|^2 + \|(I-P)Y\|^2$.
- PY est le point de $\mathrm{Im}\, X$ le plus proche de Y.
- Les valeurs propres de P valent 0 ou 1 ; le nombre de 1 est $\mathrm{rg}\, P$.

Pour la retrouver : dans $P^2 = X(X^\top X)^{-1}X^\top X(X^\top X)^{-1}X^\top$, le milieu $X^\top X(X^\top X)^{-1}$ vaut I_p. Valeurs propres : $Pv = \mu v$ et $P^2 = P$ donnent $\mu^2 = \mu$. Exemple : $X = \mathbf{1}$ donne $P = \frac{1}{n}\mathbf{1}\mathbf{1}^\top$, qui remplace chaque coordonnée par la moyenne.

Théorème — Trace : cyclicité, trace d'un projecteur PAR CŒUR À SAVOIR REFAIRE → Rappels

- $\mathrm{tr}\, A = \sum_i A_{ii}$, linéaire ; **cyclicité** : $\mathrm{tr}(AB) = \mathrm{tr}(BA)$, même si A est $n \times p$ et B est $p \times n$.
- $\mathrm{tr}\, A = \sum_j \mu_j$ pour A symétrique ; pour un projecteur orthogonal, $\mathrm{tr}\, P = \mathrm{rg}\, P$.
- Un nombre est sa propre trace : $\varepsilon^\top M \varepsilon = \mathrm{tr}(M\varepsilon\varepsilon^\top)$.

Vérification à connaître : $\mathrm{tr}\left(X(X^\top X)^{-1}X^\top\right) = \mathrm{tr}\left((X^\top X)^{-1}X^\top X\right) = \mathrm{tr}\, I_p = p$.

Preuve express

1. $$\operatorname{tr}(AB) = \sum_i \sum_k A_{ik} B_{ki} = \sum_k \sum_i B_{ki} A_{ik} = \operatorname{tr}(BA)$$
   ↳ on écrit le produit matriciel, puis on échange les deux sommes

2. $$\operatorname{tr} A = \operatorname{tr}(VDV^\top) = \operatorname{tr}(DV^\top V) = \operatorname{tr} D = \sum_j \mu_j$$
   ↳ théorème spectral, cyclicité, puis $V^\top V = I$

3. $\operatorname{tr} P =$ nombre de valeurs propres égales à $1 = \operatorname{rg} P$.
   ↳ les valeurs propres d'un projecteur valent 0 ou 1

Réflexe — l'espérance d'un carré de norme d'un bruit

Quand vous voyez $\mathbb{E}\,\|A\varepsilon\|^2$ ou $\mathbb{E}\,\|P\varepsilon\|^2$ → « un nombre est sa propre trace » : $\mathbb{E}\,\|A\varepsilon\|^2 = \sigma^2 \operatorname{tr}(A^\top A)$, et pour un projecteur $\sigma^2 \times$(dimension). Où : S1 · erreur des MCO, S1 · identité de Cp, S1 · oracle.

Dériver et optimiser : gradient, convexité, existence, Lagrange, Newton

Formules — Gradient et hessienne PAR CŒUR → Rappels

$$\begin{aligned}
\nabla_\beta (a^\top \beta) &= a, \\
\nabla_\beta (\beta^\top A \beta) &= (A + A^\top)\beta, \\
\nabla_\beta \|Y - X\beta\|^2 &= -2X^\top (Y - X\beta), \\
\nabla^2_\beta \|Y - X\beta\|^2 &= 2X^\top X.
\end{aligned}$$

(La deuxième formule vaut $2A\beta$ quand A est symétrique.)

Pour la retrouver : développez $\|Y - X\beta\|^2 = Y^\top Y - 2\beta^\top X^\top Y + \beta^\top X^\top X \beta$; vérification en dimension 1 : $\frac{d}{d\beta} \sum_i (y_i - x_i\beta)^2 = -2 \sum_i x_i (y_i - x_i\beta)$. Annuler le gradient donne les équations normales $X^\top X\beta = X^\top Y$; $X^\top (Y - X\beta)$ est le vecteur des produits scalaires entre chaque variable et le résidu.

Théorème — Ce qu'il faut savoir sur la convexité PAR CŒUR → Rappels

f est convexe si $f(tu + (1-t)v) \le tf(u) + (1-t)f(v)$ pour tout $t \in [0,1]$; strictement convexe si l'inégalité est stricte pour $u \neq v$ et $t \in (0,1)$.

1. f deux fois dérivable est convexe $\iff$ $\nabla^2 f$ est semi-définie positive partout ($f'' \ge 0$ en dimension 1).
2. Une somme de convexes, cf avec $c \ge 0$, toute norme : convexes.
3. Pour f convexe : minimum local = minimum global.
4. Strictement convexe $\Rightarrow$ **au plus un** minimiseur.
5. Ordre 1 (f convexe dérivable) : $f(v) \ge f(u) + \nabla f(u)^\top (v - u)$; donc $\nabla f(u) = 0 \Rightarrow u$ est un minimum global.

Pour la retrouver : unicité = « le milieu de deux minimiseurs distincts ferait strictement mieux que le minimum ». Exemples : $\|Y - X\beta\|^2$ est convexe (hessienne $2X^\top X$), strictement si $\operatorname{rg} X = p$; $\|\beta\|_1$ et $\|\beta\|_2^2$ sont convexes ; $\|\beta\|_0$ et $|\cdot|^\gamma$ avec $\gamma < 1$ ne le sont pas.

Théorème — Existence et unicité d'un minimiseur PAR CŒUR À SAVOIR REFAIRE → Rappels

1. Weierstrass : une fonction continue sur un ensemble fermé, borné et non vide (par exemple une boule fermée $\{\|\beta\| \leq M\}$) atteint son minimum.
2. Une fonction continue et **coercive** ($f(\beta) \to +\infty$ quand $\|\beta\| \to \infty$) sur $\mathbb{R}^p$ atteint son minimum.
3. Strictement convexe $\Rightarrow$ au plus un minimiseur.
4. $f = h + \lambda \|\beta\|^2$ avec h continue, convexe et **positive**, et $\lambda > 0 \Rightarrow$ **exactement un** minimiseur.

Critère	Ce qu'on sait de ses minimiseurs
Moindres carrés $\|Y - X\beta\|^2$	il en existe toujours (projection) ; unique ssi $\operatorname{rg} X = p$
Ridge $\|Y - X\beta\|^2 + \lambda \|\beta\|^2$, $\lambda > 0$	exactement un (TD1, ex. 1)
Lasso $\|Y - X\beta\|^2 + \lambda \|\beta\|_1$, $\lambda > 0$	au moins un (coercif : $\geq \lambda \|\beta\|_1$) ; plusieurs possibles, mais tous ont le même $X\hat{\beta}$ et la même norme $\|\hat{\beta}\|_1$ (TD1, ex. 2)
Log-vraisemblance logistique négative $-\ell_n$	peut n'en avoir aucun : données séparables, ou $p \geq n$ avec $\operatorname{rg} X = n$ (TD3) ; s'il en existe un : unique si $\operatorname{rg} X = p$, jamais unique si $p > n$
Ridge logistique $-\ell_n + \lambda \|\beta\|^2$, $\lambda > 0$	exactement un (Cours5 enrichi p. 36, TD3 ex. 1)

Preuve express du résultat 4

1. $$\|tu + (1-t)v\|^2 = t\|u\|^2 + (1-t)\|v\|^2 - t(1-t)\|u - v\|^2 \qquad (t \in [0,1])$$
   ↳ on développe, on remplace $2u^\top v = \|u\|^2 + \|v\|^2 - \|u - v\|^2$; c'est le calcul du corrigé officiel du TD1 (ex. 1, question 1)
2. $$f\big(tu + (1-t)v\big) \leq tf(u) + (1-t)f(v) - \lambda t(1-t)\|u - v\|^2$$
   ↳ h est convexe, et on ajoute λ fois l'identité : pour $u \neq v$ et $t \in (0,1)$ le dernier terme est < 0, donc f est strictement convexe (au plus un minimiseur)
3. $f(\beta) \geq \lambda \|\beta\|^2 \to +\infty$: f est coercive et continue, donc un minimiseur existe.
   ↳ $h \geq 0$, puis le résultat 2

Théorème — Pénalisé ⇒ contraint (le sens facile) PAR CŒUR À SAVOIR REFAIRE → Rappels

Si $\hat{\beta}(\lambda)$ minimise $f + \lambda g$ (avec $\lambda \geq 0$), alors $\hat{\beta}(\lambda)$ minimise f sous la contrainte $g(\beta) \leq t$, avec $t = g(\hat{\beta}(\lambda))$. La réciproque (pour tout t, il existe un λ) demande la convexité de f et g (dualité de Lagrange, admise), et **la correspondance $t \leftrightarrow \lambda$ dépend des données**.

Preuve en une ligne : pour tout β avec $g(\beta) \leq g(\hat{\beta})$: $f(\hat{\beta}) + \lambda g(\hat{\beta}) \leq f(\beta) + \lambda g(\beta) \leq f(\beta) + \lambda g(\hat{\beta})$, puis on simplifie. L'idée de Lagrange : à la solution contrainte, une ligne de niveau de f est tangente au bord de $\{g \leq t\}$, donc $\nabla f = -\lambda \nabla g$ avec $\lambda \geq 0$, c'est-à-dire « gradient de $f + \lambda g$ nul ». Exemple

1D : $(b-a)^2 + \lambda|a|$ et « $(b-a)^2$ sous $|a| \le t$ » (avec $0 < t < b$) ont la même solution ssi $\lambda = 2(b-t)$, qui dépend de la donnée b.

Méthode — Taylor à l'ordre 2 et pas de Newton PAR CŒUR → Rappels

$$f(\beta+h) \approx f(\beta) + \nabla f(\beta)^\top h + \tfrac{1}{2} h^\top \nabla^2 f(\beta) h,$$
$$\beta_{k+1} = \beta_k - \left[\nabla^2 f(\beta_k)\right]^{-1} \nabla f(\beta_k).$$

La formule est la même pour maximiser une log-vraisemblance concave.

Pour la retrouver : on annule le gradient de la parabole en h : $\nabla f + \nabla^2 f\, h = 0$. Sur une fonction quadratique (les moindres carrés), un seul pas donne la solution exacte ; près de la solution, l'erreur est (à une constante près) mise au carré à chaque pas : c'est la convergence quadratique. Pour un GLM, c'est l'IRLS (S5).

Réflexe — devant un nouvel « argmin »

(1) Le critère est-il convexe (somme de convexes) ? Alors un point critique, ou $0 \in \partial F$, suffit. (2) Est-il strictement convexe ? Alors la solution est unique. (3) Existe-t-elle ? Contrainte fermée bornée, ou coercivité. Une pénalité $\lambda \|\beta\|^2$ ($\lambda > 0$) ajoutée à un critère convexe positif règle (2) et (3) d'un coup. Où : TD1 · ex. 1, TD1 · ex. 2, TD3 · Ridge logistique.

Les petites inégalités qui débloquent les preuves

Théorème — La boîte à astuces PAR CŒUR → Rappels

1. Triangulaire $\|a+b\| \le \|a\| + \|b\|$ et triangulaire inversée $\|a\| - \|b\| \le \|a-b\|$.
2. $2ab \le a^2 + b^2$; Young : pour tout $\eta > 0$, $ab \le \eta a^2 + \dfrac{b^2}{4\eta}$.
3. $u^2 \le cu$ avec $u, c \ge 0 \Rightarrow u \le c$.
4. $u^2 \le cu + d$ avec $u, c, d \ge 0 \Rightarrow u \le c + \sqrt{d}$.
5. Pour tout $\alpha > 0$: $(a+b)^2 \le (1+\alpha)a^2 + (1+\alpha^{-1})b^2$; avec $\alpha = 1$: $(a+b)^2 \le 2a^2 + 2b^2$.
6. Pour $a, b \ge 0$: $\sqrt{a+b} \le \sqrt{a} + \sqrt{b}$.
7. Pour une famille finie : $\max_m x_m \le \sum_m (x_m)_+$, donc $\mathbb{E}[\max_m X_m] \le \sum_m \mathbb{E}[(X_m)_+]$.

Pour la retrouver : 2 et 5 viennent d'un carré positif, $0 \le \left(\sqrt{\eta}\, a - \frac{b}{2\sqrt{\eta}}\right)^2$ et $0 \le \left(\sqrt{\alpha}\, a - \frac{b}{\sqrt{\alpha}}\right)^2$; 3 : diviser par u si $u > 0$ (si $u = 0$, c'est $c \ge 0$) ; 4 : u est sous la plus grande racine de $u^2 - cu - d$; 6 : $(\sqrt{a} + \sqrt{b})^2 = a + b + 2\sqrt{ab}$.

Où elles servent (à reconnaître)

- BRT (S3 · étape 4, critère $\frac{1}{n}\|Y - X\beta\|^2 + 2r\|\beta\|_1$) : on arrive à $u^2 \le \frac{4r\sqrt{s}}{\kappa} u$ avec $u = \|X\delta\|/\sqrt{n}$, d'où $u \le \frac{4r\sqrt{s}}{\kappa}$ (astuce 3).
- Oracle rapide (S4, critère $\frac{1}{n}\|y - X\beta\|^2 + 2\lambda\|\beta\|_1$) : avec $u = \left\|X(\hat\beta - \beta)\right\|/\sqrt{n}$, Young avec $\eta = 1$ donne $\frac{3\lambda\sqrt{s}}{\kappa} u \le u^2 + \frac{9\lambda^2 s}{4\kappa^2}$, et $\lambda^2 = \frac{8\sigma^2(x + \log M)}{n}$ transforme $\frac{9\lambda^2 s}{4\kappa^2}$ en $\frac{18\sigma^2 s(x+\log M)}{\kappa^2 n}$: c'est le 18 de la diapo 58.

- TD1, ex. 3 (questions 2(d)–2(e)) : astuce 7 (maximum sur tous les modèles), astuce 6 ($\sqrt{2\xi} \le \sqrt{2c} + \sqrt{2(\xi - c)_+}$), astuce 5 avec $\alpha = \frac{K-1}{K+1}$, et $(\sqrt{d} + \sqrt{2L})^2 \le 2d + 4L$.

Réflexe — une inconnue au carré à gauche, à la puissance 1 à droite

Quand la même quantité $u \ge 0$ apparaît au carré à gauche et à la puissance 1 à droite, c'est gagné : divisez par u (astuce 3) ou absorbez le terme linéaire avec Young (astuce 2). Où : S3 · étape 4, S4 · oracle rapide.

Espérance, vecteurs gaussiens, formes quadratiques, khi-deux

Formules — Espérance et covariance d'un vecteur aléatoire PAR CŒUR → Rappels

Avec $\mathrm{Cov}(Z) = \mathbb{E}\big[(Z - \mathbb{E}Z)(Z - \mathbb{E}Z)^\top\big]$, et A, b non aléatoires :

$$\begin{aligned} \mathbb{E}[AZ + b] &= A\,\mathbb{E}Z + b, \\ \mathrm{Cov}(AZ + b) &= A\,\mathrm{Cov}(Z)\,A^\top, \\ \mathbb{E}\,\|Z\|^2 &= \|\mathbb{E}Z\|^2 + \mathrm{tr}\,\mathrm{Cov}(Z). \end{aligned}$$

Application à connaître : $\hat\beta^{\mathrm{MC}} = (X^\top X)^{-1} X^\top Y = \beta^* + (X^\top X)^{-1} X^\top \varepsilon$, donc $\mathbb{E}\hat\beta^{\mathrm{MC}} = \beta^*$ (sans biais) et $\mathrm{Cov}(\hat\beta^{\mathrm{MC}}) = \sigma^2 (X^\top X)^{-1}$ (« sandwich »). Attention : $\mathbb{E}\,\|Z\|^2 = \mathrm{tr}\,\mathrm{Cov}(Z)$ seulement si Z est centré.

Théorème — Le fait gaussien central du cours PAR CŒUR → Rappels

$Z \sim \mathcal{N}(m, \Sigma)$ ssi toute combinaison linéaire vérifie $a^\top Z \sim \mathcal{N}(a^\top m,\ a^\top \Sigma a)$. Si $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$ et a est fixé : $a^\top \varepsilon \sim \mathcal{N}(0, \sigma^2 \|a\|^2)$. En particulier :

$$X_j^\top \varepsilon \sim \mathcal{N}\big(0, \sigma^2 \|X_j\|^2\big),$$

et si les colonnes sont normalisées, $\|X_j\|^2 = n$:

$$\frac{X_j^\top \varepsilon}{\sigma\sqrt{n}} \sim \mathcal{N}(0,1), \qquad \frac{1}{n} X_j^\top \varepsilon \sim \mathcal{N}\Big(0, \frac{\sigma^2}{n}\Big).$$

Pour la retrouver : combinaison linéaire de gaussiennes, donc gaussienne ; variance par le sandwich $a^\top(\sigma^2 I_n)a = \sigma^2 \|a\|^2$. C'est le point de départ de tous les choix de λ.

Théorème — Espérance d'une forme quadratique du bruit PAR CŒUR À SAVOIR REFAIRE → Rappels

Si $\mathbb{E}\varepsilon = 0$ et $\mathrm{Cov}(\varepsilon) = \sigma^2 I_n$ (la gaussianité est inutile), pour toute matrice fixe $M \in \mathbb{R}^{n \times n}$:

$$\mathbb{E}[\varepsilon^\top M \varepsilon] = \sigma^2\,\mathrm{tr}\,M,$$

et pour un projecteur orthogonal P :

$$\mathbb{E}\,\|P\varepsilon\|^2 = \sigma^2\,\mathrm{rg}\,P.$$

L'idée : « chaque dimension sur laquelle on projette coûte σ^2 ». C'est toute la preuve de $\mathbb{E}\left\|X\hat\beta^{\mathrm{MC}} - X\beta^*\right\|_n^2 = \sigma^2\,\mathrm{rg}(X)/n$, de l'identité de Cp et du risque de l'oracle.

Preuve express

1. $$\varepsilon^\top M\varepsilon = \mathrm{tr}(\varepsilon^\top M\varepsilon) = \mathrm{tr}(M\varepsilon\varepsilon^\top)$$
   ↳ un nombre est sa propre trace, puis cyclicité

2. $$\mathbb{E}[\varepsilon^\top M\varepsilon] = \mathrm{tr}\left(M\,\mathbb{E}[\varepsilon\varepsilon^\top]\right) = \mathrm{tr}(M\,\sigma^2 I_n) = \sigma^2\,\mathrm{tr}\,M$$
   ↳ la trace est linéaire, elle commute avec l'espérance ; $\mathbb{E}[\varepsilon\varepsilon^\top] = \mathrm{Cov}(\varepsilon) = \sigma^2 I_n$ car ε est centré

3. $$\|P\varepsilon\|^2 = \varepsilon^\top P^\top P\varepsilon = \varepsilon^\top P\varepsilon \;\Rightarrow\; \mathbb{E}\,\|P\varepsilon\|^2 = \sigma^2\,\mathrm{tr}\,P = \sigma^2\,\mathrm{rg}\,P$$
   ↳ $P^\top P = P^2 = P$, puis trace d'un projecteur = rang

Théorème — Khi-deux et exponentielle PAR CŒUR → Rappels

- $Z_1, \dots, Z_k$ indépendantes $\mathcal{N}(0,1)$: $Z_1^2 + \cdots + Z_k^2 \sim \chi^2(k)$, d'espérance k et de variance $2k$.
- $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$ et S sous-espace de dimension d : $\|P_S\varepsilon\|^2/\sigma^2 \sim \chi^2(d)$; si $S \perp T$, $P_S\varepsilon$ et $P_T\varepsilon$ sont indépendants.
- $\xi \sim \mathcal{E}(1) : \mathbb{P}(\xi > x) = e^{-x}$ pour $x \geq 0$, $\mathbb{E}\xi = 1$, et pour $c \geq 0 : \mathbb{E}[(\xi - c)_+] = e^{-c}$ (avec $\leq$ si l'on sait seulement $\mathbb{P}(\xi > x) \leq e^{-x}$).

Pour la retrouver : formule de la queue $\mathbb{E}W = \int_0^\infty \mathbb{P}(W > t)\,dt$ pour $W \geq 0$, avec $\mathbb{P}\big((\xi - c)_+ > t\big) = e^{-c-t}$. Dans le TD1 : $c = \log(1/\Pi_m)$ donne $\mathbb{E}[(\xi_m - c)_+] = \Pi_m$, et $\sum_m \Pi_m = 1$ permet de sommer sur tous les modèles.

Queues gaussiennes, maximum de p gaussiennes, concentration, Hoeffding

Théorème — Markov, queue gaussienne, borne de l'union PAR CŒUR À SAVOIR REFAIRE → Rappels

1. Markov : pour $W \geq 0$ et $a > 0$, $\mathbb{P}(W \geq a) \leq \mathbb{E}W/a$.
2. Queue gaussienne, $Z \sim \mathcal{N}(0,1)$, $t \geq 0 : \mathbb{P}(Z \geq t) \leq e^{-t^2/2}$, $\mathbb{P}(|Z| \geq t) \leq 2e^{-t^2/2}$, et même $\mathbb{P}(|Z| \geq t) \leq e^{-t^2/2}$ (version fine).
3. Borne de l'union : $\mathbb{P}(A_1 \cup \cdots \cup A_p) \leq \mathbb{P}(A_1) + \cdots + \mathbb{P}(A_p)$, **sans aucune hypothèse d'indépendance**.

Qui utilise quoi : le Cours 3 (BRT) utilise la version fine, d'où $1 - p^{1-A^2/8}$ sans facteur 2 ; le Cours 4 et le TD2 utilisent $2e^{-t^2/2}$, d'où $1 - 2e^{-x}$ et $1 - 2p^{1-A^2/8}$.

Preuve express (Chernoff)

1. $$\mathbb{E}[e^{\theta Z}] = \int \frac{e^{\theta z - z^2/2}}{\sqrt{2\pi}}\,dz = e^{\theta^2/2}$$
   ↳ on complète le carré : $\theta z - \frac{z^2}{2} = \frac{\theta^2}{2} - \frac{(z-\theta)^2}{2}$, et l'intégrale d'une densité vaut 1

2. $$\mathbb{P}(Z \geq t) = \mathbb{P}\big(e^{\theta Z} \geq e^{\theta t}\big) \leq e^{-\theta t}\,\mathbb{E}[e^{\theta Z}] = e^{\theta^2/2 - \theta t} \qquad (\theta > 0)$$
   ↳ l'exponentielle est croissante, puis Markov avec $W = e^{\theta Z}$

3 $$\theta = t \;\Rightarrow\; \mathbb{P}(Z \geq t) \leq e^{-t^2/2}, \qquad \mathbb{P}(|Z| \geq t) \leq 2e^{-t^2/2}$$

↳ le meilleur θ minimise $\theta^2/2 - \theta t$; puis symétrie de la gaussienne

Théorème — Le maximum de p gaussiennes PAR CŒUR À SAVOIR REFAIRE → Rappels

Soient $Z_1, \ldots, Z_p \sim \mathcal{N}(0,1)$, indépendantes **ou non**. Pour tout $x > 0$:

$$\mathbb{P}\Big(\max_{1 \leq j \leq p} |Z_j| > \sqrt{2(\log p + x)}\Big) \leq 2e^{-x}.$$

Conséquence, si $\|X_j\|^2 = n$: avec probabilité au moins $1 - 2e^{-x}$, $\max_j \dfrac{|X_j^\top \varepsilon|}{n} \leq \sigma\sqrt{\dfrac{2(\log p + x)}{n}}$.

Les probabilités des théorèmes du cours viennent toutes de ce calcul (borne de l'union + queue ; dans le TD3, Hoeffding remplace la queue gaussienne). Avec $\|X_j\|^2 = n$ et $Z_j = \frac{X_j^\top \varepsilon}{\sigma\sqrt{n}} \sim \mathcal{N}(0,1)$: $\frac{2}{n}\left|X_j^\top \varepsilon\right| > \lambda \iff |Z_j| > z := \frac{\lambda\sqrt{n}}{2\sigma}$.

Où	Événement, seuil z	Probabilité d'échec
S3 (BRT), pénalité $2r\|\beta\|_1$	$\frac{2}{n}\left\|X^\top\varepsilon\right\|_\infty \leq r$, $r = A\sigma\sqrt{\log p/n}$: $z = \frac{A}{2}\sqrt{\log p}$	$p\,e^{-z^2/2} = p^{1-A^2/8}$ (queue fine)
TD2, même critère	même événement, même z	$2p\,e^{-z^2/2} = 2p^{1-A^2/8}$
S4 (oracles), pénalité $\lambda\|\beta\|_1$ (lente) ou $2\lambda\|\beta\|_1$ (rapide)	$\frac{2}{n}\left\|X^\top\varepsilon\right\|_\infty \leq \lambda$, $\lambda = 2\sigma\sqrt{2(x+\log M)/n}$: $z = \sqrt{2(x+\log M)}$	$2M\,e^{-z^2/2} = 2e^{-x}$
TD3 (Hoeffding), pénalité $\lambda\|\beta\|_1$	$\lvert V_j\rvert \leq \frac{\lambda}{2}$ pour tout j, $\lambda = A\sqrt{\log p/n}$, $\lvert z_{ij}\rvert \leq c$	$p \cdot 2e^{-n\lambda^2/(2c^2)} = 2p^{1-A^2/(2c^2)}$

L'idée : union + queue donnent $2p\,e^{-t^2/2}$, et le choix $t^2 = 2(\log p + x)$ compense exactement le facteur p. D'où $\lambda \asymp \sigma\sqrt{\log p/n}$ dans tous les théorèmes : la pénalité doit dominer la plus forte corrélation apparente entre une variable et le bruit pur. Le maximum grandit très lentement : $p = 10\,000$, $x = 3$ donnent un seuil $\approx 4{,}94$, contre $\sqrt{6} \approx 2{,}45$ pour $p = 1$.

Preuve express

1 $$\mathbb{P}\Big(\max_j |Z_j| > t\Big) = \mathbb{P}\Big(\bigcup_j \{|Z_j| > t\}\Big) \leq \sum_{j=1}^{p} \mathbb{P}(|Z_j| > t) \leq 2p\,e^{-t^2/2}$$

↳ le maximum dépasse t ssi l'un des $|Z_j|$ dépasse t ; borne de l'union ; queue gaussienne

2 $$t^2 = 2(\log p + x) \;\Rightarrow\; 2p\,e^{-t^2/2} = 2p\,e^{-\log p - x} = 2e^{-x}$$

↳ on choisit t pour compenser le facteur p

3 On l'applique à $Z_j = \dfrac{X_j^\top \varepsilon}{\sigma\sqrt{n}} \sim \mathcal{N}(0,1)$.

↳ fait gaussien central avec des colonnes normalisées $\|X_j\|^2 = n$

Réflexe — contrôler p quantités gaussiennes à la fois

« Je dois contrôler simultanément p gaussiennes » → borne de l'union + queue gaussienne → seuil en $\sqrt{2\log p}$ (en écarts-types). Le prix de la grande dimension est logarithmique. Où : S3 · étape 5, S4 · oracle lente, TD2 · question 4.

Théorème — Concentration gaussienne des fonctions lipschitziennes (admis) PAR CŒUR

→ Rappels

F est L-lipschitzienne si $|F(u)-F(v)| \le L\,\|u-v\|$ pour tous u, v. Si $Z \sim \mathcal{N}(0, \sigma^2 I_d)$ et F est L-lipschitzienne, pour tout $t \ge 0$:

$$\mathbb{P}\big(F(Z) \ge \mathbb{E}F(Z) + \sigma L t\big) \le e^{-t^2/2},$$

quelle que soit la dimension d.

Forme du TD1 : $F(Z) \le \mathbb{E}F(Z) + \sigma L\sqrt{2\xi}$, où $\mathbb{P}(\xi > x) \le e^{-x}$ pour tout $x \ge 0$.

Application à connaître : $z \mapsto \|P_S z\|$ est 1-lipschitzienne et $\mathbb{E}\,\|P_S\varepsilon\| \le \sigma\sqrt{d}$ (Jensen), donc avec probabilité au moins $1-e^{-x}$: $\|P_S\varepsilon\| \le \sigma\big(\sqrt{d} + \sqrt{2x}\big)$. Autres fonctions 1-lipschitziennes : $a^\top z$ avec $\|a\| = 1$, $\|z\|$, $\max_j z_j$.

Théorème — Inégalité de Hoeffding PAR CŒUR → Rappels

$X_1, \dots, X_n$ indépendantes, $X_i \in [a_i, b_i]$ presque sûrement, $S = \sum_{i=1}^n (X_i - \mathbb{E}X_i)$. Pour tout $x > 0$:

$$\mathbb{P}(|S| \ge x) \le 2\exp\Big(-\frac{2x^2}{\sum_{i=1}^n (b_i - a_i)^2}\Big).$$

Sans valeur absolue, même borne sans le facteur 2 : $\mathbb{P}(S \ge x) \le \exp\big(-2x^2 / \sum_i (b_i - a_i)^2\big)$.

Pour la retrouver : c'est la queue gaussienne $2e^{-x^2/(2v)}$ avec $v = \sum_i (b_i - a_i)^2/4$: chaque variable bornée compte comme une gaussienne d'écart-type sa demi-longueur $(b_i - a_i)/2$. Dans le TD3 ($|z_{ij}| \le c$) : $\mathbb{P}(|V_j| \ge \lambda/2) \le 2e^{-n\lambda^2/(2c^2)}$, puis $\lambda = A\sqrt{\log p / n}$ et l'union donnent $2p^{1-A^2/(2c^2)}$.

Réflexe — un bruit borné mais pas gaussien

Réponses 0/1, comptages plafonnés → Hoeffding à la place de la queue gaussienne : même forme $e^{-(\cdots)x^2}$, même choix $\lambda \asymp \sqrt{\log p/n}$, même borne de l'union, même preuve que l'inégalité oracle lente. Où : TD3 · ex. 2, question 3(b).

Convergences et lemme de Slutsky

Définitions — Convergences et consistance PAR CŒUR → Rappels

- En probabilité : pour tout $\eta > 0$, $\mathbb{P}(|Z_n - c| > \eta) \to 0$. En loi : $\mathbb{P}(Z_n \le z) \to \mathbb{P}(Z \le z)$ en tout point z où la fonction de répartition de Z est continue.
- $\hat\theta_n$ est consistant si $\hat\theta_n \to \theta$ en probabilité ; il suffit que $\mathbb{E}[(\hat\theta_n - \theta)^2] \to 0$ (Markov).
- $Y_1, \dots, Y_n$ i.i.d. : loi des grands nombres $\bar Y_n \to \mathbb{E}Y$ (en probabilité) ; si $\mathrm{Var}\,Y < \infty$, théorème central limite $\sqrt{n}(\bar Y_n - \mathbb{E}Y) \to \mathcal{N}(0, \mathrm{Var}\,Y)$ en loi.

À comprendre : asymptotique = « quand $n \to \infty$ » (normalité de l'EMV, séance 5) ; non asymptotique = « pour tout n, avec probabilité au moins $1-\delta$ » (BRT, inégalités oracle, séances 3–4), utilisable même quand p dépend de n. Une borne en $s \log p / n$ tend vers 0 ssi $s \log p = o(n)$.

Théorème — Application continue et lemme de Slutsky (admis) PAR CŒUR → Rappels

1. Si $Y_n \xrightarrow{\mathbb{P}} a$ et si g est continue en a, alors $g(Y_n) \xrightarrow{\mathbb{P}} g(a)$.
2. Si $X_n \xrightarrow{\mathcal{L}} X$ et $Y_n \xrightarrow{\mathbb{P}} c$ où c est une **constante** : $X_n + Y_n \xrightarrow{\mathcal{L}} X + c$, $Y_n X_n \xrightarrow{\mathcal{L}} cX$, et $X_n / Y_n \xrightarrow{\mathcal{L}} X/c$ si $c \neq 0$. Même chose avec des matrices $Y_n \xrightarrow{\mathbb{P}} C$: $Y_n X_n \xrightarrow{\mathcal{L}} CX$.

Usage type, l'intervalle de Wald : $\sqrt{n}(\hat\theta - \theta) \to \mathcal{N}(0, I(\theta)^{-1})$ fait intervenir θ, inconnu ; comme $\hat\theta \to \theta$ en probabilité et I est continue, $I(\hat\theta) \to I(\theta)$ en probabilité (résultat 1), et Slutsky donne l'intervalle asymptotique $\hat\theta \pm q_{1-\alpha/2}/\sqrt{nI(\hat\theta)}$ ($q_{0{,}975} = 1{,}96$) ; pour une coordonnée d'un GLM : $\hat\beta_j \pm q_{1-\alpha/2}\sqrt{[I(\hat\beta)^{-1}]_{jj}/n}$ (S5).

Piège — Slutsky demande une limite constante

Si $Y_n \to Y$ en loi avec Y aléatoire, $X_n Y_n$ ne converge pas forcément vers XY (il faudrait la loi du couple). Et l'intervalle de Wald n'a le niveau $1-\alpha$ que **quand** $n \to \infty$: le « $\geq 1-\alpha$ » écrit au tableau (Cours5 enrichi p. 26–27) est le but visé, pas une garantie à n fixé.

Statistique : biais–variance, vraisemblance, Fisher, validation croisée

Théorème — Décomposition biais–variance PAR CŒUR À SAVOIR REFAIRE → Rappels

$$\underbrace{\mathbb{E}\left\|\hat\theta - \theta\right\|^2}_{\text{risque}} = \underbrace{\left\|\mathbb{E}\hat\theta - \theta\right\|^2}_{\text{biais}^2} + \underbrace{\mathbb{E}\left\|\hat\theta - \mathbb{E}\hat\theta\right\|^2}_{\text{variance} = \operatorname{tr}\operatorname{Cov}(\hat\theta)}.$$

En dimension 1 (erreur quadratique moyenne) : $\mathbb{E}[(\hat\theta - \theta)^2] = (\mathbb{E}\hat\theta - \theta)^2 + \operatorname{Var}(\hat\theta)$.

Preuve en une ligne : écrire $\hat\theta - \theta = (\hat\theta - \mathbb{E}\hat\theta) + (\mathbb{E}\hat\theta - \theta)$ et développer ; le double produit est d'espérance nulle car $\mathbb{E}\hat\theta - \theta$ n'est pas aléatoire. Exemple : $c\bar Y$ a le risque $(1-c)^2\mu^2 + c^2\sigma^2/n$, minimal en $c^* = \frac{\mu^2}{\mu^2 + \sigma^2/n} < 1$: accepter un peu de biais peut réduire beaucoup le risque. C'est l'idée du Ridge.

Définition — Vraisemblance et EMV PAR CŒUR → Rappels

$L(\theta) = \prod_{i=1}^n f_\theta(y_i)$, $\ell(\theta) = \sum_{i=1}^n \log f_\theta(y_i)$, et l'EMV est $\hat\theta \in \arg\max_\theta \ell(\theta)$. Régression gaussienne (σ connu) : $\ell(\beta) = \text{cte} - \dfrac{\|Y - X\beta\|^2}{2\sigma^2}$, donc **EMV = moindres carrés**.

À savoir refaire (log, somme, dériver, annuler, vérifier le signe de la dérivée seconde) : Bernoulli $\hat p = \bar y$; Poisson $\hat\lambda = \bar y$; exponentielle $f_\theta(y) = \theta e^{-\theta y}$, $\hat\theta = 1/\bar y$.

Théorème — Score, information de Fisher, normalité asymptotique de l'EMV PAR CŒUR

À SAVOIR REFAIRE → Rappels

- Score d'une observation : $s_\theta(y) = \partial_\theta \log f_\theta(y)$, et $\mathbb{E}_\theta[s_\theta(Y)] = 0$.
- Information de Fisher d'**une** observation : $I(\theta) = \mathbb{E}\big[s_\theta(Y)^2\big] = -\mathbb{E}\big[\partial_\theta^2 \log f_\theta(Y)\big]$; paramètre vectoriel : $I(\theta) = -\mathbb{E}\big[\nabla^2 \log f_\theta(Y)\big]$ (une matrice). Pour n observations indépendantes et de même loi, l'information **totale** vaut $nI(\theta)$.
- Sous des conditions de régularité : $\sqrt{n}(\hat\theta_n - \theta) \xrightarrow{\mathcal{L}} \mathcal{N}\big(0, I(\theta)^{-1}\big)$, c'est-à-dire $\hat\theta_n \approx \mathcal{N}\big(\theta, \frac{1}{nI(\theta)}\big)$: la variance asymptotique est l'inverse de l'information totale.
- Notation de la séance 5 (GLM), suivie dans toute cette fiche : $I_n(\beta) = -\mathbb{E}\big[\nabla^2 \ell_n(\beta)\big]$, avec $\ell_n = \frac{1}{n}\ell$, est l'information **moyenne** ; on suppose $I_n(\beta^*) \to I(\beta^*) \succ 0$, et alors $\sqrt{n}(\hat\beta - \beta^*) \xrightarrow{\mathcal{L}} \mathcal{N}\big(0, I(\beta^*)^{-1}\big)$.

Piège de notation : la page Rappels (comme l'ancienne diapo 72 du Cours 5) note $I_n(\theta) = nI(\theta)$ l'information *totale* ; la séance 5 et cette fiche notent $I_n(\beta)$ l'information *moyenne*. GLM à lien canonique : $\nabla^2\ell = -X^\top W X$, donc $I_n(\beta) = \frac{1}{n}X^\top W(\beta) X$ et $\hat\beta \approx \mathcal{N}\big(\beta^*, (X^\top W X)^{-1}\big)$, avec W pris en β^* (S5). **Exemples :** Bernoulli $I(p) = \frac{1}{p(1-p)}$; Poisson $I(\lambda) = \frac{1}{\lambda}$; modèle linéaire gaussien : la courbure est $X^\top X/\sigma^2$ et l'on retrouve $\mathrm{Cov}(\hat\beta^{\mathrm{MC}}) = \sigma^2(X^\top X)^{-1}$.

Preuve express des deux identités

1. $$\int f_\theta(y)\,dy = 1 \;\Rightarrow\; \int \partial_\theta f_\theta(y)\,dy = 0$$
   ↳ on dérive sous l'intégrale (c'est la « condition de régularité »)

2. $$\partial_\theta f_\theta = s_\theta\, f_\theta \;\Rightarrow\; \mathbb{E}[s_\theta] = \int s_\theta f_\theta = 0$$
   ↳ dérivée du log : $(\log f)' = f'/f$

3. $$\int (\partial_\theta s_\theta)\, f_\theta + \int s_\theta\, \partial_\theta f_\theta = 0 \;\Rightarrow\; \mathbb{E}\big[\partial_\theta^2 \log f_\theta\big] + \mathbb{E}\big[s_\theta^2\big] = 0$$
   ↳ on dérive encore $\int s_\theta f_\theta = 0$ (dérivée d'un produit), puis $\partial_\theta f_\theta = s_\theta f_\theta$

C'est la preuve faite au tableau (Cours5 enrichi p. 17–18), qui donne les moments de la famille exponentielle (S5).

Formules — Erreur d'apprentissage, erreur de test, validation croisée

PAR CŒUR → Rappels

Moindres carrés dans un modèle linéaire correct à d paramètres ($\mathrm{rg}\, X = d$), erreurs moyennes par observation :

$$\text{apprentissage} : \mathbb{E}\Big[\tfrac{1}{n}\big\|Y - X\hat\beta^{\mathrm{MC}}\big\|^2\Big] = \sigma^2\Big(1 - \frac{d}{n}\Big),$$
$$\text{test} : \mathbb{E}\Big[\tfrac{1}{n}\big\|Y' - X\hat\beta^{\mathrm{MC}}\big\|^2\Big] = \sigma^2\Big(1 + \frac{d}{n}\Big),$$

où $Y' = X\beta^* + \varepsilon'$ sont de nouvelles données : même X, bruit ε' indépendant de ε et de même loi.

Validation croisée à K blocs : pour chaque λ d'une grille, ajuster sur $K-1$ blocs, mesurer l'erreur sur le bloc restant, moyenner les K erreurs ; garder le λ d'erreur minimale, puis réajuster sur toutes les données.

À comprendre : l'erreur d'apprentissage ne peut que diminuer quand on agrandit le modèle (modèles emboîtés) ; l'écart $2\sigma^2 d/n$ (« l'optimisme ») est ce que corrigent Cp et AIC. Toute étape

qui regarde les données (sélection, réajustement) doit être refaite dans chaque tour de validation croisée (S6).

À comprendre — Pourquoi les tests ne suffisent plus en grande dimension À COMPRENDRE

→ Rappels

Pour $p < n$ ($\operatorname{rg} X = p$, bruit gaussien), sous $H_0 : \beta_j^* = 0$, $T_j = \hat{\beta}_j^{\mathrm{MC}} / \left(\hat{\sigma}\sqrt{[(X^\top X)^{-1}]_{jj}}\right)$ suit une loi de Student à $n-p$ degrés de liberté, avec $\hat{\sigma}^2 = \left\|Y - X\hat{\beta}\right\|^2 / (n-p)$. Si $p \geq n$, rien de tout cela n'est défini. Et avec p tests au niveau 5 %, si toutes les variables sont inutiles, on attend environ $0{,}05\,p$ faux positifs ; la correction de Bonferroni (niveau α/p par test, c'est la borne de l'union) donne un seuil du même ordre que $\sqrt{2\log p}$.

1. Moindres carrés, Ridge, sélection ℓ0, Lasso → S1 → TD1

L'essentiel de la séance en 5 lignes

- **MCO** : $X\hat{\beta}^{\mathrm{MC}} = PY$ est la projection de Y sur $\operatorname{Im} X$; erreur de prédiction $\sigma^2 \operatorname{rg}(X)/n$. Inutilisables si $p \geq n$ (interpolation ; dès que $p > n$, β^* n'est plus identifiable) ou si $X^\top X$ a de petites valeurs propres (variance σ^2/μ_j).
- **Ridge** $(X^\top X + \lambda I_p)^{-1} X^\top Y$ pour le critère $\|Y - X\beta\|^2 + \lambda \|\beta\|^2$ (avec $\|Y - X\beta\|_n^2$, λ devient $n\lambda$) : décale le spectre de λ, multiplie la composante MCO de chaque direction propre par $\frac{\mu_j}{\mu_j + \lambda}$; biaisé mais stable ; ne sélectionne pas.
- **ℓ0** : MCO sur chaque sous-ensemble de variables + un prix λ_n par variable dans $\|Y - X\beta\|_n^2 + \lambda_n \|\beta\|_0$ (Cp/AIC : $2\sigma^2/n$, BIC : $\sigma^2 \log(n)/n$) ; sélectionne, mais 2^p modèles.
- **Parcimonie** : $|\mathcal{A}^*| \leq s = o(n)$; l'oracle (MCO sur $\mathcal{A}^*$) fait $\sigma^2 |\mathcal{A}^*| / n$: c'est la cible.
- **Lasso** : $\|Y - X\beta\|_n^2 + \lambda \|\beta\|_1$ en S1 (sans $\frac{1}{n}$ au TD1) ; pénalité convexe *et* créatrice de zéros ; pénalisé ⇔ contraint. **TD1** : Ridge unique et contraint, biais et variance spectraux, Lasso pénalisé = contraint, inégalité oracle pour la sélection de modèles.

Le modèle et les objectifs

Définition — Le modèle linéaire du cours Cours1 · diapos 3–5 PAR CŒUR → S1

$$Y = X\beta^* + \varepsilon, \qquad \varepsilon \sim \mathcal{N}(0, \sigma^2 I_n).$$

- $Y \in \mathbb{R}^n$ observé ; $X \in \mathbb{R}^{n \times p}$ **déterministe** (design fixé) ; $\beta^* \in \mathbb{R}^p$ inconnu ; σ connu.
- $X\beta = \sum_{j=1}^p \beta_j X_j$ (X_j : colonne j) parcourt $\operatorname{Im}(X)$, de dimension $\operatorname{rg} X \leq \min(n, p)$.
- $\mathbb{E}$ porte sur le bruit seulement ; $\|u\|_n^2 = \frac{1}{n}\|u\|^2$.
- Grande dimension : $p = p(n) \geq n$. Objectifs : estimer β^* (estimation), $X\beta^*$ (prédiction), et plus loin $\mathcal{A}^* = \{j : \beta_j^* \neq 0\}$ (sélection).

Pour la retrouver : la loi des données est $Y \sim \mathcal{N}(X\beta^*, \sigma^2 I_n)$; elle ne dépend de β^* qu'à travers $X\beta^*$. Tout le cours en découle : $X\beta^*$ est toujours « visible », β^* seulement si X est injective, ou bien sous une hypothèse de parcimonie et une condition sur X (séance 3).

À comprendre — Prédire n'est pas estimer À COMPRENDRE → S1

Si $X_2 = X_1$ (une variable mesurée deux fois), $\beta^* = (1, 0)$ et $\beta^* = (0, 1)$ donnent le même $X\beta^*$: aucune donnée ne peut les départager. La prédiction ($X\beta^*$) reste parfaitement possible, l'estimation (β^*) non. Quand $p > n$, c'est la situation générale.

Les moindres carrés

Définition — Moindres carrés et équations normales Cours1 · diapo 6 PAR CŒUR À SAVOIR REFAIRE → S1

$$\hat{\beta}^{\mathrm{MC}} \in \arg\min_{\beta \in \mathbb{R}^p} \|Y - X\beta\|_n^2 .$$

Un vecteur $\hat{\beta}$ est un minimiseur si et seulement s'il vérifie les **équations normales** :

$$X^\top X\,\hat{\beta} = X^\top Y.$$

Si $X^\top X$ est inversible : $\hat{\beta}^{\mathrm{MC}} = (X^\top X)^{-1} X^\top Y$. Dans tous les cas, $X\hat{\beta}^{\mathrm{MC}} = PY$, la projection orthogonale de Y sur $\mathrm{Im}\, X$, est **unique**.

Pour la retrouver : annulez le gradient de $\|Y - X\beta\|^2$; ou, géométriquement, écrivez que le résidu $Y - X\hat{\beta}$ est orthogonal à chaque colonne : $X_j^\top (Y - X\hat{\beta}) = 0$. Vérification en dimension 1 : $\hat{\beta} = \sum_i x_i y_i / \sum_i x_i^2$.

Preuve express

1. $$\|Y - X\beta\|^2 = Y^\top Y - 2\beta^\top X^\top Y + \beta^\top X^\top X\beta$$

   ↳ on développe $(Y - X\beta)^\top (Y - X\beta)$; $Y^\top X\beta$ est un nombre, égal à sa transposée $\beta^\top X^\top Y$.

2. $$\nabla_\beta \|Y - X\beta\|^2 = -2X^\top Y + 2X^\top X\beta = -2X^\top (Y - X\beta)$$

   ↳ $\nabla(a^\top \beta) = a$ et $\nabla(\beta^\top A\beta) = 2A\beta$ pour A symétrique.

3. $$\nabla_\beta \left\|Y - X\hat{\beta}\right\|^2 = 0 \iff X^\top X\hat{\beta} = X^\top Y$$

   ↳ on divise par -2 ; le facteur $\frac{1}{n}$ du critère ne change pas l'argmin.

4. $$v^\top (2X^\top X) v = 2\|Xv\|^2 \geq 0$$

   ↳ hessienne positive : le critère est convexe, donc gradient nul ⇔ minimum global.

Proposition — Quand les MCO sont-ils uniques ? PAR CŒUR → S1

$\mathrm{Ker}(X^\top X) = \mathrm{Ker}\, X$. Donc $X^\top X$ inversible $\iff \mathrm{Ker}\, X = \{0\} \iff$ colonnes linéairement indépendantes $\iff \mathrm{rg}\, X = p$. C'est **impossible si** $p > n$, car $\mathrm{rg}\, X \leq \min(n, p)$. Si $X^\top X$ n'est pas inversible, il y a une infinité de solutions $\hat{\beta} + v$, $v \in \mathrm{Ker}\, X$, toutes avec le même ajustement $X\hat{\beta} = PY$.

L'idée : $X^\top X v = 0 \Rightarrow v^\top X^\top X v = \|Xv\|^2 = 0 \Rightarrow Xv = 0$. Par le théorème du rang, on en tire aussi $\mathrm{rg}(X^\top X) = \mathrm{rg}\, X$.

Formule — Projecteur, biais et covariance des MCO (cas $\mathrm{rg}\, X = p$) PAR CŒUR → S1

- $P = X(X^\top X)^{-1}X^\top$ vérifie $P^\top = P$, $P^2 = P$, $PX = X$ et $\mathrm{tr}\, P = \mathrm{rg}\, X$.
- $\mathbb{E}\hat{\beta}^{\mathrm{MC}} = \beta^*$ (sans biais) et $\mathrm{Cov}(\hat{\beta}^{\mathrm{MC}}) = \sigma^2(X^\top X)^{-1}$.
- Avec $X^\top X = \sum_j \mu_j v_j v_j^\top$ (v_j orthonormés) : $\mathrm{Var}(v_j^\top \hat{\beta}^{\mathrm{MC}}) = \dfrac{\sigma^2}{\mu_j}$ et $\mathbb{E}\left\|\hat{\beta}^{\mathrm{MC}} - \beta^*\right\|^2 = \sigma^2 \sum_{j=1}^{p} \dfrac{1}{\mu_j}$.

Pour la retrouver : $\hat{\beta}^{\mathrm{MC}} = AY$ avec $A = (X^\top X)^{-1}X^\top$; donc $\mathbb{E}\hat{\beta}^{\mathrm{MC}} = AX\beta^*$ et $\mathrm{Cov}(\hat{\beta}^{\mathrm{MC}}) = A(\sigma^2 I_n)A^\top$. Inverser une matrice symétrique, c'est inverser ses valeurs propres.

L'erreur de prédiction des MCO

Théorème — Erreur de prédiction des MCO Cours1 · diapo 7 PAR CŒUR À SAVOIR REFAIRE → S1

Pour tout (p, n) :

$$\mathbb{E}\left[\left\|X\hat{\beta}^{\mathrm{MC}} - X\beta^*\right\|_n^2\right] = \sigma^2 \frac{\mathrm{rg}(X)}{n}.$$

$X\hat{\beta}^{\mathrm{MC}}$ est donc consistant (au sens ℓ_2) dès que $\mathrm{rg}(X)/n \to 0$, par exemple si p est fixe ou si $p = o(n)$. Si $\mathrm{rg}\, X = n$ (le cas typique quand $p \geq n$), l'erreur vaut σ^2 : les MCO interpolent ($X\hat{\beta} = Y$).

L'idée : l'erreur est $P\varepsilon$, la part du bruit qui « tient » dans $\mathrm{Im}\, X$. Chaque dimension gardée apporte σ^2 en moyenne : **chaque paramètre coûte** σ^2/n.

Preuve express

1. $$X\hat{\beta}^{\mathrm{MC}} - X\beta^* = P(X\beta^* + \varepsilon) - X\beta^* = P\varepsilon$$
   ↳ $X\hat{\beta}^{\mathrm{MC}} = PY$ (P : projection orthogonale sur $\mathrm{Im}\, X$) et $PX\beta^* = X\beta^*$ car $X\beta^* \in \mathrm{Im}\, X$.

2. $$\|P\varepsilon\|^2 = \varepsilon^\top P^\top P\varepsilon = \varepsilon^\top P\varepsilon = \mathrm{tr}(P\varepsilon\varepsilon^\top)$$
   ↳ $P^\top P = P^2 = P$; un nombre est égal à sa trace ; $\mathrm{tr}(AB) = \mathrm{tr}(BA)$.

3. $$\mathbb{E}\,\|P\varepsilon\|^2 = \mathrm{tr}\left(P\,\mathbb{E}[\varepsilon\varepsilon^\top]\right) = \sigma^2\,\mathrm{tr}\,P$$
   ↳ linéarité de l'espérance et de la trace ; $\mathbb{E}[\varepsilon\varepsilon^\top] = \sigma^2 I_n$.

4 $$\operatorname{tr} P = \operatorname{rg} X$$

↳ un projecteur a pour valeurs propres 0 et 1, avec autant de 1 que la dimension de son image (en rang plein : $\operatorname{tr}(X(X^\top X)^{-1}X^\top) = \operatorname{tr} I_p = p$ par cyclicité).

5 $$\mathbb{E}\left\|X\hat{\beta}^{\mathrm{MC}} - X\beta^*\right\|_n^2 = \tfrac{1}{n}\mathbb{E}\left\|P\varepsilon\right\|^2 = \sigma^2\,\tfrac{\operatorname{rg} X}{n}$$

↳ on divise par n.

Formule — Erreur d'apprentissage des MCO et estimation de σ^2 À SAVOIR REFAIRE → S1, exercice 6

$$\mathbb{E}\left\|Y - X\hat{\beta}^{\mathrm{MC}}\right\|^2 = \sigma^2\,(n - \operatorname{rg} X),$$

donc l'estimateur suivant est sans biais :

$$\hat{\sigma}^2 = \frac{\left\|Y - X\hat{\beta}^{\mathrm{MC}}\right\|^2}{n - \operatorname{rg} X}.$$

Si $\operatorname{rg} X = n$, les résidus sont nuls : on ne peut plus estimer σ^2 ainsi.

Pour la retrouver : le bruit a n directions ; le modèle en « mange » $\operatorname{rg} X$ (elles passent dans $X\hat{\beta}$), il en reste $n - \operatorname{rg} X$ dans les résidus. C'est le « diviser par $n - p$ » des statistiques classiques.

Preuve express

1 $$Y - X\hat{\beta}^{\mathrm{MC}} = (I_n - P)Y = (I_n - P)\varepsilon$$

↳ $X\hat{\beta}^{\mathrm{MC}} = PY$; $(I_n - P)X\beta^* = 0$ car $X\beta^* \in \operatorname{Im} X$.

2 $$\mathbb{E}\left\|(I_n - P)\varepsilon\right\|^2 = \sigma^2 \operatorname{tr}(I_n - P)$$

↳ astuce de la trace, avec $(I_n - P)^\top(I_n - P) = I_n - P$ (projecteur orthogonal).

3 $$\operatorname{tr}(I_n - P) = n - \operatorname{tr} P = n - \operatorname{rg} X$$

↳ linéarité de la trace et $\operatorname{tr} P = \operatorname{rg} X$.

Piège — De quelle erreur parle-t-on ?

On prédit aux *mêmes* points $x_1, \dots, x_n$ et on compare à $X\beta^*$, pas à Y : le bruit est imprévisible. Ce n'est ni l'erreur sur de nouveaux x, ni l'erreur d'estimation $\left\|\hat{\beta} - \beta^*\right\|$. Ordres de grandeur, avec $\sigma = 1$, $n = 100$ et X de rang plein : $p = 5$ donne $0{,}05$; $p = 50$ donne $0{,}5$; $p = 100$ donne $1 = \sigma^2$.

Réflexe — L'astuce de la trace

Quand vous voyez $\mathbb{E}\left\|A\varepsilon\right\|^2$ ou $\mathbb{E}[\varepsilon^\top M\varepsilon]$ → écrivez $\mathbb{E}[\varepsilon^\top M\varepsilon] = \sigma^2 \operatorname{tr} M$ et $\mathbb{E}\left\|A\varepsilon\right\|^2 = \sigma^2 \operatorname{tr}(A^\top A)$; pour un projecteur, cela donne $\sigma^2 \operatorname{rg} P$. Rappel

Les limites des MCO

Proposition — Identifiabilité de β^* quand $p > n$ Cours1 · diapo 8 PAR CŒUR → S1

Si $p > n$, alors $\dim \operatorname{Ker} X = p - \operatorname{rg} X \geq p - n > 0$. Pour $v \in \operatorname{Ker} X$, $v \neq 0$, on a $X(\beta^* + v) = X\beta^*$: β^* et $\beta^* + v$ donnent la **même loi** de Y. Conséquences :

- $X^\top X$ ($p \times p$, de rang $\leq n$) n'est pas inversible ;
- les MCO ne sont pas uniques et pas interprétables ;
- typiquement $\operatorname{rg} X = n$: l'erreur vaut σ^2, il n'y a pas de consistance.

Plus généralement (diapo 8), β^* n'est pas identifiable dès que $X^\top X$ n'est pas inversible, c'est-à-dire dès que les colonnes de X sont liées.

Pour la retrouver : identifiable veut dire que deux paramètres différents donnent deux lois différentes ; or la loi de Y ne voit que $X\beta^*$. Ajoutez le théorème du rang et $\operatorname{rg} X \leq n$.

À comprendre — Le mauvais conditionnement À COMPRENDRE → S1

$\mu_j = v_j^\top X^\top X v_j = \|Xv_j\|^2$ mesure de combien bougent les prédictions quand β bouge dans la direction v_j. Une petite valeur propre désigne une direction presque invisible pour les données, donc une variance σ^2/μ_j énorme.

Des variables corrélées en créent. Deux colonnes centrées et normalisées ($\|X_j\|^2 = n$) de corrélation empirique ρ donnent les valeurs propres $n(1 \pm \rho)$ et $\operatorname{Var}(\hat{\beta}_1^{\mathrm{MC}}) = \frac{\sigma^2}{n(1-\rho^2)}$. Avec $\rho = 0{,}99$, c'est environ 50 fois plus qu'avec $\rho = 0$, et le conditionnement $\frac{1+\rho}{1-\rho}$ vaut 199.

À retenir : « $X^\top X$ inversible » ne suffit pas ; ce qui compte, c'est la **plus petite valeur propre**. La condition RE de la séance 3 en est la version raffinée.

Méthodes pénalisées et Ridge

Définition — Estimateur pénalisé Cours1 · diapo 10 PAR CŒUR → S1

$$\hat{\beta} = \operatorname*{arg\,min}_{\beta \in \mathbb{R}^p} \Big\{ \|Y - X\beta\|_n^2 + \operatorname{pen}(\beta, n) \Big\},$$

où $\operatorname{pen} : \mathbb{R}^p \to \mathbb{R}_+$ est la pénalité. Son paramètre $\lambda \geq 0$ règle la balance entre ajustement et simplicité : $\lambda = 0$ redonne les MCO ; $\lambda \to \infty$ écrase tout vers $\beta = 0$. Bien choisie, la pénalité évite d'inverser $X^\top X$.

Pour la retenir : quand $p > n$, une infinité de β expliquent parfaitement les données. La pénalité les départage (rasoir d'Occam) : prendre le plus petit (Ridge), ou celui qui utilise le moins de variables (ℓ_0, Lasso).

Formule — L'estimateur Ridge et ses deux conventions Cours1 · diapo 11 PAR CŒUR

À SAVOIR REFAIRE → S1 → TD1

Pour $\lambda > 0$, le minimiseur existe et est **unique**, même si $p \geq n$.

- Critère non normalisé $\|Y - X\beta\|^2 + \lambda \|\beta\|^2$ (convention du TD1) :

$$\hat{\beta}^R(\lambda) = (X^\top X + \lambda I_p)^{-1} X^\top Y.$$

- Critère normalisé $\|Y - X\beta\|_n^2 + \lambda \|\beta\|^2$: $(X^\top X + n\lambda I_p)^{-1} X^\top Y$.

La diapo 11 mélange les deux : elle écrit le critère normalisé, mais la formule du critère non normalisé.

Pour la retrouver : ce sont les équations normales dans lesquelles $X^\top X$ devient $X^\top X + \lambda I_p$, car le gradient gagne un terme $+2\lambda\beta$. Un $\frac{1}{n}$ devant l'ajustement se reporte sur λ : il devient $n\lambda$.

Preuve express (TD1, ex. 1 Q1)

On note $f(\beta) = \|Y - X\beta\|^2 + \lambda \|\beta\|^2$.

1. $$\nabla f(\beta) = -2X^\top (Y - X\beta) + 2\lambda\beta$$

   ↳ gradient des moindres carrés, plus $\nabla(\lambda\beta^\top\beta) = 2\lambda\beta$.

2. $$\begin{aligned} & v^\top (X^\top X + \lambda I_p) v \\ &= \|Xv\|^2 + \lambda \|v\|^2 \\ &\geq \lambda \|v\|^2 > 0 \quad (v \neq 0) \end{aligned}$$

   ↳ $X^\top X + \lambda I_p$ est définie positive (valeurs propres $\mu_j + \lambda \geq \lambda > 0$), donc inversible ; la hessienne $2(X^\top X + \lambda I_p)$ rend f strictement convexe : au plus un minimiseur.

3. $$f(\beta) \geq \lambda \|\beta\|^2 \xrightarrow[\|\beta\| \to \infty]{} +\infty$$

   ↳ f est continue et coercive : elle atteint son minimum (existence).

4. $$\begin{aligned} & \nabla f(\hat{\beta}) = 0 \\ \iff & (X^\top X + \lambda I_p)\hat{\beta} = X^\top Y \\ \iff & \hat{\beta} = (X^\top X + \lambda I_p)^{-1} X^\top Y \end{aligned}$$

   ↳ f est convexe et dérivable : minimiseur ⇔ gradient nul.

Formule — Le Ridge, direction propre par direction propre Cours1 · diapos 12–13 PAR CŒUR → S1

On écrit $X^\top X = \sum_j \mu_j v_j v_j^\top$ ($\mu_j = \|Xv_j\|^2 \geq 0$, v_j orthonormés) et l'on prend le critère non normalisé :

$$(X^\top X + \lambda I_p)^{-1} = \sum_{j=1}^{p} \frac{1}{\mu_j + \lambda} v_j v_j^\top,$$

$$v_j^\top \hat{\beta}^R(\lambda) = \frac{\mu_j}{\mu_j + \lambda} v_j^\top \hat{\beta}^{\mathrm{MC}} \qquad (\mu_j > 0).$$

- Les vecteurs propres sont ceux de $X^\top X$, et les valeurs propres sont décalées : $\mu_j \to \mu_j + \lambda$.
- Le conditionnement passe de $\frac{\mu_{\max}}{\mu_{\min}}$ à $\frac{\mu_{\max}+\lambda}{\mu_{\min}+\lambda}$.
- En design orthogonal ($X^\top X = I_p$) : $\hat{\beta}^R(\lambda) = \hat{\beta}^{\mathrm{MC}}/(1+\lambda)$.

Pour la retenir : inverser une matrice, c'est inverser ses valeurs propres. Une direction bien mesurée ($\mu_j \gg \lambda$) est gardée. Une direction mal mesurée ($\mu_j \ll \lambda$), là où la variance σ^2/μ_j des MCO explosait, est écrasée. Une direction de $\operatorname{Ker} X$ reçoit une composante nulle.

Formule — Biais et variance du Ridge

PAR CŒUR · À SAVOIR REFAIRE · → S1 · → TD1

Critère non normalisé $\|Y - X\beta\|^2 + \lambda \|\beta\|^2$. On écrit $X^\top X = PDP^\top$, avec P orthogonale de colonnes $v_1, \dots, v_p$ (ici P n'est pas un projecteur), $D = \operatorname{diag}(\mu_1, \dots, \mu_p)$ et $\theta_j = [P^\top \beta^*]_j = v_j^\top \beta^*$.

$$\mathbb{E}\hat{\beta}^R(\lambda) - \beta^* = -\lambda (X^\top X + \lambda I_p)^{-1} \beta^*.$$

Dans la direction v_j : biais $-\dfrac{\lambda}{\mu_j + \lambda}\,\theta_j$, variance $\dfrac{\sigma^2 \mu_j}{(\mu_j + \lambda)^2}$. En sommant :

$$\begin{aligned} B^R(\lambda) &= \left\| \mathbb{E}\hat{\beta}^R(\lambda) - \beta^* \right\|^2 \\ &= \sum_{j=1}^{p} \frac{\lambda^2 \theta_j^2}{(\mu_j + \lambda)^2}, \end{aligned}$$

$$\begin{aligned} V^R(\lambda) &= \mathbb{E} \left\| \hat{\beta}^R(\lambda) - \mathbb{E}\hat{\beta}^R(\lambda) \right\|^2 \\ &= \sigma^2 \sum_{j=1}^{p} \frac{\mu_j}{(\mu_j + \lambda)^2}, \end{aligned}$$

$$\mathbb{E} \left\| \hat{\beta}^R(\lambda) - \beta^* \right\|^2 = \sum_{j=1}^{p} \frac{\lambda^2 \theta_j^2 + \sigma^2 \mu_j}{(\mu_j + \lambda)^2}.$$

Le biais croît avec λ (vers $\|\beta^*\|^2$) et la variance décroît (vers 0). En $\lambda = 0$, si tous les $\mu_j > 0$, on retrouve le risque des MCO, $\sigma^2 \sum_j 1/\mu_j$.

Pour la retrouver : dans la direction v_j, le Ridge garde en moyenne la fraction $\frac{\mu_j}{\mu_j+\lambda}$ de θ_j, donc il en perd $\frac{\lambda}{\mu_j+\lambda}\theta_j$ (c'est le biais, au signe près). Et $v_j^\top \hat{\beta}^R = \frac{(Xv_j)^\top Y}{\mu_j+\lambda}$ a pour variance $\frac{\sigma^2 \|Xv_j\|^2}{(\mu_j+\lambda)^2} = \frac{\sigma^2 \mu_j}{(\mu_j+\lambda)^2}$.

Preuve express (TD1, ex. 1 Q3–Q4)

1

$$\begin{aligned} \mathbb{E}\hat{\beta}^R &= (X^\top X + \lambda I_p)^{-1} X^\top X \beta^* \\ &= \beta^* - \lambda (X^\top X + \lambda I_p)^{-1} \beta^* \end{aligned}$$

↳ $\hat{\beta}^R$ est linéaire en Y et $\mathbb{E}Y = X\beta^*$; on écrit $X^\top X = (X^\top X + \lambda I_p) - \lambda I_p$.

2

$$\begin{aligned} &(X^\top X + \lambda I_p)^{-1} \\ &= P (D + \lambda I_p)^{-1} P^\top \end{aligned}$$

↳ $X^\top X + \lambda I_p = PDP^\top + \lambda PP^\top = P(D + \lambda I_p)P^\top$, avec P orthogonale.

3

$$\begin{aligned} B^R(\lambda) &= \lambda^2 \left\| (D + \lambda I_p)^{-1} P^\top \beta^* \right\|^2 \\ &= \sum_j \frac{\lambda^2 \theta_j^2}{(\mu_j + \lambda)^2} \end{aligned}$$

↳ une matrice orthogonale conserve la norme ; $(D + \lambda I_p)^{-1}$ est diagonale.

4

$$\hat{\beta}^R - \mathbb{E}\hat{\beta}^R = A\varepsilon,$$
$$A = (X^\top X + \lambda I_p)^{-1} X^\top,$$
$$V^R = \mathbb{E}\,\|A\varepsilon\|^2 = \sigma^2 \operatorname{tr}(AA^\top)$$

↳ astuce de la trace, puis $\operatorname{tr}(A^\top A) = \operatorname{tr}(AA^\top)$; seule la covariance $\sigma^2 I_n$ du bruit sert, pas sa gaussianité.

5

$$AA^\top = P \operatorname{diag}\left(\frac{\mu_j}{(\mu_j+\lambda)^2}\right) P^\top$$
$$\Rightarrow\ V^R = \sigma^2 \sum_j \frac{\mu_j}{(\mu_j+\lambda)^2}$$

↳ $AA^\top = (X^\top X + \lambda I_p)^{-1} X^\top X (X^\top X + \lambda I_p)^{-1}$, que l'on diagonalise ; puis $\operatorname{tr}(PMP^\top) = \operatorname{tr} M$.

À comprendre — Un peu de Ridge bat toujours les MCO (hors diapos) À COMPRENDRE → S1

La dérivée en λ du terme j du risque vaut $\frac{2\mu_j(\lambda\theta_j^2 - \sigma^2)}{(\mu_j+\lambda)^3}$, soit $-2\sigma^2/\mu_j^2 < 0$ en $\lambda = 0$: le risque commence par **décroître** (Hoerl et Kennard, 1970).

En dimension 1, pour le critère $\sum_i (y_i - x_i\beta)^2 + \lambda\beta^2$ et avec $S = \sum_i x_i^2$: le biais vaut $-\frac{\lambda\beta^*}{S+\lambda}$, la variance $\frac{\sigma^2 S}{(S+\lambda)^2}$, et le meilleur choix est $\lambda^* = \sigma^2/\beta^{*2}$ (si $\beta^* \neq 0$). Il dépend de β^*, inconnu : en pratique, on choisit λ par validation croisée.

Proposition — La forme contrainte du Ridge TD1 · ex. 1 Q2 PAR CŒUR À SAVOIR REFAIRE → TD1

Pour $\lambda > 0$ et $M_\lambda = \left\|\hat{\beta}^R(\lambda)\right\|$, le Ridge $\hat{\beta}^R(\lambda) = (X^\top X + \lambda I_p)^{-1} X^\top Y$ est l'**unique** solution de

$$\min_{\|\beta\| \le M_\lambda} \|Y - X\beta\|^2 .$$

Le rayon M_λ dépend des données Y, et il décroît quand λ augmente.

L'idée : le Ridge est admissible pour le problème contraint. Une solution $\tilde{\beta}$ du problème contraint ajuste au moins aussi bien et ne paie pas plus de pénalité ; elle minimise donc le critère pénalisé, et l'unicité (Q1) donne $\tilde{\beta} = \hat{\beta}^R$.

Preuve express

1

$$\exists\, \tilde{\beta} \in \arg\min_{\|\beta\| \le M_\lambda} \|Y - X\beta\|^2$$

↳ fonction continue sur une boule fermée bornée, donc compacte.

2

$$\left\|Y - X\tilde{\beta}\right\|^2 \le \left\|Y - X\hat{\beta}^R\right\|^2,$$
$$\lambda\left\|\tilde{\beta}\right\|^2 \le \lambda M_\lambda^2 = \lambda\left\|\hat{\beta}^R\right\|^2$$

↳ $\hat{\beta}^R$ est dans la boule (sa norme vaut M_λ), et $\tilde{\beta}$ aussi.

3

$$f(\tilde{\beta}) \leq f(\hat{\beta}^R) = \min f$$
$$\Rightarrow \ \tilde{\beta} = \hat{\beta}^R$$

↳ on additionne les deux inégalités ; $\hat{\beta}^R$ est l'unique minimiseur de f (Q1). Le problème contraint a donc une solution (étape 1), et toute solution vaut $\hat{\beta}^R$: il y en a exactement une.

Piège — Le Ridge ne sélectionne pas

Il rétrécit tous les coefficients mais n'en annule aucun. En design orthogonal, $\hat{\beta}_j^R = \hat{\beta}_j^{\mathrm{MC}}/(1+\lambda)$ est non nul dès que $\hat{\beta}_j^{\mathrm{MC}} \neq 0$, ce qui arrive avec probabilité 1. Le Ridge ne répond donc pas à la question « quelles variables comptent ? ».

Sélection de variables et pénalités ℓ0 : Cp, AIC, BIC

À comprendre — Trois approches classiques de la sélection Cours1 · diapo 14 À COMPRENDRE → S1

- **Sous-ensembles** : pour chaque taille k, on cherche le meilleur ensemble B_k (plus petite somme des carrés des résidus). Il y a 2^p ensembles en tout.
- **Seuillage** d'un estimateur préliminaire (les MCO si $p \leq n$) : on garde les j tels que $\left|\hat{\beta}_j\right| > \tau$. Il faut un bon estimateur de départ, qu'on n'a plus si $p > n$.
- **Tests** de $H_0 : \beta_j = 0$ (Student, Fisher) : ils demandent $p < n$, et p tests à 5 % donnent environ 5 % de faux positifs parmi les variables inutiles (problème des tests multiples).

Définition — Support, indice de sparsité, « norme » ℓ0, critère ℓ0 Cours1 · diapos 15–16 PAR CŒUR → S1

- Support (ou ensemble de sparsité) : $\mathcal{A}^* = \{j : \beta_j^* \neq 0\}$; indice de sparsité : $|\mathcal{A}^*|$.
- $\|\beta\|_0 = \sum_{j=1}^p \mathbf{1}\{\beta_j \neq 0\}$ compte les coordonnées non nulles. Ce n'est pas une norme : $\|2\beta\|_0 = \|\beta\|_0$.
- Critère : $\mathrm{pen}(\beta, n) = \lambda_n \|\beta\|_0$. En pratique, on calcule les MCO $\hat{\beta}_m$ sur chaque modèle $m \subset \{1, \ldots, p\}$, puis $\hat{m}$ minimise $\left\|Y - X\hat{\beta}_m\right\|_n^2 + \lambda_n |m|$.

Pourquoi pénaliser : si $m \subset m'$, la projection sur le plus grand espace est plus proche de Y. L'erreur d'apprentissage *diminue donc toujours* quand le modèle grossit : sans prix par variable, on prendrait toujours le modèle complet.

Théorème — L'identité d'optimisme, fondement de Cp et d'AIC Cours1 · diapos 17–18 PAR CŒUR

À SAVOIR REFAIRE → S1

Bruit gaussien ; modèle m **fixé** ; P projection orthogonale sur $\mathrm{Im}(X_m)$; $d = \mathrm{rg}(X_m) = \mathrm{tr}\, P$; $X\hat{\beta}_m = PY$. Alors

$$\begin{aligned}&\mathbb{E}\left\|X\hat{\beta}_m - X\beta^*\right\|_n^2 + \sigma^2 \\ &= \mathbb{E}\left\|Y - X\hat{\beta}_m\right\|_n^2 + \frac{2\sigma^2 d}{n}.\end{aligned}$$

Le membre de gauche est l'erreur de test (de nouvelles réponses aux mêmes points). Donc $\left\|Y - X\hat{\beta}_m\right\|_n^2 + \frac{2\sigma^2 d}{n}$ estime sans biais l'erreur de test. Comme $d = \left\|\hat{\beta}_m\right\|_0$ presque sûrement (colonnes de X_m indépendantes), on obtient

$$\mathrm{pen}_{Cp}(\beta, n) = \mathrm{pen}_{AIC}(\beta, n) = \frac{2\sigma^2 \|\beta\|_0}{n}.$$

AIC vaut $-2\times$ log-vraisemblance $+ 2d$: dans le modèle gaussien à σ connu, il a le même minimiseur que Cp.

L'idée : le terme « ce que le modèle ne sait pas représenter », $\|(I-P)X\beta^*\|^2$, est le même des deux côtés. Le bruit vaut $\sigma^2(n-d)$ dans l'erreur d'apprentissage (le modèle a « mangé » d directions) et $\sigma^2 d$ dans l'erreur de prédiction. La différence (prédiction moins apprentissage) est $2\sigma^2 d - n\sigma^2$.

Preuve express

On note $\mu = X\beta^*$; P et $I-P$ sont des projections orthogonales de rangs d et $n-d$, et $P(I-P) = 0$.

1 $$\begin{aligned}&Y - PY = (I-P)\mu + (I-P)\varepsilon \\ &\Rightarrow \mathbb{E}\,\|Y - PY\|^2 \\ &\quad = \|(I-P)\mu\|^2 + \sigma^2(n-d)\end{aligned}$$

↳ le terme croisé est d'espérance nulle ; $\mathbb{E}\,\|(I-P)\varepsilon\|^2 = \sigma^2\,\mathrm{tr}(I-P)$.

2 $$\begin{aligned}&PY - \mu = -(I-P)\mu + P\varepsilon \\ &\Rightarrow \mathbb{E}\,\|PY - \mu\|^2 \\ &\quad = \|(I-P)\mu\|^2 + \sigma^2 d\end{aligned}$$

↳ le terme croisé est nul car $(I-P)P = 0$; $\mathbb{E}\,\|P\varepsilon\|^2 = \sigma^2\,\mathrm{tr}\,P$.

3 $$\begin{aligned}&\mathbb{E}\,\|PY - \mu\|^2 - \mathbb{E}\,\|Y - PY\|^2 \\ &\quad = 2\sigma^2 d - n\sigma^2\end{aligned}$$

↳ on soustrait : le biais disparaît. On divise par n et on fait passer $-\sigma^2$ à gauche.

Formule — La pénalité BIC Cours1 · diapos 19–20 PAR CŒUR → S1

Avec le critère normalisé $\|Y - X\beta\|_n^2 + \mathrm{pen}(\beta, n)$:

$$\mathrm{pen}_{BIC}(\beta, n) = \sigma^2 \log(n) \frac{\|\beta\|_0}{n}.$$

BIC est plus sévère que Cp et AIC dès que $\log n > 2$, c'est-à-dire $n \geq 8$ (« dès que $n > 7$ ») : il choisit des modèles plus parcimonieux.

- **BIC** est meilleur pour la **sélection** (estimer $\mathcal{A}^*$).
- **Cp et AIC** sont meilleurs pour la **prédiction** (estimer $X\beta^*$).

Pour la retenir : comparez les prix par variable, $2\sigma^2/n$ contre $\sigma^2 \log(n)/n$, sachant que $e^2 \approx 7{,}39$. Une variable inutile, ajoutée à un modèle qui contient déjà les vraies variables, fait baisser $\left\|Y - X\hat{\beta}\right\|^2$ de $\sigma^2 Z^2$, avec $Z \sim \mathcal{N}(0,1)$. AIC l'accepte si $|Z| > \sqrt{2}$, avec probabilité $\approx 0{,}157$ quel que soit n ; BIC l'accepte si $Z^2 > \log n$, avec une probabilité qui tend vers 0.

À comprendre — Le talon d'Achille de ℓ0 : 2^p modèles À COMPRENDRE → S1

Minimiser exactement un critère ℓ_0 demande de comparer 2^p sous-ensembles : $2^{30} \approx 10^9$, $2^{50} \approx 10^{15}$, $2^{100} \approx 10^{30}$. C'est infaisable au-delà de $p \approx 40$; le critère est non convexe (saut en 0).

Remèdes de la diapo : supposer les variables ordonnées ($p+1$ modèles emboîtés), ou se restreindre à une petite famille $\hat{F}$ d'estimateurs parcimonieux (ce que fournira le chemin du Lasso). Ces méthodes ont été conçues pour $p \leq n$.

Piège — Modèle fixé contre modèle choisi

L'identité d'optimisme vaut pour un modèle choisi **avant** de voir les données. Parmi beaucoup de candidats, le modèle retenu est celui qui a eu « de la chance » avec le bruit : son erreur d'apprentissage est encore plus optimiste. C'est ce que traite l'exercice 3 du TD1 (plus bas).

Réflexe — Comparer des modèles

Quand vous comparez des modèles de tailles différentes → n'utilisez jamais l'erreur d'apprentissage seule. Pénalisez $\left\|Y - X\hat{\beta}_m\right\|_n^2$ (Cp/AIC : $+2\sigma^2 d/n$; BIC : $+\sigma^2 d \log(n)/n$) ou faites une validation croisée.

Parcimonie et oracle

Définition — Hypothèse de parcimonie (S) Cours1 · diapo 21 PAR CŒUR → S1

On se place en grande dimension, $p > n$. **Hypothèse (S)** : il existe un entier s tel que $|\mathcal{A}^*| \leq s$, avec $s = o(n)$. Trois objectifs : estimer β^*, estimer $X\beta^*$, estimer le support $\mathcal{A}^*$.

À retenir : ce qui doit être petit devant n, c'est s ; p peut être bien plus grand que n.

Théorème — L'oracle : moindres carrés restreints à $\mathcal{A}^*$ Cours1 · diapo 22 PAR CŒUR → S1

$$\hat{\beta}^{MCR} = (X_{\mathcal{A}^*}^\top X_{\mathcal{A}^*})^{-1} X_{\mathcal{A}^*}^\top Y,$$

$$\mathbb{E}\Big[\,\big\|X\hat{\beta}^{MCR} - X\beta^*\big\|_n^2\,\Big] = \sigma^2\,\frac{|\mathcal{A}^*|}{n}.$$

$X_{\mathcal{A}^*}$ est formée des colonnes X_j, $j \in \mathcal{A}^*$, supposées indépendantes (rang $|\mathcal{A}^*| \le n$) ; $\hat{\beta}^{MCR}$ est complété par des 0 hors de $\mathcal{A}^*$. Sous (S), l'erreur est au plus $\sigma^2 s/n \to 0$: elle dépend de la vraie dimension, pas de p. Comme $\mathcal{A}^*$ est inconnu, cet estimateur est inutilisable : c'est une **référence**.

Preuve en une ligne : $X\beta^* = X_{\mathcal{A}^*}\beta^*_{\mathcal{A}^*}$, donc le modèle réduit est exact ; on applique le théorème des MCO à $X_{\mathcal{A}^*}$, de rang plein $|\mathcal{A}^*| \le n$.

À comprendre — La question de tout le cours À COMPRENDRE

Peut-on, **sans connaître** $\mathcal{A}^*$, faire presque aussi bien que l'oracle ? La séance 3 répond : le Lasso atteint $\sigma^2 s\log(p)/n$ à une constante près, sous une condition sur X et avec grande probabilité. Le prix de l'ignorance est un facteur $\log p$.

Le Lasso

Définition — Le Lasso, forme contrainte et forme pénalisée Cours1 · diapo 23 PAR CŒUR → S1

$$\tilde{\beta}^L(t) = \underset{\beta\in\mathbb{R}^p}{\arg\min}\,\|Y - X\beta\|_n^2$$
$$\text{sous la contrainte } \|\beta\|_1 \le t \quad (t \ge 0),$$

$$\hat{\beta}^L(\lambda) \in \underset{\beta\in\mathbb{R}^p}{\arg\min}\Big\{\,\|Y - X\beta\|_n^2 + \lambda\,\|\beta\|_1\,\Big\},$$

où $\|\beta\|_1 = \sum_{j=1}^p |\beta_j|$.

Les deux formes sont équivalentes point par point : à λ fixé, $t = \sum_j \left|\hat{\beta}_j^L(\lambda)\right|$ convient ; à t fixé, il existe un λ. Mais la correspondance $t \leftrightarrow \lambda$ **dépend des données**. LASSO signifie *Least Absolute Shrinkage and Selection Operator* (Tibshirani, 1996).

Pour la retenir : on écrit « $\in \arg\min$ » car la solution n'est pas toujours unique. Le nom dit les deux effets : *shrinkage* (il rétrécit, comme le Ridge) et *selection* (zéros exacts, comme ℓ_0). Cas extrêmes : $\lambda = 0$ redonne les MCO, λ grand donne $\hat{\beta}^L = 0$ (séance 2).

À comprendre — Pourquoi ℓ1 : le meilleur des deux mondes À COMPRENDRE → S1

Pénalité	Convexe (donc calculable) ?	Zéros exacts (donc sélection) ?
ℓ_0 : $\|\beta\|_0$ (Cp, AIC, BIC)	non — 2^p modèles	oui
ℓ_2 : $\|\beta\|_2^2$ (Ridge)	oui	non
ℓ_1 : $\|\beta\|_1$ (Lasso)	oui	oui

Sur une coordonnée, β_j^2 est plate en 0 : pénaliser un petit coefficient ne coûte presque rien, il n'y a aucune raison de l'annuler. $|\beta_j|$ garde une pente ± 1 jusqu'à 0 et pousse les petits coefficients jusqu'à exactement 0. Enfin, $|x|$ est l'enveloppe convexe de $\mathbf{1}\{x \neq 0\}$ sur $[-1, 1]$ (séance 4).

À comprendre — La géométrie des zéros exacts

À COMPRENDRE → S1

Si $X^\top X$ est inversible, $\|Y - X\beta\|^2 = \left\|Y - X\hat{\beta}^{\mathrm{MC}}\right\|^2 + (\beta - \hat{\beta}^{\mathrm{MC}})^\top X^\top X(\beta - \hat{\beta}^{\mathrm{MC}})$, par Pythagore et les équations normales. Les lignes de niveau sont donc des **ellipses centrées en** $\hat{\beta}^{\mathrm{MC}}$.

La forme contrainte gonfle l'ellipse jusqu'à ce qu'elle touche la boule $\{\|\beta\|_1 \leq t\}$, un losange dont les **coins sont sur les axes**. Le contact a souvent lieu en un coin, où une coordonnée est exactement nulle. Le disque du Ridge n'a pas de coin.

Proposition — De la pénalité à la contrainte

À SAVOIR REFAIRE → S1

Soit $\lambda \geq 0$, $\hat{\beta} = \hat{\beta}^L(\lambda)$ et $t = \left\|\hat{\beta}\right\|_1$. Alors $\hat{\beta}$ minimise $\|Y - X\beta\|_n^2$ sur la boule $\{\|\beta\|_1 \leq t\}$.

Preuve express

1

$$\|Y - X\beta\|_n^2 \geq \left\|Y - X\hat{\beta}\right\|_n^2 + \lambda\left(\left\|\hat{\beta}\right\|_1 - \|\beta\|_1\right)$$

↳ pour tout β, car $\hat{\beta}$ minimise le critère pénalisé ; on fait passer $\lambda\|\beta\|_1$ à droite.

2

$$\|\beta\|_1 \leq t = \left\|\hat{\beta}\right\|_1 \Rightarrow \|Y - X\beta\|_n^2 \geq \left\|Y - X\hat{\beta}\right\|_n^2$$

↳ le terme ajouté est alors ≥ 0 ; et $\hat{\beta}$ est lui-même dans la boule.

L'égalité des *ensembles* de solutions, réciproque comprise, est démontrée dans le TD1 (encadré suivant).

Théorème — Lasso pénalisé et Lasso contraint

TD1 · ex. 2 PAR CŒUR À SAVOIR REFAIRE → TD1

Critères du TD : $f_0(\beta) = \|Y - X\beta\|^2$; problème pénalisé $\min f_0 + \lambda\|\beta\|_1$ ($\lambda > 0$) ; problème contraint $\min_{\|\beta\|_1 \leq M_\lambda} f_0$.

1. Toutes les solutions du Lasso pénalisé ont les **mêmes valeurs ajustées** $X\hat{\beta}$ et la **même norme** $\left\|\hat{\beta}\right\|_1 =: N_\lambda$.
2. Avec $M_\lambda = N_\lambda$, les deux problèmes ont **exactement les mêmes solutions**.

Ce qui est unique pour le Lasso : $X\hat{\beta}$, $\left\|\hat{\beta}\right\|_1$ et la valeur du critère — pas forcément $\hat{\beta}$.

L'idée : le milieu de deux solutions est encore solution. Si les ajustements différaient sur une ligne, la stricte convexité de $x \mapsto x^2$ ferait strictement mieux : c'est absurde. Même ajustement ⇒ même f_0 ⇒ même pénalité ; on divise par $\lambda > 0$.

Preuve express

On note $f = f_0 + \lambda \|\cdot\|_1$, et $\hat\beta^{(1)}$, $\hat\beta^{(2)}$ deux solutions du problème pénalisé.

1

$$\bar\beta = \tfrac{1}{2}\hat\beta^{(1)} + \tfrac{1}{2}\hat\beta^{(2)} \ : \\ f_0(\bar\beta) < \tfrac{1}{2} f_0(\hat\beta^{(1)}) + \tfrac{1}{2} f_0(\hat\beta^{(2)}) \\ \text{si } X\hat\beta^{(1)} \neq X\hat\beta^{(2)}$$

↳ sur une ligne i_0 où les ajustements diffèrent, $\left(\frac{a+b}{2}\right)^2 < \frac{a^2+b^2}{2}$ pour $a \neq b$; l'inégalité est large sur les autres lignes.

2

$$\lambda \left\|\bar\beta\right\|_1 \\ \leq \tfrac{1}{2}\lambda \left\|\hat\beta^{(1)}\right\|_1 + \tfrac{1}{2}\lambda \left\|\hat\beta^{(2)}\right\|_1 \\ \Rightarrow \ f(\bar\beta) < \min f$$

↳ inégalité triangulaire. C'est une contradiction, donc $X\hat\beta^{(1)} = X\hat\beta^{(2)}$.

3

$$\lambda \left\|\hat\beta^{(1)}\right\|_1 = \min f - f_0(\hat\beta^{(1)}) \\ = \min f - f_0(\hat\beta^{(2)}) \\ = \lambda \left\|\hat\beta^{(2)}\right\|_1$$

↳ f_0 ne dépend que de $X\beta$; on divise par $\lambda > 0$. C'est faux pour $\lambda = 0$: les solutions $\hat\beta^{\text{MC}} + v$, $v \in \operatorname{Ker} X$, ont des normes ℓ_1 différentes.

4

$$f_0(\hat\beta) \leq f_0(\beta) + \lambda\big(\|\beta\|_1 - N_\lambda\big) \\ \leq f_0(\beta) \quad \text{si } \|\beta\|_1 \leq N_\lambda$$

↳ pénalisé ⊂ contraint : $f(\hat\beta) \leq f(\beta)$ et $\left\|\hat\beta\right\|_1 = N_\lambda$, donc $\hat\beta$ est admissible et optimal.

5

$$f_0(\tilde\beta) + \lambda \left\|\tilde\beta\right\|_1 \leq f_0(\hat\beta) + \lambda N_\lambda \\ = \min f$$

↳ contraint ⊂ pénalisé : soit $\tilde\beta$ une solution du problème contraint et $\hat\beta$ une solution pénalisée (il en existe : f est continue et coercive). $\hat\beta$ est admissible, donc $f_0(\tilde\beta) \leq f_0(\hat\beta)$; et $\lambda \left\|\tilde\beta\right\|_1 \leq \lambda M_\lambda = \lambda N_\lambda$. On additionne : $\tilde\beta$ minimise f.

Réflexe — Passer de pénalisé à contraint

Pour passer d'une forme à l'autre → la solution de l'une est **admissible** pour l'autre, avec pour rayon sa propre norme ; comparez les deux critères en ce point ; concluez par l'unicité (Ridge) ou par l'égalité des normes des solutions (Lasso).

TD1, exercice 3 — Sélection de modèles : une inégalité oracle

Définition — Le cadre de la sélection de modèles TD1 · ex. 3 PAR CŒUR → TD1

- $Y = f^* + \varepsilon$, avec $f^* = X\beta^* \in \mathbb{R}^n$ et $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$; le vrai modèle $m^* = \{j : \beta_j^* \neq 0\}$ est inconnu.
- Un modèle est un ensemble $m \subset \{1, \dots, p\}$: $S_m = \mathrm{Vect}\{X_j,\ j \in m\}$ (colonnes), $d_m = \dim S_m$, $\hat{f}_m = P_{S_m} Y$. On choisit dans une collection $\mathcal{M}$.
- Risque (non normalisé) : $R(\hat{f}_m) = \mathbb{E}\left\|\hat{f}_m - f^*\right\|^2$. Oracle : $m_0 = \arg\min_{m \in \mathcal{M}} R(\hat{f}_m)$; il n'est pas aléatoire mais dépend de β^*, donc $\hat{f}_{m_0}$ est inutilisable. But : choisir $\hat{m}$ tel que $\mathbb{E}\left\|\hat{f}_{\hat{m}} - f^*\right\|^2 \leq C\,\mathbb{E}\left\|\hat{f}_{m_0} - f^*\right\|^2$.
- m^* n'est pas forcément dans $\mathcal{M}$; et même si $m^* \in \mathcal{M}$, on peut avoir $m_0 \neq m^*$.

Formule — Le risque d'un modèle fixé TD1 · ex. 3 Q1 PAR CŒUR À SAVOIR REFAIRE → TD1

$$R(\hat{f}_m) = \underbrace{\|(I_n - P_{S_m}) f^*\|^2}_{\text{biais}^2} + \underbrace{\sigma^2 d_m}_{\text{variance}}.$$

Le biais² (carré de la distance de f^* à S_m) décroît quand le modèle grossit ; la variance croît. L'oracle réalise le meilleur compromis.

Pour la retrouver : $\hat{f}_m - f^* = -(I_n - P_{S_m}) f^* + P_{S_m}\varepsilon$; le terme croisé est d'espérance nulle et $\mathbb{E}\,\|P_{S_m}\varepsilon\|^2 = \sigma^2 \operatorname{tr} P_{S_m} = \sigma^2 d_m$. C'est le $\sigma^2\,\mathrm{rg}(X)/n$ de la séance 1, sans le $\frac{1}{n}$ et pour un modèle qui peut être faux.

Exemple : colonnes orthonormées, $\beta^* = (3;\, 0{,}1)$, $\sigma^2 = 1$. Les risques valent $9{,}01$ pour $\emptyset$, $1{,}01$ pour $\{1\}$, 10 pour $\{2\}$ et 2 pour $\{1,2\}$: l'oracle est $\{1\}$, différent de $m^* = \{1,2\}$.

Théorème — Inégalité oracle pour la sélection de modèles TD1 · ex. 3 Q2 PAR CŒUR → TD1

Critère et pénalité :

$$C(m) = \left\|Y - \hat{f}_m\right\|^2 + \sigma^2\,\mathrm{pen}(m),$$

$$\mathrm{pen}(m) = K\left(\sqrt{d_m} + \sqrt{2\log(1/\Pi_m)}\right)^2,$$

avec $K > 1$, des poids $\Pi_m \in\,]0, 1]$ tels que $\sum_{m \in \mathcal{M}} \Pi_m = 1$, et $\hat{m} = \arg\min_{m \in \mathcal{M}} C(m)$. Alors il existe $C'_K > 0$, qui ne dépend que de K, tel que

$$\begin{aligned}\mathbb{E}\left\|\hat{f}_{\hat{m}} - f^*\right\|^2 \\ \leq C'_K \min_{m \in \mathcal{M}} \Big\{ \mathbb{E}\left\|\hat{f}_m - f^*\right\|^2 \\ + \sigma^2 \log(\Pi_m^{-1}) + \sigma^2 \Big\}.\end{aligned}$$

Si de plus $\log(\Pi_m^{-1}) \leq C d_m$ pour tout m ($C > 0$ constante), alors $\mathbb{E}\left\|\hat{f}_{\hat{m}} - f^*\right\|^2 \leq C'_K(2 + C)\,\mathbb{E}\left\|\hat{f}_{m_0} - f^*\right\|^2$: **on fait aussi bien que l'oracle, à une constante près.**

Pour la retenir : c'est un « Cp en plus fort ». d_m paie la variance ; $\sqrt{2\log(1/\Pi_m)}$ paie la taille de la collection (borne de l'union pondérée) ; $K > 1$ permet d'absorber. La garantie vaut pour toute collection, sans condition sur X, avec des constantes indépendantes de n, p, f^* et de la taille de

$\mathcal{M}$. Notation : l'énoncé appelle C_K à la fois la constante de (d) et celle de (f) ; la page du TD les distingue, C_K pour (d) et C'_K pour (f). Leurs valeurs ($C_3 = 14$, $C'_3 = 28$) ne sont pas à retenir.

Méthode — La carte de la preuve À SAVOIR REFAIRE → TD1

1. **(a) Inégalité de base.** On part de $C(\hat{m}) \le C(m)$ et on remplace Y par $f^* + \varepsilon$. Comme $\left\|Y - \hat{f}\right\|^2 = \left\|f^* - \hat{f}\right\|^2 + 2\langle \varepsilon,\, f^* - \hat{f}\rangle + \|\varepsilon\|^2$, les $\|\varepsilon\|^2$ se simplifient :

$$\begin{aligned} R(\hat{f}_{\hat{m}}) \le\ & R(\hat{f}_m) \\ & + 2\mathbb{E}\langle \varepsilon,\, f^* - \hat{f}_m\rangle + \sigma^2 \mathrm{pen}(m) \\ & + \mathbb{E}\big[2\langle \varepsilon,\, \hat{f}_{\hat{m}} - f^*\rangle - \sigma^2 \mathrm{pen}(\hat{m})\big]. \end{aligned}$$

2. **(b) Terme croisé du modèle fixé.** $f^* - \hat{f}_m = (I_n - P_{S_m}) f^* - P_{S_m}\varepsilon$, donc $\mathbb{E}\langle \varepsilon,\, f^* - \hat{f}_m\rangle = -\mathbb{E}[\varepsilon^\top P_{S_m}\varepsilon] = -\sigma^2 d_m$ (bruit centré, puis trace d'un projecteur).
3. **(c) Terme croisé du modèle choisi.** Comme $\hat{m}$ dépend de ε, on ne peut que majorer. Le vecteur $v = \hat{f}_{\hat{m}} - f^*$ appartient à $\bar{S}_{\hat{m}} = \mathrm{Vect}(S_{\hat{m}}, f^*)$, donc $\langle \varepsilon,\, v\rangle = \langle P_{\bar{S}_{\hat{m}}}\varepsilon,\, v\rangle$. On applique Cauchy–Schwarz, puis Young $2xy \le ax^2 + y^2/a$ ($a > 1$), puis Pythagore dans $\bar{S}_{\hat{m}} = \tilde{S}_{\hat{m}} \oplus \mathrm{Vect}(f^*)$:

$$\begin{aligned} 2\langle \varepsilon,\, \hat{f}_{\hat{m}} - f^*\rangle \le\ & a\sigma^2\big(N^2 + U_{\hat{m}}\big) \\ & + a^{-1}\left\|\hat{f}_{\hat{m}} - f^*\right\|^2, \end{aligned}$$

   avec $N^2 = \left\|P_{\mathrm{Vect}(f^*)}\varepsilon\right\|^2/\sigma^2 \sim \chi^2(1)$ et $U_m = \left\|P_{\tilde{S}_m}\varepsilon\right\|^2/\sigma^2$.
4. **(d) Le cœur : contrôler $U_{\hat{m}}$.** On prend $a = \frac{K+1}{2}$ et $Z = a\sigma^2(N^2 + U_{\hat{m}}) - \sigma^2\mathrm{pen}(\hat{m})$, de sorte que (c) donne $2\langle \varepsilon,\, \hat{f}_{\hat{m}} - f^*\rangle - \sigma^2\mathrm{pen}(\hat{m}) \le a^{-1}\left\|\hat{f}_{\hat{m}} - f^*\right\|^2 + Z$. Il reste à montrer $\mathbb{E}Z \lesssim \sigma^2$, en quatre gestes :
   - *pire cas* : $aU_{\hat{m}} - \mathrm{pen}(\hat{m}) \le a\sum_m \left(U_m - \frac{2}{K+1}\mathrm{pen}(m)\right)_+$;
   - *modèle fixé* : la concentration gaussienne ($\varepsilon \mapsto \left\|P_{\tilde{S}_m}\varepsilon\right\|$ est 1-lipschitzienne) et Jensen ($\mathbb{E}\left\|P_{\tilde{S}_m}\varepsilon\right\| \le \sigma\sqrt{d_m}$) donnent $\sqrt{U_m} \le \sqrt{d_m} + \sqrt{2\xi_m}$, avec $\xi_m \sim \mathcal{E}(1)$;
   - *faire apparaître le poids* : avec $L_m = \log(1/\Pi_m)$, $\sqrt{2\xi_m} \le \sqrt{2L_m} + \sqrt{2(\xi_m - L_m)_+}$, puis $(x+y)^2 \le (1+\alpha)x^2 + (1+\alpha^{-1})y^2$ avec $\alpha = \frac{K-1}{K+1}$;
   - *espérance* : $\mathbb{E}(\xi - c)_+ \le e^{-c}$.

   On obtient

$$\mathbb{E}\Big(U_m - \tfrac{2}{K+1}\mathrm{pen}(m)\Big)_+ \le \tfrac{4K}{K-1}\,\Pi_m,$$

   puis, avec $\sum_m \Pi_m = 1$ et $\mathbb{E}N^2 \le 1$, $\mathbb{E}Z \le \big(\frac{K+1}{2} + \frac{2K(K+1)}{K-1}\big)\sigma^2 =: C_K\sigma^2$.
5. **(e) La pénalité est au plus de l'ordre du risque.** Avec $(u+v)^2 \le 2u^2 + 2v^2$ et $\sigma^2 d_m \le R(\hat{f}_m)$: $\sigma^2\mathrm{pen}(m) \le 2KR(\hat{f}_m) + 4K\sigma^2\log(\Pi_m^{-1})$.
6. **(f) Assembler et absorber.** On reporte (b), (d) (en espérance) et (e) dans (5), et l'on oublie $-2\sigma^2 d_m \le 0$. $R(\hat{f}_{\hat{m}})$ apparaît à droite avec le facteur $a^{-1} < 1$: on le fait passer à gauche, où il reste $\big(1 - \frac{1}{a}\big)R(\hat{f}_{\hat{m}}) = \frac{K-1}{K+1}R(\hat{f}_{\hat{m}})$:

$$\begin{aligned} \tfrac{K-1}{K+1}R(\hat{f}_{\hat{m}}) \le\ & (1+2K)R(\hat{f}_m) \\ & + 4K\sigma^2\log(\Pi_m^{-1}) + C_K\sigma^2. \end{aligned}$$

   On divise, on majore chaque coefficient par le plus grand, puis on prend le meilleur m : $C'_K = \frac{K+1}{K-1}\max(1+2K,\, 4K,\, C_K)$.
7. **(g) Cas $\log(\Pi_m^{-1}) \le Cd_m$.** On a $\sigma^2\log(\Pi_m^{-1}) \le C\sigma^2 d_m \le C\,R(\hat{f}_m)$, et $\sigma^2 \le \sigma^2 d_m \le R(\hat{f}_m)$ car $d_m \ge 1$. En effet, sous l'hypothèse, $d_m = 0$ imposerait $\Pi_m = 1$, donc des poids nuls pour les autres modèles : c'est

impossible dès que $\mathcal{M}$ contient au moins deux modèles (avec un seul modèle, $\hat{m} = m_0$ et il n'y a rien à montrer). Le minimum de (f) vaut donc au plus $(2+C)R(\hat{f}_{m_0})$, d'où $\mathbb{E}\left\|\hat{f}_{\hat{m}} - f^*\right\|^2 \leq C'_K(2+C)R(\hat{f}_{m_0})$.

À comprendre — Le rôle de $K > 1$ et des poids Π_m À COMPRENDRE → TD1

- $K > 1$ donne $\alpha = \frac{K-1}{K+1} > 0$ à l'étape (d) et $a = \frac{K+1}{2} > 1$ pour l'absorption de l'étape (f). Quand $K \to 1$, la constante explose.
- Les poids forment un **budget de complexité** de somme 1 : chaque modèle paie $\sqrt{2\log(1/\Pi_m)}$.
  - Modèles emboîtés $m_d = \{1, \dots, d\}$, $d = 1, \dots, p$, avec $\Pi_{m_d} \propto e^{-d}$: $\log(1/\Pi_{m_d}) \leq d$, et la pénalité est de l'ordre de d, comme Cp, avec une constante plus grande.
  - Tous les sous-ensembles (colonnes indépendantes, donc $d_m = |m|$), avec $\Pi_m = \frac{1}{(p+1)\binom{p}{d_m}}$: la pénalité est de l'ordre de $d_m \log(p/d_m)$, et **le** $\log p$ **revient**. On retrouve la vitesse $\sigma^2 s \log p$ du Lasso (soit $\sigma^2 s \log(p)/n$ en $\|\cdot\|_n^2$), sans condition sur X, mais avec 2^p modèles à parcourir.

Piège — Traiter $\hat{m}$ comme s'il était fixé

Écrire « $U_{\hat{m}} \sim \chi^2(d_{\hat{m}})$ » est faux : $\hat{m}$ est choisi *parce que* le bruit y est grand. Réflexe : pour un objet choisi par les données, bornez par le pire cas sur la collection ($\max \leq \sum(\cdot)_+$), puis contrôlez modèle par modèle, avec des poids de somme 1.

Piège — Deux erreurs du corrigé officiel à ne pas apprendre

(1) « $\mathbb{E}\|V\|^2 = \operatorname{tr}\operatorname{Var}(V)$, aussi dans le cas non centré » est faux. En général $\mathbb{E}\|V\|^2 = \operatorname{tr}\operatorname{Var}(V) + \|\mathbb{E}V\|^2$; seule l'égalité $\mathbb{E}\|V - \mathbb{E}V\|^2 = \operatorname{tr}\operatorname{Var}(V)$ est toujours vraie.

(2) À la question (d), le corrigé ne traite pas le terme $a\sigma^2 N^2$ de Z : il ne borne que $\mathbb{E}[aU_{\hat{m}} - \operatorname{pen}(\hat{m})] \leq \frac{2K(K+1)}{K-1}$. Comme $\mathbb{E}[aN^2] \leq \frac{K+1}{2}$, la bonne constante est $C_K = \frac{K+1}{2} + \frac{2K(K+1)}{K-1}$. La conclusion ne change pas.

Autre coquille, sans conséquence : dans l'exercice 2 Q3, il manque deux fois le facteur λ. Toutes les coquilles

2. Le Lasso de près : seuillage doux, KKT, chemin → S2

L'essentiel de la séance en 5 lignes

- **Convention** : $F(\beta) = \|Y - X\beta\|^2 + \lambda\|\beta\|_1$, sans $\frac{1}{n}$. D'où le facteur 2 des KKT et le seuil $\lambda/2$.
- **Curseur** : $\lambda = 0$ donne les moindres carrés ; $\lambda \geq \lambda_{\max} = 2\left\|X^\top Y\right\|_\infty$ donne $\hat{\beta}^L = 0$ exactement.
- **Design orthogonal** ($X^\top X = I_p$) : seuillage doux $\hat{\beta}^L_j = \operatorname{sgn}(b_j)(|b_j| - \lambda/2)_+$ avec $b = X^\top Y = \hat{\beta}^{\mathrm{MC}}$, c'est-à-dire sélection + rétrécissement.
- **KKT** : $2X_j^\top(Y - X\hat{\beta}) = \lambda\operatorname{sgn}(\hat{\beta}_j)$ si $\hat{\beta}_j \neq 0$, $2\left|X_j^\top(Y - X\hat{\beta})\right| \leq \lambda$ sinon ; nécessaires et suffisantes. Elles rendent le chemin linéaire par morceaux, et LARS le suit.
- **Objectifs** : prédiction, puis estimation, puis sélection (de plus en plus difficile). Une inégalité de sparsité fait comme l'oracle $\sigma^2 s/n$ au prix d'un $\log p$, sous une hypothèse sur $\Psi_n = X^\top X/n$.

La convention de toute la séance PAR CŒUR → S2

$$F(\beta) = \|Y - X\beta\|^2 + \lambda \|\beta\|_1$$

Pas de $\frac{1}{n}$: c'est le critère des diapos 26–27.

Ce qui change avec une autre normalisation : avec $\frac{1}{2}\|Y - X\beta\|^2 + \lambda\|\beta\|_1$, le 2 disparaît des KKT ($X_j^\top(Y - X\hat\beta) = \lambda\,\mathrm{sgn}(\hat\beta_j)$), le seuil orthogonal devient λ et $\lambda_{\max} = \left\|X^\top Y\right\|_\infty$. Avec $\frac{1}{n}\|Y - X\beta\|^2 + \lambda\|\beta\|_1$, les KKT s'écrivent $\frac{2}{n}X_j^\top(Y - X\hat\beta) = \lambda\,\mathrm{sgn}(\hat\beta_j)$ et $\lambda_{\max} = \frac{2}{n}\left\|X^\top Y\right\|_\infty$. Tableau complet : les conventions.

Le curseur λ et la lecture bayésienne

Ce que fait λ aux deux extrémités du curseur PAR CŒUR → S2

- $\lambda = 0$: ce sont les moindres carrés. Si $X^\top X$ est inversible, $\hat\beta^L = \hat\beta^{\mathrm{MC}}$ et toutes les variables sont (en général) sélectionnées ; si $p > n$, il y a une infinité de solutions et le Lasso à $\lambda = 0$ n'est pas bien défini.
- $\lambda \geq \lambda_{\max} = 2\left\|X^\top Y\right\|_\infty$: $\hat\beta^L = 0_p$ **exactement**, aucune variable n'est sélectionnée.
- Entre les deux : d'autant moins de variables que λ est grand (en tendance).

Pour la retrouver : comparez à $\beta = 0$. On a $F(\hat\beta) \leq F(0) = \|Y\|^2$, donc $\lambda\left\|\hat\beta\right\|_1 \leq \|Y\|^2$, soit $\left\|\hat\beta\right\|_1 \leq \|Y\|^2/\lambda \to 0$. Le seuil exact $\lambda_{\max}$ vient des KKT (plus bas).

Piège — « moins de variables quand λ grandit » n'est qu'une tendance

C'est exact en design orthogonal. Dans le cas général, quand λ diminue, une variable déjà active peut **ressortir** (son coefficient repasse par 0) : le nombre de variables actives n'est pas toujours monotone en λ.

Lecture bayésienne du Lasso (et du Ridge) PAR CŒUR À SAVOIR REFAIRE → S2

Modèle $Y \mid \beta \sim \mathcal{N}(X\beta, \sigma^2 I_n)$. A priori : $\beta_1, \ldots, \beta_p$ indépendants, de loi de Laplace de densité $\frac{a}{2}e^{-a|\beta_j|}$ (la diapo 25 appelle ce paramètre λ). Le maximum a posteriori (MAP) vaut alors

$$\hat\beta^{\mathrm{MAP}} = \arg\min_\beta \left\{ \|Y - X\beta\|^2 + 2\sigma^2 a \|\beta\|_1 \right\},$$

c'est un Lasso, de paramètre $\lambda_{\mathrm{Lasso}} = 2\sigma^2 a$. Avec un a priori gaussien, $\beta_j \sim \mathcal{N}(0, \tau^2)$ indépendants, le MAP est le Ridge $\|Y - X\beta\|^2 + \frac{\sigma^2}{\tau^2}\|\beta\|^2$.

Pour la retrouver : MAP = maximiser vraisemblance × a priori = minimiser $-\log$ de ce produit, soit $\frac{1}{2\sigma^2}\|Y - X\beta\|^2 + a\|\beta\|_1 + C$; multipliez par $2\sigma^2$. Règle : **pénalité =** $-\log$ **a priori** quand l'attache aux données est $-\log$ vraisemblance $= \frac{1}{2\sigma^2}\|Y - X\beta\|^2$; ramener le carré à $\|Y - X\beta\|^2$ multiplie la pénalité par $2\sigma^2$. Laplace ↔ ℓ_1, Gauss ↔ ℓ_2^2. Avec le critère $\frac{1}{n}\|Y - X\beta\|^2 + \lambda\|\beta\|_1$ (diapo 23), on multiplie par $2\sigma^2/n$: $\lambda = 2\sigma^2 a/n$.

Preuve express

1. $$\pi(\beta \mid Y) \propto f(Y \mid \beta)\,\pi(\beta)$$

   ↳ formule de Bayes ; le dénominateur $f(Y)$ ne dépend pas de β.

2

$$f(Y \mid \beta) = (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{\|Y - X\beta\|^2}{2\sigma^2}\right)$$

$$\pi(\beta) = \left(\frac{a}{2}\right)^p e^{-a\|\beta\|_1}$$

↳ densité du vecteur gaussien $\mathcal{N}(X\beta, \sigma^2 I_n)$; produit des p densités de Laplace (indépendance), et $\sum_j |\beta_j| = \|\beta\|_1$.

3

$$-\log \pi(\beta \mid Y) = \frac{1}{2\sigma^2}\|Y - X\beta\|^2 + a\|\beta\|_1 + C$$

↳ C regroupe tout ce qui ne dépend pas de β.

4

$$\hat{\beta}^{\text{MAP}} = \arg\min_{\beta} \left\{ \|Y - X\beta\|^2 + 2\sigma^2 a \|\beta\|_1 \right\}$$

↳ maximiser $\pi(\beta \mid Y) \Leftrightarrow$ minimiser $-\log \pi(\beta \mid Y)$; multiplier par $2\sigma^2 > 0$ ne change pas l'argmin.

Piège — ce n'est pas l'a priori qui est parcimonieux

Un tirage sous l'a priori de Laplace n'a presque sûrement **aucune** coordonnée nulle. Les zéros viennent du fait de prendre le **mode** (le MAP) d'une densité anguleuse en 0. Attention aussi à la lettre : la diapo 25 utilise λ pour la Laplace et pour le Lasso, alors que $\lambda_{\text{Lasso}} = 2\sigma^2\lambda_{\text{Laplace}}$ (critère $\|Y - X\beta\|^2 + \lambda\|\beta\|_1$).

Design orthogonal : le seuillage doux

Le découplage en design orthogonal

PAR CŒUR · À SAVOIR REFAIRE · → S2

Hypothèse : $X^\top X = I_p$ (colonnes orthonormées, ce qui impose $p \le n$). On pose $b = X^\top Y$; alors $b = \hat{\beta}^{\text{MC}}$ (les moindres carrés) et

$$F(\beta) = \sum_{j=1}^{p} \left[(\beta_j - b_j)^2 + \lambda|\beta_j|\right] + \|Y\|^2 - \|b\|^2 .$$

Chaque coordonnée résout son propre problème à une variable : $\hat{\beta}_j^L = \arg\min_{\beta_j \in \mathbb{R}} \left\{(\beta_j - b_j)^2 + \lambda|\beta_j|\right\}$.

Pour la retrouver : c'est Pythagore. $Xb = XX^\top Y$ est la projection orthogonale de Y sur $\operatorname{Im} X$, et $\|Xv\| = \|v\|$ pour tout v ; donc $\|Y - X\beta\|^2 = \|Y - Xb\|^2 + \|X(b - \beta)\|^2 = \|\beta - b\|^2 + \text{cte}$, une somme sur les coordonnées.

Preuve express

1

$$\|Y - X\beta\|^2 = \|Y\|^2 - 2\beta^\top X^\top Y + \beta^\top X^\top X\beta$$

↳ on développe $(Y - X\beta)^\top(Y - X\beta)$; les deux termes croisés sont des nombres égaux (transposés l'un de l'autre).

2

$$= \|Y\|^2 - 2\beta^\top b + \|\beta\|^2$$

↳ $X^\top Y = b$ et $X^\top X = I_p$.

3 $$= \sum_{j=1}^{p} (\beta_j - b_j)^2 + \|Y\|^2 - \|b\|^2$$

↳ on complète le carré coordonnée par coordonnée : $\beta_j^2 - 2b_j\beta_j = (\beta_j - b_j)^2 - b_j^2$.

4 On ajoute $\lambda \|\beta\|_1 = \sum_j \lambda |\beta_j|$: le j-ième terme de F ne dépend que de β_j, donc on minimise chaque terme séparément.

↳ minimiser une somme de fonctions de variables distinctes revient à minimiser chacune d'elles.

Théorème — Seuillage doux, convention $(\beta - b)^2 + \lambda|\beta|$ PAR CŒUR À SAVOIR REFAIRE → S2

$$\arg\min_{\beta \in \mathbb{R}} \left\{ (\beta - b)^2 + \lambda |\beta| \right\} = \begin{cases} b - \lambda/2 & \text{si } b > \lambda/2, \\ 0 & \text{si } |b| \leq \lambda/2, \\ b + \lambda/2 & \text{si } b < -\lambda/2, \end{cases}$$

soit, en une formule :

$$\arg\min_{\beta \in \mathbb{R}} \left\{ (\beta - b)^2 + \lambda |\beta| \right\} = \operatorname{sgn}(b) \big(|b| - \lambda/2 \big)_+ .$$

Pour la retrouver : sur $\beta > 0$, la dérivée $2(\beta - b) + \lambda$ s'annule en $b - \lambda/2$: c'est le 2 du carré qui divise λ. Contrôle : en $|b| = \lambda/2$ la formule donne 0 (le plateau inclut ses bords). Autre convention : $\frac{1}{2}(\beta - b)^2 + \lambda|\beta|$ donne $\operatorname{sgn}(b)(|b| - \lambda)_+$ (seuil λ, comme en Séance 4).

Preuve express (trois cas, puis la version sous-gradient)

1 Sur $\beta > 0$: $f(\beta) = (\beta - b)^2 + \lambda\beta$ et $f'(\beta) = 2(\beta - b) + \lambda$ s'annule en $\beta = b - \lambda/2$.

↳ candidat valable seulement s'il est dans la région $\beta > 0$, c'est-à-dire si $b > \lambda/2$.

2 Sur $\beta < 0$: $f'(\beta) = 2(\beta - b) - \lambda$ s'annule en $\beta = b + \lambda/2$.

↳ candidat valable seulement si $b < -\lambda/2$.

3 Si $|b| \leq \lambda/2$: $f'(\beta) = 2\beta + (\lambda - 2b) > 0$ sur $\beta > 0$ et $f'(\beta) = 2\beta - (\lambda + 2b) < 0$ sur $\beta < 0$.

↳ f décroît jusqu'à 0 puis croît : le minimum est en 0.

4 f est convexe, donc un point où la dérivée s'annule est le minimum global.

↳ somme de deux fonctions convexes (rappel).

5 Version sous-gradient (voir plus bas) : $0 \in 2(\hat\beta - b) + \lambda\, \partial|\cdot|(\hat\beta)$. Si $\hat\beta \neq 0$: $\hat\beta = b - \frac{\lambda}{2}\operatorname{sgn}(\hat\beta)$. Si $\hat\beta = 0$: $0 \in -2b + \lambda[-1, 1]$, soit $|b| \leq \lambda/2$.

↳ même résultat en deux lignes, sans étude de signe.

Le Lasso en design orthogonal et son chemin PAR CŒUR → S2

Si $X^\top X = I_p$, avec $b = \hat{\beta}^{\mathrm{MC}} = X^\top Y$ (Cours2, diapo 26) :

$$\hat{\beta}_j^L(\lambda) = \operatorname{sgn}(\hat{\beta}_j^{\mathrm{MC}})\left(\left|\hat{\beta}_j^{\mathrm{MC}}\right| - \lambda/2\right)_+ \quad \text{pour tout } j.$$

- La variable j est active si et seulement si $\lambda < 2\,|b_j|$: elle sort en $\lambda = 2\,|b_j|$.
- Chemin linéaire par morceaux : $\hat{\beta}_j^L(\lambda) = \operatorname{sgn}(b_j)(|b_j| - \lambda/2)$ est affine en λ (pente $-\operatorname{sgn}(b_j)/2$) pour $\lambda < 2\,|b_j|$, puis nul ; coudes en $\lambda = 2\,|b_1|, \ldots, 2\,|b_p|$.
- Quand λ décroît depuis $+\infty$, les variables entrent dans l'ordre des $|b_j|$ décroissants ; la première en $\lambda = 2\max_j |b_j| = 2\left\|X^\top Y\right\|_\infty$.

Pour la retrouver : c'est le seuillage doux appliqué à chaque b_j ; « sortir » signifie que $|b_j| - \lambda/2$ atteint 0.

Note sur la diapo 26 — un facteur 2

La diapo dit que la linéarité change en $\lambda^{(k)} = \left|\hat{\beta}_k^{\mathrm{MC}}\right|$. Avec sa propre formule (seuil $\lambda/2$), la coordonnée k s'annule quand $\left|\hat{\beta}_k^{\mathrm{MC}}\right| = \lambda/2$: le coude est en $\lambda^{(k)} = 2\left|\hat{\beta}_k^{\mathrm{MC}}\right|$. La valeur $\left|\hat{\beta}_k^{\mathrm{MC}}\right|$ de la diapo est celle du critère $\frac{1}{2}\|Y - X\beta\|^2 + \lambda\|\beta\|_1$ (seuil λ). Écrivez toujours la convention avant de répondre.

À comprendre — sélection et rétrécissement À COMPRENDRE → S2

- **Sélection** : les b_j tels que $|b_j| \le \lambda/2$ sont jugés indiscernables du bruit et mis exactement à 0.
- **Rétrécissement** (*shrinkage*) : les coefficients gardés perdent tous $\lambda/2$; même un très grand coefficient est biaisé de $\lambda/2$ (la Séance 6 corrige ce biais).
- Comparaison avec le Ridge ($\|Y - X\beta\|^2 + \lambda\|\beta\|^2$, $X^\top X = I$) : $b_j/(1+\lambda)$, jamais nul si $b_j \neq 0$. Le nom « Lasso » le dit : *Least Absolute Shrinkage and Selection Operator*.

Méthode — Calculer le Lasso en design orthogonal À SAVOIR REFAIRE → S2

1. Vérifier $X^\top X = I_p$: colonnes de norme 1, deux à deux orthogonales.
2. Calculer $b = X^\top Y$ (c'est $\hat{\beta}^{\mathrm{MC}}$) et le seuil $\lambda/2$ (convention $\|Y - X\beta\|^2 + \lambda\|\beta\|_1$).
3. Pour chaque j : $\hat{\beta}_j = 0$ si $|b_j| \le \lambda/2$; sinon b_j rapproché de 0 de $\lambda/2$.
4. Pour le chemin : la variable j entre en $\lambda = 2\,|b_j|$, et $\lambda_{\max} = 2\max_j |b_j|$.

Exemple de la séance : $b = (3, 2)$ et $\lambda = 5$ (seuil 2,5) donnent $\hat{\beta} = (0{,}5;\ 0)$; la variable 2 sort en $\lambda = 4$, la variable 1 en $\lambda = 6$.

Les conditions KKT : reconnaître la solution

Définition — Sous-gradient, et sous-différentiel de $|\cdot|$ PAR CŒUR → S2

Soit $\varphi : \mathbb{R} \to \mathbb{R}$ convexe. Le nombre g est un **sous-gradient** de φ en a si $\varphi(v) \geq \varphi(a) + g\,(v - a)$ pour tout $v \in \mathbb{R}$; leur ensemble est le **sous-différentiel** $\partial\varphi(a)$.

$$\partial\,|\cdot|\,(a) = \begin{cases} \{\operatorname{sgn}(a)\} & \text{si } a \neq 0, \\ [-1, 1] & \text{si } a = 0. \end{cases}$$

Trois règles : (1) là où φ est dérivable, $\partial\varphi(a) = \{\varphi'(a)\}$; (2) a minimise φ convexe **si et seulement si** $0 \in \partial\varphi(a)$; (3) si h est convexe dérivable et $\lambda \geq 0$, $\partial(h + \lambda\,|\cdot|)(a) = h'(a) + \lambda\,\partial\,|\cdot|\,(a)$.

Pour la retrouver : dessinez le « V » de $|u|$: en 0, toutes les droites de pente comprise entre -1 et 1 restent sous le graphe ; ailleurs, seule la tangente convient. La règle (2) est la définition même : $\varphi(v) \geq \varphi(a) + 0 \cdot (v - a)$ pour tout v. Version dans $\mathbb{R}^p$ et preuves : Séance 4.

Théorème — Les conditions KKT du Lasso PAR CŒUR À SAVOIR REFAIRE → S2

Critère $\|Y - X\beta\|^2 + \lambda\,\|\beta\|_1$, $\lambda \geq 0$ (Cours2, diapo 27). Un vecteur $\hat{\beta}^L \in \mathbb{R}^p$, d'ensemble actif $\hat{\mathcal{A}} = \{j : \hat{\beta}^L_j \neq 0\}$, est solution **si et seulement si**

$$\begin{cases} 2X_j^\top (Y - X\hat{\beta}^L) = \lambda\,\operatorname{sgn}(\hat{\beta}^L_j) & \forall j \in \hat{\mathcal{A}}, \\ 2\left|X_j^\top (Y - X\hat{\beta}^L)\right| \leq \lambda & \forall j \notin \hat{\mathcal{A}}. \end{cases}$$

Ces conditions sont nécessaires et suffisantes, parce que le critère est convexe.

Pour la retrouver : « $0 \in$ gradient de la partie lisse $+\lambda\,\partial\,|\cdot|$ », coordonnée par coordonnée ; le gradient de $\|Y - X\beta\|^2$ est $-2X^\top(Y - X\beta)$, d'où le 2. Autres conventions : avec $\frac{1}{2}\,\|\cdot\|^2$, $X_j^\top(Y - X\hat{\beta}) = \lambda\operatorname{sgn}(\hat{\beta}_j)$; avec $\frac{1}{n}\,\|\cdot\|^2$, $\frac{2}{n}X_j^\top(Y - X\hat{\beta}) = \lambda\operatorname{sgn}(\hat{\beta}_j)$.

Preuve express

1. $$\frac{\partial}{\partial\beta_j}\,\|Y - X\beta\|^2 = -2X_j^\top(Y - X\beta)$$
   ↳ j-ième coordonnée du gradient $-2X^\top(Y - X\beta)$ (rappel).

2. $$0 \in -2X_j^\top(Y - X\hat{\beta}) + \lambda\,\partial\,|\cdot|\,(\hat{\beta}_j)$$
   ↳ pour tout j : règle d'optimalité $0 \in \partial F(\hat{\beta})$ et règle de la somme, coordonnée par coordonnée (la pénalité est séparable ; la règle en dimension p est établie en Séance 4).

3. Si $\hat{\beta}_j \neq 0$: $\partial\,|\cdot|\,(\hat{\beta}_j) = \{\operatorname{sgn}(\hat{\beta}_j)\}$, donc $2X_j^\top(Y - X\hat{\beta}) = \lambda\operatorname{sgn}(\hat{\beta}_j)$.
   ↳ première ligne.

4. Si $\hat{\beta}_j = 0$: $\partial\,|\cdot|\,(0) = [-1, 1]$, donc $2X_j^\top(Y - X\hat{\beta}) \in [-\lambda, \lambda]$.
   ↳ seconde ligne.

5. F est convexe, donc $0 \in \partial F(\hat{\beta})$ caractérise exactement ses minimiseurs.
   ↳ d'où « nécessaires **et** suffisantes ».

À comprendre — des corrélations plafonnées à $\lambda/2$ À COMPRENDRE → S2

Notons $r = Y - X\hat{\beta}$ le résidu et $c_j = X_j^\top r$ (proportionnel à la corrélation empirique si les colonnes sont centrées et de même norme). Les KKT disent : **toutes** les variables vérifient $|c_j| \leq \lambda/2$ (un plafond) ; les variables **actives** sont **au plafond**, $|c_j| = \lambda/2$, et leur coefficient a le signe de c_j ; une variable sous le plafond a un coefficient nul. Les moindres carrés, eux, annulent toutes les corrélations ($X^\top(Y - X\hat{\beta}^{\mathrm{MC}}) = 0$) : le Lasso tolère un résidu encore corrélé aux variables, jusqu'à $\lambda/2$.

Proposition — Le seuil $\lambda_{\max}$ PAR CŒUR À SAVOIR REFAIRE → S2

Avec la convention $\|Y - X\beta\|^2 + \lambda\|\beta\|_1$:

$$\hat{\beta} = 0 \text{ est solution du Lasso} \iff \lambda \geq \lambda_{\max},$$

$$\lambda_{\max} := 2\left\|X^\top Y\right\|_\infty = 2\max_j \left|X_j^\top Y\right|.$$

Pour $\lambda \geq \lambda_{\max}$ et $\lambda > 0$, 0 est même l'**unique** solution. En design orthogonal, $\lambda_{\max} = 2\max_j |b_j|$.

Pour la retrouver : KKT en $\beta = 0$: aucune variable active, le résidu vaut Y, il ne reste que $2\left|X_j^\top Y\right| \leq \lambda$ pour tout j. Autres conventions : $\left\|X^\top Y\right\|_\infty$ avec $\frac{1}{2}\|\cdot\|^2$, et $\frac{2}{n}\left\|X^\top Y\right\|_\infty$ avec $\frac{1}{n}\|\cdot\|^2$.

Preuve express

1. En $\hat{\beta} = 0$, toutes les coordonnées sont nulles : seule la seconde ligne des KKT s'applique, avec le résidu $r = Y - X \cdot 0 = Y$.
   ↳ l'ensemble actif est vide.
2. 0 est solution $\Leftrightarrow 2\left|X_j^\top Y\right| \leq \lambda$ pour tout $j \Leftrightarrow \lambda \geq 2\max_j \left|X_j^\top Y\right|$.
   ↳ les KKT sont nécessaires et suffisantes : c'est une équivalence.
3. Unicité ($\lambda > 0$) : toute solution a la même norme ℓ_1 que la solution 0 (encadré suivant), donc elle est nulle.
   ↳ $\left\|\hat{\beta}\right\|_1 = 0 \Rightarrow \hat{\beta} = 0$.

Ce qui est unique dans le Lasso PAR CŒUR À SAVOIR REFAIRE → S2

Pour $\lambda > 0$, même quand $\hat{\beta}^L$ n'est pas unique (par exemple avec deux colonnes identiques), toutes les solutions ont les mêmes **valeurs ajustées** $X\hat{\beta}^L$ et la même norme $\left\|\hat{\beta}^L\right\|_1$.

L'idée : $u \mapsto \|Y - u\|^2$ est strictement convexe : le milieu de deux solutions ferait strictement mieux si leurs valeurs ajustées différaient. (Pour des données « génériques », $\hat{\beta}^L$ est d'ailleurs unique : hors programme.)

Preuve express (exercice 7 de la séance)

1. $$\left\|Y - \tfrac{u+v}{2}\right\|^2 = \tfrac{1}{2}\|Y - u\|^2 + \tfrac{1}{2}\|Y - v\|^2 - \tfrac{1}{4}\|u - v\|^2$$
   ↳ identité obtenue en développant les carrés, avec $u = X\hat{\beta}$, $v = X\tilde{\beta}$ pour deux solutions $\hat{\beta}, \tilde{\beta}$; on note m la valeur minimale de F.

2 $$F\left(\frac{\hat\beta+\tilde\beta}{2}\right) \le \frac{1}{2}F(\hat\beta) + \frac{1}{2}F(\tilde\beta) - \frac{1}{4}\|u-v\|^2$$
$$= m - \frac{1}{4}\|u-v\|^2$$
↳ on ajoute l'inégalité triangulaire $\left\|\frac{\hat\beta+\tilde\beta}{2}\right\|_1 \le \frac{1}{2}\left\|\hat\beta\right\|_1 + \frac{1}{2}\left\|\tilde\beta\right\|_1$.

3 Comme $F \ge m$ partout, $\|u-v\|^2 \le 0$, donc $X\hat\beta = X\tilde\beta$.
↳ m est le minimum de F.

4 $\lambda\left\|\hat\beta\right\|_1 = m - \left\|Y - X\hat\beta\right\|^2 = m - \left\|Y - X\tilde\beta\right\|^2 = \lambda\left\|\tilde\beta\right\|_1$, et $\lambda > 0$.
↳ mêmes valeurs ajustées ⇒ même norme ℓ_1.

Méthode — Vérifier qu'un vecteur est (ou n'est pas) solution du Lasso

À SAVOIR REFAIRE → S2

1. Écrire la convention du critère (le facteur devant λ).
2. Calculer le résidu $r = Y - X\beta$, puis les $2X_j^\top r$.
3. Variables actives ($\beta_j \neq 0$) : vérifier l'**égalité** $2X_j^\top r = \lambda\,\mathrm{sgn}(\beta_j)$, signe compris.
4. Variables inactives ($\beta_j = 0$) : vérifier $\left|2X_j^\top r\right| \le \lambda$.
5. Tout est vrai ⇒ β est solution (convexité). Une seule condition fausse ⇒ ce n'est pas la solution.

Méthode — Calculer le chemin à la main (design quelconque)

À SAVOIR REFAIRE → S2

1. Pour $\lambda \ge \lambda_{\max} = 2\left\|X^\top Y\right\|_\infty$: $\hat\beta = 0$.
2. Juste en dessous : la variable la plus corrélée ($\left|X_j^\top Y\right|$ maximal) entre, avec le signe de $X_j^\top Y$.
3. Deviner l'ensemble actif A et les signes s_A, puis résoudre le système linéaire $X_A^\top X_A\,\beta_A = X_A^\top Y - \frac{\lambda}{2}s_A$.
4. Vérifier les inégalités des inactives et la cohérence des signes : on obtient l'intervalle de λ où ce morceau est valable, donc le coude suivant.

Exemple de la séance ($X^\top X = \begin{pmatrix}2 & 1\\ 1 & 2\end{pmatrix}$, $X^\top Y = (5,3)$) : $\hat\beta = 0$ pour $\lambda \ge 10$; $\hat\beta = (\frac{5}{2} - \frac{\lambda}{4},\ 0)$ pour $2 \le \lambda \le 10$; $\hat\beta = (\frac{7}{3} - \frac{\lambda}{6},\ \frac{1}{3} - \frac{\lambda}{6})$ pour $\lambda \le 2$.

Pourquoi le chemin est linéaire par morceaux

PAR CŒUR À SAVOIR REFAIRE → S2

Sur un intervalle de λ où l'ensemble actif A et les signes $s_A = \mathrm{sgn}(\hat\beta_A)$ ne changent pas (colonnes de X_A linéairement indépendantes) :

$$\hat\beta_A(\lambda) = (X_A^\top X_A)^{-1}\left(X_A^\top Y - \frac{\lambda}{2}\,s_A\right)$$

(et $\hat\beta_{A^c} = 0$), qui est **affine en** λ. Les coudes ont lieu quand une variable inactive atteint $2\left|X_j^\top r\right| = \lambda$ (sa contrainte devient saturée : elle entre) ou quand un coefficient actif atteint 0 (la variable sort). Il y a un nombre fini de coudes.

Pour la retrouver : écrivez la première ligne des KKT pour tout A à la fois, $2X_A^\top(Y - X_A\hat\beta_A) = \lambda s_A$, et résolvez. En design orthogonal ($X_A^\top X_A = I$), on retrouve $\hat\beta_j = b_j - \frac{\lambda}{2}\,\mathrm{sgn}(b_j)$.

Preuve express

1. $$2X_A^\top(Y - X_A\hat{\beta}_A) = \lambda\, s_A$$
   ↳ première ligne des KKT, écrite pour tous les $j \in A$ à la fois ; $X\hat{\beta} = X_A\hat{\beta}_A$ car les autres coefficients sont nuls.

2. $$X_A^\top X_A\, \hat{\beta}_A = X_A^\top Y - \frac{\lambda}{2}\, s_A$$
   ↳ on développe et on divise par 2.

3. $$\hat{\beta}_A(\lambda) = (X_A^\top X_A)^{-1}\Big(X_A^\top Y - \frac{\lambda}{2}\, s_A\Big)$$
   ↳ colonnes actives linéairement indépendantes, donc $X_A^\top X_A$ inversible ; à A et s_A fixés, c'est affine en λ.

4. Ce morceau reste la solution tant que les signes de $\hat{\beta}_A(\lambda)$ restent s_A et que $2\left|X_j^\top r\right| \leq \lambda$ pour $j \notin A$. Il s'arrête quand un coefficient actif atteint 0 ou quand une inégalité devient une égalité.
   ↳ KKT nécessaires et suffisantes : ce sont les deux façons de les violer.

L'algorithme LARS

LARS (version Lasso), en mots À COMPRENDRE → S2

1. **Départ** en $\lambda = \lambda_{\max}$: $\beta = 0$, résidu $r = Y$; la variable la plus corrélée ($\left|X_j^\top Y\right|$ maximal) entre.
2. **Avancer** son coefficient dans le sens de sa corrélation : sa corrélation avec le résidu baisse, celles des autres changent.
3. **Nouvelle entrée** dès qu'une autre variable atteint la même corrélation absolue.
4. **Avancer ensemble** dans la direction qui garde les corrélations des actives **égales** : le résidu fait le même angle avec toutes les colonnes actives (direction « équiangulaire », d'où *Least Angle Regression*). Les coefficients évoluent linéairement : c'est la formule $(X_A^\top X_A)^{-1}(\dots)$ ci-dessus.
5. **Modification Lasso** : un coefficient actif qui atteint 0 fait sortir sa variable.
6. Continuer jusqu'à $\lambda = 0$ (les moindres carrés si $p \leq n$).

À retenir (diapo 28) : LARS est fondé sur les KKT, c'est-à-dire sur les corrélations entre le résidu et les variables. Avec la modification Lasso, il donne exactement le chemin, pour un coût de l'ordre d'un seul calcul de moindres carrés (tant que le nombre de coudes reste de l'ordre de $\min(n, p)$). **Défaut** : il gère mal les variables fortement corrélées et tend à n'en garder qu'une par groupe. Une variable écartée n'est donc pas forcément inutile ; la Séance 6 répond avec l'elastic net.

Prédire, estimer, sélectionner : les inégalités de sparsité

Définition — Les trois objectifs et leurs mesures PAR CŒUR → S2

- **Prédiction** : approcher le vecteur $X\beta^*$; on mesure $\left\|X\hat{\beta} - X\beta^*\right\|_n^2 = \frac{1}{n}\left\|X(\hat{\beta} - \beta^*)\right\|^2$.
- **Estimation** : approcher β^* ; on mesure $\left\|\hat{\beta} - \beta^*\right\|_1$, $\left\|\hat{\beta} - \beta^*\right\|_2$ ou $\left\|\hat{\beta} - \beta^*\right\|_\infty$.
- **Sélection** : retrouver le support $\mathcal{A}^* = \{j : \beta_j^* \neq 0\}$ (ou le vecteur des signes de β^*) ; on regarde l'événement $\{j : \hat{\beta}_j \neq 0\} = \mathcal{A}^*$.

La prédiction est la plus facile, puis vient l'estimation, puis la sélection.

Pour la retrouver : si $X_1 \approx X_2$ et $\beta^* = (1, 0)$, l'estimateur $\hat{\beta} = (0, 1)$ **prédit bien** ($X\hat{\beta} - X\beta^* = X_2 - X_1$ minuscule), **estime mal** ($\left\|\hat{\beta} - \beta^*\right\|_1 = 2$) et **sélectionne faux**. Estimer demande des colonnes pas trop semblables ; sélectionner demande en plus des coefficients non nuls assez grands pour dépasser le bruit.

Définition — Les inégalités de sparsité (IS) PAR CŒUR → S2

Sous l'hypothèse de sparsité (S) d'indice s ($|\mathcal{A}^*| \leq s$, avec $s = o(n)$), un estimateur $\hat{\beta}$ vérifie une IS (Cours2, diapo 30)

- en prédiction si

$$\mathbb{E}\left[\left\|X\beta^* - X\hat{\beta}\right\|_n^2\right] \leq C\, s\, \frac{L(n,p)}{n}\,;$$

- en estimation en norme ℓ_1 si

$$\mathbb{E}\left[\left\|\hat{\beta} - \beta^*\right\|_1\right] \leq C\, s\sqrt{\frac{L(n,p)}{n}}\,;$$

- en estimation en norme sup si

$$\mathbb{E}\left[\left\|\hat{\beta} - \beta^*\right\|_\infty\right] \leq C\sqrt{\frac{L(n,p)}{n}},$$

où $C > 0$ ne dépend ni de n, ni de p, ni de s, et $L(n,p)$ dépend au plus logarithmiquement de n et p (typiquement $L(n,p) = \log p$). Les IS peuvent aussi s'énoncer avec probabilité.

Pour la retrouver : avec des colonnes $\|X_j\|^2 = n$, chaque coordonnée est estimée à $\sigma\sqrt{\log p / n}$ près (le maximum de p gaussiennes vaut environ $\sqrt{2\log p}$) : c'est la vitesse en norme sup ; la norme ℓ_1 additionne s telles erreurs ; la prédiction additionne s carrés. L'étalon est l'oracle de la Séance 1, $\sigma^2 s/n$: une IS en prédiction coûte un facteur $\log p$ de plus, et non le facteur p/s qu'on paierait sans exploiter la parcimonie.

Piège — espérance ou probabilité ?

La diapo 30 écrit les IS en espérance, mais le théorème de la Séance 3 est énoncé « avec probabilité au moins $1 - p^{1-A^2/8}$ ». Les deux formes disent la même chose en substance. Dans les deux cas, on compare à l'oracle : $\mathbb{E}\left\|X\hat{\beta}^{MCR} - X\beta^*\right\|_n^2 = \sigma^2\,|\mathcal{A}^*|\,/n \leq \sigma^2 s/n$.

La matrice de Gram et le « bon » estimateur

Définition — La matrice de Gram Ψ_n PAR CŒUR → S2

$$\Psi_n = \frac{X^\top X}{n}, \qquad (\Psi_n)_{jk} = \frac{1}{n} X_j^\top X_k.$$

Si les colonnes sont centrées et normalisées ($\|X_j\|^2 = n$), la diagonale vaut 1 et $(\Psi_n)_{jk}$ est la corrélation empirique des variables j et k. Si $p > n$, $\operatorname{rg} \Psi_n \leq n < p$: Ψ_n n'est **jamais** inversible.

Pourquoi une hypothèse sur Ψ_n est indispensable (diapo 31) : si $X_1 = X_2$, les données ne distinguent pas $\beta^* = (1, 0, \dots)$ de $(0, 1, \dots)$; si $p > n$, il existe $v \neq 0$ avec $Xv = 0$, et $\beta^* + v$ prédit exactement comme β^*. On ne peut pas exiger l'inversibilité : la Séance 3 la remplace par une condition plus faible, la condition de valeurs propres restreintes.

Les quatre qualités d'un « bon » estimateur (diapo 31) PAR CŒUR → S2

1. **Optimalité** : asymptotique (consistance quand $n \to \infty$) et non asymptotique (IS valables pour tous n et p).
2. **Hypothèses** sur Ψ_n aussi faibles que possible.
3. **Complexité algorithmique** raisonnable, même si $p > n$.
4. **Interprétabilité** : un estimateur parcimonieux.

À retenir : le Lasso coche 3 et 4 par construction (convexe, calculable par LARS ; parcimonieux). Les critères ℓ_0 échouent sur 3 (2^p modèles), le Ridge sur 4. Les Séances 3 et 4 montrent que le Lasso coche aussi 1, sous une hypothèse faible sur Ψ_n.

Réflexes de la Séance 2

- Une valeur absolue dans un problème à une variable → séparez les cas $\beta > 0$, $\beta < 0$, $\beta = 0$, ou écrivez $0 \in$ (dérivée de la partie lisse) $+\lambda[-1, 1]$ en 0.
- $X^\top X = I$ → développez le carré : le problème se découple, chaque coordonnée est un seuillage doux de $b_j = X_j^\top Y$.
- « Montrer que β est la solution du Lasso » → résidu, puis $2X_j^\top r$, puis égalité (avec le signe) sur les actives et inégalité sur les inactives.
- « Pour quels λ la solution est-elle nulle ? » → $\lambda \geq 2 \left\|X^\top Y\right\|_\infty$; recalculez le facteur si la convention change.
- Une borne d'erreur → comparez-la à l'oracle $\sigma^2 s/n$: le prix acceptable est un facteur $\log p$.

3. Pourquoi le Lasso marche : cône, condition RE, théorème BRT

→ S3 → TD2

L'essentiel de la séance en 5 lignes

- Quand $p > n$, la matrice de Gram $\Psi_n = X^\top X/n$ est dégénérée : il existe $\delta \neq 0$ avec $X\delta = 0$, donc on ne peut pas contrôler une erreur quelconque.
- Mais sur l'événement $\mathcal{E} = \{\frac{2}{n} \left\|X^\top \varepsilon\right\|_\infty \leq r\}$, l'erreur $\delta = \hat{\beta}^L - \beta^*$ du Lasso vit dans le **cône** $\left\|\delta_{J_0^c}\right\|_1 \leq 3 \left\|\delta_{J_0}\right\|_1$, où $J_0 = J(\beta^*)$ est le vrai support.

- **RE**$(s,3)$ demande seulement que X « voie » les directions de ces cônes : $\|X\delta\|_2 \geq \kappa\sqrt{n}\ \|\delta_{J_0}\|_2$ pour tout J_0 de taille $\leq s$ et tout δ du cône de J_0, avec $\kappa = \kappa(s,3) > 0$.
- **Théorème BRT** : avec $r = A\sigma\sqrt{\log p/n}$ et $A > 2\sqrt{2}$, avec probabilité $\geq 1 - p^{1-A^2/8}$, l'erreur de prédiction est de l'ordre de $\sigma^2 s \log p/n$: celle de l'oracle, à un facteur $\log p$ près.
- **Preuve** : base → Hölder + $\mathcal{E}$ → découpage selon J_0 → cône → RE → $u^2 \leq cu$ → union + queue gaussienne. Le TD2 la refait via un lemme valable pour *tout* β.

Convention de la séance et du TD2 PAR CŒUR → S3

Le Lasso (critère (3) de la diapo 33) :

$$\hat{\beta}^L = \arg\min_{\beta\in\mathbb{R}^p} \left\{ \frac{1}{n}\|Y - X\beta\|_2^2 + 2r\|\beta\|_1 \right\}$$

Normalisation : la diagonale de $X^\top X/n$ vaut 1, c'est-à-dire $\|X_j\|^2 = n$ pour tout j. Conditions KKT :

$$\begin{aligned} \frac{1}{n}X_j^\top(Y - X\hat{\beta}^L) &= r\ \mathrm{sgn}(\hat{\beta}_j^L) \quad (\hat{\beta}_j^L \neq 0), \\ \left|\frac{1}{n}X_j^\top(Y - X\hat{\beta}^L)\right| &\leq r \qquad\qquad (\hat{\beta}_j^L = 0). \end{aligned}$$

Pour la retrouver : multiplié par n, le critère devient $\|Y - X\beta\|^2 + \lambda'\|\beta\|_1$ avec $\lambda' = 2nr$ (séance 2) ; en forme normalisée $\frac{1}{n}\|Y - X\beta\|^2 + \lambda\|\beta\|_1$, c'est $\lambda = 2r$. Les KKT de la séance 2, $2X_j^\top(Y - X\hat{\beta}) = \lambda'\mathrm{sgn}(\hat{\beta}_j)$, divisées par $2n$, donnent celles-ci : le « 2 » devant r sert à faire disparaître le 2 des KKT.

Notations, matrice de Gram, cas dégénéré

Définition — $J(\beta)$, $M(\beta)$, δ_J PAR CŒUR → S3

- $J(\beta) = \{j : \beta_j \neq 0\}$ est le support de β ; $M(\beta) = |J(\beta)| = \sum_{j=1}^p \mathbf{1}_{\{\beta_j\neq 0\}}$ est son nombre de coordonnées non nulles ($= \|\beta\|_0$).
- Pour $J \subset \{1,\dots,p\}$, $\delta_J \in \mathbb{R}^p$ a les mêmes coordonnées que δ sur J et des zéros sur J^c (c'est toujours un vecteur de $\mathbb{R}^p$).
- Dans la preuve : $\delta = \hat{\beta}^L - \beta^*$ (l'erreur) et $J_0 = J(\beta^*)$ (le vrai support, $|J_0| = M(\beta^*) \leq s$).

$$\begin{gathered} \delta = \delta_J + \delta_{J^c}, \\ \|\delta\|_1 = \|\delta_J\|_1 + \|\delta_{J^c}\|_1, \\ \|\delta_J\|_1 \leq \sqrt{|J|}\ \|\delta_J\|_2 \leq \sqrt{|J|}\ \|\delta\|_2. \end{gathered}$$

Pour la retrouver : δ_J et δ_{J^c} ont leurs coordonnées non nulles à des endroits disjoints, d'où l'addition des normes ℓ_1. La dernière inégalité est Cauchy–Schwarz entre $(|\delta_j|)_{j\in J}$ et $(1,\dots,1)$. Hors du vrai support, $\delta_{J_0^c} = \hat{\beta}^L_{J_0^c}$: c'est ce que le Lasso a mis, à tort, sur les variables inutiles.

Définition — Matrice de Gram, normalisation, $\varphi_{\max}$ PAR CŒUR → S3

$$\Psi_n = \frac{X^\top X}{n}, \qquad (\Psi_n)_{jk} = \frac{1}{n}X_j^\top X_k.$$

Hypothèse : la diagonale de Ψ_n vaut 1, c'est-à-dire $\|X_j\|^2 = n$ pour tout j. $\varphi_{\max}$ est la plus grande valeur propre de Ψ_n ; elle n'intervient que dans la borne (8) sur $M(\hat{\beta}^L)$.

Pourquoi normaliser : (1) la pénalité $\|\beta\|_1$ traite toutes les variables de la même façon, elles doivent donc être à la même échelle ; (2) dans la preuve, tous les $X_j^\top \varepsilon$ ont alors la même loi $\mathcal{N}(0, n\sigma^2)$, donc un même seuil r convient à toutes les variables. Repères : $\varphi_{\max} = 1$ en design orthonormé, $\varphi_{\max} = p$ si toutes les colonnes sont égales.

Proposition — Le cas dégénéré $p > n$ (formule (4), diapo 35) PAR CŒUR → S3

Si $p > n$:

$$\min_{\delta \neq 0} \frac{(\delta^\top \Psi_n \delta)^{1/2}}{\|\delta\|_2} = \min_{\delta \neq 0} \frac{\|X\delta\|_2}{\sqrt{n}\,\|\delta\|_2} = 0.$$

Les moindres carrés exigent Ψ_n définie positive : ils ne marchent pas. Le Lasso se contente d'un minimum pris sur un **ensemble restreint** de δ (le cône), avec au dénominateur la norme ℓ_2 d'**une partie seulement** de δ (celle sur le support).

Pour la retrouver : $\delta^\top \Psi_n \delta = \frac{1}{n}\|X\delta\|^2$; $\operatorname{rg} X \leq n < p$, donc $\dim \operatorname{Ker} X = p - \operatorname{rg} X \geq 1$: un $\delta \neq 0$ du noyau annule le quotient. Les deux restrictions annoncées sont exactement les deux ingrédients de la condition RE.

Le cône (diapo 36)

Proposition — Le cône, énoncé (5) de la diapo 36 PAR CŒUR À SAVOIR REFAIRE → S3

Soit l'événement

$$\begin{aligned}\mathcal{E} &= \left\{ \max_{1 \leq j \leq p} \frac{2}{n} \left| X_j^\top \varepsilon \right| \leq r \right\} \\ &= \left\{ \frac{2}{n} \left\| X^\top \varepsilon \right\|_\infty \leq r \right\},\end{aligned}$$

de probabilité $\geq 1 - p^{1 - A^2/8}$ quand $r = A\sigma\sqrt{\log p / n}$ (bruit $\mathcal{N}(0, \sigma^2)$ i.i.d., colonnes normalisées). Sur $\mathcal{E}$, l'erreur $\delta = \hat{\beta}^L - \beta^*$ vérifie l'inégalité centrale $(\star)$ et le cône (5), avec $J_0 = J(\beta^*)$:

$$\begin{aligned}\frac{1}{n}\|X\delta\|^2 + r\|\delta\|_1 &\leq 4r\|\delta_{J_0}\|_1 \qquad (\star) \\ \|\delta_{J_0^c}\|_1 &\leq 3\|\delta_{J_0}\|_1 \qquad (5)\end{aligned}$$

Notation : le TD2 et la fiche réflexes appellent cet événement $\mathcal{A}$. C'est le même : avec $V_j = \frac{1}{n} X_j^\top \varepsilon$, $\mathcal{A} = \bigcap_{j=1}^p \{2|V_j| \leq r\} = \mathcal{E}$. Cette fiche le note $\mathcal{E}$ partout, comme la séance 3, y compris dans la partie TD2.

Pour retrouver le 3 : pénalité $2r$ par unité, bruit au plus r par unité. Sur le support, l'erreur peut « rapporter » jusqu'à $2r + r$; hors du support, elle « coûte » au moins $2r - r$. Rapport $\frac{2r+r}{2r-r} = 3$, et en général $\frac{\text{pénalité}+\text{bruit}}{\text{pénalité}-\text{bruit}}$. Dans la preuve : $4 - 1 = 3$. En mots : au moins un quart de la masse ℓ_1 de l'erreur est sur le vrai support, car $\|\delta\|_1 \leq 4\|\delta_{J_0}\|_1$.

Preuve express

1

$$\frac{1}{n}\|X\delta\|^2 \le \frac{2}{n}\varepsilon^\top X\delta + 2r\big(\|\beta^*\|_1 - \|\hat\beta^L\|_1\big)$$

↳ inégalité de base : critère($\hat\beta^L$) $\le$ critère(β^*) ; $Y - X\beta^* = \varepsilon$ et $Y - X\hat\beta^L = \varepsilon - X\delta$; on développe $\|\varepsilon - X\delta\|^2$ et $\frac{1}{n}\|\varepsilon\|^2$ se simplifie.

2

$$\begin{aligned}\frac{2}{n}\varepsilon^\top X\delta &\le \frac{2}{n}\|X^\top\varepsilon\|_\infty \|\delta\|_1 \\ &\le r\|\delta\|_1 \quad \text{sur } \mathcal{E}\end{aligned}$$

↳ Hölder $|a^\top b| \le \|a\|_\infty \|b\|_1$, puis la définition de $\mathcal{E}$.

3

$$\begin{aligned}&\frac{1}{n}\|X\delta\|^2 + r\|\delta\|_1 \\ &\quad\le 2r\big(\|\delta\|_1 + \|\beta^*\|_1 - \|\hat\beta^L\|_1\big) \\ &\quad\le 4r\|\delta_{J_0}\|_1\end{aligned}$$

↳ on ajoute $r\|\delta\|_1$ des deux côtés et on factorise $2r$; puis le lemme de découpage (encadré suivant).

4

$$\begin{aligned}&r\|\delta_{J_0}\|_1 + r\|\delta_{J_0^c}\|_1 \le 4r\|\delta_{J_0}\|_1 \\ &\implies \|\delta_{J_0^c}\|_1 \le 3\|\delta_{J_0}\|_1\end{aligned}$$

↳ on retire $\frac{1}{n}\|X\delta\|^2 \ge 0$, on découpe $\|\delta\|_1$, on retranche $r\|\delta_{J_0}\|_1$ et on divise par $r > 0$.

Lemme — Le découpage selon le support PAR CŒUR À SAVOIR REFAIRE → S3

Si β^* est nul hors de J_0 et $\delta = \hat\beta^L - \beta^*$:

$$\|\delta\|_1 + \|\beta^*\|_1 - \|\hat\beta^L\|_1 \le 2\|\delta_{J_0}\|_1,$$

ou, de façon équivalente,

$$\|\beta^*\|_1 - \|\hat\beta^L\|_1 \le \|\delta_{J_0}\|_1 - \|\delta_{J_0^c}\|_1.$$

L'idée : hors du support, $\hat\beta^L_{J_0^c} = \delta_{J_0^c}$ et les termes se compensent exactement ; sur le support, inégalité triangulaire inversée $|a| - |b| \le |a-b|$ coordonnée par coordonnée. **C'est le signe moins devant $\|\delta_{J_0^c}\|_1$ qui fabrique le cône.**

Preuve express

1

$$\begin{aligned}\|\delta\|_1 &= \|\delta_{J_0}\|_1 + \|\delta_{J_0^c}\|_1, \\ \|\beta^*\|_1 &= \|\beta^*_{J_0}\|_1, \\ \|\hat\beta^L\|_1 &= \|\hat\beta^L_{J_0}\|_1 + \|\delta_{J_0^c}\|_1\end{aligned}$$

↳ découpage selon J_0 ; β^* est nul hors de J_0, donc $\delta_{J_0^c} = \hat\beta^L_{J_0^c}$.

2

$$\begin{aligned}\|\delta\|_1 + \|\beta^*\|_1 - \left\|\hat\beta^L\right\|_1 \\ = \|\delta_{J_0}\|_1 + \|\beta^*_{J_0}\|_1 - \left\|\hat\beta^L_{J_0}\right\|_1\end{aligned}$$

↳ on additionne les trois lignes : les deux termes $\left\|\delta_{J_0^c}\right\|_1$ se compensent exactement.

3

$$\begin{aligned}\left\|\beta^*_{J_0}\right\|_1 - \left\|\hat\beta^L_{J_0}\right\|_1 &= \sum_{j\in J_0}\left(|\beta^*_j| - \left|\hat\beta^L_j\right|\right) \\ &\le \sum_{j\in J_0}\left|\beta^*_j - \hat\beta^L_j\right| = \|\delta_{J_0}\|_1\end{aligned}$$

↳ triangulaire inversée, coordonnée par coordonnée. Reporté dans la ligne 2 : $\le 2\,\|\delta_{J_0}\|_1$.

Calcul de la diapo 36 — Pourquoi le cône sauve la situation À SAVOIR REFAIRE → S3

Soit Ψ une matrice $p \times p$ définie positive et $\omega_n = \max_{i,j}|(\Psi_n - \Psi)_{ij}|$. Pour tout $\delta \neq 0$ vérifiant (5) :

$$\begin{aligned}\frac{\delta^\top \Psi_n \delta}{\|\delta\|_2^2} &\ge \frac{\delta^\top \Psi \delta}{\|\delta\|_2^2} - \frac{\omega_n \|\delta\|_1^2}{\|\delta\|_2^2} \\ &\ge \frac{\delta^\top \Psi \delta}{\|\delta\|_2^2} - 16\,\omega_n\,|J_0|\,.\end{aligned}$$

Donc si $16\,\omega_n\,|J_0| < \lambda_{\min}(\Psi)$, le quotient reste loin de 0 sur le cône : une « positivité définie restreinte ».

Pour la retrouver : $\left|\delta^\top(\Psi_n - \Psi)\delta\right| \le \omega_n \sum_{i,j}|\delta_i|\,|\delta_j| = \omega_n\,\|\delta\|_1^2$; le cône donne $\|\delta\|_1 \le 4\,\|\delta_{J_0}\|_1 \le 4\sqrt{|J_0|}\;\|\delta_{J_0}\|_2 \le 4\sqrt{|J_0|}\;\|\delta\|_2$, d'où le facteur $16\,|J_0|$. Sans le cône, on n'aurait que $\|\delta\|_1^2 \le p\,\|\delta\|_2^2$: le facteur serait p.

La condition de valeurs propres restreintes RE$(s,3)$ (diapo 37)

Définition — La condition RE$(s,3)$ et la constante $\kappa(s,3)$ PAR CŒUR → S3

Pour un entier s tel que $1 \le s \le p$, la condition RE$(s,3)$ demande $\kappa(s,3) > 0$, où

$$\kappa(s,3) = \min_{\substack{J_0 \subseteq \{1,\dots,p\} \\ |J_0| \le s}} \; \min_{\substack{\delta \neq 0 \\ \left\|\delta_{J_0^c}\right\|_1 \le 3\left\|\delta_{J_0}\right\|_1}} \frac{\|X\delta\|_2}{\sqrt{n}\;\|\delta_{J_0}\|_2}$$

Forme utilisable : pour tout J_0 avec $|J_0| \le s$ et tout δ tel que $\left\|\delta_{J_0^c}\right\|_1 \le 3\,\|\delta_{J_0}\|_1$,

$$\|\delta_{J_0}\|_2 \le \frac{\|X\delta\|_2}{\kappa(s,3)\sqrt{n}}.$$

Pour la retrouver : c'est le quotient de la formule (4) avec les deux restrictions de la diapo 35 : (i) δ seulement dans le cône ; (ii) au dénominateur, seulement $\|\delta_{J_0}\|_2$. Le premier minimum porte sur *tous* les J_0 de taille $\le s$ parce qu'on ne connaît pas le vrai support : on pourra appliquer RE au vrai $J_0 = J(\beta^*)$ sans le connaître. s joue le rôle d'une borne sur la parcimonie $M(\beta^*)$.

Ce qu'il faut savoir sur $\kappa(s,3)$ PAR CŒUR À SAVOIR REFAIRE → S3

- **Plus faible que l'inversibilité :** $\kappa(s,3) \geq \sqrt{\lambda_{\min}(\Psi_n)}$, mais RE peut être vraie avec $\lambda_{\min}(\Psi_n) = 0$ (cas $p > n$) : c'est tout son intérêt.
- **Toujours** $\kappa(s,3) \leq 1$ quand les colonnes sont normalisées ($\|X_j\|^2 = n$).
- **Design orthonormé** $X^\top X = nI_p$ (possible seulement si $p \leq n$) : $\kappa(s,3) = 1$ pour tout s.
- **Deux colonnes identiques** $X_1 = X_2$: $\kappa(s,3) = 0$ pour tout $s \geq 1$ (RE échoue).
- **RE$(s,3)$ entraîne RE$(s,1)$:** $\kappa(s,1) \geq \kappa(s,3)$.

Les cinq preuves, une ligne chacune

1

$$\|X\delta\|^2 = n\,\delta^\top \Psi_n \delta \geq n\lambda_{\min}\,\|\delta\|_2^2 \geq n\lambda_{\min}\,\|\delta_{J_0}\|_2^2$$

↳ quotient de Rayleigh, puis $\|\delta_{J_0}\|_2 \leq \|\delta\|_2$: chaque quotient de RE est $\geq \sqrt{\lambda_{\min}}$.

2

$$J_0 = \{j\},\ \delta = e_j : \quad \frac{\|X_j\|_2}{\sqrt{n}\cdot 1} = 1$$

↳ e_j est dans le cône ($\delta_{J_0^c} = 0$) : le minimum vaut au plus 1.

3

$$\|X\delta\|^2 = \delta^\top X^\top X \delta = n\,\|\delta\|_2^2 \geq n\,\|\delta_{J_0}\|_2^2$$

↳ si $X^\top X = nI_p$: le quotient est toujours ≥ 1, et vaut 1 en $\delta = e_j$.

4

$$\left\|\delta_{J_0^c}\right\|_1 = 1 \leq 3 = 3\,\|\delta_{J_0}\|_1\,,\quad X\delta = X_1 - X_2 = 0$$

↳ avec $\delta = (1,-1,0,\ldots,0)$ et $J_0 = \{1\}$: δ est dans le cône et invisible pour X, le quotient est nul.

5

$$\left\|\delta_{J_0^c}\right\|_1 \leq \|\delta_{J_0}\|_1 \implies \left\|\delta_{J_0^c}\right\|_1 \leq 3\,\|\delta_{J_0}\|_1$$

↳ le cône de constante 1 est inclus dans celui de constante 3 ; un minimum sur un ensemble plus petit est plus grand.

Proposition — Ce que RE$(s,3)$ impose aux colonnes de X (remarques des diapos 37 et 39)

PAR CŒUR À SAVOIR REFAIRE → S3

Sous RE$(s,3)$: pour tout $\delta \neq 0$ avec $M(\delta) \leq 2s$, on a $X\delta \neq 0$. Autrement dit, **toute famille d'au plus $2s$ colonnes de X est libre**, et les sous-matrices carrées $X_K^\top X_K/n$ de la matrice de Gram (K ensemble d'au plus $2s$ indices, X_K les colonnes d'indices dans K) sont définies positives. Conséquences :

- il faut $n \geq 2s$ (dès que $p \geq 2s$) ;
- **identifiabilité** : β^* est le seul vecteur à au plus s coordonnées non nulles tel que $X\beta = X\beta^*$. RE n'implique pas l'identifiabilité (X n'est pas injective quand $p > n$), mais β^* est défini de façon unique grâce à $M(\beta^*) \leq s$.

Preuve express

1 Soit J l'ensemble des indices des s plus grandes coordonnées de δ en valeur absolue.

↳ si $M(\delta) \leq s$, prendre $J = J(\delta)$: alors $\delta_{J^c} = 0$.

2
$$\begin{aligned} \|\delta_{J^c}\|_1 &\leq s \cdot \min_{j \in J} |\delta_j| \leq \|\delta_J\|_1 \\ &\leq 3 \|\delta_J\|_1 \end{aligned}$$

↳ δ_{J^c} a au plus $2s - s = s$ coordonnées non nulles, chacune plus petite que toutes celles de J : δ est dans le cône de J (même dans celui de constante 1).

3
$$\|X\delta\|_2 \geq \kappa(s, 3)\sqrt{n}\ \|\delta_J\|_2 > 0$$

↳ RE avec $|J| \leq s$; $\delta_J \neq 0$ car J contient la plus grosse coordonnée, non nulle.

4
$$\begin{aligned} & X\beta = X\beta', \quad M(\beta), M(\beta') \leq s \\ \implies & M(\beta - \beta') \leq 2s \\ & \text{et } X(\beta - \beta') = 0 \\ \implies & \beta = \beta' \end{aligned}$$

↳ identifiabilité parmi les vecteurs s-parcimonieux ; et $2s$ vecteurs libres de $\mathbb{R}^n$ demandent $2s \leq n$.

Méthode — Montrer que RE$(s, 3)$ échoue

À SAVOIR REFAIRE → S3

Exhiber J_0 avec $|J_0| \leq s$ et $\delta \neq 0$ tels que $X\delta = 0$ (ou $\|X\delta\|$ arbitrairement petit) **et** $\|\delta_{J_0^c}\|_1 \leq 3\|\delta_{J_0}\|_1$. Réflexe : chercher une combinaison linéaire nulle de *peu* de colonnes, et mettre dans J_0 les indices des plus gros coefficients. Exemple : $X_1 \perp X_2$ normalisées et $X_3 = (X_1 + X_2)/\sqrt{2}$; $\delta = (1, 1, -\sqrt{2})$ vérifie $X\delta = 0$, et avec $J_0 = \{3\}$: $2 \leq 3\sqrt{2}$. RE$(1, 3)$ échoue alors qu'aucune paire de colonnes n'est colinéaire.

Piège — RE n'est pas l'injectivité

RE ne rend pas X injective : quand $p > n$, une infinité de β vérifient $X\beta = X\beta^*$. RE demande seulement que le noyau de X évite les cônes. En dimension 2 avec $s = 1$, les cônes de $J_0 = \{1\}$ et $J_0 = \{2\}$ recouvrent tout le plan : là, RE$(1, 3)$ équivaut à l'inversibilité. RE n'est vraiment plus faible qu'en grande dimension, où les vecteurs du noyau sont « étalés » sur beaucoup de coordonnées. Enfin, RE n'est pas vérifiable sur une matrice donnée (il faudrait parcourir tous les J_0).

Le théorème de Bickel, Ritov et Tsybakov (diapo 38)

Théorème (Bickel, Ritov, Tsybakov, 2009) PAR CŒUR À SAVOIR REFAIRE → S3

Hypothèses :

- les ε_i sont des variables indépendantes de loi $\mathcal{N}(0, \sigma^2)$, avec $\sigma^2 > 0$;
- les éléments diagonaux de $X^\top X/n$ valent 1 (soit $\|X_j\|^2 = n$) ;
- $M(\beta^*) \leq s$, où $1 \leq s \leq p$, $n \geq 1$, $p \geq 2$;
- RE$(s, 3)$ est vérifiée.

On prend le Lasso (3), $\hat{\beta}^L = \arg\min_{\beta \in \mathbb{R}^p} \left\{ \frac{1}{n} \|Y - X\beta\|_2^2 + 2r \|\beta\|_1 \right\}$, avec $r = A\sigma\sqrt{\dfrac{\log p}{n}}$ et $A > 2\sqrt{2}$. Alors, **avec probabilité au moins** $1 - p^{1-A^2/8}$:

$$\left\|\hat{\beta}^L - \beta^*\right\|_1 \leq \frac{16A}{\kappa^2(s,3)}\, \sigma s \sqrt{\frac{\log p}{n}} \quad (6)$$

$$\left\|X(\hat{\beta}^L - \beta^*)\right\|_2^2 \leq \frac{16A^2}{\kappa^2(s,3)}\, \sigma^2 s \log p \quad (7)$$

$$M(\hat{\beta}^L) \leq \frac{64\,\varphi_{\max}}{\kappa^2(s,3)}\, s \quad (8)$$

Pour retrouver les constantes : tout sort de $c = \dfrac{4r\sqrt{s}}{\kappa}$ (étape 3) et de $u = \|X\delta\|_2/\sqrt{n} \leq c$. Alors $\frac{1}{n}\|X\delta\|^2 \leq c^2 = \frac{16r^2 s}{\kappa^2}$, et $nr^2 = A^2\sigma^2 \log p$ donne (7) ; $r\|\delta\|_1 \leq c^2$ donne $\|\delta\|_1 \leq \frac{16rs}{\kappa^2}$, c'est (6) ; chaque variable sélectionnée coûte $\frac{r^2}{4}$, donc $M(\hat{\beta}^L) \leq \frac{4\varphi_{\max}}{r^2}c^2 = \frac{64\varphi_{\max} s}{\kappa^2}$, c'est (8). Probabilité : seuil $\frac{A}{2}\sqrt{\log p}$ par variable, queue $e^{-t^2/2} = p^{-A^2/8}$, fois p variables. Attention : (7) porte sur $\|X\delta\|_2^2$, **non divisé** par n.

Preuve express (la preuve condensée en 12 lignes)

Notations : $\delta = \hat{\beta}^L - \beta^*$, $J_0 = J(\beta^*)$, $\kappa = \kappa(s,3)$, $u = \|X\delta\|_2/\sqrt{n}$, $\mathcal{E} = \{\frac{2}{n}\|X^\top\varepsilon\|_\infty \leq r\}$. Les lignes 1 à 10 et 12 sont déterministes, sur $\mathcal{E}$; la ligne 11 montre que $\mathcal{E}$ est très probable.

1 $$u^2 \leq \frac{2}{n}\varepsilon^\top X\delta + 2r\left(\|\beta^*\|_1 - \left\|\hat{\beta}^L\right\|_1\right)$$

↳ base : critère$(\hat{\beta}^L) \leq$ critère(β^*) et $Y - X\hat{\beta}^L = \varepsilon - X\delta$.

2 $$\frac{2}{n}\varepsilon^\top X\delta \leq r\|\delta\|_1$$

↳ Hölder, sur $\mathcal{E}$.

3 $$u^2 + r\|\delta\|_1 \leq 2r\left(\|\delta\|_1 + \|\beta^*\|_1 - \left\|\hat{\beta}^L\right\|_1\right)$$

↳ on ajoute $r\|\delta\|_1$ des deux côtés.

4

$$\|\delta\|_1 + \|\beta^*\|_1 - \left\|\hat{\beta}^L\right\|_1 \leq 2\,\|\delta_{J_0}\|_1$$

↳ lemme de découpage : les termes hors support se compensent, triangulaire inversée sur le support.

5

$$u^2 + r\,\|\delta\|_1 \leq 4r\,\|\delta_{J_0}\|_1 \qquad (\star)$$

↳ l'inégalité centrale.

6

$$\left\|\delta_{J_0^c}\right\|_1 \leq 3\,\|\delta_{J_0}\|_1$$

↳ le cône : on retire u^2, on découpe $\|\delta\|_1$.

7

$$\begin{aligned} 4r\,\|\delta_{J_0}\|_1 &\leq 4r\sqrt{s}\;\|\delta_{J_0}\|_2 \\ &\leq \frac{4r\sqrt{s}}{\kappa}\,u = c\,u \end{aligned}$$

↳ Cauchy–Schwarz sur $|J_0| \leq s$ coordonnées, puis RE$(s,3)$, permis car δ est dans le cône et $|J_0| \leq s$.

8

$$u^2 + r\,\|\delta\|_1 \leq c\,u$$

↳ l'inégalité est « fermée » : une seule inconnue, u.

9

$$\begin{aligned} u^2 \leq cu \;\Rightarrow\; u \leq c \;\Rightarrow\; \\ \|X\delta\|_2^2 = nu^2 \leq \frac{16r^2sn}{\kappa^2} \\ = \frac{16A^2}{\kappa^2}\sigma^2 s\log p \end{aligned}$$

↳ on jette $r\,\|\delta\|_1 \geq 0$; si $u > 0$ on divise par u : c'est (7).

10

$$\begin{aligned} r\,\|\delta\|_1 \leq cu \leq c^2 \;\Rightarrow\; \\ \|\delta\|_1 \leq \frac{16rs}{\kappa^2} = \frac{16A}{\kappa^2}\sigma s\sqrt{\frac{\log p}{n}} \end{aligned}$$

↳ on jette cette fois $u^2 \geq 0$: c'est (6).

11

$$\begin{aligned} \mathbb{P}(\mathcal{E}^c) &\leq \sum_{j=1}^{p} \mathbb{P}\Big(\,|Z_j| > \frac{A}{2}\sqrt{\log p}\Big) \\ &\leq p\cdot p^{-A^2/8} = p^{1-A^2/8} \end{aligned}$$

↳ $Z_j = X_j^\top \varepsilon/(\sigma\sqrt{n}) \sim \mathcal{N}(0,1)$ (colonnes normalisées), borne de l'union, queue $\mathbb{P}(|Z| > t) \leq e^{-t^2/2}$.

12

$$\begin{aligned} M(\hat{\beta}^L)\,\frac{r^2}{4} &\leq \left\|\frac{1}{n}X^\top X\delta\right\|_2^2 \\ &\leq \varphi_{\max} u^2 \leq \varphi_{\max} c^2 \end{aligned}$$

↳ KKT + $\mathcal{E}$: $\left|\frac{1}{n}X_j^\top X\delta\right| \geq \frac{r}{2}$ pour chaque j sélectionné ; on somme les carrés ; Rayleigh ($XX^\top/n$ a pour plus grande valeur propre $\varphi_{\max}$) ; enfin $u \leq c$ (ligne 9). Avec $c^2 = 16r^2 s/\kappa^2$: c'est (8).

Méthode — La carte de la preuve de BRT, à réciter

À SAVOIR REFAIRE → S3

1. **Base** : critère($\hat{\beta}^L$) $\leq$ critère(β^*), puis $Y = X\beta^* + \varepsilon$.
2. **Bruit et cône** : Hölder + $\mathcal{E}$; ajouter $r\,\|\delta\|_1$; découper selon J_0 ⇒ $(\star)$ ⇒ cône.
3. **RE** : $\|\delta_{J_0}\|_1 \leq \sqrt{s}\;\|\delta_{J_0}\|_2 \leq \sqrt{s}\,u/\kappa$ ⇒ $u^2 + r\,\|\delta\|_1 \leq cu$ avec $c = 4r\sqrt{s}/\kappa$.
4. **Conclure** : $u^2 \leq cu$ ⇒ $u \leq c$ ⇒ (7) ; puis $r\,\|\delta\|_1 \leq c^2$ ⇒ (6).
5. **Probabilité** : $X_j^\top \varepsilon \sim \mathcal{N}(0, n\sigma^2)$, queue gaussienne + borne de l'union ⇒ $\mathbb{P}(\mathcal{E}^c) \leq p^{1-A^2/8}$.
6. **Bonus (8)** : KKT + $\mathcal{E}$ ⇒ chaque variable sélectionnée coûte $r^2/4$; la somme est $\leq \varphi_{\max} u^2$.

Ce squelette est celui de toute la grande dimension : on le retrouve en séance 4 (inégalités oracle, un β quelconque à la place de β^*), au TD2 (le lemme) et au TD3 (Lasso logistique, avec Hoeffding à la place de la queue gaussienne).

Hypothèse du théorème	Où elle sert dans la preuve
Bruit gaussien, indépendant	étape 5 : chaque $X_j^\top \varepsilon$ est gaussien, de loi connue
Diagonale de $X^\top X/n$ égale à 1	étape 5 : tous les $X_j^\top \varepsilon$ ont la même loi $\mathcal{N}(0, n\sigma^2)$, donc un seul seuil r
$M(\beta^*) \leq s$	étape 3 : $\lvert J_0\rvert \leq s$, pour appliquer RE et $\|\delta_{J_0}\|_1 \leq \sqrt{s}\;\|\delta_{J_0}\|_2$
RE$(s, 3)$	étape 3 : majorer $\|\delta_{J_0}\|_2$ par u/κ, ce qui « referme » l'inégalité
$r = A\sigma\sqrt{\log p/n}$	étapes 2 et 5 : la pénalité domine le bruit sur toutes les variables à la fois
$A > 2\sqrt{2}$	étape 5 : l'exposant $1 - A^2/8$ est négatif ; sinon la borne de probabilité ne dit rien
Conditions KKT (une propriété du Lasso, pas une hypothèse)	seulement pour (8) ; le cœur de la preuve n'utilise que « $\hat{\beta}^L$ minimise le critère »

Proposition — La probabilité de l'événement $\mathcal{E}$ (étape 5)

PAR CŒUR À SAVOIR REFAIRE → S3

Si $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$, $\|X_j\|^2 = n$ pour tout j et $r = A\sigma\sqrt{\log p/n}$:

$$\mathbb{P}(\mathcal{E}^c) = \mathbb{P}\Big(\max_{1\leq j\leq p} \frac{2}{n}\,\lvert X_j^\top \varepsilon\rvert > r\Big) \leq p^{1-A^2/8}.$$

Pourquoi $A > 2\sqrt{2}$: $A > 2\sqrt{2} \iff \frac{A}{2}\sqrt{\log p} > \sqrt{2\log p}$, le maximum typique de p gaussiennes standard. **On place r juste au-dessus du niveau du bruit** : c'est la plus petite régularisation qui domine le bruit sur toutes les variables à la fois, d'où le $\log p$. Avec la queue de Chernoff $2e^{-t^2/2}$ du TD2, on obtiendrait $2p^{1-A^2/8}$.

Preuve express

1

$$\mathbb{P}(\mathcal{E}^c) \le \sum_{j=1}^{p} \mathbb{P}\Big(\frac{2}{n}\left|X_j^\top \varepsilon\right| > r\Big)$$

↳ le maximum dépasse r si l'un des termes le dépasse ; borne de l'union (aucune indépendance requise).

2

$$\begin{aligned} X_j^\top \varepsilon &= \sum_{i=1}^{n} x_{ij}\varepsilon_i \\ &\sim \mathcal{N}\left(0, \sigma^2 \left\|X_j\right\|^2\right) \\ &= \mathcal{N}(0, n\sigma^2) \end{aligned}$$

↳ combinaison linéaire de gaussiennes indépendantes ; colonnes normalisées.

3

$$\begin{aligned} &\frac{2}{n}\left|X_j^\top \varepsilon\right| > r \\ \iff\ &|Z_j| > \frac{r\sqrt{n}}{2\sigma} \\ \iff\ &|Z_j| > \frac{A}{2}\sqrt{\log p} \end{aligned}$$

↳ avec $Z_j = X_j^\top \varepsilon/(\sigma\sqrt{n}) \sim \mathcal{N}(0,1)$: on divise par $\frac{2}{n}\cdot\sigma\sqrt{n} = \frac{2\sigma}{\sqrt{n}}$, puis $r\sqrt{n}/\sigma = A\sqrt{\log p}$.

4

$$\begin{aligned} &\mathbb{P}\Big(|Z_j| > \frac{A}{2}\sqrt{\log p}\Big) \\ &\le \exp\Big(-\frac{1}{2}\cdot\frac{A^2\log p}{4}\Big) \\ &= p^{-A^2/8} \end{aligned}$$

↳ queue gaussienne $\mathbb{P}(|Z| > t) \le e^{-t^2/2}$ (vraie pour tout $t \ge 0$) ; $e^{-a\log p} = p^{-a}$.

5

$$\mathbb{P}(\mathcal{E}^c) \le p \cdot p^{-A^2/8} = p^{1-A^2/8}$$

↳ somme de p termes identiques.

Bonus — La borne (8) sur la taille du support estimé À SAVOIR REFAIRE → S3

Sur $\mathcal{E}$, toute variable sélectionnée ($\hat\beta_j^L \neq 0$) vérifie $\left|\frac{1}{n}X_j^\top X\delta\right| \ge \frac{r}{2}$. Donc

$$\begin{aligned} M(\hat\beta^L)\,\frac{r^2}{4} &\le \left\|\frac{1}{n}X^\top X\delta\right\|_2^2 \le \varphi_{\max}\,\frac{1}{n}\left\|X\delta\right\|^2 \\ &\le \varphi_{\max}\,\frac{16r^2 s}{\kappa^2} \end{aligned}$$

(la dernière inégalité est la borne (7) divisée par n), d'où $M(\hat\beta^L) \le \dfrac{64\,\varphi_{\max}}{\kappa^2}\,s$.

L'idée : « on ne sélectionne pas une variable gratuitement ». Les KKT donnent une corrélation exactement $\pm r$ avec le résidu ; le bruit en explique au plus $r/2$; le reste, au moins $r/2$, vient de l'erreur $X\delta$. C'est la seule étape qui utilise les KKT, et le r^2 se simplifie : (8) ne dépend pas de A.

Preuve express

1

$$\frac{1}{n} X_j^\top X\delta = \frac{1}{n} X_j^\top \varepsilon - r\ \mathrm{sgn}(\hat\beta_j^L)$$

↳ KKT $\frac{1}{n} X_j^\top (Y - X\hat\beta^L) = r\,\mathrm{sgn}(\hat\beta_j^L)$ pour j sélectionné, et $Y - X\hat\beta^L = \varepsilon - X\delta$.

2

$$\begin{aligned}\left|\frac{1}{n} X_j^\top X\delta\right| &\geq r - \frac{1}{n}\left|X_j^\top \varepsilon\right| \\ &\geq r - \frac{r}{2} = \frac{r}{2}\end{aligned}$$

↳ triangulaire inversée ($\left|\mathrm{sgn}(\hat\beta_j^L)\right| = 1$), puis $\frac{1}{n}\left|X_j^\top \varepsilon\right| \leq \frac{r}{2}$ sur $\mathcal{E}$.

3

$$\begin{aligned}M(\hat\beta^L)\,\frac{r^2}{4} &\leq \sum_{j=1}^{p} \left(\frac{1}{n} X_j^\top X\delta\right)^2 \\ &= \left\|\frac{1}{n} X^\top X\delta\right\|_2^2\end{aligned}$$

↳ on somme les carrés sur les variables sélectionnées, puis on ajoute les autres termes, positifs.

4

$$\begin{aligned}&\left\|\frac{1}{n} X^\top X\delta\right\|_2^2 \\ &\quad= \frac{1}{n}(X\delta)^\top \frac{XX^\top}{n}(X\delta) \\ &\quad\leq \varphi_{\max}\,\frac{1}{n}\,\|X\delta\|^2\end{aligned}$$

↳ Rayleigh ; $XX^\top/n$ et $X^\top X/n$ ont les mêmes valeurs propres non nulles, donc la même plus grande.

5

$$\begin{aligned}M(\hat\beta^L) &\leq \frac{4\varphi_{\max}}{r^2} \cdot \frac{16 r^2 s}{\kappa^2} \\ &= \frac{64\varphi_{\max}}{\kappa^2}\, s\end{aligned}$$

↳ borne (7) divisée par n : $\frac{1}{n}\|X\delta\|^2 \leq 16 r^2 s/\kappa^2$.

À comprendre — Ce que disent les trois bornes

À COMPRENDRE → S3

- **(7) divisée par n** : $\frac{1}{n}\left\|X\hat\beta^L - X\beta^*\right\|^2 \leq \frac{16A^2}{\kappa^2} \cdot \sigma^2 \frac{s}{n} \cdot \log p$, soit l'erreur de l'oracle $\sigma^2 s/n$ multipliée par $\log p$ et par une constante. C'est l'inégalité de sparsité en prédiction de la séance 2, avec $L(n,p) = \log p$.
- **(6)** : tout se passe comme si chacun des s coefficients utiles était estimé à $\sigma\sqrt{\log p/n}$ près.
- **(8)** : le Lasso garde au plus une constante fois s variables (il peut cependant se tromper de variables).
- κ^2 est au dénominateur partout : plus les variables sont corrélées, plus κ est petit et plus les garanties se dégradent ; avec $\kappa = 0$, le théorème ne dit plus rien.
- Les constantes sont très pessimistes : la **forme** $s \log p/n$ est la bonne, pas la valeur (en simulation, l'erreur réelle est de l'ordre de $s\,r^2$, sans le facteur 16).
- Augmenter A fait vite monter la probabilité, mais augmente les bornes (via A et A^2).

Réflexes de la séance 3

- Estimateur défini par un argmin → **inégalité de base** : critère(estimateur) $\leq$ critère(vérité), puis $Y = X\beta^* + \varepsilon$.

- Terme croisé $\varepsilon^\top X\delta$ face à une pénalité ℓ_1 → **Hölder** ℓ_∞/ℓ_1, **jamais Cauchy–Schwarz** : $\left\|X^\top\varepsilon\right\|_\infty \approx \sigma\sqrt{2n\log p}$ est un maximum, alors que $\left\|X^\top\varepsilon\right\|_2 \approx \sigma\sqrt{np}$ est une somme.
- Maximum de p gaussiennes → borne de l'union + queue $e^{-t^2/2}$ → seuil d'environ $\sqrt{2\log p}$ écarts-types → $\lambda \asymp \sigma\sqrt{\log p/n}$.
- Un ensemble d'indices privilégié → couper chaque vecteur « sur J » et « hors de J ».
- Constante du cône = (pénalité + bruit)/(pénalité − bruit) : la pénalité doit dominer le bruit.
- Inégalité fermée $u^2 \le cu$ → $u \le c$; deux termes positifs à gauche → deux bornes, en jetant l'un puis l'autre.

Lire le théorème avec recul (diapo 39)

À comprendre — « Non asymptotique » et identifiabilité À COMPRENDRE → S3

- Le théorème donne seulement des bornes supérieures **non asymptotiques** : explicites pour vos n, p, s, avec une probabilité qui dépend de p, sous des conditions qui dépendent de n et p (RE porte sur la matrice X de taille $n \times p$).
- Pour en tirer une convergence quand $n \to \infty$, il faudrait des propriétés supplémentaires très fortes : $\kappa(s,3) \ge \kappa_0 > 0$ pour toute la suite de matrices, $s\log p/n \to 0$, et $p \to \infty$ (ou A croissant) pour que la probabilité tende vers 1.
- RE$(s,3)$ n'implique pas l'identifiabilité de β^*, mais β^* est défini de façon unique grâce à l'hypothèse $M(\beta^*) \le s$: c'est l'unique explication s-parcimonieuse des données.

Piège — Ce que le théorème ne dit pas → S3

- **Pas de garantie de sélection** : il borne l'erreur et le *nombre* de variables choisies, mais ne dit pas que le Lasso retrouve *le bon* support. Retrouver exactement le support demande des hypothèses plus fortes (hors diapos).
- **Le bon r dépend de σ**, inconnu en pratique : on choisit alors λ par validation croisée, que le théorème ne couvre pas.
- **RE n'est pas vérifiable** sur une matrice donnée, et les constantes sont pessimistes.
- Du caractère gaussien du bruit, la preuve n'utilise que la queue $\mathbb{P}(|Z| > t) \le e^{-t^2/2}$.

TD2 — Le lemme valable pour tout β

Lemme du TD2 — les résultats (2), (3) et (4) PAR CŒUR À SAVOIR REFAIRE → TD2

Même cadre que le théorème, sans RE ni parcimonie : $p \geq 2$, $n \geq 1$, bruit $\mathcal{N}(0, \sigma^2)$ i.i.d., $\|X_j\|^2 = n$, Lasso $\frac{1}{n}\|Y - X\beta\|^2 + 2r\|\beta\|_1$ avec $r = A\sigma\sqrt{\log p / n}$ et $A > 2\sqrt{2}$. Avec $V_j = \frac{1}{n} X_j^\top \varepsilon$, l'événement de bruit s'écrit $\mathcal{E} = \bigcap_{j=1}^p \{2|V_j| \leq r\}$. Alors $\mathbb{P}(\mathcal{E}) \geq 1 - 2p^{1-A^2/8}$ (outils du TD) et, sur $\mathcal{E}$, on a **pour tout** $\beta \in \mathbb{R}^p$ l'inégalité (2) :

$$\begin{aligned}
&\left\|X\hat{\beta}^L - X\beta^*\right\|_n^2 + r\left\|\hat{\beta}^L - \beta\right\|_1 \\
&\quad\leq \|X\beta - X\beta^*\|_n^2 \\
&\qquad + 4r \sum_{j \in J(\beta)} \left|\hat{\beta}_j^L - \beta_j\right| \\
&\quad\leq \|X\beta - X\beta^*\|_n^2 \\
&\qquad + 4r\sqrt{M(\beta)} \Big(\sum_{j \in J(\beta)} \left|\hat{\beta}_j^L - \beta_j\right|^2 \Big)^{1/2}
\end{aligned}$$

ainsi que (3) et (4) :

$$\left\|\frac{1}{n} X^\top (X\beta^* - X\hat{\beta}^L)\right\|_\infty \leq \frac{3r}{2} \qquad (3)$$

$$M(\hat{\beta}^L) \leq \frac{4\varphi_{\max}}{r^2} \left\|X\hat{\beta}^L - X\beta^*\right\|_n^2 \qquad (4)$$

Notations : $\|u\|_n^2 = \frac{1}{n}\|u\|^2$; le TD écrit $\mathcal{M}$ et $\phi_{\max}$ ce que la séance 3 note M et $\varphi_{\max}$.

Pour le retrouver : c'est la preuve de la séance 3 avec un β quelconque à la place de β^* : le prix est « $4r$ sur le support de β ». (3) : r (KKT) $+ r/2$ (bruit). (4) : chaque variable sélectionnée coûte $r^2/4$. Probabilité : la queue de Chernoff $2e^{-z^2/2}$ apporte le facteur 2. Pourquoi c'est plus fort : on peut comparer le Lasso à une bonne approximation parcimonieuse de β^* ; c'est la forme des inégalités oracle de la séance 4.

Preuve express (questions 1 à 9)

1

$$\begin{aligned}
&\left\|X\beta^* - X\hat{\beta}^L\right\|_n^2 + 2r\left\|\hat{\beta}^L\right\|_1 \\
&\quad\leq \|X\beta^* - X\beta\|_n^2 \\
&\qquad + 2\sum_{j=1}^p (\hat{\beta}_j^L - \beta_j) V_j \\
&\qquad + 2r\|\beta\|_1
\end{aligned}$$

↳ Q1 : critère$(\hat{\beta}^L) \leq$ critère(β) ; $Y - Xb = (X\beta^* - Xb) + \varepsilon$; on développe, $\|\varepsilon\|_n^2$ se simplifie, et le terme croisé s'écrit avec les V_j.

2

$$V_j \sim \mathcal{N}\Big(0, \frac{\sigma^2}{n}\Big),$$
$$\mathbb{P}(2\,|V_j| > r) = \mathbb{P}\Big(\,|\eta| > \frac{\sqrt{n}\,r}{2\sigma}\Big)$$
$$= \mathbb{P}\Big(\,|\eta| > \frac{A}{2}\sqrt{\log p}\Big)$$
$$\leq 2p^{-A^2/8}$$

↳ Q2–Q4 : normalisation $\sum_i x_{ij}^2 = n$, $\eta \sim \mathcal{N}(0,1)$, Chernoff $\mathbb{P}(|\eta| \geq z) \leq 2e^{-z^2/2}$; puis l'union sur p variables : $\mathbb{P}(\mathcal{E}^c) \leq 2p^{1-A^2/8}$.

3

$$2\sum_j (\hat\beta_j^L - \beta_j)V_j$$
$$\leq \sum_j 2\,|V_j|\,\left|\hat\beta_j^L - \beta_j\right|$$
$$\leq r\left\|\hat\beta^L - \beta\right\|_1 \quad \text{sur } \mathcal{E}$$

↳ Q5 : c'est Hölder écrit à la main.

4

$$\left\|X\hat\beta^L - X\beta^*\right\|_n^2 + r\left\|\hat\beta^L - \beta\right\|_1$$
$$\leq \|X\beta - X\beta^*\|_n^2 + 2r\sum_{j=1}^p t_j$$

↳ on ajoute $r\left\|\hat\beta^L - \beta\right\|_1$ des deux côtés et on regroupe, avec $t_j = \left|\hat\beta_j^L - \beta_j\right| + |\beta_j| - \left|\hat\beta_j^L\right|$.

5

$$t_j = 0 \quad (j \notin J(\beta)),$$
$$t_j \leq 2\left|\hat\beta_j^L - \beta_j\right| \quad (j \in J(\beta))$$

↳ $\beta_j = 0$ hors du support ; triangulaire inversée dessus. D'où (2), puis Cauchy–Schwarz sur les $M(\beta)$ coordonnées du support.

6

$$\frac{1}{n}X^\top(X\beta^* - X\hat\beta^L)$$
$$= \frac{1}{n}X^\top(Y - X\hat\beta^L) - \frac{1}{n}X^\top\varepsilon$$

↳ Q6 : « résidu moins bruit ». Les KKT donnent $\left\|\frac{1}{n}X^\top(Y - X\hat\beta^L)\right\|_\infty \leq r$; le second terme a pour coordonnées les V_j, $\leq r/2$ sur $\mathcal{E}$; triangulaire : $r + \frac{r}{2}$, c'est (3).

7

$$\left|\frac{1}{n}X_j^\top(X\beta^* - X\hat\beta^L)\right|$$
$$\geq r - |V_j| \geq \frac{r}{2}$$

↳ Q7, pour $\hat\beta_j^L \neq 0$: KKT avec égalité $r\,\mathrm{sgn}(\hat\beta_j^L)$, puis triangulaire inversée et $|V_j| \leq r/2$ sur $\mathcal{E}$.

8

$$\frac{r^2}{4}M(\hat\beta^L) \leq \frac{1}{n^2}v^\top XX^\top v$$
$$\leq \varphi_{\max}\,\|v\|_n^2$$

↳ Q8–Q9 avec $v = X\beta^* - X\hat\beta^L$: somme des carrés sur les variables sélectionnées, Rayleigh, et $\lambda_{\max}(XX^\top/n) = \lambda_{\max}(X^\top X/n) = \varphi_{\max}$: c'est (4).

Piège — $1-2p^{1-A^2/8}$ (TD2) ou $1-p^{1-A^2/8}$ (diapo 38) ? → TD2

Les deux sont justes. Le TD démontre la queue de Chernoff $\mathbb{P}(|Z|\geq z)\leq 2e^{-z^2/2}$ et obtient $1-2p^{1-A^2/8}$; la séance 3 utilise la version fine $\mathbb{P}(|Z|\geq z)\leq e^{-z^2/2}$ (vraie pour tout $z\geq 0$) et obtient $1-p^{1-A^2/8}$, la probabilité de l'énoncé du théorème (que le TD recopie sans la justifier avec ses outils). À l'examen, dites quelle queue vous utilisez. Attention aussi aux numéros : les bornes (5), (6), (7) du TD sont les (6), (7), (8) de la diapo 38.

Lemme — Queue gaussienne par la méthode de Chernoff (TD2, question 3) PAR CŒUR À SAVOIR REFAIRE → TD2

Si $Z\sim\mathcal{N}(0,1)$, alors pour tout $z>0$:

$$\mathbb{P}(|Z|\geq z)\leq 2\,e^{-z^2/2}.$$

La recette : Markov sur $e^{\theta Z}$, puis optimiser en θ ; il suffit de connaître $\mathbb{E}[e^{\theta Z}]=e^{\theta^2/2}$ (compléter le carré). La même recette donne l'inégalité de Hoeffding utilisée au TD3.

Preuve express

1. $$\begin{aligned}\mathbb{P}(|Z|\geq z)&=2\,\mathbb{P}(Z\geq z)\\&=2\,\mathbb{P}\big(e^{\theta Z}\geq e^{\theta z}\big)\end{aligned}$$

   ↳ pour tout $\theta>0$: symétrie de la loi de Z, et $x\mapsto e^{\theta x}$ est strictement croissante.

2. $$\begin{aligned}\mathbb{P}\big(e^{\theta Z}\geq e^{\theta z}\big)&\leq e^{-\theta z}\,\mathbb{E}\big[e^{\theta Z}\big]\\&=\exp\Big(\frac{\theta^2}{2}-\theta z\Big)\end{aligned}$$

   ↳ Markov $\mathbb{P}(W\geq a)\leq \mathbb{E}W/a$; $\theta x-\frac{x^2}{2}=\frac{\theta^2}{2}-\frac{(x-\theta)^2}{2}$ et la densité de $\mathcal{N}(\theta,1)$ intègre à 1.

3. $$\min_{\theta>0}\Big(\frac{\theta^2}{2}-\theta z\Big)=-\frac{z^2}{2}$$

   ↳ dérivée $\theta-z$: minimum en $\theta=z$. D'où $\mathbb{P}(Z\geq z)\leq e^{-z^2/2}$, et le facteur 2 vient de la ligne 1.

TD2 — Du lemme au cône, puis au théorème

Corollaire et théorème, déduits du lemme À SAVOIR REFAIRE → TD2

Sous les hypothèses du théorème ($M(\beta^*)\leq s$, RE$(s,3)$), sur $\mathcal{E}$, avec $\delta=\hat\beta^L-\beta^*$, $J_0=J(\beta^*)$, $\kappa=\kappa(s,3)$:

- **Cône (corollaire)** : (2) avec $\beta=\beta^*$ donne $\|X\delta\|_n^2+r\,\|\delta\|_1\leq 4r\,\|\delta_{J_0}\|_1$, d'où $\|\delta_{J_0^c}\|_1\leq 3\,\|\delta_{J_0}\|_1$.
- **Prédiction** : seconde ligne de (2) avec $\beta=\beta^*$: $\|X\delta\|_n^2\leq 4r\sqrt{s}\,\|\delta_{J_0}\|_2$; RE : $\kappa^2\,\|\delta_{J_0}\|_2^2\leq\|X\delta\|_n^2$. Donc $\|\delta_{J_0}\|_2\leq\frac{4r\sqrt{s}}{\kappa^2}$, puis $\|X\delta\|_n^2\leq\frac{16r^2s}{\kappa^2}$.
- **Norme ℓ_1** : $\|\delta\|_1\leq 4\,\|\delta_{J_0}\|_1\leq 4\sqrt{s}\,\|\delta_{J_0}\|_2\leq\frac{16rs}{\kappa^2}$.
- **Support** : (4) et la borne de prédiction donnent $M(\hat\beta^L)\leq\frac{4\varphi_{\max}}{r^2}\cdot\frac{16r^2s}{\kappa^2}=\frac{64\varphi_{\max}s}{\kappa^2}$.

Deux routes, mêmes constantes : le TD borne d'abord $\|\delta_{J_0}\|_2$ grâce à RE, puis réinjecte ; la séance 3 remplace $\|\delta_{J_0}\|_2$ par u/κ et résout $u^2\leq cu$. Retenez-en une, sachez reconnaître l'autre. Avec les

outils du TD, tout cela a lieu avec probabilité $\geq 1 - 2p^{1-A^2/8}$.

Deux faits sur les valeurs propres (TD2) PAR CŒUR À SAVOIR REFAIRE → TD2

- $X^\top X$ et $XX^\top$ ont les **mêmes valeurs propres non nulles** ; en particulier $\lambda_{\max}(XX^\top/n) = \lambda_{\max}(X^\top X/n) = \varphi_{\max}$.
- Si $p > n$ et $\|X_j\|^2 = n$ pour tout j : $\varphi_{\max} \geq p/n$ (remarque de la page TD2, hors énoncé du TD).

Pour les retrouver : $X^\top X u = \mu u$ avec $\mu \neq 0 \Rightarrow Xu \neq 0$ et $XX^\top(Xu) = \mu\, Xu$ (et symétriquement). $\operatorname{tr}(X^\top X/n) = \sum_j \|X_j\|^2/n = p$ est la somme des valeurs propres, dont au plus $\operatorname{rg} X \leq n$ sont non nulles : la plus grande vaut au moins p/n. Conséquence : la borne (8) devient pessimiste quand $p \gg n$.

Réflexes du TD2

- Comparer l'estimateur à un β **quelconque**, pas seulement à la vérité : on obtient une inégalité de type oracle (séance 4).
- L'événement $\{\max_j |V_j| \leq \text{seuil}\}$ **ne dépend pas de** β : sur lui, le résultat vaut pour tous les β à la fois, et l'on peut choisir β après coup.
- « Ajouter $r\left\|\hat\beta - \beta\right\|_1$ des deux côtés » fait apparaître $\left|\hat\beta_j - \beta_j\right| + |\beta_j| - \left|\hat\beta_j\right|$: nul hors du support de β, au plus $2\left|\hat\beta_j - \beta_j\right|$ dessus.
- Les KKT donnent des bornes ℓ_∞ : $\left\|\frac{1}{n}X^\top(Y - X\hat\beta)\right\|_\infty \leq r$. Pour une corrélation avec l'erreur $X\beta^* - X\hat\beta$, écrire « résidu moins bruit ».
- Compter des variables : si chacune contribue au moins c à une somme de carrés majorée par B, il y en a au plus B/c.

---

4. Outils convexes et inégalités oracle → S4

L'essentiel de la séance en 5 lignes

- **Dictionnaire** : une fonction f quelconque est approchée par $f_\beta = \sum_{j=1}^M \beta_j f_j$; avec $X_{ij} = f_j(Z_i)$, on retombe sur une régression linéaire à M variables (souvent $M \gg n$).
- **Inégalité oracle** : l'erreur de l'estimateur est au plus celle du meilleur concurrent, plus un prix : $\frac{1}{n}\left\|f_{\hat\beta} - f\right\|^2 \leq \inf_\beta\{\text{approximation}(\beta) + \text{prix}(\beta)\}$.
- **Outils convexes** : le sous-différentiel remplace le gradient là où $|\cdot|$ fait un coin ; « minimum $\Leftrightarrow 0 \in \partial\varphi$ » redonne en deux lignes le seuillage doux et les KKT ; $\|\cdot\|_1$ est l'enveloppe convexe de $\|\cdot\|_0$ sur $[-1,1]^M$.
- **Oracle lente** : aucune hypothèse sur X (sauf la normalisation), prix $2\lambda\|\beta\|_1$, vitesse $1/\sqrt{n}$.
- **Oracle rapide** : sous RE$(s,3)$, pour l'estimateur pénalisé par $2\lambda\|\beta\|_1$, prix $\frac{18\sigma^2 s(x+\log M)}{\kappa^2 n}$, vitesse $s\log M/n$. Même $\lambda = 2\sigma\sqrt{2(x+\log M)/n}$ et même probabilité $1 - 2e^{-x}$ pour les deux.

Les conventions de la séance 4 PAR CŒUR → S4

- Dictionnaire de M fonctions (M joue le rôle de p) ; n observations ; $f = (f(Z_1), \dots, f(Z_n))^\top$, $f_\beta = X\beta$, $y = f + \varepsilon$.
- Norme empirique $\|u\|_n^2 = \frac{1}{n}\|u\|^2$: $\|f_\beta - f\|_n^2 = \frac{1}{n}\|f_\beta - f\|^2$ et $R_n(\beta) = \|y - f_\beta\|_n^2 = \frac{1}{n}\|y - X\beta\|^2$.
- Critère **normalisé** : $\frac{1}{n}\|y - X\beta\|^2 + \lambda\|\beta\|_1$, d'où des KKT en $\frac{2}{n}X_j^\top(y - X\hat\beta)$.
- Un seul $\lambda = 2\sigma\sqrt{2(x + \log M)/n}$ ($x > 0$: niveau de confiance) ; pénalité $\lambda\|\beta\|_1$ pour l'inégalité lente, $2\lambda\|\beta\|_1$ pour la rapide.
- Seuillage doux : convention $\frac{1}{2}(a-b)^2 + \lambda|a|$, donc seuil λ (et non $\lambda/2$ comme en séance 2).

Dictionnaires et inégalités oracle

Définition — Régression non linéaire et dictionnaire (diapos 41–43) PAR CŒUR → S4

Modèle : $Y_i = f(Z_i) + \varepsilon_i$, $i = 1, \dots, n$, avec $Z_i \in \mathbb{R}^p$ déterministes, $\varepsilon_1, \dots, \varepsilon_n$ i.i.d. $\mathcal{N}(0, \sigma^2)$ et $f : \mathbb{R}^p \to \mathbb{R}$ inconnue, quelconque.

Dictionnaire $\mathcal{F} = \{f_1, \dots, f_M\}$ et combinaisons $f_\beta = \sum_{j=1}^M \beta_j f_j$, $\beta \in \mathbb{R}^M$. On cherche β avec une erreur empirique $\frac{1}{n}\sum_i \big(f_\beta(Z_i) - f(Z_i)\big)^2$ petite **et** $\|\beta\|_0$ petit devant M (représentation parcimonieuse).

Matrice du dictionnaire : $X_{ij} = f_j(Z_i)$, de taille $n \times M$, de sorte que $X\beta = f_\beta$ (valeurs aux points observés) et $y = f + \varepsilon$. Cas $M = p$, $f_j(z) = z_j$: la régression linéaire des séances 1–3.

Pour la retrouver : ligne i = toutes les briques évaluées au point Z_i ; colonne j = la brique f_j en tous les points. Si $M > n$, X a un noyau non nul : deux combinaisons différentes peuvent coïncider aux points observés.

Piège — f n'est pas forcément dans le dictionnaire

Il n'existe peut-être aucun β tel que $X\beta = f$: il reste toujours une **erreur d'approximation** $\frac{1}{n}\|f_\beta - f\|^2$. Ici β^* (et $f^* = f_{\beta^*}$) désigne la meilleure approximation de f dans le dictionnaire, pas un « vrai paramètre ».

Définition — Inégalité oracle (diapo 44) PAR CŒUR → S4

On cherche un estimateur $\hat\beta_n$ avec $\|\hat\beta_n\|_0 \ll M$ et

$$\frac{1}{n}\left\|f_{\hat\beta_n} - f\right\|^2 \le \inf_{\beta \in \mathbb{R}^M}\left\{\frac{1}{n}\|f_\beta - f\|^2 + \text{reste}(\beta)\right\},$$

avec un reste petit, qui dépend de β (et éventuellement de n, $\mathcal{F}$, σ^2). L'« oracle » est $f^* = f_{\beta^*}$, $\beta^* \in \arg\min_\beta \|f_\beta - f\|^2$: il dépend de f, inconnue.

Pour la lire : « pour **tout** concurrent β, mon erreur est au plus son erreur d'approximation plus son prix ». Pour l'utiliser, choisissez un β concret : si $f = X\beta^\circ$ avec β° s-parcimonieux, $\beta = \beta^\circ$ annule l'approximation et donne une borne de prédiction du type Bickel–Ritov–Tsybakov.

À comprendre — Approximation contre complexité À COMPRENDRE → S4

Plus un concurrent utilise de briques (s grand), mieux il approche f (le terme d'approximation baisse), mais plus son prix est élevé (il croît typiquement comme s). Un devin qui connaît f choisirait le meilleur

compromis ; l'inégalité oracle dit que l'estimateur, calculé **sans** connaître f, fait presque aussi bien que ce devin. Elle généralise la séance 3 au cas où le modèle linéaire est faux.

Définition — Le Lasso sur un convexe Θ (diapo 45) PAR CŒUR → S4

$$\hat{\beta}_n = \arg\min_{\beta\in\Theta}\left\{\frac{1}{n}\sum_{i=1}^{n}\left(Y_i - f_\beta(Z_i)\right)^2 + \lambda\left\|\beta\right\|_1\right\}$$
$$= \arg\min_{\beta\in\Theta}\left\{\frac{1}{n}\left\|y - X\beta\right\|^2 + \lambda\left\|\beta\right\|_1\right\},$$

avec $\Theta \subset \mathbb{R}^M$ convexe (par exemple $\mathbb{R}^M$, des coefficients positifs ou bornés).

Pourquoi un convexe : on reste en optimisation convexe (sous-différentiel, critère d'optimalité de la diapo 52), et l'on peut imposer des contraintes naturelles. Dans le doute, prenez $\Theta = \mathbb{R}^M$.

Seuillage doux, rétrécissement, relaxation convexe

Formule — Seuillage doux, convention $\frac{1}{2}$ (diapo 46) PAR CŒUR À SAVOIR REFAIRE → S4

$$\arg\min_{a\in\mathbb{R}}\left\{\frac{1}{2}(a-b)^2 + \lambda\left|a\right|\right\} = \operatorname{sgn}(b)\left(\left|b\right| - \lambda\right)_+,$$

$$\text{c'est-à-dire}\quad \hat{a} = \begin{cases} b-\lambda & \text{si } b > \lambda, \\ 0 & \text{si } \left|b\right| \le \lambda, \\ b+\lambda & \text{si } b < -\lambda. \end{cases}$$

En dimension M tout se découple : $\arg\min_{a\in\mathbb{R}^M}\left\{\frac{1}{2}\left\|a-b\right\|_2^2 + \lambda\left\|a\right\|_1\right\} = T_\lambda(b)$, avec $\left(T_\lambda(b)\right)_j = \operatorname{sgn}(b_j)\left(\left|b_j\right| - \lambda\right)_+$.

Pour la retrouver : $0 \in a - b + \lambda\,\partial\left|a\right|$. Si $\hat{a} \neq 0$: $\hat{a} = b - \lambda\operatorname{sgn}(\hat{a})$, possible seulement si $\left|b\right| > \lambda$; si $\hat{a} = 0$: $b \in [-\lambda, \lambda]$. Sans le $\frac{1}{2}$ (critère $(a-b)^2 + \lambda\left|a\right|$ de la séance 2), le seuil devient $\lambda/2$.

Preuve express (par cas)

1. $$h(a) = \tfrac{1}{2}(a-b)^2 + \lambda\left|a\right|.$$

   ↳ h a un unique minimiseur : elle est strictement convexe (un carré plus une fonction convexe) et tend vers $+\infty$ quand $\left|a\right| \to \infty$.

2. $$a > 0 :\ h'(a) = a - b + \lambda = 0 \iff a = b - \lambda,$$
   $$\text{admissible si } b > \lambda.$$

   ↳ Sur $]0, +\infty[$, $\left|a\right| = a$; un point critique d'une fonction convexe est un minimum global, à condition d'être dans la zone de calcul.

3. $$a < 0 :\ h'(a) = a - b - \lambda = 0 \iff a = b + \lambda,$$
   $$\text{admissible si } b < -\lambda.$$

   ↳ Même calcul avec $\left|a\right| = -a$.

4

$$|b| \le \lambda : \quad h'(a) = a + (\lambda - b) > 0 \ \text{ pour } a > 0,$$
$$h'(a) = a - (b + \lambda) < 0 \ \text{ pour } a < 0.$$

↳ h décroît puis croît : le minimum est en 0. Les trois cas se résument en $\operatorname{sgn}(b)(|b| - \lambda)_+$.

Formule — Rétrécissement, le pendant Ridge (diapo 47) PAR CŒUR → S4

$$\arg\min_{a \in \mathbb{R}} \left\{ \frac{1}{2}(a-b)^2 + \frac{\lambda}{2} a^2 \right\} = \frac{b}{1+\lambda}.$$

Tout coefficient est multiplié par le même facteur $\frac{1}{1+\lambda} < 1$: rapproché de 0, mais **jamais exactement nul** (sauf si $b = 0$).

Pour la retrouver : tout est dérivable, $a - b + \lambda a = 0$. À retenir en comparaison : le Lasso a une *zone morte* $|b| \le \lambda$ (sélection) et décale les gros coefficients d'une quantité fixe λ (biais constant) ; Ridge ne fait aucun zéro et biaise les gros coefficients proportionnellement ; le seuillage dur (pénalité ℓ_0) garde les gros coefficients intacts mais saute brutalement au seuil.

À comprendre — Pourquoi ℓ_1 crée des zéros, et pas Ridge (diapo 48) À COMPRENDRE → S4

Les pentes. En $a = 0$, l'ajustement $\frac{1}{2}(a-b)^2$ a une pente $-b$: il tire vers b avec une force $|b|$. La pénalité $\lambda |a|$ a un coin : pente totale $-b + \lambda$ à droite, $-b - \lambda$ à gauche. Si $|b| < \lambda$, la fonction monte des deux côtés : 0 est le minimum. La pénalité Ridge $\frac{\lambda}{2} a^2$ a une pente nulle en 0 : elle n'oppose aucune résistance, on quitte 0 dès que $b \neq 0$.

La géométrie. La boule ℓ_1 a des coins $\pm t\, e_j$ (une seule coordonnée non nulle) ; les ellipses de niveau des moindres carrés la touchent souvent en un coin ou sur une arête : solution parcimonieuse. La boule ℓ_2 est ronde : contact en un point générique, sans zéro.

Définition et résultat — Enveloppe convexe ; celle de $\mathbf{1}\{x \neq 0\}$ et celle de $\|\cdot\|_0$ (Cours5, diapo 46) PAR CŒUR À SAVOIR REFAIRE → S4

Enveloppe convexe de $g : [a,b] \to \mathbb{R}$: $g^{\text{env}}(x) = \sup\{h(x) : \ h \text{ convexe}, \ h \le g \text{ sur } [a,b]\}$, la plus grande fonction convexe qui reste sous g.

L'enveloppe convexe de $\mathbf{1}\{x \neq 0\}$ sur $[-1,1]$ est $|x|$; celle de $x \mapsto \|x\|_0$ sur $[-1,1]^M$ est $x \mapsto \|x\|_1$. (Sur $[-R,R]$: $|x|\,/R$.)

L'image : on tend un élastique sous le graphe de l'indicatrice ; il passe par $(0,0)$ et $(\pm 1, 1)$: c'est le V de $|x|$.

Preuve express

1

$$g^{\text{env}}(x) \ge |x| .$$

↳ $|x|$ est convexe et $\le \mathbf{1}\{x \neq 0\}$ sur $[-1,1]$ (0 en 0, au plus 1 ailleurs) : c'est l'un des candidats du sup.

2

$$h \text{ convexe}, \ h \le \mathbf{1}\{\cdot \neq 0\}$$
$$\Rightarrow \ h(0) \le 0, \ \ h(\pm 1) \le 1.$$

↳ On évalue l'inégalité en 0 et en ± 1.

3 $$x \in [0,1] : \; h(x) = h\big((1-x)\cdot 0 + x \cdot 1\big) \\ \leq (1-x)h(0) + xh(1) \leq x = |x| \,.$$

↳ Convexité : la corde entre 0 et 1 est au-dessus du graphe. Même chose sur $[-1,0]$ avec la corde entre -1 et 0.

4 $$\text{Donc } g^{\text{env}} \leq |\cdot| \,, \text{ et finalement } g^{\text{env}} = |\cdot| \,.$$

↳ Un sup de fonctions toutes $\leq |x|$ est $\leq |x|$; avec l'étape 1, égalité.

À comprendre — Relaxer le problème ℓ_0 (Cours5, diapos 46–47) À COMPRENDRE → S4

1. $\min \|x\|_0$ sous $x \in C$, $\|x\|_\infty \leq R$ équivaut à $\min \sum_i u_i$ sous $u \in \{0,1\}^M$, $|x_i| \leq R u_i$, $x \in C$ (un interrupteur par coordonnée) : 2^M cas, problème combinatoire.
2. Relaxation : $u \in [0,1]^M$ au lieu de $\{0,1\}^M$; le problème devient convexe.
3. À x fixé, le meilleur u est $u_i = |x_i| / R$, d'où le problème relaxé $\min \frac{1}{R} \|x\|_1$ sous $x \in C$, $\|x\|_\infty \leq R$: « compter les non-zéros » devient « sommer les valeurs absolues ».

La diapo 47 réécrit $u \in \{0,1\}^M$ dans le problème relaxé : lisez $u \in [0,1]^M$.

Sous-différentiel et conditions d'optimalité

Définition — Sous-gradient, sous-différentiel (diapo 49) PAR CŒUR → S4

Soit $\varphi : \mathbb{R}^p \to \mathbb{R}$ convexe. Un vecteur $g \in \mathbb{R}^p$ est un **sous-gradient** de φ en u si

$$\varphi(v) - \varphi(u) \geq g^\top (v - u) \qquad \text{pour tout } v \in \mathbb{R}^p.$$

Le **sous-différentiel** $\partial\varphi(u)$ est l'ensemble des sous-gradients en u. Si φ est dérivable en u : $\partial\varphi(u) = \{\nabla\varphi(u)\}$.

Pour la retrouver : c'est « une fonction convexe est au-dessus de ses tangentes », avec toutes les pentes possibles en un point anguleux : l'hyperplan $v \mapsto \varphi(u) + g^\top(v-u)$ touche le graphe en u et reste dessous.

Formules — Les sous-différentiels à connaître (diapos 49–53) PAR CŒUR À SAVOIR REFAIRE → S4

Fonction	Sous-différentiel
$\lvert u\rvert$, $u \in \mathbb{R}$	$\{1\}$ si $u > 0$; $\{-1\}$ si $u < 0$; $[-1,1]$ si $u = 0$
$\|u\|_1$, $u \in \mathbb{R}^p$	$\{\operatorname{sgn}(u) + h : \; \|h\|_\infty \leq 1, \; h \odot u = 0\}$, c'est-à-dire $g_j = \operatorname{sgn}(u_j)$ si $u_j \neq 0$ et $g_j \in [-1,1]$ si $u_j = 0$: le produit $\partial\lvert u_1\rvert \times \cdots \times \partial\lvert u_p\rvert$
$\|u\|_2$, $u \in \mathbb{R}^p$	$\{u / \|u\|_2\}$ si $u \neq 0$; la boule unité $\{g : \|g\|_2 \leq 1\}$ si $u = 0$ (sert au group-Lasso)
indicatrice δ_C d'un convexe C (0 sur C, $+\infty$ ailleurs), en $u \in C$	le cône normal $N_C(u) = \{g : \; g^\top(v-u) \leq 0 \text{ pour tout } v \in C\}$ (les directions qui « sortent » de C)

Pour les retrouver : en 0, $g \in \partial\,|\cdot|\,(0) \iff |v| \geq gv\ \forall v \iff |g| \leq 1$ (si $|g| > 1$, prendre $v = \operatorname{sgn}(g)$). Même argument pour $\|\cdot\|_2$ en 0, avec Cauchy–Schwarz et $v = g$. La norme ℓ_1 est une somme de fonctions d'une seule coordonnée : son sous-différentiel est le produit des $\partial\,|u_j|$. Exemple de la diapo 53 : $u = (17, -42, 0, 3)$ donne $\{1\} \times \{-1\} \times [-1, 1] \times \{1\}$.

Propriétés — Les trois règles de calcul (diapo 50) PAR CŒUR → S4

1. **Règle de Fermat convexe** : $u^* \in \arg\min_{u \in \mathbb{R}^p} \varphi(u) \iff 0 \in \partial\varphi(u^*)$ (équivalence, sans condition d'ordre 2).
2. **Règle de la somme** : φ_k convexes, $\alpha_k \geq 0$ ⇒ $\partial\big(\sum_k \alpha_k \varphi_k\big)(u) = \sum_k \alpha_k\, \partial\varphi_k(u)$ (somme d'ensembles).
3. **Règle du maximum** : $\varphi = \max_k \varphi_k$ avec φ_k convexes ⇒ $\partial\varphi(u) = \operatorname{conv}\left(\bigcup\{\partial\varphi_k(u) :\ \varphi_k(u) = \varphi(u)\}\right)$: seules les fonctions *actives* comptent.

Pour les retrouver : (1) $0 \in \partial\varphi(u^*)$ s'écrit $\varphi(v) - \varphi(u^*) \geq 0$ pour tout v, la définition d'un minimum global. (3) se vérifie sur $|u| = \max(u, -u)$: en 0 les deux fonctions sont actives, et les mélanges de 1 et -1 forment $[-1, 1]$. Usage type, pour $F(\beta) = \frac{1}{n}\|y - X\beta\|^2 + \lambda\|\beta\|_1$: $\partial F(\beta) = \left\{ -\frac{2}{n}X^\top(y - X\beta) + \lambda g :\ g \in \partial\|\beta\|_1 \right\}$.

Proposition — Critère d'optimalité sur un convexe (diapos 51–52) PAR CŒUR → S4

Soit $\varphi : \mathbb{R}^p \to \mathbb{R}$ convexe et $C \subset \mathbb{R}^p$ convexe. Alors $u^* \in \arg\min_{u \in C} \varphi(u)$ si et seulement si

$$\exists\, g^* \in \partial\varphi(u^*) \ \text{ tel que}$$
$$(g^*)^\top(u - u^*) \geq 0 \ \text{ pour tout } u \in C,$$

autrement dit $-g^* \in N_C(u^*) = \partial\delta_C(u^*)$: minimiser φ sur C, c'est minimiser $\varphi + \delta_C$ sur $\mathbb{R}^p$.

L'idée : aucune direction qui reste dans C ne fait descendre φ ; si u^* est intérieur à C, on retrouve $g^* = 0$. Le sens « si » tient en une ligne : $\varphi(u) - \varphi(u^*) \geq (g^*)^\top(u - u^*) \geq 0$. Exemple : $(u - 3)^2$ sur $[0, 1]$: $u^* = 1$, $g^* = -4$, et $-4(u - 1) \geq 0$ pour tout $u \leq 1$.

Proposition — Monotonie du sous-différentiel (diapo 52) PAR CŒUR À SAVOIR REFAIRE → S4

Soit φ convexe, $g_1 \in \partial\varphi(u_1)$ et $g_2 \in \partial\varphi(u_2)$. Alors $(u_1 - u_2)^\top(g_1 - g_2) \geq 0$.

L'idée : en dimension 1, « $u_1 > u_2 \Rightarrow g_1 \geq g_2$ » : les pentes d'une fonction convexe croissent. Dans la preuve rapide, elle permet de remplacer le sous-gradient inconnu $\hat{g}$ en $\hat{\beta}$ par un sous-gradient g en β que l'on choisit.

Preuve express

1 $$\varphi(u_2) - \varphi(u_1) \geq g_1^\top(u_2 - u_1),$$
$$\varphi(u_1) - \varphi(u_2) \geq g_2^\top(u_1 - u_2).$$

↳ Définition du sous-gradient en u_1 (appliquée au point $v = u_2$), puis en u_2 (appliquée au point $v = u_1$).

2

$$0 \geq g_1^\top (u_2 - u_1) + g_2^\top (u_1 - u_2)$$
$$= -(g_1 - g_2)^\top (u_1 - u_2).$$

↳ On additionne : les φ s'éliminent ; on factorise par $u_1 - u_2$ et l'on change de signe.

Méthode — Seuillage doux et KKT en deux lignes À SAVOIR REFAIRE → S4

1. Écrire $0 \in \partial(\text{critère})$ (règle de Fermat), puis développer par la règle de la somme : gradient de la partie lisse + $\lambda\, \partial \|\cdot\|_1$.
2. Lire coordonnée par coordonnée : coefficient non nul ⇒ **égalité** avec sgn ; coefficient nul ⇒ **inégalité** (le sous-gradient est libre dans $[-1, 1]$).
3. Seuillage doux : $0 \in a - b + \lambda\, \partial \|a\|_1$ donne $\hat{a}_j = b_j - \lambda \operatorname{sgn}(\hat{a}_j)$ si $|b_j| > \lambda$, et $\hat{a}_j = 0$ si $|b_j| \leq \lambda$: c'est $T_\lambda(b)$.

KKT du Lasso pour $F(\beta) = \frac{1}{n}\|y - X\beta\|^2 + \lambda \|\beta\|_1$ minimisé sur $\mathbb{R}^M$ (sans contrainte, $\Theta = \mathbb{R}^M$) : $0 \in -\frac{2}{n} X^\top (y - X\hat{\beta}) + \lambda\, \partial \left\|\hat{\beta}\right\|_1$, soit

$$\frac{2}{n} X_j^\top (y - X\hat{\beta}) = \lambda \operatorname{sgn}(\hat{\beta}_j) \ \text{ si } \hat{\beta}_j \neq 0,$$
$$\left|\frac{2}{n} X_j^\top (y - X\hat{\beta})\right| \leq \lambda \ \text{ si } \hat{\beta}_j = 0.$$

Contrôle : avec le critère non normalisé $\|y - X\beta\|^2 + \lambda \|\beta\|_1$ de la séance 2, c'est $2X_j^\top (y - X\hat{\beta}) = \lambda \operatorname{sgn}(\hat{\beta}_j)$: la même chose au facteur n près. Le critère est convexe : ces conditions sont nécessaires **et** suffisantes.

Réflexe

Quand vous devez caractériser le minimiseur d'un critère convexe **non dérivable** → $0 \in \partial F$, règle de la somme, puis lecture coordonnée par coordonnée (non nul : égalité ; nul : inégalité). Quand une contrainte convexe apparaît → indicatrice δ_C et cône normal : « aucune direction admissible ne fait descendre ».

L'inégalité oracle lente

Théorème — Inégalité oracle lente (diapos 54–55) PAR CŒUR À SAVOIR REFAIRE → S4

Hypothèses : $y = f + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$; colonnes normalisées $\|X_j\|_2 = \sqrt{n}$; $\Theta \subset \mathbb{R}^M$ convexe. Aucune autre hypothèse sur X.

Estimateur : $\hat{\beta} = \arg\min_{\beta \in \Theta} \left\{ \frac{1}{n}\|y - X\beta\|^2 + \lambda \|\beta\|_1 \right\}$ avec $\lambda = 2\sigma \sqrt{\dfrac{2(x + \log M)}{n}}$, $x > 0$.

Conclusion : avec probabilité au moins $1 - 2e^{-x}$,

$$\frac{1}{n}\left\|f_{\hat{\beta}} - f\right\|^2 \leq \inf_{\beta \in \Theta} \left\{ \frac{1}{n}\|f_\beta - f\|^2 + 2\lambda \|\beta\|_1 \right\}.$$

Pour retrouver λ : on le choisit pour que $\frac{\lambda\sqrt{n}}{2\sigma} = \sqrt{2(x + \log M)}$; la queue gaussienne donne alors $2e^{-(x+\log M)} = \frac{2e^{-x}}{M}$ par brique, et l'union sur les M briques donne $2e^{-x}$. **Pour retrouver le 2λ** : λ de pénalité du concurrent, plus λ venu du bruit (les $\lambda \left\|\hat{\beta}\right\|_1$ se compensent).

Preuve express (rédaction de la professeure, Preuves cours 4 · p. 1)

Notations : $\|u\|_n^2 = \frac{1}{n}\|u\|^2$, $V_j = \frac{1}{n}\sum_i \varepsilon_i f_j(Z_i) = \frac{1}{n} X_j^\top \varepsilon$ (corrélation bruit/brique), $\mathcal{A} = \bigcap_{j=1}^M \{|V_j| \le \lambda/2\}$. On fixe un concurrent $\beta \in \Theta$.

1

$$\left\|y - f_{\hat\beta}\right\|_n^2 + \lambda \left\|\hat\beta\right\|_1 \le \|y - f_\beta\|_n^2 + \lambda \|\beta\|_1 .$$

↳ Inégalité de base : $\hat\beta$ minimise le critère sur Θ et $\beta \in \Theta$.

2

$$\begin{aligned}\left\|f_{\hat\beta} - f\right\|_n^2 \le \|f_\beta - f\|_n^2 + \frac{2}{n}\langle \varepsilon,\, f_{\hat\beta} - f_\beta\rangle \\ + \lambda\|\beta\|_1 - \lambda\left\|\hat\beta\right\|_1 .\end{aligned}$$

↳ On remplace $y = f + \varepsilon$ et on développe les carrés : $\|\varepsilon\|_n^2$ apparaît des deux côtés et s'élimine.

3

$$\begin{aligned}\frac{2}{n}\langle \varepsilon,\, f_{\hat\beta} - f_\beta\rangle &= \frac{2}{n}\langle \varepsilon,\, X(\hat\beta - \beta)\rangle \\ &= 2\sum_{j=1}^M (\hat\beta_j - \beta_j) V_j .\end{aligned}$$

↳ On échange les deux sommes : le bruit n'intervient qu'à travers les V_j.

4

$$\begin{aligned}\text{Sur } \mathcal{A} :\ 2\sum_j (\hat\beta_j - \beta_j) V_j &\le \lambda \left\|\hat\beta - \beta\right\|_1 \\ &\le \lambda\left\|\hat\beta\right\|_1 + \lambda\|\beta\|_1 .\end{aligned}$$

↳ $|V_j| \le \lambda/2$ pour tout j (c'est Hölder), puis l'inégalité triangulaire.

5

$$\text{Sur } \mathcal{A},\ \text{pour tout } \beta \in \Theta :$$
$$\left\|f_{\hat\beta} - f\right\|_n^2 \le \|f_\beta - f\|_n^2 + 2\lambda\|\beta\|_1 .$$

↳ On reporte : les $\lambda\left\|\hat\beta\right\|_1$ se compensent. $\mathcal{A}$ ne dépend pas de β : on peut passer à l'inf.

6

$$V_j \sim \mathcal{N}\Big(0, \frac{\sigma^2}{n^2}\sum_i f_j(Z_i)^2\Big) = \mathcal{N}\Big(0, \frac{\sigma^2}{n}\Big).$$

↳ Combinaison linéaire de gaussiennes indépendantes ; $\sum_i f_j(Z_i)^2 = \|X_j\|^2 = n$ par la normalisation.

7

$$\begin{aligned}\mathbb{P}(\mathcal{A}^c) &\le \sum_{j=1}^M \mathbb{P}\Big(|Z| > \frac{\lambda\sqrt{n}}{2\sigma}\Big) \\ &\le 2M\, e^{-\frac{1}{2}\left(\frac{\lambda\sqrt{n}}{2\sigma}\right)^2} \\ &= 2Me^{-(x+\log M)} = 2e^{-x}.\end{aligned}$$

↳ Borne de l'union (aucune indépendance requise), standardisation $Z = \sqrt{n}V_j/\sigma \sim \mathcal{N}(0,1)$, queue gaussienne $\mathbb{P}(|Z| > t) \le 2e^{-t^2/2}$ (TD2, question 3).

Dans le manuscrit, la deuxième ligne écrit $\frac{2}{n}\langle \varepsilon,\, f_\beta - f_{\hat\beta}\rangle$: lisez $\frac{2}{n}\langle \varepsilon,\, f_{\hat\beta} - f_\beta\rangle$ (coquille de signe sans conséquence). Le facteur 2 de $2e^{-x}$ vient des deux queues : $\mathbb{P}(|Z| > z) = 2\mathbb{P}(Z > z) \le 2e^{-z^2/2}$. Quand le manuscrit écrit $2\sum_j \mathbb{P}\big(|Z| > \frac{\lambda\sqrt{n}}{2\sigma}\big)$, lisez $2\sum_j \mathbb{P}\big(Z > \frac{\lambda\sqrt{n}}{2\sigma}\big)$.

Réflexe — Le terme croisé bruit × écart

Quand vous voyez $\frac{2}{n}\varepsilon^\top X\delta$ → Hölder : $\le \frac{2}{n}\left\|X^\top\varepsilon\right\|_\infty \|\delta\|_1$; puis $X_j^\top\varepsilon \sim \mathcal{N}(0, n\sigma^2)$ (normalisation), queue gaussienne et borne de l'union ⇒ $\lambda \asymp \sigma\sqrt{\log M/n}$.

À comprendre — Pourquoi « lente », et d'où vient le $\log M$ À COMPRENDRE → S4

Le prix $2\lambda\,\|\beta\|_1 = 4\sigma\,\|\beta\|_1\sqrt{2(x+\log M)/n}$ décroît comme $1/\sqrt{n}$, alors que l'oracle des séances 1–3 paie $\sigma^2 s/n$: c'est la **vitesse lente**, et le prix porte sur $\|\beta\|_1$, pas sur le nombre de coefficients. En échange, la garantie est « tout terrain » : seulement la normalisation, aucune hypothèse de corrélation entre briques, f quelconque. Le $\log M$ vient du maximum des M corrélations bruit/brique (de l'ordre de $\sqrt{2\log M}$ une fois standardisées) : la taille du dictionnaire ne coûte que logarithmiquement. Ordre de grandeur : $x = 3$ donne une probabilité $\ge 1 - 2e^{-3} \approx 0{,}90$.

L'inégalité oracle rapide

À comprendre — Pourquoi il faut une hypothèse sur X (diapo 56) À COMPRENDRE → S4

Matrice de Gram du dictionnaire : $G = \frac{1}{n}X^\top X = \big(\frac{1}{n}\langle f_j,\, f_{j'}\rangle\big)_{1\le j,j'\le M}$ (diagonale égale à 1 avec la normalisation). Si $M > n$, $\dim \operatorname{Ker} X \ge M - n > 0$, donc $\min_{t\neq 0}\frac{\sqrt{t^\top G t}}{\|t\|} = \min_{t\neq 0}\frac{\|Xt\|}{\sqrt{n}\|t\|} = 0$: la plus petite valeur propre de G est nulle, et « Xt petit » n'entraîne pas « t petit ». Pour passer de $1/\sqrt{n}$ à $1/n$, on ne demande cette implication que sur un cône : c'est la condition RE.

Hypothèse — Valeurs propres restreintes RE(s, c_0) (diapo 57) PAR CŒUR → S4

X vérifie RE(s, c_0), pour un $c_0 > 0$ et un $s \in \{1, \dots, M\}$, si

$$\kappa(s, c_0) = \min_{\substack{J\subset\{1,\dots,M\}\\ |J|\le s}} \min_{\substack{t\neq 0\\ \|t_{J^c}\|_1 \le c_0\|t_J\|_1}} \frac{\|Xt\|}{\sqrt{n}\,\|t_J\|} > 0,$$

où t_J est le vecteur t mis à zéro hors de J. Autrement dit, sur le cône : $\|Xt\| \ge \kappa\sqrt{n}\,\|t_J\|$.

Pour la retrouver : c'est le quotient $\frac{\|Xt\|}{\sqrt{n}\|t\|}$ de la matrice de Gram, mais (i) seulement pour les t du cône, (ii) avec $\|t_J\|$ au dénominateur. Même condition qu'en séance 3, avec $c_0 = 3$. Plus c_0 est grand, plus le cône est gros, plus la condition est exigeante : $\kappa(s, 3) \le \kappa(s, 1)$.

Proposition — Ce que RE impose aux petites sous-matrices de X (diapo 57) PAR CŒUR À SAVOIR REFAIRE → S4

Si X vérifie RE$(s, 1)$, toute sous-matrice de X formée d'au plus $2s$ colonnes est de rang plein (ses colonnes sont linéairement indépendantes).

L'idée : un vecteur non nul à au plus $2s$ coordonnées non nulles est dans le cône $c_0 = 1$ si l'on prend pour J ses s plus grandes coordonnées ; il ne peut donc pas être dans le noyau. Conséquence : deux briques ne peuvent pas coïncider aux points observés. La séance 3 l'énonce

sous RE$(s,3)$ (remarque de la diapo 37) : c'est cohérent, puisque RE$(s,3)$ entraîne RE$(s,1)$, l'hypothèse plus faible de la diapo 57.

Preuve express

1. $$|S| \le 2s, \quad t \text{ nul hors de } S, \quad Xt = 0.$$

   ↳ Il faut montrer $t = 0$: « X_S de rang plein » signifie que la seule combinaison nulle de ses colonnes est la combinaison triviale.

2. $$|J| = s, \qquad |t_k| \ge |t_l| \quad \text{pour } k \in J,\ l \notin J.$$

   ↳ On prend pour J les indices des s plus grandes valeurs de $|t_j|$: le J le plus favorable pour entrer dans le cône.

3. $$\|t_{J^c}\|_1 \le s \min_{k \in J} |t_k| \le \|t_J\|_1 .$$

   ↳ Hors de J il reste au plus s coordonnées non nulles, chacune $\le \min_J |t_k|$; et J contient s coordonnées, chacune $\ge \min_J |t_k|$.

4. $$0 = \|Xt\| \ge \kappa(s,1)\sqrt{n}\ \|t_J\| \\ \Rightarrow\ t_J = 0\ \Rightarrow\ t = 0.$$

   ↳ RE$(s,1)$ sur le cône ; J contient les plus grandes coordonnées, donc toutes sont nulles.

Théorème — Inégalité oracle rapide (diapo 58, rédaction de la professeure) PAR CŒUR À SAVOIR REFAIRE → S4

Hypothèses : $y = f + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$; $\|X_j\|_2 = \sqrt{n}$; RE$(s,3)$; Θ convexe.

Estimateur : $\hat\beta \in \arg\min_{\beta \in \Theta} \left\{ \frac{1}{n} \|y - X\beta\|^2 + 2\lambda \|\beta\|_1 \right\}$, avec **le même** $\lambda = 2\sigma\sqrt{2(x + \log M)/n}$ que pour l'inégalité lente (pénalité deux fois plus forte).

Conclusion : avec probabilité au moins $1 - 2e^{-x}$,

$$\frac{1}{n} \left\| f_{\hat\beta} - f \right\|^2 \le \inf_{\substack{\beta \in \Theta \\ \|\beta\|_0 \le s}} \left\{ \frac{1}{n} \|f_\beta - f\|^2 + \frac{9\lambda^2 s}{4\kappa(s,3)^2} \right\},$$

$$\text{avec} \quad \frac{9\lambda^2 s}{4\kappa(s,3)^2} = \frac{18\,\sigma^2 s\,(x + \log M)}{\kappa(s,3)^2\, n}.$$

Pour retrouver le 18 : $18 = \frac{9}{4} \times 8$. Le $\frac{9}{4} = \left(\frac{3}{2}\right)^2$ vient de $ax - x^2 \le \frac{a^2}{4}$ avec $a = \frac{3\lambda\sqrt{s}}{\kappa}$, où $3 = 2$ (pénalité 2λ) $+ 1$ (bruit au plus λ) ; le 8 vient de $\lambda^2 = \frac{8\sigma^2(x + \log M)}{n}$. Le s vient de Cauchy–Schwarz $\|\delta_J\|_1 \le \sqrt{s}\,\|\delta_J\|_2$, le κ^2 de RE.

Note sur la diapo 58 : elle énonce l'inégalité sans redire l'estimateur ; la professeure (Preuves cours 4 · p. 2) le pénalise par $2\lambda\|\beta\|_1$, soit $\lambda' = 2\lambda = 4\sigma\sqrt{2(x + \log M)/n}$ si l'on écrit le critère $\frac{1}{n}\|y - X\beta\|^2 + \lambda'\|\beta\|_1$. Retenez la version de la professeure.

Preuve express (étapes A à G, Preuves cours 4 · p. 2–4)

Notations : $R_n(\beta) = \|y - f_\beta\|_n^2$; un concurrent $\beta \in \Theta$ avec $J = J(\beta) = \{j : \beta_j \ne 0\}$, $|J| \le s$; $\delta = \hat\beta - \beta$; l'événement $\mathcal{A} = \left\{ \frac{1}{n} \left\| X^\top \varepsilon \right\|_\infty \le \frac{\lambda}{2} \right\}$ de la preuve lente.

1

$$\exists\, \hat{g} \in \partial \left\|\hat{\beta}\right\|_1 \ \text{ tel que, pour tout } \beta \in \Theta,$$
$$\left\langle -\frac{2}{n} X^\top (y - X\hat{\beta}) + 2\lambda \hat{g},\ \hat{\beta} - \beta \right\rangle \leq 0.$$

↳ A — Critère d'optimalité sur le convexe Θ (diapo 52) et règle de la somme : $\partial(R_n + 2\lambda \left\|\cdot\right\|_1) = \nabla R_n + 2\lambda\, \partial \left\|\cdot\right\|_1$.

2

$$\frac{2}{n}\langle f_{\hat{\beta}} - f,\ f_{\hat{\beta}} - f_\beta \rangle + 2\lambda \langle \hat{g},\ \hat{\beta} - \beta \rangle \leq \frac{2}{n}\langle \varepsilon,\ f_{\hat{\beta}} - f_\beta \rangle.$$

↳ B — On passe $X^\top$ de l'autre côté, puis $X\hat{\beta} = f_{\hat{\beta}}$, $y = f + \varepsilon$ et $X(\hat{\beta} - \beta) = f_{\hat{\beta}} - f_\beta$.

3

$$\text{pour tout } g \in \partial \left\|\beta\right\|_1 :$$
$$\left\|f_{\hat{\beta}} - f\right\|_n^2 + \left\|f_{\hat{\beta}} - f_\beta\right\|_n^2 \leq \left\|f_\beta - f\right\|_n^2 - 2\lambda \langle g,\ \hat{\beta} - \beta \rangle + \frac{2}{n}\langle \varepsilon,\ f_{\hat{\beta}} - f_\beta \rangle.$$

↳ C — Monotonie $\langle \hat{g} - g,\ \hat{\beta} - \beta \rangle \geq 0$ (le sous-gradient inconnu $\hat{g}$ est remplacé par g, à choisir), puis polarisation $2\langle a,\ a - c \rangle = \|a\|^2 + \|a - c\|^2 - \|c\|^2$ avec $a = f_{\hat{\beta}} - f$, $c = f_\beta - f$: apparaît le **bonus** $\left\|f_{\hat{\beta}} - f_\beta\right\|_n^2$.

4

$$\left\|f_{\hat{\beta}} - f\right\|_n^2 + \left\|f_{\hat{\beta}} - f_\beta\right\|_n^2 + 2\lambda \left\|\hat{\beta}_{J^c}\right\|_1 \leq \left\|f_\beta - f\right\|_n^2 + 2\lambda \left\|\delta_J\right\|_1 + \frac{2}{n}\langle \varepsilon,\ f_{\hat{\beta}} - f_\beta \rangle. \qquad (\star)$$

↳ D — On choisit $g = \operatorname{sgn}(\beta) + h$ avec $h_J = 0$ et $h_j = \operatorname{sgn}(\hat{\beta}_j)$ hors de J : $|\langle \operatorname{sgn}(\beta),\ \delta \rangle| \leq \left\|\delta_J\right\|_1$ et $\langle h,\ \delta \rangle = \left\|\hat{\beta}_{J^c}\right\|_1 = \left\|\delta_{J^c}\right\|_1$.

5

$$\text{Cas 1 : } \left\|f_{\hat{\beta}} - f\right\|_n^2 + \left\|f_{\hat{\beta}} - f_\beta\right\|_n^2 - \left\|f_\beta - f\right\|_n^2 \leq 0$$
$$\implies \left\|f_{\hat{\beta}} - f\right\|_n^2 \leq \left\|f_\beta - f\right\|_n^2.$$

↳ E — C'est mieux que l'inégalité voulue : terminé.

6

$$\text{Cas 2, sur } \mathcal{A} : \frac{2}{n}\langle X^\top \varepsilon,\ \delta \rangle \leq \lambda \left\|\delta_J\right\|_1 + \lambda \left\|\delta_{J^c}\right\|_1$$
$$\implies \left\|\delta_{J^c}\right\|_1 \leq 3 \left\|\delta_J\right\|_1.$$

↳ E — Dans le cas 2, la quantité du cas 1 est > 0 : on l'enlève de $(\star)$, il reste $2\lambda \left\|\hat{\beta}_{J^c}\right\|_1 \leq 2\lambda \left\|\delta_J\right\|_1 + \text{bruit}$. Sur $\mathcal{A}$, Hölder morceau par morceau avec $\frac{2}{n}\left\|X^\top \varepsilon\right\|_\infty \leq \lambda$: le bruit vaut au plus la **moitié** de la pénalité. Comme $\delta_{J^c} = \hat{\beta}_{J^c}$, on obtient $\lambda \left\|\hat{\beta}_{J^c}\right\|_1 \leq 3\lambda \left\|\delta_J\right\|_1$: le cône $c_0 = 3$.

7

$$\left\|\delta_J\right\|_2 \leq \frac{\|X\delta\|}{\sqrt{n}\,\kappa(s,3)} = \frac{\left\|f_{\hat{\beta}} - f_\beta\right\|_n}{\kappa(s,3)}.$$

↳ E — RE$(s,3)$ s'applique : δ est dans le cône associé à J, avec $|J| \leq s$.

8

$$\left\|f_{\hat\beta}-f\right\|_n^2+\left\|f_{\hat\beta}-f_\beta\right\|_n^2+\lambda\left\|\hat\beta_{J^c}\right\|_1 \le \|f_\beta-f\|_n^2+3\lambda\|\delta_J\|_1.$$

↳ F — La borne du bruit reportée dans $(\star)$: $2\lambda+\lambda=3\lambda$ devant $\|\delta_J\|_1$, et il reste $\lambda\left\|\hat\beta_{J^c}\right\|_1$ à gauche.

9

$$3\lambda\|\delta_J\|_1 \le \frac{3\lambda\sqrt{|J|}}{\kappa(s,3)}\left\|f_{\hat\beta}-f_\beta\right\|_n \le \left\|f_{\hat\beta}-f_\beta\right\|_n^2+\frac{9\lambda^2|J|}{4\kappa(s,3)^2}.$$

↳ F — Cauchy–Schwarz $\|\delta_J\|_1\le\sqrt{|J|}\,\|\delta_J\|_2$, RE, puis $ax\le x^2+\frac{a^2}{4}$ (c'est $ax-x^2\le\frac{a^2}{4}$) : le bonus $\left\|f_{\hat\beta}-f_\beta\right\|_n^2$ apparaît à droite.

10

$$\begin{aligned}\left\|f_\beta-f\right\|_n^2 &\le \|f_\beta-f\|_n^2+\frac{9\lambda^2|J|}{4\kappa^2}\\ &= \|f_\beta-f\|_n^2+\frac{18\sigma^2|J|\,(x+\log M)}{\kappa^2 n}\\ &\le \|f_\beta-f\|_n^2+\frac{18\sigma^2 s(x+\log M)}{\kappa^2 n}.\end{aligned}$$

↳ G — On reporte la seconde ligne F dans la première : le bonus, présent des deux côtés, se simplifie ; puis on oublie $\lambda\left\|\hat\beta_{J^c}\right\|_1\ge 0$. Ensuite $\lambda^2=\frac{8\sigma^2(x+\log M)}{n}$ et $|J|\le s$. Le cas 1 donne mieux. $\mathcal{A}$ ne dépend pas de β : inf sur les concurrents ; et $\mathbb{P}(\mathcal{A})\ge 1-2e^{-x}$ (même calcul que la preuve lente).

Dans le manuscrit, la dernière égalité oublie le facteur $|J|$ $(\le s)$; l'énoncé du théorème a bien le s.

Réflexe — Pourquoi une pénalité 2λ pour la vitesse rapide ?

L'événement est le même dans les deux preuves : le bruit vaut au plus λ, au sens où $\frac{2}{n}|\langle\varepsilon,\,X\delta\rangle|\le\lambda\|\delta\|_1$. Avec la pénalité $\lambda\|\beta\|_1$ (preuve lente), le bruit peut la consommer entièrement. Avec $2\lambda\|\beta\|_1$, il n'en consomme que la moitié ; l'autre moitié « gagne » hors du support et force le cône $c_0=3$. Plus généralement, une pénalité $c\lambda\|\beta\|_1$ $(c>1)$ donne le cône $c_0=\frac{c+1}{c-1}$ et la constante $2(c+1)^2$ au lieu de 18. Retenez : *vitesse rapide = pénalité au moins deux fois le bruit + cône + RE + $ax-x^2\le a^2/4$.*

À comprendre — Ce que dit le théorème rapide

À COMPRENDRE → S4

- **Compromis** : pour chaque s, le meilleur concurrent s-parcimonieux paie approximation + complexité $\frac{18\sigma^2 s(x+\log M)}{\kappa^2 n}$; le Lasso, solution d'un problème convexe simple, réalise ce compromis sans connaître f.
- **Vitesse** $s\log M/n$: en $1/n$, et la taille du dictionnaire ne coûte que $\log M$; $1/\kappa^2$ mesure la difficulté du dictionnaire.
- **Cas bien spécifié** : si $f=X\beta^\circ$ avec $\|\beta^\circ\|_0\le s$, $\beta^\circ\in\Theta$, alors $\frac{1}{n}\left\|X\hat\beta-X\beta^\circ\right\|^2\le\frac{18\sigma^2 s(x+\log M)}{\kappa^2 n}$. Avec $M=p$ et $x=(\frac{A^2}{8}-1)\log p$ $(A>2\sqrt{2})$, on a $\lambda=A\sigma\sqrt{\log p/n}=r$: l'estimateur rapide est exactement le Lasso de BRT, et la borne devient $\frac{9}{4}A^2\frac{\sigma^2 s\log p}{\kappa^2 n}$ (au lieu de $16A^2$), avec probabilité $\ge 1-2p^{1-A^2/8}$. La probabilité d'échec est doublée par rapport à la diapo 38 $(1-p^{1-A^2/8})$: la preuve utilise la queue $2e^{-t^2/2}$ au lieu de $e^{-t^2/2}$.

Piège — Confondre les deux inégalités

« Lente » ne veut dire ni fausse ni inutile : elle est vraie sans aucune hypothèse de corrélation. « Rapide » demande RE, qu'on ne peut pas vérifier en pratique (calculer κ est combinatoire). Les deux sont **non asymptotiques** (valables pour tout n, avec une probabilité explicite), ont le même λ et la même probabilité $1-2e^{-x}$, mais ne portent pas sur le même estimateur : pénalité $\lambda\|\beta\|_1$ pour la lente, $2\lambda\|\beta\|_1$ pour la rapide.

Bilan : séance 3 contre séance 4 → S4

	Séance 3 (BRT)	S4 : oracle lente	S4 : oracle rapide
Modèle	$Y = X\beta^* + \varepsilon$, β^* s-parcimonieux	$y = f + \varepsilon$, f quelconque	$y = f + \varepsilon$, f quelconque
Hypothèse sur X	normalisation + RE$(s,3)$	normalisation seulement	normalisation + RE$(s,3)$
Pénalité	$2r\|\beta\|_1$, $r = A\sigma\sqrt{\log p/n}$, $A > 2\sqrt{2}$	$\lambda\|\beta\|_1$, $\lambda = 2\sigma\sqrt{2(x+\log M)/n}$	$2\lambda\|\beta\|_1$, même λ
Événement de bruit	$\max_j \frac{2}{n}\left\|X_j^\top\varepsilon\right\| \le r$	$\max_j \|V_j\| \le \lambda/2$	le même que la lente
Probabilité	$\ge 1 - p^{1-A^2/8}$	$\ge 1 - 2e^{-x}$	$\ge 1 - 2e^{-x}$
Résultat	$\frac{1}{n}\left\|X(\hat\beta - \beta^*)\right\|^2 \le \frac{16A^2\sigma^2 s\log p}{\kappa^2 n}$	$\le \inf_{\beta\in\Theta}\{\text{approx.} + 2\lambda\|\beta\|_1\}$	$\le \inf_{\beta\in\Theta,\,\|\beta\|_0\le s}\{\text{approx.} + \frac{18\sigma^2 s(x+\log M)}{\kappa^2 n}\}$
Vitesse	$s\log p/n$	$\|\beta\|_1\sqrt{\log M/n}$	$s\log M/n$
Point de départ de la preuve	inégalité de base	inégalité de base	critère d'optimalité + monotonie

« approx. » $= \frac{1}{n}\|f_\beta - f\|^2$. Probabilité de BRT : $1 - p^{1-A^2/8}$ (diapo 38, queue $\mathbb{P}(|Z| > t) \le e^{-t^2/2}$). Le lemme du TD2, et l'inégalité rapide prise avec $x = (\frac{A^2}{8} - 1)\log p$, donnent $1 - 2p^{1-A^2/8}$ (queue $2e^{-t^2/2}$).

---

5. Modèles linéaires généralisés, régression logistique et de Poisson → S5 → TD3

L'essentiel de la séance en 5 lignes

- **GLM** = une loi de la famille exponentielle pour Y_i + un prédicteur linéaire $\eta_i = x_i^\top\beta$ + un lien $g(\mu_i) = \eta_i$; le lien canonique $g = (A')^{-1}$ donne $\theta_i = x_i^\top\beta$.
- **Tout se lit sur** A : moyenne $A'(\theta)$, variance $A''(\theta)$; avec le lien canonique, $L_n = -\frac{1}{n}\ell$ a pour gradient $\frac{1}{n}X^\top(\mu - y)$ et pour hessienne $\frac{1}{n}X^\top W X$, $W = \operatorname{diag}(\operatorname{Var} Y_i) \succeq 0$: L_n est convexe.
- **EMV** : équations $X^\top y = X^\top\mu$ (lien canonique), résolues par Newton = IRLS ; à p fixé, $\sqrt{n}(\hat\beta - \beta^*) \to \mathcal{N}(0, I(\beta^*)^{-1})$, d'où les intervalles de Wald (lemme de Slutsky).
- **Grande dimension** : l'EMV peut ne pas exister (séparation) ; Lasso $L_n(\beta) + \lambda\|\beta\|_1$, KKT $\frac{1}{n}X_j^\top(y - \hat\mu) = \lambda\operatorname{sgn}(\hat\beta_j)$ si $\hat\beta_j \ne 0$ (et $\le \lambda$ en valeur absolue sinon), $\lambda_{\max} = \|\nabla L_n(0)\|_\infty$ sans constante.

- **Logistique** : perte $f(z) = \log(1 + e^{-z})$ de la marge $z = y\,x^\top\beta$ ($y = \pm 1$) ; $f'' = \sigma(1-\sigma) \le \frac{1}{4}$ mais $\inf_\beta W_{ii} = 0$: inégalité oracle lente sans condition RE, avec seulement $|z_{ij}| \le c$ (Hoeffding, TD3) ; vitesse rapide seulement sous RE + bornes.

Pourquoi un GLM, et ses trois ingrédients

À comprendre — Pourquoi le modèle linéaire ne convient pas à une réponse binaire ou de comptage À COMPRENDRE → S5

Avec $Y_i \in \{0,1\}$: (1) $x_i^\top\beta$ finit par sortir de $[0,1]$, alors que $\mathbb{E}Y_i = \mathbb{P}(Y_i = 1)$ est une probabilité ; (2) $\operatorname{Var} Y_i = \pi_i(1-\pi_i)$ dépend de la moyenne (pas de variance constante σ^2) ; (3) le bruit $Y_i - x_i^\top\beta$ ne prend que deux valeurs : il n'est pas gaussien. Pour un comptage : moyenne > 0 et, pour une loi de Poisson, variance = moyenne. On garde la combinaison linéaire $x_i^\top\beta$, mais on la fait passer par une fonction.

Définition — Modèle linéaire généralisé PAR CŒUR → S5

Pour des données $(x_1, Y_1), \dots, (x_n, Y_n)$ avec des Y_i indépendantes, un GLM est la donnée de trois ingrédients :

1. une loi de la **famille exponentielle** pour chaque Y_i ;
2. un **prédicteur linéaire** $\eta_i = x_i^\top\beta$, $\beta \in \mathbb{R}^p$;
3. une **fonction de lien** g, strictement monotone et dérivable, qui « prend toutes les valeurs que $\mathbb{E}(Y)$ peut prendre » (définie sur l'ensemble des moyennes possibles, qu'elle envoie sur tout $\mathbb{R}$), avec $g\big(\mathbb{E}(Y_i)\big) = x_i^\top\beta$, c'est-à-dire $\mu_i = \mathbb{E}(Y_i) = g^{-1}(x_i^\top\beta)$.

Au tableau : linéaire $\mathbb{E}[Y \mid X = x] = x^\top\beta$; GLM $g\big(\mathbb{E}[Y \mid X = x]\big) = x^\top\beta$.

Pour la retrouver : suivez la chaîne $\beta \to \eta_i = x_i^\top\beta \to \mu_i = g^{-1}(\eta_i) \to \theta_i \to$ loi de Y_i. « Strictement monotone » rend g inversible ; « toutes les valeurs » garantit que $g^{-1}(\eta)$ est une moyenne admissible pour tout $\eta \in \mathbb{R}$ (logit pour $\mu \in]0,1[$, log pour $\mu > 0$; l'identité ne convient pas à une Bernoulli : elle autoriserait $\mu = 1{,}3$).

La famille exponentielle et ses moments

Définition — Famille exponentielle PAR CŒUR → S5

Y appartient à la famille exponentielle si sa densité (sa loi, si Y est discrète) s'écrit

$$f_\theta(y) = \exp\big(\eta(\theta)\,T(y) - A(\theta) + B(y)\big),$$

avec η, T, A, B déterministes. Forme **naturelle** : $\eta(\theta) = \theta$ (θ est le paramètre naturel). Dans tout le cours, $T(y) = y$. La fonction A (log-partition) n'est pas libre, elle est imposée par $\int f_\theta = 1$:

$$A(\theta) = \log \int e^{\eta(\theta)T(y)+B(y)}\,\mathrm{d}y$$

(une somme pour une loi discrète).

Pour la retrouver : écrivez $\log f_\theta(y)$ et rangez en trois tas : les termes mixtes (ils doivent former un produit $\eta(\theta)\,T(y)$), les termes en θ seul ($-A$), les termes en y seul (B). Contre-exemple : la loi uniforme sur $[0,\theta]$, dont le support dépend de θ.

Formules — Les trois lois du cours sous forme naturelle PAR CŒUR → S5

Pour les trois, $T(y) = y$; $\sigma(t) = \frac{1}{1+e^{-t}}$ est la sigmoïde.

Loi	θ (naturel)	$A(\theta)$	$B(y)$	$\mathbb{E}Y = A'(\theta)$	$\operatorname{Var} Y = A''(\theta)$
$\mathcal{N}(\mu, 1)$	μ	$\theta^2/2$	$-\frac{y^2}{2} - \log\sqrt{2\pi}$	$\theta = \mu$	1
Bernoulli $\mathcal{B}(p)$	$\log\frac{p}{1-p}$	$\log(1+e^\theta)$	0	$\sigma(\theta) = p$	$p(1-p)$
Poisson $\mathcal{P}(\lambda)$	$\log\lambda$	e^θ	$-\log y!$	$e^\theta = \lambda$	λ

Pour la retrouver : Bernoulli $\log f = y\log\frac{p}{1-p} + \log(1-p)$, donc $A = -\log(1-p) = \log(1+e^\theta)$ (car $1-p = \frac{1}{1+e^\theta}$) ; Poisson $\log f = y\log\lambda - \lambda - \log y!$, donc $A = \lambda = e^\theta$; gaussienne $\log f = y\mu - \frac{\mu^2}{2} - \frac{y^2}{2} - \log\sqrt{2\pi}$. Même méthode pour la loi exponentielle $\lambda e^{-\lambda y}$ (exercice 1 de S5) : $\theta = -\lambda < 0$, $A(\theta) = -\log(-\theta)$, $B = 0$, lien canonique $g(\mu) = -1/\mu$, qui n'atteint que $]-\infty, 0[$.

Définition — Forme avec paramètre de dispersion (version Cours6) PAR CŒUR → S5

$$f_\theta(y) = \exp\left(\frac{y\theta - b(\theta)}{a(\phi)} + c(y,\phi)\right),$$
$$\mathbb{E}Y = b'(\theta), \qquad \operatorname{Var} Y = a(\phi)\, b''(\theta).$$

a, b, c déterministes, c dérivable, b trois fois dérivable de dérivée première inversible ; θ : paramètre naturel, ϕ : paramètre de dispersion (tous deux inconnus) ; b joue le rôle de A, c celui de B. Exemple $\mathcal{N}(\mu, \sigma^2)$: $\theta = \mu$, $b(\theta) = \theta^2/2$, $a(\phi) = \phi = \sigma^2$, $c(y,\phi) = -\frac{y^2}{2\phi} - \frac{1}{2}\log(2\pi\phi)$. Bernoulli et Poisson : $a(\phi) = 1$, on retrouve la forme de Cours5.

Pour la retrouver : même preuve par le score, avec $\frac{\partial \ell}{\partial\theta} = \frac{y - b'(\theta)}{a(\phi)}$ et $\frac{\partial^2 \ell}{\partial\theta^2} = -\frac{b''(\theta)}{a(\phi)}$: score centré ⇒ $\mathbb{E}Y = b'(\theta)$; identité de Fisher ⇒ $\frac{b''(\theta)}{a(\phi)} = \frac{\operatorname{Var} Y}{a(\phi)^2}$. Contrôle : $\mathcal{N}(\mu, \sigma^2)$ donne $\operatorname{Var} Y = \sigma^2 \cdot 1$.

Théorème — Moyenne et variance d'une loi de la famille exponentielle PAR CŒUR À SAVOIR REFAIRE → S5

Si $f_\theta(y) = \exp\big(\theta T(y) - A(\theta) + B(y)\big)$ et qu'on peut dériver sous l'intégrale :

$$\mathbb{E}[T(Y)] = A'(\theta), \qquad \operatorname{Var}[T(Y)] = A''(\theta).$$

Ce sont les deux identités du score, $\mathbb{E}\big[\frac{\partial \ell}{\partial\theta}\big] = 0$ et $-\mathbb{E}\big[\frac{\partial^2 \ell}{\partial\theta^2}\big] = \mathbb{E}\big[\big(\frac{\partial \ell}{\partial\theta}\big)^2\big]$ (identité de Fisher), appliquées à $\ell = \theta T(y) - A(\theta) + B(y)$.

Pour la retrouver : $A = \log Z$ avec $Z(\theta) = \int e^{\theta T + B}$: dériver le log d'une constante de normalisation donne une moyenne ($Z'/Z = \mathbb{E}T$), dériver deux fois donne une variance ($Z''/Z - (Z'/Z)^2$). Contrôle sur Bernoulli : $A' = \sigma = p$, $A'' = \sigma(1-\sigma) = p(1-p)$.

Preuve express (par le score)

1. $$\int \frac{\partial f_\theta}{\partial\theta}\, \mathrm{d}y = 0$$

   ↳ on dérive $\int f_\theta = 1$ en θ (dérivation sous l'intégrale).

2 $$\mathbb{E}\left[\frac{\partial \ell}{\partial \theta}\right] = 0$$

↳ $\frac{\partial f_\theta}{\partial \theta} = f_\theta \frac{\partial \ell}{\partial \theta}$; une intégrale contre f_θ est une espérance.

3 $$\mathbb{E}[T(Y)] = A'(\theta)$$

↳ ici $\frac{\partial \ell}{\partial \theta} = T(y) - A'(\theta)$.

4 $$\mathbb{E}\left[\frac{\partial^2 \ell}{\partial \theta^2}\right] + \mathbb{E}\left[\left(\frac{\partial \ell}{\partial \theta}\right)^2\right] = 0$$

↳ on dérive encore $\int \frac{\partial \ell}{\partial \theta} f_\theta = 0$ (dérivée d'un produit, et à nouveau $\frac{\partial f_\theta}{\partial \theta} = f_\theta \frac{\partial \ell}{\partial \theta}$).

5 $$\mathrm{Var}[T(Y)] = A''(\theta)$$

↳ $\frac{\partial^2 \ell}{\partial \theta^2} = -A''(\theta)$ et $\left(\frac{\partial \ell}{\partial \theta}\right)^2 = \big(T(Y) - \mathbb{E}T(Y)\big)^2$.

À comprendre — Deux conséquences des moments À COMPRENDRE → S5

- $A'' = \mathrm{Var} \geq 0$: A est convexe, et A' est strictement croissante (dès que $T(Y)$ n'est pas constante), donc inversible. La relation $\mu = A'(\theta)$ se renverse en $\theta = (A')^{-1}(\mu)$: c'est ce qui fait exister le lien canonique.
- La variance est une fonction de la moyenne, $V(\mu) = A''\big((A')^{-1}(\mu)\big)$: $\mu(1-\mu)$ pour Bernoulli, μ pour Poisson, 1 pour $\mathcal{N}(\mu, 1)$.

Piège — Le signe de A au tableau Cours5 enrichi · p. 9 → S5

Pour Bernoulli paramétrée par $\theta = p$ (avec $\eta(\theta) = \log\frac{\theta}{1-\theta}$, $T(y) = y$, $B = 0$), le tableau écrit « $A(\theta) = \log(1-p)$ » : il faut lire $A(\theta) = -\log(1-\theta) > 0$. Test express : en $y = 0$, $f(0) = e^{-A(\theta)}$ doit valoir $1 - p$. En forme naturelle, c'est $A(\theta) = \log(1 + e^\theta)$.

Lien canonique et les trois GLM classiques

Définition — Lien canonique PAR CŒUR → S5

Pour $f_\theta(y) = \exp\big(\theta T(y) - A(\theta) + B(y)\big)$ avec $T(y) = y$, on a $\mu = \mathbb{E}(Y) = A'(\theta)$. Le lien canonique est défini par $\theta = g(\mu)$; si A' est inversible (c'est le cas dès que Y n'est pas constante, car $A'' = \mathrm{Var}\, Y > 0$),

$$g = (A')^{-1}.$$

Avec lui, $\theta_i = g(\mu_i) = x_i^\top \beta$: **le paramètre naturel est le prédicteur linéaire**.

Pour le trouver : forme naturelle, puis exprimez θ en fonction de μ. Gaussienne $\theta = \mu$ ⇒ identité ; Bernoulli $\theta = \log\frac{\mu}{1-\mu}$ ⇒ logit ; Poisson $\theta = \log\mu$ ⇒ log.

Formules — Les trois GLM classiques PAR CŒUR → S5

Modèle	valeurs de Y	lien canonique $g(\mu)$	$\mu = g^{-1}(\eta)$	$\operatorname{Var} Y$ en fonction de μ
linéaire gaussien	$\mathbb{R}$	μ (identité)	η	σ^2 (constante)
logistique	$\{0,1\}$	$\log \frac{\mu}{1-\mu}$ (logit)	$\sigma(\eta) = \frac{e^\eta}{1+e^\eta}$	$\mu(1-\mu)$
Poisson (log-linéaire)	$\{0,1,2,\dots\}$	$\log \mu$	e^η	μ

Formules — Lire un coefficient β_j PAR CŒUR → S5

Quand x_{ij} augmente de 1, les autres variables fixées :

- **linéaire** : la moyenne augmente de β_j ;
- **logistique** : la cote $\frac{\pi_i}{1-\pi_i} = e^{x_i^\top \beta}$ est **multipliée par** e^{β_j} (rapport de cotes, *odds ratio*) ;
- **Poisson** : la moyenne $\mu_i = e^{x_i^\top \beta}$ est multipliée par e^{β_j}.

Repères : $e^{0,7} \approx 2$ (la cote double) ; $e^{-0,2} \approx 0,82$ (18 % de moins). Piège : en logistique, β_j n'est **pas** l'effet sur la probabilité π_i, qui dépend du point (sigmoïde raide au milieu, plate aux bords).

Équations de vraisemblance, convexité, algorithme IRLS

Théorème — Équations de vraisemblance d'un GLM (lien quelconque) PAR CŒUR À SAVOIR REFAIRE → S5

Avec $\ell = \sum_i \ell_i$, $\ell_i = \log f_{\theta_i}(y_i)$ et $T(y) = y$:

$$\begin{aligned}\frac{\partial \ell_i}{\partial \beta_j} &= \frac{\partial \ell_i}{\partial \theta_i}\frac{\partial \theta_i}{\partial \mu_i}\frac{\partial \mu_i}{\partial \eta_i}\frac{\partial \eta_i}{\partial \beta_j} \\ &= \frac{(y_i - \mu_i)\, x_{ij}}{\operatorname{Var}(Y_i)}\frac{\partial \mu_i}{\partial \eta_i},\end{aligned}$$

d'où les p équations

$$\sum_{i=1}^{n} \frac{(y_i - \mu_i)\, x_{ij}}{\operatorname{Var}(Y_i)}\frac{\partial \mu_i}{\partial \eta_i} = 0, \qquad j = 1, \dots, p,$$

non linéaires en β : pas de formule fermée, il faut une méthode itérative.

Pour la retrouver : la chaîne $\beta \to \eta_i \to \mu_i \to \theta_i \to \ell_i$, un maillon à la fois. Contrôle : gaussien + identité ($\partial \mu_i / \partial \eta_i = 1$, $\operatorname{Var} Y_i = \sigma^2$) redonne les équations normales $X^\top (y - X\beta) = 0$.

Preuve express (les quatre maillons)

1 $$\frac{\partial \ell_i}{\partial \theta_i} = y_i - A'(\theta_i) = y_i - \mu_i$$

↳ $\ell_i = \theta_i y_i - A(\theta_i) + B(y_i)$ et $A'(\theta_i) = \mu_i$.

2 $$\frac{\partial \theta_i}{\partial \mu_i} = \frac{1}{A''(\theta_i)} = \frac{1}{\mathrm{Var}(Y_i)}$$

↳ dérivée d'une réciproque : $\mu = A'(\theta)$, donc $\frac{\mathrm{d}\theta}{\mathrm{d}\mu} = 1/\frac{\mathrm{d}\mu}{\mathrm{d}\theta}$.

3 $$\frac{\partial \mu_i}{\partial \eta_i} = \frac{1}{g'(\mu_i)}, \qquad \frac{\partial \eta_i}{\partial \beta_j} = x_{ij}$$

↳ $\eta_i = g(\mu_i)$ (même règle) ; $\eta_i = \sum_k x_{ik}\beta_k$.

4 On multiplie les quatre maillons, on somme sur i et on annule.
↳ dérivée d'une composée = produit des dérivées ; condition d'ordre 1 pour un maximum.

Théorème — Équations de vraisemblance avec le lien canonique PAR CŒUR À SAVOIR REFAIRE

→ S5

Si $\theta_i = x_i^\top \beta$, alors $\frac{\partial \mu_i}{\partial \eta_i} = A''(\theta_i) = \mathrm{Var}(Y_i)$ se simplifie avec le dénominateur :

$$\frac{\partial \ell_i}{\partial \beta_j} = (y_i - \mu_i)\, x_{ij},$$
$$\nabla \ell(\beta) = X^\top \big(y - \mu(\beta)\big),$$

et les équations de vraisemblance s'écrivent $X^\top y = X^\top \mu(\hat\beta)$: les résidus $y - \hat\mu$ sont orthogonaux aux colonnes de X, comme pour les moindres carrés.

Pour la retrouver en une ligne : $\ell(\beta) = y^\top X\beta - \sum_i A(x_i^\top \beta) + \text{cte}$ et $\nabla A(x_i^\top \beta) = A'(x_i^\top \beta)\, x_i = \mu_i x_i$. Avec une colonne de 1 dans X : $\sum_i y_i = \sum_i \hat\mu_i$ (en logistique, la somme des probabilités prédites égale le nombre de 1 observés).

Théorème — Convexité de la log-vraisemblance négative d'un GLM canonique PAR CŒUR

À SAVOIR REFAIRE → S5 Cours5 enrichi · p. 24

Pour un GLM canonique avec $T(y) = y$, soit ($\ell_n = \frac{1}{n}\ell$: log-vraisemblance **moyenne**)

$$\begin{aligned} L_n(\beta) &= -\ell_n(\beta) \\ &= \frac{1}{n}\sum_{i=1}^{n} \big[A(x_i^\top \beta) - y_i\, x_i^\top \beta - B(y_i)\big]. \end{aligned}$$

Avec $\mu_i(\beta) = A'(x_i^\top \beta)$ et $W(\beta) = \mathrm{diag}\left(A''(x_i^\top \beta)\right)$:

$$\nabla L_n(\beta) = \frac{1}{n} X^\top \big(\mu(\beta) - y\big),$$
$$\nabla^2 L_n(\beta) = \frac{1}{n} X^\top W(\beta) X,$$

$$\begin{aligned} v^\top \nabla^2 L_n(\beta)\, v &= \frac{1}{n}\sum_{i=1}^{n} A''(x_i^\top \beta)\, (x_i^\top v)^2 \\ &\geq 0 \qquad \text{car } A'' = \mathrm{Var} \geq 0, \end{aligned}$$

donc L_n est convexe. Conséquences : tout point critique (solution de $X^\top(y - \mu) = 0$) est un minimum global, donc un EMV ; si $A'' > 0$ et $\mathrm{rg}\, X = p$, L_n est strictement convexe (au plus un minimiseur).

L'idée : la courbure, ce sont les variances. Gaussien $\mathcal{N}(\mu_i, 1)$: $A'' = 1$, on retrouve la hessienne constante $\frac{1}{n}X^\top X$ des moindres carrés.

Preuve express

1

$$\begin{aligned}\nabla_\beta\left[A(x_i^\top\beta)\right] &= A'(x_i^\top\beta)\,x_i \\ &= \mu_i(\beta)\,x_i, \\ \nabla_\beta\left[y_i\,x_i^\top\beta\right] &= y_i\,x_i\end{aligned}$$

↳ règle de la chaîne ; $B(y_i)$ ne dépend pas de β.

2

$$\begin{aligned}\nabla L_n(\beta) &= \frac{1}{n}\sum_{i=1}^{n}\big(\mu_i(\beta)-y_i\big)x_i \\ &= \frac{1}{n}X^\top\big(\mu(\beta)-y\big)\end{aligned}$$

↳ $\sum_i c_i x_i = X^\top c$ (les $x_i^\top$ sont les lignes de X).

3

$$\begin{aligned}\nabla^2 L_n(\beta) &= \frac{1}{n}\sum_{i=1}^{n}A''(x_i^\top\beta)\,x_i x_i^\top \\ &= \frac{1}{n}X^\top W(\beta)X\end{aligned}$$

↳ on redérive $A'(x_i^\top\beta)\,x_i$: la chaîne fait sortir $x_i^\top$; le terme $y_i x_i$ est constant.

4

$$\begin{aligned}&v^\top\nabla^2 L_n(\beta)\,v \\ &\quad= \frac{1}{n}\sum_i A''(x_i^\top\beta)\,(x_i^\top v)^2 \geq 0\end{aligned}$$

↳ variance ≥ 0 fois carré ≥ 0 : hessienne semi-définie positive partout, donc L_n convexe. Si $A'' > 0$, la somme est nulle seulement si $Xv = 0$.

Piège — Convexe ne veut pas dire « le minimum existe »

- Données séparées en logistique : L_n décroît sans fin, l'EMV n'existe pas (TD3, question 2). Strictement convexe donne « au plus un » minimiseur, pas « exactement un ».
- L'argument « hessienne $= \frac{1}{n}X^\top WX$ » suppose le lien **canonique** ; avec un autre lien (probit), la hessienne dépend des y_i et il faut un autre argument.
- Notation : dans les diapos (p. 24–28), $\ell_n = \frac{1}{n}\ell$ est la log-vraisemblance **moyenne** ; dans le TD3, ℓ_n désigne la **somme** (exercice 1 : critère $-\ell_n + \lambda\|\beta\|_1$, sans $\frac{1}{n}$; exercice 2 : $\hat{R} = -\frac{1}{n}\ell_n$; exercice 3 : $L_n = -\frac{1}{n}\ell + \text{cte}$, normalisés). Les facteurs $\frac{1}{n}$ des conditions KKT et de $\lambda_{\max}$ en dépendent.

Formules — Gradient, hessienne et pas de Newton (lien canonique) PAR CŒUR À SAVOIR REFAIRE

→ S5

Ici $\ell = \sum_i \ell_i$ (la somme) :

$$\nabla \ell(\beta) = X^\top (y - \mu),$$
$$\nabla^2 \ell(\beta) = -X^\top W X,$$
$$W = \operatorname{diag}(w_i), \quad w_i = A''(\theta_i) = \operatorname{Var}(Y_i).$$

Pas de Newton depuis β_k (μ et W calculés en β_k) : $h^* = -[\nabla^2 \ell(\beta_k)]^{-1} \nabla \ell(\beta_k) = (X^\top W X)^{-1} X^\top (y - \mu)$ (la diapo p. 25 l'écrit avec $\ell_n = \frac{1}{n}\ell$: même h^*, le $\frac{1}{n}$ se simplifie), soit

$$\beta_{k+1} = (X^\top W X)^{-1} X^\top W z,$$
$$z = X\beta_k + W^{-1}(y - \mu),$$
$$z_i = \eta_i + \frac{y_i - \mu_i}{w_i},$$

c'est-à-dire $\beta_{k+1} = \arg\min_\beta \sum_i w_i (z_i - x_i^\top \beta)^2$: des moindres carrés pondérés, avec poids et réponse de travail recalculés à chaque itération (IRLS). Poids : $\mu_i(1-\mu_i)$ en logistique, μ_i en Poisson, 1 pour $\mathcal{N}(\mu_i, 1)$ (pour $\mathcal{N}(\mu_i, \sigma^2)$, $w_i = 1/\sigma^2$ et non σ^2 : l'égalité $w_i = \operatorname{Var} Y_i$ suppose $a(\phi) = 1$).

Pour la retrouver : z_i est la linéarisation de $g(y_i)$ autour de μ_i : $g(y_i) \approx g(\mu_i) + g'(\mu_i)(y_i - \mu_i)$ avec $g'(\mu_i) = 1/w_i$. Près de la solution, le nombre de décimales justes double à chaque itération (convergence quadratique de Newton).

Preuve express

1. $$\frac{\partial^2 \ell}{\partial \beta_k \, \partial \beta_j} = -\sum_i x_{ij} \frac{\partial \mu_i}{\partial \beta_k} = -\sum_i x_{ij} \, A''(\theta_i) \, x_{ik}$$

   ↳ on dérive $\sum_i (y_i - \mu_i) x_{ij}$; lien canonique : $\partial \mu_i / \partial \eta_i = A''(\theta_i)$. D'où $\nabla^2 \ell = -X^\top W X$.

2. $$q(h) = \ell(\beta_k) + s^\top h - \tfrac{1}{2} h^\top X^\top W X h, \qquad s = X^\top (y - \mu)$$

   ↳ Taylor à l'ordre 2 ; on maximise cette parabole concave.

3. $$\nabla q(h) = s - X^\top W X h = 0 \iff h^* = (X^\top W X)^{-1} s$$

   ↳ $X^\top W X$ est inversible si $\operatorname{rg} X = p$ et $w_i > 0$.

4. $$\beta_{k+1} = (X^\top W X)^{-1} \left[X^\top W X \beta_k + X^\top W \, W^{-1} (y - \mu) \right] = (X^\top W X)^{-1} X^\top W z$$

   ↳ on met $(X^\top W X)^{-1}$ en facteur ; c'est la solution des moindres carrés pondérés de z sur X.

Méthode — L'algorithme IRLS À SAVOIR REFAIRE → S5

1. Partir de β_0 (par exemple 0).
2. Calculer $\eta_i = x_i^\top \beta_k$, $\mu_i = g^{-1}(\eta_i)$ et les poids $w_i = \mathrm{Var}(Y_i) = A''(\theta_i)$.
3. Former la réponse de travail $z_i = \eta_i + (y_i - \mu_i)/w_i$.
4. Régression pondérée : $\beta_{k+1} = (X^\top W X)^{-1} X^\top W z$; recommencer jusqu'à ce que β ne bouge plus.

Contrôle : $x = (-2,-1,1,2)$, $y = (0,1,0,1)$, logistique sans constante, $\beta_0 = 0$: $\mu_i = \frac{1}{2}$, $w_i = \frac{1}{4}$, $X^\top(y-\mu) = 1$, $X^\top W X = 2{,}5$, donc $\beta_1 = 0{,}4$ (puis $0{,}4195$ et $0{,}4196$).

Normalité asymptotique de l'EMV et intervalles de confiance

Théorème — Consistance et normalité asymptotique de l'EMV PAR CŒUR → S5

Cours5 enrichi · p. 26

Information de Fisher **moyenne** : $I_n(\beta) = -\mathbb{E}[\nabla^2 \ell_n(\beta)]$, où $\ell_n = \frac{1}{n}\ell$ (lien canonique : $I_n(\beta) = \frac{1}{n} X^\top W(\beta) X$). On suppose $I_n(\beta^*) \to I(\beta^*) \succ 0$. Alors, **pour p fixé**, sous des hypothèses de régularité et de design (identifiabilité, information limite non dégénérée ; des covariables bornées seules ne suffisent pas) :

$$\hat\beta \xrightarrow{\mathbb{P}} \beta^*,$$
$$\sqrt{n}\,(\hat\beta - \beta^*) \xrightarrow{\mathcal{L}} \mathcal{N}\big(0, I(\beta^*)^{-1}\big).$$

En pratique : $\hat\beta \approx \mathcal{N}\big(\beta^*, (X^\top W X)^{-1}\big)$.

L'idée : $0 = \nabla\ell(\hat\beta) \approx \nabla\ell(\beta^*) - X^\top W X(\hat\beta - \beta^*)$, et $\nabla\ell(\beta^*) = \sum_i (y_i - \mu_i) x_i \approx \mathcal{N}(0, X^\top W X)$ par le TCL. Contrôle : modèle linéaire, $W = I/\sigma^2$, on retrouve la loi exacte $\mathcal{N}\big(\beta^*, \sigma^2 (X^\top X)^{-1}\big)$ de la séance 1.

Rappel — Lemme de Slutsky et application continue PAR CŒUR → Rappels

Si $Z_n \xrightarrow{\mathcal{L}} Z$ et $M_n \xrightarrow{\mathbb{P}} M$ avec M **constante**, alors $M_n Z_n \xrightarrow{\mathcal{L}} MZ$. Si h est continue et $\hat\beta \xrightarrow{\mathbb{P}} \beta^*$, alors $h(\hat\beta) \xrightarrow{\mathbb{P}} h(\beta^*)$.

Théorème — Intervalle de confiance asymptotique et intervalle de Wald PAR CŒUR À SAVOIR REFAIRE → S5 Cours5 enrichi · p. 26–27 (tableau)

En dimension 1, avec $q_{1-\alpha/2}$ le quantile d'ordre $1 - \frac{\alpha}{2}$ de $\mathcal{N}(0,1)$ ($1{,}96$ pour $\alpha = 5\,\%$) :

$$IC(\alpha) = \left[\hat\beta \pm q_{1-\alpha/2}\,\frac{I(\hat\beta)^{-1/2}}{\sqrt{n}}\right],$$
$$\mathbb{P}\big(\beta^* \in IC(\alpha)\big) \xrightarrow[n\to\infty]{} 1 - \alpha.$$

Coordonnée j : $\hat\beta_j \pm q_{1-\alpha/2}\sqrt{[I(\hat\beta)^{-1}]_{jj}/n}$. **Wald** (on prend $I(\hat\beta) \approx \frac{1}{n} X^\top \hat W X$) : $\widehat{\mathrm{se}}_j = \sqrt{[(X^\top \hat W X)^{-1}]_{jj}}$, intervalle à 95 % $\hat\beta_j \pm 1{,}96\,\widehat{\mathrm{se}}_j$; on rejette $\beta_j = 0$ au niveau 5 % si $\big|\hat\beta_j\big| / \widehat{\mathrm{se}}_j > 1{,}96$.

La recette : centrer-réduire ; remplacer l'inconnu $I(\beta^*)$ par un estimateur consistant $I(\hat\beta)$; invoquer Slutsky ; retourner $|\cdot| \le q_{1-\alpha/2}$ pour isoler β^*.

Preuve express

1. $$\sqrt{n}\, I(\beta^*)^{1/2}(\hat{\beta} - \beta^*) \xrightarrow{\mathcal{L}} \mathcal{N}(0, I_p)$$

   ↳ on multiplie par la matrice fixe $I(\beta^*)^{1/2}$: $I^{1/2} I^{-1} I^{1/2} = I_p$. Mais cette quantité dépend de β^*, inconnu.

2. $$\begin{aligned}\sqrt{n}\, I(\hat{\beta})^{1/2}(\hat{\beta} - \beta^*) &= \underbrace{\left[I(\hat{\beta})^{1/2} I(\beta^*)^{-1/2}\right]}_{\xrightarrow{\mathbb{P}} I_p} \\ &\quad \times \sqrt{n}\, I(\beta^*)^{1/2}(\hat{\beta} - \beta^*)\end{aligned}$$

   ↳ consistance $\hat{\beta} \to \beta^*$ et continuité de $\beta \mapsto I(\beta)^{1/2}$; avec des matrices, le facteur se met **à gauche**.

3. $$\sqrt{n}\, I(\hat{\beta})^{1/2}(\hat{\beta} - \beta^*) \xrightarrow{\mathcal{L}} \mathcal{N}(0, I_p)$$

   ↳ lemme de Slutsky.

4. $$\begin{aligned}&\mathbb{P}\left(\left|\sqrt{n}\, I(\hat{\beta})^{1/2}(\hat{\beta} - \beta^*)\right| \le q_{1-\alpha/2}\right) \\ &\to 1 - \alpha\end{aligned}$$

   ↳ en dimension 1 ; on isole β^* dans l'inégalité : c'est l'intervalle annoncé.

Piège — Un niveau seulement asymptotique, et à p fixé

Le tableau écrit « $\mathbb{P}(\beta^* \in IC(\alpha)) \ge 1 - \alpha$ » : c'est l'objectif ; la construction garantit seulement une probabilité qui **tend vers** $1 - \alpha$. Et tout suppose p fixé, $n \to \infty$: quand p est de l'ordre de n, l'EMV peut être très biaisé, voire ne pas exister.

Le Lasso d'un GLM

Définition — Lasso d'un modèle linéaire généralisé PAR CŒUR → S5 Cours5 enrichi · p. 27

Pour $\lambda > 0$:

$$\hat{\beta}_\lambda \in \operatorname*{arg\,min}_{\beta \in \mathbb{R}^p} \left\{ L_n(\beta) + \lambda \|\beta\|_1 \right\},$$
$$L_n = -\ell_n = -\frac{1}{n}\ell.$$

Une éventuelle constante (*intercept*) n'est pas pénalisée. Les trois points de la diapo : la pénalité ℓ_1 favorise la parcimonie ; avec un lien canonique, l'objectif est convexe ; contrairement aux moindres carrés gaussiens, L_n n'est en général pas quadratique.

Pourquoi : quand p est grand, l'EMV peut ne pas être unique ($Xv = 0$ avec $v \neq 0$: même vraisemblance en β et $\beta + v$) ou ne pas exister (séparation). Pour $\lambda > 0$, le critère est coercif : le Lasso existe (avec une constante non pénalisée, il faut en plus $0 < \bar{y} < 1$ en logistique). D'où vient le critère : en gaussien de variance 1, $-\ell(\beta) = \frac{1}{2}\|y - X\beta\|^2 + \text{cte}$.

Théorème — Conditions d'optimalité du Lasso d'un GLM canonique PAR CŒUR À SAVOIR REFAIRE

→ S5 Cours5 enrichi · p. 28

Lien canonique, $L_n = -\frac{1}{n}\ell$ (log-vraisemblance **moyenne**). Par convexité, $\hat\beta$ minimise $L_n(\beta) + \lambda\|\beta\|_1$ si et seulement si

$$\begin{aligned} & 0 \in \nabla L_n(\hat\beta) + \lambda\,\partial\left\|\hat\beta\right\|_1 \\ \iff\ & \frac{1}{n}X^\top(y-\hat\mu) \in \lambda\,\partial\left\|\hat\beta\right\|_1, \end{aligned}$$

où $\hat\mu = \mu(\hat\beta)$, c'est-à-dire, coordonnée par coordonnée :

$$\begin{cases} \frac{1}{n}X_j^\top(y-\hat\mu) = \lambda\ \mathrm{sgn}(\hat\beta_j) & \text{si } \hat\beta_j \neq 0, \\ \left|\frac{1}{n}X_j^\top(y-\hat\mu)\right| \le \lambda & \text{si } \hat\beta_j = 0. \end{cases}$$

Pour la retrouver : les KKT de la séance 2 avec $Y - X\hat\beta$ remplacé par $y - \hat\mu$. Le seuil est λ et non $\lambda/2$: le critère est normalisé par $\frac{1}{n}$ et la dérivée de $A(\eta) - y\eta$ vaut $\mu - y$, sans le facteur 2 du carré.

Preuve express

1. $L_n + \lambda\|\cdot\|_1$ est convexe, donc $\hat\beta$ est un minimiseur $\iff 0 \in \nabla L_n(\hat\beta) + \lambda\,\partial\left\|\hat\beta\right\|_1$.
   ↳ optimalité convexe et règle de la somme (L_n est dérivable), séance 4.

2. $$\begin{aligned} -\nabla L_n(\hat\beta) &= \frac{1}{n}X^\top(y-\hat\mu) \\ &\in \lambda\,\partial\left\|\hat\beta\right\|_1 \end{aligned}$$
   ↳ gradient de la diapo p. 24, passé de l'autre côté.

3. $\partial\|\beta\|_1$ est le produit des $\partial|\cdot|(\beta_j) : \{\mathrm{sgn}\,\beta_j\}$ si $\beta_j \neq 0$, $[-1,1]$ sinon.
   ↳ sous-différentiel de la norme ℓ_1 ; on lit chaque coordonnée.

À comprendre — Qu'est-ce qui change par rapport au Lasso linéaire ? (la question de la diapo p. 28) À COMPRENDRE → S5

Ce qui ne change pas	Ce qui change
• problème convexe : KKT nécessaires et suffisantes ; • même lecture : la corrélation de chaque variable avec le résidu est plafonnée à λ, et atteinte (avec le bon signe) par les variables actives ; • un $\lambda_{\max}$ au-delà duquel tout est nul ; même effet parcimonieux.	• résidu non linéaire $\hat\mu_i = A'(x_i^\top\hat\beta)$: pas de seuillage doux explicite, même en design orthogonal ; • chemin $\lambda \mapsto \hat\beta_\lambda$ courbe (affine par morceaux en linéaire) ; • calcul itératif : IRLS + Lasso pondéré $\min_\beta \frac{1}{2n}\sum_i w_i(z_i - x_i^\top\beta)^2 + \lambda\|\beta\|_1$ (`glmnet`) ; • hessienne $\frac{1}{n}X^\top W(\beta)X$ variable : la théorie demande plus d'hypothèses.

Méthode — Le $\lambda_{\max}$ d'un Lasso de GLM PAR CŒUR À SAVOIR REFAIRE → S5

1. Écrire les KKT au point candidat $\hat\beta = 0$: toutes les coordonnées sont nulles, seule l'inégalité s'applique, avec $\hat\mu = \mu(0)$.
2. 0 est solution $\iff$ $\lambda \geq \lambda_{\max} = \|\nabla(\text{partie lisse})(0)\|_\infty$ (les KKT sont nécessaires et suffisantes, par convexité).

- Logistique sans constante, critère $L_n + \lambda\|\beta\|_1$: $\mu(0) = \sigma(0)\mathbf{1} = \frac{1}{2}\mathbf{1}$, donc $\lambda_{\max} = \left\|\frac{1}{n}X^\top(y - \frac{1}{2}\mathbf{1})\right\|_\infty$ si $y \in \{0,1\}$, soit $\frac{1}{2n}\left\|X^\top y\right\|_\infty$ en codage $y \in \{-1,1\}$.
- Logistique avec constante non pénalisée ($0 < \bar y < 1$) : $\hat\mu = \bar y\mathbf{1}$, $\lambda_{\max} = \frac{1}{n}\max_j \left|X_j^\top(y - \bar y\mathbf{1})\right|$.
- Poisson sans constante : $\mu(0) = \mathbf{1}$, $\lambda_{\max} = \left\|\frac{1}{n}X^\top(Y - \mathbf{1})\right\|_\infty$.
- Autres conventions : TD3, exercice 1 (critère $-\ell_n + \lambda\|\beta\|_1$, somme sans $\frac{1}{n}$) : $\left\|X^\top(Y - \frac{1}{2}\mathbf{1})\right\|_\infty$; linéaire $\|Y - X\beta\|^2 + \lambda\|\beta\|_1$ (séance 2) : $2\left\|X^\top Y\right\|_\infty$.

La régression logistique de A à Z, et sa courbure

Définition — Liens pour une réponse binaire : les fonctions quantiles PAR CŒUR → S5

Cours5 enrichi · p. 30–31

$\pi_i = \mathbb{P}(Y_i = 1) \in]0,1[$ et $x_i^\top\beta \in \mathbb{R}$: on prend $g = F^{-1}$ (fonction quantile), où F est une fonction de répartition continue et strictement croissante ; le modèle est $\pi_i = F(x_i^\top\beta)$.

- $F = \Phi$ (répartition de $\mathcal{N}(0,1)$) : lien Φ^{-1}, régression **probit**, lien non canonique ;
- $F = \sigma$, $\sigma(t) = \frac{1}{1+e^{-t}} = \frac{e^t}{1+e^t}$ (loi logistique) : lien $\log\frac{\pi}{1-\pi}$ (logit), régression **logistique**, lien canonique (le paramètre naturel de Bernoulli est $\operatorname{logit}\pi$).

La sigmoïde : $\sigma' = \sigma(1-\sigma)$, $\sigma(-t) = 1 - \sigma(t)$, $\sigma(0) = \frac{1}{2}$.

Image (hors diapos) : $Y_i = 1$ quand un score caché $x_i^\top\beta + \xi_i$ est positif, avec ξ_i de loi symétrique de répartition F : $\mathbb{P}(Y_i = 1) = F(x_i^\top\beta)$. Bruit gaussien ⇒ probit ; bruit logistique ⇒ logit.

Formules — Vraisemblance en codage $Y \in \{-1,1\}$ et perte logistique PAR CŒUR À SAVOIR REFAIRE → S5 Cours5 enrichi · p. 32–33

Pour $y \in \{-1,1\}$:

$$\mathbb{P}(Y = y \mid X = x) = \sigma(y\,x^\top\beta),$$
$$-\frac{1}{n}\ell(\beta) = \frac{1}{n}\sum_{i=1}^n f\left(y_i\,x_i^\top\beta\right),$$
$$f(z) = \log\left(1 + e^{-z}\right).$$

f est la **perte logistique**, $z_i = y_i\,x_i^\top\beta$ la **marge** de l'observation i. Avec le codage $\tilde y = \frac{y+1}{2} \in \{0,1\}$: $\log(1 + e^{-y\eta}) = \log(1+e^\eta) - \tilde y\,\eta$, donc c'est le même critère $L_n(\beta) = \frac{1}{n}\sum_i\left[\log(1 + e^{x_i^\top\beta}) - \tilde y_i x_i^\top\beta\right]$.

Pour la retrouver : $\sigma(-z) = 1 - \sigma(z)$ (σ est la répartition d'une loi symétrique), donc les deux cas $y = \pm 1$ tiennent dans $\sigma(y\,x^\top\beta)$; puis $-\log\sigma(z) = \log(1 + e^{-z})$. Lecture : marge $\gg 0$ ⇒ perte $\approx e^{-z} \approx 0$ (bien prédit) ; marge $\ll 0$ ⇒ perte $\approx |z|$ (très mal prédit).

Formules — Dérivées de la perte logistique, gradient, hessienne PAR CŒUR À SAVOIR REFAIRE

→ S5 Cours5 enrichi · p. 34–35

$$f'(z) = -\sigma(-z),$$
$$f''(z) = \sigma(z)\big(1-\sigma(z)\big) \in \,]0, \tfrac{1}{4}].$$

Avec $L_n = -\frac{1}{n}\ell$:

$$\nabla L_n(\beta) = -\frac{1}{n}\sum_{i=1}^{n} y_i\,\sigma(-y_i\,x_i^\top\beta)\,x_i,$$
$$\nabla^2 L_n(\beta) = \frac{1}{n}X^\top W(\beta) X,$$

avec $W_{ii} = \pi_i(\beta)\big(1-\pi_i(\beta)\big)$, $\pi_i(\beta) = \sigma(x_i^\top\beta)$, et $0 \preceq \nabla^2 L_n(\beta) \preceq \frac{1}{4n}X^\top X$: le problème est convexe.

Preuve express

1

$$f'(z) = \frac{-e^{-z}}{1+e^{-z}} = \frac{-1}{1+e^{z}} = -\sigma(-z)$$

↳ $(\log u)' = u'/u$, puis on multiplie haut et bas par e^z.

2

$$f''(z) = \frac{e^z}{(1+e^z)^2} = \sigma(z)\,\sigma(-z) = \sigma(z)\big(1-\sigma(z)\big) \le \tfrac{1}{4}$$

↳ $t(1-t) = \frac{1}{4} - (t-\frac{1}{2})^2$, avec égalité en $z=0$.

3

$$\nabla_\beta f(y_i x_i^\top\beta) = f'(y_i x_i^\top\beta)\,y_i x_i,$$
$$\nabla^2_\beta f(y_i x_i^\top\beta) = f''(y_i x_i^\top\beta)\,y_i^2\,x_i x_i^\top$$

↳ règle de la chaîne ; $y_i^2 = 1$ et $f''(-z) = f''(z)$, donc le poids vaut $\sigma(x_i^\top\beta)\big(1-\sigma(x_i^\top\beta)\big)$ quel que soit le signe de y_i.

4

$$v^\top\nabla^2 L_n\,v = \frac{1}{n}\sum_i W_{ii}\,(x_i^\top v)^2$$
$$\in \Big[0,\ \frac{1}{4n}\,\|Xv\|^2\Big]$$

↳ $0 < W_{ii} \le \frac{1}{4}$: hessienne semi-définie positive, donc convexité.

Théorème — Ridge et Lasso logistiques, conditions KKT PAR CŒUR → S5 Cours5 enrichi · p. 29, 36

Ridge : $\hat\beta_\lambda = \arg\min_\beta\ \frac{1}{n}\sum_i \log\left(1+e^{-y_i x_i^\top\beta}\right) + \lambda\,\|\beta\|_2^2$. Problème strictement convexe (hessienne $\succeq 2\lambda I_p$, même si $p > n$) et coercif ⇒ **solution unique** ; pas de formule fermée.

Lasso : même critère avec $\lambda\,\|\beta\|_1$; convexe, solution qui existe, parcimonieuse, pas forcément unique. KKT (codage ± 1), avec $c_j = \frac{1}{n}\sum_i y_i\,\sigma(-y_i x_i^\top\hat\beta)\,x_{ij}$:

$$\begin{cases} c_j = \lambda\ \mathrm{sgn}(\hat\beta_j) & \text{si } \hat\beta_j \neq 0, \\ |c_j| \le \lambda & \text{si } \hat\beta_j = 0. \end{cases}$$

Pour relier aux KKT de la p. 28 : $y\,\sigma(-y\eta) = \tilde{y} - \sigma(\eta)$ (vérifiez $y = 1$ puis $y = -1$), donc $c_j = \frac{1}{n} X_j^\top (\tilde{y} - \hat{\mu})$: ce sont les mêmes conditions, écrites avec les étiquettes 0/1.

Piège — Deux codages, un seul modèle

$Y \in \{0, 1\}$: perte $\log(1 + e^{x^\top \beta}) - y\, x^\top \beta$, résidu $y - \mu$. $Y \in \{-1, 1\}$: perte $\log(1 + e^{-y\, x^\top \beta})$, poids $y\,\sigma(-y\, x^\top \beta)$. Les formules ne se ressemblent pas, mais elles donnent les mêmes estimateurs. Avant d'appliquer une formule, **vérifiez le codage**.

Proposition — Courbure : du Lasso linéaire au Lasso logistique PAR CŒUR → S5

Cours5 enrichi · p. 35

Linéaire gaussien (perte $\|y - X\beta\|_2^2 / (2n)$) : $\nabla^2 L_n(\beta) = \frac{1}{n} X^\top X$, **constante**. Logistique : $\nabla^2 L_n(\beta) = \frac{1}{n} X^\top W(\beta) X$, $W_{ii}(\beta) = \pi_i(\beta)\big(1 - \pi_i(\beta)\big)$, et

$$0 < W_{ii}(\beta) \leq \tfrac{1}{4} \quad \text{mais} \quad \inf_{\beta \in \mathbb{R}^p} W_{ii}(\beta) = 0 \quad (x_i \neq 0).$$

Conséquence : des inégalités oracle plus rapides, en $s \log(p)/n$, demandent une condition de valeurs propres restreintes **et** des hypothèses de bornitude sur les covariables et les prédicteurs linéaires [Kwemou, 2016].

Pour la retrouver : $\beta = t\, x_i$, $t \to +\infty$: $x_i^\top \beta = t \|x_i\|^2 \to \infty$, $\sigma \to 1$, $W_{ii} \to 0$ (infimum non atteint). Repères : $W_{ii} = 0{,}25$; $0{,}197$; $0{,}105$; $0{,}045$ pour $x_i^\top \beta = 0$; 1 ; 2 ; 3.

À comprendre — Pourquoi la courbure compte pour la théorie À COMPRENDRE

Dans les preuves des séances 3 et 4, c'est le terme $\frac{1}{n} \|X\delta\|^2$, venu du carré (courbure constante), qui « tient » l'erreur, et la condition RE porte sur $\frac{1}{n} X^\top X$. En logistique, le terme analogue vaut environ $\frac{1}{n} \sum_i W_{ii} (x_i^\top \delta)^2$: si des W_{ii} s'effondrent, un petit excès de risque peut cacher une grande erreur sur β. L'inégalité **lente** n'utilise pas la courbure : elle passe au logistique sans condition RE, avec seulement des covariables bornées, $|z_{ij}| \leq c$ (TD3, exercice 2).

TD3, exercice 1 — Le modèle logistique

Formules — Densité, vraisemblance, log-vraisemblance (questions 1a à 1c) PAR CŒUR À SAVOIR REFAIRE → TD3

$Y \sim \mathcal{B}(\mu)$ (la « binomiale » de l'énoncé est une Bernoulli) : $f_\mu(y) = \mu^y (1 - \mu)^{1-y}$, $y \in \{0, 1\}$ (densité par rapport à la mesure de comptage). Vraisemblance : $L(\mu_1, \ldots, \mu_n) = \prod_i \mu_i^{Y_i} (1 - \mu_i)^{1 - Y_i}$. Avec $\log \frac{\mu_i}{1 - \mu_i} = X_i^\top \beta$, la log-vraisemblance (une **somme**, sans $\frac{1}{n}$: c'est le ℓ_n du TD3) vaut

$$\ell_n(\beta) = \sum_{i=1}^{n} \Big(Y_i X_i^\top \beta - \log\big(1 + e^{X_i^\top \beta}\big) \Big).$$

Preuve express

1

$$\log L = \sum_i \Big[Y_i \log \frac{\mu_i}{1-\mu_i} + \log(1-\mu_i) \Big]$$

↳ log du produit, puis on regroupe les termes en Y_i.

2

$$\mu_i = \frac{e^{X_i^\top \beta}}{1+e^{X_i^\top \beta}}, \qquad 1-\mu_i = \frac{1}{1+e^{X_i^\top \beta}}$$

↳ on inverse le logit.

3 On remplace : le logit vaut $X_i^\top \beta$ et $\log(1-\mu_i) = -\log\left(1+e^{X_i^\top \beta}\right)$.
↳ c'est la forme canonique $\sum_i [\theta_i Y_i - A(\theta_i)]$ avec $A(\theta) = \log(1+e^\theta)$.

Proposition — ℓ_n est-elle dérivable, convexe, concave ? Gradient et hessienne (question 1d)

PAR CŒUR · À SAVOIR REFAIRE · → TD3

ℓ_n est C^∞ et

$$\nabla \ell_n(\beta) = X^\top \big(Y - \mu(\beta)\big),$$
$$\nabla^2 \ell_n(\beta) = -X^\top W(\beta) X,$$
$$W = \operatorname{diag}\big(\mu_i(1-\mu_i)\big).$$

$v^\top \nabla^2 \ell_n v = -\sum_i \mu_i(1-\mu_i)(X_i^\top v)^2 \le 0$: ℓ_n est **concave**, pas convexe (dès qu'un $X_i \neq 0$) ; **strictement concave si et seulement si** $\operatorname{rg} X = p$ (donc jamais si $p > n$). Et $\ell_n < 0$ partout.

Pour la retrouver : $h(t) = \log(1+e^t)$ a pour dérivées $h' = \sigma$ et $h'' = \sigma(1-\sigma) > 0$; puis $\nabla_\beta h(X_i^\top \beta) = h'(X_i^\top \beta) X_i$ et $\nabla^2_\beta h(X_i^\top \beta) = h''(X_i^\top \beta) X_i X_i^\top$.

Proposition — Le Ridge logistique, et le cas $\lambda = 0$ (question 2)

PAR CŒUR · À SAVOIR REFAIRE · → TD3

$F_\lambda(\beta) = -\ell_n(\beta) + \lambda \|\beta\|^2$, $\lambda > 0$: $\nabla^2 F_\lambda = X^\top W X + 2\lambda I_p \succeq 2\lambda I_p$ (fortement convexe ⇒ au plus un minimiseur) et $F_\lambda(\beta) \ge \lambda \|\beta\|^2 \to \infty$ (car $-\ell_n \ge 0$: coercive ⇒ un minimiseur existe). Donc $\hat\beta^R(\lambda)$ **existe et est unique**, même si $p > n$. **Pas de formule fermée** : $X^\top \big(Y - \sigma(X\beta)\big) = 2\lambda\beta$ n'est pas linéaire en β. On le calcule par Newton = IRLS pénalisé :

$$\beta_{k+1} = (X^\top W_k X + 2\lambda I)^{-1} X^\top W_k z_k,$$
$$z_k = X\beta_k + W_k^{-1}(Y - \mu_k).$$

Pour $\lambda = 0$, c'est l'EMV ($X^\top(Y - \hat\mu) = 0$), qui **peut ne pas exister** : si les données sont séparables ($\exists b$ avec $X_i^\top b > 0$ quand $Y_i = 1$ et $X_i^\top b < 0$ quand $Y_i = 0$), $\ell_n(tb) \to 0 = \sup \ell_n$ sans être atteint ; si $p \ge n$ et $\operatorname{rg} X = n$, c'est toujours le cas. S'il existe et que $\operatorname{rg} X = p$, il est unique.

À comprendre — Génomique : Ridge ou Lasso ? (question 3)

À COMPRENDRE · → TD3

Le Lasso. (1) L'objectif, « les gènes qui ont de l'influence », est une **sélection**, et seul le Lasso met des coefficients exactement à 0 ; (2) $p \gg n$: l'EMV n'existe pas, il faut pénaliser de toute façon ; (3) un modèle

à quelques gènes est interprétable. En pratique : standardiser les variables, choisir λ par validation croisée, ne pas pénaliser la constante ; gènes très corrélés ⇒ elastic net ou group-Lasso (séance 6).

Formules — KKT du Lasso logistique, convention du TD (question 4) PAR CŒUR → TD3

Critère $-\ell_n(\beta) + \lambda \|\beta\|_1$ (somme, **sans** $\frac{1}{n}$), $\hat{\mu}_i = \sigma(X_i^\top \hat{\beta})$:

$$\begin{cases} X_j^\top (Y - \hat{\mu}) = \lambda \operatorname{sgn}(\hat{\beta}_j) & \text{si } \hat{\beta}_j \neq 0, \\ \left| X_j^\top (Y - \hat{\mu}) \right| \leq \lambda & \text{si } \hat{\beta}_j = 0, \end{cases}$$

et, sans constante dans le modèle,

$$\lambda_{\max} = \left\| X^\top \left(Y - \tfrac{1}{2}\mathbf{1} \right) \right\|_\infty .$$

Pour la retrouver : la diapo p. 28 multipliée par n. Ici X_j est la **colonne** j (l'énoncé note aussi X_i l'individu i).

TD3, exercice 2 — Une inégalité oracle pour le Lasso logistique

Définition — Cadre, risque empirique, risque, processus empirique (questions 1 et 2) PAR CŒUR → TD3

$\mathbb{P}(Y_i = 1) = \pi(z_i^\top \beta_0)$ avec $\pi = \sigma$, $z_i \in \mathbb{R}^p$ déterministes, $\max_{i,j} |z_{ij}| \leq c$. Risque empirique et Lasso :

$$\begin{aligned} \hat{R}(\beta) &= \frac{1}{n} \sum_{i=1}^{n} \left[\log\left(1 + e^{z_i^\top \beta}\right) - Y_i z_i^\top \beta \right] \\ &= -\frac{1}{n} \ell_n(\beta), \end{aligned}$$

$$\hat{\beta}_L = \operatorname*{arg\,min}_{\beta \in \mathbb{R}^p} \left\{ \hat{R}(\beta) + \lambda \|\beta\|_1 \right\},$$

où ℓ_n est la log-vraisemblance de l'exercice 1 (une somme) : ici le critère est normalisé par $\frac{1}{n}$. Risque : $R(\beta) = \mathbb{E}[\hat{R}(\beta)] = \hat{R}(\beta) + \frac{1}{n}\sum_i z_i^\top \beta \big(Y_i - \pi(z_i^\top \beta_0)\big)$. Processus empirique : $V_j = \frac{1}{n}\sum_i z_{ij}\varepsilon_i$ avec $\varepsilon_i = Y_i - \mathbb{E}Y_i$, de sorte que $\hat{R}(\beta) = R(\beta) - \sum_j \beta_j V_j$.

Question 1 (pourquoi $\hat{R}$) : c'est la log-vraisemblance négative normalisée (le Lasso est un maximum de vraisemblance pénalisé, celui de la diapo p. 27) ; c'est aussi la moyenne des pertes logistiques $\log(1 + e^{-\tilde{Y}_i z_i^\top \beta})$, $\tilde{Y}_i = 2Y_i - 1$; elle est convexe et lisse ; le $\frac{1}{n}$ en fait une moyenne, d'où λ de l'ordre de $\sqrt{\log p / n}$.

Pour la retrouver : Y_i apparaît linéairement dans $\hat{R}$: l'espérance remplace Y_i par $\pi(z_i^\top \beta_0)$. Bonus : $R(\beta) - R(\beta_0)$ est une moyenne de divergences de Kullback–Leibler entre lois de Bernoulli, donc ≥ 0 : β_0 minimise R.

Rappel — Inégalité de Hoeffding PAR CŒUR → Rappels

$X_1, \ldots, X_n$ indépendantes, $X_i \in [a_i, b_i]$ presque sûrement, $S = \sum_{i=1}^n (X_i - \mathbb{E}X_i)$. Pour tout $x > 0$:

$$\mathbb{P}(|S| \geq x) \leq 2 \exp\left(- \frac{2x^2}{\sum_{i=1}^n (b_i - a_i)^2} \right).$$

Théorème — Inégalité oracle lente du Lasso logistique (question 3) PAR CŒUR À SAVOIR REFAIRE

→ TD3

Si $\max_{i,j}|z_{ij}| \le c$ et $\lambda = A\sqrt{\frac{\log p}{n}}$ avec $A > \sqrt{2}\,c$, alors, avec probabilité au moins $1 - 2p^{1-A^2/(2c^2)}$:

$$\begin{aligned} &R(\hat\beta_L) - R(\beta_0) \\ &\quad\le \inf_{\beta\in\mathbb{R}^p}\Big\{R(\beta) - R(\beta_0) \\ &\qquad\qquad + 2A\,\|\beta\|_1\sqrt{\frac{\log p}{n}}\Big\}. \end{aligned}$$

L'idée : exactement la preuve de l'inégalité oracle lente de la séance 4 ; Hoeffding remplace la queue gaussienne et c joue le rôle de σ. La condition $A > \sqrt{2}\,c$ rend l'exposant $1 - \frac{A^2}{2c^2}$ négatif.

Preuve express

1. $$R(\hat\beta) \le R(\beta) + \sum_j (\hat\beta_j - \beta_j)V_j + \lambda\|\beta\|_1 - \lambda\left\|\hat\beta\right\|_1$$

   ↳ inégalité de base $\hat R(\hat\beta) + \lambda\left\|\hat\beta\right\|_1 \le \hat R(\beta) + \lambda\|\beta\|_1$, puis $\hat R = R - \sum_j \beta_j V_j$ (question 3a).

2. $$\mathcal{A} = \bigcap_{j=1}^{p}\Big\{|V_j| \le \frac{\lambda}{2}\Big\}$$

   ↳ l'événement qui rend le terme aléatoire petit devant la pénalité (question 3b).

3. $$\begin{aligned} &\mathbb{P}\Big(|V_j| > \frac{\lambda}{2}\Big) \\ &\quad\le 2\exp\Big(-\frac{2(n\lambda/2)^2}{nc^2}\Big) \\ &\quad= 2\exp\Big(-\frac{n\lambda^2}{2c^2}\Big) \end{aligned}$$

   ↳ Hoeffding pour $X_i = z_{ij}Y_i \in [\min(0, z_{ij}), \max(0, z_{ij})]$: $b_i - a_i = |z_{ij}| \le c$, et $\sum_i (X_i - \mathbb{E}X_i) = nV_j$.

4. $$\begin{aligned} \mathbb{P}(\mathcal{A}^c) &\le 2p\,e^{-n\lambda^2/(2c^2)} \\ &= 2p\cdot p^{-A^2/(2c^2)} \\ &= 2p^{1-A^2/(2c^2)} \end{aligned}$$

   ↳ borne de l'union sur les p variables ; $n\lambda^2 = A^2\log p$.

5. $$\begin{aligned} &\sum_j (\hat\beta_j - \beta_j)V_j \\ &\quad\le \frac{\lambda}{2}\left\|\hat\beta - \beta\right\|_1 \\ &\quad\le \frac{\lambda}{2}\left\|\hat\beta\right\|_1 + \frac{\lambda}{2}\|\beta\|_1 \end{aligned}$$

   ↳ sur $\mathcal{A}$: Hölder ($|a^\top b| \le \|a\|_\infty\|b\|_1$), puis inégalité triangulaire.

6

$$\begin{aligned} R(\hat\beta) - R(\beta_0) &\le R(\beta) - R(\beta_0) \\ &\quad + \frac{3\lambda}{2}\|\beta\|_1 - \frac{\lambda}{2}\left\|\hat\beta\right\|_1 \\ &\le R(\beta) - R(\beta_0) + 2\lambda\|\beta\|_1 \end{aligned}$$

↳ on reporte, on retranche $R(\beta_0)$, on oublie $-\frac{\lambda}{2}\left\|\hat\beta\right\|_1 \le 0$. $\mathcal{A}$ ne dépend pas de β : on prend l'infimum ; $2\lambda = 2A\sqrt{\log p/n}$.

À comprendre — Commenter le résultat (question 3d) et la remarque de l'énoncé À COMPRENDRE

→ TD3

- **Inégalité oracle** : le Lasso fait presque aussi bien que le meilleur compromis entre excès de risque et taille $\|\beta\|_1$. Avec $\beta = \beta_0$: $R(\hat\beta) - R(\beta_0) \le 2A\|\beta_0\|_1\sqrt{\log p/n}$, qui tend vers 0 si $\|\beta_0\|_1 = o\big(\sqrt{n/\log p}\big)$, même si $p \gg n$.
- **Lente** : vitesse $1/\sqrt{n}$, et dépendance en $\|\beta\|_1$ plutôt qu'en la parcimonie. **Presque sans hypothèse** : rien sur les corrélations, seulement $|z_{ij}| \le c$. Le $\log p$ vient de la borne de l'union. A grand : meilleure probabilité mais borne plus grande ; $A > \sqrt{2}\,c$ est l'analogue du $A > 2\sqrt{2}$ du théorème BRT.
- **Remarque (Kwemou, 2016, admise)** : sous RE$(s,3)$, avec $|J(\beta_0)| \le s$ et une borne sur les prédicteurs linéaires (pour garder de la courbure), on obtient la vitesse rapide $s\log p/n$. L'événement $\{|V_j| \le \lambda/2\}$ laisse une marge qui donne le cône $\left\|\delta_{J_0^c}\right\|_1 \le 3\|\delta_{J_0}\|_1$, $\delta = \hat\beta - \beta_0$, $J_0 = J(\beta_0)$: c'est le « 3 » de RE$(s,3)$.

TD3, exercice 3 — Régression de Poisson

Formules — Lasso de Poisson : critère, gradient, hessienne, convexité (questions 1 et 2)

PAR CŒUR À SAVOIR REFAIRE → TD3

$Y_i \sim \mathcal{P}(\mu_i)$ indépendantes, $\mu_i = \exp(X_i^\top\beta^*)$. À la constante $\frac{1}{n}\sum_i \log(Y_i!)$ près, $-\frac{1}{n}\ell$ vaut

$$L_n(\beta) = \frac{1}{n}\sum_{i=1}^n \Big[\exp(X_i^\top\beta) - Y_i X_i^\top\beta\Big],$$

$$\begin{aligned} \nabla L_n(\beta) &= \frac{1}{n}X^\top\big(\mu(\beta) - Y\big), \\ \nabla^2 L_n(\beta) &= \frac{1}{n}X^\top \operatorname{diag}\big(\mu_i(\beta)\big)X, \\ \mu_i(\beta) &= e^{X_i^\top\beta}. \end{aligned}$$

$v^\top\nabla^2 L_n v = \frac{1}{n}\sum_i \mu_i(X_i^\top v)^2 \ge 0$: L_n est convexe ; **strictement convexe si et seulement si** $\operatorname{rg} X = p$.

Pour la retrouver : la diapo p. 24 avec $A(\theta) = e^\theta$ et $B(y) = -\log y!$; poids $W_{ii} = A'' = \mu_i$: la variance d'une Poisson est sa moyenne.

Formules — KKT du Lasso de Poisson et plus petit λ qui annule tout (questions 3 à 5) PAR CŒUR

À SAVOIR REFAIRE → TD3

$\hat\beta$ minimise $L_n(\beta)+\lambda\|\beta\|_1 \iff \frac{1}{n}X^\top(Y-\hat\mu)\in\lambda\,\partial\left\|\hat\beta\right\|_1$, $\hat\mu_i=\exp(X_i^\top\hat\beta)$. Coordonnée par coordonnée : $\frac{1}{n}X_j^\top(Y-\hat\mu)=\lambda\operatorname{sgn}(\hat\beta_j)$ si $\hat\beta_j\neq 0$; $\left|\frac{1}{n}X_j^\top(Y-\hat\mu)\right|\le\lambda$ si $\hat\beta_j=0$.

- $\left|\frac{1}{n}X_j^\top(Y-\hat\mu)\right|<\lambda\Rightarrow\hat\beta_j=0$ (contraposée : si $\hat\beta_j\neq 0$, la KKT donne $\left|\frac{1}{n}X_j^\top(Y-\hat\mu)\right|=\lambda$) ; la **réciproque est fausse** ($\hat\beta_j=0$ autorise l'égalité, par exemple pour $\lambda=\lambda_{\max}$).
- En $\beta=0$, $\hat\mu=\mathbf{1}$: $\lambda_{\max}=\left\|\frac{1}{n}X^\top(Y-\mathbf{1})\right\|_\infty$. Exemple du TD : $(0{,}3\,;-0{,}1\,;0{,}05)$ donne $\lambda_{\max}=0{,}3$.

Piège — Comptages tous nuls

Si tous les Y_i valent 0 et que le modèle a une constante, $L_n(\beta)=\frac{1}{n}\sum_i e^{X_i^\top\beta}\to 0$ quand la constante tend vers $-\infty$: pas d'EMV (l'analogue de la séparation). Avec une pénalité sur **tous** les coefficients, le Lasso existe ; si la constante n'est pas pénalisée, il faut au moins un $Y_i>0$.

Récapitulatif : pour un GLM canonique, tout se lit sur A

Formules — Les trois modèles côte à côte PAR CŒUR → TD3

Modèle	$A(\theta)$	$L_n(\beta)$ (à une constante près)	$\nabla L_n(\beta)$	$W_{ii}=A''(x_i^\top\beta)$	$\lambda_{\max}$ (sans constante)
gaussien (variance 1)	$\theta^2/2$	$\frac{1}{2n}\|y-X\beta\|^2$	$\frac{1}{n}X^\top(X\beta-y)$	1	$\left\|\frac{1}{n}X^\top y\right\|_\infty$
logistique	$\log(1+e^\theta)$	$\frac{1}{n}\sum_i[\log(1+e^{x_i^\top\beta})-y_ix_i^\top\beta]$	$\frac{1}{n}X^\top(\sigma(X\beta)-y)$	$\mu_i(1-\mu_i)\in]0,\frac{1}{4}]$	$\left\|\frac{1}{n}X^\top(y-\frac{1}{2}\mathbf{1})\right\|_\infty$
Poisson	e^θ	$\frac{1}{n}\sum_i[e^{x_i^\top\beta}-y_ix_i^\top\beta]$	$\frac{1}{n}X^\top(e^{X\beta}-y)$	μ_i	$\left\|\frac{1}{n}X^\top(y-\mathbf{1})\right\|_\infty$

Règle unique : gradient $=\frac{1}{n}X^\top(\text{prédiction}-\text{observation})$, hessienne $=\frac{1}{n}X^\top WX$ avec les variances pour poids, $\lambda_{\max}=\|\nabla L_n(0)\|_\infty$ (en l'ajustement « constante seule » si la constante n'est pas pénalisée).

6. Les variantes du Lasso → S6

L'essentiel de la séance en 5 lignes

- Le Lasso a quatre défauts : il **biaise** les gros coefficients, garde **au plus** n variables, choisit **au hasard** parmi des variables corrélées, **ignore la structure** (groupes, ordre). Chaque variante en corrige un (l'elastic net en corrige deux).
- Bridge $\lambda\sum_j|\beta_j|^\gamma$: convexe $\Leftrightarrow\gamma\ge 1$, zéros exacts $\Leftrightarrow\gamma\le 1$; seul le Lasso ($\gamma=1$) a les deux.
- La méthode de toute la séance : en design orthonormé, le critère vaut $\sum_j(\beta_j-b_j)^2+\text{pénalité}+\text{cte}$; on résout un problème à une variable (ou à un bloc) et on obtient une règle $b\mapsto\hat\beta$.
- Débiaiser : LSLasso (seuillage dur), Lasso relaxé (rétrécissement $\delta\lambda/2$), Lasso adaptatif (retire $\lambda/(2\,|b_j|)$ au lieu de $\lambda/2$; garde $|b_j|>\sqrt{\lambda/2}$). Dantzig : $\min\|\beta\|_1$ sous la contrainte des KKT, d'où $\left\|\hat\beta^D\right\|_1\le\left\|\hat\beta^L\right\|_1$.

- Elastic net ($+\lambda_2 \|\beta\|_2^2$) : solution unique, partage égal entre colonnes identiques, Lasso divisé par $1+\lambda_2$ en orthonormé. Structure : group-Lasso (blocs gardés ou tués en entier), Lasso fusionné (paliers).

Convention de toute la section → S6

Critères **non normalisés**, comme les diapos 74–87 : $\|Y - X\beta\|^2 + \text{pénalité}$ (avec $\frac{1}{n}\|Y - X\beta\|^2$, remplacez λ par $n\lambda$). Design **orthonormé** : $X^\top X = I_p$ (donc $p \leq n$), et $b = X^\top Y = \hat{\beta}^{\text{MC}}$. Dans cette convention, le seuil du Lasso est $\lambda/2$.

Méthode — Le laboratoire orthonormé PAR CŒUR À SAVOIR REFAIRE → S6

Si $X^\top X = I_p$ et $b = X^\top Y$:

$$\|Y - X\beta\|^2 = \sum_{j=1}^{p} (\beta_j - b_j)^2 + \left(\|Y\|^2 - \|b\|^2\right),$$

et le dernier terme ne dépend pas de β.

Une pénalité séparable donne p problèmes à une variable indépendants, $\min_{\beta_j} (\beta_j - b_j)^2 + \text{pén}(\beta_j)$; une pénalité par groupes donne un problème par bloc. Brique de base (Lasso à une variable) :

$$\arg\min_{\beta_j \in \mathbb{R}} (\beta_j - b_j)^2 + \lambda |\beta_j| = \text{sgn}(b_j)\big(|b_j| - \lambda/2\big)_+.$$

Pour la retrouver : $\|Y - X\beta\|^2 = \|Y\|^2 - 2\beta^\top X^\top Y + \beta^\top X^\top X\beta = \|Y\|^2 - 2\beta^\top b + \|\beta\|^2$, puis on complète le carré.

1. Écrire le problème à une variable.
2. Cas $\beta_j > 0$, puis $\beta_j < 0$: annuler la dérivée, vérifier que la solution a bien le signe supposé.
3. Cas $\beta_j = 0$: $0 \in \partial(\text{critère})(0)$, avec $\partial|\cdot|(0) = [-1, 1]$; pour la pénalité ℓ_0, comparer directement les coûts.
4. Dessiner la règle $b \mapsto \hat{\beta}$: zone morte autour de 0 ? biais pour les grands $|b|$? continuité ?

Les quatre défauts du Lasso, et qui les corrige

Défaut du Lasso	Ce qu'on observe	Variante(s) qui corrige(nt)
1. Biais sur les gros coefficients	le seuillage doux retire $\lambda/2$ à tout coefficient gardé, même très grand	LSLasso, Lasso relaxé, Lasso adaptatif
2. Au plus n variables	si $p > n$, il garde au plus n variables, même si davantage sont pertinentes	elastic net
3. Variables corrélées	il en garde une « au hasard » ; avec une colonne dupliquée, une infinité de solutions	elastic net
4. Structure ignorée	coefficients qui vont par groupes, voisins qui devraient être égaux	group-Lasso, Lasso fusionné

Deux constructions complètent le panorama : le **bridge**, qui range ℓ0, Lasso et Ridge dans une même famille, et le **sélecteur de Dantzig**, un autre estimateur parcimonieux, très proche du Lasso (mais distinct en

général), qui se calcule par programmation linéaire.

Bridge : ℓ0, Lasso et Ridge dans une même famille

Définition — Estimateur bridge PAR CŒUR → S6

Pour $\lambda \geq 0$ et $\gamma \geq 0$:

$$C_{\lambda,\gamma}(\beta) = \|Y - X\beta\|^2 + \lambda \|\beta\|_\gamma^\gamma,$$

$$\|\beta\|_\gamma^\gamma = \begin{cases} \sum_{j=1}^p |\beta_j|^\gamma & \text{si } \gamma > 0, \\ \sum_{j=1}^p \mathbf{1}\{\beta_j \neq 0\} & \text{si } \gamma = 0, \end{cases}$$

$$\hat{\beta}^{\text{Bridge}}(\lambda, \gamma) = \arg\min_{\beta \in \mathbb{R}^p} C_{\lambda,\gamma}(\beta).$$

Trois cas ($\lambda > 0$) : $\gamma = 0$ sélection de modèle (ℓ0 : Cp, AIC, BIC) ; $\gamma = 1$ Lasso ; $\gamma = 2$ Ridge.

Pour la retrouver : on remplace $|\beta_j|$ par $|\beta_j|^\gamma$. Le cas $\gamma = 0$ est la limite naturelle : $|u|^\gamma \to 1$ quand $\gamma \to 0$ si $u \neq 0$, alors que $|0|^\gamma = 0$.

Formules — Bridge en design orthonormé pour $\gamma = 2, 1, 0$ PAR CŒUR À SAVOIR REFAIRE → S6

$$\begin{aligned} \gamma = 2 \text{ (Ridge)} : &\quad \hat{\beta}_j = \frac{b_j}{1+\lambda} \\ \gamma = 1 \text{ (Lasso)} : &\quad \hat{\beta}_j = \operatorname{sgn}(b_j)\big(|b_j| - \lambda/2\big)_+ \\ \gamma = 0 \ (\ell_0) : &\quad \hat{\beta}_j = b_j \, \mathbf{1}\{|b_j| > \sqrt{\lambda}\} \end{aligned}$$

Ridge : tout est rétréci, rien n'est nul. Lasso : *seuillage doux* (zéros + décalage de $\lambda/2$). ℓ0 : *seuillage dur* (on garde tel quel ou on tue).

Pour la retrouver : Ridge, dériver ; Lasso, trois cas de signe ; ℓ0, comparer deux coûts : $\beta_j = b_j$ coûte λ, $\beta_j = 0$ coûte b_j^2, on garde ssi $b_j^2 > \lambda$.

Preuve express

1. $$2(\beta_j - b_j) + 2\lambda\beta_j = 0 \iff \beta_j = \frac{b_j}{1+\lambda}$$

   ↳ $\gamma = 2$: critère dérivable et strictement convexe en β_j, on annule la dérivée.

2. $$2(\beta_j - b_j) + \lambda = 0 \iff \beta_j = b_j - \lambda/2$$

   ↳ $\gamma = 1$, cas $\beta_j > 0$: sur $]0, +\infty[$, $|\beta_j| = \beta_j$ est dérivable ; cohérent ssi $b_j > \lambda/2$. Le cas $\beta_j < 0$ donne de même $b_j + \lambda/2$ si $b_j < -\lambda/2$.

3. $$0 \in -2b_j + \lambda[-1, 1] \iff |b_j| \leq \lambda/2$$

   ↳ $\gamma = 1$, cas $\beta_j = 0$: condition $0 \in \partial(\text{critère})(0)$ avec $\partial\,|\cdot|\,(0) = [-1, 1]$. Les trois cas se résument en $\operatorname{sgn}(b_j)(|b_j| - \lambda/2)_+$.

4

$$\min\Big(\underbrace{\lambda}_{\beta_j=b_j},\ \underbrace{b_j^2}_{\beta_j=0}\Big) \Rightarrow \hat{\beta}_j = b_j\,\mathbf{1}\{b_j^2 > \lambda\}$$

↳ $\gamma = 0$: si $\beta_j \neq 0$, la pénalité vaut λ quel que soit β_j, donc le meilleur choix est $\beta_j = b_j$ (ajustement nul) ; sinon on paie b_j^2.

Proposition — Convexité du bridge

PAR CŒUR · À SAVOIR REFAIRE · → S6

Pour $\gamma \geq 1$, $\beta \mapsto \|\beta\|_\gamma^\gamma$ est convexe (strictement si $\gamma > 1$), donc $C_{\lambda,\gamma}$ est convexe. Pour $0 \leq \gamma < 1$: la boule $\{\|\beta\|_\gamma^\gamma \leq 1\}$ n'est pas convexe ($p \geq 2$), et $C_{\lambda,\gamma}$ n'est pas convexe ($\lambda > 0$). La région de contrainte est convexe **si et seulement si** $\gamma \geq 1$ (diapo 76).

Zéros exacts ⇔ $\gamma \leq 1$ (pointe en 0). Seul $\gamma = 1$ est à la fois convexe et créateur de zéros.

L'idée : $\gamma \geq 1$: $t \mapsto t^\gamma$ est convexe et croissante sur $[0, \infty[$, composée avec $|\cdot|$. $\gamma < 1$: e_1 et e_2 sont dans la boule, pas leur milieu, car $2 \cdot 2^{-\gamma} = 2^{1-\gamma} > 1$.

Preuve express

1

$$\begin{aligned}|\theta u + (1-\theta)v|^\gamma &\leq \big(\theta\,|u| + (1-\theta)\,|v|\big)^\gamma \\ &\leq \theta\,|u|^\gamma + (1-\theta)\,|v|^\gamma\end{aligned}$$

↳ $\gamma \geq 1$: inégalité triangulaire et croissance de t^γ, puis convexité de t^γ sur $[0, \infty[$ (dérivée seconde $\gamma(\gamma-1)t^{\gamma-2} \geq 0$). Une somme de convexes est convexe, et $\|Y - X\beta\|^2$ est convexe.

2

$$\left\|\tfrac{e_1+e_2}{2}\right\|_\gamma^\gamma = 2\big(\tfrac{1}{2}\big)^\gamma = 2^{1-\gamma} > 1$$

↳ $0 < \gamma < 1$: e_1 et e_2 sont dans la boule ($\|e_1\|_\gamma^\gamma = \|e_2\|_\gamma^\gamma = 1$), pas leur milieu : boule non convexe (exemple : $\gamma = 0{,}5$ donne $\sqrt{2} \approx 1{,}41$). Pour $\gamma = 0$: la « norme » du milieu vaut 2.

3

$$\varphi''(t) = 2\,\|X_1\|^2 + \lambda\gamma(\gamma-1)t^{\gamma-2} \xrightarrow[t\to 0^+]{} -\infty$$

↳ $\varphi(t) = C_{\lambda,\gamma}(\beta + te_1)$ avec $\beta_1 = 0$ et $0 < \gamma < 1$: φ est concave près de 0^+, donc le critère n'est pas convexe sur cette droite, donc pas convexe (pour $\gamma = 0$, le milieu est au-dessus de la corde).

À comprendre — Pourquoi la pointe en 0 crée des zéros

À COMPRENDRE · → S6

Un coefficient posé en 0 a-t-il intérêt à bouger ? L'ajustement gagne, au premier ordre, une quantité proportionnelle au déplacement $|\beta_j|$; la pénalité coûte $\lambda\,|\beta_j|^\gamma$. Si $\gamma \leq 1$, ce coût est au moins du même ordre ($|\beta_j|^\gamma \geq |\beta_j|$ près de 0) : quand le gain est faible, rester à 0 est optimal. Si $\gamma > 1$, la pénalité a une dérivée nulle en 0 : rester à 0 exigerait $X_j^\top(Y - X\hat{\beta}) = 0$ exactement, un événement de probabilité nulle.

Les énoncés de la diapo 75, un par un PAR CŒUR → S6

Cas	Énoncé	Pourquoi
$\gamma = 0$	l'estimateur existe si X est injective	2^p problèmes de moindres carrés restreints à comparer ; l'injectivité rend chacun unique (en fait un minimiseur existe toujours)
$\gamma > 0$	l'estimateur existe	critère continu et coercif : la pénalité explose quand $\|\beta\| \to \infty$
$0 \leq \gamma < 1$	$C_{\lambda,\gamma}$ n'est pas convexe, peut être très dur à minimiser en grande dimension	minima locaux ; la proposition ci-dessus
$\gamma = 1$	$C_{\lambda,1}$ convexe ; un unique minimiseur si X est injective	X injective $\Leftrightarrow \operatorname{rg} X = p \Rightarrow$ hessienne $2X^\top X \succ 0$, ajustement strictement convexe (sinon, voir la colonne dupliquée)
$\gamma > 1$	strictement convexe, unique minimiseur ; presque sûrement toutes les coordonnées sont non nulles	t^γ strictement convexe ; pénalité de dérivée nulle en 0
contrainte	$\hat\beta^{\text{Bridge}}(\lambda,\gamma) = \arg\min_{\{\beta:\ \|\beta\|_\gamma^\gamma \leq t\}} \|Y - X\beta\|^2$ pour un t associé à λ	Lagrange ; garanti pour $\gamma \geq 1$ (cas convexe)

Piège — « norme » ℓγ pour $\gamma < 1$

Pour $\gamma < 1$, $\|\beta\|_\gamma = (\sum_j |\beta_j|^\gamma)^{1/\gamma}$ **n'est pas une norme** (l'inégalité triangulaire échoue, c'est la non-convexité), et $\|\beta\|_0$ non plus (pas homogène). Le mot est un abus de langage.

En dimension 2 : les ellipses et le premier contact

Identité — L'ajustement autour des moindres carrés PAR CŒUR À SAVOIR REFAIRE → S6

$$\|Y - X\beta\|^2 = (\beta - \hat\beta^{\text{MC}})^\top X^\top X(\beta - \hat\beta^{\text{MC}}) + \left\|Y - X\hat\beta^{\text{MC}}\right\|^2$$

Le problème contraint $\arg\min_{\|\beta\|_\gamma^\gamma \leq t} \|Y - X\beta\|^2$ revient donc à minimiser $(\beta - \hat\beta^{\text{MC}})^\top X^\top X(\beta - \hat\beta^{\text{MC}})$ sur la région de contrainte.

L'idée : Pythagore. On écrit $Y - X\beta = \hat r + X(\hat\beta^{\text{MC}} - \beta)$ avec $\hat r = Y - X\hat\beta^{\text{MC}}$; les équations normales donnent $X^\top \hat r = 0$, ce qui tue le terme croisé.

Preuve express

1. $$\|Y - X\beta\|^2 = \|\hat r\|^2 + 2\,\hat r^\top X(\hat\beta^{\text{MC}} - \beta) + \left\|X(\hat\beta^{\text{MC}} - \beta)\right\|^2$$
   ↳ $Y - X\beta = \hat r + X(\hat\beta^{\text{MC}} - \beta)$ et $\|u+v\|^2 = \|u\|^2 + 2u^\top v + \|v\|^2$.

2 $$\hat{r}^\top X(\hat{\beta}^{\mathrm{MC}} - \beta) = (X^\top \hat{r})^\top (\hat{\beta}^{\mathrm{MC}} - \beta) = 0$$

↳ équations normales : $X^\top X \hat{\beta}^{\mathrm{MC}} = X^\top Y$, soit $X^\top \hat{r} = 0$.

3 $$\left\| X(\hat{\beta}^{\mathrm{MC}} - \beta) \right\|^2 = (\beta - \hat{\beta}^{\mathrm{MC}})^\top X^\top X (\beta - \hat{\beta}^{\mathrm{MC}})$$

↳ $\|Xv\|^2 = v^\top X^\top X v$.

À comprendre — Pourquoi le losange donne des zéros, et pas le disque À COMPRENDRE → S6

Les lignes de niveau de l'ajustement sont des **ellipses centrées en** $\hat{\beta}^{\mathrm{MC}}$ (axes : vecteurs propres de $X^\top X$; demi-axes $\sqrt{c/\mu_k}$). L'estimateur contraint est le **premier point de contact** entre une ellipse qu'on gonfle et la région permise. Le losange $\ell 1$ a des **coins sur les axes** : le contact s'y produit pour toute une plage de positions de $\hat{\beta}^{\mathrm{MC}}$ (en un coin, le cône normal est un secteur de 90°), d'où une coordonnée exactement nulle. Le disque $\ell 2$ n'a pas de coin : toucher un axe est un accident. Le Lasso ne garde pas forcément les plus gros $\hat{\beta}_j^{\mathrm{MC}}$: avec $X^\top X = \begin{pmatrix} 4 & 1{,}4 \\ 1{,}4 & 1 \end{pmatrix}$, $t = 1$ (diapo 77) et $\hat{\beta}^{\mathrm{MC}} = (2, 3)$ (figure de la diapo 78), le Lasso vaut $(1, 0)$ et le Ridge environ $(0{,}89;\ 0{,}46)$.

LSLasso : Lasso, puis moindres carrés

À comprendre — D'où vient le biais du Lasso À COMPRENDRE → S6

En design orthonormé, $b_j = \beta_j^* + X_j^\top \varepsilon \sim \mathcal{N}(\beta_j^*, \sigma^2)$ est sans biais. Pour un gros β_j^*, le Lasso renvoie $b_j - \lambda/2$: un **biais systématique de** $\lambda/2$ sur un coefficient dont la non-nullité ne fait aucun doute. Le même λ sert à *sélectionner* (il le faut assez grand pour tuer le bruit) et à *estimer* (il le faudrait petit pour ne pas biaiser).

Définition — LSLasso (*Least Squares Lasso*) PAR CŒUR → S6

1. Lasso : on obtient $\hat{\beta}^L(\lambda)$.
2. Moindres carrés sur les covariables actives :

$$\hat{\beta}^{\mathrm{LSLasso}}(\lambda) = \underset{\beta \in \mathbb{R}^p :\, \mathrm{supp}(\beta) = \mathrm{supp}(\hat{\beta}^L(\lambda))}{\arg\min} \ \tfrac{1}{2} \|Y - X\beta\|_2^2 .$$

La validation croisée doit porter sur **toute la procédure** (implémenté dans `glmnet`, `relax=TRUE`).

Pour la retrouver : le Lasso *choisit* les variables, les moindres carrés les *estiment* sans rétrécissement. Limite : une variable oubliée à l'étape 1 reste oubliée.

Formule — LSLasso en design orthonormé PAR CŒUR À SAVOIR REFAIRE → S6

$$\hat{\beta}_j^{\mathrm{LSLasso}} = b_j \, \mathbf{1}\{|b_j| > \lambda/2\}$$

C'est le seuillage dur au seuil $\lambda/2$.

Pour la retrouver : l'étape 1 garde $\{j : |b_j| > \lambda/2\}$; l'étape 2 se découple, et chaque $(\beta_j - b_j)^2$ est minimal en $\beta_j = b_j$. C'est la même règle que la sélection $\ell 0$ de paramètre $\lambda' = \lambda^2/4$ (seuil $\sqrt{\lambda'} = \lambda/2$) : en orthonormé, le LSLasso résout le problème combinatoire sans explorer les 2^p modèles.

Preuve express

1. $$\hat{S} := \operatorname{supp}(\hat{\beta}^L) = \{j : |b_j| > \lambda/2\}$$

   ↳ seuillage doux : la coordonnée est non nulle exactement quand $|b_j|$ dépasse le seuil.

2. $$\min_{\beta:\, \beta_j = 0 \ \forall j \notin \hat{S}} \|Y - X\beta\|^2 = \min \sum_{j \in \hat{S}} (\beta_j - b_j)^2 + \text{cte}$$

   ↳ découplage orthonormé, avec $\beta_j = 0$ imposé hors de $\hat{S}$.

3. $$\hat{\beta}_j^{\text{LSLasso}} = b_j \ (j \in \hat{S}), \qquad 0 \ (j \notin \hat{S})$$

   ↳ chaque terme est minimal en $\beta_j = b_j$: plus aucun rétrécissement.

Piège — Régler λ pour le Lasso seul, puis réajuster → S6

La validation croisée du Lasso seul choisit plutôt un **petit** λ (pour moins rétrécir les bons coefficients), quitte à laisser entrer du bruit avec des coefficients minuscules ; le réajustement donne alors à ce bruit un coefficient **plein** : surapprentissage. Pour chaque λ candidat, calculez tout l'estimateur en deux étapes sur les plis d'apprentissage, et mesurez son erreur sur le pli de validation.

Le sélecteur de Dantzig

Définition — Sélecteur de Dantzig (Candès et Tao, 2007) PAR CŒUR → S6

$$D_\lambda = \left\{\beta \in \mathbb{R}^p : \ \left\|2X^\top (Y - X\beta)\right\|_\infty \leq \lambda\right\} \ \text{(convexe)},$$

$$\hat{\beta}^D(\lambda) = \arg\min_{\beta \in D_\lambda} \|\beta\|_1 .$$

Pour la retrouver : D_λ, c'est l'inégalité des KKT du Lasso imposée à toutes les variables : aucune variable n'est trop corrélée au résidu. Lasso : « bien ajuster en payant la taille » ; Dantzig : « être le plus petit possible en ajustant assez bien ».

Proposition — Dantzig contre Lasso PAR CŒUR À SAVOIR REFAIRE → S6

$\left\|\hat{\beta}^D(\lambda)\right\|_1 \leq \left\|\hat{\beta}^L(\lambda)\right\|_1$. Les performances numériques et théoriques des deux estimateurs sont très proches ; dans certains cas ils coïncident (par exemple en design orthonormé).

L'idée : les KKT disent $\hat{\beta}^L \in D_\lambda$, et $\hat{\beta}^D$ minimise $\|\cdot\|_1$ sur D_λ.

Preuve express

1. $$\left|2X_j^\top (Y - X\hat{\beta}^L)\right| = \lambda \quad \text{si } \hat{\beta}_j^L \neq 0,$$
   $$\left|2X_j^\top (Y - X\hat{\beta}^L)\right| \leq \lambda \quad \text{si } \hat{\beta}_j^L = 0$$

   ↳ conditions KKT du Lasso, critère $\|Y - X\beta\|^2 + \lambda \|\beta\|_1$.

2 $$\left\|2X^\top(Y - X\hat\beta^L)\right\|_\infty \le \lambda, \text{ i.e. } \hat\beta^L \in D_\lambda$$

↳ chaque coordonnée est au plus λ en valeur absolue.

3 $$\left\|\hat\beta^D\right\|_1 = \min_{\beta \in D_\lambda} \|\beta\|_1 \le \left\|\hat\beta^L\right\|_1$$

↳ un minimum sur un ensemble est inférieur à la valeur en n'importe quel point de cet ensemble.

Méthode — Écrire Dantzig comme un programme linéaire À SAVOIR REFAIRE → S6

On sépare parties positive et négative : $\beta = \beta^+ - \beta^-$, $\beta^\pm \ge 0$, et $|\beta_j| = \beta_j^+ + \beta_j^-$ à l'optimum.

$$\begin{aligned} &\min_{\beta^+, \beta^- \ge 0} \sum_{j=1}^{p} (\beta_j^+ + \beta_j^-) \\ &\text{s.c.} \quad -\lambda \le 2X_j^\top \left(Y - X\beta^+ + X\beta^-\right) \le \lambda, \quad j = 1, \dots, p. \end{aligned}$$

Objectif et contraintes linéaires : $2p$ inconnues positives, $2p$ inégalités. Le Lasso, lui, est un programme *quadratique*.

Proposition — Le sélecteur de Dantzig en design orthonormé PAR CŒUR À SAVOIR REFAIRE → S6

$$D_\lambda = \left\{\beta : \ |\beta_j - b_j| \le \lambda/2 \ \ \forall j\right\}$$

$$\hat\beta_j^D = \operatorname{sgn}(b_j)\big(|b_j| - \lambda/2\big)_+ = \hat\beta_j^L.$$

L'idée : $2X^\top(Y - X\beta) = 2(b - \beta)$: la contrainte devient une boîte, et l'on minimise chaque $|\beta_j|$ sur son intervalle.

Preuve express

1 $$2X^\top(Y - X\beta) = 2(X^\top Y - X^\top X\beta) = 2(b - \beta)$$

↳ $X^\top Y = b$ et $X^\top X = I_p$.

2 $$\|2(b - \beta)\|_\infty \le \lambda \iff \beta_j \in \left[b_j - \lambda/2, \ b_j + \lambda/2\right] \text{ pour tout } j$$

↳ on divise par 2 : D_λ est une boîte.

3 $$\min_{\beta \in D_\lambda} \sum_j |\beta_j| = \sum_j \min_{|\beta_j - b_j| \le \lambda/2} |\beta_j|$$

↳ objectif et contrainte se découplent : chaque β_j se choisit séparément.

4 $$\hat\beta_j^D = \begin{cases} 0 & \text{si } |b_j| \le \lambda/2, \\ b_j - \operatorname{sgn}(b_j)\,\lambda/2 & \text{sinon} \end{cases}$$

↳ on prend 0 s'il est dans l'intervalle, sinon l'extrémité la plus proche de 0 : c'est $\operatorname{sgn}(b_j)(|b_j| - \lambda/2)_+$, le Lasso.

Le Lasso adaptatif

Définition — Lasso adaptatif (Zou, 2006) PAR CŒUR → S6

$$\hat{\beta}^{\text{AdapL}}(\lambda) = \underset{\beta \in \mathbb{R}^p}{\arg\min} \left\{ \|Y - X\beta\|^2 + \lambda \sum_{j=1}^{p} \omega_j \, |\beta_j| \right\},$$

avec $\omega_j = 1/\left|\tilde{\beta}_j\right|$, où $\tilde{\beta}$ est un estimateur préliminaire ; choix usuel si p n'est pas trop grand : $\omega_j = 1/\left|\hat{\beta}_j^{\text{ols}}\right|$ (moindres carrés).

Pour la retrouver : on fait confiance aux gros. $\left|\tilde{\beta}_j\right|$ grand ⇒ poids petit ⇒ peu pénalisé, donc peu biaisé ; $\left|\tilde{\beta}_j\right|$ petit ⇒ poids énorme ⇒ tué.

Formule — Lasso adaptatif en design orthonormé, avec $\tilde{\beta} = b$ PAR CŒUR À SAVOIR REFAIRE → S6

$$\hat{\beta}_j^{\text{AdapL}} = \text{sgn}(b_j)\Big(|b_j| - \frac{\lambda}{2\,|b_j|} \Big)_+$$

Coordonnée gardée ssi $|b_j| > \sqrt{\lambda/2}$; biais d'une coordonnée gardée : $\dfrac{\lambda}{2\,|b_j|}$, qui tend vers 0 quand $|b_j| \to \infty$ (contre $\lambda/2$ pour le Lasso).

L'idée : c'est un Lasso à une variable de paramètre $\lambda\omega_j$, donc un seuillage doux au seuil $\lambda\omega_j/2 = \lambda/(2\,|b_j|)$. Intermédiaire entre seuillage doux (près du seuil) et seuillage dur (grands b_j).

Preuve express

1. $$\min_{\beta_j} (\beta_j - b_j)^2 + \lambda\omega_j \, |\beta_j|$$

   ↳ découplage orthonormé : la pénalité pondérée reste séparable.

2. $$\begin{aligned} \hat{\beta}_j &= \text{sgn}(b_j)\Big(|b_j| - \frac{\lambda\omega_j}{2} \Big)_+ \\ &= \text{sgn}(b_j)\Big(|b_j| - \frac{\lambda}{2\,|b_j|} \Big)_+ \end{aligned}$$

   ↳ seuillage doux avec $\lambda\omega_j$ à la place de λ, puis $\omega_j = 1/\,|b_j|$.

3. $$\hat{\beta}_j \neq 0 \iff |b_j| > \frac{\lambda}{2\,|b_j|} \iff |b_j|^2 > \frac{\lambda}{2}$$

   ↳ on multiplie par $|b_j| > 0$.

4. $$|b_j| - \left|\hat{\beta}_j\right| = \frac{\lambda}{2\,|b_j|}$$

   ↳ pour une coordonnée gardée ; à comparer au biais constant $\lambda/2$ du Lasso.

Méthode — Calculer un Lasso adaptatif avec un logiciel de Lasso À SAVOIR REFAIRE → S6

Poser $\gamma_j = \omega_j \beta_j$ et $\tilde{X}_j = X_j / \omega_j$. Alors $X\beta = \sum_j (\omega_j \beta_j) \frac{X_j}{\omega_j} = \tilde{X}\gamma$ et $\sum_j \omega_j |\beta_j| = \|\gamma\|_1$, donc

$$\|Y - X\beta\|^2 + \lambda \sum_j \omega_j |\beta_j| = \left\|Y - \tilde{X}\gamma\right\|^2 + \lambda \|\gamma\|_1 .$$

On résout ce Lasso standard en γ, puis $\hat{\beta}_j = \hat{\gamma}_j / \omega_j$.

Remarque : si $\tilde{\beta}_j = 0$, le poids est infini, la colonne $\tilde{X}_j$ est nulle : la variable est exclue d'office.

Le Lasso relaxé

Définition — Lasso relaxé (Meinshausen, 2007) PAR CŒUR → S6

1. Calculer $\hat{\beta}^L(\lambda) = \arg\min_\beta \{\|Y - X\beta\|^2 + \lambda \|\beta\|_1\}$ et poser $\hat{S}_\lambda = \{j : \hat{\beta}^L_j(\lambda) \neq 0\}$.
2. Pour $\delta \in [0, 1]$:

$$\hat{\beta}^{\text{relaxedL}}(\lambda, \delta) = \underset{\beta \in \mathbb{R}^p,\, J(\beta) \subset \hat{S}_\lambda}{\arg\min} \left\{ \|Y - X\beta\|^2 + \delta\lambda \|\beta\|_1 \right\}.$$

$\delta = 1$ redonne le Lasso (s'il est unique) ; $\delta = 0$ redonne le LSLasso (valeur couramment utilisée).

Pour la retrouver : deux paramètres pour deux rôles : λ *choisit* les variables, $\delta\lambda \leq \lambda$ règle combien on les *rétrécit*.

Formule — Lasso relaxé en design orthonormé PAR CŒUR À SAVOIR REFAIRE → S6

$$\hat{\beta}^{\text{relaxedL}}_j(\lambda, \delta) = \begin{cases} X_j^\top Y - \dfrac{\delta\lambda}{2} & \text{si } X_j^\top Y \geq \dfrac{\lambda}{2}, \\ 0 & \text{si } -\dfrac{\lambda}{2} \leq X_j^\top Y \leq \dfrac{\lambda}{2}, \\ X_j^\top Y + \dfrac{\delta\lambda}{2} & \text{si } X_j^\top Y \leq -\dfrac{\lambda}{2}, \end{cases}$$

soit, avec $b_j = X_j^\top Y$: $\hat{\beta}_j = \mathbf{1}\{|b_j| > \lambda/2\}\big(b_j - \operatorname{sgn}(b_j)\, \delta\lambda/2\big)$.

L'idée : seuil $\lambda/2$ (sélection de l'étape 1), puis rétrécissement réduit à $\delta\lambda/2$. Lasso, LSLasso et relaxé ont la **même zone morte** $[-\lambda/2, \lambda/2]$: mêmes variables, seule l'amplitude change.

Preuve express

1. $$\hat{S}_\lambda = \{j : |b_j| > \lambda/2\}, \qquad j \notin \hat{S}_\lambda \Rightarrow \hat{\beta}_j = 0$$

   ↳ étape 1 = seuillage doux au seuil $\lambda/2$; puis contrainte $J(\beta) \subset \hat{S}_\lambda$.

2. $$\hat{\beta}_j = \arg\min_{\beta_j} (\beta_j - b_j)^2 + \delta\lambda |\beta_j|$$
   $$= \operatorname{sgn}(b_j) \Big(|b_j| - \frac{\delta\lambda}{2} \Big)_+$$

   ↳ pour $j \in \hat{S}_\lambda$: découplage orthonormé, seuillage doux au seuil $\delta\lambda/2$.

3

$$= b_j - \operatorname{sgn}(b_j)\frac{\delta\lambda}{2}$$

↳ $|b_j| > \lambda/2 \geq \delta\lambda/2$ car $\delta \leq 1$: la partie positive est inutile. Aux points frontières $|b_j| = \lambda/2$ près (sans importance), c'est la formule de la diapo 83.

L'elastic net

Proposition — Deux défauts du Lasso (diapo 84) PAR CŒUR À SAVOIR REFAIRE → S6

1. Si $p > n$, le Lasso sélectionne **au plus n variables** avant de saturer.
2. **Colonne dupliquée** : soit $\tilde{X} = [X, X_p] \in \mathbb{R}^{n\times(p+1)}$. Si $\hat{\beta}^L_p(\lambda) \neq 0$, alors pour tout $\alpha \in [0,1]$,

$$\tilde{\beta}(\lambda) = \left(\hat{\beta}^L_1(\lambda), \ldots, \hat{\beta}^L_{p-1}(\lambda),\ \alpha\,\hat{\beta}^L_p(\lambda),\ (1-\alpha)\,\hat{\beta}^L_p(\lambda)\right)$$

est solution de $\arg\min_{\beta\in\mathbb{R}^{p+1}}\left\{\left\|Y - \tilde{X}\beta\right\|^2 + \lambda\|\beta\|_1\right\}$: une **infinité de solutions**.

L'idée (point 2) : répartir $\hat{\beta}^L_p$ entre les deux copies ne change ni l'ajustement (même colonne) ni la norme ℓ1 (morceaux de même signe), et l'on ne peut pas faire mieux avec $\tilde{X}$ qu'avec X (inégalité triangulaire).

Sur la diapo 84, « $\tilde{X} \in \mathbb{R}^{n\times p}$ » est une coquille : $\tilde{X}$ a $p+1$ colonnes.

Preuve express (colonne dupliquée)

Notons C et $\tilde{C}$ les critères du Lasso avec X et avec $\tilde{X}$, et $m(\gamma) = (\gamma_1, \ldots, \gamma_{p-1}, \gamma_p + \gamma_{p+1}) \in \mathbb{R}^p$ pour $\gamma \in \mathbb{R}^{p+1}$.

1

$$\tilde{X}\gamma = X\,m(\gamma)$$

↳ les colonnes p et $p+1$ de $\tilde{X}$ valent toutes deux X_p.

2

$$\|\gamma\|_1 \geq \|m(\gamma)\|_1$$

↳ inégalité triangulaire $|\gamma_p| + |\gamma_{p+1}| \geq |\gamma_p + \gamma_{p+1}|$.

3

$$\tilde{C}(\gamma) \geq C(m(\gamma)) \geq C(\hat{\beta}^L) \quad \text{pour tout } \gamma$$

↳ lignes 1 et 2, puis minimalité de $\hat{\beta}^L$.

4

$$m(\tilde{\beta}) = \hat{\beta}^L \ \text{ et } \ \left\|\tilde{\beta}\right\|_1 = \left\|\hat{\beta}^L\right\|_1$$
$$\Longrightarrow\ \tilde{C}(\tilde{\beta}) = C(\hat{\beta}^L) = \min \tilde{C}$$

↳ $\alpha\hat{\beta}^L_p$ et $(1-\alpha)\hat{\beta}^L_p$ ont le même signe : l'inégalité triangulaire est une égalité.

À comprendre — Pourquoi « au plus n variables » À COMPRENDRE → S6

Il existe toujours une solution du Lasso dont les colonnes actives sont **linéairement indépendantes**, donc avec au plus $\operatorname{rg} X \leq n$ coefficients non nuls. Idée : si les colonnes actives sont liées, il existe $v \neq 0$, nul hors du support, avec $Xv = 0$; le long de v l'ajustement ne bouge pas et la pénalité ℓ1 varie linéairement,

donc (minimalité) reste constante ; on avance jusqu'à annuler une coordonnée active, et on recommence. (Preuve hors diapos ; la diapo énonce le fait.)

Définition — Elastic net (Zou et Hastie, 2005) PAR CŒUR → S6

Pour $\lambda_1 > 0$ et $\lambda_2 > 0$:

$$\hat{\beta}^{e.n}(\lambda_1, \lambda_2) = \underset{\beta \in \mathbb{R}^p}{\arg\min} \left\{ \|Y - X\beta\|^2 + \lambda_1 \|\beta\|_1 + \lambda_2 \|\beta\|_2^2 \right\}.$$

Le critère est **strictement convexe** : un unique minimiseur, sans aucune hypothèse sur X. Version améliorée : $(1+\lambda_2)\,\hat{\beta}^{e.n}(\lambda_1, \lambda_2)$.

Pour la retrouver : Lasso + un peu de Ridge, **au carré**. C'est le carré qui donne la stricte convexité (hessienne $2\lambda_2 I_p \succ 0$; convexe + strictement convexe = strictement convexe) ; sans carré, ce serait un group-Lasso à un seul groupe. Existence : critère continu et coercif.

Formule — Elastic net en design orthonormé PAR CŒUR À SAVOIR REFAIRE → S6

$$\hat{\beta}_j^{e.n} = \frac{\operatorname{sgn}(b_j)\big(|b_j| - \lambda_1/2\big)_+}{1+\lambda_2} = \frac{\hat{\beta}_j^{L}(\lambda_1)}{1+\lambda_2}$$

et la version corrigée vaut $(1+\lambda_2)\,\hat{\beta}_j^{e.n} = \hat{\beta}_j^{L}(\lambda_1)$: le Lasso.

L'idée : double rétrécissement, d'abord un seuillage doux (Lasso), puis une division par $1+\lambda_2$ (Ridge). D'où la correction $\times(1+\lambda_2)$, qui redonne exactement le Lasso quand les variables sont orthogonales : l'elastic net ne change quelque chose que dans le cas **corrélé**.

Preuve express

1. $$\begin{aligned}&(\beta - b)^2 + \lambda_1 |\beta| + \lambda_2 \beta^2 \\ &= (1+\lambda_2)\beta^2 - 2b\beta + \lambda_1 |\beta| + b^2\end{aligned}$$

   ↳ on développe $(\beta - b)^2$ et on regroupe les β^2 (indice j omis).

2. $$= (1+\lambda_2)\left[\left(\beta - \frac{b}{1+\lambda_2}\right)^2 + \frac{\lambda_1}{1+\lambda_2}|\beta|\right] + \text{cte}$$

   ↳ on factorise par $1+\lambda_2 > 0$ et on complète le carré.

3. $$\begin{aligned}\hat{\beta} &= \operatorname{sgn}(b)\left(\frac{|b|}{1+\lambda_2} - \frac{\lambda_1}{2(1+\lambda_2)}\right)_+ \\ &= \frac{\operatorname{sgn}(b)\big(|b| - \lambda_1/2\big)_+}{1+\lambda_2}\end{aligned}$$

   ↳ le crochet est un Lasso à une variable de cible $b/(1+\lambda_2)$ et de paramètre $\lambda_1/(1+\lambda_2)$: seuillage doux, puis mise en facteur.

Proposition — Elastic net avec deux colonnes identiques PAR CŒUR À SAVOIR REFAIRE → S6

Si les colonnes X_p et X_{p+1} sont identiques, la solution (unique) de l'elastic net vérifie $\hat{\beta}_p^{e.n} = \hat{\beta}_{p+1}^{e.n}$.

L'idée : remplacer $(\hat\beta_p, \hat\beta_{p+1})$ par $(c/2, c/2)$, où $c = \hat\beta_p + \hat\beta_{p+1}$: même ajustement, norme $\ell 1$ pas plus grande, et partie ℓ_2^2 strictement plus petite si $\hat\beta_p \neq \hat\beta_{p+1}$.

Preuve express

1. $$\hat\beta_p X_p + \hat\beta_{p+1} X_p = c X_p = \tfrac{c}{2} X_p + \tfrac{c}{2} X_p$$
   ↳ les deux colonnes sont égales : l'ajustement ne change pas.

2. $$|c/2| + |c/2| = |c| \leq \left|\hat\beta_p\right| + \left|\hat\beta_{p+1}\right|$$
   ↳ inégalité triangulaire : la partie $\ell 1$ ne peut que diminuer.

3. $$\left(\tfrac{c}{2}\right)^2 + \left(\tfrac{c}{2}\right)^2 = \tfrac{c^2}{2} \leq \hat\beta_p^2 + \hat\beta_{p+1}^2$$
   ↳ $a^2 + (c-a)^2 = 2(a - c/2)^2 + c^2/2$ est minimal uniquement en $a = c/2$: égalité ssi $\hat\beta_p = \hat\beta_{p+1}$.

4. Si $\hat\beta_p \neq \hat\beta_{p+1}$, le vecteur modifié a un critère strictement plus petit.
   ↳ impossible pour le minimiseur : donc $\hat\beta_p = \hat\beta_{p+1}$.

À comprendre — Ce que l'elastic net change À COMPRENDRE → S6

Face à des variables très corrélées, le Lasso en garde une **arbitrairement** (et change d'avis à la moindre perturbation des données) ; l'elastic net les fait entrer et sortir **ensemble**, avec des coefficients proches (« effet de groupe »). Il peut aussi garder plus de n variables : c'est un Lasso sur les données augmentées $Y^* = \begin{pmatrix} Y \\ 0_p \end{pmatrix}$, $X^* = (1+\lambda_2)^{-1/2} \begin{pmatrix} X \\ \sqrt{\lambda_2} I_p \end{pmatrix}$, de rang p (exercice 8 de la séance, hors diapos).

Le Lasso fusionné

Définition — Lasso fusionné (Tibshirani, Saunders, Rosset, Zhu et Knight, 2005) PAR CŒUR → S6

Pour $\lambda_1 > 0$ et $\lambda_2 > 0$:

$$\hat\beta^{\text{fused}}(\lambda_1, \lambda_2) = \underset{\beta \in \mathbb{R}^p}{\arg\min} \Big\{ \|Y - X\beta\|^2 + \lambda_1 \sum_{j=1}^{p} |\beta_j| + \lambda_2 \sum_{j=2}^{p} |\beta_j - \beta_{j-1}| \Big\}.$$

Premier terme : la pénalité du Lasso. Second : il encourage des coefficients **voisins identiques**. Voisinage général (pixels adjacents) : $\lambda_2 \sum_{j \sim j'} |\beta_j - \beta_{j'}|$. Les paramètres λ_1, λ_2 sont difficiles à régler.

Pour la retrouver : $\ell 1$ fabrique des zéros exacts ; mis sur les *différences*, il fabrique des sauts nuls, donc des paliers. On suppose « peu de ruptures » (détection de ruptures, signal constant par morceaux) au lieu de « peu de coefficients non nuls ».

Piège — Pas de règle orthonormée, et l'ordre compte → S6

Même avec $X^\top X = I$, $|\beta_j - \beta_{j-1}|$ **couple** chaque coordonnée à ses voisines : pas de découplage, pas de formule coordonnée par coordonnée (on utilise des algorithmes dédiés). Et la pénalité n'a de sens que si l'ordre des variables en a un (temps, position sur un chromosome, pixels).

Méthode — Le Lasso fusionné à deux points À SAVOIR REFAIRE → S6, exercice 9

$X = I_2$, $\lambda_1 = 0$: $\min_\beta (\beta_1 - y_1)^2 + (\beta_2 - y_2)^2 + \lambda_2 |\beta_1 - \beta_2|$. Changez de variables : $m = \frac{\beta_1+\beta_2}{2}$, $d = \beta_1 - \beta_2$, $\bar{y} = \frac{y_1+y_2}{2}$, $\Delta = y_1 - y_2$. Le critère vaut $2(m-\bar{y})^2 + \frac{1}{2}(d-\Delta)^2 + \lambda_2 |d|$ et se découple.

$\hat{m} = \bar{y}$ et $\hat{d} = \operatorname{sgn}(\Delta)\big(|\Delta| - \lambda_2\big)_+$: si $|y_1 - y_2| \le \lambda_2$, les deux estimations **fusionnent** en $\frac{y_1+y_2}{2}$; sinon chacune se rapproche de l'autre de $\lambda_2/2$.

Le group-Lasso

Définition — Group-Lasso (Yuan et Lin, 2006) PAR CŒUR → S6

On se donne K groupes connus $G_1, \dots, G_K$, non vides et disjoints ; pour $\lambda > 0$:

$$\hat{\beta}^{\text{group}}(\lambda) = \underset{\beta \in \mathbb{R}^p}{\arg\min} \left\{ \|Y - X\beta\|^2 + \lambda \sum_{k=1}^{K} \|\beta_{(k)}\| \right\},$$

$$\beta_{(k)j} = \begin{cases} \beta_j & \text{si } j \in G_k, \\ 0 & \text{sinon.} \end{cases}$$

Norme euclidienne **non élevée au carré**. Si $K = p$ (groupes singletons), $\|\beta_{(k)}\| = |\beta_k|$: c'est le Lasso standard.

Pour la retrouver : un Lasso dont les « coordonnées » sont des blocs. La norme non carrée est pointue en 0 comme $|u|$ (son sous-différentiel en 0 est la boule unité), donc un bloc entier peut être nul ; avec le carré on retrouverait le Ridge, $\sum_k \|\beta_{(k)}\|^2 = \|\beta\|^2$. Exemple type : une variable catégorielle codée par plusieurs indicatrices, à garder ou retirer en entier.

Hors diapos : pour des groupes de tailles différentes, Yuan et Lin pondèrent chaque terme par $\sqrt{|G_k|}$. La diapo 87, et donc toute cette fiche, n'a pas ce poids.

Proposition — Caractérisation du group-Lasso (diapo 87) PAR CŒUR À SAVOIR REFAIRE → S6

$X_{(k)}$: sous-matrice des colonnes du groupe k. Pour tout $k \in \{1, \dots, K\}$:

$$\begin{cases} 2X_{(k)}^\top (Y - X\hat{\beta}^{\text{group}}) = \lambda \dfrac{\hat{\beta}^{\text{group}}_{(k)}}{\left\|\hat{\beta}^{\text{group}}_{(k)}\right\|_2} & \text{si } \hat{\beta}^{\text{group}}_{(k)} \neq 0, \\ \left\|2X_{(k)}^\top (Y - X\hat{\beta}^{\text{group}})\right\|_2 \le \lambda & \text{si } \hat{\beta}^{\text{group}}_{(k)} = 0. \end{cases}$$

La procédure garde ou écarte **tous** les coefficients d'un bloc.

L'idée : les KKT du Lasso, où la valeur absolue de la corrélation d'une variable avec le résidu devient la **norme du vecteur des corrélations** du groupe. Un groupe reste à 0 tant que, collectivement, il n'est pas assez corrélé au résidu.

Preuve express

1. $$0 \in -2X^\top(Y - X\hat\beta) + \lambda\,\partial\Big(\sum_k \big\|\hat\beta_{(k)}\big\|\Big)$$

   ↳ le critère est convexe : $\hat\beta$ minimise $\Leftrightarrow$ 0 appartient au sous-différentiel ; le gradient de l'ajustement vaut $-2X^\top(Y - X\beta)$.

2. $$0 \in -2X_{(k)}^\top(Y - X\hat\beta) + \lambda\,\partial\,\|\cdot\|_2\,(\hat\beta_{(k)})$$

   ↳ pour chaque groupe k : les blocs sont disjoints, donc la pénalité est une somme de fonctions de blocs différents ; on lit la condition bloc par bloc (lignes du groupe k).

3. $$\partial\,\|\cdot\|_2\,(u) = \{u/\,\|u\|_2\} \qquad (u \neq 0),$$
   $$\partial\,\|\cdot\|_2\,(0) = \{h : \|h\|_2 \leq 1\}$$

   ↳ sous-différentiel de la norme euclidienne : le premier cas donne l'égalité, le second donne $2X_{(k)}^\top(Y - X\hat\beta) = \lambda h$ avec $\|h\|_2 \leq 1$.

Formule — Group-Lasso en design orthonormé PAR CŒUR À SAVOIR REFAIRE → S6

$$\hat\beta_{(k)} = \Big(1 - \frac{\lambda}{2\,\big\|b_{(k)}\big\|_2}\Big)_+ b_{(k)}$$

Seuillage doux *par groupe* : bloc entier nul ssi $\big\|b_{(k)}\big\|_2 \leq \lambda/2$; sinon il est rétréci **dans sa direction** (toutes ses coordonnées multipliées par le même facteur). Groupes de taille 1 : $\big(1 - \frac{\lambda}{2|b_j|}\big)_+ b_j = \mathrm{sgn}(b_j)(|b_j| - \lambda/2)_+$, le seuillage doux.

L'idée : le critère se découple par groupe en $\min_u \|u - c\|^2 + \lambda\,\|u\|$ ($c = b_{(k)}$) : $u = 0$ ssi $\|c\| \leq \lambda/2$; sinon u est un multiple positif de c et $\|u\| = \|c\| - \lambda/2$.

Preuve express

1. $$0 \in -2c + \lambda\{h : \|h\| \leq 1\} \iff \|c\| \leq \lambda/2$$

   ↳ $u = 0$ est solution ssi cette condition d'optimalité en 0 a lieu : $2c$ doit s'écrire λh avec $\|h\| \leq 1$.

2. $$2(u - c) + \lambda\frac{u}{\|u\|} = 0 \iff u\Big(1 + \frac{\lambda}{2\,\|u\|}\Big) = c$$

   ↳ en $u \neq 0$ le critère est dérivable : on annule le gradient.

3. $$\|u\| + \frac{\lambda}{2} = \|c\|\,, \qquad u = \frac{\|c\| - \lambda/2}{\|c\|}\,c$$

   ↳ le facteur est positif, donc u a la direction de c ; on prend les normes. Possible seulement si $\|c\| > \lambda/2$; la partie positive regroupe les deux cas.

Bilan : quel outil pour quel défaut

Méthode	Corrige	Critère / définition	Règle $b \mapsto \hat{\beta}$ ($X^\top X = I$)	Convexe ?
Lasso	(référence)	$\|Y - X\beta\|^2 + \lambda \|\beta\|_1$	$\mathrm{sgn}(b)(\|b\| - \lambda/2)_+$	oui
Ridge (bridge $\gamma = 2$)	instabilité de $(X^\top X)^{-1}$	$\|Y - X\beta\|^2 + \lambda \|\beta\|_2^2$	$b/(1+\lambda)$	oui, strictement
Sélection ℓ0 (bridge $\gamma = 0$)	—	$\|Y - X\beta\|^2 + \lambda \|\beta\|_0$	$b\,\mathbf{1}\{\|b\| > \sqrt{\lambda}\}$	non
LSLasso	biais	Lasso, puis moindres carrés sur le support	$b\,\mathbf{1}\{\|b\| > \lambda/2\}$	chaque étape
Lasso relaxé	biais	Lasso, puis Lasso de paramètre $\delta\lambda$ sur le support	$\mathbf{1}\{\|b\| > \lambda/2\}\,(b - \mathrm{sgn}(b)\,\delta\lambda/2)$	chaque étape
Lasso adaptatif	biais	$\|Y - X\beta\|^2 + \lambda \sum_j \|\beta_j\| \,/\, \|\tilde{\beta}_j\|$	$\mathrm{sgn}(b)\big(\|b\| - \frac{\lambda}{2\|b\|}\big)_+$ ($\tilde{\beta} = b$)	oui
Dantzig	(autre formulation)	$\min \|\beta\|_1$ s.c. $\|2X^\top(Y - X\beta)\|_\infty \le \lambda$	$\mathrm{sgn}(b)(\|b\| - \lambda/2)_+$ (= Lasso)	oui (programme linéaire)
Elastic net	au plus n variables ; corrélations	$\|Y - X\beta\|^2 + \lambda_1 \|\beta\|_1 + \lambda_2 \|\beta\|_2^2$	$\mathrm{sgn}(b)(\|b\| - \lambda_1/2)_+/(1+\lambda_2)$	oui, strictement
Lasso fusionné	structure ordonnée	$\|Y - X\beta\|^2 + \lambda_1 \|\beta\|_1 + \lambda_2 \sum_{j\ge 2} \|\beta_j - \beta_{j-1}\|$	pas de découplage	oui
Group-Lasso	structure en groupes	$\|Y - X\beta\|^2 + \lambda \sum_k \|\beta_{(k)}\|_2$	$\big(1 - \frac{\lambda}{2\|b_{(k)}\|}\big)_+ b_{(k)}$ (par groupe)	oui

À comprendre — Trois questions devant chaque règle À COMPRENDRE → S6

(1) Vaut-elle exactement 0 sur un intervalle autour de 0 ? (sélection) (2) Colle-t-elle à la diagonale pour les grands $|b|$? (pas de biais sur les gros effets) (3) Est-elle continue ? (stabilité). Le seuillage doux est continu mais biaisé ; le seuillage dur est sans biais pour les grands b mais saute au seuil, d'où plus de variance ; l'adaptatif et le relaxé sont des intermédiaires. Aucune règle ne gagne partout : c'est encore le compromis biais–variance.

Le message des diapos 88–89 : des critères convexes contournent la complexité combinatoire de la sélection de modèle ; ils introduisent un biais mais réduisent la variance et donnent un petit ensemble de prédicteurs interprétable ; on modifie la pénalité ℓ1 pour corriger les défauts du Lasso ou injecter une connaissance a priori ; le choix de λ reste un défi ; tout s'étend aux modèles linéaires généralisés.

Réflexes de la séance 6

- Nouvelle pénalité ? → design orthonormé, problème à une variable, dessin de $b \mapsto \hat{\beta}$.
- Pénalité pointue en 0 ? → zéros exacts. Convexe ? → calculable, caractérisée par $0 \in \partial F$.
- Comparer deux estimateurs définis par un minimum ? → montrer que l'un est admissible pour le problème de l'autre ($\hat{\beta}^L \in D_\lambda$).
- Variables corrélées, solution instable ? → un peu de ℓ_2^2 : stricte convexité ⇒ unicité.
- Procédure en deux étapes ? → validation croisée sur la procédure complète.

Les théorèmes et leurs hypothèses

« Énoncez le théorème » veut dire : le cadre, les hypothèses, l'estimateur avec sa convention et son λ, la conclusion avec ses constantes, et la probabilité. Les quatre colonnes de droite sont à savoir par cœur.

Résultat	Cadre et hypothèses	Estimateur, λ	Conclusion	Probabilité
Erreur des MCO → S1	$Y = X\beta^* + \varepsilon$, X déterministe, ε centré de covariance $\sigma^2 I_n$ (gaussien dans le cours)	moindres carrés	$\mathbb{E}\left\|X\hat{\beta}^{\mathrm{MC}} - X\beta^*\right\|_n^2 = \sigma^2 \operatorname{rg}(X)/n$	en espérance
Identité de Cp → S1	même cadre ; un modèle m **fixé** (choisi sans regarder les données), de dimension d	MCO sur le modèle m	$\mathbb{E}\left\|X\hat{\beta}_m - X\beta^*\right\|_n^2 + \sigma^2 = \mathbb{E}\left\|Y - X\hat{\beta}_m\right\|_n^2 + \frac{2\sigma^2 d}{n}$	en espérance
Sélection de modèle → TD1	$Y = f^* + \varepsilon \in \mathbb{R}^n$, $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$; modèles S_m de dimension d_m, $\hat{f}_m = P_{S_m} Y$; poids $\Pi_m \in]0,1]$, $\sum_m \Pi_m = 1$; $K > 1$	$\hat{m} = \arg\min_m \{\left\|Y - \hat{f}_m\right\|^2 + \sigma^2 \mathrm{pen}(m)\}$, $\mathrm{pen}(m) = K\left(\sqrt{d_m} + \sqrt{2\log(1/\Pi_m)}\right)^2$	$\mathbb{E}\left\|\hat{f}_{\hat{m}} - f^*\right\|^2 \le C'_K \min_m \left\{\mathbb{E}\left\|\hat{f}_m - f^*\right\|^2 + \sigma^2 \log(1/\Pi_m) + \sigma^2\right\}$, C'_K ne dépendant que de K (notée C_K dans l'énoncé)	en espérance
Bickel–Ritov–Tsybakov → S3	$\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$; $\|X_j\|^2 = n$; $M(\beta^*) \le s$; RE $(s, 3)$, $\kappa = \kappa(s,3)$; $\varphi_{\max}$ plus grande valeur propre de $X^\top X/n$	$\frac{1}{n}\|Y - X\beta\|^2 + 2r\|\beta\|_1$, $r = A\sigma\sqrt{\log p / n}$, $A > 2\sqrt{2}$	$\left\|\hat{\beta} - \beta^*\right\|_1 \le \frac{16A}{\kappa^2}\sigma s\sqrt{\frac{\log p}{n}}$; $\left\|X(\hat{\beta} - \beta^*)\right\|^2 \le \frac{16A^2}{\kappa^2}\sigma^2 s \log p$; $M(\hat{\beta}) \le \frac{64\varphi_{\max}}{\kappa^2} s$	$\ge 1 - p^{1 - A^2/8}$

Résultat	Cadre et hypothèses	Estimateur, λ	Conclusion	Probabilité
Lemme du TD2 → TD2	bruit gaussien, $\mathrm{diag}(X^\top X/n) = 1$; ni RE ni parcimonie ; vrai **pour tout** $\beta \in \mathbb{R}^p$	même estimateur, même r, $A > 2\sqrt{2}$	$\left\|X\hat\beta - X\beta^*\right\|_n^2 + r\left\|\hat\beta - \beta\right\|_1 \le \|X\beta - X\beta^*\|_n^2 + 4r\sum_{j\in J(\beta)}\left\|\hat\beta_j - \beta_j\right\|$; $\left\|\frac{1}{n}X^\top(X\beta^* - X\hat\beta)\right\|_\infty \le \frac{3r}{2}$; $M(\hat\beta) \le \frac{4\varphi_{\max}}{r^2}\left\|X\hat\beta - X\beta^*\right\|_n^2$	$\ge 1 - 2p^{1-A^2/8}$
Inégalité oracle lente → S4	$Y_i = f(Z_i) + \varepsilon_i$, $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$; dictionnaire de M fonctions $f_1, \dots, f_M$, $X_{ij} = f_j(Z_i)$, $f_\beta = X\beta$; colonnes normalisées $\|X_j\|^2 = n$; Θ convexe ; aucune hypothèse sur les corrélations	$\arg\min_{\beta\in\Theta}\{\frac{1}{n}\|y - f_\beta\|^2 + \lambda\|\beta\|_1\}$, $\lambda = 2\sigma\sqrt{2(x + \log M)/n}$, $x > 0$	$\frac{1}{n}\left\|f_{\hat\beta} - f\right\|^2 \le \inf_{\beta\in\Theta}\{\frac{1}{n}\|f_\beta - f\|^2 + 2\lambda\|\beta\|_1\}$	$\ge 1 - 2e^{-x}$
Inégalité oracle rapide → S4	idem + RE$(s, 3)$, $\kappa = \kappa(s, 3)$	$\arg\min_{\beta\in\Theta}\{\frac{1}{n}\|y - f_\beta\|^2 + 2\lambda\|\beta\|_1\}$, **même** λ	$\frac{1}{n}\left\|f_{\hat\beta} - f\right\|^2 \le \inf_{\beta\in\Theta,\,\|\beta\|_0\le s}\{\frac{1}{n}\|f_\beta - f\|^2 + \frac{18\sigma^2 s(x+\log M)}{\kappa^2 n}\}$	$\ge 1 - 2e^{-x}$
Normalité asymptotique de l'EMV d'un GLM → S5	p fixé, $n \to \infty$; information de Fisher moyenne $I_n(\beta) = -\mathbb{E}[\nabla^2 \ell_n(\beta)]$, $\ell_n = \frac{1}{n}\ell$ (= $\frac{1}{n}X^\top W(\beta)X$ avec le lien canonique), et $I_n(\beta^*) \to I(\beta^*) \succ 0$; plus identifiabilité et conditions de régularité	maximum de vraisemblance	$\hat\beta \to \beta^*$ en probabilité et $\sqrt{n}(\hat\beta - \beta^*) \to \mathcal{N}\big(0, I(\beta^*)^{-1}\big)$ en loi ; IC de Wald $\hat\beta_j \pm q_{1-\alpha/2}\sqrt{[I(\hat\beta)^{-1}]_{jj}/n}$	niveau $1 - \alpha$ seulement asymptotiquement (Slutsky)
Lasso logistique, oracle lente → TD3	$Y_i \in \{0, 1\}$ indépendantes, $\mathbb{P}(Y_i = 1) = \pi(z_i^\top \beta_0)$, z_i déterministes ; $\max_{i,j}\|z_{ij}\| \le c$; aucune hypothèse sur les corrélations	$\arg\min\{\hat R(\beta) + \lambda\|\beta\|_1\}$, $\hat R(\beta) = \frac{1}{n}\sum_i[\log(1 + e^{z_i^\top\beta}) - Y_i z_i^\top\beta]$; $\lambda = A\sqrt{\log p/n}$, $A > \sqrt{2}\,c$	$R(\hat\beta) - R(\beta_0) \le \inf_\beta\{R(\beta) - R(\beta_0) + 2A\|\beta\|_1\sqrt{\log p/n}\}$, $R = \mathbb{E}\hat R$	$\ge 1 - 2p^{1-A^2/(2c^2)}$

À comprendre — La même mécanique partout À COMPRENDRE

Les théorèmes « avec grande probabilité » se démontrent tous de la même façon. On écrit l'inégalité de base (le minimiseur bat n'importe quel concurrent ; pour l'inégalité rapide, la professeure part du critère d'optimalité). Le bruit n'apparaît que dans un terme croisé, majoré par $\|\cdot\|_\infty \times \|\cdot\|_1$ (Hölder). On se place sur l'événement où ce terme est dominé par la pénalité. La probabilité de cet événement vient d'une queue gaussienne (ou de Hoeffding), combinée avec une borne de l'union sur les p (ou M) colonnes : c'est de là que vient le $\log p$ dans λ. Dans les versions « rapides », le bruit ne consomme que la moitié de la pénalité ; l'autre moitié met l'erreur dans le cône, puis RE fait passer de la norme ℓ_1 à la norme de prédiction.

Les preuves à savoir refaire

Pour chaque ligne : lisez le résultat, récitez l'idée clé (cachée en mode auto-test), puis refaites la preuve sur une feuille. La « fiche » contient la preuve express.

Résultat	L'idée clé, à réciter	Où la revoir
Hölder et vecteur parcimonieux : $\lvert a^\top b\rvert \le \|a\|_1 \, \|b\|_\infty$ et $\|v_J\|_1 \le \sqrt{\lvert J\rvert}\, \|v_J\|_2$	Hölder : $\left\lvert\sum_j a_j b_j\right\rvert \le \sum_j \lvert a_j\rvert \, \lvert b_j\rvert$, puis chaque $\lvert b_j\rvert \le \|b\|_\infty$. Parcimonieux : Cauchy–Schwarz entre $(1,\dots,1) \in \mathbb{R}^{\lvert J\rvert}$ et $(\lvert v_j\rvert)_{j\in J}$.	fiche · Rappels · S3
Matrice de Gram : $X^\top X$ symétrique positive, $\operatorname{Ker}(X^\top X) = \operatorname{Ker} X$, $\operatorname{rg}(X^\top X) = \operatorname{rg} X$	$v^\top X^\top X v = \|Xv\|^2 \ge 0$; si $X^\top X v = 0$, alors $\|Xv\|^2 = v^\top X^\top X v = 0$, donc $Xv = 0$; théorème du rang pour deux matrices à p colonnes.	fiche · Rappels
Espérance d'une forme quadratique : $\mathbb{E}[\varepsilon^\top M \varepsilon] = \sigma^2 \operatorname{tr} M$, et $\mathbb{E}\,\|P\varepsilon\|^2 = \sigma^2 \operatorname{rg} P$	Un nombre est sa propre trace : $\varepsilon^\top M \varepsilon = \operatorname{tr}(M\varepsilon\varepsilon^\top)$; la trace commute avec l'espérance et $\mathbb{E}[\varepsilon\varepsilon^\top] = \sigma^2 I_n$. Pour un projecteur, $P^\top P = P$ et $\operatorname{tr} P = \operatorname{rg} P$.	fiche · Rappels
Queue gaussienne (Chernoff) : $\mathbb{P}(Z \ge t) \le e^{-t^2/2}$, et $\mathbb{P}(\lvert Z\rvert \ge t) \le 2e^{-t^2/2}$	Markov appliqué à $e^{\theta Z}$, avec $\mathbb{E}[e^{\theta Z}] = e^{\theta^2/2}$ (compléter le carré) ; on optimise en $\theta = t$; la symétrie donne le facteur 2.	fiche · fiche TD2 · Rappels · TD2
Maximum de p gaussiennes : $\mathbb{P}\big(\max_j \lvert Z_j\rvert > \sqrt{2(\log p + x)}\big) \le 2e^{-x}$	Borne de l'union (aucune indépendance requise) puis queue gaussienne : $2p\,e^{-t^2/2}$; le choix $t^2 = 2(\log p + x)$ compense exactement le facteur p.	fiche · Rappels · S3
Décomposition biais–variance : $\mathbb{E}\left\|\hat\theta - \theta\right\|^2 = \left\|\mathbb{E}\hat\theta - \theta\right\|^2 + \mathbb{E}\left\|\hat\theta - \mathbb{E}\hat\theta\right\|^2$	Ajouter et retrancher $\mathbb{E}\hat\theta$, développer le carré ; le double produit est d'espérance nulle car $\mathbb{E}\hat\theta - \theta$ n'est pas aléatoire.	fiche · Rappels
Identités du score : $\mathbb{E}[s_\theta(Y)] = 0$ et $I(\theta) = \mathbb{E}[s_\theta(Y)^2] = -\mathbb{E}[\partial_\theta^2 \log f_\theta(Y)]$	Dériver $\int f_\theta = 1$ sous l'intégrale, avec $\partial_\theta f_\theta = s_\theta f_\theta$; dériver encore $\int s_\theta f_\theta = 0$ (dérivée d'un produit).	fiche · Rappels · S5

Résultat	L'idée clé, à réciter	Où la revoir
Équations normales des MCO : $X^\top X\hat\beta = X^\top Y$, minimum global	Développer $\|Y-X\beta\|^2$, annuler le gradient $-2X^\top(Y-X\beta)$; la hessienne $2X^\top X$ est positive, donc gradient nul ⇔ minimum. Géométriquement : le résidu est orthogonal à $\operatorname{Im} X$.	fiche · S1
Erreur de prédiction des MCO : $\mathbb{E}\left\|X\hat\beta^{\mathrm{MC}} - X\beta^*\right\|_n^2 = \sigma^2 \operatorname{rg}(X)/n$	$X\hat\beta^{\mathrm{MC}} - X\beta^* = P\varepsilon$ (P projecteur sur $\operatorname{Im} X$, qui fixe $X\beta^*$), puis $\mathbb{E}\,\|P\varepsilon\|^2 = \sigma^2 \operatorname{tr} P = \sigma^2 \operatorname{rg} X$.	fiche · S1
Ridge : $(X^\top X + \lambda I_p)^{-1}X^\top Y$ est l'unique minimiseur de $\|Y-X\beta\|^2 + \lambda\|\beta\|^2$, $\lambda>0$ (TD1, ex. 1 Q1)	Hessienne $2(X^\top X+\lambda I_p)$ définie positive (valeurs propres $\mu_j+\lambda \geq \lambda > 0$) : stricte convexité ; coercivité $f \geq \lambda\|\beta\|^2$; gradient nul.	fiche · TD1
Biais² et variance du Ridge dans la base propre (TD1, ex. 1 Q3–Q4)	$\mathbb{E}\hat\beta^R - \beta^* = -\lambda(X^\top X+\lambda I_p)^{-1}\beta^*$; l'écart à la moyenne est $A\varepsilon$, d'où une variance $\sigma^2 \operatorname{tr}(AA^\top)$; puis diagonaliser $X^\top X = PDP^\top$.	fiche · TD1
Identité d'optimisme (Cp/AIC), modèle fixé : en moyenne, erreur de test = erreur d'apprentissage $+\,2\sigma^2 d/n$ (en $\|\cdot\|_n^2$)	Même biais $\|(I-P)X\beta^*\|^2$ des deux côtés ; le bruit vaut $\sigma^2\operatorname{tr}(I-P) = \sigma^2(n-d)$ en apprentissage et $\sigma^2 \operatorname{tr} P = \sigma^2 d$ en prédiction ; on soustrait.	fiche · S1
Forme contrainte du Ridge (TD1, ex. 1 Q2)	Le Ridge est admissible pour la boule de rayon $\left\|\hat\beta^R\right\|$; une solution contrainte ajuste au moins aussi bien et ne paie pas plus de pénalité, donc minimise le critère pénalisé ; on conclut par l'unicité.	fiche · TD1
Lasso : mêmes $X\hat\beta$ et même $\left\|\hat\beta\right\|_1$ pour toutes les solutions ; pénalisé = contraint (TD1, ex. 2)	Milieu de deux solutions + stricte convexité de $x\mapsto x^2$ ⇒ même ajustement ⇒ même f_0 ⇒ même pénalité (diviser par $\lambda>0$). Puis, pour chaque inclusion, comparer les critères en une solution de l'autre problème, avec $M_\lambda = N_\lambda$.	fiche · TD1
Inégalité oracle pour la sélection de modèles (TD1, ex. 3)	Inégalité de base ; terme croisé du modèle fixé $= -\sigma^2 d_m$; terme croisé du modèle choisi : projection, Young, puis $\max \leq \sum(\cdot)_+$, concentration gaussienne et poids Π_m de somme 1 ; enfin absorber $a^{-1}R$ à gauche ($a = \frac{K+1}{2} > 1$).	fiche · TD1
Lasso = MAP avec a priori de Laplace de densité $\frac{a}{2}e^{-a\|\beta_j\|}$ (S2) : $\lambda_{\mathrm{Lasso}} = 2\sigma^2 a$ pour le critère $\|Y-X\beta\|^2 + \lambda\|\beta\|_1$	$-\log(\text{vraisemblance gaussienne} \times \text{a priori de Laplace}) = \frac{1}{2\sigma^2}\|Y-X\beta\|^2 + a\|\beta\|_1 + C$, puis multiplier par $2\sigma^2$.	fiche · S2

Résultat	L'idée clé, à réciter	Où la revoir
Design orthogonal (S2) : critère $\|Y-X\beta\|^2+\lambda\|\beta\|_1$, $X^\top X = I_p$, $b = X^\top Y$; $\hat\beta^L_j = \operatorname{sgn}(b_j)(\|b_j\|-\lambda/2)_+$	$X^\top X = I \Rightarrow \|Y-X\beta\|^2 = \sum_j(\beta_j-b_j)^2 + \text{cte}$: p problèmes à une variable ; trois cas selon le signe de β_j (ou $0 \in 2(\hat\beta_j - b_j) + \lambda\,\partial\|\cdot\|(\hat\beta_j)$).	fiche · S2
Conditions KKT du Lasso (S2, critère $\|Y-X\beta\|^2+\lambda\|\beta\|_1$) : $2X_j^\top(Y-X\hat\beta) = \lambda\operatorname{sgn}(\hat\beta_j)$ si $\hat\beta_j \neq 0$, $2\left\|X_j^\top(Y-X\hat\beta)\right\| \le \lambda$ sinon	Pour chaque j : $0 \in -2X_j^\top(Y-X\hat\beta) + \lambda\,\partial\|\cdot\|(\hat\beta_j)$, avec $\partial\|\cdot\| = \{\operatorname{sgn}\}$ hors de 0 et $[-1,1]$ en 0 ; critère convexe ⇒ conditions nécessaires et suffisantes.	fiche · S2
$\hat\beta = 0$ est solution $\Leftrightarrow \lambda \ge 2\left\|X^\top Y\right\|_\infty$ (S2, critère $\|Y-X\beta\|^2+\lambda\|\beta\|_1$)	KKT en 0 : aucune variable active, le résidu vaut Y, il reste $2\left\|X_j^\top Y\right\| \le \lambda$ pour tout j.	fiche · S2
Le chemin du Lasso est linéaire par morceaux (S2)	À A et s_A fixés, l'égalité KKT $2X_A^\top(Y-X_A\hat\beta_A) = \lambda s_A$ donne $\hat\beta_A = (X_A^\top X_A)^{-1}(X_A^\top Y - \frac{\lambda}{2}s_A)$, affine en λ ; coude quand une variable entre ou sort.	fiche · S2
Valeurs ajustées $X\hat\beta^L$ et norme $\left\|\hat\beta^L\right\|_1$ uniques pour $\lambda > 0$ (S2)	Milieu de deux solutions + identité $\left\|Y-\frac{u+v}{2}\right\|^2 = \frac12\|Y-u\|^2 + \frac12\|Y-v\|^2 - \frac14\|u-v\|^2$: $F(\text{milieu}) \le m - \frac14\|u-v\|^2$, donc $u=v$, puis normes ℓ_1 égales.	fiche · S2
Inégalité de base du Lasso (BRT, étape 1) : $\frac1n\|X\delta\|^2 \le \frac2n\varepsilon^\top X\delta + 2r(\|\beta^*\|_1 - \left\|\hat\beta^L\right\|_1)$	Critère$(\hat\beta^L) \le$ critère(β^*) ; $Y - X\beta^* = \varepsilon$ et $Y - X\hat\beta^L = \varepsilon - X\delta$; on développe $\|\varepsilon - X\delta\|^2$ et $\frac1n\|\varepsilon\|^2$ se simplifie.	fiche · S3
Le cône sur $\mathcal{E}$: $\left\|\delta_{J_0^c}\right\|_1 \le 3\|\delta_{J_0}\|_1$	Hölder + $\mathcal{E}$: bruit $\le r\|\delta\|_1$; ajouter $r\|\delta\|_1$; découpage (termes hors support compensés, triangulaire inversée dessus) ⇒ $\frac1n\|X\delta\|^2 + r\|\delta\|_1 \le 4r\|\delta_{J_0}\|_1$; $4-1=3$.	fiche · S3
Bornes (7) et (6) du théorème BRT	Sur le cône, $\|\delta_{J_0}\|_1 \le \sqrt{s}\,\|\delta_{J_0}\|_2 \le \sqrt{s}\,u/\kappa$ (RE) ⇒ $u^2 + r\|\delta\|_1 \le cu$, $c = 4r\sqrt{s}/\kappa$; $u \le c$ donne (7), $r\|\delta\|_1 \le c^2$ donne (6).	fiche · S3
$\mathbb{P}(\mathcal{E}^c) \le p^{1-A^2/8}$ pour $r = A\sigma\sqrt{\log p/n}$	$X_j^\top\varepsilon/(\sigma\sqrt{n}) \sim \mathcal{N}(0,1)$ (colonnes normalisées) ; seuil $\frac{A}{2}\sqrt{\log p}$; queue $e^{-t^2/2}$ donne $p^{-A^2/8}$; borne de l'union sur les p variables.	fiche · S3
Taille du support estimé : $M(\hat\beta^L) \le 64\varphi_{\max}s/\kappa^2$	KKT (égalité $\pm r$) + $\mathcal{E}$ (bruit $\le r/2$) ⇒ $\left\|\frac1nX_j^\top X\delta\right\| \ge r/2$ pour chaque variable sélectionnée ; somme des carrés $\le \varphi_{\max}\frac1n\|X\delta\|^2 \le \varphi_{\max}\cdot 16r^2s/\kappa^2$.	fiche · S3
Sous RE$(s,3)$, toute famille d'au plus $2s$ colonnes est libre	J = les s plus grosses coordonnées de δ : $\|\delta_{J^c}\|_1 \le \|\delta_J\|_1$, donc δ est dans le cône ; RE donne $\|X\delta\|_2 \ge \kappa\sqrt{n}\,\|\delta_J\|_2 > 0$.	fiche · S3

Résultat	L'idée clé, à réciter	Où la revoir
Lemme du TD2 : (2) pour tout β, (3) et (4)	Base contre β ; sur $\mathcal{E}$, bruit $\leq r\left\|\hat{\beta}^L-\beta\right\|_1$; ajouter $r\left\|\hat{\beta}^L-\beta\right\|_1$; terme nul hors de $J(\beta)$, $\leq 2\left\|\hat{\beta}_j^L-\beta_j\right\|$ dessus. (3) : résidu (KKT, $\leq r$) moins bruit ($\leq r/2$). (4) : $r^2/4$ par variable sélectionnée, Rayleigh avec $XX^\top/n$.	fiche · TD2
Seuillage doux : $\arg\min_a\{\frac{1}{2}(a-b)^2+\lambda\left\|a\right\|\}=\operatorname{sgn}(b)(\left\|b\right\|-\lambda)_+$	Trois cas : $a>0$ et $a<0$ (dériver, puis vérifier que la solution a le bon signe), et $\left\|b\right\|\leq\lambda$ où la fonction décroît puis croît, d'où 0. En une ligne : $0\in a-b+\lambda\,\partial\left\|a\right\|$.	fiche · S4
L'enveloppe convexe de $\mathbf{1}\{x\neq 0\}$ sur $[-1,1]$ est $\left\|x\right\|$	$\left\|x\right\|$ est un candidat ; tout h convexe sous l'indicatrice vérifie $h(0)\leq 0$ et $h(\pm1)\leq 1$, et la corde entre 0 et ±1 donne $h(x)\leq\left\|x\right\|$.	fiche · S4
$\partial\left\|\cdot\right\|(0)=[-1,1]$, puis $\partial\left\|u\right\|_1$ et $\partial\left\|\cdot\right\|_2(0)$	$g\in\partial\left\|\cdot\right\|(0)\iff\left\|v\right\|\geq gv\ \forall v\iff\left\|g\right\|\leq 1$ (contre-exemple $v=\operatorname{sgn}(g)$) ; $\left\|\cdot\right\|_1$ est une somme de fonctions d'une coordonnée, d'où le produit des $\partial\left\|u_j\right\|$; pour $\left\|\cdot\right\|_2$ en 0 : Cauchy–Schwarz, puis $v=g$.	fiche · S4
Monotonie : $(u_1-u_2)^\top(g_1-g_2)\geq 0$	L'inégalité du sous-gradient en u_1 (au point u_2) et en u_2 (au point u_1), additionnées : les φ s'éliminent.	fiche · S4
Conditions KKT du Lasso (critère $\frac{1}{n}\left\|y-X\beta\right\|^2+\lambda\left\|\beta\right\|_1$)	Règle de Fermat et règle de la somme : $0\in-\frac{2}{n}X^\top(y-X\hat{\beta})+\lambda\,\partial\left\|\hat{\beta}\right\|_1$, puis lecture coordonnée par coordonnée (égalité si $\hat{\beta}_j\neq 0$, inégalité sinon).	fiche · S4
RE$(s,1)$ ⇒ toute sous-matrice d'au plus $2s$ colonnes est de rang plein	Un $t\neq 0$ à au plus $2s$ coordonnées non nulles, avec J = ses s plus grandes coordonnées, est dans le cône $c_0=1$; RE donne alors $\left\|Xt\right\|>0$.	fiche · S4
Inégalité oracle lente (pénalité $\lambda\left\|\beta\right\|_1$) : sur $\mathcal{A}$, $\left\|f_{\hat{\beta}}-f\right\|_n^2\leq\left\|f_\beta-f\right\|_n^2+2\lambda\left\|\beta\right\|_1$ pour tout $\beta\in\Theta$	$F(\hat{\beta})\leq F(\beta)$ et $y=f+\varepsilon$; terme croisé $2\sum_j(\hat{\beta}_j-\beta_j)V_j\leq\lambda\left\|\hat{\beta}-\beta\right\|_1$ sur $\mathcal{A}=\{\left\|V_j\right\|\leq\lambda/2\ \forall j\}$; l'inégalité triangulaire fait disparaître $\lambda\left\|\hat{\beta}\right\|_1$; $V_j\sim\mathcal{N}(0,\sigma^2/n)$, queue gaussienne et borne de l'union : $\mathbb{P}(\mathcal{A}^c)\leq 2e^{-x}$.	fiche · S4
Inégalité oracle rapide (RE$(s,3)$, pénalité $2\lambda\left\|\beta\right\|_1$ avec le même λ) : constante 18	Critère d'optimalité, monotonie et polarisation (bonus $\left\|f_{\hat{\beta}}-f_\beta\right\|_n^2$) ; $g=\operatorname{sgn}(\beta)+h$ fait apparaître $-2\lambda\left\|\hat{\beta}_{J^c}\right\|_1$; deux cas, bruit $\leq\lambda$ (moitié de la pénalité) ⇒ cône $c_0=3$; RE, Cauchy–Schwarz et $ax\leq x^2+\frac{a^2}{4}$: reste $\frac{9\lambda^2 s}{4\kappa^2}=\frac{18\sigma^2 s(x+\log M)}{\kappa^2 n}$.	fiche · S4
Moments de la famille exponentielle : $\mathbb{E}T(Y)=A'(\theta)$, $\operatorname{Var}T(Y)=A''(\theta)$	Score d'espérance nulle (dériver $\int f_\theta=1$) et identité de Fisher (dériver une seconde fois), avec $\frac{\partial\ell}{\partial\theta}=T(y)-A'(\theta)$ et $\frac{\partial^2\ell}{\partial\theta^2}=-A''(\theta)$. Ou bien : $A=\log Z$, $(\log Z)'=\mathbb{E}T$, $(\log Z)''=\operatorname{Var}T$.	fiche · S5

Résultat	L'idée clé, à réciter	Où la revoir
Équations de vraisemblance d'un GLM ; $X^\top y = X^\top \mu$ avec le lien canonique	Chaîne $\beta \to \eta \to \mu \to \theta \to \ell$: $\frac{\partial \ell_i}{\partial \beta_j} = (y_i - \mu_i) \cdot \frac{1}{\operatorname{Var} Y_i} \cdot \frac{\partial \mu_i}{\partial \eta_i} \cdot x_{ij}$; avec le lien canonique, $\frac{\partial \mu_i}{\partial \eta_i} = A''(\theta_i) = \operatorname{Var} Y_i$ se simplifie.	fiche · S5
Convexité de $L_n = -\ell_n$ (canonique, p. 24) ; existence et unicité du Ridge logistique ; pas d'EMV en cas de séparation	$\nabla^2 L_n = \frac{1}{n}\sum_i A''(x_i^\top\beta)\, x_i x_i^\top$, donc $v^\top \nabla^2 L_n v = \frac{1}{n}\sum_i A''(x_i^\top\beta)(x_i^\top v)^2 \geq 0$ car $A'' = \operatorname{Var}$. Ridge : hessienne $\succeq 2\lambda I$ + coercivité ($-\ell_n \geq 0$). Séparation : $\ell_n(tb) \to 0 = \sup \ell_n$, jamais atteint.	fiche · TD3 · S5
IRLS : un pas de Newton est une régression par moindres carrés pondérés	$h^* = (X^\top W X)^{-1} X^\top (y - \mu)$, puis on factorise : $\beta_{k+1} = (X^\top W X)^{-1} X^\top W \big(X\beta_k + W^{-1}(y-\mu)\big) = (X^\top W X)^{-1} X^\top W z$.	fiche · S5
Intervalle de confiance asymptotique (lemme de Slutsky)	$\sqrt{n}\, I(\beta^*)^{1/2}(\hat\beta - \beta^*) \to \mathcal{N}(0, I_p)$; remplacer $I(\beta^*)$ par $I(\hat\beta)$ (consistance + continuité), conclure par Slutsky, puis isoler β^* dans $\lvert\cdot\rvert \leq q_{1-\alpha/2}$.	fiche · S5
Régression logistique en codage ± 1 : perte, gradient, hessienne, convexité	$\sigma(-z) = 1 - \sigma(z) \Rightarrow \mathbb{P}(Y = y \mid x) = \sigma(y\, x^\top\beta) \Rightarrow$ perte $f(z) = \log(1 + e^{-z})$; $f' = -\sigma(-z)$, $f'' = \sigma(1-\sigma) \in \,]0, \tfrac{1}{4}]$ $\Rightarrow 0 \preceq \nabla^2 \preceq \frac{1}{4n} X^\top X$.	fiche · S5
Conditions KKT d'un Lasso de GLM et $\lambda_{\max}$ (logistique, Poisson)	$0 \in \nabla L_n(\hat\beta) + \lambda\, \partial \left\lVert\hat\beta\right\rVert_1$ avec $\nabla L_n = \frac{1}{n} X^\top(\mu - y)$, lu coordonnée par coordonnée ; en $\hat\beta = 0$ seule l'inégalité reste : 0 est solution $\iff \lambda \geq \lVert\nabla L_n(0)\rVert_\infty$.	fiche · TD3 · S5
Inégalité oracle lente du Lasso logistique (TD3, exercice 2)	Inégalité de base avec $\hat R = R - \sum_j \beta_j V_j$; événement $\max_j \lvert V_j\rvert \leq \lambda/2$ (Hoeffding avec $b_i - a_i \leq c$, puis borne de l'union : $2p^{1 - A^2/(2c^2)}$) ; Hölder + triangulaire $\Rightarrow$ reste $\frac{3\lambda}{2}\lVert\beta\rVert_1 \leq 2\lambda \lVert\beta\rVert_1$.	fiche · TD3
Identité $\lVert Y - X\beta\rVert^2 = (\beta - \hat\beta^{\mathrm{MC}})^\top X^\top X (\beta - \hat\beta^{\mathrm{MC}}) + \left\lVert Y - X\hat\beta^{\mathrm{MC}}\right\rVert^2$	Ajouter et retrancher $X\hat\beta^{\mathrm{MC}}$; le terme croisé $2\hat r^\top X(\hat\beta^{\mathrm{MC}} - \beta)$ est nul car $X^\top \hat r = 0$ (équations normales). Pythagore.	fiche · S6
Bridge : convexe $\Leftrightarrow \gamma \geq 1$	$\gamma \geq 1$: $t \mapsto t^\gamma$ convexe et croissante sur $[0, \infty[$, composée avec $\lvert\cdot\rvert$, puis somme. $\gamma < 1$: e_1, e_2 dans la boule, leur milieu donne $2^{1-\gamma} > 1$.	fiche · S6
Règles orthonormées : Ridge, Lasso, $\ell 0$, LSLasso, relaxé, adaptatif	Découplage $\sum_j (\beta_j - b_j)^2 + \mathrm{cte}$; problème à une variable : Ridge, dérivée nulle ; Lasso, cas $\beta_j > 0$, $\beta_j < 0$, puis $\beta_j = 0 \Leftrightarrow \lvert b_j\rvert \leq \lambda/2$; $\ell 0$: comparer λ et b_j^2 ; seuil remplacé par $\lambda\omega_j/2$ (adaptatif) ou $\delta\lambda/2$ sur $\hat S_\lambda$ (relaxé).	fiche · S6
Dantzig : $\left\lVert\hat\beta^D\right\rVert_1 \leq \left\lVert\hat\beta^L\right\rVert_1$, et Dantzig = Lasso en design orthonormé	KKT $\Rightarrow \left\lVert 2X^\top(Y - X\hat\beta^L)\right\rVert_\infty \leq \lambda$, donc $\hat\beta^L \in D_\lambda$, où $\hat\beta^D$ minimise $\lVert\cdot\rVert_1$. Orthonormé : D_λ est la boîte $\lvert\beta_j - b_j\rvert \leq \lambda/2$; minimiser $\lvert\beta_j\rvert$ sur un intervalle donne le seuillage doux.	fiche · S6

Résultat	L'idée clé, à réciter	Où la revoir
Elastic net en design orthonormé : $\hat{\beta}_j^{e.n} = \mathrm{sgn}(b_j)(\lvert b_j\rvert - \lambda_1/2)_+/(1+\lambda_2)$	Regrouper les β^2, factoriser par $1+\lambda_2$, compléter le carré : Lasso à une variable de cible $b/(1+\lambda_2)$ et de paramètre $\lambda_1/(1+\lambda_2)$.	fiche · S6
Colonne dupliquée : infinité de solutions du Lasso ; partage égal de l'elastic net	Fusionner les deux copies ($\gamma_p + \gamma_{p+1}$) ne change pas l'ajustement et ne fait pas augmenter $\ell 1$ (inégalité triangulaire, égalité si même signe). Elastic net : $a^2 + (c-a)^2$ n'est minimal qu'en $a = c/2$.	fiche · S6 · partage
Group-Lasso : conditions de la diapo 87 et seuillage doux par groupe	$0 \in -2X_{(k)}^\top(Y - X\hat{\beta}) + \lambda\,\partial\lVert\cdot\rVert_2(\hat{\beta}_{(k)})$ bloc par bloc ; $\partial\lVert\cdot\rVert_2(0)$ = boule unité ⇒ bloc nul ssi $\lVert b_{(k)}\rVert \le \lambda/2$; sinon $\hat{\beta}_{(k)}$ a la direction de $b_{(k)}$ et $\lVert\hat{\beta}_{(k)}\rVert = \lVert b_{(k)}\rVert - \lambda/2$.	fiche · S6

Les pièges classiques

Les erreurs que l'on fait sous la pression de l'examen. Cachez la colonne de droite et dites pourquoi la phrase de gauche est fausse.

La phrase fausse (ou le geste risqué)	La bonne version
Appliquer une formule de seuil ou de KKT sans regarder la normalisation du critère.	Seuil λ ou $\lambda/2$, KKT avec ou sans facteur 2, λ ou $n\lambda$: écrivez d'abord le critère exact (voir les conventions).
« Quand $p > n$, on ne peut rien prédire. »	$\hat{\beta}^{\mathrm{MC}}$ n'est pas unique mais $X\hat{\beta}^{\mathrm{MC}} = PY$ l'est (les MCO interpolent toutefois : erreur $\sigma^2\,\mathrm{rg}(X)/n$, soit σ^2 si $\mathrm{rg}\,X = n$). Prédire $X\beta^*$ reste possible avec le Lasso, sans hypothèse sur les corrélations (inégalité oracle lente, si $\lVert\beta^*\rVert_1$ n'est pas trop grand) ; estimer β^* demande la parcimonie et une condition comme RE.
« La solution du Lasso est unique. »	Pas toujours (colonnes liées, par exemple deux colonnes identiques ; c'est possible dès que $p > n$). Mais, pour $\lambda > 0$, toutes les solutions ont le même ajustement $X\hat{\beta}$ et la même norme $\lVert\hat{\beta}\rVert_1$ (TD1).
« Le Ridge sélectionne des variables. »	Non : en design orthonormé, $b_j/(1+\lambda) \neq 0$ dès que $b_j \neq 0$. Il rétrécit tout, n'annule (presque) rien.
Choisir le modèle qui minimise l'erreur d'apprentissage.	Elle décroît toujours quand on ajoute des variables : pour un modèle fixé de dimension d, elle est optimiste de $2\sigma^2 d/n$ en moyenne (identité de Cp). D'où Cp/AIC, BIC, validation croisée.
Écrire la dérivée de $\lvert\beta_j\rvert$ en $\beta_j = 0$.	$\lvert\cdot\rvert$ n'est pas dérivable en 0 : $\partial\lvert\cdot\rvert(0) = [-1,1]$. C'est ce coin qui crée les zéros exacts, et qui donne l'inégalité des KKT.

La phrase fausse (ou le geste risqué)	La bonne version
« RE, c'est $X^\top X/n$ inversible. »	RE ne demande $\|X\delta\| > 0$ que pour les $\delta \neq 0$ du cône (pour tout J_0 de taille $\leq s$). Elle est compatible avec $p > n$: le noyau de X peut être non trivial s'il évite le cône.
« $\|\beta\|_0$ est une norme. »	$\|2\beta\|_0 = \|\beta\|_0$: ni homogène, ni convexe. D'où la difficulté combinatoire et la relaxation convexe en ℓ_1.
Énoncer BRT ou une inégalité oracle sans la probabilité.	Ce sont des résultats sur un événement : donnez λ (ou r), l'événement, et la probabilité (BRT : $1 - p^{1-A^2/8}$, ou $1 - 2p^{1-A^2/8}$ avec la queue du TD2 ; oracle lente et rapide : $1 - 2e^{-x}$; Lasso logistique : $1 - 2p^{1-A^2/(2c^2)}$).
Inégalité oracle rapide pour le Lasso pénalisé par $\lambda \|\beta\|_1$.	Dans la preuve de la professeure, l'estimateur est pénalisé par $2\lambda \|\beta\|_1$ avec le **même** λ que l'inégalité lente ; le reste vaut $\frac{9\lambda^2 s}{4\kappa^2} = \frac{18\sigma^2 s(x+\log M)}{\kappa^2 n}$.
$\mathbb{E}\|Z\|^2 = \operatorname{tr}\operatorname{Var} Z$ pour un vecteur Z non centré.	$\mathbb{E}\|Z\|^2 = \operatorname{tr}\operatorname{Var} Z + \|\mathbb{E}Z\|^2$ (c'est « biais² + variance »).
« L'intervalle de Wald est de niveau $1-\alpha$. »	Seulement asymptotiquement, à p fixé (normalité asymptotique + Slutsky) ; à n fini, le niveau réel peut être plus petit.
Mélanger les codages logistiques.	$y \in \{0,1\}$: perte $\log(1+e^\eta) - y\eta$. $\tilde{y} = 2y - 1 \in \{-1,1\}$: perte $\log(1 + e^{-\tilde{y}\eta})$. C'est la même perte, écrite autrement.
Pénaliser la constante dans le Lasso d'un GLM.	La constante n'est pas pénalisée (Cours5 enrichi p. 27). $\lambda_{\max}$ se calcule alors au point « constante seule », où $\hat{\mu}_i = \bar{y}$: en logistique ($0 < \bar{y} < 1$), $\lambda_{\max} = \frac{1}{n}\left\|X^\top(y - \bar{y}\mathbf{1})\right\|_\infty$.
« La hessienne logistique est $\succeq 0$, donc le critère est fortement convexe. »	$W_{ii} = \pi_i(1-\pi_i) \to 0$ quand $\left\|x_i^\top \beta\right\| \to \infty$: pas de courbure minimale uniforme ($\inf W_{ii} = 0$).
LSLasso : réutiliser le λ choisi pour le Lasso seul.	La validation croisée doit porter sur toute la procédure (Lasso puis MCO sur le support).
« Le bridge avec $\gamma < 1$ se calcule comme le Lasso. »	Pour $\gamma < 1$ la pénalité n'est pas convexe : minima locaux, aucune garantie qu'un algorithme trouve le minimum global.

Auto-test : les questions

Répondez de tête (ou par écrit), puis ouvrez la réponse. Notez le numéro des questions ratées et refaites-les le lendemain. Pour un quiz de synthèse supplémentaire : le quiz de la fiche réflexes.

Boîte à outils → la fiche

1. Énoncez l'inégalité de Hölder ℓ_1–ℓ_∞. À quel terme des preuves du Lasso l'applique-t-on, et qu'y gagne-t-on ?

Réponse

$\left|a^\top b\right| \le \|a\|_1 \, \|b\|_\infty$. On l'applique au terme croisé $\varepsilon^\top X\delta = (X^\top\varepsilon)^\top\delta \le \left\|X^\top\varepsilon\right\|_\infty \|\delta\|_1$: la partie aléatoire devient un *maximum* de p gaussiennes, contrôlable par la borne de l'union, et l'erreur une norme ℓ_1, que la pénalité sait compenser.

2. Pour $v = (2, 0, -1, 0, 2)$, calculez $\|v\|_0$, $\|v\|_1$, $\|v\|_2$, $\|v\|_\infty$, puis vérifiez $\|v\|_1 \le \sqrt{\|v\|_0}\,\|v\|_2$.

Réponse

$\|v\|_0 = 3$, $\|v\|_1 = 5$, $\|v\|_2 = \sqrt{4+1+4} = 3$, $\|v\|_\infty = 2$. Et $\sqrt{3}\times 3 \approx 5{,}20 \ge 5$: presque une égalité, car les valeurs absolues non nulles (2, 1, 2) sont assez proches ; il y aurait égalité si elles étaient toutes égales.

3. Vrai ou faux : « si $p > n$, la matrice $X^\top X$ n'est jamais inversible ». Justifiez en une ligne.

Réponse

Vrai : $\operatorname{rg}(X^\top X) = \operatorname{rg} X \le \min(n, p) = n < p$, et une matrice $p \times p$ est inversible ssi son rang vaut p.

4. A est symétrique, de valeurs propres 0, 1 et 4. Donnez les valeurs propres et le conditionnement de $A + 2I$, et la plus petite valeur de $v^\top(A+2I)v$ quand $\|v\| = 1$.

Réponse

Mêmes vecteurs propres, valeurs propres décalées de 2 : 2, 3 et 6. Conditionnement $6/2 = 3$ (A elle-même n'est pas inversible). Par Rayleigh, le minimum de $v^\top(A+2I)v$ sur la sphère unité vaut la plus petite valeur propre, 2 : c'est l'effet du Ridge.

5. Si $\operatorname{rg} X = p$, que valent $\operatorname{tr}\left(X(X^\top X)^{-1}X^\top\right)$ et $\operatorname{tr}\left(I_n - X(X^\top X)^{-1}X^\top\right)$? Quelle conséquence statistique en tire-t-on ?

Réponse

Par cyclicité, $\operatorname{tr}\left((X^\top X)^{-1}X^\top X\right) = \operatorname{tr} I_p = p$, et donc $n - p$ pour $I_n - P$. Conséquences : $\mathbb{E}\,\|P\varepsilon\|^2 = \sigma^2 p$ (chaque paramètre ajusté coûte σ^2), et $\mathbb{E}\left\|Y - X\hat\beta^{\mathrm{MC}}\right\|^2 = \mathbb{E}\,\|(I-P)\varepsilon\|^2 = \sigma^2(n-p)$, d'où l'estimateur sans biais $\hat\sigma^2 = \left\|Y - X\hat\beta^{\mathrm{MC}}\right\|^2/(n-p)$.

6. ε est centré, de covariance $\sigma^2 I_3$ avec $\sigma^2 = 2$, et $M = \begin{pmatrix} 1 & 5 & 0 \\ 0 & 2 & 7 \\ 3 & 0 & 4 \end{pmatrix}$. Que vaut $\mathbb{E}[\varepsilon^\top M \varepsilon]$? Faut-il que ε soit gaussien ?

Réponse

$\sigma^2 \operatorname{tr} M = 2 \times (1+2+4) = 14$; les termes hors diagonale ne comptent pas. La gaussianité est inutile : seuls $\mathbb{E}\varepsilon = 0$ et $\mathrm{Cov}(\varepsilon) = \sigma^2 I_3$ servent.

7. Loi de $X_j^\top \varepsilon$ quand $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$? Loi de $\frac{1}{n} X_j^\top \varepsilon$ quand $\|X_j\|^2 = n$?

Réponse

$X_j^\top \varepsilon \sim \mathcal{N}(0, \sigma^2 \|X_j\|^2)$ (combinaison linéaire de gaussiennes, variance par le sandwich). Avec $\|X_j\|^2 = n$: $\frac{1}{n} X_j^\top \varepsilon \sim \mathcal{N}(0, \sigma^2/n)$, d'écart-type $\sigma/\sqrt{n}$.

8. Énoncez la borne de Chernoff pour une gaussienne standard et refaites sa preuve en trois lignes.

Réponse

$\mathbb{P}(Z \geq t) \leq e^{-t^2/2}$ pour $t \geq 0$. (1) $\mathbb{E}[e^{\theta Z}] = e^{\theta^2/2}$ en complétant le carré. (2) Markov : $\mathbb{P}(Z \geq t) = \mathbb{P}(e^{\theta Z} \geq e^{\theta t}) \leq e^{\theta^2/2 - \theta t}$ pour $\theta > 0$. (3) On prend $\theta = t$. Par symétrie, $\mathbb{P}(|Z| \geq t) \leq 2e^{-t^2/2}$.

9. Pourquoi a-t-on le droit d'appliquer la borne de l'union aux p variables $X_j^\top \varepsilon$, alors qu'elles sont corrélées entre elles ?

Réponse

Parce que $\mathbb{P}(A_1 \cup \cdots \cup A_p) \leq \sum_j \mathbb{P}(A_j)$ est vraie pour **n'importe quels** événements, sans hypothèse d'indépendance. On paie seulement un facteur p, que le choix $t^2 = 2(\log p + x)$ compense.

10. Avec $p = 1000$ variables et $x = 3$, calculez le seuil $\sqrt{2(\log p + x)}$ et la probabilité garantie que tous les $|Z_j|$ restent en dessous.

Réponse

$\log 1000 \approx 6{,}91$, donc le seuil vaut $\sqrt{2 \times 9{,}91} \approx 4{,}45$. La probabilité est au moins $1 - 2e^{-3} \approx 0{,}90$.

11. Le théorème BRT du Cours 3 annonce une probabilité $1 - p^{1-A^2/8}$, le TD2 annonce $1 - 2p^{1-A^2/8}$. D'où vient la différence ?

Réponse

De la version de la queue gaussienne. Dans les deux cas, chaque variable donne $t = \frac{A}{2}\sqrt{\log p}$, donc $e^{-t^2/2} = p^{-A^2/8}$, puis l'union multiplie par p. Le Cours 3 utilise la version fine $\mathbb{P}(|Z| \geq t) \leq e^{-t^2/2}$; le TD2 utilise $2e^{-t^2/2}$, d'où le facteur 2.

12. Énoncez l'inégalité de Hoeffding. Pour des réponses $Y_i \in \{0,1\}$, qu'est-ce qui joue le rôle de σ ?

Réponse

Variables indépendantes $X_i \in [a_i, b_i]$, $S = \sum_i (X_i - \mathbb{E}X_i)$: $\mathbb{P}(|S| \geq x) \leq 2\exp\left(-2x^2 / \sum_i (b_i - a_i)^2\right)$. C'est une queue gaussienne de variance $\sum_i (b_i - a_i)^2/4$: pour $Y_i \in \{0,1\}$, la demi-longueur $\frac{1}{2}$ joue le rôle de l'écart-type.

13. $\xi \sim \mathcal{E}(1)$. Calculez $\mathbb{E}[(\xi - \log 20)_+]$. À quoi sert ce calcul dans le TD1 ?

Réponse

$\mathbb{E}[(\xi - c)_+] = e^{-c}$, donc $e^{-\log 20} = \frac{1}{20} = 0{,}05$. Dans le TD1 (exercice 3), avec $c = \log(1/\Pi_m)$, on obtient $\mathbb{E}[(\xi_m - c)_+] = \Pi_m$; comme $\sum_m \Pi_m = 1$, on peut sommer sur tous les modèles : c'est ce qui contrôle le modèle $\hat{m}$ choisi avec les données.

14. Vrai ou faux : « une fonction strictement convexe sur $\mathbb{R}$ a toujours un unique minimiseur ».

Réponse

Faux : $x \mapsto e^x$ est strictement convexe mais n'atteint jamais sa borne inférieure 0. La stricte convexité donne *au plus* un minimiseur ; l'existence demande autre chose (coercivité, ou un ensemble fermé borné). Même phénomène pour la log-vraisemblance logistique négative avec des données séparables.

15. Montrez en une ligne que le Lasso ($\lambda > 0$) a au moins une solution, même si $p > n$. En a-t-il toujours une seule ?

Réponse

Le critère est continu et minoré par $\lambda \|\beta\|_1 \geq \lambda \|\beta\|_2 \to +\infty$: il est coercif, donc atteint son minimum. Mais il n'est pas strictement convexe en général (par exemple si $p > n$ ou avec deux colonnes égales) : l'unicité n'est pas garantie. Ce qui est commun à toutes les solutions (TD1, exercice 2) : les valeurs ajustées $X\hat{\beta}$ et la norme $\left\|\hat{\beta}\right\|_1$.

16. Énoncez le lemme de Slutsky. Quelle hypothèse ne faut-il pas oublier, et à quoi sert-il dans le cours ?

Réponse

Si $X_n \to X$ en loi et $Y_n \to c$ en probabilité, alors $X_n + Y_n \to X + c$, $Y_n X_n \to cX$ et $X_n / Y_n \to X/c$ (si $c \neq 0$), en loi. L'hypothèse clé : la limite c de Y_n est une **constante**. Il sert à remplacer $I(\beta^*)$, inconnue, par $I(\hat{\beta})$ dans la normalité asymptotique, pour construire des intervalles de confiance calculables (séance 5).

17. Information de Fisher d'une observation de Bernoulli(p) ? Déduisez-en un intervalle de confiance asymptotique à 95 % pour p, avec $n = 400$ et $\hat{p} = 0{,}2$.

Réponse

$I(p) = \frac{1}{p(1-p)}$ pour une observation ; l'information totale des n observations est $nI(p)$, donc $\hat{p} \approx \mathcal{N}\left(p, \frac{p(1-p)}{n}\right)$. Intervalle de Wald : $\hat{p} \pm 1{,}96\sqrt{\hat{p}(1-\hat{p})/n} = 0{,}2 \pm 1{,}96 \times 0{,}02 = 0{,}2 \pm 0{,}039$, soit environ $[0{,}161;\ 0{,}239]$.

18. Modèle linéaire correct à $d = 10$ paramètres, ajusté par moindres carrés sur $n = 50$ observations. Erreur d'apprentissage moyenne ? Erreur moyenne sur de nouvelles données (même X) ? Que corrigent Cp et AIC ?

Réponse

Apprentissage : $\sigma^2(1 - 10/50) = 0{,}8\,\sigma^2$. Nouvelles données : $\sigma^2(1 + 10/50) = 1{,}2\,\sigma^2$. Cp et AIC ajoutent l'écart moyen entre les deux, l'optimisme $2\sigma^2 d/n = 0{,}4\,\sigma^2$.

Séance 1 et TD1 → la fiche

1. Écrivez le modèle linéaire du cours avec toutes ses hypothèses. Sur quoi porte l'espérance $\mathbb{E}$?

Réponse

$Y = X\beta^* + \varepsilon$, avec $X \in \mathbb{R}^{n \times p}$ déterministe, $\beta^* \in \mathbb{R}^p$ inconnu, $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$ (composantes indépendantes) et σ connu. $\mathbb{E}$ porte sur le bruit seulement : X est fixée, elle se comporte comme une constante dans les calculs.

2. Retrouvez les équations normales de deux façons différentes.

Réponse

(i) Par le calcul : $\nabla \|Y - X\beta\|^2 = -2X^\top(Y - X\beta) = 0$. (ii) Par la géométrie : $X\hat{\beta}$ est la projection de Y sur $\mathrm{Im}\, X$, donc le résidu est orthogonal à chaque colonne, $X_j^\top(Y - X\hat{\beta}) = 0$ pour tout j. Les deux donnent $X^\top X\hat{\beta} = X^\top Y$.

3. Vrai ou faux : quand $p > n$, les moindres carrés n'ont pas de solution.

Réponse

Faux. La projection de Y sur $\mathrm{Im}\, X$ existe toujours. Il y a même une infinité de solutions $\hat{\beta} + v$, $v \in \mathrm{Ker}\, X$ (de dimension $\geq p - n$), qui ont toutes le même ajustement $X\hat{\beta} = PY$. Ce qui est perdu, c'est l'unicité de $\hat{\beta}$ et l'identifiabilité de β^*.

4. Montrez que $\mathrm{Ker}(X^\top X) = \mathrm{Ker}\, X$. Qu'en déduit-on pour $\mathrm{rg}(X^\top X)$?

Réponse

Si $Xv = 0$, alors $X^\top X v = 0$. Réciproquement, si $X^\top X v = 0$, alors $0 = v^\top X^\top X v = \|Xv\|^2$, donc $Xv = 0$. Par le théorème du rang (les deux matrices ont p colonnes), $\mathrm{rg}(X^\top X) = p - \dim \mathrm{Ker}\, X = \mathrm{rg}\, X$.

5. On a $n = 50$ et $\sigma^2 = 2$. Que vaut l'erreur de prédiction moyenne des MCO si $p = 10$ (rang plein) ? Et si $p = 80$? Pourquoi ne dépend-elle pas de β^* ?

Réponse

Avec $p = 10$: $\sigma^2\, \mathrm{rg}(X)/n = 2 \times 10/50 = 0{,}4$. Avec $p = 80 > n$: $\mathrm{rg}\, X \leq 50$, typiquement 50, d'où une erreur de $2 \times 50/50 = 2 = \sigma^2$; les MCO interpolent ($X\hat\beta = Y$). L'erreur vaut $P\varepsilon$, du bruit pur : les MCO sont sans biais et toute l'erreur est de la variance, d'où l'absence de β^*.

6. Montrez que $\mathbb{E}\left\|Y - X\hat\beta^{\mathrm{MC}}\right\|^2 = \sigma^2(n - \mathrm{rg}\, X)$. Quel estimateur de σ^2 en déduit-on ?

Réponse

$Y - X\hat\beta = (I - P)Y = (I - P)\varepsilon$, car $(I - P)X\beta^* = 0$. Par l'astuce de la trace, $\mathbb{E}\,\|(I - P)\varepsilon\|^2 = \sigma^2\, \mathrm{tr}(I - P) = \sigma^2(n - \mathrm{rg}\, X)$. On en déduit l'estimateur sans biais $\hat\sigma^2 = \left\|Y - X\hat\beta^{\mathrm{MC}}\right\|^2 / (n - \mathrm{rg}\, X)$, qui n'a plus de sens si $\mathrm{rg}\, X = n$ (résidus nuls).

7. Deux colonnes centrées et normalisées ($\|X_j\|^2 = n$) ont une corrélation empirique ρ. Que valent les valeurs propres de $X^\top X$ et la variance de $\hat\beta_1^{\mathrm{MC}}$? Que se passe-t-il pour $\rho = 0{,}99$?

Réponse

$X^\top X = n \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix}$ a pour valeurs propres $n(1 + \rho)$ et $n(1 - \rho)$, et $\mathrm{Var}(\hat\beta_1^{\mathrm{MC}}) = \frac{\sigma^2}{n(1-\rho^2)}$. Pour $\rho = 0{,}99$, c'est environ 50 fois σ^2/n, et le conditionnement vaut $\frac{1+\rho}{1-\rho} = 199$.

8. Donnez le Ridge pour le critère $\|Y - X\beta\|_n^2 + \lambda\|\beta\|^2$, puis pour le critère $\|Y - X\beta\|^2 + \lambda\|\beta\|^2$.

Réponse

Normalisé : $(X^\top X + n\lambda I_p)^{-1} X^\top Y$. Non normalisé (formule de la diapo et du TD1) : $(X^\top X + \lambda I_p)^{-1} X^\top Y$. Le $\frac{1}{n}$ devant l'ajustement se reporte sur λ.

9. Pourquoi $X^\top X + \lambda I_p$ est-elle inversible pour tout $\lambda > 0$, même si $p > n$?

Réponse

Pour $v \neq 0$, $v^\top(X^\top X + \lambda I_p)v = \|Xv\|^2 + \lambda\|v\|^2 \geq \lambda\|v\|^2 > 0$. De façon équivalente, ses valeurs propres sont $\mu_j + \lambda \geq \lambda > 0$, car $\mu_j = \|Xv_j\|^2 \geq 0$, même quand certaines μ_j sont nulles.

10. $X^\top X$ a pour valeurs propres 9 et 1, et $\lambda = 1$ (critère non normalisé). Par quel facteur le Ridge multiplie-t-il la composante des MCO dans chaque direction propre ? Que devient le conditionnement ?

Réponse

Les facteurs sont $\frac{\mu_j}{\mu_j+\lambda}$: $\frac{9}{10} = 0{,}9$ et $\frac{1}{2} = 0{,}5$. La direction la moins bien mesurée est la plus rétrécie. Le conditionnement passe de $9/1 = 9$ à $(9+1)/(1+1) = 5$.

11. Donnez le biais au carré et la variance du Ridge $(X^\top X + \lambda I_p)^{-1} X^\top Y$ dans la base propre de $X^\top X$. Comment varient-ils avec λ ?

Réponse

Avec $\theta_j = v_j^\top \beta^*$, la direction v_j a un biais $-\frac{\lambda}{\mu_j+\lambda}\theta_j$ et une variance $\frac{\sigma^2\mu_j}{(\mu_j+\lambda)^2}$. En sommant : $B^R(\lambda) = \sum_j \frac{\lambda^2\theta_j^2}{(\mu_j+\lambda)^2}$, croissant de 0 (si tous les $\mu_j > 0$) vers $\|\beta^*\|^2$; $V^R(\lambda) = \sigma^2 \sum_j \frac{\mu_j}{(\mu_j+\lambda)^2}$, décroissant vers 0. Le risque est leur somme.

12. Ridge en dimension 1, pour le critère $\sum_i (y_i - x_i\beta)^2 + \lambda\beta^2$, avec $S = \sum_i x_i^2$: que valent l'estimateur, son biais, sa variance, et le λ optimal ?

Réponse

$\hat\beta(\lambda) = \frac{\sum_i x_i y_i}{S+\lambda}$; biais $-\frac{\lambda\beta^*}{S+\lambda}$; variance $\frac{\sigma^2 S}{(S+\lambda)^2}$. La dérivée du risque est $R'(\lambda) = \frac{2S(\lambda\beta^{*2} - \sigma^2)}{(S+\lambda)^3}$, d'où $\lambda^* = \sigma^2/\beta^{*2}$ (si $\beta^* \neq 0$) : plus le bruit est fort devant le signal, plus il faut rétrécir.

13. Comment montre-t-on que le Ridge est aussi l'unique solution des moindres carrés sur la boule $\{\|\beta\| \leq \left\|\hat\beta^R(\lambda)\right\|\}$?

Réponse

Il existe une solution $\tilde\beta$ (fonction continue sur un compact). Le Ridge est admissible, donc $\left\|Y - X\tilde\beta\right\|^2 \leq \left\|Y - X\hat\beta^R\right\|^2$; et $\lambda\left\|\tilde\beta\right\|^2 \leq \lambda\left\|\hat\beta^R\right\|^2$. En additionnant, $\tilde\beta$ minimise le critère pénalisé, dont $\hat\beta^R$ est l'unique minimiseur : $\tilde\beta = \hat\beta^R$.

14. Énoncez l'identité d'optimisme. Pour quels modèles est-elle valable, et quelle pénalité en déduit-on ?

Réponse

$\mathbb{E}\left\|X\hat\beta_m - X\beta^*\right\|_n^2 + \sigma^2 = \mathbb{E}\left\|Y - X\hat\beta_m\right\|_n^2 + \frac{2\sigma^2 d}{n}$, pour un modèle m de dimension d **fixé** à l'avance (pas choisi avec les données). L'erreur d'apprentissage sous-estime l'erreur de test de $2\sigma^2 d/n$ en moyenne, d'où la pénalité de Cp et d'AIC, $2\sigma^2 \|\beta\|_0 / n$.

15. On a $n = 100$ et $\sigma^2 = 1$. Passer de 3 à 4 variables fait baisser l'erreur d'apprentissage $\left\|Y - X\hat{\beta}\right\|_n^2$ de $0{,}03$. AIC ajoute-t-il la variable ? Et BIC ?

Réponse

Le prix AIC d'une variable est $2\sigma^2/n = 0{,}02 < 0{,}03$: AIC l'ajoute. Le prix BIC est $\sigma^2 \log(100)/100 \approx 0{,}046 > 0{,}03$: BIC la refuse.

16. Pourquoi AIC ne retrouve-t-il pas le vrai support, même avec beaucoup de données, alors que BIC y parvient ? Lequel préférer pour prédire ?

Réponse

Une variable inutile, ajoutée à un modèle qui contient déjà les vraies variables, fait baisser la somme des carrés des résidus de $\sigma^2 Z^2$, avec $Z \sim \mathcal{N}(0,1)$. AIC l'accepte si $Z^2 > 2$, avec probabilité $\approx 0{,}157$ quel que soit n. BIC l'accepte si $Z^2 > \log n$, avec une probabilité qui tend vers 0. Pour prédire, on préfère AIC : il estime sans biais l'erreur de test, et une variable inutile ne coûte qu'environ σ^2/n.

17. Énoncez l'hypothèse (S) et l'erreur de l'oracle. Pourquoi parle-t-on d'« oracle » ?

Réponse

(S) : il existe s tel que $|\mathcal{A}^*| \leq s$, avec $s = o(n)$. Les MCO restreints aux colonnes de $\mathcal{A}^*$ ont une erreur $\mathbb{E}\left\|X\hat{\beta}^{MCR} - X\beta^*\right\|_n^2 = \sigma^2 |\mathcal{A}^*|/n \leq \sigma^2 s/n$. On parle d'oracle parce que cet estimateur utilise $\mathcal{A}^*$, qui est inconnu : ce n'est pas un vrai estimateur, c'est la référence à atteindre.

18. Donnez les deux définitions du Lasso. Comment passe-t-on de λ à t ?

Réponse

Forme contrainte : $\arg\min \|Y - X\beta\|_n^2$ sous $\|\beta\|_1 \leq t$. Forme pénalisée : $\hat{\beta}^L(\lambda) \in \arg\min\{\|Y - X\beta\|_n^2 + \lambda \|\beta\|_1\}$. À λ fixé, on prend $t = \left\|\hat{\beta}^L(\lambda)\right\|_1$. La correspondance dépend des données : on ne peut pas convertir λ en t une fois pour toutes.

19. Donnez deux raisons pour lesquelles la pénalité ℓ_1 produit des zéros exacts, contrairement à la pénalité ℓ_2.

Réponse

(i) Sur une coordonnée, $|\beta_j|$ garde une pente ± 1 jusqu'en 0, alors que β_j^2 a une dérivée nulle en 0 : seule la première pousse les petits coefficients jusqu'à 0. (ii) Géométriquement, la boule ℓ_1 a des coins sur les axes, et l'ellipse de l'ajustement la touche souvent en un coin ; le disque ℓ_2 n'a pas de coin.

20. Pourquoi deux solutions du Lasso ont-elles les mêmes valeurs ajustées ? Pourquoi ont-elles alors la même norme ℓ_1 ?

Réponse

Leur milieu est encore une solution. Si les ajustements différaient sur une ligne, la stricte convexité de $x \mapsto x^2$ rendrait l'ajustement du milieu strictement meilleur, sans que la pénalité augmente (inégalité triangulaire) : le milieu ferait strictement mieux que le minimum, ce qui est absurde. Avec le même $X\hat{\beta}$, les deux solutions ont le même f_0, donc la même pénalité $\min f - f_0$; on divise par $\lambda > 0$.

21. Quel rayon M_λ rend le Lasso contraint équivalent au Lasso pénalisé ? Pourquoi l'argument échoue-t-il pour $\lambda = 0$?

Réponse

$M_\lambda = N_\lambda$, la norme ℓ_1 commune à toutes les solutions pénalisées ; les deux ensembles de solutions sont alors égaux. Pour $\lambda = 0$, on ne peut pas diviser par λ : les solutions des MCO $\hat{\beta}^{\mathrm{MC}} + v$, $v \in \operatorname{Ker} X$, ont des normes ℓ_1 différentes.

22. TD1, exercice 3 : que vaut le risque d'un modèle fixé ? Pourquoi l'oracle peut-il différer du vrai modèle ?

Réponse

$R(\hat{f}_m) = \|(I_n - P_{S_m})f^*\|^2 + \sigma^2 d_m$ (biais² + variance). Garder une variable coûte σ^2 de variance ; si son effet est plus petit, mieux vaut l'oublier. Par exemple, avec des colonnes orthonormées, $\beta^* = (3;\, 0{,}1)$ et $\sigma^2 = 1$, le modèle $\{1\}$ (risque $1{,}01$) bat le vrai modèle $\{1, 2\}$ (risque 2).

23. TD1, exercice 3 : énoncez la pénalité et l'inégalité oracle. Que devient-elle si $\log(1/\Pi_m) \le C d_m$?

Réponse

On minimise $C(m) = \left\|Y - \hat{f}_m\right\|^2 + \sigma^2 \mathrm{pen}(m)$, avec $\mathrm{pen}(m) = K\left(\sqrt{d_m} + \sqrt{2\log(1/\Pi_m)}\right)^2$, $K > 1$, $\Pi_m \in]0, 1]$ et $\sum_m \Pi_m = 1$. Alors $\mathbb{E}\left\|\hat{f}_{\hat{m}} - f^*\right\|^2 \le C'_K \min_m\{R(\hat{f}_m) + \sigma^2 \log(\Pi_m^{-1}) + \sigma^2\}$, où C'_K ne dépend que de K. Si $\log(1/\Pi_m) \le C d_m$ pour tout m, les deux derniers termes sont absorbés par le risque : $\sigma^2 \log(\Pi_m^{-1}) \le C\sigma^2 d_m \le C R(\hat{f}_m)$, et $\sigma^2 \le R(\hat{f}_m)$ car $d_m \ge 1$ ($d_m = 0$ forcerait $\Pi_m = 1$, donc des poids nuls pour les autres modèles). D'où $\mathbb{E}\left\|\hat{f}_{\hat{m}} - f^*\right\|^2 \le C'_K(2 + C) R(\hat{f}_{m_0})$: l'oracle à une constante près.

24. TD1, exercice 3 : pourquoi ne peut-on pas écrire $\mathbb{E}U_{\hat{m}} \le d_{\hat{m}}$? Que fait-on à la place ?

Réponse

Parce que $\hat{m}$ dépend du bruit : il est choisi justement là où le bruit projeté est grand, donc $U_{\hat{m}}$ ne suit pas une loi du χ^2. On borne par le pire cas, $\max_m \le \sum_m (\cdot)_+$; on contrôle chaque modèle fixé par la concentration gaussienne ; et les poids Π_m, de somme 1, rendent la somme finie. C'est une borne de l'union pondérée.

25. Vrai ou faux : pour tout vecteur aléatoire V, $\mathbb{E}\,\|V\|^2 = \operatorname{tr}\operatorname{Var}(V)$.

Réponse

Faux, sauf si V est centré : $\mathbb{E}\,\|V\|^2 = \operatorname{tr}\operatorname{Var}(V) + \|\mathbb{E}V\|^2$. Ce qui est toujours vrai, c'est $\mathbb{E}\,\|V - \mathbb{E}V\|^2 = \operatorname{tr}\operatorname{Var}(V)$. Le corrigé officiel du TD1 se trompe sur ce point.

Séance 2 — le Lasso de près → la fiche

1. Écrivez le critère du Lasso dans la convention de la Séance 2. Que deviennent les conditions KKT et $\lambda_{\max}$ si l'on remplace $\|Y - X\beta\|^2$ par $\frac{1}{2}\|Y - X\beta\|^2$?

Réponse

$F(\beta) = \|Y - X\beta\|^2 + \lambda\|\beta\|_1$, sans $\frac{1}{n}$. Avec $\frac{1}{2}$, le facteur 2 disparaît partout : $X_j^\top(Y - X\hat\beta) = \lambda\,\mathrm{sgn}(\hat\beta_j)$ si $\hat\beta_j \neq 0$, $\left|X_j^\top(Y - X\hat\beta)\right| \leq \lambda$ sinon, et $\lambda_{\max} = \left\|X^\top Y\right\|_\infty$. En design orthonormé, le seuil devient λ au lieu de $\lambda/2$.

2. Que vaut le Lasso pour $\lambda = 0$? Est-il toujours bien défini ?

Réponse

Le critère devient $\|Y - X\beta\|^2$: ce sont les moindres carrés. Si $X^\top X$ est inversible, la solution est unique ($\hat\beta^{\mathrm{MC}}$) et toutes les variables sont en général sélectionnées. Si $p > n$, il y a une infinité de solutions : le Lasso à $\lambda = 0$ n'est pas un estimateur bien défini.

3. Montrez en une ligne que $\left\|\hat\beta^L(\lambda)\right\|_1 \leq \|Y\|^2/\lambda$. Qu'en déduit-on quand $\lambda \to \infty$?

Réponse

$\hat\beta$ minimise F, donc $\lambda\left\|\hat\beta\right\|_1 \leq F(\hat\beta) \leq F(0) = \|Y\|^2$. Ainsi $\left\|\hat\beta^L(\lambda)\right\|_1 \to 0$: le Lasso tend vers 0. (Le résultat plus fort, nul **exactement** dès $\lambda \geq 2\left\|X^\top Y\right\|_\infty$, vient des KKT.)

4. Bruit $\mathcal{N}(0, \sigma^2 I_n)$ avec $\sigma = 2$; a priori : les β_j sont indépendants, de densité $\frac{a}{2}e^{-a|\beta_j|}$ avec $a = 0{,}5$. Le MAP est un Lasso $\|Y - X\beta\|^2 + \lambda\|\beta\|_1$: que vaut λ ?

Réponse

$-\log\pi(\beta \mid Y) = \frac{1}{2\sigma^2}\|Y - X\beta\|^2 + a\|\beta\|_1 + C$; en multipliant par $2\sigma^2$, on obtient $\lambda = 2\sigma^2 a = 2 \times 4 \times 0{,}5 = 4$.

5. Quel a priori fait du Ridge $\|Y - X\beta\|^2 + \lambda \|\beta\|^2$ un MAP, et avec quel λ ? Que se passe-t-il quand l'a priori devient « plat » ?

Réponse

Les β_j indépendants de loi $\mathcal{N}(0, \tau^2)$: $-\log \pi(\beta) = \frac{1}{2\tau^2} \|\beta\|^2 + \text{cte}$, d'où $\lambda = \sigma^2/\tau^2$. Quand $\tau \to \infty$ (a priori plat), $\lambda \to 0$: on retrouve les moindres carrés.

6. Vrai ou faux : « sous l'a priori de Laplace, le vecteur β a des coordonnées nulles ; c'est pour cela que le Lasso est parcimonieux ».

Réponse

Faux. La loi de Laplace a une densité : un tirage n'a presque sûrement aucune coordonnée nulle. La parcimonie vient du **mode** de la loi a posteriori (le MAP), car la densité est anguleuse en 0.

7. Design orthogonal, convention de la Séance 2, $\lambda = 3$ et $b = X^\top Y = (2;\ -1{,}2;\ 1{,}5;\ -4)$. Que vaut $\hat{\beta}^L$?

Réponse

Seuil $\lambda/2 = 1{,}5$: $\hat{\beta}^L = (0{,}5;\ 0;\ 0;\ -2{,}5)$. La troisième coordonnée est exactement au seuil ($|1{,}5| \leq 1{,}5$) : elle est nulle.

8. Design orthogonal, $b = (-5;\ 2;\ 0{,}5)$. Que vaut $\lambda_{\max}$? Dans quel ordre, et pour quelles valeurs de λ, les variables entrent-elles ? Que vaut $\hat{\beta}^L$ pour $\lambda = 3$?

Réponse

$\lambda_{\max} = 2 \times 5 = 10$. La variable 1 entre en $\lambda = 10$ (avec un coefficient négatif), la variable 2 en $\lambda = 4$, la variable 3 en $\lambda = 1$. Pour $\lambda = 3$ (seuil 1,5) : $\hat{\beta}^L = (-3{,}5;\ 0{,}5;\ 0)$.

9. Retrouvez le seuillage doux $\arg\min_\beta \{(\beta - b)^2 + \lambda\,|\beta|\}$ en deux lignes avec le sous-différentiel.

Réponse

$\hat{\beta}$ est optimal $\Leftrightarrow 0 \in 2(\hat{\beta} - b) + \lambda\, \partial\,|\cdot|\,(\hat{\beta})$. Si $\hat{\beta} \neq 0$: $\hat{\beta} = b - \frac{\lambda}{2}\,\mathrm{sgn}(\hat{\beta})$, ce qui n'est cohérent que si $|b| > \lambda/2$, et alors $\mathrm{sgn}(\hat{\beta}) = \mathrm{sgn}(b)$. Si $\hat{\beta} = 0$: $0 \in -2b + \lambda[-1, 1]$, soit $|b| \leq \lambda/2$. D'où $\hat{\beta} = \mathrm{sgn}(b)(|b| - \lambda/2)_+$.

10. Que vaut $\partial\,|\cdot|\,(0)$? Pourquoi la pente $g = 1{,}2$ n'est-elle pas un sous-gradient de $|\cdot|$ en 0 ?

Réponse

$\partial\,|\cdot|\,(0) = [-1, 1]$. Pour $g = 1{,}2$, la condition $|v| \geq 0 + g\,v$ échoue en $v = 1$: $1 \geq 1{,}2$ est faux. La droite de pente 1,2 passe au-dessus du « V » à droite de 0.

11. $X_1 = (1,1,0,0)^\top$, $X_2 = (0,1,1,0)^\top$, $Y = (4,2,1,0)^\top$ **et** $\lambda = 4$ **(convention de la Séance 2). Le vecteur** $(2,\ 0)$ **est-il solution du Lasso ? Et** $(2{,}5;\ 0)$ **?**

Réponse

Pour $(2,0)$: $r = Y - 2X_1 = (2,0,1,0)$. Variable 1 active : $2X_1^\top r = 2 \times 2 = 4 = \lambda\,\mathrm{sgn}(2)$ ✓. Variable 2 inactive : $2\left|X_2^\top r\right| = 2 \times 1 = 2 \leq 4$ ✓. C'est la solution. Pour $(2{,}5;0)$: $r = (1{,}5;\ -0{,}5;\ 1;\ 0)$ et $2X_1^\top r = 2 \neq 4$: l'égalité échoue, ce n'est pas la solution.

12. On sait que $X^\top Y = (4;\ -9;\ 2)$ **et** $n = 10$**. Que vaut** $\lambda_{\max}$ **avec** $\|Y - X\beta\|^2 + \lambda\|\beta\|_1$ **? avec** $\frac{1}{2}\|Y - X\beta\|^2 + \lambda\|\beta\|_1$ **? avec** $\frac{1}{n}\|Y - X\beta\|^2 + \lambda\|\beta\|_1$ **? Quelle variable entre en premier, et avec quel signe ?**

Réponse

$2 \times 9 = 18\,;\ 9\,;\ \frac{2}{10} \times 9 = 1{,}8$. La variable 2 entre en premier ($|-9|$ est le plus grand), avec un coefficient **négatif** : une variable active a le signe de sa corrélation avec le résidu, qui vaut presque Y juste sous $\lambda_{\max}$.

13. À l'optimum, deux variables sont actives, avec $\hat\beta_1 > 0$ **et** $\hat\beta_3 < 0$**. Que valent** $2X_1^\top r$ **et** $2X_3^\top r$ **(**$r = Y - X\hat\beta$**) ? Que vérifient les autres variables ?**

Réponse

Sans aucun calcul : $2X_1^\top r = \lambda$ et $2X_3^\top r = -\lambda$ (les actives sont au plafond, avec le signe de leur coefficient). Les autres vérifient $2\left|X_j^\top r\right| \leq \lambda$.

14. Pourquoi le chemin $\lambda \mapsto \hat\beta^L(\lambda)$ **est-il linéaire par morceaux ? Où sont les coudes ?**

Réponse

Tant que l'ensemble actif A et les signes s_A ne changent pas, l'égalité des KKT donne $\hat\beta_A(\lambda) = (X_A^\top X_A)^{-1}(X_A^\top Y - \frac{\lambda}{2}s_A)$, affine en λ. Un coude apparaît quand une variable inactive atteint $2\left|X_j^\top r\right| = \lambda$ (elle entre) ou quand un coefficient actif atteint 0 (il sort).

15. Vrai ou faux : « le nombre de variables actives du Lasso décroît toujours quand λ **augmente ».**

Réponse

Faux en général : quand λ diminue, une variable active peut ressortir (son coefficient repasse par 0). C'est vrai en design orthogonal, où la variable j est active exactement pour $\lambda < 2\,|b_j|$.

16. Qu'est-ce qui est unique dans le Lasso quand $\lambda > 0$? Illustrez avec deux colonnes identiques $X = (u \;\; u)$, $\|u\| = 1$, $u^\top Y = 5$ et $\lambda = 4$.

Réponse

Les valeurs ajustées $X\hat\beta$ et la norme $\left\|\hat\beta\right\|_1$. Ici l'ajustement $X(a,c)^\top = (a+c)u$ ne dépend que de $t = a + c$, et $|a| + |c| \geq |t|$ avec égalité si et seulement si a et c sont de même signe (ou nuls) : on se ramène au Lasso à une variable de colonne u, d'où $t^* = \operatorname{sgn}(5)(5 - 4/2)_+ = 3$. Les solutions sont tous les (a, c) avec $a + c = 3$, $a, c \geq 0$ (le segment $\{(3\alpha, 3(1-\alpha)) : \alpha \in [0,1]\}$) : une infinité, mais toutes avec $X\hat\beta = 3u$ et $\left\|\hat\beta\right\|_1 = 3$.

17. Sur quoi repose l'algorithme LARS ? D'où vient son nom ? Quel est son défaut principal ?

Réponse

Sur les KKT, c'est-à-dire sur les corrélations entre le résidu et les variables : on part de $\lambda_{\max}$, on fait entrer la variable la plus corrélée, et on avance en gardant les corrélations des actives égales. Le résidu fait alors le même angle avec toutes les colonnes actives : *Least Angle Regression*. Défaut : avec des variables très corrélées, il en garde une par groupe et écarte les autres (diapo 28).

18. Classez prédiction, estimation et sélection de la plus facile à la plus difficile, et donnez un exemple d'estimateur qui prédit bien mais estime mal.

Réponse

Prédiction, puis estimation, puis sélection. Avec $X_1 \approx X_2$ et $\beta^* = (1, 0)$, l'estimateur $\hat\beta = (0, 1)$ a une erreur de prédiction $\|X_2 - X_1\|_n^2$ minuscule, mais $\left\|\hat\beta - \beta^*\right\|_1 = 2$ et il sélectionne la mauvaise variable.

19. Énoncez les trois inégalités de sparsité de la diapo 30. Que représentent C et $L(n,p)$?

Réponse

Sous (S) d'indice s : $\mathbb{E}\left\|X\beta^* - X\hat\beta\right\|_n^2 \leq Cs\frac{L(n,p)}{n}$, $\mathbb{E}\left\|\hat\beta - \beta^*\right\|_1 \leq Cs\sqrt{\frac{L(n,p)}{n}}$, $\mathbb{E}\left\|\hat\beta - \beta^*\right\|_\infty \leq C\sqrt{\frac{L(n,p)}{n}}$. $C > 0$ est une constante indépendante de n, p, s ; $L(n,p)$ dépend au plus logarithmiquement de n et p, typiquement $\log p$.

20. $n = 400$, $p = 10^5$, $s = 8$, $\sigma = 1$ et $L = \log p \approx 11{,}5$. Comparez l'oracle $\sigma^2 s/n$ et la vitesse $s \log p/n$. Quel facteur perdrait-on sans exploiter la parcimonie ?

Réponse

Oracle : $8/400 = 0{,}02$. IS : $8 \times 11{,}5/400 \approx 0{,}23$, soit un facteur $\log p \approx 11{,}5$. Sans la parcimonie, le prix serait $\sigma^2 p/n$, soit un facteur $p/s = 12\,500$ par rapport à l'oracle (et les moindres carrés sont même impossibles ici, car $p > n$).

21. Pourquoi faut-il une hypothèse sur $\Psi_n = X^\top X/n$ pour estimer β^*, et pourquoi ne peut-on pas simplement supposer Ψ_n inversible ?

Réponse

Si deux colonnes sont identiques, ou si $p > n$ (il existe $v \neq 0$ avec $Xv = 0$), deux vecteurs différents donnent exactement les mêmes données : aucun estimateur ne peut les distinguer. Mais quand $p > n$, $\operatorname{rg} \Psi_n \leq n < p$: Ψ_n n'est jamais inversible. Il faut une hypothèse plus faible, qui ne porte que sur les petits groupes de variables (la condition RE de la Séance 3).

22. Citez les quatre qualités d'un « bon » estimateur (diapo 31). Lesquelles le Lasso a-t-il par construction ?

Réponse

Optimalité (consistance asymptotique et IS non asymptotiques), hypothèses sur Ψ_n aussi faibles que possible, complexité algorithmique raisonnable même si $p > n$, interprétabilité (parcimonie). Par construction : la complexité (problème convexe, LARS) et l'interprétabilité ; l'optimalité est l'objet des Séances 3 et 4.

Séance 3 et TD2 → la fiche

1. Écrivez le critère du Lasso de la séance 3, l'hypothèse de normalisation des colonnes et les conditions KKT associées.

Réponse

$\hat{\beta}^L = \arg\min_\beta \{\frac{1}{n} \|Y - X\beta\|_2^2 + 2r \|\beta\|_1\}$, avec $\|X_j\|^2 = n$ pour tout j (diagonale de $X^\top X/n$ égale à 1). KKT : $\frac{1}{n} X_j^\top (Y - X\hat{\beta}^L) = r \operatorname{sgn}(\hat{\beta}_j^L)$ si $\hat{\beta}_j^L \neq 0$, et $\left|\frac{1}{n} X_j^\top (Y - X\hat{\beta}^L)\right| \leq r$ si $\hat{\beta}_j^L = 0$. C'est le critère $\|Y - X\beta\|^2 + \lambda' \|\beta\|_1$ de la séance 2 avec $\lambda' = 2nr$.

2. Pourquoi, quand $p > n$, ne peut-on pas contrôler une erreur δ quelconque à partir de $X\delta$? Que propose la diapo 35 ?

Réponse

$\operatorname{rg} X \leq n < p$, donc le noyau de X est de dimension $\geq p - n \geq 1$: il existe $\delta \neq 0$ avec $X\delta = 0$, et $\min_{\delta \neq 0} \|X\delta\|_2 / (\sqrt{n} \|\delta\|_2) = 0$ (formule (4)). Les moindres carrés, qui exigent Ψ_n définie positive, échouent. La diapo propose de prendre le minimum sur un ensemble restreint de δ (le cône) et de ne mettre au dénominateur que la norme d'une partie de δ (celle sur le support) : c'est RE.

3. Énoncez le cône. Sur quel événement est-il garanti ? Traduisez-le en mots.

Réponse

Sur $\mathcal{E} = \{\frac{2}{n}\left\|X^\top \varepsilon\right\|_\infty \le r\}$, l'erreur $\delta = \hat\beta^L - \beta^*$ vérifie $\left\|\delta_{J_0^c}\right\|_1 \le 3\left\|\delta_{J_0}\right\|_1$ avec $J_0 = J(\beta^*)$. En mots : la masse ℓ_1 que le Lasso met à tort hors du vrai support ($\delta_{J_0^c} = \hat\beta^L_{J_0^c}$) ne dépasse pas trois fois l'erreur commise sur le support ; de façon équivalente $\|\delta\|_1 \le 4\left\|\delta_{J_0}\right\|_1$: au moins un quart de la masse de l'erreur est sur le support.

4. Pourquoi le facteur $\frac{2}{n}$ dans la définition de $\mathcal{E}$?

Réponse

Parce que le terme de bruit de l'inégalité de base est $\frac{2}{n}\varepsilon^\top X\delta$ (il vient du double produit de $\frac{1}{n}\|\varepsilon - X\delta\|^2$). Hölder le majore par $\frac{2}{n}\left\|X^\top\varepsilon\right\|_\infty \|\delta\|_1$, et $\mathcal{E}$ est exactement l'événement où ce facteur est $\le r$, de sorte que le bruit coûte au plus r par unité de $\|\delta\|_1$, la moitié du poids $2r$ de la pénalité.

5. On garde la pénalité $2r\|\beta\|_1$ mais on travaille sur $\{\frac{2}{n}\left\|X^\top\varepsilon\right\|_\infty \le \eta\}$ avec $0 < \eta < 2r$. Quelle est la constante du cône ? Que se passe-t-il si $\eta \ge 2r$?

Réponse

La base, Hölder et le découpage selon J_0 donnent $\frac{1}{n}\|X\delta\|^2 \le (2r+\eta)\left\|\delta_{J_0}\right\|_1 - (2r-\eta)\left\|\delta_{J_0^c}\right\|_1$, d'où le cône de constante $\frac{2r+\eta}{2r-\eta}$ (qui vaut 3 pour $\eta = r$). Si $\eta \ge 2r$, le coefficient de $\left\|\delta_{J_0^c}\right\|_1$ n'est plus positif : plus de cône, la preuve s'effondre. La pénalité doit dominer le bruit.

6. Écrivez la définition exacte de $\kappa(s,3)$. Pourquoi le premier minimum porte-t-il sur tous les J_0 de taille au plus s ?

Réponse

$$\kappa(s,3) = \min_{\substack{J_0 \subseteq \{1,\dots,p\} \\ |J_0| \le s}} \; \min_{\substack{\delta \ne 0 \\ \left\|\delta_{J_0^c}\right\|_1 \le 3\left\|\delta_{J_0}\right\|_1}} \frac{\|X\delta\|_2}{\sqrt{n}\,\left\|\delta_{J_0}\right\|_2}$$

RE$(s,3)$ demande $\kappa(s,3) > 0$. On ne connaît pas le vrai support : en demandant la propriété pour tous les supports possibles de taille $\le s$, on peut l'appliquer au vrai $J_0 = J(\beta^*)$ (grâce à $M(\beta^*) \le s$) sans le connaître.

7. Que vaut $\kappa(s,3)$ si $X^\top X = nI_p$? Et si deux colonnes de X sont égales ?

Réponse

Design orthonormé : $\|X\delta\|^2 = n\|\delta\|_2^2 \ge n\|\delta_{J_0}\|_2^2$, quotient toujours ≥ 1 et égal à 1 en $\delta = e_j$: $\kappa = 1$. Colonnes égales $X_1 = X_2$: $\delta = (1,-1,0,\dots,0)$ et $J_0 = \{1\}$ donnent un vecteur du cône ($1 \le 3$) avec $X\delta = 0$: $\kappa = 0$, RE échoue pour tout $s \ge 1$.

8. $p = 2$, $s = 1$, $\Psi_n = \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix}$ **avec** $\rho = 0{,}6$. **Calculez** $\kappa(1,3)$ **et comparez à** $\sqrt{\lambda_{\min}(\Psi_n)}$.

Réponse

Par symétrie, $J_0 = \{1\}$ suffit ; on normalise $\delta = (1, t)$ avec $|t| \leq 3$. Le quotient au carré vaut $\delta^\top \Psi_n \delta = 1 + 2\rho t + t^2$, minimal en $t = -\rho = -0{,}6$ (bien dans $[-3, 3]$) : $1 - \rho^2 = 0{,}64$. Donc $\kappa(1,3) = 0{,}8$. Les valeurs propres de Ψ_n sont $1 \pm \rho$, donc $\sqrt{\lambda_{\min}} = \sqrt{0{,}4} \approx 0{,}63 \leq 0{,}8$: la constante de RE est meilleure, conformément à $\kappa \geq \sqrt{\lambda_{\min}}$.

9. Vrai ou faux : « sous RE$(s,3)$, la matrice X est injective ».

Réponse

Faux. Quand $p > n$, le noyau de X n'est jamais réduit à 0. RE demande seulement que le noyau évite les cônes. Ce qui est vrai : toute famille d'au plus $2s$ colonnes est libre, donc β^* est le seul vecteur s-parcimonieux tel que $X\beta = X\beta^*$.

10. Pourquoi RE$(s,3)$ impose-t-elle $n \geq 2s$? Quelle parcimonie maximale peut-on espérer traiter avec $n = 100$ observations ?

Réponse

Sous RE$(s,3)$, toute famille d'au plus $2s$ colonnes de X est libre (on met les s plus grosses coordonnées de δ dans J : δ est dans le cône, et RE interdit $X\delta = 0$). Or $2s$ vecteurs libres de $\mathbb{R}^n$ exigent $2s \leq n$ (dès que $p \geq 2s$). Avec $n = 100$: $s \leq 50$. C'est une condition nécessaire, loin d'être suffisante.

11. Énoncez le théorème de Bickel, Ritov et Tsybakov : hypothèses, choix de r, probabilité et trois conclusions.

Réponse

Hypothèses : ε_i i.i.d. $\mathcal{N}(0, \sigma^2)$, $\sigma^2 > 0$; diagonale de $X^\top X/n$ égale à 1 ; $M(\beta^*) \leq s$ avec $1 \leq s \leq p$, $n \geq 1$, $p \geq 2$; RE$(s,3)$. Lasso $\frac{1}{n}\|Y - X\beta\|^2 + 2r\|\beta\|_1$ avec $r = A\sigma\sqrt{\log p/n}$, $A > 2\sqrt{2}$. Avec probabilité $\geq 1 - p^{1-A^2/8}$: $\left\|\hat{\beta}^L - \beta^*\right\|_1 \leq \frac{16A}{\kappa^2}\sigma s\sqrt{\frac{\log p}{n}}$; $\left\|X(\hat{\beta}^L - \beta^*)\right\|_2^2 \leq \frac{16A^2}{\kappa^2}\sigma^2 s \log p$; $M(\hat{\beta}^L) \leq \frac{64\varphi_{\max}}{\kappa^2}s$, avec $\kappa = \kappa(s,3)$.

12. Pour chacune des hypothèses du théorème, dites à quelle étape de la preuve elle sert.

Réponse

Bruit gaussien : étape 5 (loi des $X_j^\top \varepsilon$). Colonnes normalisées : étape 5 (tous les $X_j^\top \varepsilon$ ont la même loi $\mathcal{N}(0, n\sigma^2)$, un seul seuil). $M(\beta^*) \leq s$: étape 3 ($|J_0| \leq s$ pour appliquer RE et Cauchy–Schwarz). RE $(s,3)$: étape 3 (passer de $\|\delta_{J_0}\|_2$ à $\|X\delta\|$). $r = A\sigma\sqrt{\log p/n}$ et $A > 2\sqrt{2}$: étapes 2 et 5 (la pénalité domine le bruit ; exposant $1 - A^2/8 < 0$). Les KKT ne servent que pour (8).

13. Retrouvez les constantes 16, $16A^2$ et 64 du théorème à partir de l'inégalité $u^2 + r\|\delta\|_1 \le cu$.

Réponse

Ici $u = \|X\delta\|_2/\sqrt{n}$ et $c = 4r\sqrt{s}/\kappa$. $u^2 \le cu$ donne $u \le c$, donc $\|X\delta\|_2^2 = nu^2 \le 16r^2 sn/\kappa^2 = 16A^2\sigma^2 s\log p/\kappa^2$ (car $nr^2 = A^2\sigma^2\log p$). $r\|\delta\|_1 \le cu \le c^2$ donne $\|\delta\|_1 \le 16rs/\kappa^2 = \frac{16A}{\kappa^2}\sigma s\sqrt{\log p/n}$. Enfin $M(\hat\beta^L)\frac{r^2}{4} \le \varphi_{\max}u^2 \le \varphi_{\max}c^2$ donne $M(\hat\beta^L) \le 64\varphi_{\max}s/\kappa^2$.

14. Pourquoi majorer le terme $\frac{2}{n}\varepsilon^\top X\delta$ par Hölder (ℓ_∞/ℓ_1) et pas par Cauchy–Schwarz ?

Réponse

Parce que $\|X^\top\varepsilon\|_\infty = \max_j |X_j^\top\varepsilon|$ est un maximum de p gaussiennes de variance $n\sigma^2$, de l'ordre de $\sigma\sqrt{2n\log p}$, alors que $\|X^\top\varepsilon\|_2$ est une somme : $\mathbb{E}\|X^\top\varepsilon\|_2^2 = pn\sigma^2$. Avec Cauchy–Schwarz il faudrait $r \gtrsim 2\sigma\sqrt{p/n}$ et la borne de prédiction deviendrait de l'ordre de $\sigma^2 sp/n$, inutile quand $p > n$. De plus, Hölder fait apparaître $\|\delta\|_1$, comparable à la pénalité.

15. Démontrez $\mathbb{P}(\mathcal{E}^c) \le p^{1-A^2/8}$. Pourquoi faut-il $A > 2\sqrt{2}$?

Réponse

Borne de l'union : $\mathbb{P}(\mathcal{E}^c) \le \sum_j \mathbb{P}(\frac{2}{n}|X_j^\top\varepsilon| > r)$. Comme $X_j^\top\varepsilon \sim \mathcal{N}(0, n\sigma^2)$, $Z_j = X_j^\top\varepsilon/(\sigma\sqrt{n}) \sim \mathcal{N}(0,1)$ et l'événement s'écrit $|Z_j| > \frac{r\sqrt{n}}{2\sigma} = \frac{A}{2}\sqrt{\log p}$. La queue $\mathbb{P}(|Z| > t) \le e^{-t^2/2}$ donne $p^{-A^2/8}$ par variable, donc $p^{1-A^2/8}$ au total. Il faut $1 - A^2/8 < 0$, soit $A > 2\sqrt{2}$, pour que cette borne soit < 1 et tende vers 0 quand p grandit ; c'est aussi placer le seuil au-dessus de $\sqrt{2\log p}$, le maximum typique de p gaussiennes.

16. Application : $n = 400$, $p = 1000$, $s = 5$, $\sigma = 1$, $A = 3$, $\kappa = 1$. Calculez r, la probabilité garantie, la borne (7) divisée par n, et comparez à l'oracle.

Réponse

$\log p \approx 6{,}91$, $\sqrt{\log p/n} \approx 0{,}131$, donc $r \approx 0{,}394$. Probabilité $\ge 1 - 1000^{1-9/8} = 1 - 1000^{-0{,}125} \approx 1 - 0{,}42 = 0{,}58$. Borne (7)$/n$: $16A^2\sigma^2 s\log p/n = 16r^2 s \approx 12{,}4$. Oracle : $\sigma^2 s/n = 0{,}0125$, soit environ mille fois moins. La forme $s\log p/n$ est la bonne, les constantes sont très pessimistes.

17. Avec $p = 1000$, quelle valeur de A faut-il pour que le théorème (version de la diapo) garantisse une probabilité d'au moins $0{,}99$?

Réponse

Il faut $p^{1-A^2/8} \le 10^{-2}$, soit $(A^2/8 - 1)\log p \ge \log 100$, c'est-à-dire $A^2 \ge 8\big(1 + \frac{\log 100}{\log 1000}\big) = 8 \cdot \frac{5}{3} = \frac{40}{3}$. Donc $A \ge \sqrt{40/3} \approx 3{,}65$.

18. Pourquoi, sur $\mathcal{E}$, toute variable sélectionnée vérifie-t-elle $\left|\frac{1}{n}X_j^\top X\delta\right| \geq \frac{r}{2}$? Qu'en déduit-on ?

Réponse

KKT : $\frac{1}{n}X_j^\top(Y - X\hat{\beta}^L) = r\,\mathrm{sgn}(\hat{\beta}_j^L)$, et $Y - X\hat{\beta}^L = \varepsilon - X\delta$, donc $\frac{1}{n}X_j^\top X\delta = \frac{1}{n}X_j^\top\varepsilon - r\,\mathrm{sgn}(\hat{\beta}_j^L)$, de valeur absolue $\geq r - \frac{r}{2}$ car $\frac{1}{n}\left|X_j^\top\varepsilon\right| \leq \frac{r}{2}$ sur $\mathcal{E}$. En sommant les carrés : $M(\hat{\beta}^L)\frac{r^2}{4} \leq \left\|\frac{1}{n}X^\top X\delta\right\|_2^2 \leq \varphi_{\max}\frac{1}{n}\|X\delta\|^2$, puis (8) grâce à la borne (7).

19. Écrivez la première ligne du lemme (2) du TD2. Qu'apporte le fait qu'elle soit vraie pour tout β, sur un même événement ?

Réponse

Sur $\mathcal{E} = \{2\,|V_j| \leq r\ \forall j\}$, $V_j = \frac{1}{n}X_j^\top\varepsilon$: $\left\|X\hat{\beta}^L - X\beta^*\right\|_n^2 + r\left\|\hat{\beta}^L - \beta\right\|_1 \leq \|X\beta - X\beta^*\|_n^2 + 4r\sum_{j\in J(\beta)}\left|\hat{\beta}_j^L - \beta_j\right|$ pour tout $\beta \in \mathbb{R}^p$. Le Lasso prédit presque aussi bien que n'importe quel candidat β, avec un prix qui ne porte que sur le support de β : on peut le comparer à une bonne approximation parcimonieuse de β^* (forme oracle). Comme $\mathcal{E}$ ne dépend pas de β, l'inégalité vaut pour tous les β simultanément, et l'on peut choisir β après coup.

20. Que donne le lemme (2) pour $\beta = 0$?

Réponse

$J(0) = \varnothing$, la somme est vide : $\left\|X\hat{\beta}^L - X\beta^*\right\|_n^2 + r\left\|\hat{\beta}^L\right\|_1 \leq \|X\beta^*\|_n^2$. Sur $\mathcal{E}$, le Lasso ne prédit jamais plus mal que le prédicteur nul, et $\left\|\hat{\beta}^L\right\|_1 \leq \|X\beta^*\|_n^2/r$.

21. Démontrez le résultat (3) du TD2 : $\left\|\frac{1}{n}X^\top(X\beta^* - X\hat{\beta}^L)\right\|_\infty \leq \frac{3r}{2}$ sur $\mathcal{E}$.

Réponse

$X\beta^* - X\hat{\beta}^L = (Y - X\hat{\beta}^L) - \varepsilon$, donc $\frac{1}{n}X^\top(X\beta^* - X\hat{\beta}^L) = \frac{1}{n}X^\top(Y - X\hat{\beta}^L) - (V_1, \ldots, V_p)^\top$. Les KKT donnent $\left\|\frac{1}{n}X^\top(Y - X\hat{\beta}^L)\right\|_\infty \leq r$ et, sur $\mathcal{E}$, $|V_j| \leq r/2$. L'inégalité triangulaire donne $r + r/2 = 3r/2$. Aucune hypothèse RE n'est utilisée.

22. Démontrez $\mathbb{P}(|Z| \geq z) \leq 2e^{-z^2/2}$ pour $Z \sim \mathcal{N}(0,1)$ et $z > 0$.

Réponse

$\mathbb{P}(|Z| \geq z) = 2\mathbb{P}(Z \geq z)$ par symétrie. Pour $\theta > 0$, Markov sur $e^{\theta Z}$: $\mathbb{P}(Z \geq z) \leq e^{-\theta z}\mathbb{E}[e^{\theta Z}] = e^{\theta^2/2 - \theta z}$ (on complète le carré : $\mathbb{E}[e^{\theta Z}] = e^{\theta^2/2}$). Le minimum de $\theta^2/2 - \theta z$ est atteint en $\theta = z$ et vaut $-z^2/2$. D'où $\mathbb{P}(Z \geq z) \leq e^{-z^2/2}$ et le résultat.

23. Le TD2 obtient la probabilité $1 - 2p^{1-A^2/8}$, la diapo 38 annonce $1 - p^{1-A^2/8}$. D'où vient l'écart ? Que valent les deux pour $p = 1000$ et $A = 4$?

Réponse

De la borne de queue : Chernoff $\mathbb{P}(|Z| \geq z) \leq 2e^{-z^2/2}$ dans le TD, version fine $e^{-z^2/2}$ (vraie pour tout $z \geq 0$) en séance 3. Le raisonnement est le même. Pour $p = 1000$, $A = 4$: $p^{1-A^2/8} = 1000^{-1}$, donc $0{,}998$ (TD) contre $0{,}999$ (diapo).

24. Vrai ou faux : « avec grande probabilité, le Lasso retrouve exactement le support de β^* ; c'est ce que dit le théorème BRT ».

Réponse

Faux. Le théorème borne l'erreur de prédiction, l'erreur ℓ_1 et le *nombre* de variables sélectionnées, mais pas leur identité : un vrai coefficient trop petit peut être manqué, quelques variables inutiles peuvent être gardées (en nombre limité par (8)). Retrouver exactement le support demande des hypothèses plus fortes (hors diapos).

25. Le théorème est « non asymptotique ». Que faudrait-il pour en déduire une convergence quand $n \to \infty$?

Réponse

Suivre toute une suite de matrices $X^{(n)}$, avec $p = p(n)$ et $s = s(n)$, et savoir que $\kappa(s, 3)$ reste minoré par un $\kappa_0 > 0$ (propriété très forte, invérifiable), que $s \log p / n \to 0$ (pour que la borne (7)$/n$ tende vers 0), et que $p \to \infty$ (ou que A grandisse) pour que la probabilité $1 - p^{1-A^2/8}$ tende vers 1.

Séance 4 → la fiche

1. Écrivez le modèle de la séance 4 et expliquez comment un dictionnaire le ramène à une régression linéaire. Qui joue le rôle de p ?

Réponse

$Y_i = f(Z_i) + \varepsilon_i$, ε_i i.i.d. $\mathcal{N}(0, \sigma^2)$, Z_i déterministes, f inconnue. Avec un dictionnaire $f_1, \ldots, f_M$ et $X_{ij} = f_j(Z_i)$, on a $X\beta = f_\beta = (f_\beta(Z_1), \ldots, f_\beta(Z_n))^\top$ et $y = f + \varepsilon$: une régression linéaire à M variables (M joue le rôle de p, souvent $M \gg n$). Mais f n'est pas forcément de la forme $X\beta$: il reste une erreur d'approximation.

2. Que dit, en mots, une inégalité oracle ? Comment l'utilise-t-on pour retrouver une borne du type séance 3 ?

Réponse

Pour **tout** concurrent β : erreur de l'estimateur $\leq$ erreur d'approximation de β + prix de β ; l'estimateur fait presque aussi bien que le meilleur compromis, sans connaître f. Pour l'utiliser, on choisit un β : si $f = X\beta^\circ$ avec β° s-parcimonieux (et dans Θ), le choix $\beta = \beta^\circ$ annule l'approximation et laisse une borne de prédiction $\frac{1}{n}\left\|X\hat{\beta} - X\beta^\circ\right\|^2 \leq \text{reste}(\beta^\circ)$.

3. $b = (2;\ -0{,}3;\ -1{,}1;\ 0{,}8)$ et $\lambda = 0{,}8$. Calculez (a) $\arg\min_a\{\frac{1}{2}\|a-b\|^2 + \lambda\|a\|_1\}$, (b) la même chose sans le $\frac{1}{2}$, c'est-à-dire avec $\|a-b\|^2 + \lambda\|a\|_1$, (c) le rétrécissement $b/(1+\lambda)$.

Réponse

(a) Seuil $\lambda = 0{,}8$: $(1{,}2;\ 0;\ -0{,}3;\ 0)$; la dernière coordonnée est exactement au seuil ($|b| \leq \lambda$), donc nulle. (b) Seuil $\lambda/2 = 0{,}4$ (la dérivée devient $2(a-b) \pm \lambda$) : $(1{,}6;\ 0;\ -0{,}7;\ 0{,}4)$. (c) $b/1{,}8 \approx (1{,}11;\ -0{,}17;\ -0{,}61;\ 0{,}44)$: aucun zéro.

4. Vrai ou faux : « avec λ assez grand, le rétrécissement Ridge $b/(1+\lambda)$ met les petits coefficients exactement à 0 ».

Réponse

Faux : $b/(1+\lambda) \neq 0$ dès que $b \neq 0$, quel que soit λ. Seul le coin de $|a|$ en 0 crée des zéros ; la pénalité $\frac{\lambda}{2}a^2$ a une pente nulle en 0 et n'oppose aucune résistance.

5. Expliquez avec les pentes pourquoi 0 minimise $\frac{1}{2}(a-b)^2 + \lambda|a|$ dès que $|b| \leq \lambda$.

Réponse

En 0, la pente à droite vaut $-b + \lambda \geq 0$ et la pente à gauche $-b - \lambda \leq 0$: la fonction (convexe) monte des deux côtés, donc 0 est le minimum. Avec le sous-différentiel : $0 \in -b + \lambda[-1,1] \iff |b| \leq \lambda$.

6. Quelle est l'enveloppe convexe de $\mathbf{1}\{x \neq 0\}$ sur $[-1,1]$? Donnez l'argument qui montre qu'aucune fonction convexe sous l'indicatrice ne la dépasse. Et sur $[-R,R]$?

Réponse

C'est $|x|$. Si h est convexe et $h \leq \mathbf{1}\{\cdot \neq 0\}$, alors $h(0) \leq 0$ et $h(\pm 1) \leq 1$; pour $x \in [0,1]$, $h(x) \leq (1-x)h(0) + xh(1) \leq x$ (la corde est au-dessus du graphe), et de même sur $[-1,0]$. Sur $[-R,R]$, même preuve avec la corde entre 0 et $\pm R$: l'enveloppe est $|x|/R$, d'où le $\frac{1}{R}\|x\|_1$ de la relaxation (Cours5, diapo 47).

7. Donnez la définition d'un sous-gradient. Que vaut $\partial\varphi(u)$ si φ est dérivable en u ?

Réponse

g est un sous-gradient de φ (convexe) en u si $\varphi(v) - \varphi(u) \geq g^\top (v - u)$ pour tout v ; $\partial\varphi(u)$ est l'ensemble de ces g. Si φ est dérivable en u, $\partial\varphi(u) = \{\nabla\varphi(u)\}$.

8. Calculez $\partial\varphi(0)$ pour $\varphi(u) = 2\,|u| + (u-1)^2$. Le point 0 est-il un minimiseur ?

Réponse

Règle de la somme : $\partial\varphi(0) = 2[-1,1] + \{2(0-1)\} = [-2,2] - 2 = [-4,0]$. Il contient 0, donc 0 est un minimiseur (règle de Fermat convexe). Vérification : $\varphi'(u) = 2u > 0$ pour $u > 0$ et $\varphi'(u) = 2u - 4 < 0$ pour $u < 0$.

9. Calculez $\partial\,\|u\|_1$ en $u = (0;\ -3;\ 0{,}5;\ 0)$. Les vecteurs $(0{,}2;\ -1;\ 1;\ -1)$ et $(1;\ 1;\ 1;\ 0)$ en font-ils partie ?

Réponse

$\partial\,\|u\|_1 = [-1,1] \times \{-1\} \times \{1\} \times [-1,1]$. Le premier vecteur en fait partie ($0{,}2$ et -1 sont dans $[-1,1]$, les deux coordonnées imposées sont bonnes). Le second non : sa deuxième coordonnée devrait valoir $\operatorname{sgn}(-3) = -1$.

10. Calculez $\partial\,\|u\|_2$ en $u = (3;\ 4)$ et en $u = 0$. À quoi sert le second cas en séance 6 ?

Réponse

En $(3;4)$: $\{u/\,\|u\|_2\} = \{(0{,}6;\ 0{,}8)\}$. En 0 : la boule unité $\{g : \|g\|_2 \leq 1\}$ (Cauchy–Schwarz dans un sens, $v = g$ dans l'autre). C'est l'analogue de $[-1,1]$ pour $|\cdot|$: il permet au group-Lasso de mettre *tout un groupe* de coefficients à zéro.

11. Énoncez la règle du maximum et retrouvez avec elle $\partial\,|\cdot|\,(0)$.

Réponse

Si $\varphi = \max_k \varphi_k$ (convexes), $\partial\varphi(u) = \operatorname{conv}\left(\bigcup\{\partial\varphi_k(u) : \varphi_k(u) = \varphi(u)\}\right)$. Avec $|u| = \max(u, -u)$: en 0, les deux fonctions sont actives, de gradients 1 et -1 ; leurs mélanges forment $[-1,1]$.

12. Énoncez le critère d'optimalité sur un convexe C, puis vérifiez que $u^* = 0$ minimise $(u+2)^2$ sur $C = [0,5]$.

Réponse

$u^* \in \arg\min_C \varphi \iff \exists g^* \in \partial\varphi(u^*)$ tel que $(g^*)^\top (u - u^*) \geq 0$ pour tout $u \in C$. Ici $g^* = 2(0+2) = 4$ et $4(u-0) \geq 0$ pour tout $u \in [0,5]$: le critère est vérifié. La pente pousse vers la gauche, mais aller à gauche sort de C.

13. Que vaut le cône normal de $C = [0,1]$ en $u = 0$, en $u = \frac{1}{2}$ et en $u = 1$?

Réponse

$N_C(u) = \{g : \ g(v-u) \leq 0 \ \forall v \in C\}$. En 0 : $v - 0 \geq 0$, donc $g \leq 0$: $]-\infty, 0]$. En $\frac{1}{2}$: $v - \frac{1}{2}$ prend les deux signes, donc $g = 0$: $\{0\}$. En 1 : $v - 1 \leq 0$, donc $g \geq 0$: $[0, +\infty[$. Ce sont les directions qui sortent de C.

14. Démontrez la monotonie du sous-différentiel. Que dit-elle en dimension 1 ?

Réponse

$\varphi(u_2) - \varphi(u_1) \geq g_1^\top (u_2 - u_1)$ et $\varphi(u_1) - \varphi(u_2) \geq g_2^\top (u_1 - u_2)$; en additionnant, $0 \geq -(g_1 - g_2)^\top (u_1 - u_2)$, soit $(u_1 - u_2)^\top (g_1 - g_2) \geq 0$. En dimension 1 : si $u_1 > u_2$ alors $g_1 \geq g_2$, les pentes d'une fonction convexe croissent.

15. Écrivez les conditions KKT du Lasso pour le critère $\frac{1}{n}\|y - X\beta\|^2 + \lambda \|\beta\|_1$ minimisé sur $\mathbb{R}^M$ et dites d'où elles viennent. Sont-elles suffisantes ?

Réponse

$\frac{2}{n} X_j^\top (y - X\hat{\beta}) = \lambda \operatorname{sgn}(\hat{\beta}_j)$ si $\hat{\beta}_j \neq 0$; $\left|\frac{2}{n} X_j^\top (y - X\hat{\beta})\right| \leq \lambda$ si $\hat{\beta}_j = 0$. Elles viennent de $0 \in \partial F(\hat{\beta}) = -\frac{2}{n} X^\top (y - X\hat{\beta}) + \lambda \, \partial \left\|\hat{\beta}\right\|_1$ (Fermat + règle de la somme + $\partial \|\cdot\|_1$). Le critère est convexe : elles sont nécessaires et suffisantes.

16. Énoncez l'inégalité oracle lente : hypothèses, estimateur, λ, conclusion, probabilité.

Réponse

Bruit $\mathcal{N}(0, \sigma^2 I_n)$, colonnes normalisées $\|X_j\|_2 = \sqrt{n}$, Θ convexe. $\hat{\beta} = \arg\min_\Theta \{\frac{1}{n}\|y - X\beta\|^2 + \lambda \|\beta\|_1\}$ avec $\lambda = 2\sigma\sqrt{2(x + \log M)/n}$. Avec probabilité $\geq 1 - 2e^{-x}$: $\frac{1}{n}\left\|f_{\hat{\beta}} - f\right\|^2 \leq \inf_{\beta \in \Theta}\{\frac{1}{n}\|f_\beta - f\|^2 + 2\lambda \|\beta\|_1\}$.

17. $\sigma = 1$, $M = 1000$ briques, $n = 500$, $x = 2$: que vaut λ ? Avec quelle probabilité l'inégalité lente est-elle garantie ?

Réponse

$x + \log M \approx 2 + 6{,}908 = 8{,}908$, donc $\lambda = 2\sqrt{2 \times 8{,}908/500} \approx 2 \times 0{,}189 \approx 0{,}378$. Probabilité $\geq 1 - 2e^{-2} \approx 0{,}73$.

18. Dans la preuve lente, à quoi sert la normalisation $\|X_j\| = \sqrt{n}$? Pourquoi n'a-t-on besoin d'aucune hypothèse de corrélation entre les briques ?

Réponse

La normalisation donne $V_j = \frac{1}{n} X_j^\top \varepsilon \sim \mathcal{N}(0, \sigma^2/n)$ pour tout j : la même variance, donc le même seuil $\lambda/2$ convient à toutes les briques. Aucune hypothèse de corrélation : la borne de l'union ne demande pas d'indépendance entre les V_j, et la preuve n'a jamais besoin de passer de $\|X\delta\|$ à $\|\delta\|$ (seulement Hölder et l'inégalité triangulaire).

19. Énoncez l'inégalité oracle rapide : hypothèses, estimateur, λ, conclusion, probabilité. Porte-t-elle sur le même estimateur que l'inégalité lente ?

Réponse

Bruit $\mathcal{N}(0, \sigma^2 I_n)$, colonnes normalisées $\|X_j\|_2 = \sqrt{n}$, RE$(s, 3)$, Θ convexe. $\hat{\beta} \in \arg\min_\Theta \{\frac{1}{n}\|y - X\beta\|^2 + 2\lambda\|\beta\|_1\}$ avec $\lambda = 2\sigma\sqrt{2(x + \log M)/n}$. Avec probabilité $\geq 1 - 2e^{-x}$: $\frac{1}{n}\left\|f_{\hat{\beta}} - f\right\|^2 \leq \inf_{\beta \in \Theta,\, \|\beta\|_0 \leq s} \{\frac{1}{n}\|f_\beta - f\|^2 + \frac{18\sigma^2 s(x + \log M)}{\kappa(s,3)^2 n}\}$.

Non. Le λ, l'événement et la probabilité $1 - 2e^{-x}$ sont les mêmes, mais l'estimateur de la rapide est pénalisé par $2\lambda\|\beta\|_1$ (celui de la lente par $\lambda\|\beta\|_1$) : c'est ce facteur 2 qui force le cône.

20. Énoncez la condition RE(s, c_0). Pourquoi a-t-on $\kappa(s, 3) \leq \kappa(s, 1)$?

Réponse

$\kappa(s, c_0) = \min_{|J| \leq s} \min_{t \neq 0,\, \|t_{J^c}\|_1 \leq c_0 \|t_J\|_1} \frac{\|Xt\|}{\sqrt{n}\|t_J\|} > 0$. Le cône pour $c_0 = 3$ contient celui pour $c_0 = 1$: un minimum pris sur un ensemble plus gros est plus petit (ou égal). RE$(s, 3)$ est donc plus exigeante et entraîne RE$(s, 1)$.

21. Montrez directement que RE$(s, 1)$, avec $s \geq 1$, interdit deux colonnes égales $X_j = X_k$ ($j \neq k$).

Réponse

Prenons $t = e_j - e_k \neq 0$ et $J = \{j\}$: $\|t_{J^c}\|_1 = 1 \leq 1 \cdot \|t_J\|_1 = 1$, donc t est dans le cône, avec $|J| = 1 \leq s$. Or $Xt = X_j - X_k = 0$, d'où $\frac{\|Xt\|}{\sqrt{n}\|t_J\|} = 0$: contradiction avec $\kappa(s, 1) > 0$.

22. Dans le reste $\frac{18\sigma^2 s(x + \log M)}{\kappa^2 n}$ de l'inégalité rapide, d'où viennent le s, le κ^2, le $x + \log M$ et le 18 ?

Réponse

s : Cauchy–Schwarz $\|\delta_J\|_1 \leq \sqrt{|J|}\,\|\delta_J\|_2$ avec $|J| \leq s$ (élevé au carré par $ax - x^2 \leq a^2/4$). κ^2 : RE, $\|\delta_J\|_2 \leq \left\|f_{\hat{\beta}} - f_\beta\right\|_n / \kappa$, élevé au carré. $x + \log M$: $\lambda^2 = \frac{8\sigma^2(x + \log M)}{n}$, c'est-à-dire la borne de l'union sur M briques et le niveau de confiance. $18 = \frac{9}{4} \times 8$, avec $\frac{9}{4} = (\frac{3}{2})^2$ et $3 = 2 + 1$ (pénalité 2λ + bruit λ).

23. Dans la preuve rapide, à quoi servent (a) le critère d'optimalité à la place de « $F(\hat{\beta}) \le F(\beta)$ », (b) la monotonie, (c) le choix $h_j = \operatorname{sgn}(\hat{\beta}_j)$ hors du support de β ?

Réponse

(a) Avec la polarisation, il fait apparaître à gauche le bonus $\left\| f_{\hat{\beta}} - f_{\beta} \right\|_n^2$, qui absorbe à la fin le terme venu de RE. (b) Elle remplace le sous-gradient inconnu $\hat{g}$ en $\hat{\beta}$ par un sous-gradient g en β que l'on choisit. (c) Il fait apparaître $-2\lambda \left\| \hat{\beta}_{J^c} \right\|_1$: la pénalité « gagne » hors du support, ce qui donne le cône $c_0 = 3$.

24. On pénalise par $3\lambda \|\beta\|_1$ au lieu de $2\lambda \|\beta\|_1$ (même λ, même événement). Quel cône et quelle constante remplacent 3 et 18 ?

Réponse

Avec $c\lambda \|\beta\|_1$: cas 2, $(c-1)\|\delta_{J^c}\|_1 \le (c+1)\|\delta_J\|_1$, cône $c_0 = \frac{c+1}{c-1}$; reste $\frac{(c+1)^2\lambda^2 s}{4\kappa^2} = \frac{2(c+1)^2\sigma^2 s(x+\log M)}{\kappa^2 n}$. Pour $c = 3$: cône $c_0 = 2$ et constante 32, avec $\kappa(s,2)$. Plus de pénalité : cône plus petit (hypothèse plus faible) mais constante plus grande.

25. $\sigma = 1$, $M = 2000$, $n = 10\,000$, $x = 3$, un concurrent avec $s = 3$ et $\|\beta\|_1 = 3$, et $\kappa(s,3) = 0{,}5$. Comparez le prix de l'inégalité lente et celui de l'inégalité rapide.

Réponse

$x + \log M \approx 10{,}60$ et $\lambda = 2\sqrt{2 \times 10{,}60/10\,000} \approx 0{,}092$. Prix lent : $2\lambda\|\beta\|_1 \approx 0{,}55$. Prix rapide : $\frac{18 \times 3 \times 10{,}60}{0{,}25 \times 10\,000} \approx 0{,}23$. Malgré $\kappa = 0{,}5$, la borne rapide est déjà meilleure, et l'écart grandit avec n ($1/n$ contre $1/\sqrt{n}$).

26. On suppose $f = X\beta^*$ avec $\|\beta^*\|_0 \le s$, $\Theta = \mathbb{R}^M$, $M = p$, et l'on prend $x = (\frac{A^2}{8} - 1)\log p$ avec $A > 2\sqrt{2}$. Que vaut λ ? Quel est l'estimateur de l'inégalité rapide ? Quelle borne obtient-on, avec quelle probabilité ? Comparez avec BRT.

Réponse

$x + \log p = \frac{A^2}{8}\log p$, donc $\lambda = 2\sigma\sqrt{\frac{2}{n} \cdot \frac{A^2}{8}\log p} = A\sigma\sqrt{\log p / n} = r$ (et $x > 0$ exige $A > 2\sqrt{2}$). L'estimateur rapide, pénalisé par $2\lambda\|\beta\|_1 = 2r\|\beta\|_1$, est exactement le Lasso de BRT. Avec le concurrent $\beta = \beta^*$ (approximation nulle) : $\frac{1}{n}\left\| X(\hat{\beta} - \beta^*) \right\|^2 \le \frac{18}{8}A^2\frac{\sigma^2 s \log p}{\kappa^2 n} = \frac{9}{4}A^2\frac{\sigma^2 s \log p}{\kappa^2 n}$, avec probabilité $\ge 1 - 2e^{-x} = 1 - 2p^{1-A^2/8}$. BRT a la constante $16A^2$, environ 7 fois plus grande, mais la probabilité $1 - p^{1-A^2/8}$ (queue $e^{-t^2/2}$ au lieu de $2e^{-t^2/2}$).

Séance 5 et TD3 → la fiche

1. Quels sont les trois ingrédients d'un GLM ? Quelles conditions impose-t-on à la fonction de lien, et pourquoi l'identité ne convient-elle pas à une réponse 0/1 ?

Réponse

(1) Une loi de la famille exponentielle pour chaque Y_i (indépendantes) ; (2) un prédicteur linéaire $\eta_i = x_i^\top \beta$; (3) un lien $g(\mu_i) = \eta_i$, g strictement monotone, dérivable, qui envoie l'ensemble des moyennes possibles sur tout $\mathbb{R}$. Avec l'identité, $\mu_i = x_i^\top \beta$ peut valoir $1{,}3$, ce qui n'est pas une probabilité ; le logit envoie $]0,1[$ sur $\mathbb{R}$.

2. Mettez la loi binomiale $\mathcal{B}(N,p)$, avec N connu, sous forme exponentielle naturelle. Déduisez-en sa moyenne, sa variance et son lien canonique.

Réponse

$\log f(y) = y \log \frac{p}{1-p} + N\log(1-p) + \log \binom{N}{y}$: $T(y) = y$, $\theta = \operatorname{logit} p$, $A(\theta) = -N\log(1-p) = N\log(1+e^\theta)$, $B(y) = \log \binom{N}{y}$. Alors $A'(\theta) = N\sigma(\theta) = Np$ et $A''(\theta) = N\sigma(\theta)\big(1-\sigma(\theta)\big) = Np(1-p)$. De $\mu = N\sigma(\theta)$ on tire $\theta = \log \frac{\mu}{N-\mu}$: c'est le lien canonique.

3. Même question pour la loi géométrique $\mathbb{P}(Y=k) = (1-q)^k q$, $k \in \{0,1,2,\dots\}$, $q \in]0,1[$.

Réponse

$\log f(k) = k\log(1-q) + \log q$: $T(y) = y$, $\theta = \log(1-q) < 0$, $A(\theta) = -\log q = -\log(1-e^\theta)$, $B = 0$. Puis $A'(\theta) = \frac{e^\theta}{1-e^\theta} = \frac{1-q}{q}$ (la moyenne) et $A''(\theta) = \frac{e^\theta}{(1-e^\theta)^2} = \frac{1-q}{q^2}$ (la variance). De $\mu = \frac{e^\theta}{1-e^\theta}$: $e^\theta = \frac{\mu}{1+\mu}$, donc $g(\mu) = \log \frac{\mu}{1+\mu}$. Ce lien envoie $]0,+\infty[$ sur $]-\infty,0[$ seulement : il imposerait $x_i^\top \beta < 0$ (même défaut que pour la loi exponentielle).

4. Quelles sont les deux identités du score, et comment donnent-elles $\mathbb{E}T(Y)$ et $\operatorname{Var} T(Y)$ dans la famille exponentielle ?

Réponse

$\mathbb{E}\big[\frac{\partial \ell}{\partial \theta}\big] = 0$ (on dérive $\int f_\theta = 1$) et $-\mathbb{E}\big[\frac{\partial^2 \ell}{\partial \theta^2}\big] = \mathbb{E}\big[\big(\frac{\partial \ell}{\partial \theta}\big)^2\big]$ (on dérive une seconde fois : identité de Fisher). Avec $\ell = \theta T(y) - A(\theta) + B(y)$: $\frac{\partial \ell}{\partial \theta} = T - A'(\theta)$, donc $\mathbb{E}T = A'(\theta)$; $\frac{\partial^2 \ell}{\partial \theta^2} = -A''(\theta)$, donc $A''(\theta) = \mathbb{E}[(T-\mathbb{E}T)^2] = \operatorname{Var} T$.

5. Pourquoi le lien canonique $g = (A')^{-1}$ existe-t-il toujours (avec $T(y) = y$) ?

Réponse

Parce que $A''(\theta) = \operatorname{Var}(Y) > 0$ dès que Y n'est pas constante : A' est strictement croissante, donc injective, et $\theta = (A')^{-1}(\mu)$ est bien défini sur l'ensemble des moyennes possibles.

6. Régression logistique avec $\beta_j = 0{,}5$; régression de Poisson avec $\beta_j = -0{,}3$. Que se passe-t-il quand x_{ij} augmente de 1 (le reste fixé) ?

Réponse

Logistique : la cote $\frac{\pi_i}{1-\pi_i}$ est multipliée par $e^{0{,}5} \approx 1{,}65$ (+65 %) ; l'effet sur la probabilité π_i elle-même dépend du point de départ. Poisson : le nombre moyen est multiplié par $e^{-0{,}3} \approx 0{,}74$, soit environ 26 % de moins.

7. Écrivez les quatre maillons de $\frac{\partial \ell_i}{\partial \beta_j}$ et la valeur de chacun. Pourquoi les équations de vraisemblance sont-elles en général non linéaires ?

Réponse

$\frac{\partial \ell_i}{\partial \theta_i} = y_i - \mu_i$; $\frac{\partial \theta_i}{\partial \mu_i} = \frac{1}{A''(\theta_i)} = \frac{1}{\operatorname{Var} Y_i}$; $\frac{\partial \mu_i}{\partial \eta_i} = \frac{1}{g'(\mu_i)}$; $\frac{\partial \eta_i}{\partial \beta_j} = x_{ij}$. Non linéaires car $\mu_i = g^{-1}(x_i^\top \beta)$ et $\operatorname{Var} Y_i$ dépendent non linéairement de β ; seul le cas gaussien avec lien identité donne des équations linéaires (les équations normales).

8. Régression logistique avec une constante : que dit l'équation de vraisemblance associée à la constante ? Et si le modèle n'a que la constante ?

Réponse

Lien canonique : $X^\top(y - \hat{\mu}) = 0$; la colonne de 1 donne $\sum_i (y_i - \hat{\mu}_i) = 0$, c'est-à-dire $\sum_i \hat{\mu}_i = \sum_i y_i$: la somme des probabilités prédites égale le nombre de 1 observés. Avec la constante seule : $\sigma(\hat{\beta}) = \bar{y}$, donc $\hat{\beta} = \operatorname{logit}(\bar{y})$ (si $0 < \bar{y} < 1$).

9. Donnez L_n, ∇L_n et $\nabla^2 L_n$ pour un GLM canonique. Pourquoi L_n est-elle convexe ? Quand l'est-elle strictement ?

Réponse

$L_n(\beta) = \frac{1}{n}\sum_i [A(x_i^\top \beta) - y_i x_i^\top \beta - B(y_i)]$, $\nabla L_n = \frac{1}{n} X^\top(\mu(\beta) - y)$, $\nabla^2 L_n = \frac{1}{n} X^\top W(\beta) X$ avec $W = \operatorname{diag}(A''(x_i^\top \beta))$. Convexe car $v^\top \nabla^2 L_n v = \frac{1}{n}\sum_i A''(x_i^\top \beta)(x_i^\top v)^2 \geq 0$ (A'' est une variance). Strictement convexe si $A'' > 0$ et $\operatorname{rg} X = p$: la somme ne s'annule alors que pour $Xv = 0$, c'est-à-dire $v = 0$.

10. Vrai ou faux : « la log-vraisemblance logistique est concave, donc l'EMV existe ». Testez sur $x = (-1, 1, 2)$, $y = (0, 1, 1)$, modèle $\mathbb{P}(Y_i = 1) = \sigma(\beta x_i)$ sans constante.

Réponse

Faux. Ici $y_i = 1$ exactement quand $x_i > 0$: données séparées. $\ell'(\beta) = \sum_i (y_i - \sigma(\beta x_i)) x_i > 0$ pour tout β (chaque terme est positif), donc ℓ croît sans fin : $\ell(0) \approx -2{,}079$, $\ell(1) \approx -0{,}754$, $\ell(2) \approx -0{,}272$, $\ell(5) \approx -0{,}0135$, et elle tend vers 0 sans l'atteindre. Newton part à l'infini : $0 \to 1{,}33 \to 2{,}29 \to 3{,}27 \to 4{,}27 \to \cdots$ Concave ne veut pas dire « maximum atteint ».

11. Faites un pas de Newton depuis $\beta_0 = 0$ pour $x = (-2, -1, 1, 2)$, $y = (0, 1, 1, 1)$, modèle $\sigma(\beta x_i)$ sans constante, de deux façons : par la formule, puis par la réponse de travail.

Réponse

En 0 : $\mu_i = \frac{1}{2}$, $w_i = \frac{1}{4}$. Gradient $\sum_i (y_i - \frac{1}{2}) x_i = 1 - \frac{1}{2} + \frac{1}{2} + 1 = 2$; $X^\top W X = \frac{1}{4}(4 + 1 + 1 + 4) = 2{,}5$; donc $\beta_1 = 2/2{,}5 = 0{,}8$. Réponse de travail $z_i = 0 + \frac{y_i - 1/2}{1/4}$, soit $z = (-2, 2, 2, 2)$; régression pondérée : $\frac{\sum w_i x_i z_i}{\sum w_i x_i^2} = \frac{\frac{1}{4}(4 - 2 + 2 + 4)}{\frac{1}{4} \cdot 10} = 0{,}8$ ✓. La suite donne $0{,}989$, $1{,}0117$, $1{,}0120 = \hat\beta$ (données non séparées : $y = 1$ en $x = -1$).

12. IRLS pour la régression de Poisson : que valent les poids et la réponse de travail ? Faites le premier pas depuis $\beta_0 = 0$ avec $x = (1, 2)$, $y = (1, 4)$ (un paramètre, sans constante).

Réponse

$w_i = A''(\theta_i) = \mu_i$ et $z_i = \eta_i + \frac{y_i - \mu_i}{\mu_i}$. En 0 : $\mu = (1, 1)$, $w = (1, 1)$, $z = (0, 3)$, donc $\beta_1 = \frac{\sum w_i x_i z_i}{\sum w_i x_i^2} = \frac{0 + 6}{1 + 4} = 1{,}2$ (c'est aussi gradient 6 / information 5). Newton dépasse puis revient : $1{,}2 \to 0{,}855 \to 0{,}675 \to 0{,}636 \to 0{,}6345 = \hat\beta = \log \frac{\sqrt{73} - 1}{4}$.

13. Que vaut l'information de Fisher moyenne $I_n(\beta)$ d'un GLM canonique ? Pourquoi n'y a-t-il pas d'espérance à calculer ?

Réponse

Avec $\ell_n = \frac{1}{n}\ell$ (log-vraisemblance moyenne) et le lien canonique, $I_n(\beta) = -\mathbb{E}[\nabla^2 \ell_n(\beta)] = \frac{1}{n} X^\top W(\beta) X$: la hessienne $-\frac{1}{n} X^\top W(\beta) X$ ne dépend pas des y_i (seulement de β, à travers W), donc elle est égale à son espérance. L'information totale est $n I_n(\beta) = X^\top W X$.

14. Une régression logistique donne $\hat\beta_1 = 0{,}8$ et $[(X^\top \hat W X)^{-1}]_{11} = 0{,}16$. Donnez l'intervalle de Wald à 95 %, testez $\beta_1 = 0$ et interprétez en rapport de cotes.

Réponse

$\widehat{\mathrm{se}}_1 = \sqrt{0{,}16} = 0{,}4$; intervalle $0{,}8 \pm 1{,}96 \times 0{,}4 = [0{,}016\,;\,1{,}584]$. Il ne contient pas 0 ; $z = 0{,}8/0{,}4 = 2 > 1{,}96$: on rejette $\beta_1 = 0$ au niveau 5 % (de justesse). Rapport de cotes $e^{0{,}8} \approx 2{,}23$, intervalle $[e^{0{,}016}; e^{1{,}584}] \approx [1{,}02\,;\,4{,}87]$.

15. Énoncez le lemme de Slutsky. À quelle étape de la construction d'un intervalle de confiance asymptotique sert-il ?

Réponse

Si $Z_n \xrightarrow{\mathcal{L}} Z$ et $M_n \xrightarrow{\mathbb{P}} M$ constante, alors $M_n Z_n \xrightarrow{\mathcal{L}} MZ$. Il sert à remplacer l'information inconnue $I(\beta^*)$ par $I(\hat\beta)$: $\sqrt{n}\, I(\hat\beta)^{1/2}(\hat\beta - \beta^*) = \left[I(\hat\beta)^{1/2} I(\beta^*)^{-1/2}\right] \sqrt{n}\, I(\beta^*)^{1/2}(\hat\beta - \beta^*)$, où le crochet tend vers I_p en probabilité (consistance + continuité) et le second facteur vers $\mathcal{N}(0, I_p)$ en loi.

16. Le tableau écrit « $\mathbb{P}(\beta^* \in IC(\alpha)) \geq 1-\alpha$ ». Qu'est-ce qui est réellement démontré ? Pour une proportion, que donne l'intervalle $\hat{\pi} \pm 1{,}96\sqrt{\hat{\pi}(1-\hat{\pi})/n}$ si l'on observe $\bar{y} = 0$?

Réponse

Seulement que $\mathbb{P}(\beta^* \in IC(\alpha)) \to 1-\alpha$ quand $n \to \infty$: un niveau **asymptotique**. Avec $\bar{y} = 0$, $\hat{\pi}(1-\hat{\pi}) = 0$ et l'intervalle se réduit à $\{0\}$: absurde. L'approximation est mauvaise quand on observe très peu de succès (ou d'échecs).

17. Pourquoi l'EMV d'un GLM peut-il ne pas être unique, ou ne pas exister, quand $p > n$? Comment le Lasso règle-t-il ces deux problèmes ?

Réponse

Pas unique : $\operatorname{rg} X < p$, donc il existe $v \neq 0$ avec $Xv = 0$, et β, $\beta + v$ donnent les mêmes $x_i^\top \beta$, donc la même vraisemblance. Pas d'existence : en logistique, si $\operatorname{rg} X = n$ les données sont toujours séparables et la vraisemblance tend vers son supremum sans l'atteindre. Le Lasso : pour $\lambda > 0$, $L_n + \lambda \|\beta\|_1$ est coercif ($L_n \geq 0$ en logistique), donc un minimiseur existe, et la pénalité sélectionne des variables. L'unicité, elle, n'est pas garantie (la norme ℓ_1 n'est pas strictement convexe) ; c'est le Ridge qui la garantit (hessienne $\succeq 2\lambda I_p$).

18. Écrivez les conditions KKT du Lasso d'un GLM canonique pour le critère $L_n(\beta) + \lambda \|\beta\|_1$. Pourquoi le seuil est-il λ et non $\lambda/2$ comme en séance 2 ?

Réponse

$\frac{1}{n} X_j^\top (y - \hat{\mu}) = \lambda \operatorname{sgn}(\hat{\beta}_j)$ si $\hat{\beta}_j \neq 0$ et $\left|\frac{1}{n} X_j^\top (y - \hat{\mu})\right| \leq \lambda$ si $\hat{\beta}_j = 0$, avec $\hat{\mu} = \mu(\hat{\beta})$. En séance 2, le critère $\|Y - X\beta\|^2 + \lambda \|\beta\|_1$ fait sortir un facteur 2 de la dérivée du carré ($2X_j^\top (Y - X\hat{\beta}) = \lambda \operatorname{sgn} \hat{\beta}_j$) ; ici le critère est en $\frac{1}{n}$ et la dérivée de $A(\eta) - y\eta$ vaut $\mu - y$, sans facteur 2.

19. Citez deux choses qui ne changent pas et trois qui changent quand on passe du Lasso linéaire au Lasso d'un GLM.

Réponse

Ne changent pas : la convexité (KKT nécessaires et suffisantes), la lecture « corrélation avec le résidu plafonnée à λ », l'existence d'un $\lambda_{\max}$, la parcimonie. Changent : le résidu $y - \mu(\beta)$ est non linéaire en β (pas de seuillage doux, même en design orthogonal) ; le chemin de régularisation est courbe ; le calcul est itératif (IRLS + Lasso pondéré) ; la hessienne $\frac{1}{n} X^\top W(\beta) X$ varie, et la théorie demande plus d'hypothèses.

20. Lasso logistique sans constante, critère $\frac{1}{n}\sum_i \log(1+e^{-y_i x_i^\top \beta}) + \lambda \|\beta\|_1$, avec $X = \begin{pmatrix} 2 & 1 \\ 0 & 1 \\ 1 & 0 \\ -1 & 1 \end{pmatrix}$ (lignes $x_i^\top$) et les étiquettes 0/1 $\tilde{y} = (1,0,1,0)$. Que vaut $\lambda_{\max}$? Quelle variable entre la première, avec quel signe ?

Réponse

En codage ± 1 : $y = 2\tilde{y} - \mathbf{1} = (1,-1,1,-1)$, et $X^\top y = (2+0+1+1\,;\,1-1+0-1) = (4\,;-1)$. Donc $\lambda_{\max} = \frac{1}{2n}\|X^\top y\|_\infty = \frac{4}{8} = 0{,}5$ (même chose que $\left\|\frac{1}{n}X^\top(\tilde{y} - \frac{1}{2}\mathbf{1})\right\|_\infty$, ce vecteur valant $(0{,}5\,;-0{,}125)$). La variable 1 atteint la première le plafond ; elle entre avec un coefficient positif.

21. Donnez la perte logistique f, ses dérivées f' et f'', et l'encadrement de f''. Pourquoi a-t-on $\mathbb{P}(Y = y \mid x) = \sigma(y\, x^\top \beta)$ en codage ± 1 ?

Réponse

$f(z) = \log(1+e^{-z})$, $f'(z) = -\sigma(-z)$, $f''(z) = \sigma(z)(1-\sigma(z)) \in]0, \frac{1}{4}]$, maximum $\frac{1}{4}$ en $z = 0$. Comme $\sigma(-z) = 1 - \sigma(z)$: pour $y = 1$ on obtient $\sigma(x^\top\beta)$, pour $y = -1$ on obtient $\sigma(-x^\top\beta) = 1 - \sigma(x^\top\beta)$. Repères : $f(0) = \log 2 \approx 0{,}693$, $f(2) \approx 0{,}127$, $f(-2) \approx 2{,}127$.

22. Pourquoi le Ridge logistique a-t-il une solution unique, même si $p > n$? A-t-il une formule fermée ?

Réponse

La hessienne du critère est celle de la partie logistique ($\succeq 0$) plus $2\lambda I_p$, donc $\succeq 2\lambda I_p$: le critère est fortement convexe, donc au plus un minimiseur, quel que soit le rang de X. Il est coercif (perte ≥ 0, $\lambda\|\beta\|^2 \to \infty$), donc un minimiseur existe. Pas de formule fermée : l'équation $\nabla = 0$ contient β à l'intérieur de σ (avec le critère du TD3 : $X^\top(Y - \sigma(X\beta)) = 2\lambda\beta$) ; on le calcule par Newton = IRLS pénalisé.

23. Montrez que $\inf_\beta W_{ii}(\beta) = 0$ en régression logistique. Pourquoi est-ce gênant pour les vitesses rapides ?

Réponse

Pour $x_i \neq 0$, prenez $\beta = t\, x_i$: $x_i^\top \beta = t\,\|x_i\|^2 \to +\infty$, donc $\pi_i \to 1$ et $W_{ii} = \pi_i(1-\pi_i) \to 0$; comme $W_{ii} > 0$ partout, l'infimum vaut 0 sans être atteint. Les vitesses rapides demandent une courbure minorée pour transformer « petit excès de risque » en « $\hat{\beta}$ proche de β_0 » ; si les W_{ii} s'effondrent, la cuvette s'aplatit : il faut RE plus des bornes sur les covariables et les prédicteurs linéaires. L'inégalité lente, elle, s'en passe.

24. TD3, exercice 2 : à quelles variables applique-t-on Hoeffding pour contrôler V_j, dans quel intervalle vivent-elles, et quelle borne obtient-on pour $\mathbb{P}(|V_j| > \lambda/2)$?

Réponse

À $X_i = z_{ij} Y_i$ (j fixé), indépendantes, dans l'intervalle d'extrémités 0 et z_{ij}, de longueur $|z_{ij}| \le c$; $\sum_i (X_i - \mathbb{E}X_i) = n V_j$. Hoeffding avec $x = n\lambda/2$: $\mathbb{P}(|V_j| > \lambda/2) \le 2\exp\big(-\frac{2(n\lambda/2)^2}{nc^2}\big) = 2\exp\big(-\frac{n\lambda^2}{2c^2}\big)$, puis la borne de l'union donne $\mathbb{P}(\mathcal{A}^c) \le 2p\, e^{-n\lambda^2/(2c^2)}$.

25. TD3, exercice 2 : $p = 1000$, $c = 1$, $A = 2$, $n = 10\,000$. A est-il admissible ? Que valent λ et la probabilité garantie ? Que donne la borne avec $\beta = \beta_0$ si $\|\beta_0\|_1 = 3$?

Réponse

Oui : $A = 2 > \sqrt{2}\, c \approx 1{,}414$. $\lambda = 2\sqrt{\log(1000)/10\,000} \approx 2 \times 0{,}0263 \approx 0{,}0526$. Probabilité $\ge 1 - 2 \cdot 1000^{1-4/2} = 1 - \frac{2}{1000} = 0{,}998$. Borne : $R(\hat\beta) - R(\beta_0) \le 2\lambda \|\beta_0\|_1 \approx 2 \times 0{,}0526 \times 3 \approx 0{,}315$.

26. TD3, exercice 2 : pourquoi choisir l'événement $\{\max_j |V_j| \le \lambda/2\}$ plutôt que $\{\max_j |V_j| \le \lambda\}$?

Réponse

Les deux donnent l'inégalité lente (le second avec une probabilité même meilleure, $1 - 2p^{1-2A^2/c^2}$). Mais $\lambda/2$ laisse une marge : le bruit ne consomme que la moitié de la pénalité. Avec $\beta = \beta_0$ et $R(\hat\beta) - R(\beta_0) \ge 0$, on obtient le cône $\|\delta_{J_0^c}\|_1 \le 3\,\|\delta_{J_0}\|_1$, porte d'entrée de RE$(s, 3)$ et des vitesses rapides ; avec λ, on n'obtient que $0 \le 2\lambda\,\|\delta_{J_0}\|_1$, aucun cône. Même mécanisme que dans le théorème BRT.

27. TD3, exercice 3 : Lasso de Poisson avec $\frac{1}{n}X^\top(Y - \mathbf{1}) = (-0{,}4\,;\,0{,}25\,;\,0{,}1)$. Que vaut $\lambda_{\max}$? Quelle variable entre la première, avec quel signe ? Pour $\lambda = 0{,}3$, le vecteur nul est-il solution ?

Réponse

En $\beta = 0$, $\hat\mu = \mathbf{1}$, et les KKT demandent $\big|\frac{1}{n}X_j^\top(Y - \mathbf{1})\big| \le \lambda$ pour tout j : $\lambda_{\max} = 0{,}4$. La variable 1 entre la première, avec un coefficient **négatif** (KKT d'une variable active : $\frac{1}{n}X_1^\top(Y - \hat\mu) = \lambda\,\mathrm{sgn}(\hat\beta_1)$, et cette quantité vaut environ $-0{,}4 < 0$). Pour $\lambda = 0{,}3 < 0{,}4$: non, la condition échoue pour $j = 1$.

28. Vrai ou faux : « si $\hat\beta_j = 0$, alors $\big|\frac{1}{n}X_j^\top(Y - \hat\mu)\big| < \lambda$ ».

Réponse

Faux : $\hat\beta_j = 0$ impose seulement $\le \lambda$. Exemple : le TD3 avec $\lambda = \lambda_{\max} = 0{,}3$; $\hat\beta = 0$ est solution et pourtant $\big|\frac{1}{n}X_1^\top(Y - \mathbf{1})\big| = 0{,}3 = \lambda$ (variable sur le point d'entrer). Le vrai sens est l'autre : une inégalité **stricte** force $\hat\beta_j = 0$ (principe des règles d'élimination, *screening*).

Séance 6 → la fiche

1. Citez les quatre défauts du Lasso et, pour chacun, la ou les variantes qui le corrigent.

Réponse

(1) Biais sur les gros coefficients (le seuillage doux retire $\lambda/2$ à tout coefficient gardé) : LSLasso, Lasso relaxé, Lasso adaptatif. (2) Au plus n variables quand $p > n$: elastic net. (3) Variables corrélées (une seule gardée, au hasard ; colonne dupliquée ⇒ infinité de solutions) : elastic net. (4) Structure ignorée : group-Lasso (groupes), Lasso fusionné (voisins égaux).

2. Écrivez le critère bridge $C_{\lambda,\gamma}$, y compris le cas $\gamma = 0$. Quelles méthodes retrouve-t-on pour $\gamma = 0, 1, 2$?

Réponse

$C_{\lambda,\gamma}(\beta) = \|Y - X\beta\|^2 + \lambda \|\beta\|_\gamma^\gamma$ avec $\|\beta\|_\gamma^\gamma = \sum_j |\beta_j|^\gamma$ si $\gamma > 0$ et $\sum_j \mathbf{1}\{\beta_j \neq 0\}$ si $\gamma = 0$; $\hat{\beta}^{\text{Bridge}} = \arg\min_\beta C_{\lambda,\gamma}(\beta)$. $\gamma = 0$: sélection de modèle ($\ell 0$) ; $\gamma = 1$: Lasso ; $\gamma = 2$: Ridge.

3. Pour quels γ le critère bridge est-il convexe ? Pour quels γ produit-il des coordonnées exactement nulles ? Qu'en conclure ?

Réponse

Convexe ⇔ $\gamma \geq 1$ (strictement convexe si $\gamma > 1$). Zéros exacts ⇔ $\gamma \leq 1$ (pénalité pointue en 0). Seul $\gamma = 1$, le Lasso, a les deux propriétés : calculable *et* sélectif.

4. Montrez en une ligne que $\{\beta \in \mathbb{R}^2 : \ |\beta_1|^{1/3} + |\beta_2|^{1/3} \leq 1\}$ n'est pas convexe.

Réponse

$(1, 0)$ et $(0, 1)$ sont dans l'ensemble ; leur milieu donne $2 \cdot \left(\frac{1}{2}\right)^{1/3} = 2^{2/3} \approx 1{,}59 > 1$: il en sort.

5. Diapo 75 : pourquoi, pour $\gamma > 1$, toutes les coordonnées de l'estimateur bridge sont-elles presque sûrement non nulles ?

Réponse

La pénalité $\lambda |\beta_j|^\gamma$ est dérivable, de dérivée $\lambda\gamma |\beta_j|^{\gamma-1} \operatorname{sgn}(\beta_j)$, nulle en $\beta_j = 0$. Une coordonnée nulle à l'optimum exigerait donc $2X_j^\top (Y - X\hat{\beta}) = 0$ exactement, un événement de probabilité nulle quand le bruit a une densité.

6. Diapo 75 : sous quelle hypothèse le Lasso a-t-il un unique minimiseur ? Pourquoi ? Est-ce possible si $p > n$?

Réponse

Si X est injective ($\operatorname{Ker} X = \{0\}$, soit $\operatorname{rg} X = p$) : la hessienne $2X^\top X$ de l'ajustement est définie positive, donc le critère est strictement convexe et a au plus un minimiseur (il en a un par coercivité). C'est impossible si $p > n$ ($\operatorname{rg} X \leq n < p$) : le Lasso peut alors avoir plusieurs solutions (colonne dupliquée).

7. Démontrez $\|Y - X\beta\|^2 = (\beta - \hat\beta^{\mathrm{MC}})^\top X^\top X(\beta - \hat\beta^{\mathrm{MC}}) + \left\|Y - X\hat\beta^{\mathrm{MC}}\right\|^2$. Quelle propriété des moindres carrés sert ?

Réponse

$Y - X\beta = \hat r + X(\hat\beta^{\mathrm{MC}} - \beta)$ avec $\hat r = Y - X\hat\beta^{\mathrm{MC}}$; on développe le carré. Le terme croisé $2\hat r^\top X(\hat\beta^{\mathrm{MC}} - \beta) = 2(X^\top \hat r)^\top(\hat\beta^{\mathrm{MC}} - \beta)$ est nul grâce aux **équations normales** $X^\top \hat r = 0$, et $\left\|X(\hat\beta^{\mathrm{MC}} - \beta)\right\|^2 = (\beta - \hat\beta^{\mathrm{MC}})^\top X^\top X(\beta - \hat\beta^{\mathrm{MC}})$.

8. Design orthonormé, $b = X^\top Y = (3;\ -1{,}2;\ 0{,}5)$ et $\lambda = 2$. Calculez le Lasso, le LSLasso, la sélection $\ell 0$ (bridge $\gamma = 0$, même λ) et le Ridge.

Réponse

Lasso (seuil doux $\lambda/2 = 1$) : $(2;\ -0{,}2;\ 0)$. LSLasso (seuil dur $\lambda/2 = 1$) : $(3;\ -1{,}2;\ 0)$. $\ell 0$ (seuil dur $\sqrt{\lambda} = \sqrt{2} \approx 1{,}41$) : $(3;\ 0;\ 0)$. Ridge ($b/(1+\lambda) = b/3$) : $(1;\ -0{,}4;\ \approx 0{,}17)$, aucun zéro.

9. Même $b = (3;\ -1{,}2;\ 0{,}5)$, même $\lambda = 2$: calculez le Lasso relaxé avec $\delta = 0{,}5$, puis le Lasso adaptatif avec $\tilde\beta = b$.

Réponse

Relaxé : on garde $|b_j| > 1$ et on retire $\delta\lambda/2 = 0{,}5$: $(2{,}5;\ -0{,}7;\ 0)$. Adaptatif : seuils $\lambda/(2\,|b_j|) = \frac{1}{3}$; $\frac{1}{1{,}2} \approx 0{,}83$; 2, d'où $(\approx 2{,}67;\ \approx -0{,}37;\ 0)$. Vérification : l'adaptatif garde exactement les $|b_j| > \sqrt{\lambda/2} = 1$.

10. Même b : calculez l'elastic net avec $\lambda_1 = 2$, $\lambda_2 = 1$, sans puis avec la correction $(1 + \lambda_2)$, et le sélecteur de Dantzig avec $\lambda = 2$.

Réponse

Elastic net naïf = Lasso$(\lambda_1)/(1+\lambda_2)$ = $(2;\ -0{,}2;\ 0)/2 = (1;\ -0{,}1;\ 0)$. Corrigé ($\times 2$) : $(2;\ -0{,}2;\ 0)$, exactement le Lasso. Dantzig = Lasso en design orthonormé : $(2;\ -0{,}2;\ 0)$.

11. Un très gros coefficient : $b_j = 10$, $\lambda = 2$. Quel biais $|b_j| - \left|\hat{\beta}_j\right|$ commettent le Lasso, le LSLasso, le Lasso relaxé ($\delta = 0{,}3$) et le Lasso adaptatif ($\tilde{\beta} = b$) ?

Réponse

Lasso : $\lambda/2 = 1$. LSLasso : 0. Relaxé : $\delta\lambda/2 = 0{,}3$. Adaptatif : $\lambda/(2\,|b_j|) = 0{,}1$, qui tend vers 0 quand $|b_j|$ grandit.

12. Vrai ou faux, en design orthonormé : « Lasso, LSLasso, Lasso relaxé et Lasso adaptatif ($\tilde{\beta} = b$) sélectionnent toujours les mêmes variables. »

Réponse

Faux, à cause de l'adaptatif. Lasso, LSLasso et relaxé ont la même zone morte $|b_j| \le \lambda/2$: mêmes variables. L'adaptatif garde $|b_j| > \sqrt{\lambda/2}$, seuil égal à $\lambda/2$ seulement si $\lambda = 2$. Contre-exemple : $\lambda = 1$, $b_j = 0{,}6$; le Lasso garde ($0{,}6 > 0{,}5$, $\hat{\beta}_j = 0{,}1$), l'adaptatif tue ($0{,}6 < \sqrt{0{,}5} \approx 0{,}71$).

13. Définissez le sélecteur de Dantzig, puis montrez que $\left\|\hat{\beta}^D(\lambda)\right\|_1 \le \left\|\hat{\beta}^L(\lambda)\right\|_1$.

Réponse

$D_\lambda = \{\beta : \left\|2X^\top(Y - X\beta)\right\|_\infty \le \lambda\}$ et $\hat{\beta}^D(\lambda) = \arg\min_{\beta \in D_\lambda} \|\beta\|_1$. Les KKT du Lasso donnent $\left|2X_j^\top(Y - X\hat{\beta}^L)\right| \le \lambda$ pour tout j (égalité sur les variables actives), donc $\hat{\beta}^L \in D_\lambda$; comme $\hat{\beta}^D$ minimise $\|\cdot\|_1$ sur D_λ, $\left\|\hat{\beta}^D\right\|_1 \le \left\|\hat{\beta}^L\right\|_1$.

14. Design orthonormé, $b = (1{,}5;\ -0{,}3)$, $\lambda = 1$: décrivez D_λ et calculez $\hat{\beta}^D$. Puis : pourquoi Dantzig est-il un programme linéaire ?

Réponse

$2X^\top(Y - X\beta) = 2(b - \beta)$, donc $D_\lambda = \{|\beta_j - b_j| \le 0{,}5\} = [1;\ 2] \times [-0{,}8;\ 0{,}2]$. On minimise chaque $|\beta_j|$ sur son intervalle : $\hat{\beta}^D = (1;\ 0)$, qui est bien le Lasso (seuil doux à 0,5). Programme linéaire : avec $\beta = \beta^+ - \beta^-$, $\beta^\pm \ge 0$, l'objectif $\sum_j(\beta_j^+ + \beta_j^-)$ est linéaire et chaque contrainte $\left|2X_j^\top(Y - X\beta)\right| \le \lambda$ donne deux inégalités linéaires. Le Lasso contient le terme quadratique $\|Y - X\beta\|^2$.

15. Comment calculer un Lasso adaptatif de poids $\omega_j > 0$ avec un logiciel qui ne sait faire que le Lasso standard ?

Réponse

Diviser chaque colonne par son poids : $\tilde{X}_j = X_j/\omega_j$, et poser $\gamma_j = \omega_j\beta_j$. Alors $X\beta = \tilde{X}\gamma$ et $\sum_j \omega_j\,|\beta_j| = \|\gamma\|_1$: on résout le Lasso standard $\left\|Y - \tilde{X}\gamma\right\|^2 + \lambda\,\|\gamma\|_1$, puis $\hat{\beta}_j = \hat{\gamma}_j/\omega_j$.

16. Deux colonnes identiques : $\tilde{X} = [x, x]$ avec $\|x\| = 1$ et $x^\top Y = 2{,}5$. Trouvez toutes les solutions du Lasso $\left\|Y - \tilde{X}\beta\right\|^2 + \|\beta\|_1$ ($\lambda = 1$), puis la solution de l'elastic net avec $\lambda_1 = 1$, $\lambda_2 = 2$.

Réponse

Seule $c = \beta_1 + \beta_2$ compte dans l'ajustement : $\|Y - cx\|^2 = \|Y\|^2 - 5c + c^2$, et $|\beta_1| + |\beta_2| \geq |c|$, avec égalité ssi β_1, β_2 ont le même signe. Le minimum en c de $c^2 - 5c + |c|$ est le seuillage doux $c = 2{,}5 - 0{,}5 = 2$. Lasso : tout le segment $\{(2\alpha,\ 2(1-\alpha)) : \alpha \in [0,1]\}$, une infinité de solutions. Elastic net : partage égal $\beta_1 = \beta_2 = c/2$, critère $c^2 - 5c + |c| + 2 \cdot \frac{c^2}{2} = 2c^2 - 5c + |c|$, minimal en $c = 1$: solution unique $(0{,}5;\ 0{,}5)$.

17. Pourquoi le critère de l'elastic net est-il strictement convexe sans aucune hypothèse sur X ? Qu'est-ce que cela apporte ?

Réponse

$\lambda_2 \|\beta\|_2^2$ est strictement convexe (hessienne $2\lambda_2 I_p \succ 0$) et les deux autres termes sont convexes : la somme est strictement convexe, donc a au plus un minimiseur ; elle est continue et coercive, donc en a un. Solution unique et stable : plus de choix arbitraire entre variables corrélées (le Lasso a une infinité de solutions avec une colonne dupliquée).

18. Retrouvez la règle de l'elastic net en design orthonormé. Pourquoi Zou et Hastie corrigent-ils par $(1 + \lambda_2)$?

Réponse

$(\beta - b)^2 + \lambda_1 |\beta| + \lambda_2 \beta^2 = (1 + \lambda_2)\left[(\beta - \frac{b}{1+\lambda_2})^2 + \frac{\lambda_1}{1+\lambda_2} |\beta|\right] + \text{cte}$, d'où $\hat{\beta} = \frac{\operatorname{sgn}(b)(|b| - \lambda_1/2)_+}{1+\lambda_2}$. C'est un double rétrécissement : seuillage doux (Lasso) puis division par $1 + \lambda_2$ (Ridge). Multiplier par $1 + \lambda_2$ annule le second ; en design orthonormé on retrouve exactement le Lasso.

19. Pourquoi le Lasso garde-t-il au plus n variables quand $p > n$? Pourquoi l'elastic net peut-il en garder davantage ?

Réponse

Il existe toujours une solution du Lasso dont les colonnes actives sont linéairement indépendantes : si elles sont liées, on se déplace selon un v du noyau supporté par le support (ajustement inchangé, pénalité $\ell 1$ constante) jusqu'à annuler une coordonnée. Au plus $\operatorname{rg} X \leq n$ variables. L'elastic net est un Lasso sur les données augmentées $X^* = (1 + \lambda_2)^{-1/2} \begin{pmatrix} X \\ \sqrt{\lambda_2}\, I_p \end{pmatrix}$, de rang p : la limite devient p.

20. Écrivez les conditions de la diapo 87 qui caractérisent le group-Lasso. Que deviennent-elles pour des groupes de taille 1 ?

Réponse

Pour tout k : $2X_{(k)}^\top(Y - X\hat\beta) = \lambda\,\hat\beta_{(k)}/\left\|\hat\beta_{(k)}\right\|_2$ si $\hat\beta_{(k)} \neq 0$, et $\left\|2X_{(k)}^\top(Y - X\hat\beta)\right\|_2 \leq \lambda$ si $\hat\beta_{(k)} = 0$. Pour un groupe $\{j\}$: $\hat\beta_{(k)}/\left\|\hat\beta_{(k)}\right\| = \operatorname{sgn}(\hat\beta_j)$ et la norme devient une valeur absolue : ce sont les KKT du Lasso, $2X_j^\top(Y - X\hat\beta) = \lambda\operatorname{sgn}(\hat\beta_j)$ ou $\left|2X_j^\top(Y - X\hat\beta)\right| \leq \lambda$.

21. Design orthonormé, $\lambda = 6$, deux groupes : $b_{(1)} = (3,\ 4)$ et $b_{(2)} = (2,\ -2,\ 1)$. Calculez le group-Lasso, puis le Lasso de même λ, et comparez.

Réponse

Seuil $\lambda/2 = 3$. $\left\|b_{(1)}\right\| = 5 > 3$: facteur $1 - \frac{6}{10} = 0{,}4$, d'où $\hat\beta_{(1)} = (1{,}2;\ 1{,}6)$. $\left\|b_{(2)}\right\| = 3 \leq 3$: $\hat\beta_{(2)} = (0, 0, 0)$. Le Lasso (seuil 3 par coordonnée) donne $(0;\ 1;\ 0;\ 0;\ 0)$: il tue la première variable du groupe 1, alors que le group-Lasso garde le bloc entier, rétréci dans sa direction.

22. Pourquoi le group-Lasso pénalise-t-il $\left\|\beta_{(k)}\right\|_2$ et non $\left\|\beta_{(k)}\right\|_2^2$?

Réponse

Avec le carré, $\sum_k \left\|\beta_{(k)}\right\|_2^2 = \|\beta\|_2^2$: c'est le Ridge, aucun zéro. La norme non carrée est pointue en 0 (son sous-différentiel en 0 est toute la boule unité) : elle retient un bloc entier exactement en 0. À l'intérieur d'un bloc gardé, elle est lisse : pas de zéro coordonnée par coordonnée.

23. Lasso fusionné : à quoi sert la seconde pénalité ? Avec $X = I_2$, $\lambda_1 = 0$ et $y = (3,\ 1)$, calculez la solution pour $\lambda_2 = 1$, puis pour $\lambda_2 = 3$.

Réponse

$\lambda_2 \sum_j |\beta_j - \beta_{j-1}|$ est une pénalité $\ell 1$ sur les différences : beaucoup de voisins deviennent exactement égaux, l'estimation est constante par morceaux (ruptures). Ici $\bar y = 2$, $\Delta = y_1 - y_2 = 2$. $\lambda_2 = 1 < 2$: l'écart passe à $2 - 1 = 1$, chacun se rapproche de $0{,}5$: $(2{,}5;\ 1{,}5)$. $\lambda_2 = 3 \geq 2$: fusion, $(2;\ 2)$.

24. LSLasso : pourquoi la validation croisée doit-elle porter sur toute la procédure, et pas seulement sur le Lasso ?

Réponse

Réglé pour le Lasso seul, λ est plutôt petit : on rétrécit moins les bons coefficients, quitte à laisser entrer des variables de bruit avec des coefficients minuscules. Le réajustement par moindres carrés donne à ces variables leur coefficient plein : surapprentissage. Il faut évaluer, pour chaque λ, l'estimateur complet (Lasso puis moindres carrés) sur les plis de validation.

25. Vrai ou faux : « En design orthonormé, le LSLasso de paramètre λ et la sélection $\ell 0$ de paramètre $\lambda^2/4$ coïncident. »

Réponse

Vrai. Le LSLasso est le seuillage dur au seuil $\lambda/2$; la sélection $\ell 0$ de paramètre λ' est le seuillage dur au seuil $\sqrt{\lambda'}$; ils coïncident ssi $\sqrt{\lambda'} = \lambda/2$, soit $\lambda' = \lambda^2/4$. En design orthonormé, le LSLasso résout donc le problème combinatoire sans explorer les 2^p modèles.

Le jour J

Méthode — En ouvrant un exercice

1. **Écrivez le cadre** : le modèle, la convention exacte du critère, les hypothèses données (normalisation des colonnes, bruit, parcimonie, RE...).
2. **Reconnaissez le type d'exercice** dans le tableau ci-dessous et **annoncez la méthode** en une phrase avant de calculer. Si le calcul déraille, la démarche reste visible.
3. **Vérifiez sur un cas simple** : design orthonormé, $p = 1$, $\lambda = 0$ ou $\lambda \to \infty$.

On vous demande de…	Commencez par…
calculer un estimateur pénalisé en design orthonormé	$\|Y - X\beta\|^2 = \|\beta - b\|^2 + \text{cte}$ avec $b = X^\top Y$; découpler coordonnée par coordonnée (ou groupe par groupe) ; trois cas $\beta_j > 0$, $\beta_j < 0$, $\beta_j = 0$; vérifier la cohérence de chaque cas.
montrer qu'un vecteur est solution, ou trouver le λ qui annule tout	Conditions KKT : $0 \in \partial F(\hat\beta)$, coordonnée par coordonnée (égalité si $\hat\beta_j \neq 0$, inégalité si $\hat\beta_j = 0$) ; le critère est convexe, donc elles suffisent. Pour $\lambda_{\max}$: les KKT au point $\hat\beta = 0$ (résidu Y, ou $y - \mu(0)$ pour un GLM).
borner une erreur de prédiction ou d'estimation	Inégalité de base ; $Y = X\beta^* + \varepsilon$ et développement ; Hölder sur le terme croisé et événement $\{\left\|\frac{2}{n}X^\top\varepsilon\right\|_\infty \leq \dots\}$; découpage selon le support (cône) ; RE ; $u^2 \leq cu \Rightarrow u \leq c$, ou Young.
minorer la probabilité de l'événement	Loi de $X_j^\top\varepsilon$ (gaussienne centrée de variance $\sigma^2\|X_j\|^2$), queue $\mathbb{P}(\|Z\| \geq z) \leq 2e^{-z^2/2}$ (TD2 ; la séance 3 utilise la version plus fine $e^{-z^2/2}$), ou Hoeffding si les Y_i sont bornées ; borne de l'union sur les p colonnes, puis réglage de λ.
calculer une espérance de norme au carré	Biais² + variance ; $\mathbb{E}[\varepsilon^\top M\varepsilon] = \sigma^2 \operatorname{tr} M$ (ε centré, $\operatorname{Cov}\varepsilon = \sigma^2 I_n$) ; pour un projecteur $\operatorname{tr} P = \operatorname{rg} P$.
traiter un GLM	Forme $\exp(\theta y - A(\theta) + B(y))$; A' = moyenne, A'' = variance ; lien canonique $(A')^{-1}$; log-vraisemblance ; avec le lien canonique, gradient $X^\top(y - \mu)$, hessienne $-X^\top W X$; ℓ concave, donc $-\ell$ convexe ; KKT si pénalisé.
passer de la forme pénalisée à la forme contrainte (ou l'inverse)	Comparer les critères en la solution de l'autre problème ; conclure par l'unicité (Ridge) ou par l'égalité des normes ℓ_1 de toutes les solutions (Lasso).

On vous demande de…	Commencez par…
commenter un résultat	Vitesse (en $s \log p/n$, ou $\|\beta\|_1 \sqrt{\log p/n}$), comparaison avec l'oracle $\sigma^2 s/n$, rôle de chaque hypothèse (κ, normalisation, parcimonie), probabilité, ce que le résultat ne dit pas (sélection exacte du support…).

Réflexe — Avant de rendre la copie

- ☐ Chaque énoncé de théorème a ses hypothèses, son λ et sa probabilité.
- ☐ Les signes des KKT ($Y - X\hat{\beta}$ et non $X\hat{\beta} - Y$) et les facteurs 2 sont cohérents avec le critère écrit en tête.
- ☐ Chaque hypothèse donnée par l'énoncé a servi quelque part (sinon, cherchez l'étape qui l'utilise).
- ☐ Les ordres de grandeur sont plausibles : un λ en $\sigma\sqrt{\log p/n}$; une erreur de prédiction $\frac{1}{n}\|X\delta\|^2$ en $s \log p/n$ (vitesse rapide) ou en $\|\beta\|_1 \sqrt{\log p/n}$ (vitesse lente).

Statistiques avancées 3A (CentraleSupélec, S. Lemler) — guide d'étude pédagogique, version 2. Les numéros de diapositives renvoient aux fichiers Cours1.pdf … Cours6.pdf du dossier parent.